RとJASPで学ぶフリーで楽しい心理統計の世界

心理学データ解析 基礎 v3

「見えないもの」をみよう・測ろう・考えよう

小杉考司

この本は Creative Commons BY-SA(CC BY-SA) ライセンス Version 4.0 に基づいて提供されています。著者に適切なクレジットを与える限り，この本を再利用，再編集，保持，改訂，再頒布 (商用利用を含む) をすることができます。もし再編集したり，このオープンなテキストを変更したい場合，すべてのバージョンにわたってこれと同じライセンス，CC BY-SA を適用しなければなりません。

https://creativecommons.org/licenses/by-sa/4.0/deed.ja

This book is published under a Creative Commons BY-SA license (CC BY-SA) version 4.0. This means that this book can be reused, remixed, retained, revised and redistributed (including commercially) as long as appropriate credit is given to the authors. If you remix, or modify the original version of this open textbook, you must redistribute all versions of this open textbook under the same license - CC BY-SA.

https://creativecommons.org/licenses/by-sa/4.0/

心理学データ解析基礎

小杉　考司

Last Compiled on 2026.10.21

はじめに

授業のテーマ

「見えないもの」をみよう・測ろう・考えようとするのが心理統計の世界である。

一年を通じて伝えたいポイント

母数を知るための推測　大学での統計，心理統計は標本の記述統計量を検証したいのではなく，母集団を表す数字を求めるための推測統計である。

確率を用いた推論　母数を知るための方法は 3 つある。代表値を用いたモーメント法，確率分布をつかった最尤法，ベイズ法である。

要因計画と線形モデル　心理学では，要因計画による研究条件をコントロールし，平均値の差をもちいた考察 (平均因果効果) をおこなうことが多い。そしてそれらは総じて線形モデルとして表現できる。

モデル比較と意思決定　モデルによる母数の推定だけではなく，そこから一定の「結論」あるいは「意思決定」を行うための方法として，モデル比較や NHST といった方法がある。

統計環境 R による実践　統計環境 R を利用して，理論的な理解だけでなく実際に計算ができることも身につけるべき技術である。

なお，各コマにおける「標準シラバスにおける位置づけ」とは，公認心理師大学カリキュラム　標準シラバス (2018 年 8 月 22 日版)[*1] との対応を表しています。

その他

授業シラバスとこの講義資料を掲載したサイト (https://kosugitti.github.io/psychometrics_syllabus/) で，最新版のシラバスと授業資料，授業で用いるサンプルデータやコードの配布を行なっています。

[*1] https://psych.or.jp/wp-content/uploads/2018/04/standard_syllabus_2018-8-22.pdf

目次

第 I 部　心理学データ解析基礎 1A(心理学統計法) 9

第 1 章　心理統計を始める前に 11
1.1 はじめに . . . 11
1.2 心理学とはどういう学問か . . . 12
1.3 近代科学の特徴 . . . 13
1.4 心理学のいとなみ . . . 15
1.5 課題 . . . 16

第 2 章　電子計算機の基礎 17
2.1 授業の目的 . . . 17
2.2 コンピュータの基礎 . . . 18
2.3 情報の単位 . . . 21
2.4 ファイルの種類と拡張子 . . . 23
2.5 ファイルの場所 . . . 24
2.6 ファイルの位置の指定 . . . 26
2.7 キーボードとショートカット . . . 27
2.8 まとめ . . . 29

第 3 章　統計環境 R の導入 33
3.1 統計環境 R/RStudio の準備 . . . 33
3.2 R/RStudio の基本操作 . . . 35
3.3 R の基本操作 . . . 43
3.4 再現性のある研究実践へ . . . 49
3.5 課題 . . . 51

第 4 章　数値データの種類 53
4.1 データと変数 . . . 53
4.2 計算機と統計の観点による分類 . . . 56
4.3 尺度水準による分類 . . . 58
4.4 コンピュータのデータ型と尺度水準の関係 . . . 60
4.5 課題 . . . 64

第 5 章　記述統計量 65

5.1 中心化傾向の指標 . . . 66
5.2 散らばりの指標 . . . 69
5.3 R による集計 . . . 73
5.4 R による統計量の算出 . . . 75
5.5 R によるデータの可視化 . . . 76
5.6 課題 . . . 77
5.7 補遺 . . . 78

第 6 章 さまざまな相関係数と R による実践 83
6.1 二変数間関係の指標 . . . 83
6.2 変数間関係の指標 . . . 84
6.3 相関係数:標準化された共分散 . . . 86
6.4 尺度水準に応じた相関係数 . . . 90
6.5 R による相関分析の実践 . . . 93
6.6 相関の落とし穴と可視化の重要性 . . . 98
6.7 課題 . . . 102

第 7 章 回帰分析の基礎 103
7.1 相関関係とモデル . . . 103
7.2 予測と線形モデル . . . 106
7.3 最小二乗法 . . . 107
7.4 残差と決定係数 . . . 109
7.5 相関関係と因果関係 . . . 110
7.6 課題 . . . 113

第 8 章 重回帰分析 115
8.1 重回帰分析の基本 . . . 115
8.2 部分相関・偏相関・偏回帰係数 . . . 118
8.3 偏回帰係数と解釈 . . . 121
8.4 標準化された係数 . . . 123
8.5 今日のまとめ . . . 124
8.6 課題 . . . 124

第 9 章 R をつかった回帰分析 127
9.1 線形回帰の実行 . . . 129
9.2 回帰診断と Q-Q プロット . . . 131
9.3 残差をデータで確認しておこう . . . 133
9.4 重回帰分析 . . . 135
9.5 課題 . . . 138

第 10 章 確率と確率分布 141
10.1 確率と呼ばれる数字 . . . 141
10.2 確率分布 . . . 142

10.3 ベルヌーイ分布と二項分布 . . . 147
10.4 正規分布の形 . . . 149
10.5 正規分布の関数 . . . 154
10.6 標準正規分布の利用 . . . 156
10.7 課題 . . . 157
10.8 補遺 . . . 159

第 11 章 確率と統計的推論 163
11.1 母集団と標本 . . . 163
11.2 母集団分布とモデル . . . 166
11.3 標本分布と標準誤差 . . . 167
11.4 まとめ . . . 171
11.5 課題 . . . 171

第 12 章 推定 173
12.1 不偏推定量 . . . 173
12.2 点推定と標準誤差 . . . 175
12.3 標本だけから推測したい . . . 178
12.4 推定と検定の関係 . . . 179

第 13 章 検定 183
13.1 帰無仮説検定の手続き . . . 184
13.2 相関係数の検定 . . . 186
13.3 χ^2 検定 . . . 189
13.4 1 つの平均値の検定 . . . 191
13.5 結果の報告の仕方 . . . 194

第 14 章 帰無仮説検定の注意点 195
14.1 有意水準と p 値の解釈 . . . 195
14.2 結果の報告と解釈 . . . 196
14.3 検定における 2 種類の誤り . . . 198
14.4 効果量と例数設計 . . . 200

第 15 章 前期のまとめ 203

第 II 部 心理学データ解析基礎 1B 205

第 16 章 二群の平均値差 207
16.1 対応のある二群の平均値差の検定 . . . 207
16.2 対応のない二群の平均値差の検定 . . . 211
16.3 R による実践;対応のある t 検定 . . . 214
16.4 R による実践;対応のない t 検定 . . . 215
16.5 課題 . . . 220

第 17 章 実験計画法の基礎と RCT 223
17.1 ランダム化の意義と方法 . . . 223
17.2 用語の整理 . . . 225
17.3 効果はどのように評価するのか . . . 227
17.4 線形モデルとしてみた要因計画 . . . 229
17.5 課題 . . . 232

第 18 章 群間計画 (Between Design) と分散分析 235
18.1 一要因群間計画の平方和の分解 . . . 235
18.2 二要因群間計画と主効果 . . . 239
18.3 交互作用の理解と解釈 . . . 242
18.4 平方和の分解と変動の源泉 . . . 247
18.5 課題 . . . 248

第 19 章 F 検定/分散分析の基礎 251
19.1 検定統計量の算出 . . . 251
19.2 分散分析の手順 . . . 252
19.3 R で一要因群間計画の分析 . . . 255
19.4 R で下位検定 . . . 261
19.5 課題 . . . 262

第 20 章 R による分散分析 265
20.1 分散分析用の関数の導入 . . . 265
20.2 データの作りかた . . . 266
20.3 二要因 Between 計画の実際 . . . 269
20.4 分析結果の可視化 . . . 274
20.5 課題 . . . 278

第 21 章 群内計画 (Within Design) の理論 281
21.1 群内計画の基本構造 . . . 281
21.2 一要因群内モデルの平方和の分解 . . . 284
21.3 二要因群内モデルの例 . . . 284
21.4 群間計画と群内計画の比較 . . . 290
21.5 課題 . . . 293

第 22 章 R による Within デザインの分散分析 295
22.1 一要因 Within 計画の実際 . . . 295
22.2 二要因 Within 計画の実際 . . . 301
22.3 単純効果の分散分析表の分割 . . . 304
22.4 分散分析のまとめ . . . 308
22.5 課題 . . . 309

第 23 章 確率モデルと尤度 311
23.1 確率モデルによる推論 . . . 311

23.2 確率関数と尤度関数 . . . 312
23.3 最尤推定 . . . 313
23.4 対数尤度関数 . . . 314
23.5 正規分布の尤度関数 . . . 315
23.6 課題 . . . 320

第 24 章 尤度と線形モデル 321
24.1 回帰モデルの確率表現 . . . 321
24.2 回帰分析の最尤推定 . . . 324
24.3 線形モデルの拡張 . . . 329
24.4 一般化線形モデル . . . 332
24.5 課題 . . . 333

第 25 章 3 つめの推定法 337
25.1 ベイズの定理 . . . 337
25.2 ベイズの定理の意味 . . . 340
25.3 3 つの推定方法の比較 . . . 343
25.4 課題 . . . 347
25.5 補遺: ベイズの定理を使った推論の例 . . . 347

第 26 章 分布で推定する 351
26.1 事前分布と事後分布 . . . 351
26.2 事前分布と尤度の折衷 . . . 357
26.3 課題 . . . 358

第 27 章 ベイズで判断する 359
27.1 ベイズ法と帰無仮説検定 . . . 359
27.2 確信区間に基づく判断 . . . 362
27.3 ベイズファクター . . . 365
27.4 帰無仮説検定に対するベイズ法の利点 . . . 367
27.5 課題 . . . 370

第 28 章 JASP でベイズ分析を体験する 371
28.1 JASP の導入とインターフェイス . . . 372
28.2 記述統計と可視化 . . . 375
28.3 JASP による相関･回帰分析 . . . 378
28.4 ベイズファクターを使った検定 . . . 381

第 29 章 ベイズを実践する 387
29.1 ベイズを実践する方法 . . . 387
29.2 brms による実用的モデリング . . . 391
29.3 stan 言語を使ったプログラミング . . . 394
29.4 生成量による新しい仮説の立て方 . . . 399
29.5 補遺･ Stan 環境の準備 . . . 401

第 30 章 後期のまとめ 405

第 A 章 よくある質問とミスの例 409
A.1 Frequently Miss and Comments 409
A.2 Frequently Asked Questions;よくある質問と答え 413

第 B 章 ギリシア文字一覧 421

第 C 章 よいデータの形式とは 423

第 D 章 分散分析ワークシート 427

引用文献 432

索引 435

第 I 部

心理学データ解析基礎 1A(心理学統計法)

第 1 章

心理統計を始める前に

これから「心理統計学」を学んでいくわけですが，皆さんはそもそも心理学と統計学が深く関わっていることをイメージしていたでしょうか。もし心理学なのに数学の話があるの？ 心理学と統計になんの関係があるの？ と思った人は，そもそも心理学というのはどういうものをイメージしていたでしょうか。

第 1 回ではまず，心理学を学ぶにあたってなぜ統計学が必要なのかを考えます。そのためには，心理学が科学 (Science) であることを知る必要があります。科学であるとはどういうことかを理解し，そのために数量的表現が有用であることをしっかりと理解してもらわなければなりません。

1.1 はじめに

みなさん，心理統計の世界，いいえ心理学の世界へようこそいらっしゃいました。

みなさんは心理学という言葉を，はじめて聞いたのはいつだったのか覚えていないのではないでしょうか。それぐらい一般的に使われていますが，さてそこではどのようなことを研究しているのか，皆さんはどんなイメージをお持ちでしょうか。皆さんが何をきっかけで心理学を志したのかによって，それは随分と異なってくると思います。

ある人はテレビドラマ「逃げるは恥だが役に立つ」をみて，主人公の女性が心理学の大学院をでたことから興味を持ったのかもしれません。あるいはスクールカウンセラーが学校にいたから，なんなら少し相談に乗ってもらったから，心理職というのがどのようなものなのか興味を持ったのかもしれません。

あるいはまた，テレビドラマ「科捜研の女」をみて，主人公が働く科学捜査研究所における心理職を知ったのかもしれません[*1]。実際の科捜研における心理職は虚偽検出を行っており，これには (生理) 心理学の知見が生かされています。

他にも高校までの科目として，倫理や現代社会でフロイト，エビングハウス，マズローなどの名前を聞いた人もいるかもしれません。知らなくても今から学ぶので問題ないのですが，それでもフロイトとポリグラフ検査はどう繋がるんだろう，と首を傾げるひともいるでしょう。心理学の知見は他にも，進路相談・職業指導や，街中に溢れるいろいろな工業製品のデザイン，トリックアートから神経生理学，果ては AI(人工知能) などにも関わってきます。

たとえば法学部では法律の勉強をするだろうということはわかりますが，「心理学を学んでいるよ」と誰かに言ってみても「それは何をするの？ 」と聞かれ，「心が読めるのか」とからかわれることもあるかもしれません。道又 (2009)には，次のような一節があります。

[*1] 科捜研には物理，化学，法医，文書，心理の 5 職種があり，文書鑑定 (筆跡鑑定) と心理 (ポリグラフ検査) を一人の技師が兼ねているところもあります。

心理学を「盛岡名物わんこそば」だとしよう。わんこそばはうまいし，おもしろいし，実に素晴らしいものだ。しかし，十分な知識のない人が，わんこそばについて勝手に空想的なイメージ (かわいいちいさなお椀にはいったおいしいおそばなど) を形成して，何の心構えもなく実際のわんこそばを注文したらどうなるだろうか。それはきっとかなり恐ろしい体験に違いない。

皆さんはまるでこの人のように，こんなものが心理学だったのかと驚かれるのではないかと思います。心理学は**名前は知られているが中身を知られていない学問**なのです。心理学が自分のイメージと違うなと思った人，とくにイメージはなかった人，色々いると思いますが，皆さんが今持っているイメージはこの 4 年間ですっかり変わってしまうと思います。少なくとも最初のメッセージとして，ともかく色々な領域に触れて自分のイメージが変わることを恐れないでください，ということを伝えておきたいと思います。(心理) 統計なんて嫌だよ，と思ったひとも，いったん真っ白な気持ちで受講してくれれば嬉しく思います。

1.2 心理学とはどういう学問か

ところで「しんりがく」という言葉はどこで区切るかご存知ですか？「し/んりがく」?「しん/りがく」?「しんり/がく」?

正解は「しん/りがく」です。心の理学，つまり「こころの理(ことわり)」についての学が心理学なのです。さらにいうと，「学」ですから，エンターテインメントや怪しげな術ではなく，知識の体系であるというのが大前提です。そして知識の体系とは，「積み重ねることができるもの」であり「誰にでも共有できるもの」でなければなりません。だからこそ大学で教育できるのです。逆に考えてみるとよくわかります。積み重ねられず，天啓を受けて，あるいは生まれ持った特殊な技能で達成できるものは学問ではありません。また，誰にも言えない特別な秘伝により限られた人や集団にしか教えられない情報も，宗教や奇跡，マジックや詐欺の領域に属するからです。心理学に神秘的で言葉にできない特殊な何かを求めている人には，残念ですがそれは心理学ではない，とお伝えしなければなりません[*2][*3]。

すでに述べたように，心理学は幅広い領域をカバーしています。それでも大きく分けると 2 つの分類ができるでしょう。下山 (2001)は次の表 1.1 のように分類しています。

表 1.1 下山 (2001)による心理学の分類

アプローチ	実証主義的アプローチ	了解的アプローチ
主な分野	基礎心理学	臨床心理学
手法	自然科学的手法	臨床的手法
対象となる側面	客観的事実	主観的事実
データ収集	実験・調査	臨床実践
データの特徴	量的データ (客観的データ)	質的データ (物語性)
モデルの有効性	理論的な検証可能性	現実状況を理解する際の有効性
対象者との関係	介入しない	積極的な関与 (関与観察)

[*2] 「なんだよー，さっきいろいろな心理学があるって言ったじゃないかよー。本当はこっそり秘伝の術があるんだろう，カウンセリングとか催眠術とかさあ。」と思っている人もいるかもしれませんが，残念ながらそれは心理学どころかそもそも学問じゃないんです。世の中には超心理学だとか，サイコなんとかだとかメンタルなんとかだといって，商売ネタに “心理” というワードを使う輩が後を絶たないから，心理学の誤解は無くならないんですよねえ。

[*3] 余談ですが，大学での学問はすべてこうした「秘伝」を否定するものです。もし言語的に伝えられない合理的でないものがあるならば，それは大学で取り扱うものではありません。もし皆さんが学びたいと思っているのに，合理的な理由なく大学教員が教えてあげないというならば，アカデミックハラスメントに該当します。

ここでは心理学のアプローチを，実証主義的なアプローチと了解的なアプローチに二分しています。一般的には基礎と応用といった名称で呼ばれることもありますが，内容的にはこちらの区分の方が良いでしょう。主な分野としてそれぞれ基礎心理学，臨床心理学が挙げられていますが，基礎心理学のなかには知覚，生理，学習，認知といったさらに細かい学術領域があります。

2 つのアプローチが大きく異なるのは，続く研究の方法論的箇所です。実証主義的アプローチは自然科学的手法を模範とし，客観的事実に基づく実験や調査を行い，理論的な検証・予測を目的とします。一方で了解的アプローチの目的は第一に，クライアントの状態が良くなるところにあり，対象に積極的な関与をしますし，理論よりも現実状況を理解する有効性を目的とするのです。とはいえいずれにも共通するのは，これが科学 (Science) であり，データに基づく知識の積み重ねであるという点です。

いずれにせよ，心理学者は心を読んだり，操ったりしているわけではありません。心というものがあるとしたら，どういう機序 (＝メカニズム，仕組み，因果関係) があるかを明らかにしようとしているのです。実は，心というものがあるのか，ないのか，それもわかりません。目にも見えず触ることもできないのですから。あなたの隣にいる人だってよくできたロボットかもしれないですよ？ [*4]そしてこの，対象が客観的・物理的に把握できない，社会的実在や主観的経験であることが心理学の難しさなのです。

心理学は「目に見えない対象を研究する」という難しい課題にチャレンジし続けている学問です。それでいて物理学 (物質の理の学) のように，規則性，法則性を探そうとしている学問です。気を付けないと，超魔術やスピリチュアル，宗教のようなものになってしまいます。心理学は，「知識の体系」＝「学」＝科学 (Science) であることを忘れないで欲しいのです。

1.3 近代科学の特徴

さて心理学が科学であるというならば，そもそもその科学とはなんでしょうか。西洋の歴史を考えてみると，そもそもギリシア哲学から学問が発生し，その後は中世に至るまでキリスト教が「世界を説明する教義」として支配的な考え方を提供していました。これが近代科学になるためには，ニュートンやガリレオなどによる科学革命を待たねばなりません。そこでは一体どういう考え方の転換があったのでしょうか？

近代科学の特徴は，次の 4 つにまとめることができるでしょう。また，それぞれの考え方に関係した人の名前を挙げています。

- 実験主義：ティコ・ブラーエやケプラーによる天文記録，ガリレオのさまざまな実験
- 数量主義 (**数学的現象主義**)：ガリレオやニュートンによる記述
- 機械論的発想：デカルトや，ラプラスのデモンに代表される考え方
- 要素還元主義的：デカルトの「第二の格率」，「分割と統合」といった考え方

まず実験主義である，というのは「教科書に書いてあるから確かめなくてもいいでしょ」という考え方への反発です。「本当かどうか，確かめてみようじゃないか」というスタイルです。西洋では長らくアリストテレスの説が世界の答えでした。アリストテレスは重たいものが軽いものよりも先に落ちる，と考えました。これが教会の権威と結びついて，疑うことが許されない教義のようになっていたのです。このことを疑うのは，神を疑うことであり，そんな人は地獄に落ちるぞ，と言われたりします。

しかしこれを確かめてみよう，と実験したのがガリレオです。ピサの斜塔から重たいものと軽いものを同時に落とし，同時に着地することを確認する。実際にやって確かめなければならない，思弁的に論じているだけではダメだ，というわけです。

[*4] 「スワンプマン」と呼ばれる思考実験の例があります。興味があれば「スワンプマン」で調べてみてください。

他にも，ティコ・ブラーエやケプラーといった天文学者は天体の動きを何年にもわたって記録し，どういう法則性があるのかを考えていました。これも実際にデータをとって考えてみるという意味では実験主義的な態度であり，これが科学の基本的なスタイルなのです。

数量主義あるいは数学的現象主義は，数学で現象を記述しようという考え方です。ニュートンは重力を発見した，と言われますが，正確には力がどのように働くのかを数式で表現したのであり，重力を見たわけではありませんよね。データをとってその関係性を記述することで，世界の理解を深めようと考えているのです[*5]。大事なポイントは，重力が何か (What) ではなく，どのように働くか (How)，という問いの大転換をしたことであり，これが近代科学の基礎を築いたのです。

機械論的発想というのは，「世界は機械＝メカだ。メカニズム (機序) があるんだ」という考え方です。西洋では長らく，世界は神様が作ったものだから，その仕組みを探ったりしたらバチが当たる，と考えられていました。デカルトは「神様が作ったのは「心」で，肉体とかの「体」はいくらでも分解して調べて，神様の考えを勉強させてもらったらええんやで」と考えました[*6]。このメカニズムを探ろう！というのが科学の目的であるということです。

最後に要素還元主義的であるというのは，「要素」に戻していこう，という考え方です。大きな問題を小さな要素に分解していき，確実にわかることを積み重ねていけば，いつかは大きな問題全体がわかる，という考え方です。これもデカルトの考え方で，「方法序説」という本に書いてあるので興味があれば読んでみてください (ルネ・デカルト，1997)。大問題を小問題に分割していこう，というのも近代科学的アプローチの基本です。

さて，心理学は科学ですから，ここにあげた 4 つの基本的な姿勢はそのまま継承しています。また，この 4 つの特徴の根本にあるのは**私秘性の排除**にあるということにも注意してください。私秘性とは聞き慣れない言葉かもしれませんが，要するに「私だけが知っている秘密」という性質であり，これを徹底的に排除しようとするのが科学的な姿勢なのです。私，というのは一個人はもちろん，教会といった特定の組織，ひいては全知全能の神様すら含まれるでしょう。説明できないところをなくし，徹底的に言語化すること，誰にでもわかるように世界を説明することが，科学の究極的な目的なのです[*7]。

ですから心理学も当然，「実験的」で「数量的」で「機械論的」で「要素還元主義的」なアプローチをとります。問題を細分化しつつ，実際に実験や介入を経て，その機序を明らかにしていくわけです。でもここで，なんで数字を使うんだ！と思う人もいるかもしれませんね。誤解しないでいてほしいのですが，数字は「言葉」です。いわゆる日常的な言葉 (日常言語) ではありませんが，科学的な営みを進めていく上では，次の点で日常言語より優れているのです。

- 正確であること；5 点は誰が見ても 5 点。客観的で正確な記述に向いており，相対的に確実な事実の伝達ができる。日常言語で「すごい」「すごくすごい」と言いながら伝えることと比べてみるとすぐにわかる。
- 比較可能性；5 点は 3 点より大きい。確率的判断により予測が可能。日常言語で「やばい」「えぐい」といった副詞の程度を比較することを考えてみると，これも明らか。
- 要約可能性；代表値等で全体を表現できる。簡潔な表現でデータの特徴や傾向がわかる。日常言語で「要するに・・・」といった表現をすることがあるが，どのように要約しているのかも記述できる。
- モデルの検証が可能；モデルにデータを与えて仮説を検証したり，客観的で合理的な結論を導くことができる。

[*5] 神様の存在を疑ったり反抗したりするのではなく，逆に「こんなにも完璧に自然を設計している神様まじパネエ」という信仰心から研究が重ねられていたようです。詳しくは池内 (2014) や蛇蔵 (2014) などがおすすめです。

[*6] 関西弁は著者の意訳によるものです。

[*7] 科学というのはそういう意味で，本質的にコミュニケーションなのです。

1.4 心理学のいとなみ

上で述べたように，数字 (数学) の言葉を使って現象を表現することは，正確で比較検証可能な表現であるだけでなく，膨大な情報を要約することもできるなど，利点は明らかです。ここまで来てもなお，「いや，数字で表現できないことがある。それこそ心だ」と言いたい人がいるかもしれません。

いいでしょう，確かに心理学の研究対象は「心」ですが，それが目に見えず触ることもできないものだというのは認めます。さらに言えば，あるかどうか，その存在すら疑わしいですね。ばかな，心はあるに決まってるじゃないか，という人もいるかもしれませんが，近代科学の作法に則ってそのことを表現してみてください。すなわち，心があるかどうかは私にはわかっている，というのは不適切な論法である (私秘性の排除が必要) ということを踏まえて，考えてみて欲しいのです。

心理学者はこの問題について，次のように考えてきました。つまり，「あるかないかはわからないけど，仮にあるとしよう」，と仮定を置きます。その上で，もし心というものがあるのなら，外部から何らかの刺激を与えた場合，その心を経由して，何らかの反応があるだろう。たとえば人を拳で殴ります (刺激)。するとその人は泣き出すわけです (反応)。なぜそうなるのか，それはきっと「殴られて悲しい」からだ，それこそが心の働きだ，というわけです。これを図にしたものが図 1.1 です。

図 1.1 刺激と反応からブラックボックスを探る

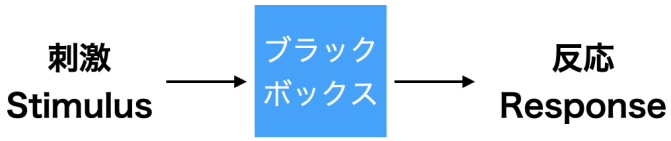

心理学では科学的に考えるために，主体 (人間に限らず心があると思われるのであれば何でも) に対してさまざまな刺激を与え，その反応パターンでもって「心があると言えるかも」と考えるのです。これはニュートンが「りんご →?→ 落ちる」の関係から，そこに「重力」があるのかも？ と思ったのと同じ理屈です。彼はこの関係を数式で表現したのでしたね (数学的現象主義)。「こころ」も「こうすれば → 心のせいで → こうなる」という因果を説明する表現方法だといえます。

さきほどの図 1.1 もそうですが具体的な現象を抽象化して表現することで，理解が進んだり新しい解釈ができたりします。この抽象化された，理想的な状態の表現方法を**モデル (model)** と言います。心理学では主体に心というモデルを想定し，もしそのモデルが現実と対応しているのであれば，(理論から導かれた特定の) 刺激に対して，(理論から導かれる結果としての) 反応が現れるはずである，と考えることができます。そこでさまざまな刺激を考え，さまざまな反応を受け止め，心というモデルの正しさを検証しようとしているのです。

もちろん刺激にはいろいろなパターンが考えられます。それこそ無数に考えられてきました。そしてそれに対応する反応もさまざまなものがあるでしょう。1 つの刺激にだって，個人差がありますから，さまざまなバリエーションのある反応が出てくるはずです。

こうしたたくさんの刺激 – 反応を正確に記録するために数値化が必要であり，数値化することで要約が可能になり，数式でその関係を表現することで一般化できます。その数式に実際の数値を代入することで事実に合致しているかどうかを検証できます。このように考えると，心理学で数字を使わないはずがないのです。もちろんそのほかの学問でも，数値化や数字は必須です。物理学のように純粋に数学を扱う領域もあれば，工学のように測定されたデータを扱って物理理論との対応を考える，いわゆる理系の学問では当然ですが，

人文社会科学においても使わないわけはないのです。

統計は，単なる集計に関する学問ではありません。とくに「心理」統計は，心という目に見えないものを見るために，どのように測定するか，どのようにデータを取るか，といったところが決定的に重要です。これらは**心理測定法 (psychometrics)** といわれ，心理学のさまざまな領域で考えられています。しかし一度数値化されたデータが手に入れば，それからどのようにメカニズムを解釈するのか，どのようにモデルを立てていくのかについては領域を超えてさまざまな手法があります。それがこの授業，心理学データ解析でみなさんが学ぶべきことなのです。みなさんはこの後，さまざまな専門領域に進んでいきますが，得られたデータを分析するという点については共通した知識・知恵の蓄積がありますので，心理学のごく基礎的な段階から学ぶ必要があります。

数字で心がわからない，と思う人がいるかもしれませんが，これについてはどのように数字にしたのか，という心理測定の問題が理由となっているのではないでしょうか。すなわち，嬉しい気持ち，悲しい気持ちを 4 とか 23 とか言われても，そういうんじゃないんだよな，といいたくなるのはわかりますが，それは嬉しい $= 4$ だと誰がどうやって決めたんだ，という問題なのです。

仮に数字が正しく心の状態を表現していたとすると，その後その大量の数値から要約したり個人差を除外して，真なる状態を求めることができるかもしれません。近年はあらゆるところに人の行動が記録される機会があります。こうした記録は膨大な量に上るので，ビッグデータと呼ばれています。ビッグデータの中から，人の行動パターンを分析するのも心理統計の範疇です。

犯罪プロファイリングやマーケティングなども心理統計の応用的実践例です。もちろん臨床的介入の効果を検証するとか，実験的操作の影響力を評価することも心理統計の守備範囲です。数値化することによって，目に見えなくて触れなくてあるのかないのかもわからないものが，どの程度わからないのか，どこまでならわかるのかといったことも表現できるようになるのです。

心理学と統計法の関係，心理統計の必要性についてご理解いただけましたでしょうか。納得をいただいた上で，心理統計の具体的な話に進んでいきたいと思います。

1.5 課題

■心理学とは何だろうか みなさんの中で心理学とはどういうイメージを持っていますか。この講義を受けるまえはどのように考えていましたか。この講義を受けた後で何か変わりましたか。できれば今考えている，あなたなりの心理学像を，どこかに書き起こしておくと良いでしょう。前期の終わり，あるいは一年の終わり，そして四年後にそれがどう変わるかを楽しみに。

■心理学にどうして統計が必要なのか 第 1 回は心理統計の中身に入る前に，どうして心理学なのに数字を扱って統計を学ぶのかについてを解説しました。みなさんの身近な人に，みなさんなりの言葉でこのことを説明してみてください。そのときに，心理統計と心理測定の違い，科学としての心理学，というキーワードを入れながら説明できれば完璧です[*8]。

[*8] また後ほど触れることになりますが，ある人が何かを理解している，わかっているということは，そのことについてさまざまな表現を延々と生み出すことができる，ということでもあります。もし言葉に詰まったり，うまく説明できないことがあれば，そこの理解ができていないと考えられます。

第 2 章

電子計算機の基礎

2.1 授業の目的

心理統計の授業では，多くの数値を扱うために計算機を用います。計算機は人間と違って，疲弊したりそのことによって能力に翳りが見えることもなく，指示された通りの計算を粛々とこなしてくれますから，心理統計を実践する上では大幅な支援をしてくれる存在であり，人間の外部にある第二の脳とも言える存在です。ただし気をつけなければいけないのは，計算機は「指示された通りに動く」のであって，「こちらの思った通りに動く」わけではないということです。正しく指示しなければ，正しい結果は得られませんし，間違った指示をすれば間違った結果が出てきます。計算機は人間のように「考える」ことはできませんので，こちらが考えた通りに動くように指示を出す必要があります。

また，皆さんは生まれた頃からインターネットが周りにあり，スマートフォンやタブレット，パソコンが身近にあったと思います[*1]。最近は計算機が含まれていなかったり，インターネットに接続していない電子的デバイスを探す方が難しいほどでしょう。デジタルネイティブな皆さんは，昭和 51 年生まれの私よりもずっと上手に使いこなしていると思います。

ただ，最近の新しい計算機界隈に生まれながらにして親しんできた皆さんは，便利な機械の使い方はご存知でも，仕組みまでは十分理解していないかもしれません。というのも，最近の計算機 (や OS) は親切設計で，ユーザに苦労をさせないような工夫をしているからです。そのこと自体は責められるべきではありませんし，皆さんにはなんの落ち度もないのですが，その工夫が逆に仕組みをわかりにくくしたり，メーカの意図せざる使い方をしてユーザが苦労させられることが少なくありません。というか，計算機がうまく動かない！というトラブルの多くはそれが原因です。

対策として，やはり計算機の仕組みを知っておくことが大切です。計算機の仕組みを知っていると，トラブルに出会ったときに「あぁこれってひょっとして」と思い当たることができたり，納得できるようになります。知らなければ「何だかわからないけどパソコンが壊れた」というか，「パソコン運が悪い」「自分はパソコンが苦手なのだ」と間違えた帰属をしてしまうことになります。

これまで，情報系の授業で聞いたことがある話，これから聞く話もあると思いますが，もし苦手意識を持っている人がいたらこれを機に再入門するつもりで読んでください。

[*1] ここまで私は「計算機」と言ってきましたが，これらをすべて包括的に表現するつもりでこの言葉を用いています。

2.2 コンピュータの基礎

21 世紀に生きる私たちは身の回りをコンピュータに囲まれて生きています[*2]。それは携帯電話の形をしていたり, ノートパソコン, デスクトップパソコンの形をしていたりします。また時々テレビなどで報道されますが, 気象予報や花粉などの飛沫がどのように飛び散るかをシミュレーションする大型計算機「富嶽」などもコンピュータですね。これらは形は違いますが, いずれも電子計算機であり, 電子計算機には次の 5 つの装置があります。

入力装置 キーボードやマウス, タッチパネルなどを使って情報を取り込むデバイス (装置)

出力装置 モニタやプリンタ, タッチパネルなどを経由して情報を出力するデバイス

演算装置 プログラムの命令にしたがって計算処理 (四則演算や論理演算) をする装置。一般に電子計算機の中央で一括して処理するので, Central Processing Unit(CPU) と呼ばれるものです。

制御装置 演算結果にしたがって他の装置に指示を出す装置のこと。演算装置とまとめて CPU に実装されています。

記憶装置 計算結果などの情報をいったん保持しておく装置のこと。コンピュータの内部にあって一時的な計算に使われる一次記憶装置, ハードディスクドライブ (Hard Disk Drive,HDD) やソリッドステートドライブ (Solid State Drive,SSD) などの二次記憶装置など。

最後の記憶装置については, 一次記憶装置, 二次記憶装置と種類が分かれていますがこの区別は簡単で, 電源を落としたときに記憶が消えてしまうのが一次記憶装置, 電源を落としても記憶が消えないのが二次記憶装置です。たとえば $12 + 38 =$ という計算をするとき, 頭の中で「えーっと一の位が 2 と 8 だから 10 になって繰り上がるから・・・」と考えてから, ノートに $= 50$ という答えを書くと思います。次の問題に進むと, 先ほどの「1 繰り上がるから・・・」という情報は忘れてますよね。でもノートに書いた $12 + 38 = 50$ というのは残っています。このノートがいわば二次記憶装置であり, 頭の中で一時的に保持していた情報が一次記憶装置ということになります。一次記憶装置は RAM(Random Access Memory) とも呼ばれます[*3]。

ところで, コンピュータがやっているのは計算だけです。私はこの資料を PC に向かって書いており, キーボード (入力装置) を叩きながら, 画面 (出力装置) を見て文字を連ねています。これも「キーが押されたら文字を表示させ, その文字列を記録する」という処理を機械が淡々とこなしているに過ぎません。あるいはマウスやトラックパッドで, アイコンを指し示し, カチリと押す[*4]ことで選択し, 押し込んだまま移動させ (ドラッグ), 離すことで別の場所に置いたりします (ドロップ)。トラックパッドの場合は 2 本指で同時に押したりしますし, タッチパネルの場合は二本指を広げたり (ピンチアウト), 逆に二本指を狭めたり (ピンチイン), 3 本以上の指でファサーッと触って場所を広げたりします。たとえば「ファイルを掴んでゴミ箱に捨てる (削除する)」というのが我々にとっての操作ですが, コンピュータの内部では実はこんなことをしていません。ファイルは (二次) 記

[*2] 私は 1976 年生まれですが, 生まれた頃は周りにコンピュータなんかありませんでした。小学生の頃にマイコン (マイクロコンピュータ, 小さなコンピュータという意味でもありますが, My Computer, 私のコンピュータという意味でもあります。つまり個人単位でコンピュータが使えるようになった, というだけでも大きな出来事だったのです。) という言葉が出てきて, なんかかっこいいなと思った記憶があります。私が 10 歳になったころ, ビデオゲーム (テレビゲームでやるゲームが家庭でできるようになり, それをこのように呼びました。) が身の回りに出てきました。ファミリーコンピュータ, とくに「スーパーマリオブラザーズ」によって日本中の子供たちが熱狂しました。それは私が 11 歳の頃のことです。「ドラゴンクエスト」によって社会問題になったのは私が 12 歳の頃です。ともかくこの頃は, コンピュータといってもゲーム機のような扱いでした。

[*3] 実はこのように人間を 1 つのコンピュータに喩えて, そこではどのように計算がされているのか, 人間の記憶装置や演算装置, 入出力装置の特徴はどうなっているのか, というのを研究するのも心理学の仕事です。記憶や演算, 制御については認知心理学や学習心理学, 入出力については知覚心理学や生理心理学が専門的に扱っています。そういう意味でもコンピュータの登場は心理学に大きな影響を与えているのですが, それはまた別の講釈で。

[*4] 押すときの音から, この操作をクリック click と言います。2 回続けて押すことをダブルクリックと言います。

憶装置に書き込まれた情報です。記憶装置は原稿用紙のように小さなマス目がたくさんあります。ファイルとはそのマス目の XXX 番目から YYY 番目までの情報，ということです。このファイルを削除するというのは，記憶装置のある場所 (アドレス) に「削除されたものなので画面に表示しない」という情報を書き込む，という操作をしているだけです。じゃあなぜ私たちは「ゴミ箱にドラッグ＆ドロップ」なんてするのでしょう？ それはそのほうがわかりやすいからですよね。「ファイルを削除する」というのは，「メモリアドレスの XXX 番地に別の情報を書き込む」という操作だと言われてもピンとこないので，コンピュータが人間にとってわかりやすい表現をして見せてくれているのです。このユーザにとってわかりやすい幻を見せてその気にさせてくれるというデザインのことを，ユーザーイリュージョンと言います。ともかくこういう「画面で見ながら操作する」ことをグラフィカル・ユーザ・インターフェイス (Graphical User Interface,GUI) といいますが，これのおかげでコンピュータの操作は随分楽になっています[*5]。

2.2.1 コンピュータの歴史

コンピュータの装置，すなわちハードウェアについての解説につづいて，ソフトの側面についても解説を加えようと思うのですが，そのためには少し歴史的な流れを説明したほうがわかりやすいかもしれません。

コンピュータの発展の歴史は，小型化の歴史でもあります。最初にできたコンピュータは ENIAC といいます。1946 年の話です。この ENIAC は 27 トン，広さにして倉庫 1 つ分 ($167m^2$，90 畳以上の広さ) が必要なもので，真空管を使った計算機でした。軍事的な計画のために開発されたオーダーメイドのものですから，一般人が触れるはずがないものです。時代が下がって真空管が半導体，IC チップになった頃，やっとサイズが小さくなって，家庭用・個人用のコンピュータというのができるかもという時代が来ました。Apple コンピュータの創始者，スティーブ・ジョブズとスティーブ・ウォズニアックが最初のパソコン (Personal Computer, 以下 PC)，Apple I を発売したのが 1976 年。爆発的に売れた Apple II が発売されたのが 1977 年です。AppleII はブラウン管表示装置とキーボードを持っていましたので，今の PC の原型とも言えるかもしれません[*6]。PC を作っている会社は Apple だけでなく，IBM や DEC などがありましたが，まだこの頃はパーソナルなレベルのものよりも大型計算機の開発が進んでいました。IBM が PC を作ったのは 1981 年で，この頃から小型化が進められていきます。

私事で恐縮ですが，1976 年に生まれた私が初めて PC を手にしたのは 1991 年，高校入学のお祝いで買ってもらった Fujitsu の FM-Towns という機体でした。この頃は「マルチメディア」という名前もなく，「ハイパーメディア」と呼んで売り出していました。この機体は他の PC(NEC の PC-9801 や Sharp の X68000 シリーズが有名でした) とは違って，CD-ROM ドライブをつけていたことが画期的だった時代です。その後 1994 年に大学生になりましたが，この頃は連絡を取り合うツールはポケベルが主流であり，携帯電話 (や PHS) のような個人端末は高級品という時代でした。大学に入るとコンピュータを学ぶ授業があり，アカウントをもらったりするのですが，それは大学が持っている大型計算機に端末からアクセスするためのものでした。いろんな部屋にあるのは「端末」で，それほど機能の優れた PC ではなく，複雑な計算 (統計的な計算など) は大型計算機に仕事を依頼しその返信を待つ，というスタイルでした。関西私立のマンモス校でしたので学生数は極めて多かったのですが，多くの学生が一度にアクセスしても，大型計算機はものすごくものすごーく計算が早かったので，瞬時に回答をもたらしてくれるものでした[*7]。つまり，まだ「専門的な計算は大型計算機」

[*5] 実は人間の意識もこのユーザーイリュージョンのようなもので，実際の体の動かし方や感覚情報の受け止め方，処理の仕方は別ですよね。すべての情報を意識に上げるのではなく，「私は XXX をしている」と身体がそれっぽい幻想を投影して見せてくれているのが意識の正体ではないか，という議論があります。興味のある人はノーレットランダーシュ (2002)を読んでみてください。

[*6] Mac の歴史についてはアイザクソン (2011)が読み物としておもしろいですよ。

[*7] Time Sharing System,TSS，時分割システムとよばれる機構です。命令を小さな単位に分割し，それを順次捌いていくという方法でした。

という時代であり，パーソナルなコンピュータになるにはもう少し時間が必要でした。

1995 年，Windows 95 という OS が発売されました。これを機に日本でも PC がどんどん浸透していくことになります。Windows95 は物凄いんだぞ，と発売前からテレビでも散々とりあげられ，発売日には行列ができて真夜中のカウントダウンと同時に大フィーバー，という売れ行きでした。当時のそれは何が凄かったのでしょう？ コンピュータにはそれ動かす基本ソフトが必要です。HDD にデータを書き込み，キーボードからの入力をディスプレイに表示する，といったごく基本的な装置を統括し，メモリ番地をファイルという単位で扱うといった基本的な操作は OS いうソフトウェアが担当します (図 2.1)[*8]。この OS，大型計算機は Unix と呼ばれるものを使っていましたが，各企業が個人向けにコンピュータを売り始めるときにも当然必要で，各社で開発もしていましたが，PC の共通規格をつくることで OS 部分は共有できるようになりました。そこを提供したのが Microsoft 社のビル・ゲイツです。どんなパーツで作られた PC であっても Windows という OS が共通のフィールドを用意してくれるので，ユーザは Windows で動くアプリケーションを選ぶだけで良い，ということになったのです。

図 2.1 コンピュータのハードウェアとソフトウェアの関係

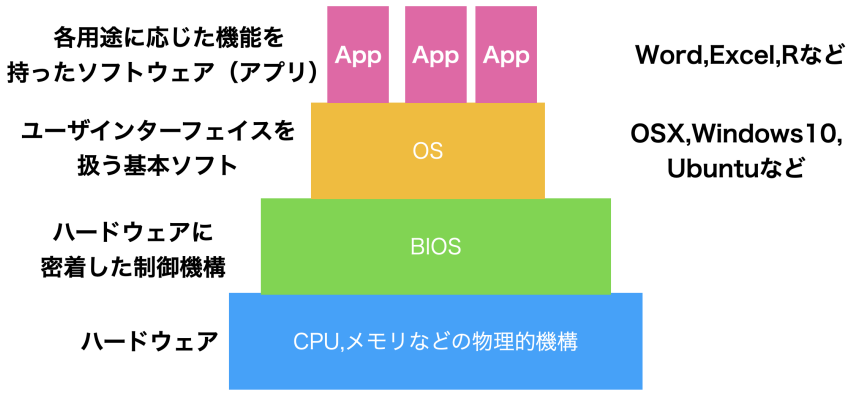

そして Windows95 は，GUI，つまり「ファイルを掴んでポイ」といった直感的な操作で使えることも大きな特徴でした。大型計算機で使われている Unix は基本的に Character User Interface,CUI で，黒い画面にプログラムを書いて実行するといった手法で，初心者には人気がなかったのです。GUI については，その頃 Apple を追放されていたスティーブ・ジョブズが，NeXT という会社で GUI を備えた OS を開発していました。この NeXT はその後 Apple に買収され，ジョブズは Apple に戻って活躍することになります。その頃から巷では，Windows の GUI は Apple の OS を真似したものだと非難されていたのですが，商業的には Windows が大勝利，というわけです。ともかくこれを機に企業などはもちろん一般家庭でも PC を使うような時代になりました。

ちなみにインターネットが広まったのもこの頃です。私は大学 3 年生の時，大学の授業で初めてインターネットを介して世界の情報を得る，という経験をしました[*9]。その頃から徐々に，大型 PC のアカウントではなくインターネットで使えるメールアドレスというのを個々人が持つようになりました。携帯電話も廉価な PHS が広まり，メッセージだけでなく徐々に音声，写真，短い動画が送れるようになっていきます。当初は当然画質・音質も今とは比べものにならないのですが，それでもインターネットを経由してつながるという経験は想像を

[*8] 物理的な機構と OS との間に Basic Input/Output System,BIOS というのが入りますが。

[*9] 教職関係の科目で，教育技術として今後使われるだろうということで担当教員が実演してくれました。隣の部屋から電話線を延長し，モデムという PC の信号を音情報に変える機器を繋げて，NASA の Web ページを Netscape というブラウザでみたのが初めての体験でした。

超えたものでした。

皆さんはすでに，携帯電話やインターネットがある時代に生まれた世代だと思います。こんな話はすでに過去のものであり，不便な頃の話を聞かされても困る，と思うかもしれません。私の世代は幸いにもコンピュータが発展していく時代に育ちました。そのため機械の根本的な理解に直結しやすい社会環境にあったのです。みなさんは便利な時代ではありますが，「初心者が苦労しないように補助輪をつけておく」「何もしなくてもできているような感覚が得られるようなイリュージョンを見せておく」という状態におかれています。そのため補助輪が対応できない道に進んだり，多くの人とは違う使い方をするときに，急にサポートが外れどこで困っているかわからなくなる，ということになりかねません。非常に大雑把な Historical Review ではありますが，理解の一助になればと思います。

ところで，先ほどサポートという言葉を使いましたが，このサポートを商売にしているのが Microsoft や Apple という IT 企業です。これらの会社は，ユーザが使いやすいようにソフトウェアを提供してくれますが，有償ですし想定外の使用をするユーザに対してはサポートをしてくれません。逆にいうと，「決められた路線を走らなければ面倒を見ない」ということでもあり，これはユーザに不自由を強いているとも言えます。また，どのような仕組みで動いているのかを尋ねても，企業秘密と言って答えてくれません。コンピュータは誰でも自由に使えるべきものであり，勝手にユーザの情報を盗んだりしていないか，といったチェックをするためにもオープンであるべきではないか。そういう考え方に基づく，フリーソフトウェアというソフトウェアのあり方があります。Unix という OS を PC 用にした Linux がそうであり，オフィスソフトの LibreOffice，統計環境の R などもこの精神に賛同するものです。フリーソフトウェアは自由であり，無償です。お金と秘密を払ってサポートを受けるのではなく，ユーザが相互に助け合ってオープンで自由な世界を広げていこうという活動です。急に何の話なんだ，と思うかもしれませんが，心理学ひいては科学的活動すべてにおいて重要な問題であることをご理解いただきたいと思います。

2.3 情報の単位

コンピュータを取り巻く世界の話はこれまでにして，ソフトの側面についての解説に入りましょう。

コンピュータは文字，音，絵，動画ファイルいずれについても，すべて 0 か 1 のデータとして管理します。0/1 の 1 つの単位を 1 bit(ビット) と言います。1 bit であれば Yes か No か，という二択の情報しか提供できませんが，これが 7 つあれば $2^7 = 128$ ですから，これで 128 種類の状態を表現できます。コンピュータは一般に，8bit で 1 つの単位として計算します。8bit のことを 1 byte(バイト) と言います。この 1 byte が 1024 集まったものを 1kb(キロバイト) といいます[*10]。1kb の次は，1024kb=1Mb(メガバイト) です。さらに 1024MB=1GB(ギガバイト) で，1024GB=1TB(テラバイト)，1024TB=1PB(ペタバイト)，1024PB=1EB(エクサバイト) と続きます。K,M,G,T,P,E といった名称は 1024 倍ごとに変わる大きさの桁をあらわしているのであって，「ギガが減る」というのは本来意味をなさない表現です[*11]。

このビット･バイトは情報に関する基本単位なのであちこちに使われます。記憶装置について使われるとき，一次記憶装置も二次記憶装置も同じ単位なので混同するかもしれませんが，2025 年現在では二次記憶装置の単位は GB から TB が使われます。USB フラッシュメモリーや外付け HDD などは数 TB の容量が一般的でしょう。これに対して，一次記憶装置は 4〜64GB ぐらいが相場かと思います。一次記憶装置は暗算の途中経過のように一時的に記憶する場所に過ぎないので十数 G でも問題ありませんが，二次記憶装置は結

[*10] キロメートルやキログラムのように，キロは 1000 の単位を表す言葉ですが，コンピュータは 2 進数なので 1000 ちょうどではなく 1024 で 1 つ上の位に上がることになります。

[*11] 同様に「USB を紛失する」というのもよく聞くおかしな表現です。USB は Universal Serial Bus の略で，データ転送規格のことを指します。なくすことができるのはそれにつなげるメモリースティックなどです。

果の記録なので大きければ大きいほど余裕が持てますね。たとえば数 TB でもテレビドラマや映画を何本も記憶できるのですから，PB や EB なんて使うのかな，と侮ってはいけません[*12]。すぐにそれぐらいのサイズが必要な時代が来ることでしょう。

実際，それぞれ単位ではどれぐらいの情報が記録できるのでしょうか。1 byte は 256 種類の情報を表現できるので，英語のアルファベット 26 文字に加え，数字や簡単な記号であれば 1 byte で表現できます。たとえば A という文字は 01000001，B という文字は 01000010，小文字の a は 01100001，といったように 0/1 の文字列 8 個と一対一対応させて考えるのです。日本語は 1 byte では足りませんので，一文字あたり 2byte が割り当てられます。また 1KB(=1024byte) は 500 文字ですから，原稿用紙一枚ぐらいになります。1MB(=1024KB) は文字だけだと新聞一紙 (朝刊の 40 ページ分) ぐらいで，昔の記録媒体であるフロッピーディスク一枚に保存できるのがちょうど 1MB でした[*13]。ちなみに「カメラ映像 + 音声」のオンラインビデオ会議を 1 時間やると 200〜300MB ぐらいの容量をやりとりしていることになります。ビデオ会議では文字 (チャット) だけでなく，画像 (動画) や音声も送り合いますね。実は画像や音声も，0/1 に置き換えています。音声の場合，1 秒間を短い間隔にくぎります。この区切りのことをサンプリング周波数といいます。たとえば 44.1 kHz という単位は 1 秒間に $44.1 \times 1000 = 44100$ 点のデータを採取します。これらのデータ点において，音の振動幅を区切ります。ビットレートと言いますが，たとえば 16bit で区切る場合は $2^{16} = 65,536$ 段階で音の高さを表現します。このように時間と音階を細かく区切り，その目に情報があるかないかを積み重ねてデータとするわけです。テキストよりも圧倒的に情報が多くなるのが分かりますね。画像も同様に，図面を細かい単位 (ピクセルなど) で分けて，そこの色合いを色々な段階で区切ります。色は R(赤)G(緑)B(青) の組み合わせで表現でき，それぞれを 8bit$= 2^8 = 256$ 段階で表現したりします。一点一点にその情報がありますから，図の情報も非常に多くなるのがわかると思います。動画はその画像が時系列的に細かく分割されたものと思ってください。このように分解しますので，テキスト，音声，図，動画の順にデータサイズが大きくなります。通信機器が最初ポケベル＝数 byte の情報しか送れなかったものから，徐々に絵文字，ショートメッセージ (音声)，写真[*14]，動画が送れるように発展していきました。今では町中のあちこちで，誰もが手軽に動画をモバイル端末で見られるようになっています。あらためて，すごい進歩ですね[*15][*16]。

なお，1 byte は 256 種の情報が記録できるので，英語のアルファベットや数字は 1 byte あれば十分だが，日本語や中国語など，英語以外の言語は文字種が多いので，2byte で一文字を表すという話をしました。この 2 バイト文字も，たとえば「あ」とか「亜」という文字に 1110001110000001100000010 とか 111001001011101010011100 という文字列を割り当てるのですが，言語ごとによってどの数字をどの文字に割り当てるかという対応表が変わってきます。これを文字コードと言います。日本語はかつて Shift-JIS というコードで変換していましたが，今は世界のあらゆる言語に対応している共通規格である，UTF-8 という文字コードで変換することが一般的です。ところがなぜか，日本の Windows OS だけ Shift-JIS をいまだに

[*12] 私事ですが，私が 1991 年に生まれて初めて手にした PC，FM-Towns はハードディスクが 40MB，RAM は 2MB で，CD-ROM がついていましたが，それは 360MB の容量でした。購入するときに，「ハードディスクが 40MB もあって何を記録するんです? CD-ROM なんか情報が詰まり過ぎてますよ！」と店員さんに笑われたのを今でも覚えています。数年後，PC の動きが遅くなったので，2 万円で 2M の RAM を追加したのも良い思い出です。今でこそ，2MB なんて USB フラッシュメモリーでも売ってないほど微小なサイズですが。

[*13] 正確には 1.2MB 入る規格 (2DD) と 1.44MB 入る規格 (2HD) とがあります。

[*14] できた当時は写真を撮ってメールができることをとくに「写メールする」と言い表したほどです。

[*15] 実は音でも画像でも，分割してそのままデータにしてしまうと膨大になりすぎるので，人間が気付きにくい周波数や色合いなどは削除して作ります。これを非可逆圧縮処理と言います。一度落としてしまった情報は戻らない，という意味です。ライブや生きている人間が処理している情報は，携帯の画面から得られるものの何億倍もの情報量なんですよ!

[*16] デジタル化のすごいところは，こうした文字，音，図版，動画といったものを bit という共通の単位に落とし込んだことです。こうすることですべて一元的 (bit という共通次元) で処理することができるようになったのです。メディアの違いが問題にならなくなり，0/1 の情報であれば複写も簡単にできてしまいます。情報化社会においては情報に特別性はなく，情報があるかないか，それを生み出せるかどうかこそが重要なのです。

使い続けており，他の PC とファイルをやり取りするときに文字コードの変換エラー問題が起きます。ファイルを開いて文字化けをしたりとか，プログラムが実行される際に「ファイルにアクセスできない」というエラーが生じたりするのは，この文字コードの問題が大きいのです[*17]。受身的な対策法になってしまいますが，PC でつかうユーザ名やファイル名などは半角英数文字を使い，短くした方がこうしたエラーに出くわしにくくなります。逆に，全角文字やスペース (空白) などを含んだファイル名，やたらと長いファイル名を使っていると，こうした問題に出くわしやすくなるということです。

2.4 ファイルの種類と拡張子

ここまで述べてきたように，計算機というのは基本的に物理的実体 (記録装置，記憶装置) の上で 0/1 のデータをやり取りしているだけです。記録 (記憶) 装置上に置かれている情報のセットは「ファイル」という形で記録されています。スマートフォンやタブレットは，ユーザの利便性のためにファイルの存在を意識しなくても良いようになってはいますが，バックエンドでは実行されるアプリケーションもファイルですし，開かれる音声や動画もファイルです。とくに PC では，どの媒体，どのアプリで使うどういうファイルかを識別するために，拡張子 (かくちょうし) と呼ばれる識別記号をファイルの後ろにつけています。拡張子はファイル名の背後にピリオドで区切って追記されています。ついてないように見えても，OS がそれを表示させない設定にしてあるだけであることに注意してください。代表的な拡張子と，それに対応づけられているアプリケーションは次のようなものがあります。

.docx マイクロソフト社の文書作成アプリケーション，Word で使うファイル

.xlsx マイクロソフト社の表計算アプリケーション，Excel で使うファイル

.pdf Adobe 社が開発した Portable Document Format 形式。OS が違っても同じレイアウトで文書を表示できるのが利点で，PDF 形式を読むことができるアプリケーションは多数。

.txt シンプルな文字だけのテキストファイル。文字の飾りやレイアウトなどの情報がない最もプレーンな形式なので，OS が違っても文字コードさえ合っていれば読むことができる。

.mp3 音楽，音声のファイル。音声データには他の種類もあります。

.jpg 画像のファイル形式の一種。

.png 画像のファイル形式の一種。

.csv comma/character separated variables ファイル。変数をカンマ (,)，あるいはタブ，半角スペースなど文字コードで区切ったファイルという意味で，中身は.txt と同じく装飾のない文字/数字だけであり，文字コードさえ間違えなければ OS を問わずに読み書きできる。データのやり取りはこの形式で行われることが多い。

.zip 圧縮ファイルの一種。1 つまたは複数のファイルをパックして圧縮してあるもの。ファイルの冗長な部分をうまくまとめてコンパクトにまとめ上げるため，ファイルサイズが小さくなるし，複数のファイルもひとまとめにできる。また圧縮の際にパスワードをかけることもできるため，メールなどに添付する場合はこの形式にまとめられることが多い[*18]。可逆圧縮であり，圧縮されたファイルは展開する (解凍するとも

[*17] Windows だけ世界標準から外れているので，早く修正して欲しいのですが，歴史的な経緯からユーザ数が多くて切り替えられないでいることと，こうした違いがあることをユーザに説明しない (素人は知らなくていい，と馬鹿にされているようなものです) ので，問題が解決される日はまだ先になりそうです。

[*18] **PPAP** というとピコ太郎の楽曲を思い出す人もいるかもしれませんが，圧縮ファイルの文脈では “「Password つき zip ファイルを送ります。Password は次のメールで送ります」 Angoka(暗号化) Protocol の略です。つまりメールでパスワード付きのファイルを送り，そのファイルを開くためのパスワードをまたメールで送るという，日本でよく見られるおかしな風習です。おかしな，というのは，メールがハッキングされていたらパスワードもどうせバレるわけで，同じメールに書いてあるのはもちろん馬鹿馬鹿しいですが，すぐ次のメールに書いてあるのも同じぐらいに馬鹿馬鹿しいことです。情報セキュリティ対策手法のつもりで行われる慣習が

いう) ことでパッキングを開封できる。zip ファイルの圧縮/展開は各種 OS が標準的に対応している。

`.txt` や `.csv` といった形式は,「装飾のない, 文字だけの」ファイルです。こうした種類のことを ASCII ファイルと言います。メモ帳などのエディタと呼ばれるプログラムで読み書きできます。逆に `.docx` など特定の会社が提供するアプリケーションに対応しているファイルは, アプリの中でのさまざまな操作・装飾を暗号化して保存しており, メモ帳などで読んでも意味がわかりません。対応しないアプリでは開くこともできません。こうした形式は ASCII ファイルに対してバイナリファイルと言います。

OS は拡張子を見てファイルの種類を判別し, そのファイルを開くのに適したアプリケーションを自動的に起動し, 開いてくれます[*19]。`.csv` ファイルは Excel などのアプリケーションで開くことも当然できますが, その際文字コードのエラーが生じたり, 保存するときに文字コードを変えたりして, 形式・内容が気づかずに変わっていることがあります。Windows も良かれと思ってやっていることなのですが, 処理が徹底してないのか, かえって不便になってしまっています[*20]。

2.5 ファイルの場所

すでに述べたように, 計算機は基本的に 0/1 データのやりとりであり, それを保存してあるのがファイルとよばれるものです。ファイルは HDD や USB メモリ, SSD に保存することができます。

最近は, こうした手元の物理的実体にファイルを置くことに加えて, クラウドに保存することも少なくありません。クラウドとは雲という意味で, インターネットの向こう側のどこか, ということを意味します。ですが, 基本的にはインターネットで繋いだその先にも電子計算機があるのです。たとえば PC A と PC B をケーブルで繋ぐと, PC A から PC B のファイルにアクセスできます[*21]。このケーブルをどんどん伸ばすと, 遠く離れていてもこの操作ができます。このケーブル網を世界レベルに広げているのがインターネットです[*22]。

ここで覚えておいて欲しいのは, 当たり前のようですが, ネットといっても基本的には電子計算機と電子計算機を繋げている実体がどこかにあって, ファイルのやりとりをしているだけだということです。ブラウザはウェブサイトの情報を書いたファイルを取り込んでホームページを見せてくれていますし[*23], Youtube は動画のファイル, Instagram は画像のファイルへのアクセスをして見せてくれているのです。最近ではクラウドサービス, というのがよくあります。中でも Dropbox とか OneDrive, iCloud などが有名です。これらは, ファイルをインターネットを介した別の大型電子計算機に保存 (アップロード) し, インターネットを介して読み込み (ダウンロード) して使う, というものです。手元の電子計算機の中に記録されているファイルのことを「ローカル」, サーバなど遠隔地にある大型機に記録されているファイルのことを「サーバ」「クラウド」と呼んで区別しますが, このローカルとサーバのファイルを常に同じものに同期しておく便利なシステムです。こうしたクラウドサービスを使うと, たとえば大学で作業して保存したファイルを, USB メモリに保存して自宅の PC にコピーする, という操作をしなくても, 大学でクラウドサービス上のフォルダ内に保存しただけで, 自宅の PC にそのファイ

広まっていますが, PPAP の標語のもと, 馬鹿馬鹿しいのでやめましょうという風潮になってきました。

[*19] 見たことのない拡張子の場合は, どのアプリケーションで開くべきか尋ねてくるでしょう。

[*20] 実際, この授業での課題データを UTF-8 形式の csv ファイルで提供しても, Excel で開いたばっかりに文字化けして分析できなくなる, という相談がこれまで多く寄せられています。根本的な解決策として, Windows を使うのをやめることをお勧めします (半分冗談です)。

[*21] もちろんファイルの情報をどのように信号に変えて送受信するか, アクセス権限はどうするかといった細々したことを調整しなければなりませんが, そのあたりの仕事をやってくれるのが OS のありがたいところです。

[*22] インターネットは軍事通信網として始まりましたが, それを電話回線や企業内通信網, 大学間通信網などと接続しあって世界中に広げています。網と網が相互に (inter) 繋がっているので inter net であり, 大学内・企業内のネットワークのことはイントラ (intra) ネットと言います。ちなみに一般用語としてのインターネットは Internet と大文字で書き始めます。

[*23] ホームページとは本来ブラウザが最初に開くページのことを指し, 企業や個人が情報発信しているページのことはウェブサイトというのが適切です。

図 2.2 インターネットとクラウド

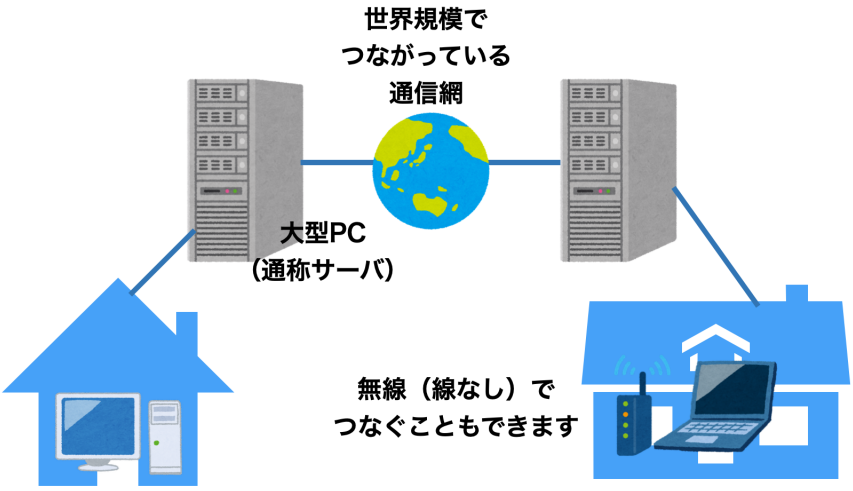

ルがコピーされているため[*24]，意識せずにそのまま作業を続けられるということです。自動的にバックアップをとってくれているとも言えるので便利ですね。

もちろん注意すべきこともあります。「他の人に見られたら困るファイル」は通信網の向こうではなく，手元 (ローカル) に置いておきましょう。個人情報・機密情報などを，クラウドドライブに保存すると，悪意を持った人が大型計算機に攻撃を仕掛けて情報を盗んでいく可能性があるからです。情報化の怖いところは，取られても気づかない (コピーすればいいだけで元ファイルになんの影響もない) ところにあります。加えて，取られたものをばら撒かれる＝インターネットを介して誰でもアクセスし保存できるようにされると，すべてを回収できなくなるのも問題です。失言が記録されて拡散されると大変なことになるのは，みなさんもこの時代に生きる人間のマナーとして色々見聞するところと思います。

また，アプリケーションの実行ファイルは，たとえば Word や Excel などのアプリケーションを起動するためのファイルです。これらは OS がインストールされているローカルに置いておく必要があります。クラウドサービスで自動的に同期されるといっても，アプリケーションの実行ファイルなどはローカルに保存するべきです。アプリケーションは実行に際してさまざまな関連ファイルにアクセスしますので，1 つでも場所が違うところがあるとエラーになって動かなくなります。同じ OS でも，です。インターネットからとってきたソフトウェアをうっかり OneDrive に保存してしまうと，アクセスできないエラーで起動しない，ということもありますので注意してください[*25]。

余談ですが，R などプログラミングを教えているときに最も頻発する質問が「ファイルがありません/読み込めません」です。その理由は大きく 2 つあって，1 つはスペルミスです。ファイル名の大文字・小文字の違いということもありますし，拡張子のまえに半角スペースが入っている，というよくみてみないと気づかないようなものもあります[*26]。2 つめの問題は，パスが通らないことです。デスクトップに置いたのに見つからない，ということもよくあります。教員や TA を悩ませるタイプの問題として，同じファイル名・フォルダ名が別の場所にあ

[*24] これはユーザが特段の指示をしなくても，アプリケーションがユーザの見えないところで (バックグラウンドで) アップロード，ダウンロードの作業を進めているからです。PC はシャットダウンしていなければ，裏でこうした作業を淡々とこなし続けてくれています。

[*25] マイクロソフト社は，これまたユーザのためを思ってやっているのかもしれませんが，デフォルトで OneDrive に保存させようとします。それでうまくインストールできなかったという相談も多々寄せられています。抜本的な解決策として，Windows を使わないことをお勧めします (半分冗談です)。

[*26] これはたとえば，`sample.csv` というファイルをダウンロードしてね，と指示したときに，複数回同じ場所に保存してしまって，機械が，`sample (1).csv`，`sample (2).csv` などと名前をつけるときに起こります。この `(1)` を削除しても，その前に半角スペースが入ってたりするのです。まったく Windows は！

ることがあります。フォルダ A の中にファイルを置いたのに見つかりません，という質問に対応していて，確かにフォルダ A を開いているのにな，と思ったら別の場所のフォルダ A だった，ということがあるのです。パスは隅々まで同じでなければ意味がないので，自分がどこに何を置いたのかをしっかり把握しておきましょう[*27]

2.6 ファイルの位置の指定

ここでファイルとそのパスについて説明します。

計算機が情報を 0/1 で管理し，それらがファイルとなってどこかに保存されている，ということでした。私たちは Finder や Explorer などファイルブラウザをつかって，実行したいファイル，参照したいファイルを探していきますね。ファイルをまとめてフォルダにまとめられ，さらにフォルダの中にフォルダがあるといった階層状態になっていることも少なくありません。ちなみに**フォルダ**と同じ意味で**ディレクトリ**という言葉が使われることもあります。

2.6.1 相対パスと絶対パス

普段 PC を使っているときは気にすることがありませんが，R や RStudio などプログラミング言語をつかっているときは，「今どこで作業しているか」という現在地が重要になってきます。たとえば，RStudio で `C:\Users\kosugitti\Documents\kiso1\`というところでプロジェクトを開いているとします。バックスラッシュ (\) はフォルダ，コロン (:) はドライブを表す記号です。プロジェクトフォルダは，C ドライブの Users フォルダの下にある，kosugitti フォルダの下にある，Documents フォルダの下にある，kiso1 というフォルダということになります (プロジェクト名が `kiso1` だとそうなります。)。この kiso1 フォルダが現在地です。

ただし，R のコードの中でフォルダの区切りを書くときは，バックスラッシュの代わりにスラッシュ (/) を使います。R の文字列の中ではバックスラッシュが特別な意味を持つので，`"C:\Users"`のように書くとエラーになるからです。Windows でもスラッシュで書けば正しく読み込めます。

このフォルダの中で，Quarto ファイルや R スクリプトファイルを使って，他のファイルを参照するようなコードを書くとしましょう。たとえば `script1.R` というファイルに `read_csv` 関数を書いたとします。読み込みたいファイルは，同じフォルダの中にある，`sample.csv` だとします。このとき，`read_csv` の書き方は次のようになるでしょう。

code : 2.1 相対パスで読み込む

```
1  dat <- read_csv("sample.csv")
```

しかし別の書き方もあります。たとえば code 2.2 のような書き方でも問題ありません。

code : 2.2 絶対パスで読み込む

```
1  dat <- read_csv("C:/Users/kosugitti/Documents/kiso1/sample.csv")
```

後者 code 2.2 の書き方は，ファイルの場所を全部書いてありますから，確実にその場所が特定できます。それに比べて前者 code 2.1 の書き方は，なぜファイルを書いただけでいいのでしょうか。これは，このコード

[*27] Windows は OneDrive にもデスクトップがあります。同じ環境がローカルと同時にクラウドにもあって常に同期していればいいのですが，必ずしもそうではないので (OneDrive の設定によります)，`C:\Users\Username\Desktop` と `C:\Users\Username\OneDrive\Desktop` のどちらに保存したのかが分かりにくくなっています。デスクトップに保存したのに，と言われてもどっちのデスクトップなのか，という問題が生じるわけです。さらに専修大学では 2023 年から仮想デスクトップ環境 (VDI) を使うようになりました。これで 3 つ目のデスクトップができたことになるわけです。なんてこった！まったく Windows は！

を実行している現在地と同じフォルダの中に sample.csv ファイルがあるからです。プログラムは，命令を受けるとファイルを探しにいきますが，現在地と同じフォルダの中を探すことになっているのです。この現在地，すなわち現在作業しているフォルダのことを**作業フォルダ (working directory)** と言います。

では作業フォルダと別のフォルダの中にファイルがあれば，アクセスできないのでしょうか。そんなことはありません。code 2.2 の書き方を使えば，作業フォルダがどこにあっても位置を特定できますから，作業フォルダを問わずに書くことができます。ちょっと長くて面倒ですが，確実にある場所を指定しているからです。この書き方のことを**絶対パス**による指定といいます。一方，code 2.1 の書き方は，今の作業フォルダから見た場所，という相対的な書き方になっています。この書き方のことを**相対パス**による指定，といいます。相対パス指定で，違うフォルダにアクセスする場合には，次のようにします (code 2.3)。ここでは，Documents フォルダの中に，kiso1,kiso2 フォルダがあり，kiso1 フォルダの中で作業しているときに kiso2 フォルダの sample2.csv ファイルを読み込む例を書いています。

code : 2.3 別のフォルダのファイルを読み込む

```
1 # 絶対パス指定
2 dat <- read_csv("C:/Users/kosugitti/Documents/kiso2/sample2.csv")
3 # 相対パス指定
4 dat <- read_csv("../kiso2/sample2.csv")
```

絶対パスはそのままなのですが，相対パスは../という記号になっていますね。このピリオドを 2 つ打つ方法で，「ひとつ上のレベルの」という意味になります。このように，現在地からの相対的な位置関係で，ファイルを指定することもできます。

絶対パスと相対パスのどちらが良いのか，というのは一概には決められません。絶対パスは，PC が変わったりフォルダの構造が変わったりすると役に立ちませんから，使い勝手が悪いと言えなくもないですが，確実に指定できる方法です。相対パスは，PC が変わったりしても「現在地から相対的に見てどこか」という話ですから，たとえばこの例で kosugitti フォルダごと別の場所に移しても (たとえば D:\Univ\Classes\kosugitti\Documents\kiso1 のように)，コードはエラーなく動きます。kiso1 フォルダ，kiso2 フォルダの相対的な位置関係が変わらなければいいのですから。バックアップを取ったり，複数の環境で同期しながら作業する場合などは相対パスの方がいいでしょうね。

いずれにせよ，現在どこで作業しているか，すなわち作業フォルダの場所を意識しておくことが重要です。ファイルをどこに置いたか，どんなファイルを置いたか，自分はどこにいるのか，これが変わってくると「ファイルが見つかりません」というエラーになるのです。言い方を変えると，ファイルが見つかりませんエラーの原因は，この 3 つのどれかであることがほとんどです。

2.7 キーボードとショートカット

最後に，キーボードの話をしておきましょう。PC を使う上で，マウスを使うことが多いと思いますが，キーボードを使うことも多いと思います。特にプログラミングをする場合は，キーボードを使うことが多くなります。キーボードは，PC の中にある情報を入力するための装置です。キーボードには，アルファベットや数字，記号などが書かれたボタンが並んでいます。これらのボタンを押すことで，PC に情報を入力することができます。

これから皆さんはキーボードを通じて計算機に指示を与えていくことが増えますが，このときよくあるのが打ち間違い，スペルミスです。X と x，S と s など大文字と小文字で形が同じものや，l(エルの小文字) と 1(数字のイチ) の違いなどは，プログラミング用フォントにして違いがわかるようにするとか，文字列の意味から類推する (Normal とあればノーマルであって，ノーマ・イチではないと察する) など工夫が必要かもしれま

せん。

さて，これらはまだ序の口。プログラミングのコードを読んでも，日本語の五十音に入っていない記号の違いがわからない，どこでそれが入力できるかわからない，質問しようにも読み方がわからないといったものもあります。ここではこれらをまとめて解説します。記号の上では微妙な違いですが，当然形が違うのでプログラミング上は違う文字として扱われますので，形の細部までよくみてください。なお，プログラミングでは言語に依存することもありますので，ご注意ください[*28]。

特に目立つのはハイフンとチルダ，アンダースコアの入力ミスです。それぞれ文字を書く領域における位置が違ったり，形が違ったりするのでよくみてください。

ハイフンは真ん中	A-B
アンダースコアは下	A_B
オーバーバーは上	A‾B
チルダはニョロ	A~B

これを踏まえて，そのほかの記号の名称や意味を表 2.1 で確認しましょう。

一般的な日本語キー配列の場合，1 つのキーに 4 つの文字・記号が割り当てられていますが，英語入力モードの場合はキーの左側，日本語入力モードはキーの右側を見ることになります。キーを押すと下の段の文字が入力されますが，シフトキーを押しながらキーを押すことで上の段の文字が入力されることになります (図 2.3)。

図 2.3 日本語キーで入力する場合

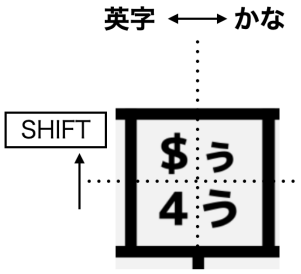

これを踏まえて，日本語キーについては図 2.4，US キーについては図 2.5 に代表的な記号とキー配列の位置を示しました。入力に困った場合は一度図を見て確認してください[*29]。

これらの配置を覚えた上で，素早く正しく入力できるように普段から慣れておくことが上達への鍵になります。特にこれから先の人生でもキーボード入力をする機会は増えていくはずですから，早いうちに修練した方が良いでしょう。特にプログラミングをする場合は，キーボードを使うことが多くなりますので，ショートカットキーを覚えておくと便利です。

2.7.1 ショートカットキー

ショートカットキーとは，特定の操作を行うためのキーの組み合わせのことを指します。たとえば，Ctrl キーと C キーを同時に押すことで，選択したテキストをコピーすることができます。このように，ショートカット

[*28] たとえばコメントアウトは C 言語では\\，R では#，TeX では % など，それぞれ異なります。

[*29] US キー配列はキートップに一種類の文字しかなく，美しい配置なのでおすすめです。

表 2.1 記号と読み方

記号	読み方	解説
:	コロン	英文中では「すなわち」などの意味。セミコロンと間違えないように
;	セミコロン	英文中では文章の区切り，接続詞のようにつかう
.	ピリオド	英文の終わりを意味する。日本語で言う句点
,	カンマ	英文の区切りを意味する。日本語で言う読点
@	アットマーク	メールアドレスに用いられることで有名
$	ドルマーク	米国の通貨単位。R では変数名指定のときにもちいる
/	スラッシュ	割り算の記号
*	アスタリスク	掛け算の記号
+	プラス	足し算の記号
-	マイナス	引き算の記号
^	ハット	累乗の計算の記号
=	イコール	等号。プログラミングでは==で一致しているかどうかの判定にも
!	エクスクラメーション	強調。プログラミングでは否定 (NOT) の意味になることも
_	アンダースコア，アンダーバー	位置に注意。ハイフンではなく文字領域の下の線 変数名をつなげる時 (ex. snake_case) に使ったりする
~	チルダ	R では独立変数と従属変数をつなぐときに使う ハイフンやオーバーライン，アンダースコアと間違えられる率高め
¯	オーバーライン，オーバーバー	アンダースコアの逆。滅多に使わないが。文字化けを直したときにみられる。
%	パーセント	プログラミングではコメントアウトの時などに使われたりする
&	アンパサンド	プログラミングにおける AND(論理積) の記号など
|	縦棒	プログラミングにおける OR(論理和)，条件つき確率の記号にも
\	バックスラッシュ	プログラミングではコメントアウトの時などに使われたりする
"	ダブルクォーテーション	文字列の開始・終了を表す。同じ記号で閉じる
'	シングルクォーテーション	文字列の開始・終了を表す。同じ記号で閉じる
`	バッククォーテーション	文字列の開始・終了を表す。同じ記号で閉じる
[]	大括弧	プログラミングでは配列を意味することがある
{}	中括弧	プログラミングではブロックの開始と終了を意味することがある
()	小括弧	数式のまとまりを表す

キーを使うことで，マウスを使わずに素早く操作を行うことができます。

これらのショートカットキーを使うことで，マウスを使わずに素早く操作を行うことができます。特にプログラミングをする場合は，キーボードを使うことが多くなりますので，ショートカットキーを覚えておくと便利です。

2.8 まとめ

計算機は，味方にするととても頼りになりますし，人間の計算能力，記憶能力を拡張してくれるデバイスです。現代においては紙とペンと同じような文房具ですので，いかにうまく使うかが重要です。何もしていないのに計算機が壊れた，というようなことはあり得なくて，自分が何をしたか理解していないというのが実態です。もちろん大事なときに意図せぬ動きをされると腹が立ち，実際に困るので嫌いになってしまうことも理解で

図 2.4 代表的な記号と日本語キー配列

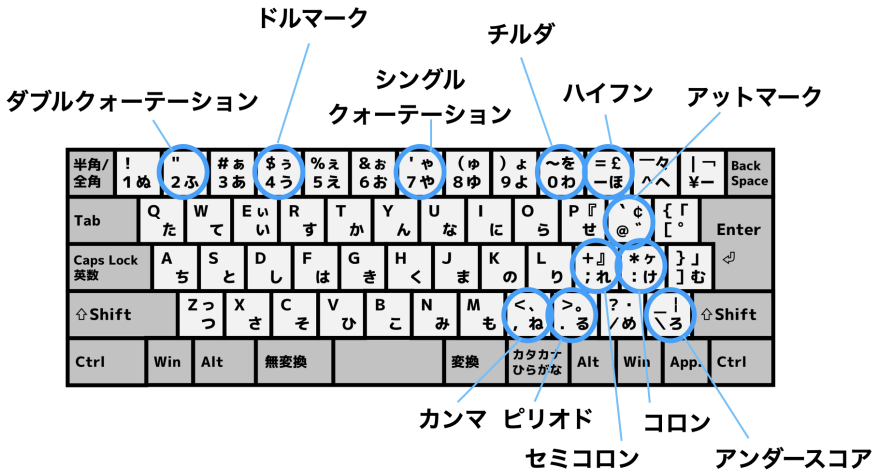

図 2.5 代表的な記号と US キー配列

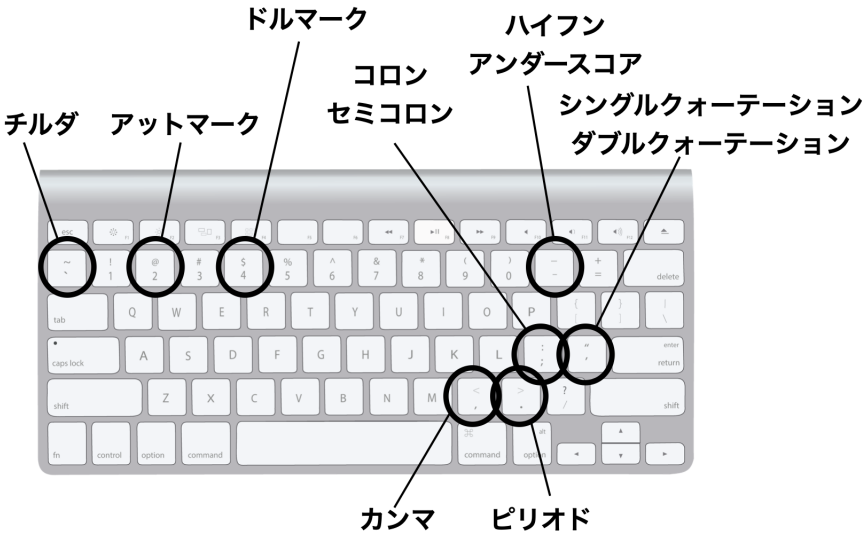

563 きますが，家族や友人のように好意を持って接し，丁寧に扱うことで素敵な経験を一緒に重ねていくことがで
564 きます。まずは計算機に名前をつけ，飾ったり (デコったり)，便利な拡張機器を追加するなどして，自分好み
565 の可愛い相棒にしましょう。

表 2.2　よく使うショートカットキー

操作	Windows	Mac
コピー	Ctrl + C	Command + C
貼り付け	Ctrl + V	Command + V
切り取り	Ctrl + X	Command + X
取り消し	Ctrl + Z	Command + Z

第 3 章

統計環境 R の導入

前回は電子計算機の概略を説明しました。今回は電子計算機，特にパソコンを使って実際に統計処理をしていくことにします。

パソコンを使って統計処理をすると言えば，Excel や Numbers,Calc のような表計算ソフトをイメージするかもしれません。しかし統計的な処理に，それらの表計算ソフトでは不十分なのです。表計算ソフトは，行方向，列方向についての計算やグラフオブジェクトを簡単に描くことは可能ですが，行列を同時に・全体的に分析したり，ある特定の変数をターゲットにした統計的な判断など，心理統計の実践的シーンで必要な計算がそのままではできません[*1]。また，Excel は WindowsOS に，Numbers は MacOS に限定されたソフトウェアです[*2]。特定の OS を使っていないと計算ができない，というのは科学的な発想と相性が良くありません。科学はオープンで誰にでも積み重ねることのできるコミュニケーション・スタイルでなければならないからです。

専修大学人間科学部心理学科では，心理統計ソフトウェアとして R を使うことにしています。これは統計に特化した言語であり，フリーソフトウェアです。以下に詳しく見ていきましょう。

3.1 統計環境 R/RStudio の準備

ここでは統計環境 **R** について解説します。

R は統計環境，統計言語とも呼ばれることがあります。統計に関する分析を CUI で行うので統計 “言語” と呼んだり，数字だけでなく図を描くなど数値処理に関わることを全体的にカバーしているので “環境” と呼ばれたりします。R が優れている点はフリーソフトウェアであるという点で，誰でも無償で利用できることです。商用ソフトウェアと違って，ソースが公開されているのでその気になれば誰でもその内部構造を調べることができますから，間違い (エラー，バグ) がないかどうかをみんなの目でチェックできるというのが利点です。金銭的に補償があるわけではないのですが，そもそも学問の世界は市井の資本主義的発想とは異なる価値で評価される世界ですから，無償であることは問題になりません。

また R は多くの研究者が利用しており，その研究成果をフリーソフトウェアの精神で共有しています。こうした R の基本関数以外の機能は，パッケージという形で提供されます。R のパッケージを共有している場所は The Comprehensive R Archive Network(**CRAN**) と呼ばれ，ここに登録されているパッケージは誰でも利用できます。最先端の分析ツールがここを介して共有され，間違いや問題が生じたら随時修正されていきますので，成長する統計ソフトウェアということができるでしょう。

[*1] そのままでは，というのは関数を使ったりマクロを組んだりしたらできるからです。実際に，Excel にいろいろな追加機能をつけて心理統計分析ができるようにしたソフトウェア ((清水，2016) など) もあります。しかしそれらは追加的なオプションでフリーソフトウェア，シェアウェアだったりしますので，ここでは「そのままでは」と表現しています。

[*2] Word や Excel の Mac 版もありますが，オリジナルは Windows 版で，Mac 版はその移植ということでできることに限界があったりもします。

またこの授業では，R を使うにあたって **RStudio** という総合開発環境アプリを使います。R というアプリケーションを便利に使うためのアプリケーション，それが RStudio です。

R は優れた統計ツールではありますが，本体だけでは簡素な言語的やりとりができるに過ぎません。分析を進めていくとすぐにわかりますが，ファイルの操作や描画機能，過去ログの参照や管理など，統計言語を扱う際にそれを取り巻くさまざまな操作が必要になります。ここをカバーしてくれるのが RStudio というアプリケーションなのです。

RStudio はそれ単体では使うことができません。R が入っている PC 上で，R を取り込んで初めて意味のあるアプリケーションになります。R の計算機能を活用するだけでなく，文書作成機能やデータベースとの連携など非常に高機能な統合的サービスを提供してくれます。文章を書き，その文章に必要な計算を行い，その結果がすべて記録 (スクリプト，コマンド，プログラム) として残るわけですから，科学論文を書くためには RStudio だけでも十分です。

3.1.1 環境を構築しよう

専修大学では 2023 年度から，仮想デスクトップ環境 (VDI) の活用を推進しています。大学が仮想空間の中に個々人のデスクトップ環境を用意しているので，私たち利用者は自分自身のデバイスからアクセスするだけで，全員共通の環境が利用できるというのが利点です[*3]。ここへのアクセスの仕方，利用方法については専修大学情報科学センターからのガイダンスや，利用案内ページがあるのでそこを参照してください。

この，本学が提供する仮想デスクトップ環境や，心理学科が管理する 4 号館 4F の PC 室には R や RStudio がすでにセットアップされていますので，これを利用するのであればとくに準備は必要ありません[*4]。

しかし大学などの設備は大学が管理していますので，自分でパッケージを追加したい，とおもっても管理権限がなくうまく行かないこともあるかもしれません。幸い R や RStudio はフリーソフトウェアですので，手元の PC にインストールして環境を構築するにしても，元手は一切かかりません。これを機に，自分のパソコン環境に R/RStudio を準備しておくと良いでしょう。

R や RStudio の環境構築については，その方法を検索すればさまざまなものが出てきますので，そちらを参考にしてください[*5]。以下には 2025 年 4 月現在，リンクが有効な Web 上の記事を紹介します。

■Windows ユーザ向け

1. 東京大学・大学院農学生命科学研究科アグリバイオインフォマティクス教育研究プログラムによる https://www.iu.a.u-tokyo.ac.jp/textbook/R/R1.010_win.pdf
2. 初心者向け R のインストールガイド https://syunsuke.github.io/r_install_guide_for_beginners/
3. 関西学院大学商学部土方ゼミ http://soc-research.org/ja/r_install_windows/
4. 多摩大学情報社会研究所・応用統計学室 https://stats.ni.tama.ac.jp/?p=46
5. 奥村 晴彦先生の https://okumuralab.org/~okumura/stat/R-win.html

■Mac ユーザ向け

[*3] 自分のデバイスを持ってきて繋げる (Bring Your Own Device;BYOD) ので，スマートフォンやタブレットでも PC と同じような利用の仕方ができるのがメリットですが，教育的な側面では大学が準備すべき設備備品費用を個々人に押し付けているとも言えます。大学が PC を全員に配布できればいいのですが。

[*4] 他にも心理学科には，計算機サーバというのがあり，ここに RStudio Server が準備されています。RStudioServer は，インターネットを介するウェブブラウザから RStudio にアクセスすることができるものです。残念ながらまだ試験的導入段階で，心理学科の学生が一気にアクセスするとサーバがダウンしてしまいますので，希望者のみの利用にとどまっています。

[*5] R の唯一の弱点は検索可能性が低いこと。R という一文字で検索してもまともなものにヒットしないので，“CRAN” とか “R と RStudio インストール” など周りに言葉を足して検索してみてください。

1. 東京大学・大学院農学生命科学研究科アグリバイオインフォマティクス教育研究プログラムによる https://www.iu.a.u-tokyo.ac.jp/textbook/R/R1.010_mac.pdf
2. note の https://note.com/toshi_matsuura/n/n127cf28362e5
3. いちばんやさしい，医療統計 https://best-biostatistics.com/r/rstudio_start.html#i-3
4. 群馬大学大学院医学系研究科機能形態学の https://anatomy.med.gunma-u.ac.jp/protocols/?p=979
5. コアラさばお氏の notehttps://note.com/mackerelman/n/nfbf8054e90d5
6. Ryu Takahashi 氏の Qiitahttps://qiita.com/ryu-takahashi2718/items/1118cad7a4ef4900da96
7. Yuhki Yano 氏の Qiitahttps://qiita.com/y-vectorfield/items/dd1a8e2715cace9981ec

以降は環境が準備できているものとして解説を続けます[*6]。

3.2 R/RStudio の基本操作

それでは今から，RStudio を使った統計処理の演習を始めましょう。少し不便かもしれませんが，この資料を見ながら，**必ず自分でコードを入力しながら**進めていってください。テキストと同じ結果が手元で再現できることを確認しながら進むことは，再現できることの重要性の確認になります。また，最初のうちは打ち間違えなどで思うように動かないことも頻発するでしょうが，その経験を繰り返すことで徐々に使い慣れていきます。失敗の経験はテキストの文中に書き込まれていませんから，読むだけでは身につきません。また，読み進んで気が向いたところだけ実行するときは，その前のデータや内容を参照している場合にエラーになるので，結局元に戻ってやり直すことになります。最初のうちは写経して作法を身につけることも重要なのです。最初の基礎的な訓練[*7]ができていると，徐々に大きなプロジェクト[*8]を動かすことができるようになりますので頑張って！

3.2.1 RStudio の機能と画面

最初に RStudio を起動すると，図 3.1 のような画面になっていると思います[*9]。ここでメニューから `File > NewFile > RScript` と進むと (図 3.2)，画面に白いページの領域が追加されます (図 3.3)。

大きくみると画面が四分割されたようになります。この 4 つの領域を基本として話を進めていきます[*10]。

■コンソール・ペイン デフォルトでは画面の左下になりますが，**コンソール (console)** ペインにあるのが R そのものです。RStudio は R を取り込んで使いやすくする環境を提供するもの，という話をしましたが，とりこまれた R だけの画面が左下にあります。そこには R のバージョン情報や，次のような注意書きが書かれ

[*6] トラブルがあって環境の準備がうまくできていない場合は，`classkosugitti@gmail.com` までご相談ください。

[*7] キーボードの入力に慣れていない人は，ブラインドタッチの練習をすることをお勧めします。キー入力は今後も活用できる社会人の基本スキルですので，なるべく早く習得しておいた方が人生が楽しくなります。ブラインドタッチの練習には，寿司打などのサイト http://typingx0.net/sushida/play.html で遊びながら学べていいですよ。ちなみに今やってみたら，私の成績は「高級 10,000 円コース【普通】で、★ 6,700 円分 お得でした！ (速度: 6.1key/秒、ミス: 55key) 」でした。

[*8] 卒論は 4 年間の集大成になる個人プロジェクトです。

[*9] こちらは MacOS11.1，RStudio は 1.4.1103，R は 4.0.3 の環境におけるスクリーンショットです (撮影時 2021 年 2 月 2 日)。2026 年 8 月 22 日の段階では，MacOS26.5.2，RStudio 2026.08.1 Build 195 "Yellow Yarrow" Release，R version 4.6.1 です。OS が違うとか，バージョンが違う，サーバ版を使っているとかで細部が異なっている可能性がありますが，ほとんど変わらないと思います。

[*10] RStudio version1.4 から，列を追加することができるようになりましたので，必ずしも四分割で使わなければならないというわけではありません。どこに何があるのかを把握していれば OK です。ちなみに列を増やしたり配置を変えたりするのは，`Tool > Global Option > Pane Layout` から可能です。

図 3.1 RStudio 起動初期の画面

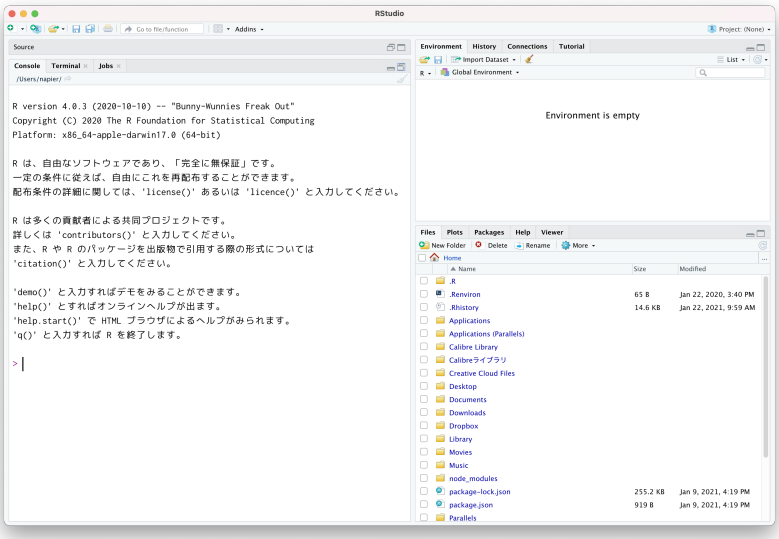

図 3.2 新しくスクリプトファイルを開く

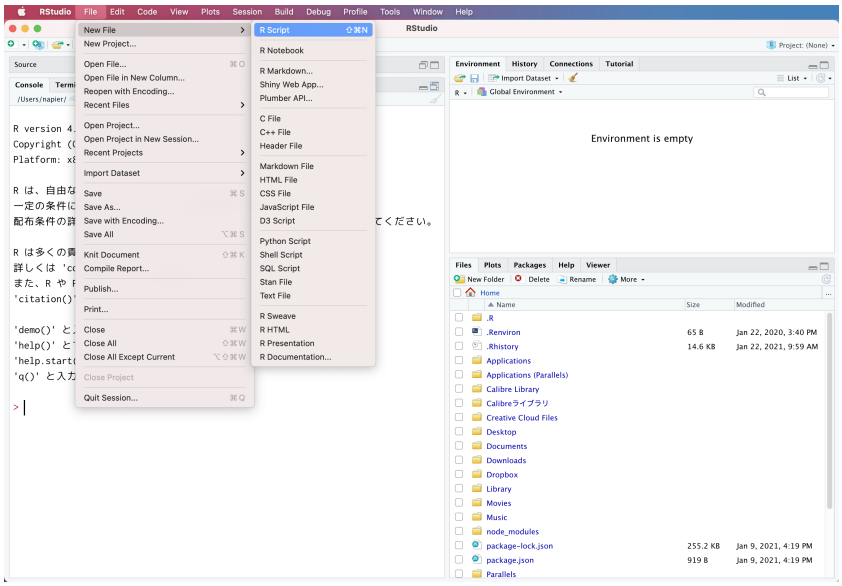

652 ています。

図 3.3 RStudio の画面

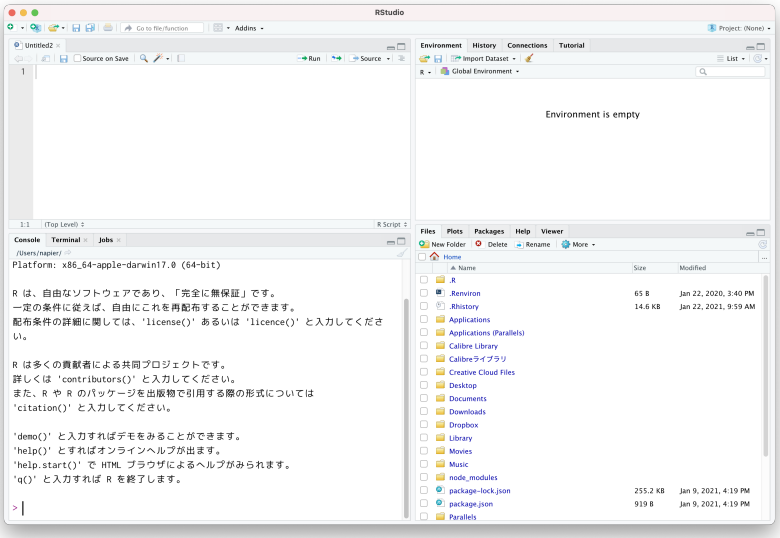

R の出力 3.1

```
R version 4.6.1 (2026-06-24) -- "Happy Hop"
Copyright (C) 2026 The R Foundation for Statistical Computing
Platform: aarch64-apple-darwin25.4.0

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.
```

その下に>という記号が出ていると思います。これは入力を待っている状態でこの記号の右側に命令をどうぞ，という意味です。この記号が出ているときは，R は次の動作準備 OK で指示を待っているという状態です。ここにコードを入力すれば計算結果が出力されるのですが，その前にスクリプトペインの説明をします。

■スクリプト・ペイン スクリプトペインは，R のコードを書くところです。R は一問一答型 (インタプリタ*11方式ともいいます) なのですが，実際の統計処理はあれをして，これをして... とたくさんの処理が連なることになります。この一連の手続きを書いておくのがこの場所です。

スクリプトとはお料理のレシピのようなものです。1 つ 1 つの計算は，たとえば「玉ねぎをみじん切りにする」といった単一の作業をさせることになりますが，全体としてハンバーグを作るのが目的であれば，1 つ 1 つの作業をすべて順番通りに実行しなければなりません。直接コンソールペインに書き込んで言ってもいいのですが，途中で「今どの工程だっけ」というのがわからなくならないとも限りませんので，いったんスクリプトのところに書いてから実行する，という手段を取るのが便利です。

実際にコマンドを 1 つ 1 つ書いていくときには，書き間違えたり違う方法を試したくなったりするので，書い

*11 プログラミング言語の実行方法として，コードを逐次翻訳していく方法と，プログラム全体を一気に機械語に翻訳して実行する方法の2種類があります。前者をインタプリタ方式，後者をコンパイラ方式と言います。インタプリタ方式の利点は書いたコードがすぐに実行されるので，どこでどういう処理がされているか分かり易いことです。エラーがあってもすぐにその場で帰ってきます。コンパイラ方式の利点は実行速度です。全部の処理を一気に機械語に翻訳してあるので，計算速度が非常に早くなります。コンパイラ方式の欠点は，どこでエラーが生じたかわかりにくい点です。

たり消したりしながら進むのが普通です。ですが最終的には清書したものだけを残すようにしましょう。下書きの要素もすべて記録していると，あとで何がどうなったかわからなくなります。また，何度か繰り返しているうちに「何にどのような操作をしたか」がわかっているようでわからなくなることがあります。最終的には，1 つのスクリプトファイルを一行目から順に実行していけば，すべての作業が再現できるようにする，ということが重要です。途中で別のレシピを参照したり，記録されていない操作を挟むのはやめましょう。

さてでは，このスクリプトペインに code:3.1 を書いてみてください[*12]。

code : 3.1　四則演算のコード

```
1    # 四則演算
2    1+2
3    2-4
4    3*5
5    6/3
6    sqrt(16)
```

■コード解説

1 行目　コメントアウト。#記号で始まる行は，その後ろに何を書かれていても R は無視します。なので，この記号を冒頭に書いて，ここに何をしているかという説明を書き入れています。このコメントは，あとで見直すときに何をしていたか判るためのものなので，必ず書かなければならないというものではないのですが，あればあるほど親切で丁寧なコードと言えるでしょう。

2-5 行目　順に和，差，積，商を求めるコードです。積*と商/の記号は PC ではこのように書きますので注意してください。

6 行目　これは関数を使って答えを出しています。sqrt 関数は正の平方根を返します。

書いたあと，スクリプトペインの右上にある Run を押すと一行ずつ実行されていきます。あるいは，CTRL+Enter でもスクリプトをコンソールに送り込むことができます。マウスで複数行を選んで Run ボタンを押すと囲んだ箇所を実行することもできます。このスクリプトペイン全体を実行したいときは Source ボタンを押します。

これらのボタンを押すと，コードがコンソールに送られて実行結果が返ってきます (図 3.4)。コンソールに示されているものは，この資料では次のような囲みで表現します (**R の出力** 3.2) が，さて，みなさんの環境で同じ結果が得られましたでしょうか。

[*12] この資料では指示がわかりやすくなるように行番号を含めて表示していますが，実際は行番号を入力する必要はありません。

図 3.4 スクリプトを実行する

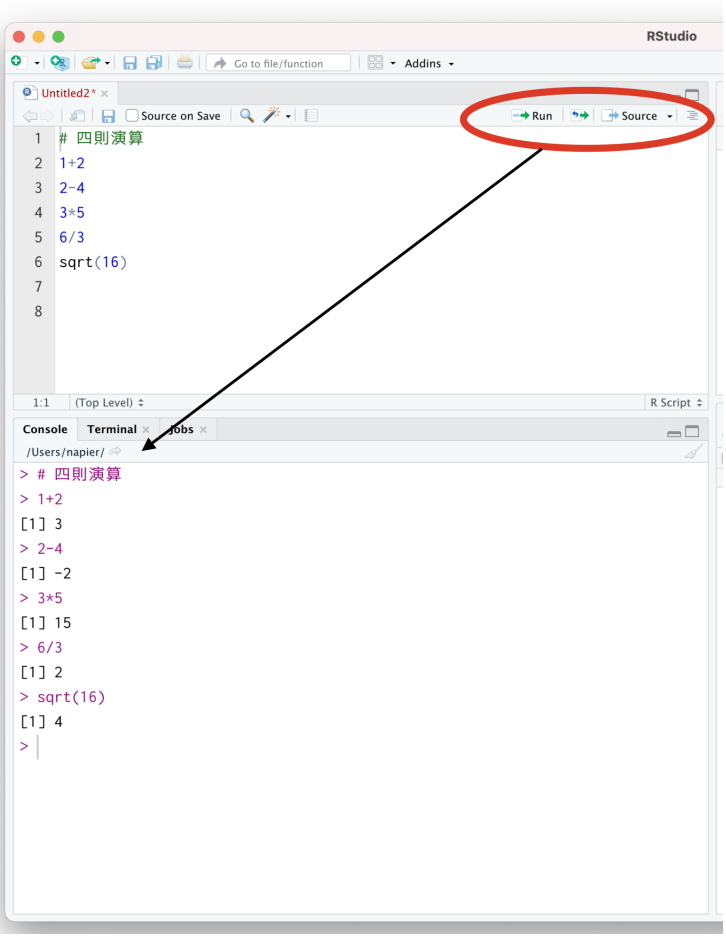

R の出力 3.2: 四則演算

```
> # 四則演算
> 1+2
[1] 3
> 2-4
[1] -2
> 3*5
[1] 15
> 6/3
[1] 2
> sqrt(16)
[1] 4
```

出力をみると，1 つ 1 つの問い (たとえば 1+2) に対して，毎回答え (たとえば [1] 3) が返ってきています。一行ずつ実行した人はわかると思いますが，毎回>の記号がでて R が回答準備ができているときに，次の命令を受け入れることになります。もしおかしなコマンドが入っていれば，エラーが出ているはずですので，それをよく読んでどういうエラーなのかを考えましょう。我々が書くコードは，ミスやバグが多分に含まれます。私もいまだにスペルミスでエラーを発生させています。複数行を一気に実行してしまうと，どこにエラーが出ているかわかりにくくなりますので，一行ずつ実行することを強くお勧めします。

ところで，$1+2$ の答えは 3 ですが，出力の [1] はなんでしょう？ これは答えの要素がひとつ，という意味です。これからたくさんのデータを一度に処理することがありますが，そのときは答えがたくさん出てくることがあるので，その場合は何行にもわたって答えが返されることがあります。詳しくは後ほどの実践例で説明していきます。

さて，これが基本中の基本の使い方です。実践的な内容に入る前に，そのほかの RStudio ペインの説明をしていきましょう。

■Environment/History・**ペイン**　画面の右上にあるのは Environment や History のペインです。Environment は環境，すなわちこの R の頭の中にどういう変数，関数が入っているかを示してくれるところです。たとえばたくさんのデータセットを読み込んだ，というときは，それがどういうデータなのかを示してくれたりします。

History は履歴を表すタブです。ここをみると，今実行した過去のログが残っています。「さっき書いた命令をもう一度実行したい」というときはここで探すといいでしょう。このペインには，`to Source` や `to Console` といったボタンもあります。ある行を選んでこのボタンを実行すると何が起こるか，確かめてみてください。

■Files/Plots/Packages/Help/Viewer・**ペイン**　右下のペインはよく使う便利なところです。

1. Files ペインは，ファイル操作をする場所です。ファイルのコピー，移動，フォルダの作成などができます。エクスプローラや Finder と同じようなものだと思ってください。
2. Plots ペインは図の出力を確認するところです。ここで作られた図を適当なサイズやファイル形式に変換して出力することもできます。
3. Packages ペインは，R のパッケージを管理するところです。R はパッケージを追加することで機能がアップしますが，この追加やアップデートをこのペインで実行すると便利です。
4. Help ペインは，関数のヘルプが表示されるところです。表記はすべて英語なのが残念ですが。
5. Viewer ペインは HTML などの出力をみる画面です。

これらは必要に応じてみていくことになりますので，ここでは大体のイメージが掴めていれば OK です。またこれらのペインは場所を変えることも可能ですので，自分の良いようにレイアウトしてみてください。

3.2.2 プロジェクト管理

さて環境の意味がわかったところで，いよいよ実践に入っていきます。先ほども少しコードを書いてみましたが，今度はより本格的に使っていこうと思います。

プロジェクトによる管理

RStudio を使う時の基本は，プロジェクトによる管理です。分析するデータ，テーマ，内容によってプロジェクトを切り替えながら使います。みなさんはこの授業の他にも，R を使う授業があるかもしれません。また，学年が上がっていくにつれて，さまざまな心理学実験，研究に関わっていくことになります。その時，すべてを同じドキュメントフォルダに入れてしまうと，何が何だかわからなくなるので，フォルダごとに区分しますよね。それと同じように，R で作業する場所を RStudio でも区切りながら管理しようということです。

メニューバーから `File > New Project` と進んでください。すると「New Directory」「Existing Directory」「Version Control」の選択肢が出てきます。New Directory は新しいディレクトリ[*13]を作ってそこで関

[*13] 計算機におけるディレクトリとフォルダは同じ意味です。

連ファイルをまとめますよ，という意味です。Existing Directory はすでに存在するディレクトリをまとめる場所にしますよ，という意味です。みなさんの環境に応じて使い分けてください。ここでは新しくフォルダを作る例を説明します[*14]。

図 3.5 プロジェクトを作る場所を選ぶ

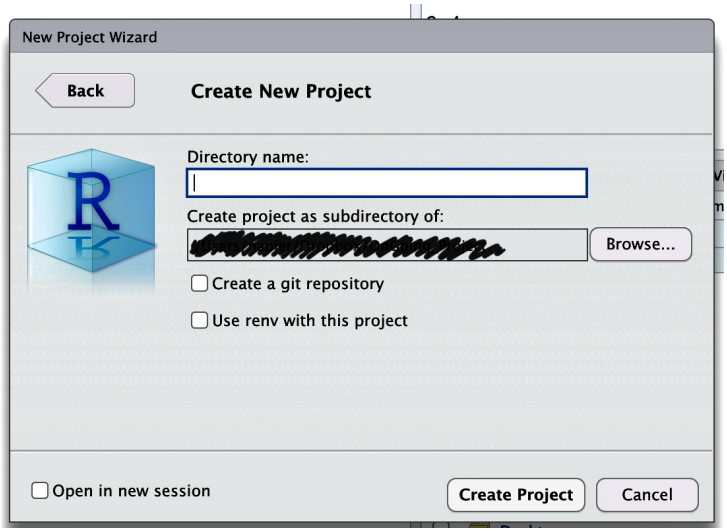

注意！ 1: プロジェクトを「ホーム」に作らないで！

Windows ユーザのために注意です。エクスプローラを開いたときに最初に表示される「ホーム」にプロジェクトを作らないでください。「ホーム」は**本物の場所ではありません**。よく使うフォルダや最近開いたファイルを一覧表示しているだけの、いわば「ショートカット集」のような画面であり，ここに作ると実際はドキュメントフォルダに作ったことになります。「ホーム」に作ったのに，「ホーム」にない！ということがおきます。Windows のフェイク画面に騙されないで！

注意！ 2: プロジェクトを「OneDrive の中」に作らないで！

OneDrive にプロジェクトフォルダを作ると，ファイルが保存できなくなるエラーが発生します。OneDrive はインターネット上に預ける仕組みですが，ローカルには実体がなく，開こうとした瞬間にダウンロードしてくる仕組みです。アクセスするパスが一時的に仮想化されており，RStudio 側から見るとデバイスが存在しない！となります。`C:\Users\<ユーザー名>\R_projects\`のような、OneDrive に同期されない場所を作業ディレクトリにする。これが一番トラブルが少ないです。
更なる落とし穴として，新規ユーザーの Documents や Desktop を勝手に OneDrive にリダイレクトします。これを無視して，強い意志で，C ドライブ直下に R_projects フォルダを作ることをお勧めします。まったく，Windows は大きなお世話を焼きたがり，結局ユーザを悩ませるので困りますねえ。

図 3.5 には `New Directory > New Project` と進んだ次のウィンドウを示しています。黒く塗りつぶしているところは私の個人的な PC 環境の内容が反映されるので誤魔化しているのですが，みなさんの環境に

[*14] Version Control はパスしましたが，研究をする上ではこれが重要になってきます。つまり，何月何日にどのような作業をしたか，という記録をすべて残しておく必要があるからです。研究ノートやラボノートと言われる記録をつけるときに必要です。この記録は不正をしていない証拠にもなります。ここを選ぶと Git や Subversion といったバージョン管理ソフトと連携できます。

あった場所 (Document とか Desktop といった場所) を選び，上の空白になっているところに新しいプロジェクト名 (たとえば `toukei` など[*15]) を入力して OK とします。するとしばらくすると，画面が変わるはずです。一見同じ状態のようにも見えますが，実はところどころ違いがあります。気がつきましたか？ 図 3.6 にはプロ

図 3.6 プロジェクトで開いている場合

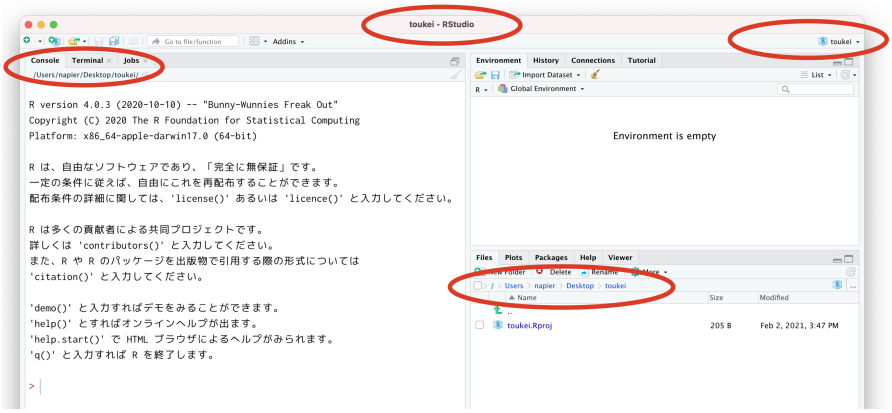

ジェクトを開いている時の RStudio 画面を示しています。赤く丸で囲っているところが，プロジェクトを開いていない時との違いがある箇所です[*16]。これをみると，コンソールペインや File ペインの場所に，今指定したフォルダの位置が示されていることがわかります[*17]。このプロジェクトが開いているフォルダに移動していることが重要で，このフォルダの中が今作業している場所として認識されるので，このフォルダの中にあるファイルにはファイル名だけでアクセスできるようになります。プロジェクトが違ったり，プロジェクトの起動をしていなかったりすると，作業している場所[*18]が変わりますので，注意が必要です[*19]。

3.2.3 エラーはヒントです。怖がらないで

以下ではみなさん自身で R コードを書いていくのですが，誰しも，間違いなく，エラーに遭遇します。エラーはムカつきますし，理由がわかりませんし，何書いているかわからん！ってなりますよね。

でも，エラーはヒントなのです。ここでこういうエラーが生じましたよ，というヒントをくれているし，それに対応しさえすればちゃんと動いてくれます。プログラムは思った通りに動くのではなく，書いた通りに動くのです。ですから，赤字で何か出てきた場合はどういうエラーなのかを読み取るようにしましょう。何行目の，どの部分で生じたエラーかがわかれば，対応の仕方がわかります。

エラーが出て困ったら，遠慮なく私や TA を頼っていただいて構いません。質問するときのコツは，エラーが出た箇所「だけ」を見せてはいけないということです。R は一行ずつ実行していきますから，ある箇所でエラーが出たとしても，その原因がその上流で生じている可能性があります。学生さんの中には，エラーが出た画面の写真をとって送ってくる人も少なくありませんが，大抵はその写真に写っていないところにエラーがあります。そんなときは「ごめん，もうちょっと上をみせて」という返信をするので，回答まで無駄なラリーが続くことがあります。質問するときは，実行しているスクリプトファイルすべてを添付する方が確実で，「これの XXX 行目でエラーと言われます」と報告しましょう。スクリプトのやり取りの利点は，私も R を持っていますから，私

[*15] 半角英数のみで作るべきです。
[*16] MacOS の例なので Windows 版では上のバーのところなど，違いもあります。
[*17] この例では `C:\Users\napier\Desktop\toukei` です。napier は私の PC の名前，toukei はプロジェクト名です。
[*18] ワーキングディレクトリといいます。詳しくは付録の 2.6 を参照。
[*19] 実際に授業をしていて，ファイルへのアクセスエラーで相談を受ける原因第 2 位です。第 1 位はファイルエンコードの問題です。

の環境で同じことをしてエラーの再現ができる点にあります。

自分の書いたコードが恥ずかしくて見せたくない，と言う人もいるかもしれません。あるいは「こんな簡単なことで質問してくるな」と思われるのでは，と思ってしまう人もいるかもしれません[*20]。そうした心理的障壁を乗り越えるのは難しいですが，そんな場合は ChatGPT をはじめとする生成 AI を利用しましょう。最近は (アカウントの登録は必要ですが) 無料で利用できます。そこにエラーメッセージやスクリプトを貼り付けて，「このエラーがこのスクリプトから出た。どこが問題か教えて」というとスラスラっと答えてくれます。生成 AI はシレッと間違えた答えをしてくるのが難点ですが，答えの通りにやってもエラーが出たら「まだエラーが出るんですけど」と言えば，さらにそれっぽい答えを教えてくれます[*21]。

繰り返しますが，エラーメッセージはヒントなのです。メッセージが自分にとっては意味不明でも，わかる人が見ればわかる情報が満載なので，エラーメッセージとスクリプトのセットで質問するようにしてください。

3.3 R の基本操作

ではこのプロジェクトの中で，演習を進めていきましょう。先ほどと同じように，`File > New File` から `R Script` と進んで新しいスクリプトファイルを開きます。

今から色々書いていきますが，これを記録しておくには，ファイルを保存する必要があります。`File > Save` と進むと保存できますので，ファイル名をつけて保存します。拡張子[*22]は `.R` にしておきましょう (小文字の `.r` でも結構です)。とくに思いつかなければ，`Lesson01.R` とでもしておいてください。

3.3.1 関数の利用

先ほど，`sqrt(16)` という関数の例をみました。この `sqrt` 関数はスクェアルート，つまり平方根を求めろというものです。何の平方根を求めるか，というと 16 という数字の平方根ですので，実行すると 4 という答えが返ってくるわけです。

このように，関数名で命令を指定し，その対象は小かっこ () で囲って渡すというやり方をします。$f(x)$ ということですね。括弧の中に入るものは**引数 (argument)** といい，今回のように目的となる数字を渡すこともありますが，そのほか関数を動かす上でのオプションを指定することもあります。また，1 つの引数だけではなく，複数の数字を渡したり，複数のオプションを指定することもあります。

たとえば関数がどのように動くか知りたいという時，ヘルプを開くのも関数で行います。`code:3.2` を実行すると，Help ペインにその説明が出てくるので確認してみてください。

code : 3.2 ヘルプのコード

```
1  # ヘルプも関数
2  help(sqrt)
```

[*20] 断言しますが，こちらはそのようには思っていません。教えるのは仕事ですし，簡単なことでも奥深いことがありますから，なんでも聞いてください。ちなみに，教えないのは教員から学生に対するアカデミックハラスメントです。

[*21] 生成 AI を利用するときは，こちらが望ましい答えや正解を知っている場合に限った方が良いでしょう。生成 AI の答えが合っているかどうかを自分でチェックできるのであれば，これはとても有用です。わからない課題を生成 AI にやらせてみると，合っているかどうかもわからないので，余計にひどいことになります！

[*22] 拡張子については前回第 2 講を参照のこと。

3.3.2 パッケージの利用

R では関数を使ってさまざまな計算をこなします。R をインストールした段階でも，簡単な統計計算は十分できるようになっています。ですが，より専門的な分析やより高機能な情報処理をしようとするならば，**パッケージ (package)** を利用することになります。たとえば，包丁一本で料理をするのは大変ですよね。包丁は確かに切ったり，皮を剥いたり，削ったり･･･と色々できることはできるのですが，皮を剥くのはピーラーで，細かく削るのはフードプロセッサーで，といった便利グッズを使えばもっと楽です。この「便利グッズ」が R でいうところのパッケージです。

R は豊富なパッケージが利用できることがその特徴で[*23]，パッケージは CRAN を通じて世界に公開されています。RStudio のパッケージペインを開くと `install` と `update` というボタンがありますが，`install` ボタンを押すと何のパッケージをとってくるか，入力できるようになります (図 3.7)[*24]。“Packages” とあるところに必要なパッケージ名を入力すると，自動的に CRAN にアクセスしてダウンロードが始まります。パッケージのインストールとダウンロードはその環境下では一度実行するだけで結構です。パッケージというのは関数群であり，関数を記載したファイルのダウンロードが終われば適切な場所 (Library) に保存されます。

ただ，ダウンロードしただけではすぐにその関数が使えるようになりません。ダウンロード後は，必要に応じて `library` 関数でパッケージを呼び出してやると，パッケージに含まれる関数が使えるようになります。購入したものを装備するかどうかは別，ということを頭の片隅に置いておいてください[*25]。また，パッケージの中には関係するパッケージを一まとめにしたパッケージというのもあります。インターネットへのアクセスは必要ですが，優れたパッケージを無償で入手できますので，便利なものをいくつか決めて入れておくと良いでしょう。本講義で必要なパッケージは随時指定しますが，ひとまずは `tidyverse` パッケージ (Wickham et al., 2019) を入れておきましょう[*26]。

図 3.7 Package タブから Install をクリック

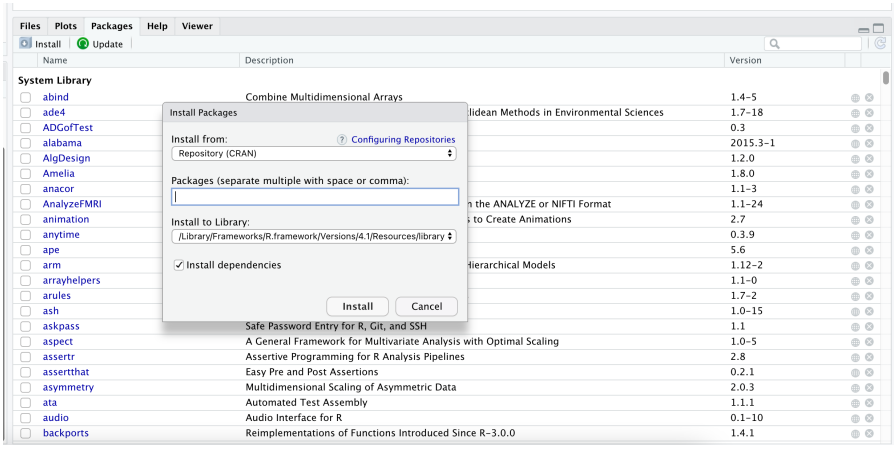

[*23] 本講執筆時点 (2026/10/21) で 25,404 件のパッケージが CRAN に登録されています。それ以外にも無数のパッケージが GitHub などで公開されています。

[*24] 出てくるボックスに示された，“Install From” が「どこからとってくるか」を示している欄になりますが，これは CRAN が自動的に選択されているので変更する必要はありません。

[*25] と同時に，同じパッケージを何度もダウンロードする必要はないということです。もっとも，R のバージョンが上がるとか，違う環境で実行する場合は再ダウンロードが必要なこともあります。

[*26] この `tidyverse` パッケージは，実はパッケージのパッケージですので，これをインストールしようとすると関連するその他のパッケージを次々と自動的に呼び出して環境を整えてくれます。初回は少し時間がかかりますが，気長に待ちましょう。大学の PC 室や計算機サーバなどには，すでにインストールが終わっているのでその作業は必要ありません。

このインストールは，RStudio のパッケージペインからも実行できますが，code:3.3 のようにコードを使って実行することも可能です。

code : 3.3　コードからインストールする

```
1  install.packages("tidyverse")
```

3.3.3　オブジェクトの利用

R で扱う変数，関数，データセットなどにはすべて，名前がついています。なまえがついた「それ」のことをオブジェクトと呼びます[*27]。code:3.4 を書いてみてください。

code : 3.4　オブジェクトに代入

```
1    # オブジェクト
2    A <- 2
3    B <- 3
4    A + B
5    A
```

1 行目　コメント

2 行目　A と名付けたものに数字の 2 を代入する。代入の記号は小なり (<) とハイフン (-) の二文字でできていて，矢印記号 ← を表しています。RStudio の機能で，Mac の場合は option とマイナス記号，Windows の場合は Alt キーとマイナスを同時に押すと入力できます。

3 行目　B と名付けたものに数字の 3 を代入しています。

4 行目　オブジェクト A とオブジェクト B を足し合わせています。

5 行目　オブジェクト A の中身を表示させろ (中身はなんだっけ)，という意味です。

実行結果は R **の出力** 3.3 のようになるでしょう。

R の出力 3.3: オブジェクトに代入する

```
> # オブジェクト
> A <- 2
> B <- 3
> A + B
[1] 5
> A
[1] 2
```

一行目は当然なんの回答もありませんが，2，3 行目を実行してもすぐに次のプロンプト (>) がでて指示待ちになります。これは「代入しろ」といわれたから代入したのであって，とくに反応を求めてないからです。次の 4 行目になって初めて足し算をせよ，と言われたのでその結果が 5 である，と返答しています。また，5 行目は A とだけ入力されました。このように指示待ちのときにそのオブジェクト名を入れると，その中身をすべて表示してくれます。今回は 2 がはいっているので，2 ですよ，と答えてくれています。

このようにオブジェクト名だけで計算を進めることが可能です。オブジェクト名はなんでもいいのですが，TRUE，FALSE，NA など R が特別な意味を持たせている言葉や，pi などの数学的意味がある言葉は予約

[*27] 適当な日本語訳がありません。object はもの，対象という抽象的な意味なので，カタカナでオブジェクトとするしかないのです。

語といって既に使われているので，避けた方がいいでしょう。かといって，A, B,C といった無味乾燥な記号でもわかりにくいので，その時々に応じて任意の名前をつけてあげてください。

ちなみにこの「オブジェクトに代入」は基本的に上書きされるというルールです。さきほどのコードに続いて code:3.5 を書いてみてください。

code : 3.5　オブジェクトは上書き

```
1  A <- 4
2  A + B
```

今度は結果として 7 が表示されたと思います。先ほどは A に 2 を代入せよといい，そのあとで A に 4 を代入せよと命じたので，いま A は 4 に上書きされています[*28]。この基本的に上書きされる，ということはよく注意しておいてください。というのも，これから長いコードを書くことがあったときに，部分的に実行を繰り返すと上書きに上書きを繰り返すこともあり得るからです。そうすると，ある時うまくいったけど，次に同じことをしようとしたらうまくいかなかった，ということにもなりかねません。くどいようですが記録は再現性の担保のためにやっているわけですから，一時的な記憶やたまたまうまくいった例に依存しては困ります。環境が空っぽの状態，クリアな状態で一行目から順に走らせて，何度やっても同じ答えが出るようにしましょう。

環境をクリアにするには，Environment タブのバーにある箒のアイコンをクリックします。これで R の頭の中が空っぽになります。あるいは `rm(list=ls())` というコードを実行するとクリアされます。スクリプトの一行目にこれを書いておくことをお勧めします。

また，R は終了すると，それまでの作業を保存しますから，同じプロジェクトをもう一度開くと以前の記憶が蘇ります。これが便利なのですが実は少し厄介で，学生さんが「自分の環境ではできた」といっても私の手元で再現できない (からレポートやり直し) ということがあります。きっと記録されているスクリプトの外で，なんらかの作業がなされているのです。清書できたスクリプトは，R の頭の中を空っぽにしてから再チェックすると良いでしょう。また，`Tools > Global Option` から，Workspace の “Restore .RData into workspace at a startup”(起動時に.RData からワークスペースの情報を復元する) のチェックを外し，“Save workspace to .RData on exit”(終了時に.RData にワークスペースの情報を保存する) を “never”(絶対そんなことしない) にしておくことで，いつでもクリーンな環境から始められます (図 3.8)。

オブジェクトの型 1・ベクトル

code:3.6 を実行してみましょう。

code : 3.6　ベクトル処理

```
1    obj1 <- 1:10
2    obj1 + 2
3    obj2 <- c(2,3,4,1,2,3,4,5,6,7)
4    obj1 + obj2
```

1 行目　obj1 オブジェクトに “1:10” を代入

2 行目　obj1 オブジェクトに 2 を加える

3 行目　obj2 オブジェクトに “c(2,3,4,1,2,3,4,5,6,7)” を代入

4 行目　obj1 オブジェクトに obj2 オブジェクトを加える

[*28] オブジェクトの中に何が入っているかは，Environment タブをみるとわかることがあります。今見ると，A に 4，B に 3 が入っていることが示されているでしょう。

図 3.8 クリーンな環境をいつでも保つための設定

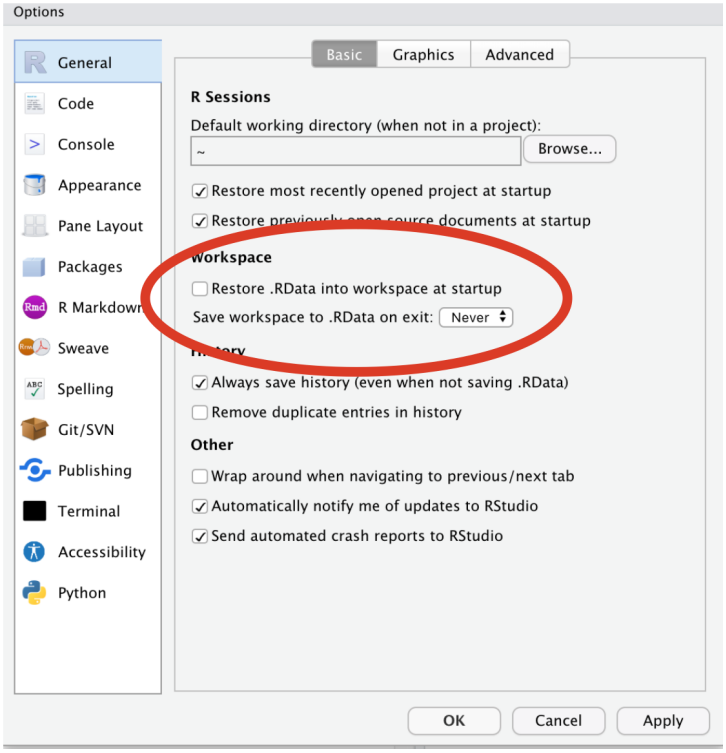

一行目で代入している “1:10” は R 独特の表記法で，コロンで繋いだ数字は連続した数字を意味します。ここでは 1 から 10 までの連続した数字，すなわち $1, 2, 3, 4, 5, 6, 7, 8, 9, 10$ です。このように数字のセットを一度に扱うことができます。このオブジェクトに 2 を加えるというのは，各要素に 2 を加えることと同じですので，そのような結果が出力されていますよね。また三行目で代入しているのは $2, 3, 4, 1, 2, 3, 4, 5, 6, 7$ という数字列です。これを c 関数で括っています。この c は一文字ですが関数で[*29]，数字をセットにするという働きをします。そして四行目で，対応する各要素を足し合わせるという計算を行っています。

このように，数字をセットで扱うことができるのが電卓とは違うところです。統計ではたくさんのデータを扱うわけですから，この機能は基本中の基本になります。ちなみに，数字のセットのことは数学でベクトルというのでした。今回のオブジェクトは数字をベクトルとして保管していることになります。

オブジェクトの型 2・リスト

データセットは数字だけではなく，文字列などを含むことがあります。そうした対象をまとめて扱うのが**リスト (list)** という形式です。つづいて code:3.7 を実行してみましょう。

code : 3.7 リスト型

```
1    obj3 <- list(
2      name = c("Taro", "Hanako", "Ken"),
3      gender = c("male", "female", "male"),
4      height = c(170,160),
5      weight = 55
6    )
```

[*29] combine や concatenate の略語と言われています。

```
7    obj3
8    obj3$name
```

1 行目 obj3 オブジェクトに代入するのは list であることを，list 関数を使って明示しています。この関数の中身は複数行にわたり，括弧が閉じられるのは 6 行目になりますので，そこまでで 1 つの命令文だということになります。

2 行目 name という名前のついたベクトルを作ります。

3 行目 gender という名前のついたベクトルを作ります。

4 行目 height という名前のついたベクトルを作ります。

5 行目 weight という名前のついたベクトルを作ります。要素が 1 つでも，要素 1 のベクトルと R は解釈します。

6 行目 1 行目から続く list 関数の終わり。リストの中に含まれるベクトルはカンマで区切られていること，対応する括弧がきちんと閉じられていること，が重要です。

7 行目 オブジェクトの中身はなあに，ということで中身を表示させています。

8 行目 obj3 オブジェクトの name 要素だけにアクセスしてみました (要素を見せて，と命じている)。

出力された画面を見て，何が起きているかを確認してみてください。コードの 2 から 6 行目に当たるところでは，コンソールの左端が>ではなく + になっていると思います。これは前の行から続いて入力されている，つまり入力がまだ終わっていないことを意味する記号になっています。また 7,8 行目については，表示させる指示をしているので，その結果が返ってきているはずです。

このように，名前 (文字列) や性別 (名義尺度水準)，身長や体重 (比率尺度水準/量的変数) などをひとまとめにして obj3 というオブジェクトに保管する，ということができています。このオブジェクトのある変数だけ参照したい，というときは，オブジェクト名の背後にドルマーク ($) をつけて繋げます。RStudio で入力している時は，obj3$と書いただけで「中身はこれですが」という候補のリストが示されたと思います。このように入力補完をしてくれるのも RStudio のいいところです。

ところでこれがデータセットだとすると奇妙ですね。名前や性別は 3 つありますが，身長は 2 つ，体重は 1 つしかデータがありません。普通こんなことはなくて，1 つのケースについて複数の変数があるので，縦に個体 × 横に変数の長方形型をしているデータセットが一般的になるはずです。リスト形式は各要素の長さに関係なく，なんでもまとめて置けるので便利なのですが，データ分析においては長方形であるという形の制約があって良いはずです。この制約を持ったリスト形式のことを**データフレーム (data.frame)** 型と言います。

オブジェクトの型 3・データフレーム型

データフレーム型にするには，data.frame という関数を使います。code:3.8 を実行してください。

code : 3.8　データフレーム型

```
1    df <- data.frame(
2      name = c("Taro", "Hanako", "Ken"),
3      gender = c("male", "female", "male"),
4      height = c(170,160,155),
5      weight = c(55,60,43)
6    )
7    df
8    df$name
```

946 **1 行目** df オブジェクトに代入するのは data.frame であることを，data.frame 関数を使って明示して
947 います。
948 **2 行目** name という名前のついたベクトルを作ります。
949 **3 行目** gender という名前のついたベクトルを作ります。
950 **4 行目** height という名前のついたベクトルを作ります。要素数を合わせます。
951 **5 行目** weight という名前のついたベクトルを作ります。要素数を合わせます。
952 **6 行目** 1 行目から続く data.frame 関数の終わり。ここに含まれるベクトルはカンマで区切られていること，対応する括弧がきちんと閉じられていること，が重要です。
953
954 **7 行目** オブジェクトの中身はなあに，ということで中身を表示させています。
955 **8 行目** df オブジェクトの name 要素だけにアクセスしてみました (要素を見せて，と命じている)。

956 コンソールには R **の出力** 3.4 のように表されていると思います。

R の出力 3.4: オブジェクトに代入する

```
> df <- data.frame(
 +     name = c("Taro", "Hanako", "Ken"),
 +     gender = c("male", "female", "male"),
 +     height = c(170,160,155),
 +     weight = c(55,60,43)
 + )
> df
 name gender height weight
1   Taro   male    170     55
2 Hanako female    160     60
3    Ken   male    155     43
> df$name
[1] "Taro"   "Hanako" "Ken"
```

957

958 このオブジェクト，df の出力を見るとわかるように，行に個人，列に変数の長方形型になっています。変数
959 にアクセスする時は，list 型の時と同じようにオブジェクト名の背後に$をつけて，df$name のようにします。
960 今回はひとまずデータを作るために，各ケースの値を入力して行ってもらいましたが，実際に統計解析をす
961 る時は表計算ソフトで素データを入力し，ファイルから R にデータを読み込むことが一般的です。これについ
962 ては次回第 4 講で説明します。

963 3.4 再現性のある研究実践へ

964 さて，これで演習の第一段階は終了です。R のスクリプトを書いてみて，いかがだったでしょうか。思った通
965 りに動かない，とイライラしたひともいるかもしれません。その通り，**コードは思った通りに動くのではなく，**
966 **書いた通りに動く**のです。正しく指示し，正しい答えを得るために，実行記録が残るということは科学的営み
967 として重要なことなのです。
968 今後，みなさんはパソコンを使って文章 (レポートや論文) を作成するという機会が増えてくることは間違い
969 ありません。文字を入力するだけであればスマートフォンでもいいですが，レイアウトを整えるためにはパソコ
970 ンが必要になってきます。文章だけでなく，図表も作成することになりますし，図表を作るのに必要な統計的
971 データの整理，分析もパソコンを使って行います。とくに図表や統計分析は，プログラムを書いて行うことにな
972 ります。機械は 0 と 1 の羅列で情報処理をしますが，その文字列を人間が考えるのは大変です。機械にやっ

て欲しい操作，計算を人間がわかる言葉で書いたものをプログラムと言います。機械と人間を繋ぐ言語だと思ってください。この言語には色々な種類がありますが，基本的に統計環境 R という言語を使えるようになってください[*30]。

計算だけでなく図表を書くのも，プログラミングすることになります。なぜそんな面倒なことをするのでしょう？ 表計算ソフトを使うと，誰でもマウスでカチカチっとすれば簡単にグラフが作れるのに，と思った人もいるかもしれません。その答えは端的にいうと，そのやり方だと記録が残らないからです。同じデータに同じプログラムをあてがえば，別の計算機上でも結果が同じになります。この誰がどこでやっても同じ結果になる，というのが科学の営みとして重要なことであるのは第 1 講で説明した通りです。また，教員と研究指導のやりとりをする上でも，プログラムに書き起こされていることは利点があります。マウスでの動きを口頭で説明するのは難しいですね。さらに自分がどういう設定・環境で実行したかを完全に意識していない場合，「なんだかわからないけど，カチカチやっているうちにこの結果が出ました」ということにもなりかねません。そういう報告を受けた教員の気持ちも想像してみてください。指導のしようがありません。

プログラムで実行するというのはすなわち，何をどのように操作するのかを書き下すことでもあります。すごく複雑な統計処理も，中身は 1 つ 1 つの「計算」の積み重ねです。何がどのように積み重なっているかをしっかり理解しなければ書けません。逆に言えば，書いてあるものを見ればどのように組み立て，どのような実行をしているのかがわかります。うまくいかないプログラム，つまりエラーがおきるプログラムであっても，プログラムされたコード (スクリプトとも言います) を見せてもらえれば，どこにエラーが生じているかを明らかにできます。研究の実践とその成果が「動作」ではなく「指示書」として記録に残ることは，研究の再現性を高めるためにも重要な営みなのです。

教育や学習の上でも利点はあります。プログラムを書くときに必要なのはこのアルゴリズム的思考，すなわち目標に向かうための必要な手続きを 1 つ 1 つ特定し，順序立てて実行していくという考え方です。お料理のように，「玉子焼き」というゴールに到達するために「卵を取る」「卵を割る」「卵をかき混ぜる」「フライパンを温める」... といった各手続きを順序立てて実行できなければなりません。これから先，統計の話が複雑になってくると，わからない！と音を上げたくなることが出てくるかもしれません。そんなときは (たっぷり休憩して心身ともに元気な状態で落ち着いて) 見直すことで，どこからどこまで理解していて，どこから理解できていないのか，確認できます。プログラムのエラーの場合，どこからどこまでが正常に動いていて，どこから計算がおかしくなるのかを見ることができるのです。諦めなければ，確実に積み重ね，前進できます。エラーが出ると言いましたが，エラーはたいていの場合エラーメッセージとともに明らかになります。このメッセージをよく読めば，解決のいとぐちが掴めるのです。わからなければエラーメッセージとともに，教員に相談してください。どこでどのようなエラーが出たかをじっくり確認すれば，何が間違いで何がわかっていなかったのかがわかるというものです。エラーを 1 つ 1 つ無くしていき，うまく動くプログラムが書けたときは嬉しいものですよ。

最後に，プログラムを含めて記録の取れる研究実践について少しだけ説明しておきます。科学は「自分だけがわかっている」という私秘性を排除した公共的な営みである，ということはすでにお話しした通りです。個々人の興味関心によって研究を積み重ねていくのですが，研究の結果明らかになったことはオープンな議論の場に出すべきです。なぜなら，自分が知りたいと思って始めた研究について，他の人から自分では気づかなかった問題点を指摘してもらえるかもしれないし，もっとおもしろいテーマに展開できるかもしれない，あるいは他の人と一緒に研究しようということになるかもしれないからです[*31]。自分の研究も他人の研究の成果を踏まえて，あるいはそこからインスパイアされて進めることになりますが，この研究のスタートとなるこれまでの

[*30] 専修大学心理学科で公式に使う統計環境になっています。

[*31] 間違いを指摘されたら恥ずかしい，などと思ってはいけません。間違いは正せばいいだけですし，間違いが直るとより良いものになっていくだけだからです。小中高の学校教育とは違って，正解がある問題を考えているわけではないので，教員はもちろん周りの人の目を気にする必要はまったくありません。そんなことでからかう人がいないのが大学という界隈の楽しいところです。

成果に間違いや嘘が含まれていては困りますね。人間を対象にした研究の場合は，間違いや嘘がまったく含まれていなくても完全に同じ状況や同じ対象に研究するというのが難しいので，先行研究の結果が再現できないという問題があります[*32]。

そこで，何をどのように研究したか，どういうデータをとってどのように分析したか，ということを事細かく記録しておく必要があります。最近では，研究を始める前に事前にどのような研究計画で進めていくかを公開し[*33]，とったデータや分析プログラムも公開するということが行われています。こうした研究計画やデータ，プログラムの公開は Open Science Framework というウェブサイト[*34]が今最もよく利用されています。ここでファイルを共有すると，いつどのようなファイルが置かれたか，どのように更新されたかという記録が残るので，記録の改竄などを疑われるような懸念がなくなるという利点もあります。

皆さんも，ごく初心者とは言え心理学という科学の営みをするメンバーの一人になったわけですから，自分の記録やファイルを管理し，公開するという意識を持って取り組むようにしてください。

3.5 課題

■自分の電子機器のスペックを調べる 皆さんが使っているパソコンの，CPU のメーカー，型番はどういったものですか。一次記憶装置はどれぐらいの容量がありますか。二次記憶装置の容量はどうですか。いま二次記憶装置の空き容量はどれぐらいですか。調べて回答してください。

■自分のファイルの場所を調べる 同じくパソコンのユーザ名は何になっていますか。また何か適当なファイルを作り，どこかに保存し，「どこにどのようなファイル名で保存したか」を報告してください。拡張子をつけることを忘れずに。

■R で遊んでみよう 今日実行した R のコードはごく簡単な計算ばかりです。数字を色々書き換えて遊んでみましょう！

[*32] 実際，社会心理学の教科書に載っているような研究は再現率が 30% しかない，という批判もあります。詳しくは池田・平石（2016）などを読んでください。

[*33] 研究をする前に計画だけの論文をチェックしてもらう方法もあります。プレレジストレーション，略してプレレジと言います。

[*34] https://osf.io/

第 4 章

数値データの種類

さて前回は，科学としての心理学なので，数量的なデータを扱って研究が進められる，という話をしました。今回は，何をどのようにデータにするか，データの種類といった点についてお話しします。

4.1　データと変数

心理学では目に見えないものを研究対象とするため，心を持つと考えられる主体にたいして刺激を与え，その反応を見て「こうすれば (刺激)→ 心のせいで → こうなる (反応)」という因果を説明するためのモデルとして研究するのだ，ということでした。ここで刺激と反応は，研究対象である「心」の外にあって，観測できるものです。これをデータにします。

図 4.1 は心理学研究の流れを説明したものです。ここで述べている「刺激と反応からデータを作る」というところは**心理測定法**と呼ばれます。何をどのようにデータにするか，ということを考えるところであり，それぞれの心理学領域によってさまざまなバリエーションがあります。神経生理のような領域での研究であれば，データは計測機から得られる電気反応の強さ，間隔などになるでしょうし，認知・知覚・学習心理学のような領域であれば，たとえば被験者のキー反応の速さなどを PC で計測してデータとするでしょう。社会・学習・臨床心理学のような応用的領域であれば，被験者の発話，調査票への回答パターンなどがデータになるでしょう。いずれの領域でデータを取るにしても，ここで重要なのはそのデータの**信頼性 (reliability)** と**妥当性 (validity)** です。

図 4.1　心理学研究のプロセス

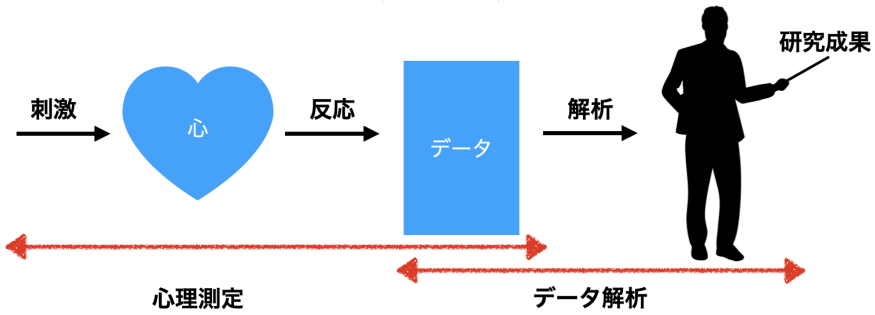

それに対して，この講義でとくに重点的に議論するのは後半のデータ解析のところになります。つまりデータが得られた後で，それをどのように分析していくか，という点です。これについては次回も言及しますが[*1]，

[*1] → セクション 3.4,Pp.49

客観性 (objectivity) や**再現性 (reproducibility)** が重要になってきます。同じデータであれば誰でも同じ結果に到達できる，ということが重要ですし，言い方を変えると数学的に正誤の判断がついてしまう領域でもありますので，正しく理解し利用できるように学んでいきましょう。

図 4.2　データって何?

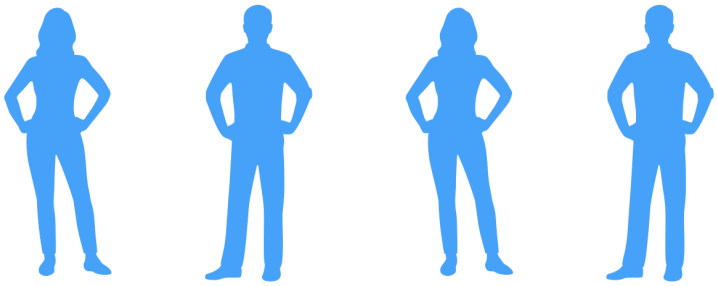

名前	Aさん	Bさん	Cさん	Dさん
性別	female	male	female	male
所持金	4200円	35,200円	7213円	15円

さてこれからデータを分析していく話をするのですが，改めてデータとは何でしょうか。図 4.2 を見てください。ここには 4 人の研究対象者がいて，色々な情報を集めてみました。この中でデータとはいったい何を表すでしょうか。所持金は数字ですので，これだけがデータだ，と思ったら大間違いです。実は名前や性別もデータです。これらはすべて数値化し，データとして扱えるものです。

少し用語の説明をしておきますと，名前，性別，所持金などは人によって[*2]変わる数字です。人によって変わる数字のことを**変数 (variables)** と言います。名前・性別・所持金は変数名であり，それがケースごとに「A さん」「男性 male」「15 円」と変わるのです。ここで 15 円はともかく，名前や性別は数字じゃないぞ？ と思われるかもしれません。先にも述べたように，数字じゃないような実体であっても，これに数字を割り振るルールを決めて数字に置き換えていきます。このルールを決めることを**尺度化 (scaling)** と言います。

図 4.3 に数値化した例を挙げました。上の段にあるのが本来の情報であり，数値化されたのが下の段にあります。下の段はすべて数字になっていますね。どこがどう変わっているのか，よく見ておきましょう。実際の統計的な分析をするときは電子計算機を使いますが，電子計算機にデータを与えるときは下の段にあるように数字だけにするのだ，と理解してください[*3]。

こうしてみていても，数字には 2 種類あることがわかります。まず所持金を見てください。これは最初から数字でしたので，そのまま数字として扱っていきます[*4]。このように本来の数字としての意味を持っているものは**量的変数 (numeric variable)** と呼ばれます。一方で，性別は「女性 female」を 1 に，「男性 male」を 2 に置き換えています。名前に至っては，「A さん」を 1 に，「B さん」を 2 に，「C さん」を 3 に，「D さん」を 4 に置き換えています。これらの数字は人や性質を分類するためのものであって，数字に大小関係など量的な違いを表すものではありません。いわば質的な違いを表すための数字で，こうした変数は**質的変数 (categorical variable)** と呼ばれます。

[*2] 心理学でも研究対象が人でない場合がありますから，データの単位は他にも「個体」「ケース」などということがあります。英語の Observation を略して Obs. と書かれることもあります。

[*3] Excel や Numbers などの表計算ソフトでは，その枠の中に日本語を書き込むことができます。しかし統計ソフトで扱う場合は，機械が内部では下段のような数字に置き換えているのだと思っておいてください。電子計算機の中では日本語も 0/1 の数列にすぎませんが。

[*4] 単位の「円」という文字は取れています。表計算ソフトに入力するときはこのように，数字以外のものは削ぎ落とすようにしてください。文字が入っていると数字として計算できないからです。ましてや 2 バイト文字なんて!

図 4.3　尺度化＝数値に置き換える

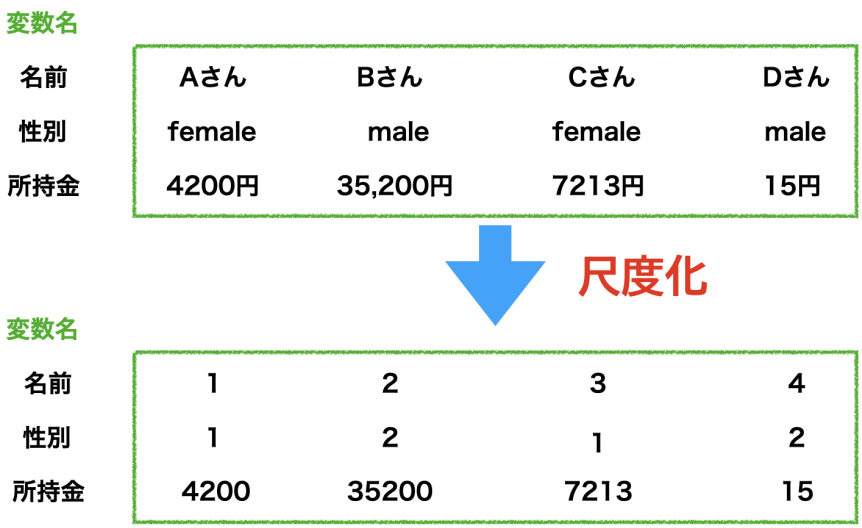

このことからわかるように，「なんでも数字にして扱うが，数字には種類がある」ということに注意が必要です。なんでも数字にする，というと眉をひそめる人がいるかもしれません。心・気持ち・想いは数字にできない！と直観的に反論したくなる人もいるでしょう。しかしまったくできないわけではないのです。というのも，言葉にできるのであればそれに適当な数字を割り振ることは可能だからです。数字が必ずしも大小関係を表すものばかりではないこともあるのですから。言葉にできるということは，質的に異なって分類できるということであり，それに数字のラベルを貼ることは可能です。一方，言葉にできない気持ちというのもあるでしょう。しかし，適切に言葉にできないのであれば，科学的な研究対象にはならないと言わざるを得ません。なぜなら「私だけが知りうる本当の気持ち」というのは，私秘性を徹底的に排除するという科学の基本姿勢に反するからです[*5][*6]。

心理学の研究法の 1 つに，質問紙法というものがあります。複数の項目が並んでいて，それぞれに対して「当てはまる」「どちらかと言えば当てはまる」「どちらとも言えない」「どちらかと言えば当てはまらない」「まったく当てはまらない」のどこかに丸をつけてください，という聞き方をするものが一般的です。たとえば「Q. この世の中では，努力がいつか報われるようになっていると思う」という問いに対して「自分の考え (気持ち，意見，態度) に最も近いところに丸をしてください」と言われ，ある人は「当てはまる」に丸を，別の人は「どちらかと言えば当てはまらない」に丸をつけたとしましょう。ここで「当てはまる」を 5 点，「どちらかと言えば当てはまらない」を 2 点，といった形で数値化すれば，大小関係は比較できるので量的変数として扱うことができます。この時ここで測りたいのは，「世界は公平だと思うか」というその人の心理的態度 (信念) を測定していると考えられます。

このように回答のパターンを見ることで，目に見えない心の状態を数値化することもできます。見たいものは目に見えない心の状態ですが，測定して，点数をつけたりします。他にも，行動や振る舞いの記録など，知

[*5] 言葉に言えないなんとも表現できない気持ちがない，と言ってるわけではないのです。科学的に研究できない，というだけで，私個人も色々な心の動きを経験しています。ただそれは私一人の思い出であって，研究対象にならないと言っているだけです。

[*6] 言葉にして数値化するというのは，心の一側面を捉えているにすぎない，という指摘も当然ありましょう。しかしだからと言って数字を使わない，というのはもったいないのです。また数字で表すことによって，どこまで表現できてどこまで表現できないか，というのも表現できたりします (正確には誤差の大きさを見積もる，という話で本講義の第 10 講ごろから触れていきます)。表現できるところはし尽くし，できないところについては黙って味わえば良いのであって，表現することを禁じるのは建設的な態度ではありません。

りたいことについて集められる情報はすべてデータであり，分析対象になります。注意してほしいのは，抽象的で目に見えないものだからなんでも好き勝手に「○○力」と名付ければいいというものではない，というところです。心理学者は空想世界に住んでいるわけではありません。現実の世界に起こる見て触れることのできるものがあり，それに基づく現象 (phenomenon) があります。この現象は抽象的なもので直接その対象が見えるわけではありませんが，現象として観測される何かがあるわけです。たとえば「流行現象」というのはモノやサービスが多くの人に利用される現象ですが，見えるのはそのモノやサービスの利用者でしかありません。ただしそれが多く観測されて，この状態を「流行」と呼ぼう，というわけです。このように抽象化されたものを**構成概念 (theoretical construct)** と言います。構成概念は現実や現象に立脚したものですが，構成概念に立脚した別の構成概念というのも考えられます。これは概念同士の関係から論理的に導出されるもので，その概念を設定する意義 (その概念がないと説明できない，あるいはその概念があることで他の概念や理論との共通点が見られるなど) がなければなりません。

図 4.4　構成概念と現実との対応 (末永 (1987) を元に作図)

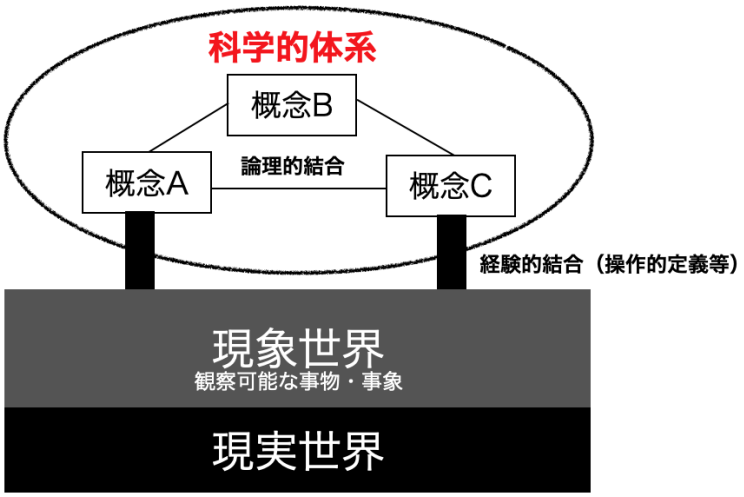

図 4.4 にあるように，概念は現実や現象に深く根ざした (経験的結合をした) ものであるか，概念同士の関係に強く結び付けられた論理的結合をしたものである必要があります。この抽象的で目に見えないものに対して，筋の通った論理的な説明体系を私たちは科学と呼ぶのです。

概念を操作して記録・数値化したものが変数となる，とも言えるでしょう。心理学的な研究対象について，何をどう変数化するか，その結びつきをどう考えるかを知るためには，先行研究を広く調べたり現実世界・現象世界についての知識と教養が必要なのはいうまでもありません。

4.2　計算機と統計の観点による分類

さて，心理学ではこのように目に見えて測れるものだけでなく，目に見えないものも数値化して扱います。そしてその数値を計算機に入れて，統計的な処理をしていくことになります。

ここで，計算機の中でそれらがどのように扱われるかを考えてみましょう。統計ソフト R では，値[*7]は 3 つの種類を持ちます。

- 数値。言葉の通り数字を数字として扱うということですが，細かく言えば整数，実数，複素数です。ま

[*7] ここでの「値」とは厳密には**リテラル (literal)** といい，値の直接的表現のことを指します。

た，数学的には無限に続く数列も数字ですが，計算機で無限は表現できないので，必ずどこかに限界があります。数学的な計算と計算機の計算結果が，この限界のせいで少しズレることもあります。また，桁の大きな数字については科学的表記法として，$2e3 = 2 \times 10^3 = 2000$ のような書き方をすることがあります。

- 文字列。シングルクォーテーション，あるいはダブルクォーテーションで渡されたものは文字列として扱います。
- 論理値。TRUE(真) や FALSE(偽) というのがそれで，T や F の一文字で表現することもあります。条件が成立したかどうか，オプションを使うかどうか，スイッチのオン･オフのような表現をしたいときに使われます。

実際に値を付与するときに，どの種類で渡されているかに注意しましょう。たとえば 1 は数値としてあつかわれますが，1 (全角文字) は文字として扱われます。計算機上は，半角数字のみが数値として扱われます。

さて，統計分析を進める上では数値にのみ注目することになりますが，統計的な観点から数値変数の種類を次のように分類することができます。この分類は，後に説明する**確率変数 (random variables)** との対応を視野にしたものであることを頭の片隅に置いておいてください。確率変数やその確率変数が従う**確率分布 (probability distribution)** については先の話題ではありますが，参考までにここで各変数の対応する確率分布についても記載しておきます。

■バイナリ　バイナリ (binary) 変数とは，0 と 1 という，2 つの値しか持たない変数です。値が二つしかありませんが，それが男と女，生と死，有ると無い，正答と誤答，成功と失敗，オンとオフのように，二分法的な意味を表していると考えると，様々な使い方ができます。もっとも単純だからこそ最もよく使われますし，使い勝手の良い変数でもあります。対応する確率分布としては，**ベルヌーイ分布 (Bernoulli distribution)** というものになります。

■カウント　カウント (count) 変数とは，正の整数しかとらない値のことを指します。年齢，友達の数，来店回数など，数を数える変数です。大きな桁数になれば 1 増えることの意味が薄らいできますが，小さな桁数の時は大きな意味がありますね (ex. 友達の数が 0 から 1 に，1 から 2 に増えることは大きなインパクトがありますが，1000 人が 1001 人になる時はそれほど感動がないかもしれません)。カウント変数は**ポアソン分布 (Poisson distribution)** に従います。

■カテゴリ　カテゴリ (category) 変数とは数値が対象と一対一対応しているもののことを指します。先ほどバイナリ変数は 0 と 1 を生と死のように解釈する，と言いましたが，これが 3 つ以上の種類があるようなものです。たとえば 47 都道府県に数字を割り振って，北海道が 1 で，東京都は 13，神奈川県は 14... とつけていくことができます。数字と対象の対応であり，この数字を使って計算することはできません。日記や逐語録 (インタビューデータ)，SNS での書き込みなど自然言語を統計解析するときは，単語や文字に数字を割り振って，カテゴリ変数として分析します。カテゴリ変数が従う確率分布は**カテゴリカル分布 (categorical distribution)** といいます。

■連続　上記以外の変数は基本的に**連続 (continuous)** 変数である，といいます。数学的に連続であることの定義は難しいですが，ここでは単に「数字と数字の間に別の数字があるようなもの」のことを言う，と理解してください。たとえば身長のことを考えてみます。170cm と 175cm の間には 172.5cm があります。170cm と 172.5cm の間には，171.25cm があります。170cm と 171.25cm の間には 170.625cm があります。170cm と 170.625cm の間には･･･とどこまでも続けていくことが (原理的には) 可能ですね。このような数値は連続

1154 しているといい，確率分布はさまざまなものが対応します。代表的には**正規分布 (normal distribution)**[*8]な
1155 どがあります。ちなみに，連続でない変数 (バイナリ，カウント，カテゴリ) は，**離散的 (discrete)** 変数，と言い
1156 ます。

1157 ここで知っておいてほしいことは，文字や文といった文字型のデータであっても数字を割り振って統計的に
1158 分析することができる，ということです。計算機で分析する以上，内部的にも概念的にも，すべて数字を割り
1159 当てて考えるのだということを知っておいてください。

1160 進んだ統計モデルを扱うときは，対応する確率分布に応じて使う手法が変わってきたりします。それほど発
1161 展的な分析でないとしても，データにどのような計算が許されるかについては考えておかなければなりませ
1162 ん。この「データにどのような計算が許されるか」については**尺度水準**を知らなければなりません。

1163 4.3 尺度水準による分類

1164 変数にはさまざまな名称があることを見てきました。尺度化して数字になってしまえば全部同じか，というと
1165 実はそうではありません。Stevens (1946) は数値が持つ情報とそれに伴う計算可能性の観点から，尺度を 4
1166 つの水準に分類しています。それぞれ次のような名前がついています。

1167 1. **名義尺度水準 (nominal scale)**
1168 2. **順序尺度水準 (ordinal scale)**
1169 3. **間隔尺度水準 (interval scale)**
1170 4. **比率尺度水準 (ratio scale)**

1171 名義尺度水準が最も下のレベルで，比率尺度水準が最も上のレベルという階層性を持っています。上に上
1172 がるほど徐々に条件が強くなっていきます。逆に言えば，上の尺度水準に該当する変数をより下位の水準の
1173 変数として扱うことが可能です。このことについて詳しくは後ほど説明するとして，それぞれがどういう意味な
1174 のかを説明していきましょう。

1175 **■名義尺度水準** 最も下位のレベルにある水準です。この水準にある数値は，数字ではありますが数字とし
1176 ての意味がないレベルです。単にラベルとして対象に数字を割り当てた，というだけのとき，その数字は**名義**
1177 **尺度水準**にある，と言います。この講のセクション 4.1,Pp.53 で，性別や名前に数字を割り当てたのを思い出
1178 してください。たとえば女性に 1 を，男性に 2 を割り当てたとします。この割り当てられた数字に，深い意味は
1179 ないですね。別に男性が 2 でもいいし，女性に 43543 という数字を当てておいても良いわけです。数字だけ
1180 見ても，女性が男性の 2 倍あるとか，男性より少ない・小さいことを意味しているわけではありません。あるい
1181 はみなさんが持っている携帯電話の番号もこの尺度水準です。みなさんの数字はどれひとつとして同じでは
1182 ないですが，その数字に深い意味はないですね[*9]。他にも学籍番号や，名前に割り当てられた数字 (A さんが
1183 1,B さんが 2 など) に数字としての特徴はなく，ただの名前を簡略化したものに過ぎません。こういう数字のこ
1184 とを名義尺度水準にある数字，というわけです。

1185 この水準の数字は，数字が大小関係や順序関係を表さないので，計算ができません。たとえば女性を 1，
1186 男性を 2 と尺度化したデータを集めて平均値を出したら 1.7 でした，と言っても意味がないのです。1.7 に
1187 該当する対象がないのですから。この尺度水準では**数字と対象が一対一対応していること**が重要なので
1188 あって，数字を計算して変化させても意味がありません。ではこの尺度水準の数字はなんの役にも立たない

[*8] 英語では normal distribution といいますが，この分布を論じたドイツの数学者カール・フリードリヒ・ガウスにちなんで**ガウス分布** (Gaussian distribution) と呼ばれることもあります。指す中身は同じものです。由来については第 10 講で改めて触れます。

[*9] 語呂合わせがしやすいかどうか，というのはありますが。

のか，と言われるとそんなことはありません。違う数字が割り振られていることから違う対象であることは分かりますので，分類するという性質は持っていますし，何よりどんな複雑な対象であっても名義尺度水準の数値は割り当てられるのです。この水準の数字は，対象そのものと一対一に結びついています。対象というのは，それ自体が複雑な意味や性質のかたまりですから，名義尺度水準の数字はその豊かさをまるごと指し示していることになります。上位の水準は，大小や間隔といった特定の側面だけを取り出すぶん扱いやすくなりますが，その代わりに対象の他の側面を捨てているのです。その意味では，この後に出てくるどんな尺度水準よりも豊富な情報を指し示している数値である，とも言えます。また，言葉にできなければ研究対象にできないという話をしましたが，言い換えると言葉にできるのであれば名義尺度水準の数値が割り当てられるということでもあります。

■順序尺度水準　名義尺度水準は数字としての意味を持たない，と言いました。これに順序関係，すなわち数字の大小に意味があるという条件が加われば，それは**順序尺度水準**の数字だということができます。たとえば好きな夕飯のメニューとして 1 番がカレー，2 番がハンバーグだと答えた人がいたら，カレーの方がハンバーグよりも好まれている，価値が高い，優先されているという情報は得られるわけです。あるいは 100m 走での順位を表す数字だと，2 と 7 を比べれば 2 位の人の方が速いんだな，ということがわかります。この程度の情報が含まれている数字のことを，順序尺度水準であると言います。ただこの水準の数字は大小関係を表すだけで，それ以外のことはわかりません。たとえば着順の話でも，1，2，3 の順で優劣がついていることはわかるのですが，「1 位がぶっちぎりだった」「団子レースだった」といった違いは表現できていないわけです。図 4.5 を見てもらうとわかるように，データとしては 1,2,3 という数字だけですから，上図のような状態でも下図のような状態でもデータとしては 1,2,3,4 であり，上図の 2 と下図の 2 を区別できません。まだ少し不便ですね。このように大小しかわからないので，計算にもまだ使えません。1 位と 2 位を足して 3 位になるはずもないですし (そもそも逆転してますが)，2 位と 3 位を足して 1 位と勝負できるかということもわからないのです。もちろんかけたり割ったりもできませんので，この水準の数字は四則演算ができません。

図 4.5　順序では程度がわからない

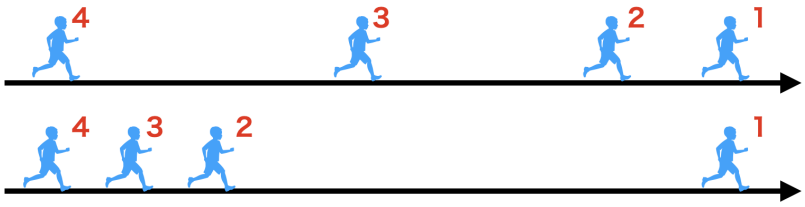

とはいえ，この水準の数字は，心理測定において最もおもしろいところであると言えるかもしれません。みなさんご自身の心の状態を数字で表すとして，さてその数字はどの水準にあるのでしょうか。たとえば「カレーはハンバーグの 100 倍美味しい！」と思っていても，本当に 100 倍という計算ができるような精度の高い数字でしょうか？ せいぜい優先順位の違いぐらいで，カレーを 5 点，ハンバーグを 4 点，餃子を 3 点･･･と採点していっても，カレーとハンバーグの違いが，ハンバーグと餃子との差と同程度であるとまでは言えないのではないでしょうか。ことほど左様に，心理学的な評価水準はせいぜい順序尺度水準であって，差や比の計算をするには，さらに上の尺度水準でなければなりません[*10]。

[*10] しかし実際には，評定値を間隔尺度水準の値を持っているとみなして分析をすることが多くあります。これには**心理測定法**の理論と歴史的な経緯があって，その両方を踏まえた上でのことであればそのような「みなし」も正当化されます。残念なことに，それらを踏まえずして仮定が満たされていないのに勝手に間隔尺度水準だと思って使っている誤用例も数多くあるのですが。

■間隔尺度水準　間隔尺度水準は，順序尺度水準に加えて数値と数値の間隔が等しいという条件を追加したものです。順序尺度水準は 1 と 2 の差が 2 と 3 の差と違っても構わないのですが，間隔尺度水準ではこれがあっている必要があります。代表的な例として，摂氏 (温度) があげられます。これは水が氷になる氷点を 0，水が水蒸気になる沸点を 100 とし，その間隔を百等分した目盛りによって温度を表現するものです[*11]。このようにそもそも等間隔になるようにつけた目盛りですから，当然間隔尺度水準の数値であると言えます。この時，10 ℃と 20 ℃の差は 20 ℃と 30 ℃の差と等しいといえますから，これは $20-10=30-20$ と引き算の計算ができるレベルになっているわけです。

しかし，20 ℃は 10 ℃の 2 倍の熱量を持っている，とは言えません。というのも，この数字は 0 ℃に意味がないからです。言い換えると，0 ℃は温度が「ない」ことを意味するのではなく，0 ℃という温度が「ある」状態です。0 がスタート地点ではないのです。スタート地点は任意に決められますから，たとえば氷点を 100，沸点を 200 とした新しい温度体系 X を作ったとします。このとき 10 ℃は 110X で，20 ℃は 120X ですから，$20/10 \neq 120/110$ ですね。同じ状態を表している数字なのに計算が合わないのはおかしいわけです。このような割り算の計算をするためには，さらにもうひとつ条件を追加する必要があります。

■比率尺度水準　比率尺度水準は，間隔尺度水準に加えて絶対 0 点を定めたものです。絶対 0 点とは，0 が「ない」ことを意味する点のことです。たとえば 0cm は長さがないのです。0kg は重さがないし，0 秒は時間が経ってない，です。このように原点 0 が決まっている数値体系になってはじめて，加減乗除の四則演算すべてに対応できます。例に挙げたように，物理的な測定単位はほとんど比率尺度水準ですから，精緻に測定すればかなり細かい予測値まで計算できるのですね。これに対して心理学のデータで主観的につけられる評定値はせいぜいが順序尺度水準なので，物理学のようになかなかうまくいかないところもあるというのが実際です。心理学のデータでも客観的で比率尺度水準の数字を扱えるものもありますし (反応時間を指標とする，など)，主観的な評定値でも工夫して間隔尺度水準以上の数値にすることもあります。

みなさんが今後，どのようなデータをとって分析するようになるかは進む専門領域によって変わると思いますが，どの数字がどの尺度水準にあるのかについて，常に注意しておいてください。というのも，名義尺度水準や順序尺度水準では加減乗除の計算ができないので，分析の方法にも限界があるからです。これら尺度水準の違いは，統計ソフトウェアで分析するときもどの尺度水準にあるのか指定する必要があります。指定がなくすべて計算可能な数値であると機械が誤認すると，頓珍漢な分析をしてしまうことになります。表 4.1 に Stevens (1946) によるまとめを引用しましたので確認しておいてください[*12]。

4.4　コンピュータのデータ型と尺度水準の関係

ここまで，計算機による値の分類と，尺度同士の変換関係すなわち値に施せる計算の関係から変数を分類してきました。では，計算機のデータと尺度水準との関係はどのようになっているでしょうか。

最も単純には，間隔尺度水準と比率尺度水準はいずれも計算できるので量的データ，名義尺度水準と順序尺度水準は (計算できないので) 質的なデータと呼ぶことがあります。しかし，カウントデータを順序尺度水準として扱うこともできますし，比率尺度水準であると考えることもできるでしょう。またバイナリデータは特殊で，2 つしか状態がないので名義尺度水準であるとも言えるし，最も単純な段階を持つ順序尺度水準である

[*11] セルシウスさんが考えた方法なのでセ氏といいます。ちなみに定義上このようになっているのであって，「水ってちょうど 0 度で氷になって，ちょうど 100 度で水蒸気になるの，奇跡じゃない?」というのは悪いジョークです。

[*12] Stevens (1946) の仕事をより正確に言うなら「測定対象全体に数値を与える適正な規則とは何か」を考えたのではなく，何らかの測定がなされた尺度がいくつかあれば，それらを相互に変換する規則が定められて，それが表にあるような 4 種類になるだろう，と言う考え方です。詳しくは吉野 (2007) を参照してください。

表 4.1 尺度水準のまとめ

尺度水準	基本的な操作	数学的な群構造	可能な統計量
名義 Nominal	同質性の判定	置換群 $x' = f(x)$ $f(x)$ は一対一対応	ケース数, 最頻値, 一致係数
順序 Ordinal	大小関係の判定	同調群 $x' = f(x)$ $f(x)$ は単調増加関数	中央値, パーセンタイル
間隔 Interval	間隔や差分の等しさの判定	一般線形群 $x' = ax + b$	平均値 , 標準偏差, 順位相関, 積率相関
比率 Ratio	比率の等しさの判定	類似性群 $x' = ax$	変動係数

とも言えるし, 数学上は比率尺度水準であると考えて計算しても良いのです。

また, 調査法によって得られた数字, たとえば「非常にそう思う」を 5 点,「全くそう思わない」を 1 点とする, といった 5 段階の点数の付け方は, 統計学的には順序尺度水準として扱うことが正しいです。**しかしながら**実践的には, 間隔尺度水準とみなして分析することが多いです。その理由の一つは, かつて計算機の計算能力が今ほど高くなかった時代に, 順序尺度水準の統計モデルは理論的に考えられていても, 実質的に計算時間がかかりすぎるので使えないから, という歴史的背景があります。もちろん今はそんなことはありませんので, 順序尺度水準は順序尺度水準として正しい統計モデルを利用するべきでしょう[*13]。

さて, 最後に統計ソフト R では数値や尺度水準をどのように扱えるのかをみてみましょう。サンプルデータとして `BaseballDecade.csv` というデータセットを使います[*14]。サンプルデータをこの授業のプロジェクトフォルダに保存し, 次のコードで読み込んでみましょう。

code : 4.1 データの読み込み

```
1  rm(list = ls())
2  dat <- read.csv("BaseballDecade.csv",na.strings = "NA")
3  str(dat)
```

■コード解説

1 行目 環境の初期化

2 行目 データファイルの読み込み

3 行目 データの構造を見る関数

これを実行すると, 次のような出力が得られると思います。

[*13] もうひとつ, 調査法の多段階反応項目について, 各カテゴリにはある仮定のもとで連続量を割り振る方法が考えられており, その手法を使うと理論的に間隔尺度水準の数字として扱えるという研究があります。サーストンの等現間隔法やリッカートのシグマ法と呼ばれるものがそれですが, 最近ではこれらの計算における仮定を無視し, 単純に 1 から 5 までの整数値を割り振る研究が後を絶ちません。この辺りの悲喜交々については, 別の講義でご紹介する機会があるかと思います。

[*14] このデータセットはこの資料を提供しているサイト, https://kosugitti.github.io/psychometrics_syllabus/ からダウンロードできます。

R の出力 4.1: 外部データの読み込み

```
> str(dat)
'data.frame': 6546 obs. of  17 variables:
 $ Year       : chr  "2011 年度" "2011 年度" "2011 年度" "2011 年度" ...
 $ Name       : chr  "永川　勝浩" "前田　健太" "栗原　健太" "東出　輝裕" ...
 $ team       : chr  "Carp" "Carp" "Carp" "Carp" ...
 $ salary     : int  12000 12000 12000 10000 9000 8000 8000 7500 7000 6600 ...
 $ bloodType : chr  "O 型" "A 型" "O 型" "A 型" ...
 $ height     : int  188 182 183 171 201 183 177 173 176 188 ...
 $ weight     : int  97 73 95 73 100 90 82 73 80 97 ...
 $ UniformNum: int  20 18 5 2 70 17 31 6 1 43 ...
 $ position   : chr  "投手" "投手" "内野手" "内野手" ...
 $ Games      : int  19 31 144 137 19 6 110 52 52 40 ...
 $ AtBats     : int  NA NA 536 543 NA NA 299 192 44 149 ...
 $ Hit        : int  NA NA 157 151 NA NA 60 41 11 35 ...
 $ HR         : int  NA NA 17 0 NA NA 4 2 0 1 ...
 $ Win        : int  1 10 NA NA 0 1 NA NA NA NA ...
 $ Lose       : int  2 12 NA NA 0 1 NA NA NA NA ...
 $ Save       : int  0 0 NA NA 0 0 NA NA NA NA ...
 $ Hold       : int  0 0 NA NA 9 0 NA NA NA NA ...
```

出力から，読み込んだファイルが data.frame 型になっていることがわかります。また，変数がいろいろあり，それぞれの型が示されています。chr とあるのは character，つまり文字型です。int とあるのは integer，つまり整数である，ということです。数値型は，int のほかにも，num，つまり numeric(数字) である，となることもあります。

表示の中で NA とあるのは**欠測値 (missing value)** です。ある観測 (observation) においてその変数の値がなかったときにこのように表示されます。ファイルを読み込むときに，欠測値に対応する文字列を指定しておけばよく，ピリオド (.) やアスタリスク (*)，特定の値 (-99 など) を仮に入れておいて，分析のときに欠測を表しているものとして指定することが一般的です。

さて，ここで変数 bloodType をみてみましょう。選手の血液型情報がありますが，これはせいぜい A,B,O,AB 型の 4 つです。すなわちカテゴリ変数であり，文字列としての意味はなく群分けのラベルがついているだけです。尺度水準でいうところの名義尺度水準ですので，そのように扱ってもらうべく変換する必要があります。次のコードを実行してみてください。

code : 4.2　Factor 型に変換する

```
1  dat$bloodType <- factor(dat$bloodType)
2  str(dat$bloodType)
3  levels(dat$bloodType)
```

■コード解説

1 行目　変数を要因 (Factor) 型にして上書き保存する

2 行目　当該変数の構造を確認する

3 行目　水準を確認する

実行すると次のように出力されるはずです。

R の出力 4.2: 因子型の確認

```
> str(dat$bloodType)
 Factor w/ 5 levels "AB 型","A 型","B 型",..: 4 2 4 2 5 3 2 3 1 5 ....
> levels(dat$bloodType)
[1] "AB 型" "A 型"  "B 型"  "O 型"  "不明"
```

R における名義尺度水準の変数は要因型 (Factor 型) と呼ばれます。今回は factor 関数で変数を要因型に変換しました。出力された結果をみると 5 つのレベル (水準) がある要因型であることがわかります。続く出力では AB 型に 1,A 型に 2，B 型に 3，O 型に 4, 不明に 5 という数字が割り振られていることがわかります。

同様のことは，team 変数や position 変数に対してもやっておくと良いでしょう。ただし，文字列変数のすべてが要因型 (名義尺度水準) であるとしなくても構いません。たとえば Name 変数 (選手の名前) はひとりにひとつ，個別の水準がありますから，水準数が多すぎますので，統計的な処理を必要としないかもしれないからです (水準として設定し，カウントすることに意味があるようなら変換しておきましょう)。

また，Year 変数は日本語を含みますので文字型になっていますが，扱うなら年度の順番を考慮した順序尺度水準にするべきですね。次のコードを実行してみましょう。

code : 4.3 Ord.Factor 型に変換する

```
1 dat$Year <- factor(dat$Year, ordered = TRUE)
2 str(dat$Year)
3 levels(dat$Year)
```

■コード解説

1 行目 変数を順序付き要因 (Ordered Factor) 型にして上書き保存する

2 行目 当該変数の構造を確認する

3 行目 水準を確認する

実行すると次のように出力されるはずです。

R の出力 4.3: 順序つき因子型の確認

```
> str(dat$Year)
 Ord.factor w/ 10 levels "2011 年度"<"2012 年度"<..: 1 1 1 1 1 1 1 1 1 1 ...
> levels(dat$Year)
 [1] "2011 年度" "2012 年度" "2013 年度" "2014 年度" "2015 年度" "2016 年度" "2017 年度"
 [8] "2018 年度" "2019 年度" "2020 年度"
```

順序つき要因型は Ordered Factor といいます。これを見ると年度ごとの大小関係が含まれた要因型として R が受け止めていることがわかります。

R は要因型に応じて，自動的に適切な統計処理，統計モデルに変えてくれる機能がありますので，データセットを読み込んだらまず，含まれる変数を適切な型に変えておくことは重要です。ちなみに変数の「型」はデータ型とかクラスとか呼ばれます。R では主に以下のような分類があります。

基本データ型

- numeric（数値型：integer，double を含む）

- character（文字列型）
- logical（論理値型）
- complex（複素数型）

特殊データ型

- factor（因子型）：カテゴリカルデータ用
- Date（日付型）
- POSIXct/POSIXlt（日時型）
- function（関数型）

4.5 課題

■変数を見つける 次のような研究計画を立てたときに，変数として記録しておくべきなのは何でしょうか。

1. 人の身長と体重の情報から，性別を予測することに興味がある。
2. 人は寝ている間にたくさんの汗をかくという。一晩にかく平均的な寝汗の量に男女差があるのかどうかを調べたい。
3. 結婚している人としていない人とで，幸福度に差があるかどうかを知りたい。

■尺度水準を理解する 次のそれぞれのデータは，どの尺度水準に該当するでしょうか。

1. 個人を識別するために回答を求めた携帯電話番号の下 4 桁の数値
2. 納税証明書に記載されている，個人の昨年度の納税額
3. 年齢を直接質問するのがはばかられたため，「10 代」「20 代」「30 代」「40 代」「50 代以上」の 5 段階について回答を求め，それぞれ 1,2,3,4,5 とコード化した数値
4. 質問に対して「とてもそう思う」を 5，「まったくそう思わない」を 1 として，両者の間を均等に分割し 2,3,4 とする。また，「答えたくない」を 0 としてコード化した数値
5. セルシウスさんが開発した，沸点を 100，氷点を 0 として百分割した温度
6. 温度とは分子の平均運動量であり，一定量の物質の温度をどんどん下げていくとこれ以上低くはならないという点が出てくる。そこを原点として作られた絶対温度 K
7. テレビ番組「帰れま 10」では，ある外食チェーン店の豊富なメニューの中から，上位 10 品が何であるかを当てなければならない。このとき，それぞれのメニューに付される人気の順位を表した数字

■R での尺度水準 サンプルデータ `BaseballDecade.csv` を読み込み，因子型にするべき変数はすべて因子型にしてみよう。

第 5 章

記述統計量

さて，ここまでで心理学においてなぜ統計学が必要か，計算機とはどういうものか，計算機に与えるデータはどういうものか，という話をしてきました。下準備はそこまでです。いよいよ，今回から心理統計の具体的な話に入っていきます。

初めに，心理統計の 3 つの枠組みを紹介しておきます。

記述統計 descriptive statistics　データの特徴を記述する統計法。可視化，代表値による要約など。データを取ったらまずやるべき作業がこちら。手元のデータでわかることを，隅々まで書き表すのが狙いです。

推測統計 inferential statistics　部分的なデータから全体像を推測する統計学。心理統計の目的は一部のサンプルから全体を予測することにあるのです。この授業の後半 (後期) は主にこの話になります。

多変量解析 multivariate analysis　大量のデータから意味のある情報を引き出す，あるいは無意味な情報を削ぎ落とす技術です。調査研究をする場合はもちろん，センサーなどの機器から大量に取れるデータを扱う場合にも使われる技術です。データサイエンス，機械学習 (いわゆる AI) などにも通じる領域です。本学では 2 年のデータ解析応用で扱います。

ということで，ここにあるように記述統計学が最初のステップになります。手元にあるデータの特徴を記述することが目的になります。記述という意味では可視化もそうなのですが，今回は数字によってデータの特徴を記述することを考えます。複数のデータの代表的な値ですから，代表値と言われたりします。

研究対象を数値化したとしましょう。それを眺めて「いろいろな数字があるなあ」と感心していたのでは，数値化した意味がありません。得られた**データは図にする**のが基本です。すぐに図にします。いろいろな図にします。前回も話しましたが，とにかく図にします。しなければなりません。さて，図を見て考えをまとめるのが重要なのですが，具体的にどういう特徴があるのか，あるいはどういう違いがあるのかといったことを，要約して表現できればなお良いですね。そこで代表値を考えることになります。

いきなり身も蓋もないことをいうようですが，たくさんの数値を 1 つの代表値を使って記述する，というのは基本的に無理があります。十人十色，いろいろな違いがあるからこそ，そのデータセットは意味があるのに，たった 1 つの数字に変えて表現するのですから。代表値は，何らかの側面で評価することで 1 つに定まるものであって，あくまでもその評価次元での代表値に過ぎません。つまり，1 つの代表値だけで全体が分かるわけではないのです。あるいは，1 つの代表値にするということは，少し無理をして情報を削ぎ落とすということでもあります。代表値は何であれ，必ず何らかの情報が欠け落ちているのです。ですから，統計データを扱うときは，複数の代表値を使って多角的に判断するのが基本です。そのことをまずしっかり理解しておいてください。

その上で，代表値を 2 つの種類に分けて説明します。ひとつは中心化傾向の指標，もうひとつは散らばりの

指標です。

5.1 中心化傾向の指標

5.1.1 平均値 mean

平均値 (mean)[*1], より正確には算術平均[*2]は最もよく知られた代表値でしょう。計算方法は, すべてのデータをたしあわせて, 足したデータの個数で割る, というものです。

図 5.1 に 5 人の所持金を示しています。この例では, 平均値は次のように計算できますね。

$$(15000 + 30000 + 20000 + 10000 + 20000)/5 = 19000$$

図 5.1 5 人の所持金データ

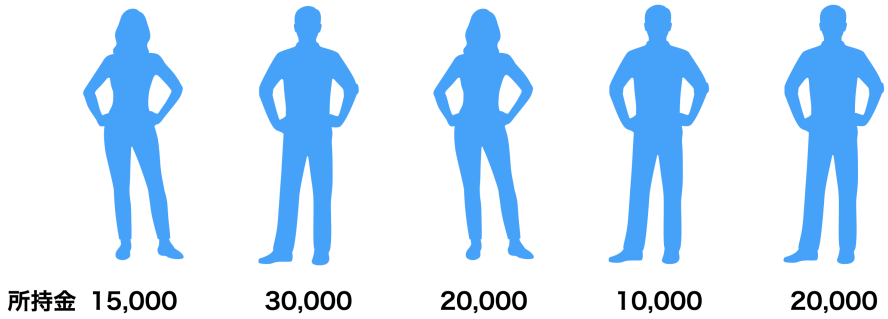

■文字と記号の導入 さてこれを, 今後のために記号で一般的に表記する方法について知っておきましょう。変数は一般に x や y で表されます。今回は 5 人分のデータがありますが, 1 人目のデータ, 2 人目のデータ, といった違いを表すときは $x_1, x_2, \cdots$ のようにアルファベットの右斜め下に小さく数字を添えます。添字と言います。さて今回は所持金という 1 つの変数でしたが, 2 つ目の変数, 3 つ目の変数・・・とたくさんのデータが手に入ることもあります。そのようなとき, 変数は x_{ij} と添字を 2 つ書いて表現します。ここで i がケース (個体, 観測番号) を表し, j が何番目の変数であるかを表す, というルールにします[*3]。

次に足し算の記号を紹介します。$\sum$ で総和を表すことにします。この記号はギリシア文字の大文字の S で, 足し合わせる summation の頭文字をとって $\sum$, サムと読みます。この記号には上と下に文字を追加して, 次のような意味で使います。

$$\sum_{i=1}^{5} x_i = x_1 + x_2 + x_3 + x_4 + x_5$$

ここにあるように, $\sum$ の下に i という文字があります。この文字 i が 1 から始まって 5 まで変化し総和する, という数学記号です。$\sum_{i=1}^{5} x_i$ の x_i という変数について, i が 1 から 5 まで変わるわけですから, 右辺にある

[*1] 英語では average というのも平均を意味します。mean の方がより意味が狭く, average はより広い意味で代表的であるという違いがあるようです。

[*2] 他にも調和平均, 幾何平均などがあります。

[*3] この講義ではこのルールで通します。必ずしも個体が前で変数が後, という決まりがあるわけではありませんが, このような記号を導入するときはどの文字が何に対応しているか明記することが一般的です。この講義でとくに明記していなければ, 前の添字が個体で後ろの添字が変数を表すのだと思ってください。

ように添字が変わりながらすべて足し合わせる，という意味の記号です。この $\sum$ も，文脈から考えてどこからどこまで足すのかが明らかな場合，上下の添字は省略されることがあります。

さて，先ほどの 5 人の平均ですが，足し算の場所は $x_1 + x_2 + \cdots + x_5 = \sum_{i=1}^{5} x_i$ と書けます。これを 5 で割れば平均になりますから，$\frac{1}{5}\sum x_i = 19000$ というわけです。このように記号で表現しておくと，平均値は一般に次のように表すことができます。

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$$

今回は 5 人でしたが，一般に N 個のデータを扱うときにまで拡張できました。左辺は平均値 $\bar{x}$ で，エックスバーで表すことが一般的です。

5.1.2 中央値 median

次の代表値は**中央値 (median)** です。データを大きさの順に並べて行って，ちょうど真ん中のケースの値をその代表値として使う，というものです。さきほどの図 5.1 の場合は，並べ替えると $10000 < 15000 < 20000 = 20000 < 30000$ となります。上から 3 番目 (下からでもいいです) が 20000 円ですから，中央値は 20000 円ということになります。

今回はたまたま，5 人のケースですから真ん中は 3 番目となりましたが，データの数が偶数しかなかったらどうするか，という問題があります。その場合は，真ん中に来た 2 つの値の算術平均でもって中央値とすることが一般的です。

5.1.3 最頻値 mode

最後に**最頻値 (mode)** についてです。漢字の成り立ちからわかるように，頻度が最も多いものを代表値とするのが最頻値です。さきほどの図 5.1 の場合は，10000 円が 1 人，15000 円が 1 人，30000 円が 1 人ですが 20000 円持っている人が 2 人いましたので，最頻値は 20000 円になります。

このように，データの中心をどのように考えるかによっても 3 つも考え方があり，それぞれが一致するわけではないのです。それぞれの意義がありますので，見比べながら考える必要があります。

では練習です。次の表 5.1 のようなデータがあった場合，平均値，中央値，最頻値はそれぞれどうなるでしょう？

表 5.1 5 人の所持金データその 2

A	B	C	D	E
10000	10000	20000	25000	100000

この場合，平均は 33000 円，中央値は 20000 円，最頻値は 10000 円となりました。平均値が他の 2 つより大きくなりましたね。これは**外れ値 (outlier)** があるからです。E さんが，平均値をぐっと押し上げているのです。平均値は量的な中心をとりますので，1 人でも遠く離れたところに位置すると全体的に中心が引っ張られます。中央値は順番の情報しか使いませんので，大金持ちが 1 人いても 1 位だ，と判断するだけです。最頻値は度数の問題ですので，大金持ちが 1 人いても度数 1 にしかなりません。平均値は外れ値に弱い，あるいは中央値や最頻値がそれに強いというだけです。

では平均値は使い物にならないのでしょうか？ もちろんそうではなくて，左右対称に散らばっているようなデータであれば，平均値は良い代表値になります。データの分布が左右対称ではなく歪んでいるようであれば，平均値は適切な代表値になりません。

図 5.2 は，厚生労働省による「2023 年・国民生活基礎調査」で示されたデータです[*4]。これを見ると所得分布は左側に歪んでおり，平均値は 524 万 2 千円ですが，中央値は 405 万円，最頻値は 100-200 万円のクラスということになります。最頻値は一番データ点が多いところですので，「国民の平均所得は 524 万円です」と言われると多くの人が (この例では少なくとも 62.2% の人が)，「えっ，私の年収低すぎ・・・?」という印象を抱きます。もちろん所得分布が低い方に歪んでいる状況も悪いのですが，代表値として平均値を使うことがそもそも適切でない例ともいえます[*5]。ニュース報道などでは平均値しか報道されませんが，それでは不当な印象を与えることになります。**データは図にする**ことが大事なのです。

図 5.2　所得金額階級別世帯数の相対度数分布

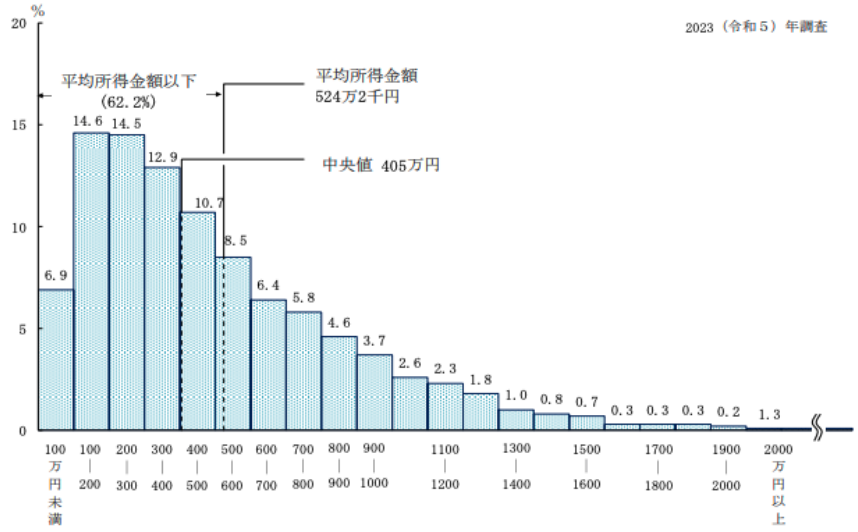

ところで，最頻値は頻度を数えるものですから，間隔尺度水準以上の連続的な数字の場合はいくつかの区間に区切って数えることになります。図 5.2 の例もそうですね。ただしこの時，最頻値は区間幅の区切り方が違うと結果が変わってしまうことに注意しましょう。図 5.3 の 2 つのヒストグラムは，実は同じデータなのです。違いは区間幅 binwidth のとり方で，左図は 15 点間隔，右図は 5 点間隔でグラフを書きました。最頻値はそれぞれ赤で囲ったところになりますが，左図の場合の最頻値は 40-55 点クラス，右図の場合は 47-52 点のクラスになります。最頻値の場合は，どのような区間幅でカウントするかということにも注意が必要ですね。

では，ここで出てきた 3 つの中心化傾向の指標をいったんまとめておきましょう。

平均値　データを全部使って計算しており，外れ値がなければ全データが反映される良い指標。実際，統計分析で最も活躍している指標です。左右対称の分布に適しています。

中央値　外れ値の影響を受けにくい指標で，ちょうど真ん中，という意味も分かり易いです。ただ，分布の真ん中の数字だけしか使ってません。データが偶数個のときの中央値の計算はいくつかあり得ます。

[*4] https://www.mhlw.go.jp/toukei/saikin/hw/k-tyosa/k-tyosa23/dl/03.pdf

[*5] もちろん為政者の目から見れば，平均は 524 万円もあるんだから日本は豊かだ，とアピールできるので良い指標なのかもしれません。数字に悪意はなく，何の数字をどのように使うのかという人の側に問題があるだけです。ちなみにこの数字は 3 年前の 2020 年当時から比べて，平均値・中央値ともに下がっています。日本は衰退しました。

図 5.3　区間幅の区切り方で結果が変わる

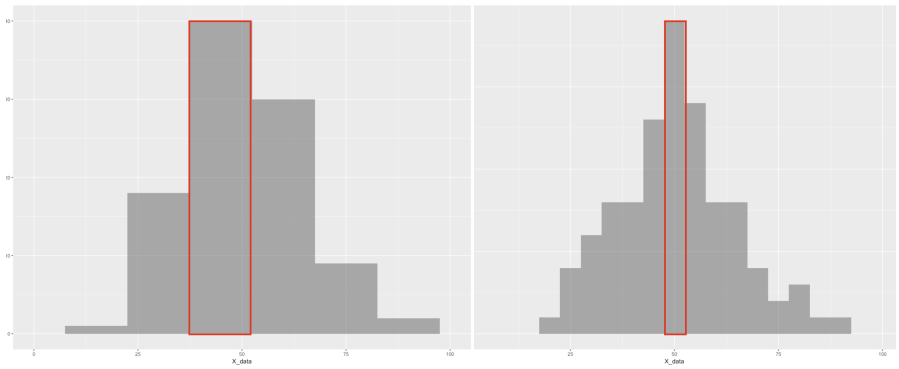

最頻値　外れ値の影響を受けにくく，左右対称でない分布の時も意味が分かり易いです。データの値ではなく度数分布にのみ注目しており，度数分布の区間幅が変わると変わってしまうという欠点があります。

5.2　散らばりの指標

5.2.1　分散と標準偏差

つぎは散らばりの指標について考えていきましょう。データの中心がどこにあるか，というだけではわからないこともあるのです。表 5.2 のような 2 つのデータがあったとしましょう。これを図示したのが図 5.4 です。

表 5.2　2 つのデータ

A	B
4	1
4	2
5	3
5	5
5	5
5	7
6	8
6	9

このデータ，A/B グループについてそれぞれ平均値，中央値，最頻値はどうなるでしょう。何と，平均値は A 群も B 群も 5，中央値も A/B 群ともに 5，最頻値も A/B 群ともに 5 となります。中心化傾向の指標だけでは，A 群と B 群の違いが表現できません。こんなにも違う見た目をしているのに！

この 2 つの群は何が違うかといって，図 5.5 を見れば明らかなように中心から左右にどれほど散らばっているかが違うのです。

■分散　これをうまく表現する代表値は，**分散 (variance)** があります。指標化のポイントは，「中心から個々のデータ点が平均的にどの程度離れているか」を考慮することにあります。数式では次のように表されます。

図 5.4　2 つのデータを見比べてみよう

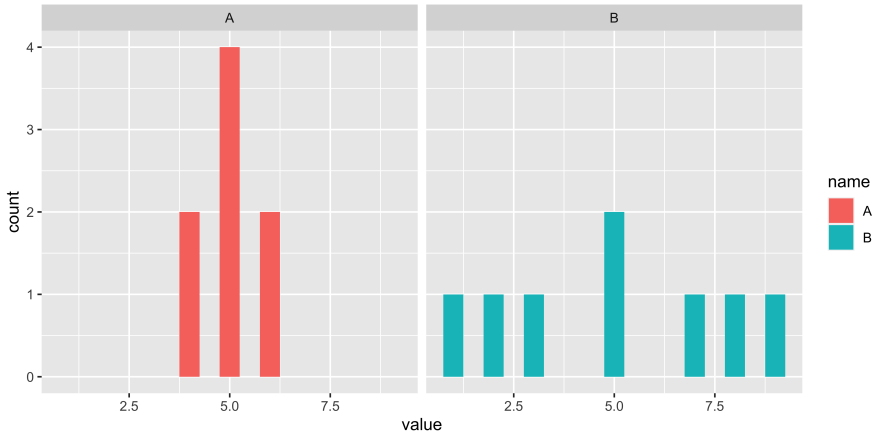

図 5.5　中心から各データ点が平均的にどの程度離れているか

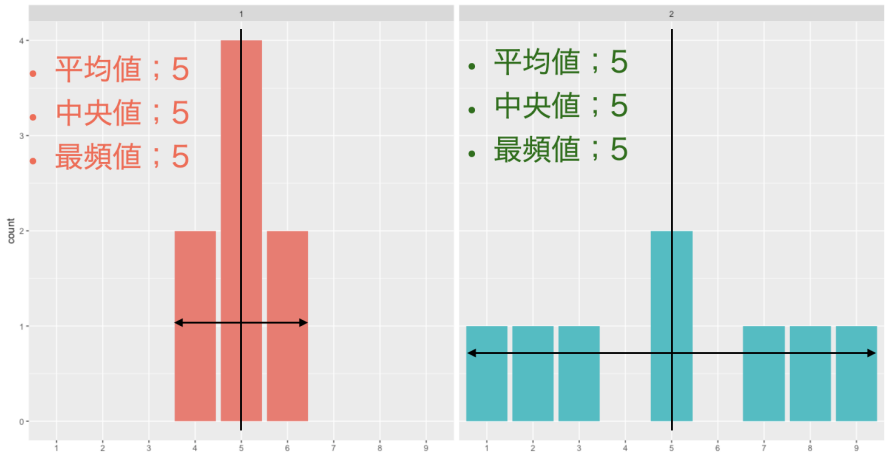

$$s_x^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2$$

この式にある $(x_i - \bar{x})$ は，各データ点 x_i が平均 $\bar{x}$ から離れている程度を表しています。これをとくに**平均偏差 (mean deviation)** と言います。それを二乗していますね。これがポイントで，二乗しておかないと平均偏差の総和はゼロになってしまうからです[*6]。プラスとマイナスが打ち消し合うからゼロになってしまうわけで，符号の影響をなくすべく二乗しているのだと思ってください。符号をなくすのには絶対値でもいいのですが，絶対値は数式で書けないから使いにくいのです[*7]

実際に計算してみましょうか。A 群の分散は，次のようになります。

$$\frac{1}{8}((4-5)^2 + (4-5)^2 + (5-5)^2 + (5-5)^2 + (5-5)^2 + (5-5)^2 + (6-5)^2 + (6-5)^2)$$
$$= \frac{1}{8}(1^2 + 1^2 + 0^2 + 0^2 + 0^2 + 0^2 + 1^2 + 1^2) = \frac{4}{8} = 0.5$$

[*6] 検算してみよう!

[*7] 絶対値は $|x|$ と書くじゃないか，と思った人もいるかもしれません。おしい，もう一歩。この記号の中身，計算式を考えてみてください。$0 \leq x$ のとき，$|x| = x$ です。$x < 0$ のとき，$|x| = -x$ です。これ，「･･･の時」という条件で分岐してて，この箇所が数式で書けてないですよね。

B 群の分散は，次のようになります。

$$\frac{1}{8}((1-5)^2+(2-5)^2+(3-5)^2+(5-5)^2+(5-5)^2+(7-5)^2+(8-5)^2+(9-5)^2)$$

$$=\frac{1}{8}(4^2+3^2+2^2+0^2+0^2+2^2+3^2+4^2)=\frac{58}{8}=7.25$$

このように，A 群の分散は 0.5，B 群の分散は 7.25 と，B 群の方が散らばりが大きいことがわかります。

分散はデータの散らばりを表現しています。分散が大きい方がデータの散らばりが大きい，というわけですね。逆に分散がゼロになると，そのデータには散らばりがない，ということです。実際取ったデータの分散がゼロだと，そこから得られる情報がない，ということになります。なぜなら，たとえばクラスの全員がテストで 100 点を取ると，分散は 0 です。この時は「どういう勉強をすれば成績が上がるか」とか「成績が低い人をどうサポートすれば良いか」という知見を得ることができません。分散が 0 のデータセットには，個々の違いがないので情報が得られないのです。つまり，分散はそのデータから取り出せる「意味」「情報」の上限という点で非常に重要な指標なのです！

ちなみに分散の式は，次のように展開できます。

$$\begin{aligned}
s_x^2 &= \frac{1}{N}\sum_{i=1}^{N}(x_i-\bar{x})^2 \\
&= \frac{1}{N}\sum_{i=1}^{N}(x_i^2-2x_i\bar{x}+\bar{x}^2) && \sum \text{記号は分配できるから} \\
&= \frac{1}{N}\sum_{i=1}^{N}x_i^2-2\frac{1}{N}\sum_{i=1}^{N}x_i\bar{x}+\frac{1}{N}\sum_{i=1}^{N}\bar{x}^2 && \text{定数を N 回足すのは N 倍と同じなので} \\
&= \frac{1}{N}\sum_{i=1}^{N}x_i^2-2\frac{1}{N}\bar{x}\sum_{i=1}^{N}x_i+\frac{1}{N}N\bar{x}^2 \\
&= \frac{1}{N}\sum_{i=1}^{N}x_i^2-2\bar{x}\frac{1}{N}\sum_{i=1}^{N}x_i+\bar{x}^2 \\
&= \frac{1}{N}\sum_{i=1}^{N}x_i^2-2\bar{x}\bar{x}+\bar{x}^2 \\
&= \frac{1}{N}\sum_{i=1}^{N}x_i^2-2\bar{x}^2+\bar{x}^2 \\
&= \frac{1}{N}\sum_{i=1}^{N}x_i^2-\bar{x}^2
\end{aligned}$$

手計算するときなどは，先にすべての変数を二乗したり，変数の平均の計算をしたりしますので，こちらの方が計算が早くなるかもしれません。もっとも電子計算機の発展している現代において，手計算で分散を求めることなんか少なくなりましたけどね。

■標準偏差 ところで，分散は元のデータを二乗した値から計算しているのでした。ですから，その単位が元の尺度と異なることに注意が必要です。つまり，元が cm 位のデータであれば，分散は cm^2 の単位になって

いるのです。ですから数字が必然的に大きくなりがちですし，分散の大きさが実際どれぐらいなのか，という実感が持ちにくいという欠点があります。

そこで，単位を元に戻すことを考えます。二乗して大きくなっているのですから，平方根をとってやれば元に戻りますね。

$$s_x = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2}$$

このようにして計算された s_x のことを**標準偏差 (standard deviation)**(SD) と言います。これはルートを取るだけですので，すぐに計算できますね。さきほどの例ですと，A 群の SD は 0.7071，B 群の SD は 2.6925 です。

■四分位数 (しぶんい) と IQR　他にも範囲を表現する指標はあります。分散や標準偏差が平均値に関する指標であったのに対し，中央値に関係した指標として**四分位 (quartile)** というのがあります。文字通り，データを四分割した時の切れ目にあたる数字のことです。中央値はデータを大きい順に並べ替えて，ちょうど真ん中になる数字という話でしたが，四分割した場合は図 5.6 にあるように，下の方が第 1 四分位，上の方が第 3 四分位ということになります。中央値は第 2 四分位と同じことになるのですね。

図 5.6　四分位と IQR

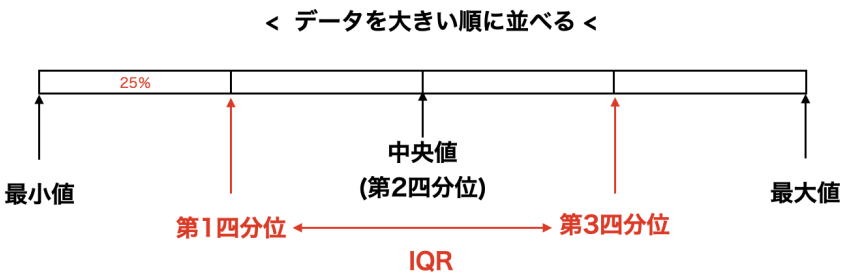

この第 1 と第 3 をつかった幅，つまり第 3 四分位数から第 1 四分位数を引いた数字のことを**四分位範囲 (inter-quartile range; IQR)** と呼びます。中央値と同じように外れ値の影響を受けにくく，また標準偏差のように元データと同じ単位ですので，理解しやすい指標です。さてここで，四分割じゃなくて五分割がいい，と思った人もいるかもしれません。いや三分割でも何分割でもいいんですが，要するになんらかの割合で区切った値というのを考えることは可能ですよね。この「割合に応じた値」のことを，**パーセンタイル (percentile)** と言います。たとえば第 1 四分位は 25 パーセンタイル，第 3 四分位は 75 パーセンタイルと同じ意味です。この表現が使えるのなら，任意の数字で分割できるのでいいですね。分布の形状によっては，95 パーセンタイルとか 5 パーセンタイルといった値を表示することもあります[*8]。

■最大値，最小値，範囲　次に最も簡単な散らばりを示す数値を紹介します。**最大値 (max)** はデータのなかで一番大きな値を指します。**最小値 (min)** は逆に，データの中で一番小さな値です。**範囲 (range)** は最大値から最小値を引いたものです。これは単純ですね。

さてここまでで，中心化傾向の指標と散らばりの指標について説明してきました。冒頭でお伝えしたように，これらの代表値は 1 つだけで表現できることに限界があります。論文などでは，取得したデータについての記

[*8] テスト理論業界では，**スタナイン (stanine)** という区切り方もあります。全体を均等に 9 区分するのではなく，上から順に 4%,7%,12%,17%,20%,17%,12%,7%,4% で区切ります。一桁で表現できる均等な区切りであり，この不均一な数字は学力の分布が正規分布に従うことから来ています。詳しくは，Shojima (2022) を参照してください。

述統計量をまず記載することが基本です。データの平均値，中央値，標準偏差，最大値と最小値などを記載することで，どういうデータだったかが (データ点すべてを書かなくても) 見えてきます。逆にいうと，平均値だけではデータの真ん中を示すだけですし，歪んだデータになっているかもしれないことが読み取れません。ちなみにデータが左右対称でない場合，よく使われる統計的分析手法が適用できないこともあります。それを無視してデータを分析すると，間違った結論に辿り着くかもしれないのです。データをさまざまな角度でみる (描画し，複数の代表値を確認する) ことを厭わないでください。幸い，多くの統計パッケージはすぐにこれらの指標を算出してくれますので，計算の苦労はありません。

5.3 R による集計

では具体的に R をつかって計算をしてみましょう。

まずは計算に先立って，この授業のプロジェクトを開き，新しいスクリプトファイルを用意してください。また，プロジェクトフォルダにサンプルデータをダウンロードし，同プロジェクトフォルダに保存してください。サンプルデータはこの講義の伴走サイト[*9]からダウンロードできます。

新しいスクリプトファイルに次のコードを書いて，データを dat に読み込んでください。

code : 5.1 データの読み込み

```
1 rm(list = ls())
2 library(tidyverse)
3 dat <- read.csv("BaseballDecade.csv",na.strings = "NA")
4 dat2011 <- dat %>% filter(Year == "2011年度")
```

■コード解説

1 行目 環境変数のクリア。R の頭の中をまず空っぽにします！

2 行目 tidyverse パッケージを読み込みます。データ操作や描画に便利な関数がたくさん入っています。

3 行目 read.csv 関数で，カンマ区切りの CSV ファイルを読み込みます。欠損値は NA として読み込みます。

4 行目 tidyverse パッケージに含まれる filter 関数[*10]で，2011 年度のデータだけを抽出して dat2011 に格納します。

実践的にはこのように，外部ファイルからデータを読み込むことが一般的です。すでにみたように，データの構造を確認するためには str() 関数を使えばよいのですが，データの中身を確認するためには head() 関数を使えばよいです。

code : 5.2 データの確認

```
1 str(dat2011)
2 head(dat2011)
```

[*9] https://kosugitti.github.io/psychometrics_syllabus/

[*10] 正確には，tidyverse パッケージは便利なパッケージのパッケージで，filter 関数は tidyverse パッケージが読み込む dplyr パッケージのもつ関数です。

R の出力 5.1: データの確認

```
> str(dat2011)
'data.frame': 626 obs. of  17 variables:
 $ Year      : chr  "2011 年度" "2011 年度" "2011 年度" "2011 年度" ...
 $ Name      : chr  "永川　勝浩" "前田　健太" "栗原　健太" "東出　輝裕" ...
 $ team      : chr  "Carp" "Carp" "Carp" "Carp" ...
 $ salary    : int  12000 12000 12000 10000 9000 8000 8000 7500 7000 6600 ...
 $ bloodType : chr  "O 型" "A 型" "O 型" "A 型" ...
 $ height    : int  188 182 183 171 201 183 177 173 176 188 ...
 $ weight    : int  97 73 95 73 100 90 82 73 80 97 ...
 $ UniformNum: int  20 18 5 2 70 17 31 6 1 43 ...
 $ position  : chr  "投手" "投手" "内野手" "内野手" ...
 $ Games     : int  19 31 144 137 19 6 110 52 52 40 ...
 $ AtBats    : int  NA NA 536 543 NA NA 299 192 44 149 ...
 $ Hit       : int  NA NA 157 151 NA NA 60 41 11 35 ...
 $ HR        : int  NA NA 17 0 NA NA 4 2 0 1 ...
 $ Win       : int  1 10 NA NA 0 1 NA NA NA NA ...
 $ Lose      : int  2 12 NA NA 0 1 NA NA NA NA ...
 $ Save      : int  0 0 NA NA 0 0 NA NA NA NA ...
 $ Hold      : int  0 0 NA NA 9 0 NA NA NA NA ...
> head(dat2011)
      Year       Name team salary bloodType height weight UniformNum
      position Games AtBats Hit HR Win Lose
1 2011 年度 永川 勝浩 Carp  12000       O 型    188     97         20     投
手    19     NA  NA NA   1    2
2 2011 年度 前田 健太 Carp  12000       A 型    182     73         18     投
手    31     NA  NA NA  10   12
3 2011 年度 栗原 健太 Carp  12000       O 型    183     95          5   内
野手   144    536 157 17  NA   NA
4 2011 年度 東出 輝裕 Carp  10000       A 型    171     73          2   内
野手   137    543 151  0  NA   NA
5 2011 年度 シュルツ Carp   9000      不明    201    100         70     投
手    19     NA  NA NA   0    0
6 2011 年度 大竹 寛 Carp   8000       B 型    183     90         17     投
手     6     NA  NA NA   1    1
  Save Hold
1    0    0
2    0    0
3   NA   NA
4   NA   NA
5    0    9
6    0    0
```

さて，このようにデータが読み込めたら，そのデータの特徴をみるために，記述統計量を算出してみましょう。まずはデータ全体の傾向を見るための，summary() 関数を使ってみましょう。

code : 5.3　記述統計量の算出

```
1  summary(dat2011)
```

量的な変数に対して，最小値 (Min)，第 1 四分位数 (1st Qu.)，中央値 (Median)，平均値 (Mean)，第 3

四分位数 (3rd Qu.), 最大値 (Max) が表示されていると思います。factor 型にしておいた変数があれば, その度数を表示してくれているはずです。

5.4 R による統計量の算出

これでも大体の概略はわかるのですが, もう少し詳しくデータの特徴をみてみましょう。この講義で学んだ記述統計量をひとつひとつ算出して行きます。

以下では例として, salary 変数の記述統計量を算出してみます。オブジェクトの特定の変数を参照するには, $を使うことを思い出してください。

まずは平均値です。平均値は mean() 関数で算出できます。

code : 5.4 平均値の算出

```
1 mean(dat2011$salary)
```

欠損値があるデータの場合は, オプションとして na.rm = TRUE を指定します。ホームランの本数の平均値を算出してみましょう。

code : 5.5 平均値の算出

```
1 mean(dat2011$HR, na.rm = TRUE)
```

中央値は median() 関数で算出できます。

code : 5.6 中央値の算出

```
1 median(dat2011$salary)
```

分散は var() 関数で, 標準偏差は sd() 関数で算出できます。ただし, これらの関数は上で定義した分散, 標準偏差を算出するものではないことに注意してください。詳しくは後の方で説明することになりますが, 分散の式の中であった $\frac{1}{N}$ の部分が, これらの関数では $\frac{1}{N-1}$ になっているのです[*11]。

code : 5.7 分散と標準偏差の算出

```
1 var(dat2011$salary)
2 sd(dat2011$salary)
```

最大値は max() 関数で, 最小値は min() 関数で算出できます。

code : 5.8 最大値と最小値の算出

```
1 max(dat2011$salary)
2 min(dat2011$salary)
```

最後に, 四分位数を算出してみましょう。

code : 5.9 四分位数の算出

```
1 quantile(dat2011$salary)
```

[*11] どうしてそうなるのかについては, 推測統計学の講義で説明します。$N-1$ で割る分散のことを不偏分散, N で割る分散のことを標本分散といい, デフォルトの関数では不偏分散の方を算出するということを頭の片隅に置いておくようにしてください。

R の出力 5.2: 四分位数の算出

```
> quantile(dat2011$salary)
   0%   25%   50%   75%  100%
  400  1000  2000  5500 50000
```

このように，四分位数は 0%,25%,50%,75%,100% の 5 つの値で表されています。50% の値は中央値と同じことを確認してください。なお，`quantile()` 関数は，デフォルトでは四分位数を算出しますが，引数を指定することで，任意のパーセンタイルを算出することも可能です。すなわち，30% のパーセンタイル点，75% のパーセンタイル点などを算出することも可能です。

code : 5.10　任意のパーセンタイルの算出

```
1  quantile(dat2011$salary, probs = c(0.3, 0.75))
```

R の出力 5.3: 任意のパーセンタイルの算出

```
> quantile(dat2011$salary, probs = c(0.3, 0.75))
 30%  75%
1200 5500
```

5.5　R によるデータの可視化

これらの関数を応用することで，データの各変数について様々な記述統計量を確認することができるようになりました。しかし，**データは図にする**ことで，より理解しやすくなります。というか，データを図にしなければ，データの特徴をみることはできません。

まずは，データの分布を視覚的に理解するために，ヒストグラムを描画してみましょう。ヒストグラムは `hist()` 関数で描画できます。

code : 5.11　ヒストグラムの描画

```
1  hist(dat2011$salary)
```

出力された図を見ると，非常に偏った分布になっていることがわかります。これに対して，身長や体重のデータは比較的左右対称の形になっていることがわかります。

図 5.7　ヒストグラムの描画

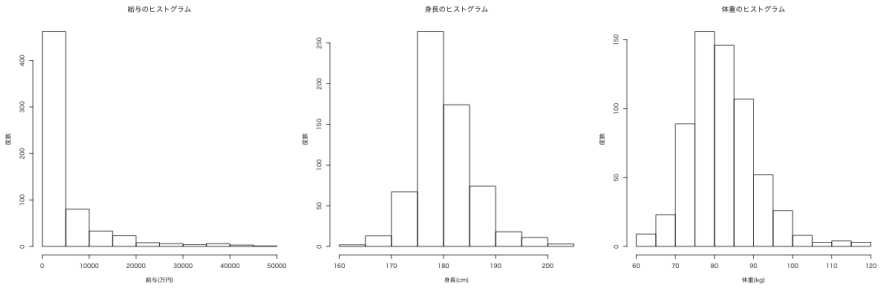

このように，ヒストグラムは単一の変数の分布を視覚的に確認するときに有用です。

次に，**箱ひげ図 (boxplot)** を描画してみましょう。箱ひげ図は `boxplot()` 関数で描画できます。

code : 5.12 箱ひげ図の描画

```
1  boxplot(dat2011$salary)
```

この箱ひげ図，別名ボックスプロットも，変数の分布を確認する表示の仕方です。もしかすると皆さんはすでに，高校までの数学で学んだことがあるかもしれません。この図示の方法は，データがどのぐらいの幅を持っているかを箱とひげで表現しています。箱の真ん中にあるのが中央値，箱の下のラインが第 1 四分位，上のラインが第 3 四分位を表すのが一般的です。ですが，髭に当たる部分については 2 通りの書き方があります。図 5.8 にあるのは同じデータですが，ひげの長さを「最大値から最小値まで」とする方法 (上段) もありますし，「IQR の 1.5 倍まで」とする方法 (下段) もあります。どちらの方法で描画されているのか，注意するようにしてください[*12]。

図 5.8 ボックスプロット (箱ひげ図) の 2 通りの書き方

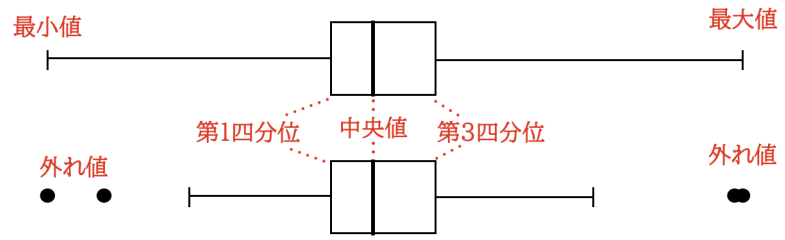

5.6 課題

今回の課題は，以下の計算をする R スクリプトファイルを提出してください。ファイル名は学籍番号と氏名を含むものとし，拡張子は.R にしてください。**提出するファイルはエラーのない完備な.R ファイルにしてください。**ファイル形式の間違い，出力にエラーが含まれている (未完成な) ものは返却しますので注意してください。

課題の内容は次のとおりです。

1. サンプルデータ BaseballDecade.csv をダウンロードし，プロジェクトフォルダに保存します。
2. 名義尺度水準のデータの変数をすべて factor 型に変換してください。Name 変数は名義尺度水準でなくて構いません。
3. データ全体の要約をする関数 summary を使って，データオブジェクトの記述統計量を表示してください。
4. 年俸 salary と安打数 Hit の平均値，中央値，最大値，最小値，IQR，5 パーセンタイル点，95 パーセンタイル点を算出してください。
5. 年俸の箱ひげ図を描いてください。

[*12] 高校数学，ひいては大学入学共通テストなどでは最大値から最小値まで表す，という記法が使われているようですが，データ分析の文脈では IQR の 1.5 倍までをひげにして，それ以上の数字は外れ値として点で表す方法が一般的です。どちらが正しいとも言えないのですが，今後は後者の書き方に出会うことの方が多いと思いますので，注意を促すために書いています。

5.7 補遺

本章で出てきた，tidyverse パッケージについて，すこし説明を追加しておきましょう。

5.7.1 データハンドリング

データハンドリングとは，データを加工するという意味です。進んだ統計的な分析などをする場合も，まずは元のデータを分析しやすい形に整える作業が必要なのです。

面白いもので，このデータハンドリングだけについて書かれた本もあります。松村他 (2021)がそうで，どんなデータをどのように分析するか，について触れることなく，どのようにデータを加工するか，加工しやすくするための準備をするか，ということに特化しています。手元に一冊置いておきたいおすすめの一冊です。

ここではよく使われる基本的な関数を抜粋して，ご紹介します。

■tidyverse **パッケージ**　ここでは tidyverse パッケージと呼ばれる，データハンドリング専門パッケージの使い方を説明していきます。このパッケージは，パッケージをひとまとめにしたパッケージです。つまり便利グッズのパッケージ，「初心者お料理セット」みたいなものですね。

インストールは前回 (セクション 3.3.2,Pp.44) で既に終わっているでしょうから，これを読み込んでハンドリングしてみましょう。ダウンロードとインストールは同じ環境で 1 回やれば終わりますので，起動するたび，実行するたびに毎回行う必要はありませんが，実行に際してはパッケージを**実装**しなければなりません。ダウンロードとインストールはグッズの購入であって，実装とはそのグッズを身につけるということですね[*13]。実装する関数は library で，実行すると図 5.4 のように表示されます。

R の出力 5.4: tidyverse パッケージの読み込み

```
> library(tidyverse)
── Attaching core tidyverse packages ──────────────────────────────────── tidyverse 2.0.0 ──
[v] dplyr     1.1.4     [v] readr     2.1.5
[v] forcats   1.0.0     [v] stringr   1.5.1
[v] ggplot2   3.5.2     [v] tibble    3.2.1
[v] lubridate 1.9.4     [v] tidyr     1.3.1
[v] purrr     1.0.4
── Conflicts ────────────────────── tidyverse_conflicts() ──
[x] dplyr::filter() masks stats::filter()
[x] dplyr::lag()    masks stats::lag()
[i] Use the conflicted package to force all conflicts to become errors
```

ここに示されているのは，dplyr，readr，forcats，stringr，ggplot2，tibble，lubridate，tidyr，purrr というパッケージを読み込みましたよ，ということと，読み込んだ dplyr パッケージの filter 関数と lag 関数が他のパッケージと干渉 (conflict) しているので，上書きしましたよということです。基本的に気にしなくてよい情報です[*14]。

[*13] ドラゴンクエストというゲームでは，武器や防具を武器屋で買いますが，買って持っているだけでは身につけたことになりませんし，当然その効果も発動しません。購入した武器や防具を「身に着ける」というアクションが必要です。武器屋で購入すると，店主が「ここで身につけていくかい」というセリフで注意喚起してくれます。

[*14] とは言え気になる人のために。パッケージは数多くありますから，あるパッケージ A で使う関数と，あるパッケージで使う関数が同じ名前だった，ということがあり得るわけです。これが「名前空間の干渉」というやつで，これを解消するためには，A パッケー

ところで，先ほどの read_csv 関数を実行すると図 5.5 のような出力が出てくるかと思います。赤い文字なのでエラーだ！と思って驚くかもしれませんが，よくみてください。6546 行 (Rows)，17 列 (Columns) とあるように，データのサイズが表示されています。続く表示も，区切り文字がカンマであること (Delimiter: ","), 文字列の変数と数値 (dbl) の変数[*15]であることなどがでています。これはエラーではなくて，正しく読み込めているかどうか確認するためのメッセージなのです。親切！

R の出力 5.5: 外部データの読み込み時メッセージ

```
> dat <- read_csv("BaseballDecade.csv",na = "NA")
Rows: 6546 Columns: 17
── Column specification ────────────────────────────────────────
Delimiter: ","
chr  (6): Year, Name, team, bloodType, UniformNum, position
dbl (11): salary, height, weight, Games, AtBats, Hit, HR, Win, Lose, Save, Hold

[i] Use `spec()` to retrieve the full column specification for this data.
[i] Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

さあでは tidyverse パッケージをつかってデータハンドリングしてみましょう。今からいくつかの関数を紹介します。それらはレゴブロックの 1 ピースのようなもので，「これだけ渡されてもどうしろと」と思うかもしれませんが，これらを組み合わせると大きなことができる･･･！と思ってお付き合いください。

■列選択：select　まずは列選択の関数，select について。先ほど読み込んだ野球データは出力 5.1 にあるように多くの変数があります。ここから，身長 height と体重 weight だけの変数を取り出したい，というときにこの関数を使います。コード 5.13 の結果が出力 5.6 です。

code : 5.13　select 関数

```
1  dat %>% select(height,weight)
```

ジの関数 f だよ，B パッケージの関数 f だよ，ということを明示してやる必要があります。R ではコロンを 2 つ繋げて，A::f() とすることで A パッケージの関数 f を表しています。ここでは dplyr::filter() が stats::filter() をマスクしましたよ，ということを意味しており，パッケージの指定なしで filter() と書くとこの後は dplyr() パッケージの filter() を使いますよ，ということです。このあとも stats パッケージの filter() を使いたい場合は，stats::filter() とすれば OK です。ちなみに stats パッケージとは，R を起動した段階で読み込まれている基本中の基本パッケージです。

[*15] dbl はダブル double，つまり倍精度の長さを持つ実数変数だということです。要するに数字です。

R の出力 5.6: select 関数の出力結果

```
> dat %>% select(height,weight)
# A tibble: 6,546 × 2
   height weight
    <dbl>  <dbl>
 1    188     97
 2    182     73
 3    183     95
 4    171     73
 5    201    100
 6    183     90
 7    177     82
 8    173     73
 9    176     80
10    188     97
# [i] 6,536 more rows
# [i] Use `print(n = ...)` to see more rows
```

変数が 2 つに絞られていることが確認できますね。

ここで重要なポイントがあります。それはパイプ演算子 %>% です。これは前のオブジェクトを後の関数の第一引数に渡す，という意味があります。たとえば，$y = f(x)$ という変換をし，さらに $z = g(y)$ という変換をしたい場合，頭の中では $x \to y \to z$ と考えていると思いますが，コードで書くと $y \leftarrow x$ で $z \leftarrow y$ という逆の向きで考えなければなりません。あるいは $z = g(f(x))$ と内側にくり入れていくので，見た目にわかりにくくなります。この思考の流れに沿った変換にするようにつなげるのが %>% です[*16][*17]。

■行選択：filter　今度は行選択。filter という関数です。先ほど読み込んだデータは 6546 行もあるのですが，たとえば 2020 年度のデータだけが欲しい，というときは行を選択することになります。ここで使うのが filter です。コード 5.14 の結果が出力 5.7 です。

code : 5.14　filter 関数

```
1  dat %>% filter(Year == "2020年度")
```

[*16] これを読むときは，頭の中で「経て」と読みましょう。dat を経て select へ。なんのこっちゃと思った人は，ダウンタウンのごっつええ感じという昔の番組で「経て」というコントがあったので，ググってみてみてください。

[*17] パーセント，大なり，パーセントと 3 回も入力するのは面倒ですね！ RStudio ではショートカットキーとして，Ctrl+Shift+M があります。Ctrl キーと Shift キーと M を同時押し，です。こうした入力ショートカットについては他にもいろいろあり，RStudio の Help メニューから Cheat Sheet を選択してください。チートシートを書き込んださまざまな情報が 1-2 枚にまとまっています。

R の出力 5.7: filter 関数の出力結果

```
> dat %>% filter(Year == "2020 年度")
# A tibble: 664 × 17
   Year     Name    team  salary bloodType height weight UniformNum
   <chr>    <chr>   <chr>  <dbl> <chr>      <dbl>  <dbl> <chr>
 1 2020 年度 菊池　涼介…… Carp   30000 A 型          171     72 33
 2 2020 年度 鈴木　誠也…… Carp   28000 A 型          181     98 1
 3 2020 年度 K．ジョンソ… Carp   27250 不明          193     95 42
 4 2020 年度 會澤　翼…… Carp   18000 B 型          177     91 27
 5 2020 年度 大瀬良　大地… Carp   17500 AB 型         187     95 14
 6 2020 年度 長野　久義…… Carp   17000 O 型          180     85 5
 7 2020 年度 田中　広輔…… Carp   15000 A 型          171     84 2
 8 2020 年度 中﨑　翔太…… Carp   14500 B 型          186     99 21
 9 2020 年度 野村　祐輔…… Carp   12000 AB 型         177     89 19
10 2020 年度 松山　竜平…… Carp    8500 B 型          176     96 55
# [i] 654 more rows
# [i] 9 more variables: position <chr>, Games <dbl>, AtBats <dbl>,
#   Hit <dbl>, HR <dbl>, Win <dbl>, Lose <dbl>, Save <dbl>,
#   Hold <dbl>
# [i] Use `print(n = ...)` to see more rows
```

これで出来上がったデータセットは 664 行 ×17 変数です。10 年分で 6500 行ほどだったので，一年分だけ切り出すとその 1/10 ほどのデータサイズになるわけですね。

ここで，filter 関数の中では，Year == "2020 年度"と書いてあります。これは Year 変数の値が「2020 年度」だった行だけ抜き出しましょう，という意味です。イコールを 2 つ重ねている==という記号は，「左が右と等しいかどうか」を判断するための関数のような動きをしています。イコールが 1 つしかなければ，R は代入せよという意味，すなわち<-と同じ意味に解釈してしまうのです[*18]。

この条件判断式は色々な使い方があります。コード 5.15 にいくつかの例を示しますので，実行してどのようになるか確かめてみてください。

code : 5.15 filter 関数

```
1  # 身長が180cm以上の人だけ取り出す
2  dat %>% filter(height >= 180)
3  # 体重が100kg以下の人だけ取り出す
4  dat %>% filter(weight <=100)
5  # 投手だけ取り出す
6  dat %>% filter(position == "投手")
7  # 野手だけ取り出す，野手とは投手でない人のことです
8  dat %>% filter(position != "投手")
9  # どちらかの条件を満たす，という場合
10 dat %>% filter(position == "捕手" | position == "内野手" |
11                  position =="外野手")
```

野手だけ取り出すときに!=という記号が出てきましたが，これは $\neq$ の意味です。$\neq$ が入力できないので，!で否定を表すようになっているのですね。このデータは投手のデータと野手のデータが含まれており，

[*18] 実は普段から，dat=read_csv(***) のように書いても良かったのですが，いわゆる等式を表す記号と混乱するのでここでは<-にしていました。

position は守備位置を表しますから，野手のデータは捕手か内野手か外野手ということになります。A か B か C, という選択を表す表現は|という表現を使いますが，今回は長くなるので「投手でない」という条件で抜き出しました。

ここまで列選択 select と行選択 filter について説明しました。両者の違いをイメージで理解しておいてください (図 5.9)。

図 5.9 filter(左) と select(右) の違い

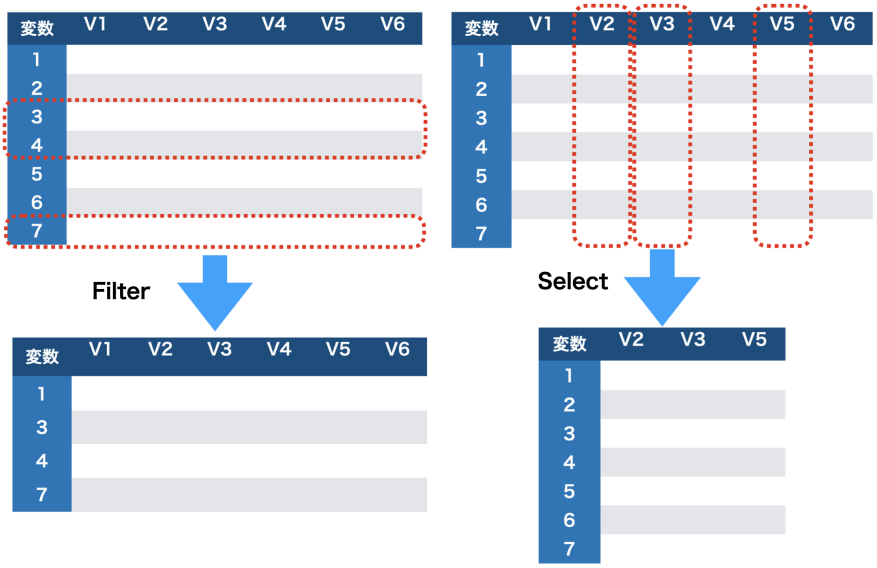

■変数生成；mutate 今度は変数を作る，mutate という関数です。たとえば打率は安打数を打席数で割ったもの，です。今回のデータセットには安打数 Hit と打席数 AtBats はありますが，打率のデータがありません。これを作ろう，というときはコード 5.16 のようにします。

code : 5.16 mutate 関数

```
1  dat %>% select(AtBats,Hit) %>% mutate(BattingAverage = Hit / AtBats)
```

今回はいったん変数を選択してから，mutate 関数に入れました。もちろん直接入れてもらっても構いません。いずれにせよ，これで変数が作れることがわかったと思います。

この「新しく変数を作る」というのは結構重要で，たとえばデータの中に欠測値があったとき，それを別の数字で置き換えるということがしたくなるかもしれません。mutate 関数で作る変数名を既存の変数名と同じにしておくと**上書き**されますから，これで書き換えることができます。

またデータサイエンスの実践上，変数同士の組み合わせからデータの特徴を表す別の変数を作り出したいということはよくあります。こうした加工のことを**特徴量エンジニアリング**といいます。

このように変数を加工することで，既存の変数から新しい変数をどんどん作っていくことができます。言い換えれば，データの加工はこれらの関数を使って，R 上で記録を取りながら加工していきましょう，ということです。データを表計算ソフトで作っていて，そこで加工してしまうとデータの捏造が疑われる可能性があります。入力ミスや欠測値など不完全なデータであっても，それをどのように修正したかをすべて R で記録しながら進めていくことが，オープンサイエンスの取り組みとして重要なことなのです。入手したデータファイルは手を加えず，加工のプロセスをすべてオープンに明示しながら分析を進めていくことが重要です。

第 6 章

さまざまな相関係数と R による実践

6.1 二変数間関係の指標

前回は 1 変数の記述統計について学んできましたが，本コマからは複数の変数間の関係性について考察します。

6.1.1 クロス集計表による理解

名義尺度水準や順序尺度水準など，算術計算ができない変数同士であってもその関係性をチェックする方法はあります。**クロス集計表 (contingency table)** はカテゴリカルデータの関連を表現する基本的な方法です。次の例 (表 6.1) を見てみましょう[*1]。これは行変数として年齢層変数，列変数に「睡眠障害の有無」変数をおいたものです。このように，2 つのカテゴリカルデータを組み合わせて，それぞれの組み合わせの出現頻度を数えたものがクロス集計表です。たとえば，10 代の人は 38 人中 8 人が睡眠障害があるということがわかります。これをもとに，年齢層と睡眠障害の関連を調べることができます。

表 6.1 年齢層と睡眠障害のクロス集計表

	あり	なし	合計
10 代	8	30	38
20 代	30	77	107
30 代	27	60	87
40 代以上	40	28	68
合計	105	195	300

特に，年齢ごとの違い (行変数の効果) が見たい場合は，睡眠障害の有無 (列変数) を基準にした相対度数にするといいでしょう。このようにしてみると，10 代は 7% しかない睡眠障害が 30 代では 34% に増え，40 代以上では 26% に減っていることがわかります。

今度は，睡眠障害の有無はどういう特徴があるのか知りたいとします。睡眠障害の有無は列変数ですから，今度は行ごとに相対頻度にします。

そうすると，睡眠障害は 10 代ではおよそ 2 : 8 の比率が，40 代では 5 : 5 の比率になっていることがわかります。つまり，年齢層が上がるにつれて，睡眠障害の有無の比率が変化していることがわかります。このように，行の比較をするには列のパーセント，列の比較をするには行のパーセントを出して考えるのが基本です。

[*1] 説明のための仮想データです。実際のデータではありません。

表 6.2　年齢層と睡眠障害のクロス集計表 (列パーセント)

	あり	なし
10 代	7.70	18.90
20 代	31.70	35.20
30 代	34.60	30.10
40 代以上	26.00	15.80
合計	100.00	100.00

表 6.3　年齢層と睡眠障害のクロス集計表 (行パーセント)

	あり	なし	合計
10 代	17.80	82.20	100.00
20 代	32.40	67.60	100.00
30 代	37.90	62.10	100.00
40 代以上	46.60	53.40	100.00

クロス集計表は，カテゴリカルデータの関連を調べるための基本的な手法であり，名義尺度や順序尺度の変数間の関係を把握するのに役立ちます。しかし，連続変数同士の関係を調べる場合はどうでしょうか。たとえば，身長と体重の関係を調べたいとします。身長は連続変数，体重も連続変数ですから，クロス集計表は使えません。このような場合には，**共分散 (covariance)** や**相関係数 (correlation coefficient)** を使います。

6.2　変数間関係の指標

指標の話をする前に，可視化を考えましょう。複数の変数を図にするとき，連続的な変数であれば**散布図**を描くのが直感的にもわかりやすいでしょう。

図 6.1　散布図の例

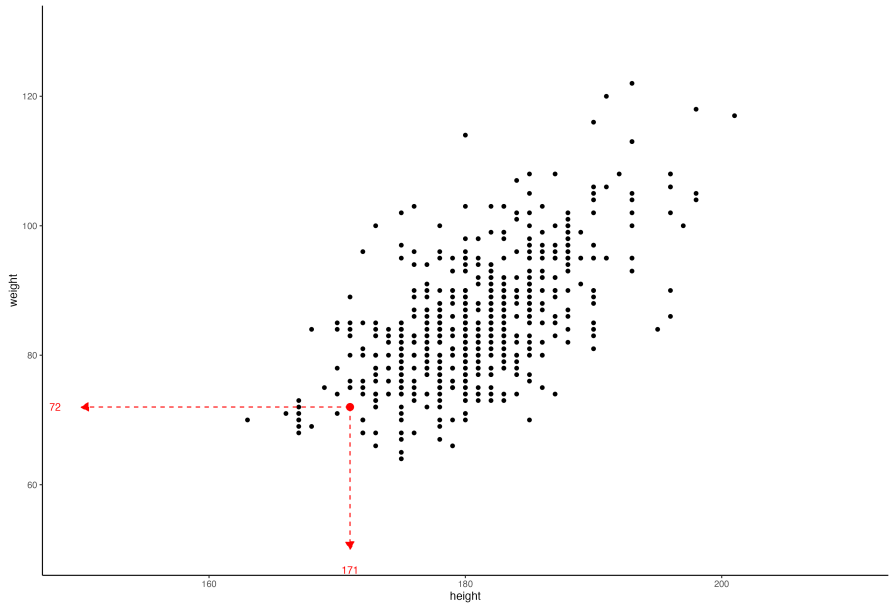

表 6.4 2020 年プロ野球選手の身長と体重のデータ (一部)

	ID	Name	height	weight
1	1	菊池 涼介	171.00	72.00
2	2	鈴木 誠也	181.00	98.00
3	3	K. ジョンソン	193.00	95.00
4	4	會澤 翼	177.00	91.00
5	5	大瀬良 大地	187.00	95.00
6	6	長野 久義	180.00	85.00

図 6.1 に，身長と体重のデータをプロットしたものを示しました[*2]。データの一部は表 6.4 に示した通りです。X 軸のラベルに height(身長)，Y 軸のラベルに weight(体重) とありますように，2 つの変数を同時にプロットしています。左下に目立つように 1 点色とサイズを変えた点を打ちましたが，これは表 6.4 の ID=1 のケース，つまり 菊池涼介選手を表しています。彼は身長が 171cm，体重が 72kg であり，対応する X 軸，Y 軸をみるとちょうどその値になっていますね。このように，各点が 1 つのケースに対応しているのが散布図です。

これを見ると次のことがいえそうです。すなわち，身長が高い人は，体重も大きく，背が低い人は体重も小さい，ということが多い傾向がある，と。というのも，身長が高くて体重が軽い領域 (グラフの右下) や，身長が低くて体重が重い領域 (グラフの左上) に点が打たれていないので，そういう人はいない，と思えるからです。この図のように，散布図に打たれた点が右上がりの方向にあると，2 つの変数の間になんらかの関係があるということが推察できますね。その関係がどのようなものであれ，このような関係にあると私たちは「何があるんだろう」と考えたり，「背が高いということは体重も重いだろうな」と予測したりできます。来年チームにやってくる新しい選手が，どんなポジションでどんな特技を持っているかはわからなくても，身長が 200cm だということだけ分かれば，まあ体重が 60kg ってことはないよな，と予測できますものね。

さて，前期後期を通じてこの授業のポイントは「見えないものを見ようとする」でした。皆さんはここで変数間の相関を推察したわけです。関係がありそうだと予測したと言ってもいいかもしれません。直接は見えない関係をデータから見出すには，変数間関係が重要であることがお分かりいただけますでしょうか。

図 6.1 に示した関係は，とくに「正の相関関係」と言います。方向が同じ，つまり一方が大きければ他方も大きい，一方が小さければ他方も小さい，という関係にあるからです。逆に負の相関関係というのもあります。一方が大きければ他方は小さく，その逆も成り立つような状況がそうで，散布図でいうと点が右下がりになるような散らばりをするときです。負の相関関係でも関係は関係ですから，予測できますね。

どちらの傾向もないデータは相関がない，無相関である，といいます。散布図で書くと，各点が円のように広がる形になります。無相関であれば，関係性・規則性がないので，予測はできません。性格心理学では血液型と性格は無相関である，ということがわかっていますが，この話をすると「でも僕は血液型は A 型で，多くの人に几帳面な性格だ，って言われるんですよ！」と反論する人がいます。実際に授業しているとよくある質問です。何がおかしいのかわかりますか？ 心理学者の主張は「無相関である」です。関係がない，一般的な傾向がないということです。無関係なので，A 型で几帳面な人もいるし，几帳面でない人もいます。B，O，AB 型で几帳面な人もいますし，そうでない人もいるというだけなのです。無相関であれば，そこから考察することはできません。

[*2] このデータは第 4 講や第 5 講で使ったものと同じ，2020 年のプロ野球選手のデータセットです。データは全体で 664 人分になります

このように，変数間関係は色々な面において重要な指標です。分散がなければ情報が取り出せない，というのと同じで，相関関係がなければ関連する情報が取り出せないのです。このことを念頭に置いた上で，変数間関係を指標化することを考えましょう。

■**共分散**　二変数間関係の強さを表す指標は**共分散 (covariance)** といいます。さきほどの図 6.1 を例にとって考えてみましょう。身長変数を x，体重変数を y とします。ID=1 の菊池選手のデータは，$x_1 = 175, y_1 = 68$ のように表します。データ全体を使って身長の平均，体重の平均を計算できますが，これをそれぞれ $\bar{x}, \bar{y}$ と表しましょう。共分散は次の式で表されます。

$$s_{xy} = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y})$$

これはよく見ると，分散の式に似ていると思いませんか。分散の式は次のように書くのでした。

$$s_x^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2$$

この二乗になっているところを展開して見ると次のようになります。

$$s_{xx} = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})(x_i - \bar{x})$$

こうして s_{xy} と s_{xx} を見比べるとわかりやすいと思いますが，分散は変数 x と x 自身との共分散であるとも言えるわけです。

もう少し違う見方をしてみましょう。共分散はそれぞれの変数についての平均偏差の積の平均である，とも言えます。$(x_i - \bar{x})$ は変数 x について，i さんの値が平均からどれほどずれているかを表していて，平均より上であればプラス，下であればマイナスになります。$(y_i - \bar{y})$ は同様に変数 y についての話ですが同じ個人 i さんについてのデータでもあります。なので，ある個人 i が，変数 x でも平均より上，変数 y でも平均より上であれば，この 2 つを掛け合わせた $(x_i - \bar{x})(y_i - \bar{y})$ はプラス × プラスで，プラスの数字になります。同様に，ある人がどちらの変数でも平均より下であれば，マイナス × マイナスでプラスですから，この数字は大きくなります。この数字が小さくなるのは，ある人が一方の変数で平均より上，他方の変数で平均より下，というときです。このとき掛け合わせた数字はマイナスになるので，総和を減らすことになります。このような数字を人数ぶん足し合わせる ($\sum_{i=1}^{N}$) という操作ですから，最終的にプラスであれば正の相関関係マイナスであれば負の相関関係がある，ということになるわけです。

注意すべきことは，共分散の大きさは変数の単位に依存するということです。たとえば身長と体重の共分散の場合ですと，身長の単位は cm，3 桁の数字で，体重は単位が kg，2 桁の数字が多いでしょうから，かけ合わせたものの平均は 2〜3 桁の数字になるでしょう。この時の単位は cm×kg でよくわかりません。ただ，身長を mm に換算し，体重をポンドに換算するといったことをすると，それに応じて共分散の大きさは変わってきます。関係が同じなのに，単位を変えただけで数字が変わってしまっては困りますね。

6.3 相関係数：標準化された共分散

相関係数 (correlation coefficients) は，単位に影響されずに変数間関係をみるものです。共分散の大きさは，元データの単位に依存するので，変数間関係を表す指標の大きさが単位に依存するということは，異なる変数間関係を比較できないことになって不便だからです。「身長と体重の関係の強さ」と「国語の成績と算

数の成績の関係の強さ」はどっちが強い結びつきをしているのでしょう？ との問いには共分散を見ても答えられません。さてでは，それぞれの変数の単位を揃えるにはどうしたらよいのでしょう？その目的のために，**標準化 (standardize)** について考えます。

6.3.1 標準化

平均値と標準偏差を使って，単位の違う変数を比較できるようにします。この手法を**標準化 (standardize)** といいます。

心理学の研究対象の多くは，絶対ゼロ点を持たないものです。たとえば性格というのを考えると，とある性格特性が「ない」ということはありません。もちろん他の人とくらべてより明るい人だとか，より勤勉な人だとか，より情緒が不安定な人だ，といったことはあります。しかしこれらはいずれも，多くの人の中での相対的な位置であって，明るい人でない＝暗い人ではあっても，明るいか暗いといった次元に存在しない人，というのはありません。すなわちデータの特徴として間隔尺度水準であることがせいぜいなのです。そうした他者との比較において考える時，相対的な位置を表現する方法を考えなければなりません。

ゼロ点が存在しないので，相対的な位置を決める中心点を平均値におくとしましょう。平均値に比べてその人がどの程度離れているか，というのは平均偏差ですから $x_i - \bar{x}$ で表現できます。表 6.5 にとある学生の成績のデータを載せてみました。これをみると，この人の素点は英語が最も高く，この人は英語が得意なんだな，と思うかもしれません。でもクラス平均と比べてみると，あらびっくり，むしろ平均より低いので，相対的に英語は苦手なんじゃないか，ということがわかります。素点だけでは困りますよね[*3]。さて，偏差を見ると国語と数学のどちらもその平均偏差は $+14$ です。なるほど，国語と数学は同じぐらい出来がいいのだな，と考えたいところですが，果たしてこの考え方もあっているでしょうか？ 実はこれでもまだ足りません。というのも，

表 6.5 成績の比較

科目	成績 X_i	クラス平均 $\bar{X}$	偏差 $(x_i - \bar{x})$	SD(s_x)
英語	86	90	-4	8
国語	67	53	14	10
数学	44	30	14	5

このクラスの標準偏差をみると，国語と数学では倍ほど違いがあります。標準偏差の違いは，データの散らばり方の違いです。図 6.2 にプロットしてみました。このテストの点数が，左右対称の分布をしているとした時の例です。

図 6.2 の最上段には英語の分布とこの人の位置が書いてあります。分布のピーク＝最も人が多いところは 90 点ぐらいのところにあり，この人はそれの左側ですから相対的にやや劣ることがわかります。二段目・三段目に国語と数学があり，相対的に優れていることがわかります。同時に，国語の分布はやや幅広く，数学は平均点が低く散らばりの幅も少ないことがわかります。国語は幅広ですから，この人よりも高い点数を取る人もいるようです。一方数学は幅が狭いため，この人よりも高い点数を取れる人がほとんどいません。ということは，かなり上位の数学力を持っていることになります。このように，相対的な位置を考えるときはこのデータがどれぐらい広がっているかを考えなければなりません。そこで平均からの偏差を標準偏差で割り，標準偏差いくつ分はずれているのかを考えましょう。この点数を z_i とし，次のように計算します。

[*3] 私の娘が通っていた中学校では，定期試験の結果を表にまとめたプリントを親に見せてくれるのですが，本人の素点と本人の平均点しか表示されておらず，まったく無意味な数値の羅列でした。学校に抗議するよう娘には伝えたのですが，卒業まで決して直ることはありませんでした。

図 6.2 データの散らばりと相対的な位置

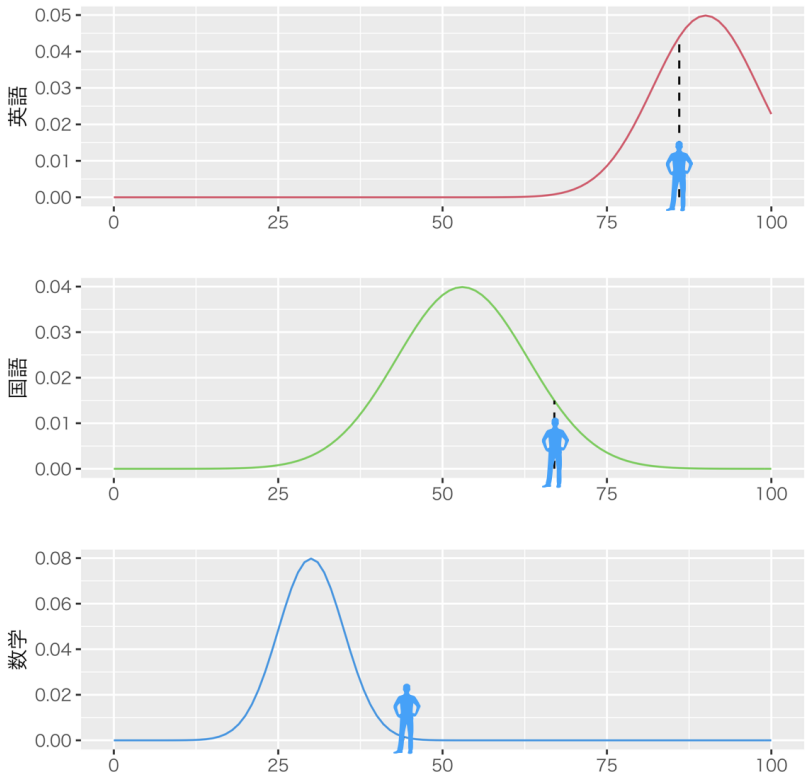

$$z_i = \frac{(x_i - \bar{x})}{s_x}$$

このスコア z_i を**標準化スコア (standardized score)** と言います。もっと簡単に z スコアということもあります。このように標準化したスコアでこの人の成績をみてみますと，英語は -0.5，国語は $+1.4$，数学は $+2.8$ となります。国語の優秀さよりも数学の優秀さのほうが際立っていることが，数字で表されましたね。

この標準化されたスコアは平均が 0 ですし，標準化されたスコアの分散は 1 になっています (標準偏差も 1 です)。平均を取り除いて標準偏差いくつ分なのか，という表現にしたのですから当然ですね。言い方を変えると，この数字からは平均や分散を取り除いたことで，単位の大きさに左右されずに複数の変数で比較できるようになったということです。先ほど，国語と数学の点数を比較しました。素点だと平均や分散によって変わってくるので，それを取り除いたことで比較できたのですが，これは国語が 200 点満点，数学が 1000 点満点だったりしても可能です。相対的な位置だけの問題になっているからです。他にも，身長と体重といった単位がまったく違うものを比較できます。心理学のデータは単位がよくわからないのですが，このスコアにすると相対的にどれぐらい「明るい人」「真面目な人」なのか，ということがわかり，比較できるようになります。標準化スコアは心理学研究の中でなくてはならないものなのです。

またみなさんは**偏差値 (deviation score)** というのを知っていると思います。学業成績に関係してくるアレですね。偏差値は，実はこの z スコアと同じです。ただ z スコアだとマイナスになったり，単位が小さくなったりするので，平均 50，標準偏差 10 になるように変換して，

$$\text{偏差値} = 10z_i + 50$$

という計算で算出します。今回の例でいうと，この人の偏差値は英語で 45，国語は 64，数学は 78 ということ

になります。

6.3.2 ピアソンの積率相関係数

さて, この標準化されたスコアを使って, 共分散の単位を整えましょう。変数 x と y の相関係数は r_{xy} と表します。

$$
\begin{aligned}
r_{xy} &= \frac{1}{N}\sum_{i=1}^{N}(z_{x_i} - \bar{z_x})(z_{y_i} - \bar{z_y}) && \text{z スコアの平均は } 0 \\
&= \frac{1}{N}\sum_{i=1}^{N} z_{x_i} z_{y_i} && \text{z スコアの式に戻そう} \\
&= \frac{1}{N}\sum_{i=1}^{N} \frac{(x_i - \bar{x})}{s_x}\frac{(y_i - \bar{y})}{s_y} && i \text{ は分子にしか関係ないから} \\
&= \frac{\frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y})}{s_x s_y} && \text{分子が共分散だ} \\
&= \frac{s_{xy}}{s_x s_y}
\end{aligned}
$$

このように展開できました。相関係数は共分散をそれぞれの標準偏差で割ったもの, と考えれば良いわけですね。この数字は単位が違う 2 つの変数でも計算できますし, 単位が整えられているので $-1 \leq r_{xy} \leq 1$ の範囲に収まります。

図 6.3 さまざまな相関係数

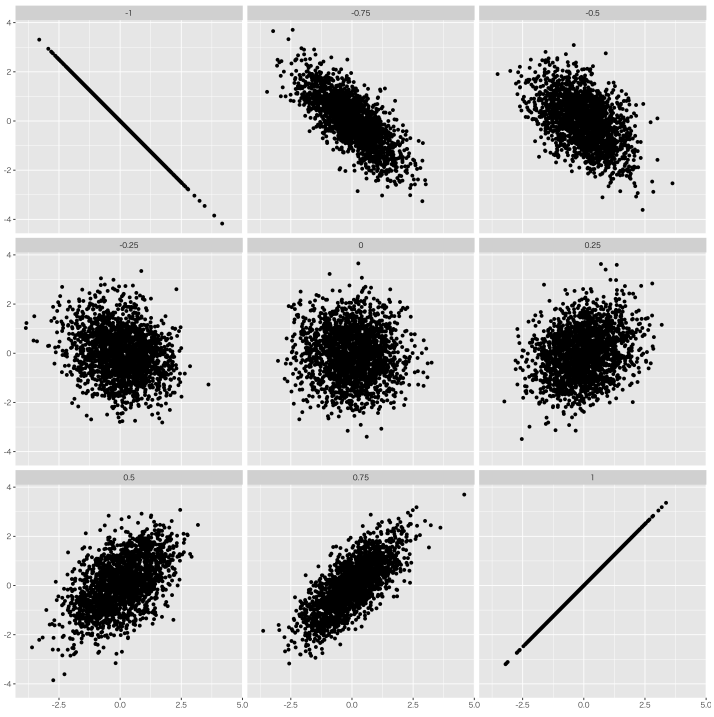

図 6.3 にはさまざまな相関係数のプロットを示しました。ちなみにさきほどの野球選手の身長と体重のデータは, 相関係数 $r = 0.645$ になります。大体の散布図のイメージを持っておいてもらうことも重要ですし, 何

かデータを取ったら図にする，ということを忘れないでください。

6.4 尺度水準に応じた相関係数

さて，相関係数は間隔尺度水準以上の量的変数でないと計算できません。名義尺度水準や順序尺度水準の時はどうすれば良いかというと，それぞれの尺度水準に応じた相関係数を使います。名義尺度水準の変数同士の相関は**カイ二乗 (chi-square)** 値を使います。順序尺度水準の変数同士の相関は**スピアマンの順位相関係数 (Spearman's rank correlation coefficient)** を使います。

6.4.1 χ^2 値

カイ二乗値は，「χ^2 値」と書きます。これはエックス (x) ではなく，ギリシア文字のカイ (χ) であることに注意してください。

χ^2 値は，クロス集計表からも計算できる，名義尺度水準の変数同士の関連の強さを表す指標です。たとえば，表 6.1 のようなクロス集計表があったとき，年齢層と睡眠障害の有無の関連を調べることができます。クロス集計表から χ^2 値を計算するには，次の式を使います。

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

ここで O_i は観測度数，E_i は期待度数といいます。期待度数は，行と列の値を掛け合わせて，行の合計と列の合計で割ったものとして計算でき，意味的には「もし変数同士が関係なかったら，変数の組み合わせから出現度数はこれぐらいになるに違いない」と考えられる値です。

期待度数について，簡単な例で見てみます。まずはクロス集計ではなく，単純な度数分布表を考えてみましょう。たとえば，携帯のキャリア会社はどこを選んでいますか，という調査をしたとします。表 6.6 のような調査結果が得られたとしましょう。

表 6.6 携帯キャリアの調査

キャリア	人数
A 社	55
D 社	32
S 社	33
合計	120

この例で，もしキャリアの選択に何の好みもないとするなら，合計の 120 人は均等に分けられるはずです。つまり，A 社，D 社，S 社それぞれの期待度数は $120/3 = 40$ 人ということになります。先ほどの記号でいうなら，$E_1 = 40, E_2 = 40, E_3 = 40$ です。さて，実際の観測度数は A 社が $O_1 = 55$ 人，D 社が $O_2 = 32$ 人，S 社が $O_3 = 33$ 人ですから，χ^2 値は次のように計算できます。

$$\chi^2 = \frac{(55-40)^2}{40} + \frac{(32-40)^2}{40} + \frac{(33-40)^2}{40} = 8.45$$

これが期待度数と観測度数の差を表す指標になります。今回は 1 変数の度数分布表でしたので，変数間関係の強さと言うより，「ばらつきの均等さ」の指標ということができます[*4]。

[*4] χ^2 値をこのように 1 変数で使うときは，理論的な分布からの偏りを見ることになります。今回は「どのキャリアを選ぶかについて

さてこのように，χ^2 値は 1 変数の分布の偏りを調べることができました。では，2 変数のクロス集計表の場合はどうなるのでしょうか。たとえば先ほどの表 6.1 の例で考えてみましょう。10 代の人は 8 人が睡眠障害があるということでした。睡眠障害の有無に年齢層の影響がなければ，その周辺度数から 105 : 195 の比率であるはずですから，$105/300$ のはず。同様に，年齢層に睡眠障害の影響がなければ，10 代の比率と同じはずですから $38/300$ のはずです。これを掛け合わせると，期待度数は $105/300 \times 38/300 = 13.3$ となります。実際の観測度数は 8 人ですから，このセルの χ^2 値は

$$(8 - 13.3)^2/13.3 = 2.11203$$

となります。この計算をすべてのセルに対して行なって，計算したのが表 6.1 の χ^2 値です。今回は 9.9627 になります。この χ^2 値が大きいほど，2 つの変数の関連が強いことを示しますが[*5]，これは総度数や分割の仕方によって変わりますので，このままでは大小関係を評価できません。

そこで，次のような指標が考えられています。

$$V = \sqrt{\frac{\chi^2}{N \times (k-1)}}$$

ここで N は全体の度数，k は行数または列数の小さい方を表します。この指標は 0 から 1 の範囲に収まります。0 に近いほど関連がない，1 に近いほど関連がある，ということになります。この指標は**クラメールの V(Cramér's V)** と呼ばれています。これは相関係数と違って，最も小さい値は 0，最も大きな値は 1 であることに注意してください。

6.4.2 スピアマンの順位相関係数

つぎに順序尺度水準のばあいを考えてみましょう。このような場合は**スピアマンの順位相関係数 (Spearman's rank correlation coefficient)** を使います。

対応する二つの変数を x と y とします。これらの変数は順序尺度水準ですから，それぞれの変数の値を順位に置き換えます。たとえば身長が 170cm，体重が 60kg の人は，身長では 1 位，体重では 2 位だったとします。この場合，身長の順位は 1，体重の順位は 2 となります。これをそれぞれ x_i と y_i とします。このとき，スピアマンの順位相関係数 r_s は次のように計算できます。

$$r_s = 1 - \frac{6\sum_{i=1}^{N} d_i^2}{N(N^2-1)}$$

ここで d_i は順位の差を表します。たとえば身長が 170cm，体重が 60kg の人は，身長では 1 位，体重では 2 位だったとします。この場合，$d_i = 1 - 2 = -1$ となります。これをすべての人について計算して，d_i^2 を足し合わせます。また，同着順位があった場合はその順位を平均して計算します。たとえば，9 点，8 点，8 点，7 点という 4 人がいた場合，順位を「1 位，2 位，2 位，4 位」とすることになりますが，平均順位とは「1 位，2.5 位，2.5 位，4 位」とするものです。これを計算して，d_i^2 を足し合わせます。あとは式に代入して計算すれば OK です。

特別な好みがない」という仮定から均等な分布を期待度数としました。実際はもちろんそんなことはありませんので，「均等からずれている」すなわち「何らかの好みがあって選ばれている」と解釈することになります。期待度数は均等にしなければならない理由はなくて，たとえば日本人の血液型は A:B:O:AB=4:2:3:1 というのが一般的な分布として知られています。であれば調査人数をこの比率で分けたのが理論分布になるわけです。このような χ^2 値の使い方は，適合度の検定と呼ばれることがあります。検定についてはのちの章で詳しく取り扱います。

[*5] このような χ^2 値の使い方を，独立性の検定ということがあります。検定については後の章で詳しく取り扱います。

数式は面倒ですが，同順位が無ければ本質的に「順序の値に対してピアソンの相関係数を計算している」と考えて構いません。また，R で実行する上では，相関係数の関数にオプションを追加するだけですので，それほど難しくはありません。

6.4.3 統計モデルに基づいた相関係数

ここまでは，変数間の関係を表す指標として，ピアソンの相関係数やスピアマンの順位相関係数を紹介しました。これらは変数間の関係を表す指標として一般的ですが，実際のデータ分析ではより複雑なモデルに基づいた相関係数が用いられることがあります。

詳細は省略しますが，これらについても R のパッケージを使って計算することができます[*6]。表 6.7 に一覧を示しますので，興味のある方は調べてみてください。大事なのは，尺度水準やデータに合った相関係数を選ぶことです。明らかに順序尺度水準でしかないのに，ピアソンの相関係数を使うのはおかしいですし，逆に連続変数であるのにスピアマンの順位相関係数を使うのもおかしいのです。データの性質をよく考えて，適切な相関係数を選ぶようにしましょう。

表 6.7 特殊な相関係数の一覧

名称	和名	対象データ	簡単な説明
Tetrachoric correlation(テトラコリック相関係数)	四分相関	バイナリ × バイナリ	2 つの二値変数の背後に連続的な潜在変数があると仮定して算出する相関係数。2×2 分割表データから潜在的な連続変数間の相関を推定する。
Polychoric correlation(ポリコリック相関係数)	多分相関	順序 × 順序	テトラコリック相関の拡張版。2 つの順序カテゴリ変数の背後に連続的な潜在変数があると仮定して算出する相関係数。
Polyserial correlation(ポリシリアル相関係数)	多系列相関	連続 × 順序	連続変数と順序カテゴリ変数の間の相関係数。順序変数の背後に連続的な潜在変数があると仮定して算出する。
バイシリアル相関係数 (Biserial correlation)	二系列相関	連続 × バイナリ	連続変数と二値変数の間の相関係数。二値変数の背後に連続的な潜在変数があると仮定して算出する。点双列相関よりも推定精度が高いが，より強い仮定が必要。
Mutual Information Coefficient (MIC)	相互情報量係数	あらゆる形式	情報理論に基づく非線形関係の測度。2 つの変数間の関係の強さを表し，線形・非線形を問わずあらゆるパターンの関連を 0〜1 の値で示す。

[*6] ポリコリック，ポリシリアル，テトラコリック相関は，心理系の便利関数がいっぱい詰まった `psych` パッケージで計算できます。小杉が作ったテストデータ分析パッケージ `exametrika` でも一部対応しています。

6.5 R による相関分析の実践

では実際に R で計算してみましょう。まず例によって，RStudio を立ち上げ，この授業のプロジェクトフォルダを開いてください。サンプルデータがワーキングディレクトリに入っているかを確認し，新しいスクリプトファイルを立ち上げ，いつもの呪文を書きます。この段階で「何言ってるの?」とか「うまくできない！」という人はすぐに TA を呼んでください。

code : 6.1 データの準備

```
1  # Rのプロジェクトを立ち上げ，プロジェクトフォルダを開いたうえで
2  # 以下のコマンドを実行してください
3  rm(list=ls())
4  library(tidyverse)
5  # データを読み込む
6  dat <- read_csv("BaseballDecade.csv")
7  # データを一部絞り込みます
8  dat <- dat[dat$Year == "2020年度",]
9  # または
10 # dat <- dat %>% filter(Year == "2020年度")
```

■コード解説

3,4 **行目** 環境のリセットと tidyverse パッケージの読み込み
6 **行目** データを読み込みます。データは CSV 形式で保存されていますので，`read_csv` 関数を使います。
8 **行目** データを絞り込みます。データには 2011 年度から 2020 年度までの 10 年度分が入っていますので，この行で 2020 年度のデータだけを取り出します。
10 **行目** 8 行目と同じ意味ですが，tidyverse パッケージの関数を使った書き方です。これを使うと，データフレームの中から条件に合ったデータだけを取り出すことができます。

■散布図の作成（R の基本関数） まずは R の基本関数 `plot` を使って，身長と体重の散布図を作成してみましょう。

code : 6.2 R base による散布図の作成

```
1  # 身長と体重の散布図（R base）
2  plot(dat$height, dat$weight,
3       xlab = "身長(cm)", ylab = "体重(kg)",
4       main = "身長と体重の散布図")
```

■コード解説

2 **行目** `plot` 関数で X 軸に身長，Y 軸に体重を指定します。
3,4 **行目** `xlab` と `ylab` で軸ラベル，`main` でタイトルを指定しています。

このコードを実行すると，R の標準グラフィックでシンプルな散布図が描画されます (図 6.4)。

■散布図の作成（ggplot2） 次に，tidyverse に含まれている **ggplot2** パッケージを使うと，より見栄えの良い散布図を簡単に作成できます。

図 6.4 身長と体重の散布図(R base)

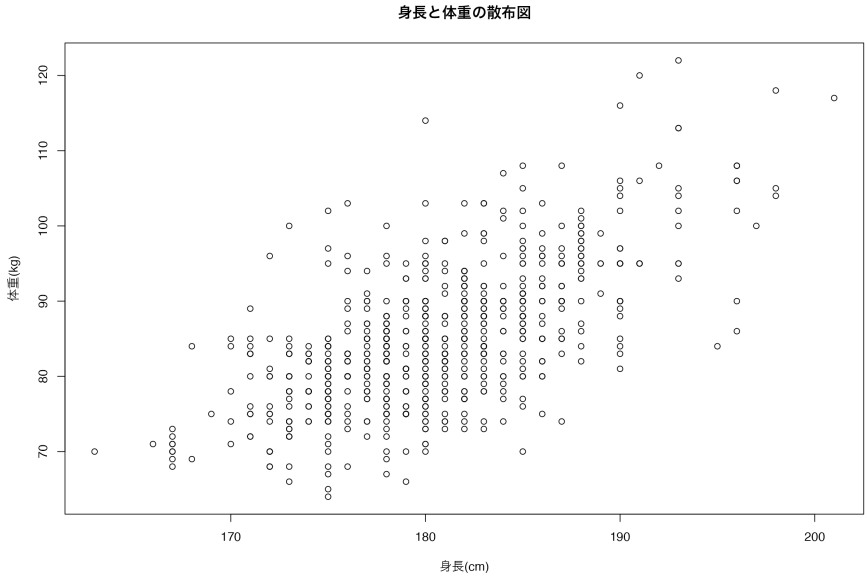

code : 6.3 ggplot2 による散布図の作成

```
1  # ggplot2による散布図
2  ggplot(dat, aes(x = height, y = weight)) +
3    geom_point() +
4    labs(x = "身長(cm)", y = "体重(kg)",
5         title = "身長と体重の散布図 (ggplot2) ") +
6    theme_bw()
```

■コード解説

2 行目 ggplot 関数でデータフレーム dat を指定し，aes で X 軸に身長，Y 軸に体重を指定します。

3 行目 geom_point で散布図を描画します。

4,5 行目 labs で軸ラベルとタイトルを指定します。

6 行目 theme_bw で白黒のシンプルなテーマを適用します。

このコードを実行すると，より美しくカスタマイズしやすい散布図が得られます (図 6.5)。

■ピアソンの相関係数の計算 ピアソンの相関係数は，2 つの連続変数間の線形関係の強さを表す指標でした。R では cor 関数を使うと簡単に計算できます。

code : 6.4 ピアソンの相関係数の計算

```
1  # ピアソンの相関係数の計算
2  cor(dat$height, dat$weight)
3  # または
4  cor(dat$height, dat$weight, method = "pearson")
```

■コード解説

2 行目 cor 関数で身長と体重のピアソンの相関係数を計算します。デフォルトではピアソンの相関係数が

図 6.5　身長と体重の散布図(ggplot2)

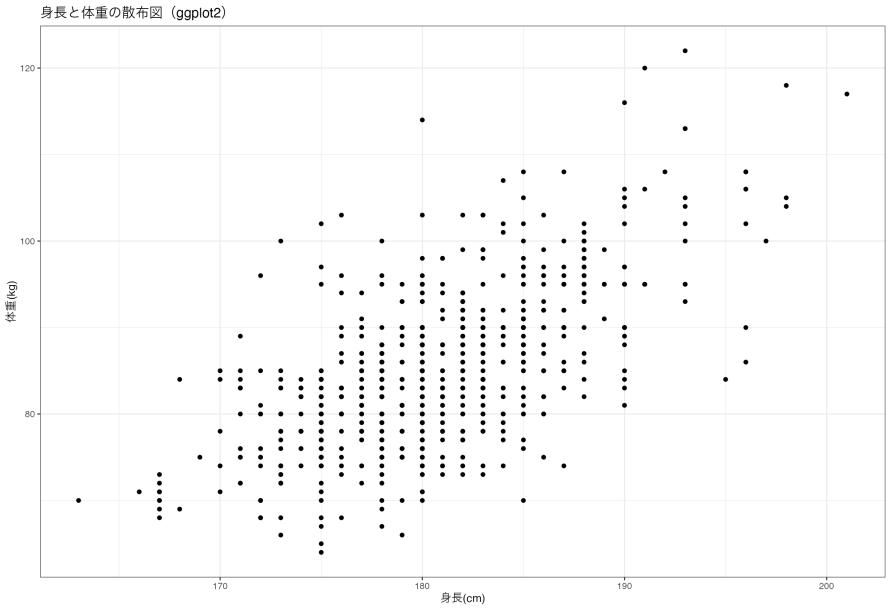

計算されます。

4 行目　明示的に `method = "pearson"`を指定することもできます。

このコードを実行すると，身長と体重のピアソンの相関係数が計算されます。`0.645125` という値が出力されていれば OK です！

■スピアマンの順位相関係数の計算　今度はスピアマンの順位相関係数を見てみましょう。

まず，データを加工します。データの中から，年俸が高い野手 TOP20 人を抜き出して，年俸とホームラン本数の順位相関を見ることにします。

code : 6.5　年俸が高い野手 TOP20 の抽出

```
1   # データを読み込む
2   dat <- read_csv("BaseballDecade.csv")
3
4   # 野手（投手以外）を選び、年俸で降順にソートしてTOP20を取得
5   top20_players <- dat %>%
6     filter(Year == "2020年度") %>%  # 2020年度のデータ
7     filter(position != "投手") %>%   # 投手以外（野手）を選択
8     arrange(desc(salary)) %>%        # 年俸の降順でソート
9     head(20) %>%                     # 上位20人を取得
10    select(Name, team, salary, HR)   # 必要な列だけを選択
```

■コード解説

2 行目　データファイルを読み込みます。`read_csv` 関数は tidyverse パッケージの関数で，CSV ファイルを読み込むためのものです。

5 行目　パイプ演算子 `%>%` を使って，データの加工を順番に行っていきます。

6 行目　`filter` 関数で 2020 年度のデータだけを抽出します。

7 行目 投手以外の選手(野手)を選択します。!=は「等しくない」という意味の演算子です。

8 行目 arrange 関数で年俸の降順にソートします。desc は降順を指定する関数です。

9 行目 head 関数で上位 20 人を取得します。

10 行目 select 関数で必要な列だけを選択します。ここでは選手名, チーム, 年俸, ホームラン数を選択しています。

ヒストグラムを描けば一目瞭然ですが, 年俸のデータは右に長く裾を引いていますし, HR もよく打つひととそうでない人がいますので, データは偏ります。散布図を描けば一目瞭然ですが, 歪んだデータ同士の相関をピアソンの相関で計算するのはよくないです。後で説明しますが, ピアソンの相関係数は外れ値に大きく影響されるからです。

順序尺度水準として捉えて, 相関係数を算出するには次のようにします。0.2858256 という値が出力されていれば OK です！

code : 6.6 スピアマンの相関係数の計算

```
1    cor(top20_players$salary, top20_players$HR, method = "spearman")
```

■カイ二乗値の計算 カイ二乗値の計算例として, チームと血液型の関係を見てみましょう。阪神タイガース, 読売ジャイアンツ, 広島カープの 3 チームの選手の血液型の分布を調べます。

code : 6.7 チームと血液型のクロス集計表の作成

```
1  # 3チームと血液型変数を抜き出し、それぞれをFactor型にした上で、
2  # クロス集計表をだす
3  team_blood <- dat %>%
4    filter(Year == "2020年度", team %in% c("Tigers", "Giants", "Carp")) %>%
5    select(team, bloodType)
6
7  # Factor型に変換
8  team_blood$team <- factor(team_blood$team)
9  team_blood$bloodType <- factor(team_blood$bloodType)
10
11 # クロス集計表の作成
12 cross_table <- table(team_blood$team, team_blood$bloodType)
13 print(cross_table)
```

■コード解説

3-5 行目 filter 関数で 2020 年度の 3 チームのデータだけを抽出し, select 関数でチームと血液型の列だけを選択します。code:6.5 でデータを 10 年度分すべて読み込み直しているので, ここでも 2020 年度に絞っておきます。

8-9 行目 factor 関数を使って, チームと血液型の変数を因子型に変換します。

12-13 行目 table 関数でクロス集計表を作成し, print 関数で表示します。

このコードを実行すると, 3 チームの選手の血液型の分布を示すクロス集計表が得られます。この表から, チームによって血液型の分布が異なるかどうかを調べることができます。χ^2 値を算出するには次のようにします。

code : 6.8 カイ二乗値の計算

```r
chi_sq_test <- chisq.test(cross_table)
print(chi_sq_test)
```

■コード解説

1 行目 chisq.test 関数を使ってクロス集計表からカイ二乗値を計算します。
2 行目 計算結果を表示します。

このコードを実行すると，チームと血液型の関係を示す χ^2 値が得られます。この値が大きいほど，チームと血液型の間に関連があることを示します。出力は次のようになっているでしょう。

R の出力 6.1: 出力例

```
 Pearson's Chi-squared test

data:  cross_table
X-squared = 12.878, df = 8, p-value = 0.1161
```

ここに表示されている X-squared = 12.878 が χ^2 値です。テストと書いてあるのは統計的検定の結果ですが，これについてはまたの機会に解説することにします。

■クラメールの V の計算 カイ二乗値は，データの大きさや分割の仕方によって値が変わってしまうため，そのままでは比較が難しいという問題があります。そこで，クラメールの V という指標が使われます。クラメールの V は 0 から 1 の範囲に収まり，値が大きいほど関連が強いことを示します。

code : 6.9 クラメールの V の計算

```r
chi_sq_value <- chi_sq_test$statistic
n <- sum(cross_table)  # サンプルサイズ
r <- nrow(cross_table)  # 行数
c <- ncol(cross_table)  # 列数
min_rc <- min(r, c)     # r と c の小さい方

# クラメールのVの計算
cramers_v <- sqrt(chi_sq_value / (n * (min_rc - 1)))
```

■コード解説

1 行目 先ほど計算したカイ二乗検定の結果から，χ^2 値を取り出します。
2 行目 クロス集計表の全セルの合計からサンプルサイズを計算します。
3-4 行目 クロス集計表の行数と列数を取得します。
5 行目 行数と列数の小さい方を取得します。
8 行目 クラメールの V の計算式にしたがって値を計算します。

このコードを実行すると，チームと血液型の関係の強さを示すクラメールの V が得られます。この値は 0 から 1 の範囲に収まり，値が大きいほど関連が強いことを示します。今回は 0.1981431 という数字になったはずです。チーム編成と血液型にはそれほど強い関係がない，ということができます。

6.6 相関の落とし穴と可視化の重要性

さて，ここまでいろいろな相関係数や関係する指標を見てきました。一般にはピアソンの積率相関係数が最もよく使われます。データは量的に得られることが多いので，「ピアソンの積率」という言葉がついてないただの「相関係数」の場合は，一般にピアソンの相関係数を出していると言っていいでしょう。しかし，深く考えずに数値だけ見ることは大変危険です。ここでは相関係数を見る時の注意すべき点をいくつかあげていきます。

相関係数を見て考える話に入る前に，注意喚起から。表 6.8 のようなデータセットがあったとしましょう[*7]

表 6.8 さまざまなデータセット

dataset	Mean.X	Mean.Y	SD.x	SD.y	Min.x	Min.y	Max.x	Max.y	Corr
circle	54.267	47.838	16.760	26.930	21.864	16.327	85.665	85.578	-0.068
dino	54.263	47.832	16.765	26.935	22.308	2.949	98.205	99.487	-0.064
star	54.267	47.840	16.769	26.930	27.025	14.366	86.436	92.215	-0.063

データセット，`circle` も `dino` も `star` も，2 つの変数 X,Y を持っているのですが，いずれも平均，標準偏差にほとんど違いがありません。相関係数も-0.06 となっており，ほぼ無相関，関係がなさそうです。

ところがどっこい，これらの変数をプロットしてみたのが図 6.6 です。ご覧の通り，無関係ではなくプロットすると図が見えてきましたね。

図 6.6 プロットしてびっくり

実際のデータではこんなことはないと思いますが，これは「数字だけ見ていてもわからないよ」という警告です。たくさんのデータを手に入れると，ついつい計算機で一気に数字を出してみたくなります。実際のデータ分析をするときは (あまりにも簡単に相関係数が計算できてしまうがために)，見落とされるところでもあります。数値化は楽ですが，その分なにかを見落としているかも知れない，ということについて常に注意するようにしましょう。

以下では相関関係があったとしても，注意深く考えないといけない例を挙げておきます。

■落とし穴 1；直線じゃないかも 図 6.3 の左上には $r = -1$ の例，右下には $r = +1$ の例があります。このように，相関係数はその極限である ± 1 のときに，直線になる関係であることを理解しておいてください。言い換えると，相関係数はあくまでも変数間の直線的関係を指標化したものであって，曲線的な関係の場合はうまく表現できないのです。図 6.7 には曲がった散布図の例を示しました。このデータの相関係数は $r = 0.05$ です。ほとんど関係ないですね！じゃあこの X 軸の変数と Y 軸の変数は何の関係もない，といっ

[*7] このデータセットは，R の `datasauRus` パッケージ (Matejka & Fitzmaurice, 2017) の一部です。

ていいでしょうか。たとえばこのデータ，X 軸がコーヒーの温度，Y 軸が美味しさだったらどうでしょう。熱すぎても冷たすぎても，コーヒーは美味しくありません。適温というのがあるのです。あるいは X 軸が血圧，Y 軸が健康度だったらどうでしょう。血圧も高ければ高いほど健康，低ければ低いほど不健康というわけではないですよね。これらの例にあるように，心理的なデータや生理的なデータというのは，中庸であることが重要であることがあります。そのときに相関係数を算出して，それがとても低いので「血圧と健康には関係がない」と結論づけるのは間違えています。直線性を表す指標がよくない，というだけなのですから。

図 6.7　曲がった関係には向かない

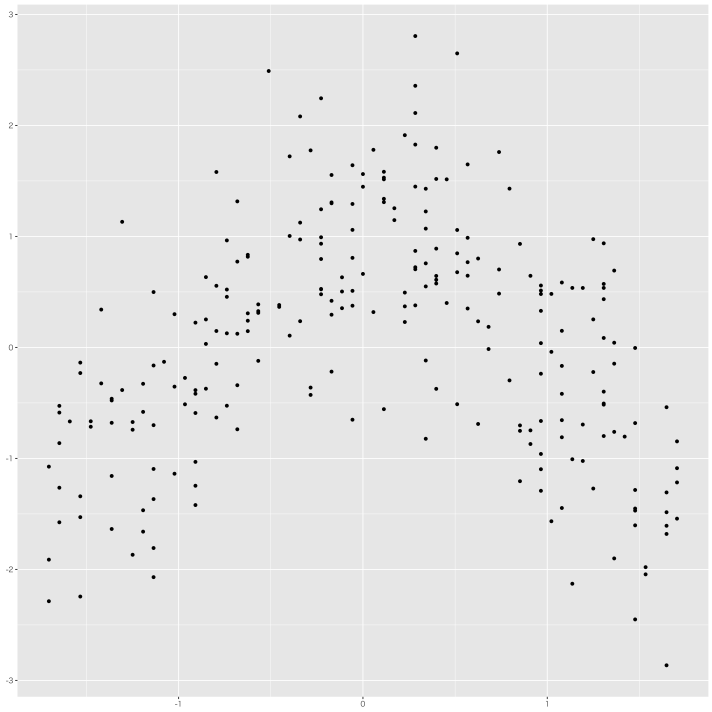

■落とし穴 2；全体の傾向じゃないかも　逆に，ある 2 変数の相関係数が $r = 0.922$ でした。この 2 変数には強い相関があるといって良いでしょうか。待って待って，いったん落ち着いて散布図を書いてみましょう。たとえば図 6.8 のようなデータなのかもしれないのですから。図 6.8 は，確かに相関係数は高いのですが，明らかにおかしなポジションにいるデータが 1 件ありますよね。平均値が外れ値に引っ張られたように，平均値をその計算過程の中に取り込んでいる相関係数も，外れ値に弱いところがあります。今回この極端な値を取る 1 ケースを取り除くと，相関係数は $r = 0.3$ にまで下がります。左の小さな群だけで見れば，むしろ関係ないと考えるべきなのです。これもデータを図にしなければ気づかない落とし穴です。

■落とし穴 3；データの一部が切り取られている　とある大学の入学試験のデータを取ってみたとします。入試の成績と，入学後の成績のデータを集め，入試の成績がどれぐらい入学後の成績と関係があるのかを考えたい，というわけです。良い成績で入学したら，入学後も成績が高いというのが普通に考えられる結果ですが，実はその相関係数は $r = 0.4$ ぐらいだった，ということもあります。なぁんだ，入試の成績はその後の頑張りと関係ないんじゃないか，入試なんか意味がないんじゃないか，と思うのは大間違い。

さて図 6.9 には，X 軸に入試の成績を，Y 軸には入学後の成績をプロットしてみました。相関係数は全体で 0.7 あるのです。ところが，大学入試というのは世知辛いもので，ある点数を取らない人はそもそもその大学に入れませんよね。図でいうと，ある線 (60 点) より右側の黒いデータしか分析するときに手に入らないの

図 6.8　外れ値がひっぱる

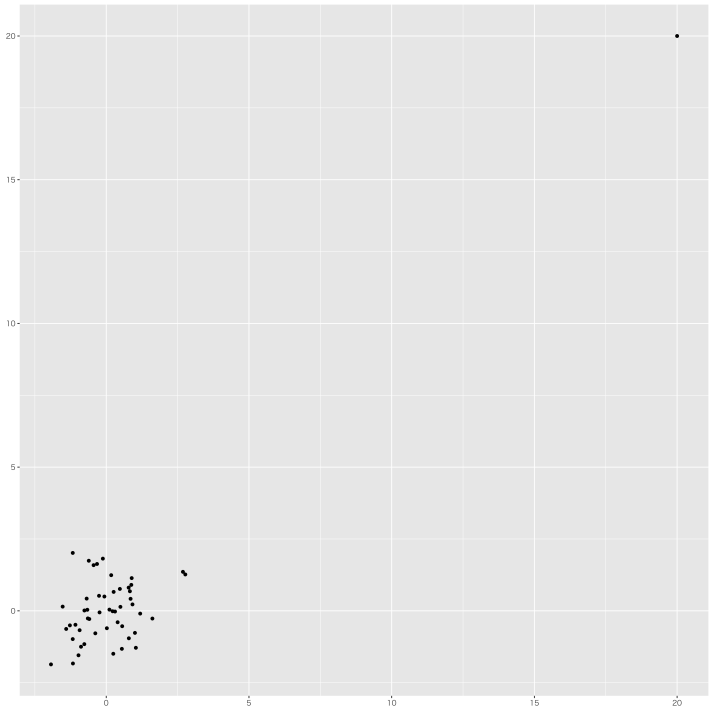

です。この黒い点だけみて相関係数が低いから，関係ないんだと思ってしまうのは間違いです。このように，データがそもそも打ち切られている可能性にも注意が必要です。このようなデータは切断データといわれます。これは相関係数の問題というより，データの問題なのですが，データの性質をよく考えて考察しなければならないということはしっかり意識しておいていただきたいところです。

図 6.9　打ち切りデータの例

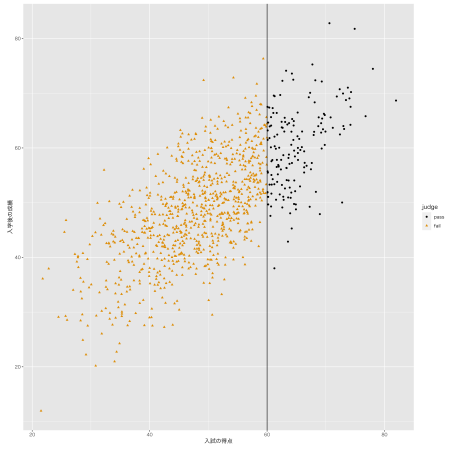

■落とし穴 4；データは色々な情報が混在している？　図 6.10 の左を見てください。これは右上がりの散布図ですから，なるほど変数間に関係はありそうです。実際に相関係数を計算すると $r = 0.67$ になります。今度は散布図もみているからバッチリ！と思うかもしれませんが，さにあらず。実はこのデータ，3 つのグループのデータが混ざった全体的な傾向です。図の右側には，グループごとに色分けをしてみました。おや，

これを見るとグループの中ではむしろ右下がりの分布をしていませんか？ 実はその通りで，グループ A は $r_A = -0.29$，グループ B は $r_B = -0.42$，グループ C は $r_C = -0.35$ と，いずれも負の相関をしているのです。にもかかわらず，全体で見ると正の相関をしている，ということもあるわけですね。

図 6.10　階層的なデータ

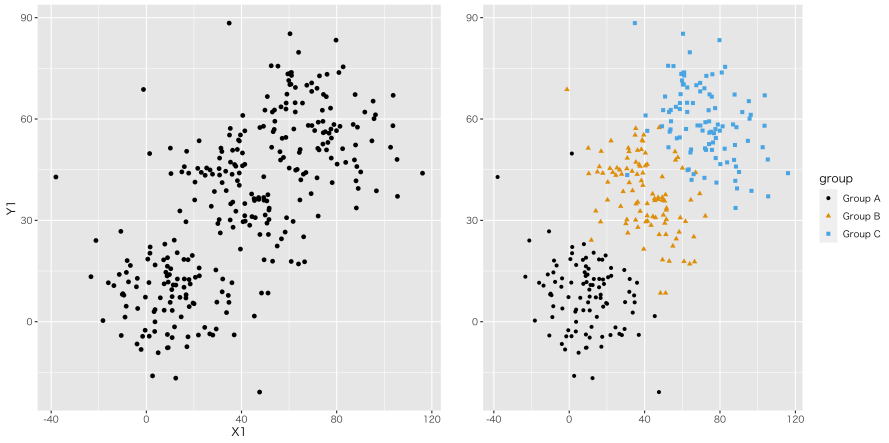

このデータ，たとえば X 軸がゲームで遊ぶ時間，Y 軸が学校の成績だったとしますと，全体で見るとゲームをすれば成績が上がる，という結論になってしまいますね。でも学校別 (グループ別) でみるとむしろ逆，ここにあるのは 3 つの学校のそもそもの成績の違いが反映されているだけでした，ということもあるわけです。このように，外的な指標で群が変わることがわかっているなら，プロットするときにその情報を加えて，このような情報の混在が生じていないかをチェックする必要があります。プロットするのは当然ですが，プロットのやり方にも注意が必要なのですね。また，群ごとの違いがわかっていなくても，潜在的に何か違うグループに分かれているのかもしれません。回答者の特性を考慮して，いくつかのクラスターに分けて分析するという手法も統計的に考えられています。データを色々な角度から見る，という姿勢は忘れてはいけません[*8]。

■疑似相関　さて，いろいろ「気をつけないといけない」相関係数の話をしてきましたが，最後にたまたま相関があるだけ，という可能性も指摘しておきます。

たとえば次の変数間には高い相関があることがわかっています[*9]。

- ニコラス・ケイジ映画出演数とプール溺死数
- マーガリン消費率とメイン州の離婚率
- 自分のベッドシーツに絡まって死んだ人の数とチーズ消費量

このように，相関があるからと言って必ず意味があるわけではありません。おそらくニコラス・ケイジ (ハリウッド俳優) が頑張って映画に出たからといって，米国でのプール溺死者数が増えるわけではないし，マーガリンを塗らなければ離婚率が下がるというものでもないでしょう。ただデータを取ると，見かけ上，相関係数が高くなってしまっただけなのです。

こうした関係のことを**疑似相関**と言います。我々は目に見えない心理学的な現象を，相関関係を手掛かりに分析していくのですが，たまたまみられる表面的な関係性を「ほらやっぱり！」と思い込んでしまわないように，慎重に考えなければなりません。

[*8] マーケティングの領域では，セグメンテーションと呼ばれることもあります。購買層のことを指します。クラスターというのは COVID-19 の関係で一般的な用語になりましたが，この言葉そのものに悪い意味はなく，塊という意味です。

[*9] 参考；http://tylervigen.com/spurious-correlations

6.7 課題

今回の課題も，以下の計算をする R スクリプトファイルを提出してもらいます。ファイル名は学籍番号と氏名を含むものとし，拡張子は.R にしてください。ただし，前回と同じファイル名にすると区別がつかないでしょうから，ファイル名の先頭に R6_をつけてください。たとえば，学籍番号が 12345678 で，氏名が山田太郎の場合は R6_12345678_yamada.R という名前になります。また，**提出するファイルはエラーのない完備な.R ファイルにしてください。**ファイル形式の間違い，出力にエラーが含まれている (未完成な) ものは返却しますので注意してください。

課題の内容は次のとおりです。

1. 2020 年度のデータを対象に，本塁打数 (HR) と安打数 (Hit) の間のピアソンの相関係数を計算し，小数点第 3 位を四捨五入して第 2 位まで報告してください。ただし，欠測値が少なくありませんので，cor 関数の引数に use = "pairwise.complete.obs"を指定してください。
2. 2020 年度のデータから，打数 (AtBats) の上位 30 人のデータを抽出し，その 30 人について，打数 (AtBats) とヒット数 (Hit) の間のスピアマンの順位相関係数を計算してください。計算結果を小数点第 3 位まで四捨五入して報告してください。
3. 2020 年度のデータから，Giants，DeNA，Dragons の 3 チームと血液型 (bloodType) のデータを抽出し，チーム変数と血液型変数をともに Factor 型に変換したうえで，上記の 2 変数を用いてクロス集計表を作成するコードを書いてください。
4. 課題 3 で作成したクロス集計表を用いて，チームと血液型の独立性に関する χ^2 値を計算してください。
5. 課題 4 で得られたカイ二乗値を用いて，クラメールの V を計算してください。

第 7 章

回帰分析の基礎

ここまで記述統計による記述と可視化，相関関係について学んできました。

ここまでは与えられたデータを受動的に見て考える，という話でしたが，ここからはデータに対して能動的に働きかけ，分析者の考えがデータに合致しているかを見ていくことにします。我々はデータに対して，「関係がありそうだ」と思ったら，「こうすればこうなる，という関係があるんじゃないか」と推論しますよね。その推論・私たちの考えを**仮説 (hypothesis)** とか**モデル (model)** といいます。ここからは，モデルをデータに当てはめるという考え方でいきましょう。

科学の目的の 1 つは予測と制御です[*1]。個々のデータには誤差 (個人差) が含まれますが，全体的にはなんらかの傾向があるだろうと考え，そのなんらかの傾向をモデルで表現します。このモデルを数式で書くことで予測ができ，予測ができるのであれば対応を考えることができる，という流れです。

本講義のテーマである「見えないものを見るための心理統計」は，ここからいよいよ，**データを通じて全体的な傾向を見つける**という意味で展開していくことになります。

7.1　相関関係とモデル

モデルとか傾向を予測するというと，なんだか複雑な話だと思われるかもしれませんが，全然そんなことはありません。

たとえばみなさんよく気になる「成績」を例に考えてみましょう。たとえば表 7.1 のように，1 週間の勉強時間と期末テストの点数がデータとして手に入ったとします。

勉強時間は 1 週間あたりの時間数，テストの点数は 100 点満点です。仮想データですが，2 つの変数の単位が違う例にしてあります。

さて，データは可視化するのが基本です。可視化してみましょう。ここでは 2 つの変数の関係を見たいので，X 軸に勉強時間を，Y 軸にテストの点数をとった**散布図 (scatter plot)** が適しています。図 7.1 に散布図を書いてみました。

散布図を見ると，データからなんらかの傾向が見えてきますよね。左下から右上にかけて，点が散らばっているのがわかります。そう，このデータには**正の相関関係**がありそうだということがわかります。

もちろん，**相関関係**があることが，すぐに**因果関係**があることを意味するわけではありません (後述)。が，今回の場合は，勉強はテストより時間的に先行しますし，どちらも学習への取り組みを反映しているものとして理解ができそうです。ということで，この相関関係から予測することは (理論的，あるいは社会通念的にも) 妥当ですから，私たちは「あの人はよく勉強していた」ときくと「その人はきっとテストの点も高いんだろうな」と

[*1] もう 1 つは「説明する」です。

表 7.1　勉強時間とテストの点数の例

学生 ID	1 週間の勉強時間	期末テストの点数
A	6	47
B	9	51
C	7	58
D	13	55
E	20	85
F	10	63
G	16	67
H	8	60
I	12	64
J	22	89
K	18	78
L	25	80
M	19	70
N	24	92
O	15	72
平均	14.93	68.73

図 7.1　散布図を見てみよう

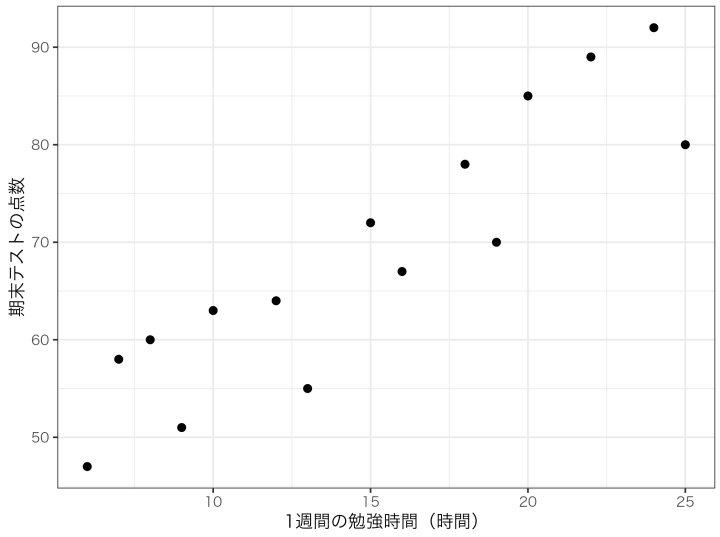

自然と考える＝予測するわけです。

予測は因果を仮定しなくても可能です。たとえば町の消防署の数と火災発生件数は高い相関係数を持ちますが，ここから消防署が火災発生の原因だ，と考える人はいないでしょう。でもデータで相関関係が示されていることがわかれば，ある町の消防署の数が多いと聞くと，火災の多い町なのかな，と予測することはできるのです。また，相関関係だけが予測のツールではありません。相関関係は変数の直線的な関係を表しているに過ぎませんから，直線的でない現象に対しては相関係数は低くなります。たとえば，血圧が高過ぎたり低過ぎたりすると，その人は不健康だなという予測はできるわけですから (前回の議論を参照してください)。

こうした注意は必要ですが，今回のデータは散布図 (図 7.1) からわかるように，相関関係も高く直線的な関係がありそうだ，ということになります。この直線的な関係を，**関数 (function)** で表すことを考えたいのです。

データが数字で得られていると，変数間関係を関数で表現できます。関数は一般的に次のように書きます。

$$y = f(x)$$

これは，x になんらかの数字が入ると，関数 f でなんらかの加工がなされて，結果としての数字が y になる，という意味ですね。心理学が科学であるとはすなわち，数学的現象主義でアプローチすること，変数間関係を関数で表現するということです。この関数が**モデル (model)** です。モデルとは「抽象化された理想的なもの」という意味ですが，科学においては数学的な関数のことをモデルというのです。もちろんこのモデル，つまり関数の形がどんなものなのかは，現象によってさまざまなものが考えられます。

ところで今回のデータは左下から右上にかけて，直線的な関係があるように思えます。直線的な関数は，みなさんすでに中学校の数学で学んだことがあると思います。直線的な関数は次のように表現できますよね。

$$y = ax + b$$

これこそ心理学で最もよく使われている，**線形関数 (linear function)** です。なぁんだ！と思いませんか。みなさんは多項式，二次式，三角関数など色々な関数を学んできたと思いますが，ここで使うのはただの $y = ax + b$ なんです。

ただし，中学校で学んだような一次式とちょっと違うところもあります。中学校の一次関数は，たとえば「ある 2 点 P,Q を通る一次関数の切片 b と傾き a を求めよ」，なんて話だったかと思いますが，今回のこの散布図にはご覧の通り，点は複数あってどこか二点を選んで線を引くわけではありません。しかも，全部の点を通るような直線はないのです。

図 7.2　線を引くのも難しい

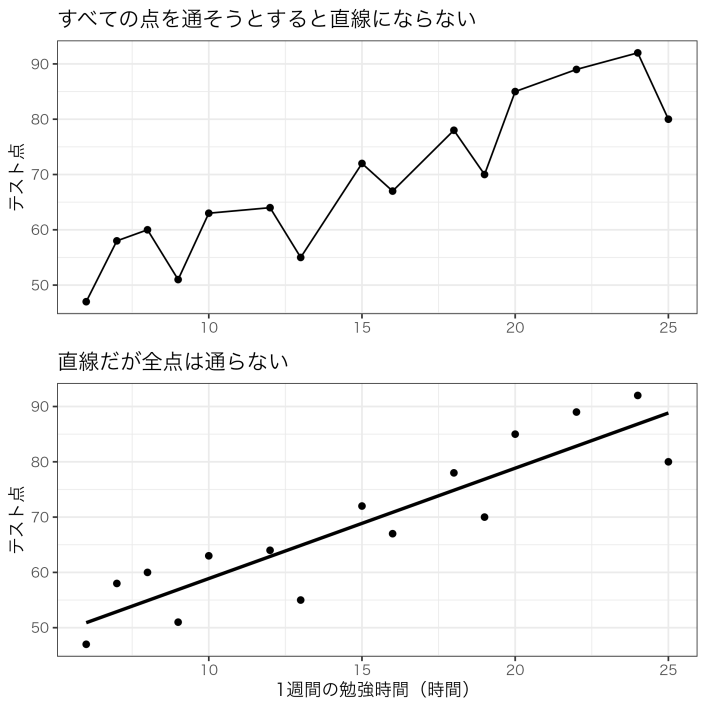

図 7.2 の上の図は，すべての点を通る線を引いてみたのですが，当然直線にはなりません。下の図は直線ではありますが，すべての点を通っているわけではありません。しかし，目指すのは下のような直線です。すべてを説明することはできませんが，だいたい当てはまっている，そういう関係を探そうというわけです。データには誤差や個人差がありますから，そのせいで直線関係が当てはまらないところがありますが，それらを除外して理想的な関係を考えれば直線なんじゃないか，というのがここでの課題になります。

線形関数は傾き a と切片 b が変われば，色々な直線を引くことができます。ここでの狙いは**データに最も当てはまりがよい直線関係を引く**ということになります。

少し余談ですが，データが直線関係にない場合や，データになるべくぴったり当てはめることを目的にすると，直線であるという縛りを捨てる必要があります。それは**非線形関数 (non-linear function)** と呼ばれ，AI(人工知能) や機械学習と呼ばれているのはこの非線形関数を使ってデータの予測精度を上げていくものです。ですが，非線形関数は n 次多項式になりますから，何が何やら意味がわかりません。意味がわからなくてもデータに当てはまればいいんだ，と言われたらそういうこともあるか，と思いますが，心理学のような学術的アプローチは人間一般に通じる理論が欲しいのですから，説明できない関数は不要なのです。なので，データにぴったり当てはまるとはいかないけれども，線形で大体説明できるところを探そうじゃないか，というわけです。

7.2 予測と線形モデル

それでは具体的に，目に見えない理想的な線形関係 $y = ax + b$ を探していきましょう。

ここで改めて，記号の表記やデータとの対応を丁寧に考えてみたいと思います。確かに中学数学でやるような $y = ax + b$ の関数は見つかりませんが，今回はたくさんのデータ点があります。図 7.1 の各点は，表 7.1 の各行に対応しています。このグラフの中の点が持つ座標は，データの値なのですから，たとえば右上の方にある点は N さんの $(24, 92)$ というデータの組み合わせになります。このように x, y の組み合わせがたくさんあるので，座標点は (x_i, y_i) のように書くべきですね。この y_i は説明される側の変数ですから，**被説明変数 (predicted variable)**，あるいは**従属変数 (dependent variable)** といい，x_i は説明する側の変数ですから**説明変数 (predictor variables)**，あるいは**独立変数 (independent variables)** ということがあります。

さてこれを踏まえて，求める式を次のように表します。

$$\hat{y_i} = b_0 + b_1 x_i$$

ここで $\hat{y_i}$ の y の上についている記号は「ハット」といいます。関数がぴったりと当てはまるわけではないのですから，y_i と書くわけにはいかなかったのです。あくまでも理論的な**予測値 (predicted value)** ですよ，ということを表すための記号がハットです。また，a の代わりに b_1，b のかわりに b_0 としました。a とか b はただの記号ですので他のどんな文字でもいいのですが，「1 つ目の説明変数についてくる係数」という意味で b_1 にしました[*2]。この 1 は 1 つ目の変数，という意味です。切片は説明変数を持ちませんから，0 番目にしたということです。今はまだ b_0, b_1 の値がわかりませんが，これがわかれば，x_i のところに適当な数字を入れることで，変数 y の値はこれぐらいなんじゃないか，という予測ができるともいえます。

このようにして引かれた直線 $\hat{y}$ は，線形結合で表された関数 $b_0 + b_1 x_i$ の解の集合です。b_0, b_1 の値はわからないので今からそれを探しに行くわけですが，x_i, y_i の組み合わせはデータとしてわかっているのでした。たとえば J さんのデータ，記号でいうなら x_{10}, y_{10} ですが，それはそれぞれ $x_{10} = 22, y_{10} = 89$ となり

[*2] なんで b なんだ a でもいいじゃないか，と言われたら返す言葉もないのですが，慣例的に b で係数を表しています。ちなみに今はアルファベットの b ですが，後期になると b のギリシア文字 β に変わります。ギリシア文字で表現するのは推測統計学的な推定に関わるようになってからです。

ます。しかし $\hat{y_{10}}$ は実際のデータのずいぶん下の方にあります (図 7.3)。これは J さんについてはこの関数の予測が外れていることを意味しますね。この外れている大きさを**誤差 (error)** あるいは**残差 (residuals)** といい，記号 e_i で表します。残差の記号 e に個人の違いを表す添字 i がついていることからわかるように，残差はすべてのデータについて生じます。

図 7.3　データと予測値と誤差の関係

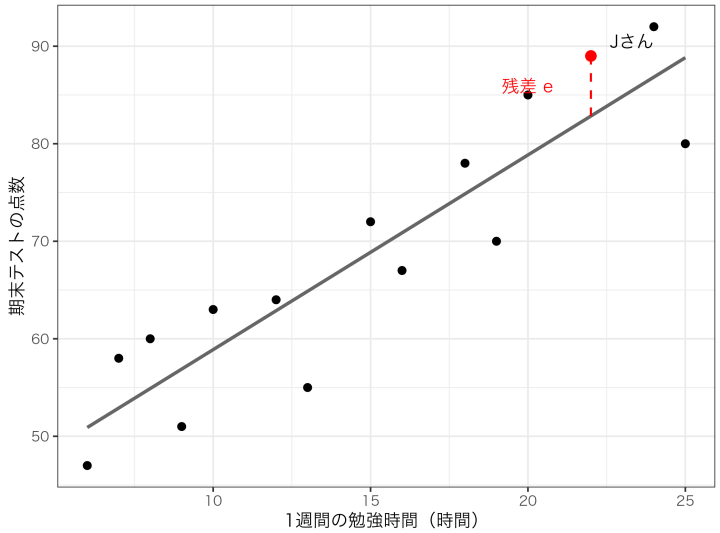

残差は次のように定義されます。

$$e_i = y_i - \hat{y_i}$$

予測値 $\hat{y_i}$ と実測値 y_i の差分が誤差 e_i だ，というわけですね。この式は次のように展開できます。

$$y_i = \hat{y_i} + e_i = b_0 + b_1 x_i + e_i$$

ここで左辺がデータ (実測値) になりました。モデルからデータを予測する式ができたわけです。

これで表記上の準備ができました。あとは b_0, b_1 の値を求めるだけです。b_0 は直線がどこから始まるかという基準となる高さを表しますし，b_1 は直線の角度，傾きを表すものです。この 2 つが決まっていないということは，どのような直線でも引くことができてしまうということでもあります。全部のデータ点にピッタリ合うような線を見つけることができないのですから，全体的に一番いい感じの線にしたいのですが，この「全体的に一番いい感じ」を数学的にどう言い表せば良いでしょうか？

7.3 最小二乗法

図 7.4 の上に，直線 A,B という 2 つの線を試しに引いてみました。直線 A のようなモデルだと，ある点は通っている＝あるデータ点については予測が実際の値に一致しているのですが，他のデータ点はすべて線 (予測値の集まり) の下方向，つまり予測値が全部実際より大きい方向にズレていることになります。逆に B のモデルだと実際のデータ点はひとつを除いてすべてモデル直線 (予測値の集まり) の上方向にあります。つまり予測値は全部低すぎるので，これも全体としてのズレは大きいと言わざるを得ないでしょう。

いいモデル式というのは，すべてのデータ点にフィットすることはない代わりに，プラスにもマイナスにも，均等にズレているものだということです (図 7.4)。個別には誤差がゼロにならないけど，全体としてはちょうど中庸のラインを通るように，切片と傾きを定めるのが良いようです。これを数式的に考えてみましょう。個別の誤差は次のように表現できるのでした。

図 7.4 考えうる色々な予測の線

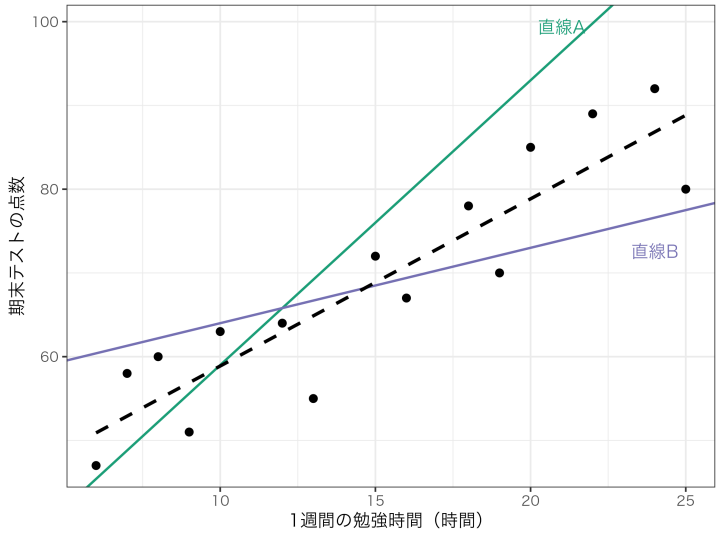

$$e_i = y_i - \hat{y}_i$$

これが全体的に真ん中を通るようにしたいわけです。全体的に，というのは言い換えると誤差を総和した時であり，真ん中を通るというのはプラスにもマイナスにも同じだけ，つまり合わせてゼロになるのが目標です。

$$\sum_{i=1}^{N} e_i = 0$$

これが目標なのですが，これは平均するとゼロになるということと同じで，誤差がどれぐらいの大きさだったのかがわかりません。誤差をなるべく小さくするような直線を求めているのですが，誤差の大きさが評価できないのでは困ります。

誤差は位置よりも (中心はゼロですから)，幅が重要です。位置ではなく幅でその大きさを評価するのです。幅，すなわち散らばりを表す指標を考えるには，分散の時のようにこれを二乗した値を考えます。

$$\sum_{i=1}^{N} e_i^2 = \sum_{i=1}^{N} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{N} (y_i - (b_0 + b_1 x_i))^2 = Q(b_0, b_1)$$

この式の最後にあるように，最終的には未知数 b_0 と b_1 の関数が出てきます。これを Q とあらわし，この Q が最小値を取るように b_0, b_1 を求める，という条件で方程式を解いていけば良いことになります。

最後に出てきたこの関数，仮に Q としてありますが，これは切片 b_0 や傾き b_1 の取り方で変わる量ですが，二乗の関数ですので極値を求めることができます。関数の極値を求めるためには微分が必要で，しかも今回は 2 変数の微分ですから偏微分という手法が必要になります。この手法について詳しくは小杉 (2018) や西内 (2017) などを参考にしていただければと思いますが，この授業の範疇を超えるのでここでは細かい計算については割愛します。

このように誤差を最小にするようにデータにモデルをフィットさせる方法，あるいは誤差を最小にするという基準で未知数を推定する方法とも言えますが，この方法のことを**最小二乗法 (least squares method)** と呼ぶということを知っておいてください。この方法を考え出したのが，正規分布を導出したガウスさんなんですね。すごいですねえ。

最小二乗法で係数を求めるのは，具体的には次のような計算式になります。

$$b_0 = \bar{y} - b_1 \bar{x}$$

$$b_1 = r_{xy} \frac{s_y}{s_x}$$

ここで r_{xy} は変数 x, y の相関係数，s_x, s_y はそれぞれ x と y の標準偏差，$\bar{x}, \bar{y}$ はそれぞれ x と y の平均値です。いかがですか！すべてデータから計算できる記述統計量で，切片と傾きを求めることができました。もちろん具体的に数字を入れて計算していってもいいのですが，実際には統計環境 R など統計パッケージを使えば一瞬で答えを出してくれます。計算過程を理解しておくことも重要なのですが，まずはデータと条件から解が求められることを理解し，どのような条件，どういう基準で何を求めたのかをしっかり確認しておいてください。

数値例でみてみましょう。表 7.1 のデータから計算される記述統計量は，まず $r_{xy} = 0.905605, s_x = 6.261751, s_y = 13.802001$ を計算して，傾きを求めます。

$$b_1 = 0.905605 \times \frac{13.802001}{6.261751} = 1.99611$$

次にこの b_1 と $\bar{x} = 14.9333, \bar{y} = 68.7333$ を使って，切片を求めます。

$$b_0 = 68.7333 - 1.99611 \times 14.9333 = 38.92470$$

つまり，予測式は次のようにすれば誤差を最小にした，言い換えればすべてのデータ点から満遍なく隔たった直線が引けるということです。

$$\hat{y}_i = 38.92470 + 1.99611 x_i$$

この分析方法のことをとくに**回帰分析 (regression analysis)** といいます。今回は変数 X から変数 Y を予測する関数，$y = f(x)$ を作りましたが，同じデータを使って変数 Y から変数 X を予測する関数，$x = g(y)$ を考えて係数を求めることができます。この関数を交互に使って，$y^1 = f(x) \to x^1 = g(y^1) \to y^2 = f(x^1) \to x^2 = g(y^2) \to \cdots$ と続けて行くと，最終的に x^n は変数 X の平均値に，y^n は変数 Y の平均値に近づいて行きます。このように回って回って平均に帰って行くので，**回帰**という名前になっています[*3]。回帰分析によって得られた係数のことを**回帰係数 (regression coefficients)** ともいいます。

ここで回帰係数の切片項，b_0 は何かというと，$x = 0$ の時の値になります。今回の例でいうと，勉強時間が 0 時間だったらテストで何点取れるか，ということですね。つまりこれはベースラインだといえます。では傾きを表す b_1 は何でしょうか。これは x の変数が 1 上がった時の，$\hat{y}$ の上昇率を表しています。今回の例では，勉強時間が 1 時間長い人はテストの点が平均的にどれぐらい高いと予想されるか，ということですね。

7.4 残差と決定係数

さて，ともかくこうして回帰係数を求めることができました。これはとても嬉しいことですね！嬉しいことですよ！だってデータから関数関係がわかったのですから。関数関係がわかるということは，$y = f(x)$ の x に数字を入れれば y の値がわかるということです。実際のデータ x_i をいれると $\hat{y}_i$ がわかります。これを見るこ

[*3] 親の身長から子供の身長を予測することを考えてみてください。次にその子が親になって，その子がまた親になって･･･というときに，「背の高い親からは背の高い子しかうまれない」というルールであれば，世界はものすごく高身長なひとと低身長な人に二分されてしまいます。そうではないということは，背の高い親から背の低い子が生まれることもあるし，その逆もあるということです。また野球選手などでルーキーのときは成績がいいのに，2 年目になったら成績が下がる，というのは 2 年目のジンクスなどといわれますが，その人の平均的な能力以上のスコアが出た次の年に，平均的な値に帰るために低くなりがちなことは，当然ありえることでもあるのです。こうした効果のことを回帰効果といいます。

とで，そのデータ点がどの程度モデルから外れているかということがわかります。誤差の大きさを量的に見積もれるわけです。さらに，もちろん，未来が予測できますね！実際のデータではなく，新しい数字を入れれば予測値が出てくるわけです。たとえば今回の例で言えば「1 週間の勉強時間が 15 時間だった」とすれば，テストの点数は $38.92470 + 15 \times 1.99611 = 68.87$ と計算できます。実際にテストを受ける前から，これぐらい勉強すればこれぐらいの点をとるだろう，ということが事前にわかるということです。素敵！

実は，BIG データだとか，AI だとかで騒いでいる話の基本は，これのことなのです。数式に入れるデータが大量であること，複数の予測変数を使うことなど，このモデルを拡張していく必要はありますが，基本はこのような「モデルをデータに当てはめて予測する」というところにあるわけです。今回はその最も単純な形，すなわち一次関数・線形モデルでしたが，人間の行動，市場の動向，あるいは次のレースで勝つ馬はどれか，なんてこともモデルを複雑にしつつ予測して行くことができるのです。

ただここで注意しておいてもらいたいのは，このように計算ができることと予測が当たることは別だ，ということです。本当に勉強時間 15 時間のひとが，テストで 68.87 点になるかどうかはわかりません。なぜなら，今回のこの係数は得られたデータに最もフィットした形で算出しましたが，それでもすべての点に合致しているわけでなく，一番当てはまりの程度がマシだ，というだけであり，実際には必ず予測できない残りの部分，すなわち**残差 (residuals)** があるからです。

このように，モデルをデータに当てはめて分析する時は，その当てはまりの程度を別途評価しなければなりません。この評価の指標のことを**適合度 (fit index)** といいます。回帰分析の場合，予測値は $\hat{y}_i$ であり，実際のデータは y_i です。両者の関係は $y_i - \hat{y}_i = e_i$ でしたね。予測値と実際のデータがどれぐらい近いかを表すために，この 2 つの相関係数 $r_{\hat{y}y}$ を考えることにします。相関係数ですから，この数字は $-1 \leq r_{\hat{y}y} \leq 1$ の範囲内に収まるのですが，負の相関であっても相関が高ければある意味合致はしているのですから，ここでの符号にはそれほど興味がありません。そこでこの相関係数を二乗してしまいましょう。この $r_{\hat{y}y}^2$ のことを，R^2 **値 (R-squared)** と言い，適合の指標と考えます。R^2 **値**は別名**決定係数 (coefficient of determination)** ともいいます。

この R^2 値は，計算すると次の関係にあることがわかります[*4]。

$$R^2 = \frac{s_{\hat{y}}^2}{s_y^2}$$

言葉でいうと，**被予測変数の分散中に占める予測値の分散の割合**ですね。つまり，この予測モデルが予測される変数の情報のうち，何 % を説明したかがわかるわけです。

今回のデータについていうと，$R^2 = 0.820$ でした。予測モデルで 82% ぐらいは説明するので，まあまあ良いモデルだったと言えるかもしれません。論文などで回帰分析について書かれている場合は，この R^2 あるいは類する適合度指標をよく見るようにしましょう。結果は出ても，説明率がうんと低ければ，実質的になんの説明もできていない，予測にはまったく役立たないということでもあるのですから。

7.5 相関関係と因果関係

回帰分析をすると「勉強時間が長いひとは，テストの点も高い」「勉強時間が 1 時間長くなると，テストの点も平均 2 点高くなる」ということがわかるのでした。

さて，細かいことをいうようですが，次の二つの文の違いを見比べてください。

- 勉強時間が 1 時間長いと，テストの点も平均 2 点高い

[*4] 細かい計算式については，小杉 (2018)の Pp.133 をみてください。

- 勉強時間を 1 時間増やすと，テストの点も平均 2 点上がる

ほとんど同じことを言ってるわけですが，日本語としては**高い**と**上がる**という違いがあります。一方は状態・事実の記述ですが，他方は動き・変化の記述です。実は，この二つを混同するのは良くないのです。

後者の方，変化を記述するのであれば「A さんが頑張って勉強時間を 1 時間増やしたら，A さんが増やさなかった時と比べてテストの点が上がった」ということになりますが，「頑張らずに勉強時間を増やさなかった A さん」はこの世に存在しないわけです (反実仮想といいます)。今回の回帰係数に使ったデータ点はすべて異なる人で，ある人の変化を表したのではなく，全体の傾向を記述したに過ぎません。このように，全体傾向の記述を個人の理解にするのは誤解を招く恐れがあります。

これは**相関関係 (correlation)** と**因果関係 (causal relationship)** を取り違えている，ともいえます。良くある間違い，ミスリーディングなのですが，この両者は違うものであるということをしっかり理解しなければなりません。

変数間に相関関係があると，我々は色々なことを推察できます。そういう意味で，相関関係は研究のスタートにもなる重要な指標です。たとえば身長と体重といった生理的な指標は相関することが一般的ですから，「新しいクラスメイトは身長が 185cm だって」という情報を得たら，まさか体重が 50kg を切っているだろうなんてことは想像しませんね (実際あり得るかも知れないのに)。このように，変数間関係があるということは，一方が決まれば他方が決まる，いわゆる関数関係をイメージしがちなわけです。

ただし，**相関関係 (correlational relationships)** があるということと，**因果関係 (causal relationships)** があるということは別です。たとえば，デスクの上が散らかっている人ほど出世しない，というような話がありますが[*5]，これを聞いて「デスクをきれいにすれば出世する」と言えるでしょうか?実証的なデータに基づいた仮説だったとしましょう。元になるデータは，デスクがきれいな人ときれいではない人をたくさん集めてきて，出世の程度と比べるわけです。出世の程度というのは分かりにくいので，年収でもいいですし，会長 – 社長 – 専務 – 部長 – 課長のように順序尺度水準で並べた数字でもいいとしましょう。そしてこの両者に相関関係が確かにあったとします。つまり，年収が高い人，役職が高い人ほどデスクのきれい度が高く，逆もまた真なり，というわけです。ではデスクの上をきれいにすると出世すると言えるでしょうか？答えは No です。

A と B，2 つの変数があって，相関関係にあるのは事実としましょう。すなわち 2 つの変数には何らかの関係があるとします。しかし因果関係は一方が原因，他方が結果という意味です。$A \to B$ なのか $B \to A$ なのか，相関関係だけでは分かりませんね。デスクがきれいから出世したのか，出世したから (秘書がつくなどして) デスクがきれいになったのか，わからないからです。このように，相関関係と因果関係では前者の方が縛りが緩く (関係があると言ってるだけ)，後者の方はそれに加えてさらに色々な条件を検証しなければなりません。

マスコミなどの報道には，浅慮なのか故意なのかわかりませんが，この手のミスリーディング事例には事欠きません。「お人好しほど収入が少ない[*6]」とか「テレビの暴力シーンを見ると子供が凶暴化する[*7]」といった，相関を因果にすり替えて議論してしまっている例が見られます。先日のテレビで[*8]，「孤独感がある」と答えた人の割合と，「1 日のスマホの使用時間」との関係が示されていました。それによると，スマホの利用時間が 1 時間未満の人の孤独感があるというひとは 35.3% であったのに対し，利用時間が 8 時間以上の人は 53.1% にまでのぼり，「スマホを使う時間が長い人ほど孤独を感じてしまうようです」とまとめられていました。おかし

[*5] 金田博之 (2020) デスクが汚い人は出世できない！ 3 つの視点,https://ameblo.jp/dolphin55/entry-12589304622.html.2022 年 2 月 18 日アクセス

[*6] ライブドアニュース (2011) 研究結果：お人好しほど収入は少なくなる https://news.livedoor.com/article/detail/6103564/.2022 年 2 月 18 日アクセス.

[*7] 朝日新聞 (1999) 暴力 TV，子供に影響/なぐる・けると相関/小中学生を総務庁調査,1999.10.31.

[*8] 2025 年 5 月 14 日 am5:59，TBS の THE Time という番組でした。

くないですか。孤独を感じるからスマホを使う時間が伸びる，ということのほうがよくある話じゃないですかねえ。

他にもたとえば，マイナスイオンを謳った商品などがありますが，あれも「滝など自然の環境にはマイナスイオンが多い。そこで人は緊張がほぐれ，リラックスしている」ことから「マイナスイオンを撒き散らせばリラックスする」という因果の向きをねじ込んで根拠としています。たとえば，町の消防車の数と火災発生件数に相関があったとして，消防車が増えると火災が増える，消防署は火をつけて回っているのだと考えるのはおかしな話だ，というのは誰でもわかると思うのですが。

相関関係以上に深い関係である，因果関係をいうためには，他にも条件が必要です。それらをまとめると次のようになります。原因変数を A, 結果変数を B とすると，

- A が先，B が後に生じていなければならない (時間的先行性)。
- 原因とされる変数が他の多くの変数の原因になっていない。すなわち，$A \to B, A \to C, A \to D \cdots$ のようになっていない (ex. 朝ごはんを食べたから犯罪を犯した，とは言えない)。
- A,B の両方に共通する別の原因 Z，すなわち $Z \to A, Z \to B$ が存在しない (ex. 親が暴力映像が好きで，わんぱくな子供に育てたかった，という共通要因の存在)。

といったことも考えなければなりません[*9]。図 7.5 に「暴力映像を見ると子供が暴力的になる」という因果関係を主張するときに，考えるべき影響力の例を挙げてみました。背後の変数 (教育変数)，媒介変数 (子供の性格)，逆向きの因果などの関係がすべて否定されて，初めて暴力映像を見たことが暴力行為の原因である，と言えるのです。

図 7.5 因果を特定するのは難しい。点線のパスがないことを確認しなければならない。

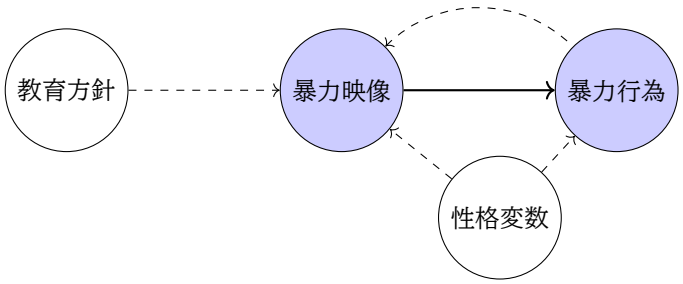

心理学で扱う多くのことは，相関関係にあって因果関係まで特定できることが少ないでしょう。ですから因果関係を考えるときには，他の原因変数がないか，因果の向きが逆ではないかということは常に意識しておかなければなりません。ある結果 R にたどり着くルートが $A \to R, B \to R, C \to R \ldots$ とあるのに，A だけが原因だと言ってしまうのも問題ですし，もっと強く影響を与えている変数を見逃していることにもなりかねません。また「暴力映像が好きだから暴力的になった」のか，「暴力的だから暴力映画も好きだ」となったのかはわからない，あるいはどちらともあり得る話なのです。また，北野武が記者に『暴力映画の影響で実際に暴力行為に出る人間も居ると思いますが，その点についてどう思われますか？』と聞かれたときに『じゃあ，何でおなみだ頂戴の良い話だらけなのに，一向に世の中は良くならねえんだよ』と聞き返した，という逸話があります。このように，ほかの可能性，逆の可能性を考えることが本質に迫る重要なポイントになるのです。研究を深めるためにも，**批判的思考 (critical thinking)** の癖をつけておきましょう[*10]。

[*9] 事象から因果関係を主張するにはどうすればよいか，というのは哲学的な問題で，J.S.Mill や D.Hume などの思索が有名ですので，色々考えてみてください。また統計的に因果を推論する方法について，近年はさまざまな技術が開発されており，統計的にも因果関係はホットなトピックスです。

[*10] 批判というと否定したり，貶めたり，論破したりすることだと勘違いしている人が少なくありませんが，疑ってよく考えようという意

7.6 課題

■回帰係数を求めてみよう 表 7.1 のデータを使って，逆に期末テストの点数から 1 週間の勉強時間を予想する回帰分析を行なった時，その切片と傾きはいくらになるか計算してみてください。なお，テストの点数から勉強時間を予測するのですから，因果の向き (時間の向き) は逆転しています。これで因果関係がわかることはないのですが，データから相関関係があれば回帰はできるのであり，それをどういう意味で使うか，伝えるかは使う側の人の問題だということを忘れないでください。

味です。そうすると人を疑うなんて！と嫌がる人もいるかもしれませんが，疑うという行為は「よく知ろう」という行為であって，無条件に信じるというのは「考えたくない，知りたくない」ということでもあるのです。漫画「ライアー・ゲーム」にもこのようなセリフが出てきますよ。

第 8 章

重回帰分析

前回は**回帰分析**というタイトルで，データの相関関係を元に予測モデルを作るということをしたのでした。予測と制御は科学の基本ですから，それができるとなったら素敵なことです。ただし，我々が使うデータは人間を対象にしているので，誤差がたくさん含まれていますから理論モデルのようにぴったりフィットすることはありません。それでも大まかに線形関数が成り立つのであれば (直線の分布をしてそうならば)，有用なことは多いのだという話をしました。

今回は前回のモデルを少し複雑にしていきます。前回は $y = b_0 + b_1 x$ で，説明される変数 y に対して説明する変数 x がひとつだけ，という簡単なモデルでした。今回は説明する変数が 2 つ以上のモデルを考えます。

8.1 重回帰分析の基本

説明変数が複数に増えた場合の回帰分析は，**重回帰分析 (multiple regression analysis)** と言います[*1]。説明変数が $x_1, x_2 \cdots x_m$ と増えますので，係数もそれに応じて $b_1, b_2, \cdots, b_m$ とつきます。切片は b_0 ひとつで変わりません。これを式で表すと次のようになります。

$$\hat{y_i} = b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_m x_{mi}$$

説明変数に x_{mi} とありますが，これは m 番目の変数についての i さんのデータということです。今示した式は予測値 $\hat{y}$ についての式ですが，実際にはこれに誤差 e_i がついて実測値 y_i になります。

$$y_i = \hat{y_i} + e_i = b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_m x_{mi} + e_i$$

一般的に書くために x_m まで用意しましたが，たとえば 2 変数であれば $y_i = b_0 + b_1 x_{1i} + b_2 x_{2i} + e_i$ となります。どこに i がついているか，どこについていないかといった細かいところまでしっかり確認してくださいね。

さて $y = b_0 + b_1 x$(あるいは懐かしい $y = ax + b$ という形でもいいですが) のときは直線になるので線形モデルという話をしました。説明変数が 2 つあると，x_1 の軸，x_2 の軸と従属変数 y の 3 つの軸からなる 3D 平面で図示することになります (図 8.1)。説明変数が 3 つ以上になると図示することはできません。しかし，抽象的・数学的なモデルとしては何の問題もありません。また，平面になってもある側面から見れば直線になっていますから，説明変数が増えても一般的に**線形回帰**あるいは**線形モデル**という名称はかわりません。

説明変数の数が増えると，回帰係数を求める計算はより複雑になります。複雑になりますが，結局のところ**最小二乗法**と同じ考え方，すなわち誤差 (の分散) が最も小さくなるように係数を定めるという基準で係数を

[*1] これに対して，説明変数が 1 つしかないモデルのことを**単回帰分析**と呼んで区別することもあります。

図 8.1　立体でも線形モデル

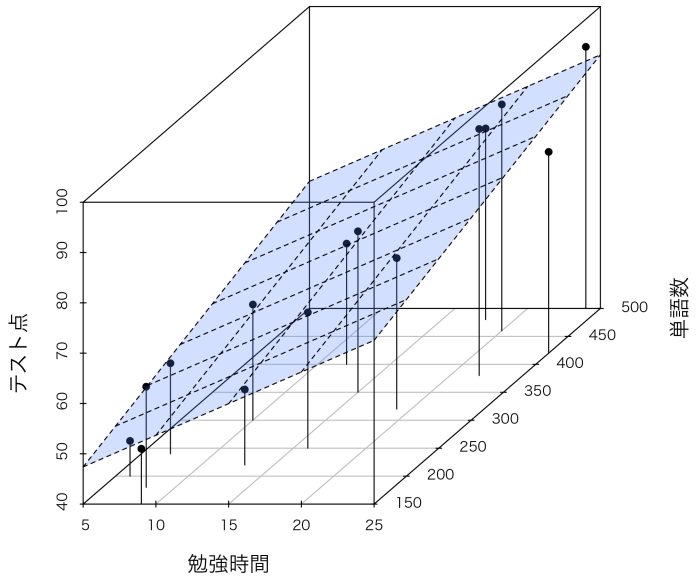

求めることができます[*2]。具体的な計算式はここで示しませんが，R を使えば単回帰分析と同じやり方で答えが出せる，ということだけ知っておいていただきたいと思います。

具体的な数値例でみてみましょう。表 8.1 には表 7.1 に一列追加したデータを用意しました。今度は 1 週間に覚えた英単語数が入っています。勉強時間と覚えた単語数が，期末テストの点数に影響している，という考え方は十分あり得そうですね。

このようなデータが得られたら，次にすることは，そう，可視化です。**データは図にする**が分析の基本だからです。

図 8.2 は 3×3 の行列にならべてデータを可視化する方法です。行に勉強時間，単語数，テスト点が，列にも勉強時間，単語数，テスト点が入っています。左上から右下にかけての対角 (セルの番地でいうと n 行 n 列目) には，データの分布を表す図が入っています。左下のほうにあるのは，2 つの変数ペアの散布図です。右上にあるのはその相関係数です。当然ながら，左下と右上には同じ情報が入っているのですが，これを可視化したものと数値化したものになっているのです。

このデータを見ると，3 つの変数の間には十分相関がありそうです。とくに，テスト点を従属変数と考えると，勉強時間とテスト点の相関が 0.906，単語数とテスト点の相関が 0.875 とあり，散布図を見てもどちらも左下から右上にかけての直線関係があるように見えます。そこで，テスト点を y，勉強時間を x_1，単語数を x_2 と考えて重回帰分析を実行してみたとします。

R でチョチョイと計算できるのですが，詳しくは次回に回すとして，結果として次のような回帰式が得られました。

$$\hat{y} = 33.433 + 1.258x_1 + 0.0511x_2$$

つまり，勉強時間を 1.258 倍し，単語数を 0.0511 倍したものに 33.433 を足せばテスト点の予測値になるのです。具体的に，たとえば勉強時間が 15 時間，単語数が 350 語の人であれば，この人は $33.433 + 1.258 \times 15 + 0.0511 \times 350 = 70.18$ ぐらいの点を取るんじゃないの，ということがわかります。

[*2] 後期に入ると，推測統計学や確率モデルの考え方を導入した，**最尤法 (maximum likelihood method)** や**ベイズ法 (Bayesian estimation method)** といった他の推定方法・推定基準が導入されますが，いずれも未知数を求める方法の一種です。

表 8.1　勉強時間・単語数・テストの点数の例

学生 ID	勉強時間	単語数	テスト点
A	6	200	47
B	9	150	51
C	7	240	58
D	13	220	55
E	20	460	85
F	10	300	63
G	16	250	67
H	8	180	60
I	12	400	64
J	22	380	89
K	18	480	78
L	25	420	80
M	19	320	70
N	24	500	92
O	15	350	72

図 8.2　変数間関係の可視化

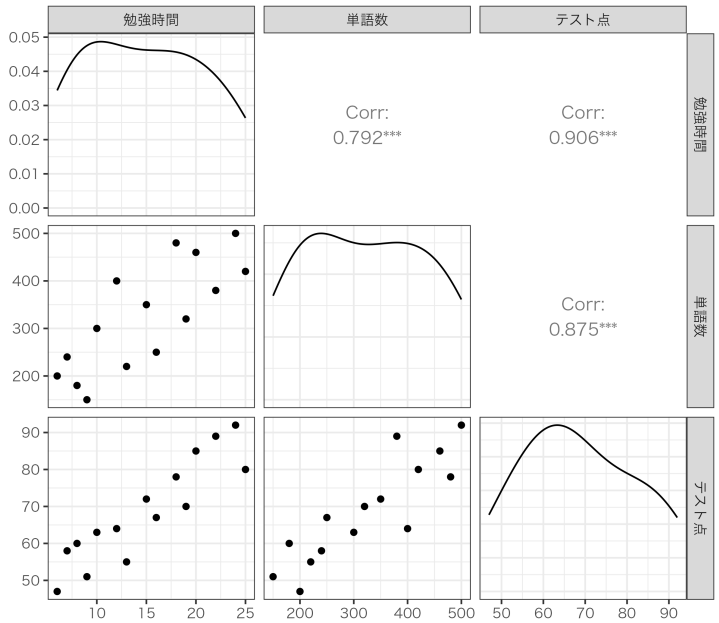

また，仮想の値ではなく今回のデータを入れると，それぞれの予測値 $\hat{y}$ と，誤差の大きさが計算できます。表 8.2 には予測値を `Yhat` 列に，誤差の大きさ (残差) を `Residuals` 列に入れてみました。

予測値と実際の従属変数との相関係数が，モデルの**適合度**を表す指標になるのでしたね。その相関係数を二乗した R^2 **値**を計算すると，今回は $R^2 = 0.887$ になります。テスト点の 8.9 割ぐらいは，勉強時間と単語数で予測できるデータだったということができます。

重回帰分析は単回帰分析と変わらず，便利な使い方ができそうだ，ということがわかってきました。ただし，

表 8.2 予測値と残差

ID	勉強	単語	テスト	Yhat	Residuals
A	6	200	47	51.20	-4.20
B	9	150	51	52.42	-1.42
C	7	240	58	54.50	3.50
D	13	220	55	61.02	-6.02
E	20	460	85	82.09	2.91
F	10	300	63	61.34	1.66
G	16	250	67	66.33	0.67
H	8	180	60	52.69	7.31
I	12	400	64	68.96	-4.96
J	22	380	89	80.52	8.48
K	18	480	78	80.59	-2.59
L	25	420	80	86.33	-6.33
M	19	320	70	73.68	-3.68
N	24	500	92	89.16	2.84
O	15	350	72	70.18	1.82

結果の解釈やそれを言葉にする時は，ちょっと注意が必要です。まず言葉上の注意ですが，重回帰分析の回帰係数はとくに**偏回帰係数**といいます。「偏」という字がつくのですが，この一文字が曲者です。

単回帰の時，傾きを表す係数 b_1 は説明変数 x_1 が一単位上昇した時の，従属変数 y の伸び率を表しているのでした。傾きってそういうことですよね。たとえば前回の例で言えば，$\hat{y} = 38.92 + 1.996x$ でしたから，勉強時間が 1 時間増えればテスト点は 2 点上がるぞ，というようなことが言えたわけです。

今回は $\hat{y} = 33.433 + 1.258x_1 + 0.0511x_2$ ですから，「勉強時間が 1 時間増えればテスト点は 1.258 上がるし，単語を 1 語多く覚えればテスト点は 0.0511 上がるぞ」と言いたいところです。がちょっと注意して欲しいのは，「勉強時間が 1 時間増えれば」「単語を 1 語多く覚えれば」という言い方です。この 2 つはまったく独立に効果が出ているようですが，図 8.1 を思い出せばわかるように，重回帰分析の場合の説明関数は面になっているということです。面の場合，x_1 が 1 ポイント上がるというのは，x_1 軸の方に水平移動するイメージですが，その時 x_2 は変化していません。x_2 が 1 ポイントあがるというのは，x_2 軸の方に水平移動するイメージですが，その時 x_1 は変化していないのです。

ところで，元のデータを図示した図 8.2 をみてください。勉強時間と単語数，つまり x_1 と x_2 の間には相関がありますね ($r = 0.792$)。ということは，x_1 が動くと x_2 もつられて動きます。データの空間上は斜めに動いているようなものです。であれば一概に，「勉強時間が 1 時間増えれば･･･」ということはできません。重回帰分析の場合の回帰係数が表しているのは，「単語数が同じであれば，勉強時間が 1 時間増えれば 1.258 点上がる」という条件つきの係数だったのです。この点，注意が必要ですのでもう少し詳しく読みといていきましょう。

8.2 部分相関・偏相関・偏回帰係数

先ほどの表 8.2 から散布図を書いた図 8.3 をみてください。

お気づきでしょうか。これを見ると，相関係数がきれいに $r = 0.0$ になっている箇所がありますね。そうで

図 8.3　予測値や残差を含んだ散布図

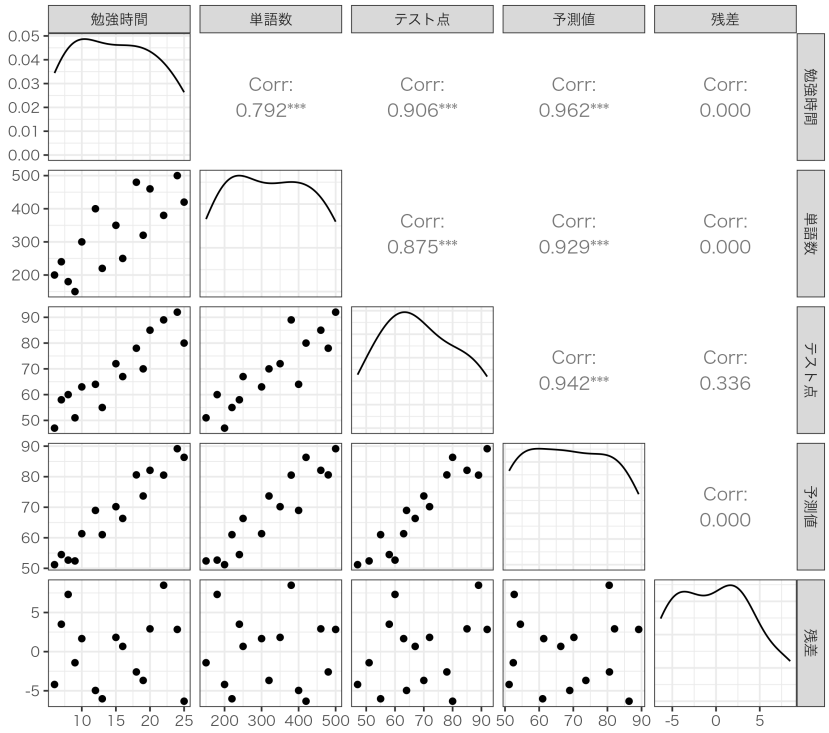

す，残差 e_i と 2 つの説明変数 x_1, x_2，および残差 e と予測値 $\hat{y}$ のところがゼロです。これがどういう意味を持つのか考えていきます。

まず残差と説明変数の相関がないことについて。被説明変数 y を説明変数 x_1 で回帰すると，この変数で説明できるパートとできないパートに分割できます (図 8.4)。説明できないパートが残差 e となって取り出されているわけです。ここで x_1 と e に相関関係が残っているようであれば，回帰分析の改良の余地があるということになってしまいます。回帰係数は今回のデータにベストフィットするように選ばれているはずなので，原理的にここには相関があるはずないのです。図 8.4 にそのイメージを描いてみました。

図 8.4　回帰分析は被説明変数を分割する

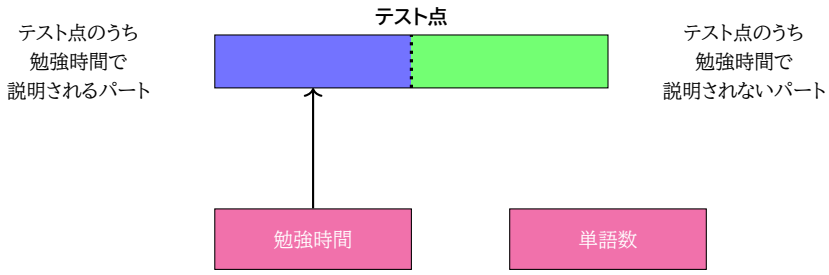

さて，この説明変数 x_1 で説明できなかった残りの部分と，もう 1 つの説明変数 x_2 について相関係数を計算できます。この相関係数のことをとくに**部分相関係数 (semi-partial correlation coefficient)** といいます。図 8.5 のイメージ図をみてもらったらわかりやすいと思います。

これは被説明変数 y である「テストの点数」を，第一の説明変数 x_1 である「勉強時間」で**統制した**，「単語数」(x_2) との部分相関係数，というように言います。統制したというのは，その変数でコントロールした，ある

図 8.5 部分相関係数

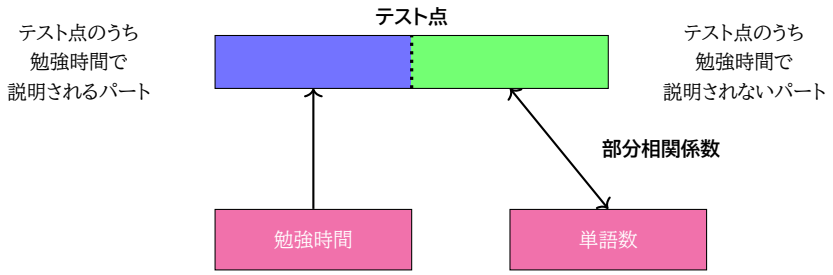

いはその変数の影響を除外した，という意味だと思ってください。なぜ影響を除外したと言えるかというと，勉強時間 (x_1) で説明できるところは説明し尽くした残りとの相関を見ているわけですから，「説明し尽くした」＝「その変数の影響を除外した」と解釈できるからです。

さらに，第一の説明変数 x_1 をつかって，第二の説明変数 x_2 を従属変数とした回帰分析をしたとします。そうすると，その残差は x_2 の中からも x_1 の影響を取り除いたものだ，ということができます。このように，勉強時間 x_1 をつかって，単語数 x_2 とテスト点 y 両方を回帰分析し，それぞれの残差の相関を求めたものを **偏相関係数 (partial correlation coefficient)** と言います。両方からある変数の影響力を取り除いた，偏りのない相関係数という意味です。図 8.6 にそのイメージ図を描いてみました。

図 8.6 偏相関係数

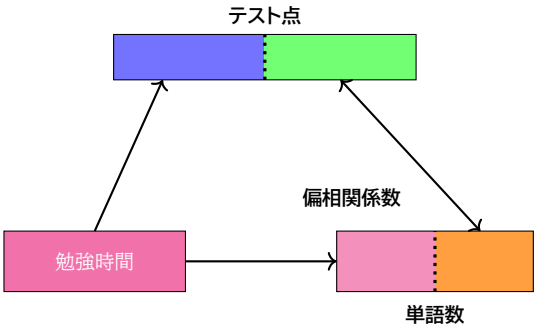

単語数にも，テスト点にも共通の「もともとの学力」といった要因がある，と考えることができますね。つまり「単語数とテスト点を純粋に比較したい」というときであっても，背後の変数の影響がどうしても残ってしまっています。でもこの方法を使うと，背後の変数の影響を取り除いた純粋な「単語数とテスト点」の関係を見ることができるようになります。これはすごいことなのです。たとえば，テストの点数は他に何で予測できるだろうか，ということを考えたとします。それに影響してくる要素の候補として，たとえば通学にかかる時間だとか，その学生がアルバイトしているかどうか，サークルに入っているかどうか，あるいはこれまで塾に通ってきたかどうか，ひいては親の収入が高かったかどうか，兄弟姉妹の数が何人か・・・などなど，考えなければいけないことは山のように出てくるでしょう。しかもこういった情報は，調査の段階で統制できるものではありません。アルバイトしているかどうかで勉強に費やせる時間が違うな，と思っても，アルバイトしている人だけ回答者を募集したり，していない人だけ募集したり，というのではコストも大変です。実験的には統制できることでも，調査の実際を考えると統制すべき変数が多すぎて制御しきれないのです。

しかしここで，考えうる諸般の事情をデータ化して回帰分析を行い，そのテスト点の残差を使うことにすると，それは諸般の事情が取り除かれたものとして扱うことができます。残差を研究することで，統制できないけどいろいろ考えなければならない効果からの影響を，綺麗に取り除くことができるともいえるのです！表 8.2

の Residuals の列には，2 つの説明変数の影響を取り除いたテスト点の情報が入っています。勉強時間や単語数は人それぞれ違いますが，それらの影響を取り除いて，テスト点はどういう違いがあるのかな，ということを考えることができるのです。

さらに，ここでは x_1 で統制された y と x_2 との相関関係を求めましたが，x_1 で x_2 を統制した残差をつかって，y を回帰することもできます (図 8.7)。実はこれが重回帰分析のときに計算されている，回帰係数になっているのです。

図 8.7　偏回帰係数

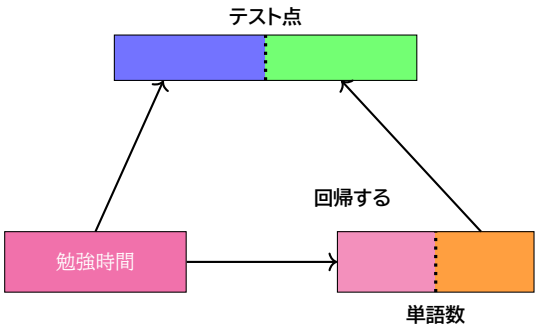

8.3　偏回帰係数と解釈

重回帰分析の回帰係数はとくに，**偏回帰係数 (partial regression coefficient)** といいます。偏という字がついているのは，相互に影響を取り除いたという意味です。前の節の最後に，回帰係数の意味は x_1, x_2 それぞれの軸に沿った水平移動をした時の上昇率だ，ということを伝えました (図 8.8)。ここで x_1 の係数を解釈するときには，x_2 が統制されている (x_2 は変化していない) ことに注意が必要です。言葉で表現するのは難しいのですが，丁寧にいうなら「単語数 (x_2) が同じだとすると，勉強時間 (x_1) が 1 時間増えるごとにテスト点 (y) は 1.258 点あがる」が正しい表現ということになります。

「なんかややこしいなあ」「何がダメなのかわかりにくい」という人もいるかと思いますので，別の例で考えてみます。大学の成績 y を予測するのに，今度はサークルにかける時間 x_1 とバイトにかける時間 x_2 というデータを集めたとします[*3]。まず，それぞれの変数で単回帰分析をしてみました。

$$\hat{y} = 2.8743 + 0.1407x_1$$

$$\hat{y} = 15.4221 - 0.5443x_2$$

なるほど，サークルをすると成績が上がる (+0.1407) のですが，バイトをすると成績が下がる (-0.5443) ようだ，という解釈ができるかと思います。

しかしここで重回帰分析をしてみます。2 つの変数を同時に予測方程式の中に入れるのです。

$$\hat{y} = 21.9910 - 0.1209x_1 - 0.5956x_2$$

おや，どちらの係数もマイナスになってしまいました。サークルをすると成績が下がるし，バイトをしても成績が下がるという結果です。サークル活動はいいんじゃなかったっけ？ なぜこのような逆転現象が起きたのでしょうか。

[*3] 説明をするための架空のデータです。

図 8.8　偏回帰係数が表す値の意味

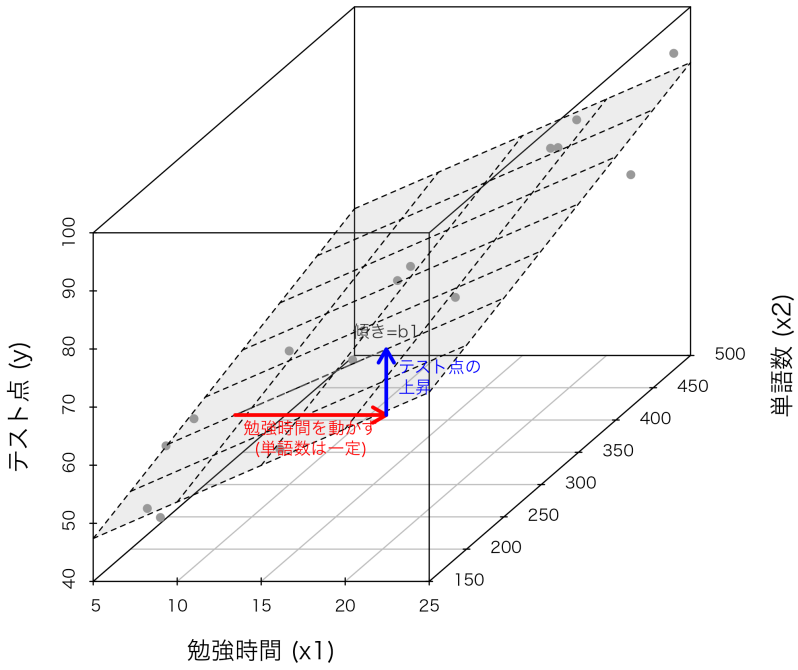

実は，このデータは x_1 と x_2 の間に相関関係があったのです ($r_{12} = -0.4360$)。サークル活動をしているとバイトしている暇がない，あるいはその逆でしょうか。いずれにせよ負の相関があることをこのように解釈できます。また，被説明変数との相関は，$r_{y1} = 0.1421, r_{y2} = -0.5529$ のようになっています。これは単回帰分析の結果と同じ傾向をしていますね。サークルに費やす時間が多い人は成績が高い，バイトの時間が長い人は成績が低い，ということがあるようです。しかし注意が必要なのは，このように $x_1 \to y$，$x_2 \to y$ という直接的な関係には，実は見えない影響が混ざっていることです。今回は x_1 と x_2 に関係がありますから，$x_1 \to x_2 \to y$ という影響力のルートがあるのです。これを**間接効果 (indirect effect)** といいます。

重回帰分析は間接効果を統制した影響を示してくれています。「サークル活動時間が多ければ成績が下がり，バイトにかける時間が多くても成績が下がる」というのではなく，「バイトにかける時間が同じであれば，サークル活動時間が多ければ成績が下がる」「サークル活動時間が同じであれば，バイトにかける時間が多いと成績は下がる」というのが正しいのです。両方が独立しているような，並列的な結論を書くのではなく，条件つきで解釈する必要があります。また，もちろん，バイト時間のことを調べていなければ，「サークルはいいよ，成績も上がることがデータで示されているよ」という結論を出してしまうかもしれません。分析する時は，被説明変数に影響しそうな変数は網羅的に考えておかないと，間違った結論を導いてしまうのです。

先ほど見たように，単純な相関係数 r_{y1} は，統制された直接的な影響 (偏相関係数) と，間接効果が入り混じったものになっているので，しっかり統制して評価しなければなりません。重回帰分析の結果を解釈するときは，その表現も注意しなければならないことがおわかりいただけましたでしょうか。

また，説明変数間に強い相関関係があるときは，重回帰分析の結果そのものが不正確なものになることがあります。この問題をとくに**多重共線性 (multicollinearity)** の問題といいます。仮に x_1 と x_2 が $r_{12} = 0.9$ とか 1.0 に近いような，かなり相関が強い関係にあったとしましょう。$x_1 \simeq x_2$ といってもいいような感じです。仮に x_2 を x_1 に置き換えてみたとすると，回帰式は次のようになります。

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2$$

ここで $x_1 \simeq x_2$ と，ほとんど同じなのですから，$x_1 = x_2$ として置き換えてしまいましょう。

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_1$$

係数をまとめて次のようになります。

$$\hat{y} = b_0 + (b_1 + b_2) x_1$$

最後の式は，単回帰分析と同じ形になっていますね。単回帰分析の係数は 1 つだけですからある係数 $b_s = b_1 + b_2$ を満たす b_1, b_2 のペアは無数に考えられます。解が定まらないのです。実際は $x_1 = x_2$ と置き換えられるほどのことはないでしょうが，かなり相関が高いと同じようなことが起こります。多重共線性が生じると，結果的に回帰係数の符号が真の関係と逆になって出てくるなど，正しく答えが出てこない問題が生じます。

このように，説明変数間に相関関係がある場合はとくにいろいろ注意しなければなりません。説明変数同士の相関がないときに用いると重回帰分析は大変シンプルなのですが，実際はそういうことばかりではありません。解釈や多重共線性に注意するためにも，得られたデータはまず可視化して，説明変数同士に相関関係があるかどうかをチェックするようにするといいでしょう。

8.4 標準化された係数

さて，話は戻ってテスト点 y を，勉強時間 x_1 と単語数 x_2 で予測する回帰式をもう一度確認したいと思います。

$$\hat{y} = 33.433 + 1.258 x_1 + 0.0511 x_2$$

これを見ると，勉強時間の回帰係数が 1.258，単語数の回帰係数が 0.0511 です。この 2 つの数字を見ると，単語数がずいぶん小さいですね。勉強時間は単語数の 25 倍も重要なのでしょうか？ いえ，そうではありません。今回の場合，従属変数 (テスト点) は最小値が 47，最大値が 92 です。説明変数はこの従属変数に合うように伸ばしたり (係数をかける) ずらしたり (切片を足す) するわけです。勉強時間は最小値が 6，最大値が 25 ですから 50–90 ぐらいの幅に合わせるには数倍に伸ばせばよいのですが，単語数は最小値が 150，最大値は 500 にもおよびます。これを 50–90 ぐらいの二桁の数字にするためにはまず 1/10 ぐらいにスケールダウンしないとどうしようもないですね。ということで，x_2 の係数は小さな数字になっているのです。

このように，ローデータ[*4]を使った表現では，単位が違うということになりますから，そのまま偏回帰係数を比較して，こちらの影響力が大きかった，という判断をできません。ではどうすればよいのでしょうか。単位が異なるから相対比較できない，ということだったので，単位がなくなれば相対比較できるようになるわけです。そう，このような操作を**標準化**というのでしたね。

説明変数も従属変数も単位がついていますから，これらを整えるためにそれぞれの変数を標準化します。標準化したデータセットは表 8.3 のようになります。

この標準化されたデータセットは，各変数平均が 0 分散が 1 となっており，このままで相対比較が可能です。これを使って回帰分析を行うと，結果は次のようになります。

$$\hat{y.z_i} = 0.5707 x.z_{1i} + 0.4230 x.z_{2i}$$

標準化された勉強時間の回帰係数は 0.5707，標準化された単語数の回帰係数は 0.4230 でした。これを比較して，勉強時間のほうが単語数よりも影響力が大きい，と適切に判断することが可能です。このよう

[*4] raw data，生のデータという意味です。ここでは取ったデータそのものという意味で使っています。

表 8.3 標準化したデータ (一部)

ID	勉強 z	単語 z	テスト z
A	-1.427	-1.079	-1.575
B	-0.948	-1.516	-1.285
C	-1.267	-0.729	-0.778
D	-0.309	-0.904	-0.995
⋮	⋮	⋮	⋮
O	0.011	0.233	0.237

に各変数を標準化して算出した偏回帰係数のことを**標準化偏回帰係数 (standardized partial regression coefficient)** といいます。長い名称ですが，意味を考えると理解できると思います。標準化偏回帰係数は，x_2 の得点が同じとすると x_1 が 1SD 上昇するときに従属変数がどれぐらい変化するか，を表している係数になります。解釈はちょっとストレートではないですね。標準化しない回帰係数は単位がついていたので理解はしやすいが比較が難しい，標準化した回帰係数は単位がないので理解はしにくいけど比較がしやすい，ということです。

さて標準化したスコアで回帰分析した時の特徴をあと 2 つほど指摘しておきましょう。まずは切片 b_0 の値がないことです。気づきましたでしょうか。切片項は変数全体の高さ調整に使われるものであり，各変数の平均値を加味して計算されるものだったわけですが，標準化したデータを使った場合すべての変数の平均が 0 になっていますから，この調整が必要なくなったわけです。ということで標準化した回帰分析のばあいは切片がないのも当然なのです。もうひとつ，モデル適合について考えてみます。実は，標準化しない時の R^2 値と標準化した時の R^2 値は同じです。データが標準化されていようがされていまいが，線形モデルの当てはめをする上で変数間関係 (相関関係) が変わるわけではありません。位置とか幅が違うだけであり，散布図の見た目が変わるわけではないのです。考えてみれば当たり前のことなのですが，改めて確認しておくといいでしょう。

8.5 今日のまとめ

- 説明変数が複数になった回帰分析を重回帰分析という。そのときの回帰係数は偏回帰係数という。
- 偏回帰係数は「他の変数を統制したときの」回帰係数である，ということに注意。部分相関係数，偏相関係数，偏回帰係数の順に理解していこう。
- 説明変数が複数ある場合は単位がそれぞれ異なるので，影響力同士を比較するには標準化偏回帰係数をつかう。

8.6 課題

大学周辺のワンルームマンションの相場を調べるため，8 件ほどの物件のデータを集めてみました (表 8.4, 図 8.9)。これをもとに，家賃を従属変数とし，広さ，築年数，最寄りの交通機関からの移動時間を独立変数とした重回帰分析を行いました。

ローデータの重回帰式は，

$$\text{予測値} = 7.05 + 0.09\text{平米} - 0.14\text{築年数} - 0.04\text{移動時間}$$

表 8.4　家賃のデータ

平米	築年数	駅から徒歩	家賃
41.40	14	10	8.60
20.28	16	9	6.10
18.20	28	10	4.20
19.87	16	13	5.70
20.28	19	7	6.30
23.18	20	14	5.40
19.87	17	12	6.25
19.87	20	17	5.80

図 8.9　サンプルデータのプロット

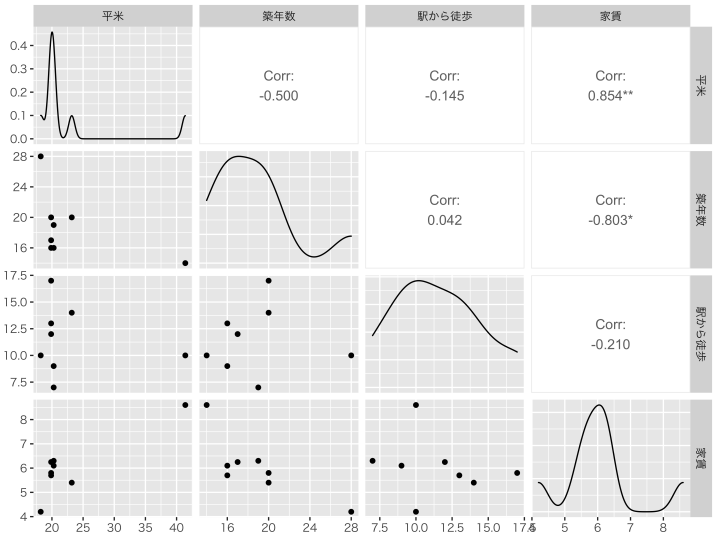

となり，すべてのデータを変数ごとに標準化したデータの重回帰式は

$$\text{予測値} = 0.58\text{平米} - 0.51\text{築年数} - 0.10\text{移動時間}$$

となりました。また，適合度指標は $R^2 = 0.93$ になりました。

このデータや結果を踏まえて，次の設問に答えてください。

■重回帰分析の結果を読み取る 1　ローデータの回帰分析とその結果について，正しい表現をしているものすべてにチェックを入れてください。

- 切片は 7.05 である
- 移動時間が同じ物件であれば，築年数が 1 年長いと家賃が 1400 円低い
- 家賃を決めるのに最も重要な変数は，回帰分析からはわからない
- 家賃を決めるのに最も重要な変数は，係数の絶対値が一番大きい築年数である。
- 家賃を決めるのに最も重要な変数は，係数が正の平米である。
- 移動時間と築年数が同じ物件であれば，1 平米広くなると家賃が 900 円高い
- 築年数が 1 年増えると家賃が 1400 円下がる

- 従属変数である家賃と平米, あるいは家賃と築年数の相関係数が高いため, 多重共線性が生じている可能性を疑うべきである。

■重回帰分析の結果を読み取る 2　標準化されたデータの回帰分析とその結果について, 正しい表現をしているものすべてにチェックを入れてください。

- 移動時間と築年数が同じ物件であれば, 1 平米広くなると家賃が 5800 円高い。
- 家賃を決めるのに最も重要な変数は, 回帰分析からはわからない。
- 家賃を決めるのに最も重要な変数は, 係数の絶対値が一番大きい平米である。
- 切片は記載されていないので, 分析結果が解釈できない。
- 家賃を決めるのに最も重要な変数は, 係数が正の平米である。
- 移動時間が同じ物件であれば, 築年数が 1 年長いと家賃が 5600 円低い。
- 標準化されたデータの散布図が描かれていないので, 分析に進むのは良くない。
- 説明変数が平米だけの回帰分析より, 平米と築年数の 2 変数を使った回帰分析の方が, また平米と築年数の回帰分析より, 平米と築年数と駅からの時間の 3 変数を使った回帰分析の方が, 適合度 R 二乗は大きくなる

第 9 章

R をつかった回帰分析

さてここまでは，回帰分析や**重回帰分析 (multiple regression analysis)** の仕組みを言葉で説明してきましたが，自分で計算できなければ絵に描いた餅です。重回帰分析の回帰係数を求める方法についてはとくに説明してきませんでしたが，R で計算する時は単回帰・重回帰の区別なく表現できるので，ここで一気に習得してしまいましょう。

今回もこれまで同様，野球選手のデータを読み込んで使います。次の 6 行を実行してください。

code : 9.1　データの読み込みと記述統計の確認

```
1  rm(list=ls())
2  library(tidyverse)
3  dat <- read_csv("BaseballDecade.csv", na="NA",
4           locale=locale(encoding="utf8")) %>%
5           filter(Year=="2020年度")
6  summary(dat)
```

■コード解説

1 行目　環境 Environment を初期化するコードです。Quarto 形式で書いている人は，この行はなくても構いません[*1][*2]。

2 行目　`tidyverse` パッケージを読み込んでいます。このパッケージはファイルの読み込みや並べ替え操作など，便利な機能がまとめられたものです。

3-4 行目　`BaseballDecade.csv` というファイルを読み込んでいます。このファイルがプロジェクトフォルダ内にあることを確認してから実行してください。

5 行目　ファイルの一部，2020 年度のデータだけに絞るようフィルターをかけています。

6 行目　読み込んだデータの記述統計量など，基本的な要約を行っています。

9.0.1　散布図の描画

データが手に入ったとき，最初にすることは可視化です。**データは図にする**という約束は忘れないでくださいね。今回はさまざまな変数があるのですが，ここで打者の身長と体重のデータだけ抜き出して図にしてみた

[*1] Quarto ファイルはそのまま使うのではなく，RStudio の `Render` ボタンを押して HTML などの出力ファイル形式に変換して使います。Render するときは毎回まっさらな環境で計算が行われるので，環境を初期化しておく必要がないのです。

[*2] Quarto で保存するときの拡張子は `.qmd` になります。ファイル名にピリオドが入っていると拡張子が変わっちゃうことがあるので，注意してください。拡張子って何，というひとは 2.4,Pp.23 を参照。

いと思います。

code : 9.2 散布図の作成

```
1  batter <- dat %>%
2    dplyr::filter(position != "投手") %>%
3    dplyr::select(height, weight)
4  g <- ggplot(batter, aes(x = height, y = weight))
5  g <-  g + geom_point()
6  g
```

■コード解説

1-3 行目 batter というオブジェクトを作っています。これは dat オブジェクトを加工して作るのですが, 詳しくはこの後で説明します。

4 行目 batter オブジェクトを使って, x 軸を height 変数, y 軸を weight 変数とするキャンバスを指定します。

5 行目 キャンバスに点を打つように geom_point します。

6 行目 描画オブジェクト g を表示します。

結果的に図 9.1 のような図ができていれば OK です。

図 9.1 身長と体重のデータ

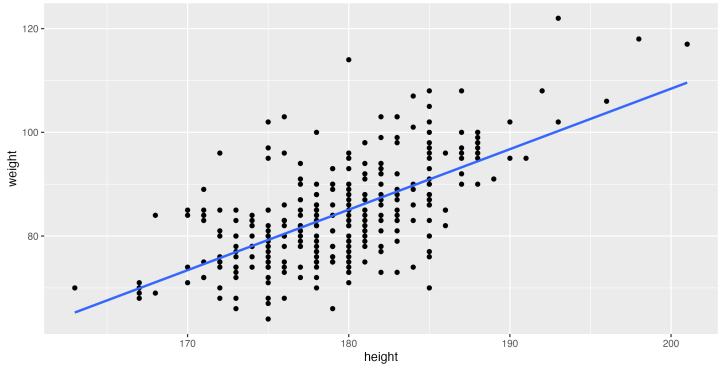

さて 1-3 行目の操作ですが, ここでやりたかったことは dat オブジェクトの中から打者のデータに限って, 身長と体重の変数を抜き出すことでした。これらの操作は tidyverse パッケージに含まれる dplyr パッケージの filter 関数と select 関数で実装されます。この両者の違いについては, セクション 5.7.1,Pp.78 を参照してください。ともかくこれで欲しいデータの散布図が書け, どうやら正の相関がありそうだということがわかりました。直線関係を仮定しても良さそうです。ちなみに次のコードを書くと ggplot で直線を書くことができますよ。

code : 9.3 回帰線を引く

```
1  g <- g + geom_smooth(method = "lm", se = FALSE)
2  g
```

■コード解説

1 行目　散布図を書いているオブジェクト g にスムージング関数 geom_smooth でデータにスムーズな線を引く。線の引き方は lm すなわち**線形モデル**。

2 行目　オブジェクト g の描画

9.1　線形回帰の実行

それではここから回帰分析を行います。回帰分析は線形関数を当てはめるので**線形モデル (linear model)** と呼ばれますが，これの頭文字をとった lm 関数が線形回帰モデルです。次の code:9.4 を実行してみましょう。

code : 9.4　回帰分析の実行

```
1      result <- lm(weight ~ height, data= batter)
2      summary(result)
```

■コード解説

1 行目　lm 関数に回帰式とデータを入れて分析を実行し，その結果を result オブジェクトに代入する。ちなみに~はチルダといいます[*3]。

2 行目　分析結果の要約を出力させる。

ここで重要なのは，1 行目の回帰式の表現です。R では $y \sim x$ という書き方で，$y = f(x)$ を表現します。これは回帰式に限らず，一般的に従属変数 y と独立変数 x の関係を $\sim$ でつなげる，という**式 (formula)** の書き方なのです。今回は lm という関数を使って表現しましたが，線形モデルではない関数で独立変数，従属変数の関係を書く時も y ~ x で表現します。この表記に慣れると，あの分析もこの分析も，形としては $y = f(x)$ なんだな，ということがわかりやすくていいですね。今回は，体重を身長で予測したということになっています。

この分析の出力結果が出力 9.1 の通りです。

[*3] 日本語キー配列の場合，「ほ」の右，アットマークの上にあるキーを Shift を押しながら押すと出ます。US キー配列の場合は tab キーの上にあります。

R の出力 9.1: 回帰分析の出力結果

```
Call:
lm(formula = weight ~ height, data = batter)

Residuals:
     Min       1Q   Median       3Q      Max
-20.9217  -4.9213  -0.4214   4.0783  28.9118

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -124.91755   13.89317  -8.991   <2e-16 ***
height         1.16670    0.07746  15.063   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.435 on 327 degrees of freedom
Multiple R-squared:  0.4096, Adjusted R-squared:  0.4078
F-statistic: 226.9 on 1 and 327 DF,  p-value: < 2.2e-16
```

何やら色々出ていますが, 順に確認していきましょう。まず Residuals とありますが, ここは残差 e_i の記述統計情報を表しています。どれぐらい残差が大きく出るのか, 確認すると良いでしょう。次の Coefficients は係数という意味です。ここに回帰係数が出ています。少しみにくいかもしれませんが, 表形式になっていて, Estimate と書かれたところが推定値, 今回知りたい回帰係数の値になっています。回帰式は次のようになります。

$$\hat{y} = -124.91755 + 1.16670 \times height$$

どの数字が結果の何に対応しているか確認しておいてください。また, この式が得られたということは身長のところに新しい数字を入れると体重の予測ができるということもわかってもらえると思います。

その他にもいろいろな情報が出ていますが, その内容は後期でお話しする推測統計に関するところですので, 今のところはまだ知らなくて OK です[*4]。それよりも大事なのは下から二行目にある, Multiple R-squared というところです。これがいわゆる R^2 値であり, モデルの**適合度**を表しています。今回は $R^2 = 0.4096$ ですから, 予測値 $\hat{y}$ と従属変数 y の相関係数が 0.64 ぐらい, 分散説明率が 40.9% ぐらいだったということがわかります。悪い当てはまりとしては, やや悪いといったところでしょうか。

[*4] それでも少し解説しておきます。まず推定値というのは今回のデータから得られる値ではなく, このデータが大きな母集団から取られた標本だと考えたときに, 標本のデータから母集団の関係を推測するならこの値になる, という意味があるからです。今回のデータについての最小二乗法での答えが欲しいのですから, 標本から推定するのではなく, 標本の特徴を考えてればいいじゃない, と思うかもしれません。いやほんとその通りなので, 今はまだ説明しないのです。幸い, 最小二乗法で求めた回帰係数の値と, 推定法 (ここでは最尤法という方法を使っていますが) による答えが一致しますから, 悩まなくてもいいのですが。また, 今回の標本ではなく別の標本だった場合, この推定値がどれぐらい違う値になる可能性があったかを計算して出しています。それが Std.Error のところです。それを踏まえて考えると, 回帰係数が 0, すなわち説明変数がまったく予測しないという状態になる可能性がどれぐらいあるか, というのを検証しているのが t value や Pr(>|t|) のところで, これをみながら今回の分析から何が言えるかを結論づけたりするわけです。

9.2 回帰診断と Q-Q プロット

今度は分析結果のオブジェクトを plot 関数に渡してみましょう。この関数による描画を見ることで，回帰分析が正しいモデルだったかどうかについての「診断」をすることができます。

code:9.5 を実行してみましょう。

code : 9.5 回帰分析の診断

```
1       plot(result)
```

キーを押すたびにプロットが変わります。一枚ずつ順番にみていきましょう。最初にプロットされるのが，残差 e_i と予測値 $\hat{y}_i$ の関係を表したプロットです (図 9.2)。

図 9.2 残差と予測値のプロット

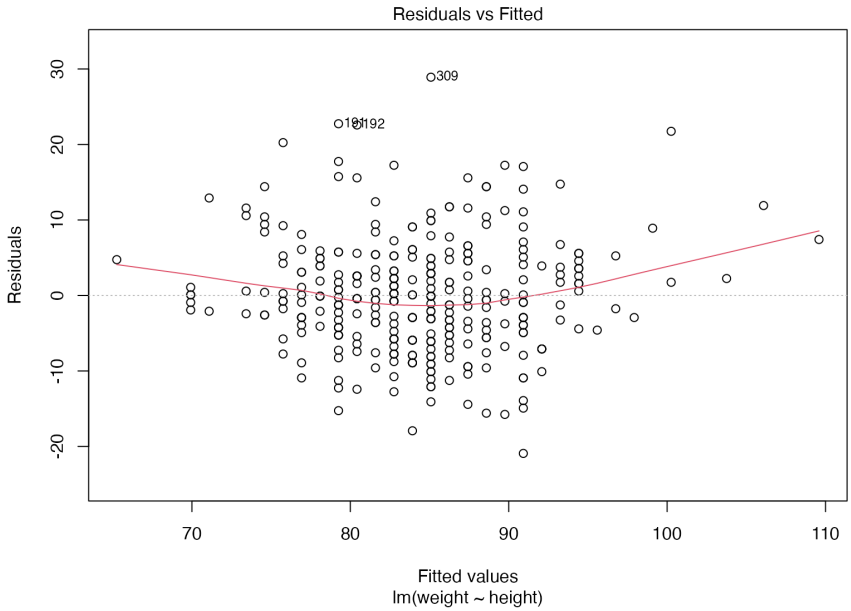

理論的には，残差と予測値の間の相関 $r_{\hat{y}e}$ はゼロになるはずで，予測値で残差を予測するような回帰分析をすると傾きがゼロ，つまり水平に近い線が引かれるはずです。線形回帰の水平線や，曲線で回帰した予測線が表示されていますが，概ね水平に近く，相関がゼロになっていそうです。ただ，このプロットの縦軸は残差の大きさですから，高い領域にプロットされている幾つかの点は大きく予測が外れている，つまり外れ値である可能性があります。特徴的なケースがないか，確認しておきましょう。

次にプロットされるのが Q-Q プロットと呼ばれるものです。

ここで表示されているのは，残差の確率的な性質を確認するためのプロットです。残差は平均が 0 で分散が一定の**正規分布 (normal distribution)** に従うと仮定されています。正規分布については次回以降で詳しく扱いますが，今は理論的な正規分布と実際の残差の分布が合致しているかを確認する図である，と理解してください。理論的な残差の分位点を横軸に，実際の残差の値の分位点を縦軸においており，理論通りであればこの散布図は左下から右上への一直線になるはずです。今回もほとんどの点がその直線に乗っていますから，まあいいでしょう。右上の方に少し外れ値があることが気になりますが，ID 番号が表示されているの

図 9.3 Q-Q プロット

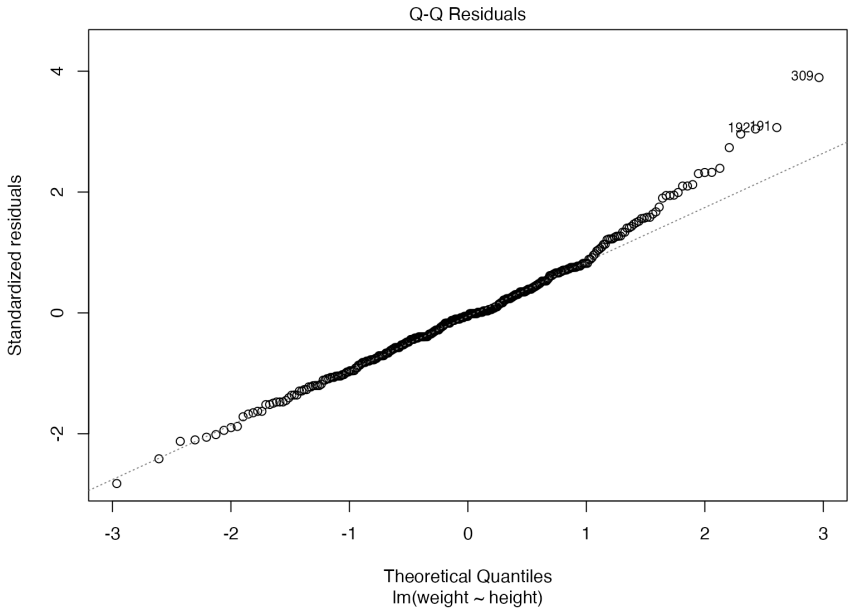

で，特殊なケースが何なのかをみておいてもいいかもしれません。

続く二つのプロットは，「標準化残差のスケールロケーションプロット」「レバレッジと標準化残差」のプロットになっています。これらも外れ値がないか，極端に係数の大きさに寄与している変数はないかというところを見るものです。

図 9.4 標準化残差のスケールロケーションプロット

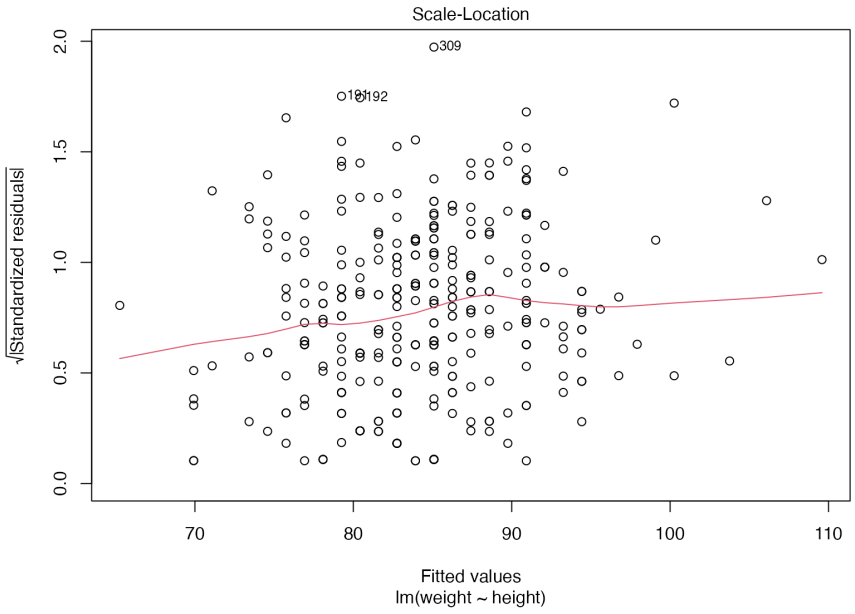

今回の結果は，いくつかの外れ値はあるものの，全体的にはいい分析ができたといえそうです。回帰分析

図 9.5 レバレッジと標準化残差

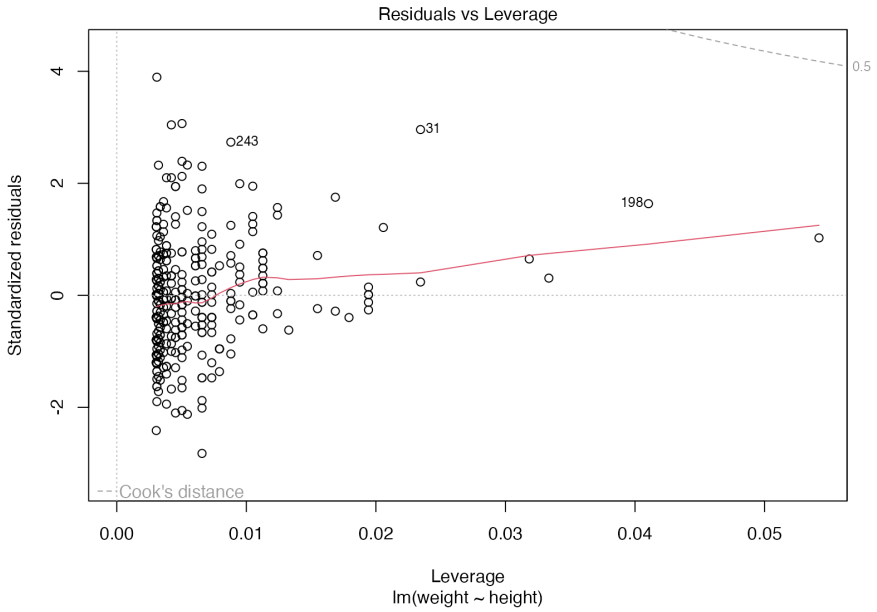

を行った時は，仮定に違反していないかとか，極端に強い影響のあるケースがないかなど，プロットして確認しておきましょう。

9.3 残差をデータで確認しておこう

さて今度は少し理論的な興味に基づいて，結果を確認してみます。

今回の `lm` 関数から返される結果を格納したオブジェクトの中には，他にも予測値 $\hat{y}_i$ や残差 e_i といった情報が含まれています。それらが架空の値ではなく，算出された個々の値であるということを確認するために，表示させてみましょう。結果のオブジェクト `result` には，`residuals` 変数として残差が含まれています。同じく `fitted.values` 変数として予測値が含まれています。これらの値を元のデータセットに追加して，全体像を見てみます。

code : 9.6 回帰分析のその他の情報

```
1  batter$residuals <- result$residuals
2  batter$yhat <- result$fitted.values
3  batter
4  summary(batter)
5  plot(batter)
6  cor(batter)
```

■コード解説

1-2 行目 `batter` オブジェクトに `result` オブジェクトの `residuals` 変数と `fitted.values` 変数を追加しています。

3 行目 上書きされた `batter` オブジェクトを表示させています。長くなりますので，上の方の一部分だけが

表示されます。

4 行目 上書きされた batter オブジェクトの要約統計量を表示させています。

5 行目 batter オブジェクトのプロットを描いています。

6 行目 batter オブジェクトの相関係数を計算しています。

R の出力 9.2: 残差と予測値の確認

```
# A tibble: 329 × 4
   height weight residuals  yhat
    <dbl>  <dbl>     <dbl> <dbl>
 1    171     72   -2.59    74.6
 2    181     98   11.7     86.3
 3    177     91    9.41    81.6
 4    180     85   -0.0882  85.1
 5    171     84    9.41    74.6
```

これを見ると，たとえば 1 行目のデータは身長 171cm 体重 72kg の選手であり，回帰式 $-124.91755 + 1.16670 \times height$ を使った計算結果は 74.6 ということがわかります。74.6 という予測値 $\hat{y_1}$ は，実際の値 y_1 と比べて 2.59 ずれていますので，$\hat{y_1} - y_1$ で-2.59 となっています。以下同様で，329 人分のデータそれぞれについて予測値と残差が計算できました。

今度は要約統計量を見てみましょう。残差 e_i の平均が 0 になっていることがわかりますね。また，予測値 $\hat{y}$ と目的変数 y の平均値がぴったり一致しています。一致するのです。データ全体の平均に沿うように，目的変数をずらしたり (切片を足す) 伸ばしたり (係数をかける) することによって，中心合わせをするからですね。

R の出力 9.3: 残差と予測値の要約統計量

```
     height          weight         residuals             yhat       
 Min.   :163.0   Min.   : 64.00   Min.   :-20.9217   Min.   : 65.25  
 1st Qu.:176.0   1st Qu.: 78.00   1st Qu.: -4.9213   1st Qu.: 80.42  
 Median :179.0   Median : 83.00   Median : -0.4214   Median : 83.92  
 Mean   :179.3   Mean   : 84.26   Mean   :  0.0000   Mean   : 84.26  
 3rd Qu.:182.0   3rd Qu.: 90.00   3rd Qu.:  4.0783   3rd Qu.: 87.42  
 Max.   :201.0   Max.   :122.00   Max.   : 28.9118   Max.   :109.59  
```

さらにプロットを見てみましょう (図 9.6)。これは ggplot を使っての出力ではなく R オリジナルの出力例ですが (そのせいか少し色気のない出力ですが)，これを見て幾つか気づく点があると思います。

R の出力 9.4: 残差と予測値の相関関係

```
 > cor(batter)
 height    weight     residuals         yhat
height     1.000000e+00 0.6400162 -6.168902e-17 1.000000e+00
weight     6.400162e-01 1.0000000  7.683614e-01 6.400162e-01
residuals -6.168902e-17 0.7683614  1.000000e+00 1.521511e-16
yhat       1.000000e+00 0.6400162  1.521511e-16 1.000000e+00
```

1 つは height と yhat の組み合わせが直線になっているところですね。次の cor 関数でも，対応するところが 1.0 になっています。これは当然で，身長データを伸ばしてずらしたのが予測値であり，この両者はいわば一対一対応，100% の相関関係にあることがわかります。また，説明変数 height と残差 residuals

図 9.6　予測値や残差を含んだ散布図

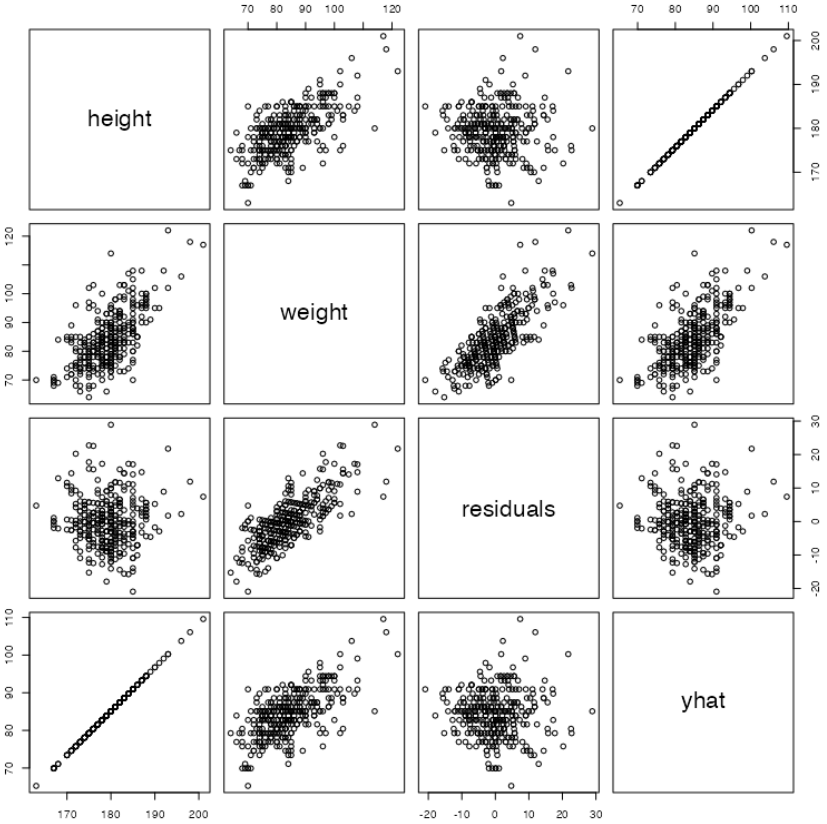

の組み合わせは丸に近く，相関係数はほぼ 0.0 です[*5]。説明変数と残差の間に相関関係があるというのは，原理的におかしなことですよね。説明変数は従属変数をできるだけ説明しようとしていて，その残りが残差なのですから，残差のところに説明変数と関係する要素があるとすれば，それは残差ではなく従属変数のまだ説明できる箇所だということになってしまうからです。

同様に，残差 `residuals` と予測値 `yhat` の相関関係もほぼ 0.0 になっています。これも原理的には 0.0 になるのです。回帰分析は説明変数によって，説明できる部分 (予測値) と説明できない部分 (残差) にきっちり分離するのですから，分離されたもの同士に関係が残っているはずがないのです。数理的な導出は小杉 (2018)の P.127–135 を見て貰えばわかりますが，データを見ることで一目瞭然だと思います。

9.4　重回帰分析

では続いて**重回帰分析**に行きましょう。R において重回帰分析を行う時は，説明項を 1 つ追加するだけでいいので，作業としては簡単なものです。ただし結果の解釈には注意が必要であることを忘れずに。

[*5] いやいや，何か数字があるよとツッコミが入りそうですね。計算結果のところには $-6.169e-17$ という表示があるかと思います。この表現は，桁数があまりにも大きいので普通の十進法で表現できなかった場合に出てくるもので，$e+$ のところが 10 の累乗を表しています。今回は $e-17$ ですから，$10^{-17} = 0.00000000000000001$ というごく小さな値を，-6.168902 にかけた値が答えとなっています。数学的にはちょうど 0.0 になることが証明できるのですが，機械の計算は丸め誤差などがあるので少しずれが生じます。が実質的にゼロだということです。

code : 9.7 重回帰分析のデータを作って可視化

```
1  batter2 <- dat %>%
2    dplyr::filter(position != "投手") %>%
3    dplyr::select(HR, Hit, salary) %>%
4    na.omit()
5  plot(batter2)
6  cor(batter2)
```

■コード解説

1-4 行目 batter2 というオブジェクトを作っています。これは dat オブジェクトを加工して作っており，2 行目で野手 (投手でない人) を選択し，3 行目で変数として本塁打，安打，salary を選択しています。4 行目は欠測値を一括で取り除く処理をしています。ホームランを打っていない人などはデータに含められないからです。

5 行目 データのプロットを描いています。

6 行目 データの相関関係を数字でみています。

プロットを見ると，ホームランの数や安打の数が増えるほど，年俸は上がっているようです (図 9.7)。さすがプロ野球は実力勝負の世界，グランドには銭が埋まっているというやつです。少しデータの左端の方，つまりホームランや安打を打たない人が数多くいるため，よく打つ人に引っ張られて相関係数が大きく出ている可能性はありますし，安打と本塁打の間にも相関があるので少し気になりますが，ひとまずはこれで分析することにしましょう。

図 9.7 本塁打，安打と年俸の関係

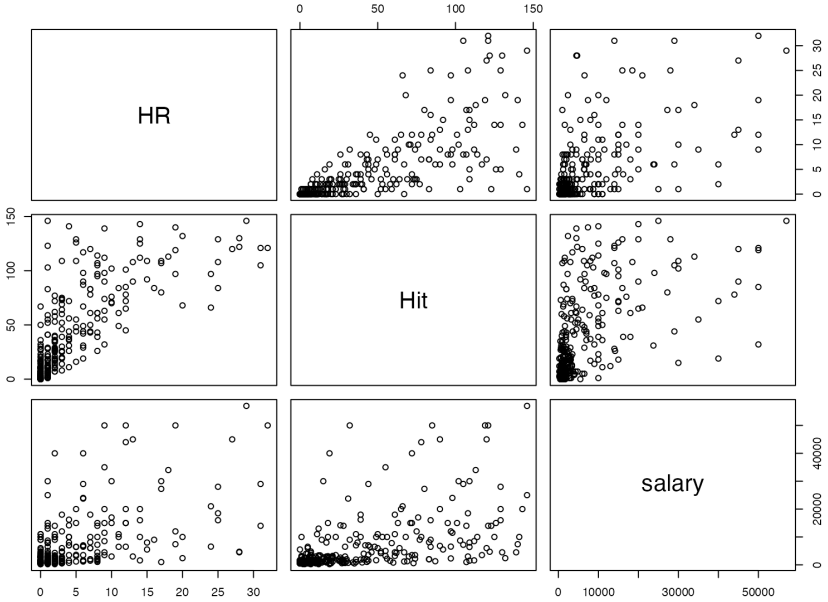

回帰分析のコード code:9.8 と出力 9.5 は次の通りです。

code : 9.8 重回帰分析の実行

```
1  result2 <- lm(salary ~ HR + Hit, data = batter2)
```

```
2  summary(result2)
```

R の出力 9.5: 回帰分析の出力結果

```
Call:
lm(formula = salary ~ HR + Hit, data = batter2)

Residuals:
   Min     1Q Median     3Q    Max
-22581  -2394  -1025    264  40723

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1620.46     575.40   2.816  0.00516 **
HR            659.15     104.09   6.333 7.98e-10 ***
Hit            53.88      16.61   3.245  0.00130 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7761 on 326 degrees of freedom
Multiple R-squared:  0.378, Adjusted R-squared:  0.3742
F-statistic: 99.06 on 2 and 326 DF,  p-value: < 2.2e-16
```

結果の読み取りはよろしいでしょうか。重回帰式は次のようになります。係数をどこから読み取るか，確認してくださいね。

$$\hat{y} = 1620.46 + 659.15 \times HR + 53.88 \times Hit$$

これをみると，安打の数が同じくらいであれば，ホームラン一本につき 660 万円年俸が上昇するようです。また本塁打の数が同じぐらいであれば，ヒット一本で 53 万円年俸が上昇します。またこのモデルの R^2 は 0.378 ですから，予測モデルは全体の 37% ぐらいしか説明できておらず，あまり良いモデルとは言えないということがわかりました。

ヒットも本塁打も単位は「本」ですので，解釈も同じようにできて簡単かもしれません。あるいはヒットと本塁打は意味が違う，というのであれば直接の比較はおかしいことになります。ここでは後者の可能性を考えて，変数同士の単位が違うから標準化しよう，という方向で分析を進めたいと思います。

データセットの各変数を標準化する必要がありますが，それには scale 関数を使います。

code : 9.9　標準化したデータで重回帰分析を実行

```
1  batter2z <- scale(batter2) %>% as.data.frame()
2  summary(batter2z)
3  result2z <- lm(salary ~ HR + Hit, data = batter2z)
4  summary(result2z)
```

■コード解説

1 行目　batter2z というオブジェクトを作っています。これは batter2 オブジェクトを scale 関数で標準化することで作れるのですが，scale 関数は出来上がったものがデータを表す data.frame 型になっていませんので，%>% でつないで as.data.frame という関数でデータの形にしています。

2 行目　出来上がった batter2z というオブジェクトの記述統計量をみています。平均値が 0.0 になっていることなどから，標準化されていることが確認できます。

3 行目　batter2z オブジェクトで同じように重回帰分析をしています。

4 行目　結果を出力させています。

R の出力 9.6: 回帰分析の出力結果

```
Call:
lm(formula = salary ~ HR + Hit, data = batter2z)

Residuals:
    Min      1Q  Median      3Q     Max
-2.3016 -0.2440 -0.1045  0.0269  4.1507

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.006e-16  4.361e-02   0.000   1.0000
HR           4.298e-01  6.786e-02   6.333 7.98e-10 ***
Hit          2.202e-01  6.786e-02   3.245   0.0013 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.7911 on 326 degrees of freedom
Multiple R-squared:  0.378, Adjusted R-squared:  0.3742
F-statistic: 99.06 on 2 and 326 DF,  p-value: < 2.2e-16
```

結果を見てみましょう (出力 9.6)。推定値の読み方，わかるでしょうか。ここにも e-01 なんて表示があるのですが，これは $10^{-1} = \dfrac{1}{10} = 0.1$ と同じ意味です。標準化した回帰分析の結果は次の通りです。

$$\hat{y} = 0.4298HR + 0.2202Hit$$

これを見比べると，ヒットよりもホームランのほうが年俸の上昇には強い影響を与えているようですね。ここでの回帰式では切片を記入しませんでした。推定値は $-1.006e-16$ であり，これは $e-16 = 10^{-16}$ がかけられていますからほぼゼロになっています。原理的にも 0 であるはずなので，ここでは書きませんでした。また R^2 が標準化しなかったときと変わっていないことも確認できますね。相対的な関係には影響しないので，このようになります。

計算自体は一瞬でできることがわかりましたね。でも計算ができたときに，何をやっていたのかわからないとか，何のためにやっていたのかわからない，ということでは意味がありません。またもちろん，結果の読み取り方が間違っていてもいけませんし，この結果から何が言えるだろうか，と考えることで初めて研究が始まるのです。「やった，できた」だけではなく，「なぜ，どうやって，どういう意味か」と考えを深めるためのツールとして，統計技術を使い倒してみてください。

9.5 課題

この章で学習した内容を確実に身につけるために，以下の課題に取り組んでください。

■課題 1：単回帰分析　今度は体重を説明変数，身長を目的変数として単回帰分析を実行してください。

- 回帰式を $\hat{y} = b_0 + b_1 x$ の形で書いてください
- 体重が 1kg 重いと, 身長は何 cm 高いと予測されますか？
- R^2 値はいくつですか？
- Q-Q プロットで残差は正規分布にしたがっているように見えますか？
- 残差 vs 予測値プロットで赤い線は概ね水平ですか？

■課題 2：重回帰分析　本塁打と安打を説明変数, 体重を目的変数とする重回帰分析を実行してください。また, 説明変数と目的変数すべてを標準化したデータでも重回帰分析を行ってください。

- 安打の非標準化偏回帰係数はいくつですか
- 本塁打の標準化偏回帰係数はいくつですか
- 標準化したモデルでの切片はいくつですか
- 標準化前後の R^2 値はどうなりますか

第 10 章

確率と確率分布

今回は確率のお話です。

ここまで，データの記述とデータにモデルを当てはめるというお話をしてきました。モデルを当てはめるときに誤差 (残差) を考えました。この誤差は，目に見えないものでどういう振る舞いをするかもわからない，規則性のないものです。ただこの規則性のなさを，どうコントロールするかというときに，確率の概念が出てきます。

確率と呼ばれる数字は，偶然性や毎回の不確実さを表しつつ，その奥にある大局的な性質を記述できます。測定の誤差が積もり重なると平均がゼロになるように，毎回の事実はわからなくても全体的な傾向を記述することはできるのです。これは大規模調査を行うときにも応用できます。すなわち，個々人の違いはわからなくても，集計して統計を取ったときに，その全体の平均的な傾向を掴むことは可能なのです。偶然性をハンドリングし，全体的な傾向としてそれをコントロールするために，確率の考え方は避けては通れないのです。

ここでは心理学でよく使われる**正規分布 (normal distribution)** をゴールに，確率とは何か，確率分布とは何か，という話をしていきたいと思います。

10.1　確率と呼ばれる数字

確率と統計については高校数学でもある程度習うでしょう。「場合の数」を数え上げることから始まって，順列，組み合わせ･･･ああ面倒くさい！という印象を持っている人もいるかもしれません。

でもそれと同時に，皆さんはもっと日常的に確率という言葉を使っています。たとえば天気予報で降水確率は 30% だとか，100% 勝てる！といった表現をすることがありますね。

これらはどちらも**確率 (probability)** です。確率という言葉で表される数字が従うべき条件は，実は次の 3 つに集約されます。

1. 確率の値は非負 (正または 0 の数字)
2. 全標本空間におけるすべての事象の確率の合計は 1.0
3. 任意の 2 つの相互に排他的な事象について，どちらか一方が発生する確率は個々の確率の和である

まず，確率は正の数字ですから (たとえば 10%=0.1 という正の実数です)，1 つ目の条件は問題ないでしょう。

2 つ目はややこしい言葉が並んでいます。実現する出来事のことを事象といい，個々の出来事のことを標本，標本が含まれる世界全体のことを全標本空間と呼んでいますから，ここでは「あり得るすべてのこと」ぐらいに理解しておいてください。つまりこの 2 つ目の条件は「あり得るすべての確率を足し合わせたら 1.0 になる」ということを指しています。だから高校数学での確率は，あり得るすべての事象を数え上げさせて，その中

の相対的な頻度でもって確率としていたのです。でもたとえば，天気予報が「晴れ」「雨」「曇り」の 3 つの状態 (事象) に限定されていて，明日の天気はその中でも「雨」になりそうな度合いが 0.3 ぐらいだというのであれば，それでもいいのです[*1]。皆さんも決意や意志の強さを確率で表現したいことがあるかもしれませんが，その時は心の中のあり得る状態をすべて考えたうち，どの程度の強い思いなのかを表現すれば良いのです。ちなみに天気予報は未来の予測であり，起こりうるすべての未来を書き出して天気の割合を算出しているわけではありません。過去の同じような天気図になったときに，実際に生じた事象を集計したものを参考に，未来に託す想いの強さを確率の言葉で表現しているのです。

さて，第 3 の条件は少しややこしいようです。でも言葉をよく読んでみましょう。「任意の 2 つの相互に排他的な事象」は「なんでもいい 2 つの事象，ただし排他的」ということです。排他的というのは一方が成立すると他方は成立しないというように，他を排除する，両立しない，という意味です。確率の例でいうなら，サイコロの出目で 1 が出るという事象と，2 が出るという事象は相互に排他的です。1 と 2 の面が同時に上を向くなんてことはあり得ないわけですから。これを踏まえて後段を考えると，「どちらか一方が発生する」確率です。先の例で言えばサイコロで「1 か 2 が出る」状態ですね。その場合は個々の確率の和，すなわち $1/6 + 1/6 = 1/3$ ということを説明しているだけです。

この 3 つの条件を満たしていると，その数字は確率と言って構いません。高校までの数学で習った確率は，たとえば「サイコロの目が出る確率は，サイコロを無限に転がしていくとその相対頻度は最終的に 1/6 に収束するはず」として定義しています。この無限回試行を行う，というのは実際にはできませんが，それぞれの出目の確率が等しいならいつかは $1/6$ にたどり着くはずで，出目の割合がそれぞれ $\{1/6, 1/6, 1/6, 1/6, 1/6, 1/6\}$ だとすると，非負で，全部足すと 1 で，第 3 の条件も成立しているので，これは確率だと言えます。また「降水確率」などとして使われる「確率」の場合，「今日が無限回繰り返されれば･･･」という考え方は成立しないのですが，「雨が降る確率が 60 %，曇りが 30 %，晴れが 10 %の確率」と表現し，「雨かつ曇り，という状態はない」と考えれば，確率の定義には当てはまっていますから，これも確率です。**この条件を満たす数字が確率であり，確率に関する数学的法則はいずれも同じように作用する**，というところがポイントです。

持って回ったような言い方をしていますが，ここで伝えたいのは要するに「無限回の数え上げだけが確率じゃない」ということです。雨が降る確率とか，お昼ご飯にカレーを食べる確率とか，そういう言い方でも問題ないよということです[*2]。むしろそうした確率の方が馴染みやすい数字ではないでしょうか。ちなみに無限回試行の相対頻度から確率を算出するやりかたで定義する方法を**頻度主義 (frequentist)** と呼ぶことがあります。それに対して，確信できる度合いの強さを表現するものとして定義する方法を**主観確率 (subjective probability)** ということがあります。どちらが正しいという話ではないので，定義に則して考えるとさまざまな解釈が可能だ，ということをここでは押さえておいてください。

10.2 確率分布

ある事象が確率的に振る舞う，あるいは個々の出来事を正確に予測はできなくとも全体的にある傾向に従うことが示せる場合，その事象は確率的な動きをする変数という意味で**確率変数 (random variable)** と呼ばれます。確率変数がどのような振る舞いをするのか，その起こりうるすべての事象と対応した確率を

[*1] 日常用語で使う確率表現の場合は，間違った使い方があり得ます。たとえば元大阪府知事の橋下徹さんは，2007 年の選挙戦前のインタビューで「出馬は 20000% ない」と発言しましたが (しかもそれを数日後に覆して出馬し，当選しましたが，それはおいといて)，これは確率の数字ではありません。同様に，Dr.Stone の主人公，千空の口癖で「100 億 % ない」などという表現がありますが，これも確率の数字とは言えません。博学の主人公にしては残念なセリフです。

[*2] もちろん条件を満たしている必要があるので，橋下さんの表現は数学的に正しくはありません。

網羅的に書き出した一覧のことを**確率分布 (probability distribution)** といいます。たとえばサイコロの出目に関して，次のように表現したとしましょう。

- 1 が出る確率 $\cdots 1/6$
- 2 が出る確率 $\cdots 1/6$
- 3 が出る確率 $\cdots 1/6$
- 4 が出る確率 $\cdots 1/6$
- 5 が出る確率 $\cdots 1/6$
- 6 が出る確率 $\cdots 1/6$

これはすべての出目と確率を対応させた一覧ですから，サイコロの目の確率分布を表していると言ってもいいでしょう。一般的な六面ダイスで説明しましたからこれでいいですが，20 面サイコロなどになるとちょっと表記が面倒ですね。また，サイコロの出目は 1.5 とか 2.3 のようになることはありません。これは出目が離散的，あるいはカテゴリカルなものと言ってもいいでしょう。尺度水準で言うところの，**名義尺度水準**や**順序尺度水準**の数字であれば，離散的，カテゴリカルなものになるわけです。このように離散的な変数についての確率分布のことを**離散分布**と言います。これに対して，連続的な変数の確率分布は**連続分布**といいます。間隔尺度水準，比率尺度水準の数字は連続分布ですね[*3]。連続分布の場合はとくに，すべての数字を網羅的に書き下すことはできません。そこで分布を数式・関数で表現することが一般的です。関数で表された確率分布のことを**確率分布関数 (probability distribution function)** といいます。

10.2.1 離散分布と確率質量

離散的な確率変数の例をさらにみていきましょう。サイコロを例にとります。サイコロの出目は離散的ですからね。サイコロを 100 回投げてその出目を記録し，グラフにしたのが図 10.1 です。

図 10.1 サイコロの確率分布

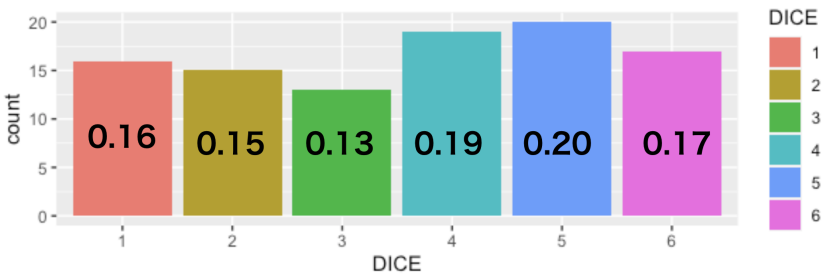

ここにはすべての出目を数えてその相対頻度を書き表してあります。このような離散的な確率変数の大きさを表す数字のことをとくに，**確率質量 (probability mass)** といいます。また相対頻度は先に述べた確率の条件に合致しているので，確率と考えることができます。ですから確率質量の総和は 1.0 になります。

[*3] 連続とは何か，というのは数学的には結構込み入ったお話ですが，直感的には「どのような値と値の間にも中点があるなら連続」と思っておけばいいでしょう。たとえば身長などの連続変数は，160 と 170 の間に 165，160 と 165 の間に 162.5，160 と 162.5 の間に 161.75，160 と 161.75 の間に... とどこまでも行けるわけです (測定精度が出るかどうかはともかく，理論的に)。

10.2.2 連続分布と確率密度関数

次に連続変数の場合を考えてみましょう。先ほどと同じく，今度は 1000 人の身長を測定したデータを例にします。身長は連続量だと考えることができます。図 10.2 にそのヒストグラムを書いてみました。このヒストグラムは 1 階級が 5cm 幅で，各階級に何人いるかの数字も同時に書いています。このように階級ごとに区切ったものは，先のサイコロの例と同じように相対頻度にできますから，たとえば 160-165cm の階級の確率質量は 0.165，という言い方をしてもいいかもしれません。しかし「5cm で区切る」ということに深い意味はなく，こ

図 10.2 身長の確率分布。bin 幅は 5cm

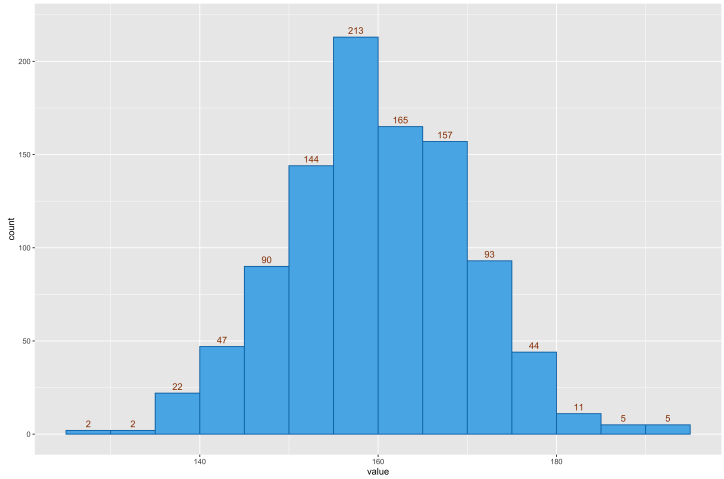

れが別に 2.5cm でも 1cm でもいいわけです。たとえば同じデータを 2.5cm 間隔で区切って書き直したのが図 10.3 になります。このように，度数は階級の区間に依存しますので，どれぐらいの幅の中にどれぐらいの量

図 10.3 身長の確率分布。bin 幅は 2.5cm

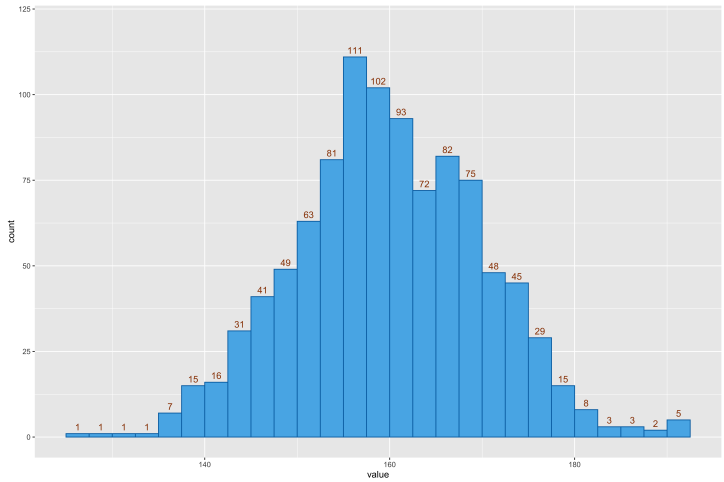

が詰まっているか，で考える必要があります。確率変数の確率質量に関する密度ですから，これを**確率密度 (probability density)** といい，確率密度＝確率質量/区間幅で計算します。たとえば図 10.2 の 160-165cm の階級は 0.165 の確率質量でしたから，密度は $0.165/5 = 0.033$，というように考えます。図 10.3 の場合は 160-162.5cm の階級に 0.093 ですから，$0.093/2.5 = 0.0372$ というようになります。

しかしこれでは，連続変数を離散変数のようにカテゴリカルに区切っているだけですから，連続変数は連続変数らしくもっと細かく，連続的になるようにこの階級をどんどん短くしていくことを考えましょう。数学的には，間隔をどんどん短くしていった極限を考えることを微分というのでした。この考え方を使って，間隔を極限まで短くして確率密度を表現したものが，連続分布になるわけです。

ここで注意することがいくつかあります。まず，離散変数の時は全事象の確率質量を足し合わせると 1.0 になるのでした。連続変数の場合は微分してその密度を考えてきましたが，全体のことを考えるには微分の逆である積分の計算が必要です。つまり連続変数の場合は，全区間の確率密度を積分すると 1.0 になる，ということになります。次に，確率質量と違って確率密度の値は 1.0 を超えることもあるということです。これは密度が確率質量 (1.0 未満) を階級で除したものであることを思い出すとすぐにわかります。分母がどこまでも小さくなっていくのですから，ある点の密度はどんどん大きくなっていくしかないのです。分母が極限まで小さくなると，密度は無限大になります。それと関係して，連続変数の場合ある一点の確率はゼロであるということになっています。つまり，**確率密度は常に「区間」を伴って考えますので，ある一点の確率，というのは連続変数の場合存在しません (0 と定義します)**。これはそうしないと色々都合が悪いので，このようなルールにしたということです。面倒な言い方になるのですが，たとえば身長が 165cm である確率は，と言われるとこの定義からゼロになるのです。そうではなく，身長が 165cm 以上である確率は，とか，身長が 165cm 以上 170cm 未満の間にくる確率は，という言い方をしなければならないということです。

10.2.3 確率分布関数

さて，離散変数であれ連続変数であれ，確率的な振る舞いのすべてを書き出したものが分布として用いられるということでした。離散変数ならまだしも，連続変数の場合にすべての実現値の値を書くことは不可能ですから，これらは数学関数の形を使って表現されます。こうした関数は，離散変数の場合は**確率質量関数 (probability mass function)**，連続変数の場合は**確率密度関数 (probability density function)** と言います。「質量」と「密度」の違いに注意しておいてください。確率密度関数の場合は，細かい話をすると微分や積分の話が出てくることになりますが，この授業では積分計算をいちいちやったりしませんので安心してください。性質として，全部足し合わせると 1.0(連続変数の場合は全部の面積が 1.0) であること，確率は非負の数字であること，を把握していれば問題ありません。

また表記法についてですが，ある変数 X がある確率分布に従うことを「$X \sim$ 確率分布 (パラメータ)」の形で表現します。この $\sim$ はチルダという記号ですが，このほにゃっとしたカーブで左側の変数が右側の分布に従うことを意味するわけです。右側にくる確率分布関数には，かっこ付きで**パラメータ (parameter)** を記載します。パラメータとは分布の見た目を決める数字のことで，この数字を調整すると分布の形がかわります。形といっても Form(数式) が変わるのではなく，Shape/Figure(見た目) の形が違うということです。たとえば先ほどの図 10.1 は横一線ですし，図 10.3 は単峰のなだらかな山のような見た目をしていますが，これを関数で表す際にはパラメータにある数字を与えて図を書かせる必要がありますね。分布の形を決めるのは，パラメータの値を決めることと同じであるということを，頭の片隅においといていただけたらと思います。

10.2.4 確率関数の期待値

ここで確率分布関数の特徴を記述することについて触れておきます。確率分布とは，確率的に変動する数字の実現値と，出現確率を一覧にしたもので，確率質量関数や確率密度関数で表現されるのでした。離散変数であれ，連続変数であれ，いろいろな数字が出てくる可能性があるので，その特徴を記述する方法をみておきましょう。ここでは確率分布の平均と分散を考えます。確率分布の平均はとくに**期待値 (expectation)** と

呼ばれます。

確率的にしか得られない数字に対して，平均的にどれぐらいの数字が得られるか，は「トータルどの程度の数字が期待できるか」という意味で期待値と呼ぶのです。サイコロの例で説明しましょう。サイコロの出目は 1，2，3，4，5，6 ですが，サイコロを振って出る目の平均はどれぐらいの値になるのか？ を考えます。ここではもちろん正当なサイコロ，出目がいずれも $1/6$ の確率であることとします。確率変数 X の期待値は $E(X)$ で表し，次のように計算します。

$$E(X) = \sum x_i \times p_i$$

ここで x_i は確率変数がとりうる値，p_i はその値が出てくる確率です。そしてすべての可能性を足し合わせ ($\sum$) ます。サイコロの期待値は次の通りです。

$$1 \times \frac{1}{6} + 2 \times \frac{1}{6} + 3 \times \frac{1}{6} + 4 \times \frac{1}{6} + 5 \times \frac{1}{6} + 6 \times \frac{1}{6} = 3.5$$

実際に 3.5 という出目があるわけではありませんが，平均はこうなるということです。このように，確率分布の平均値は実現値 $\times$ その確率をすべて足し合わせたもの，と思っておいてください。たとえば，これがわかれば宝くじの期待値がわかります。2004 年のサマージャンボ宝くじ，1 ユニット，1000 万通り当たりの当選金は表 10.1 のようになります。

表 10.1　2004 年のサマージャンボ宝くじ当選金一覧

等級	当選金	本数	当選確率
1 等	2 億円	1	0.00001%
前後賞	5 千万円	2	0.00002%
組違い	10 万円	99	0.00099%
2 等	1 億円	1	0.00001%
3 等	100 万円	10	0.0001%
4 等	10 万円	100	0.001%
5 等	3000 円	100000	1%
6 等	300 円	1000000	10%
夏ラッキー賞	ラッキー賞	40000	0.4%

これを元に期待値を計算すると次のようになります。

$$200000000 \times 0.0000001 + 50000000 \times 0.0000002 + \cdots + 10000 \times 0.004 = 143.0$$

宝くじは一枚 300 円で買えますから，300 円買っても平均 143 円しか当たらないことになります。言い換えると 157 円=52% は胴元の儲けになるので，ギャンブルとしては効率が悪い部類に入ることがよく知られています[*4][*5]。

話を戻します。このようにして，(離散) 確率分布関数の平均値が計算できます。平均値だけでなく，分散も計算できます。式は次のようになります。

$$Var(X) = \sum (x_i - E(X))^2 \times p_i$$

[*4] 外国では，「宝くじは貧乏人の税金だ」などと言われることもあるようです。一攫千金を求めてつい・・・ね。

[*5] ちなみにこれは「バラ」で買った場合です。連番で買うとちょっと計算がややこしいです。

実際の出目から期待値を引いたものの二乗に，その確率をかけたものを総和するのですね。サイコロの場合は次のようになります。

$$(1-3.5)^2\frac{1}{6}+(2-3.5)^2\frac{1}{6}+\cdots+(5-3.5)^2\frac{1}{6}+(6-3.5)^2\frac{1}{6}=2.9166...$$

連続分布の場合は足し算でなく積分をすることになりますが，基本的な発想は同じです。

10.3 ベルヌーイ分布と二項分布

10.3.1 ベルヌーイ分布

さてここまでで，確率という考え方を導入しました。離散的イベントが確率的に生じる場合，離散確率分布に従う，といいます。連続的な量が確率的に得られる場合，連続確率分布に従うといいます。確率の大きさをすべて書き表したものを確率分布といい，確率分布は関数で表現されます。離散変数は確率質量関数，連続変量は確率密度関数でそれぞれの事象・量の生じやすさが表されます。

少しややこしくなってきたので，具体的で最も簡単な例をあげながら話を進めることにします。コイントスを考えましょう。コインを弾いて表が出るか，裏が出るかは確率的な事象ですね。**結果変数 (outcome variable)** は，「表」か「裏」かのどちらかになります[*6]。これしかないので，離散的な確率変数です。

このような，結果が 2 種類だけであり，毎回の試行が独立 (前に出た結果が続く結果に影響することはない) な試行のことを，ベルヌーイ試行といいます。17 世紀の数学者，ヤコブ・ベルヌーイに因んだ名前です。コイン X の表が出ることを，$X=1$，裏が出ることを $X=0$ と書くとします。表が出る確率が θ であれば，裏が出る確率は $1-\theta$ になります。すべての確率を足し合わせると 1.0 になるし，事象は表か裏しかないからです。これは次のように表現できます。

$$X \sim Bernoulli(\theta)$$

べるぬーい，のスペルが面倒ですが，先ほど説明した表記法が具体例として示されていることを確認してください。ここで $\theta=0.5$ であればこのコインは表が出るか，裏が出るかが半々だということなので，公平なコインだと言えます。マジシャンが細工をして表が出やすくなったコインというのがあるとすれば，たとえば $X \sim Bernoulli(0.8)$ のように表現できるでしょう。このように，確率分布関数の名前 (ここでは *Bernoulli*) の後ろのカッコ内にパラメータ θ を，そしてそのパラメータの値が幾つになるかで確率分布の性質を記述したことになります。このようにパラメータが 1 つだけの分布関数もありますし，複数あるものもあります。

ベルヌーイ分布関数の中身はどうなのでしょうか。$X=1$ になる確率が θ で，$X=0$ になる確率が $1-\theta$ である，というのを数式で表現するには，次のようにします。

$$P(X=k)=\theta^k(1-\theta)^{1-k} \text{ただし } k=\{0,1\}$$

ここで $P(X=k)$ は X が k になる確率を表します。k は 0 か 1 です。表が出る確率 $P(X=1)$ は $\theta^1(1-\theta)^0=\theta\times 1=\theta$，となっていますね ($x^0=1$ という指数の定義がポイント)。

10.3.2 二項分布

さて，コイントスを 2 回行ったとします。同じコインでピン，ピンと指ではねあげるのです。結果としてあり得るのは，表・表，表・裏，裏・表，裏・裏の 4 通りです。確率はそれぞれ θ^2,$\theta(1-\theta)$,$\theta(1-\theta)$,$(1-\theta)^2$ となりま

[*6] コインが地面に突き刺さって立ったらどうするんだ！というツッコミがあるかもしれませんが，「その場合は表とする」とか，ルールを決めておけばいいですよね。ここでは例なので単純な 2 種類のアウトカムだけで話をさせてください。

す。ここで表・裏と裏・表は同じ $\theta(1-\theta) = \theta(1-\theta)$ ですから，$2\theta(1-\theta)$ ですね。$\theta = 0.5$ だとすると，表が 2 回でる確率が 0.25，1 回出るのが 0.5，0 回出るのが 0.25 ということになります。この 3 つの数字を足しても 1.0 になりますから，n 回中 k 回表が出るという組み合わせもまた確率分布になります。

n 回中 k 回成功する[*7]確率を表す確率分布は，**二項分布 (binomial distribution)** といい，次の式で表します。

$$P(X = k) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$$

ここで $\binom{n}{k}$ は組み合わせの記号で，${}_nC_k$ と同じ意味です。こちらの表記法で習った人が多いかもしれません。これは二項係数とも呼ばれるもので，詳しくは高校数学の教科書に戻って確認して欲しいのですが，ここでは要するに複数回試行の成功率を考えるときには二項分布になるという仕組みを理解してください[*8]。

さて，二項分布に従う確率変数は，「何回試行したか」という試行回数 n にも依ることなので，パラメータに n を表記に追加しなければなりません。分布の形を決めるパラメータが成功率 θ と試行回数 n の 2 つになり，次のように表記します。

$$X \sim Binom(\theta, n)$$

図 10.4　二項分布の例。最上段は $n = 5, \theta = 0.2$, 中段は $n = 10, \theta = 0.5$, 下段は $n = 30, \theta = 0.8$

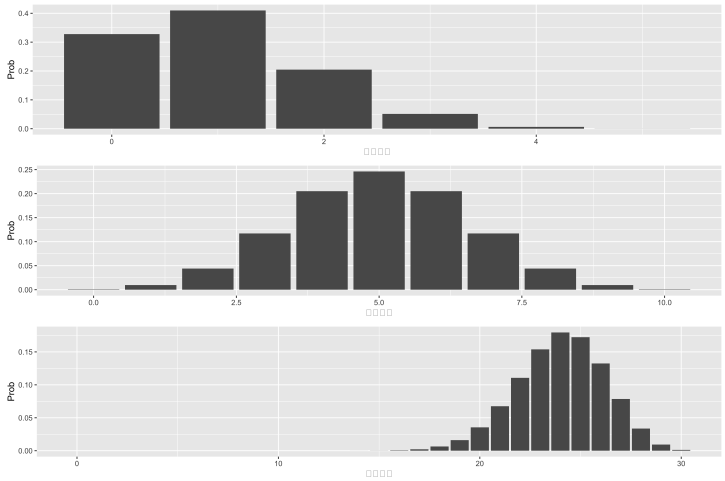

図 10.4 にはいくつかの二項分布の例を示しました。パラメータの設定はそれぞれ，最上段は $n = 5, \theta = 0.2$, 中段は $n = 10, \theta = 0.5$, 下段は $n = 30, \theta = 0.8$ となっています。同じ関数ですが，パラメータ n, θ の違いで見た目が変わっていることに注意してください。

[*7] 表が出る，でもいいのですが 0/1 の二択は裏表以外にも，男女，正誤，合否，生死など色々なもののメタファになりますので，ここは表が出ることを成立する，成功する，という言い方にしたいと思います。

[*8] 一応少し補足しておきます。n 個の中から順番を区別して取り出す方法が順列，順番の区別をしない (裏・表＝表・裏) のが組み合わせというのでした。順列は n 個から k 個取り出すとき ${}_nP_k = n \times (n-1) \times (n-2) \times \cdots (n-k+1)$ という数だけあります。この中で重複している組み合わせは ${}_kP_k = k \times (k-1) \times \cdots 1 = k!$ ありますので，組み合わせは $\binom{n}{k} = \frac{{}_nP_k}{k!}$ 個，ということになります。

10.4 正規分布の形

今度は連続的な確率変数の代表格である**正規分布 (normal distribution)** について説明します。心理学を始め，統計的アプローチでこの正規分布は中心的な役割を担います。統計モデルのほとんどは正規分布帝国に含まれる，といわれるほどです (三中，2018)。数式的には小難しいのですが，その意味的なところを理解できるように解説します。

10.4.1 正規分布ができるまで

正規分布の始まりは，ドイツの物理学者カール・フリードリヒ・ガウスの研究からです。彼の貢献に敬意を表して，正規分布のことを**ガウス分布 (Gaussian distribution)** とも呼びます。彼が考えていたのは**誤差 (error)** に関することでした。天文学ではケプラーが何十年にもわたる観測データを集めたりしていましたが，人間が観測するデータには誤差が含まれています。この誤差をなんとかハンドリングしたいというのがそもそものモチベーションです。

誤差は**系統誤差 (systematic error)** と**偶然誤差 (random error)** に分かれます。系統誤差は機械の精度や測定者の癖などで，必ず一方向にずれるもの。これはその機械の特徴や測定者の癖がわかれば，修正することが可能です。一方，偶然誤差の方は「偶然生じるもの」なので，どのように出てくるのかは全然予測できません。他の何ものとも相関しない (関係が見出せない) というのが特徴です。さらに，誤差は，「いろいろな原因が積み重なって生まれる」と考えられます。たとえば天体観測の場合，レンズの歪み，気温や湿度などの条件，観測者のちょっとしたミス・・・これらの積み重ねで「正しい値からずれる」と考えるのです。

天体観測の例で考えましょう。ある星の位置を測定していたとします。星がちょうどスコープの中に入るように，天体望遠鏡の位置を左右に調整していくとします。話を簡単にするために，右側にずらすことをプラス，左側にずらすことをマイナスと考えます。さて，ではまず何かの原因で，測定値が本当の値からちょっとプラスの方向にずれる，ということがあったとしましょう。次に第二の「誤差の原因」があり，それが今度はちょっとマイナスに働いたとします。さらに第 3 の「誤差の原因」があり，それが今度はちょっとプラスに働いたとします。誤差は何段にも何段にも重なっていくとすると，途中には「同じぐらいの大きさで向きが違う」誤差，というのも含まれてくるでしょう。これは測定上はプラス・マイナスの大きさが相殺し合って，表に出てこないことになります (図 10.5)。

誤差の大きさはさまざまですが，たとえば大きなプラスの誤差は (→→)，標準的なサイズの誤差 (→) が二度連続して出た，と考えることもできます。積み重なる原因はたくさんたくさんあるのですから，この際ちょっとぐらい増えても変わりません。また，どうせ足し合わせるんですから，順番を入れ替えても構いません。そうすると，相殺のペアはあちこちで見つけることができるようになります。結局プラスに何回，マイナスに何回，という組み合わせがどれだけ出るかという話になります。

さて，誤差がプラス側に出るのを 1，マイナス側に出るのを 0 と表したとして，その試行を何度も何度も繰り返し，結果的に「1 が 1 つだけ」「0 が 1 つだけ」「1 が 2 つ」「0 が 2 つ」「1 が 3 つ」・・・「全部 1」「全部 0」というパターンを数え上げていくとすると，これはどういう形になるでしょうか。

そう，**二項分布**ですね！

復習です。n 回試行したうち，k 回表が出る (成功する) 確率を表す確率分布のことを，二項分布というのでした。今回の例では $n \to \infty$，つまり何度も何度もコイントスをする，無限回する，というイメージで考えてください。そのうち，たまたま 1 回表がでた (ちょっとプラスになった) のは何回か，2 回表が出た，3 回出たのはどうか，・・・・全部表だった場合はどうか，という時の組み合わせの形を考えていきます。その行き着く先

図 10.5　色々な大きさの誤差が重なり合う。時には同じ大きさで相殺し合うことも。

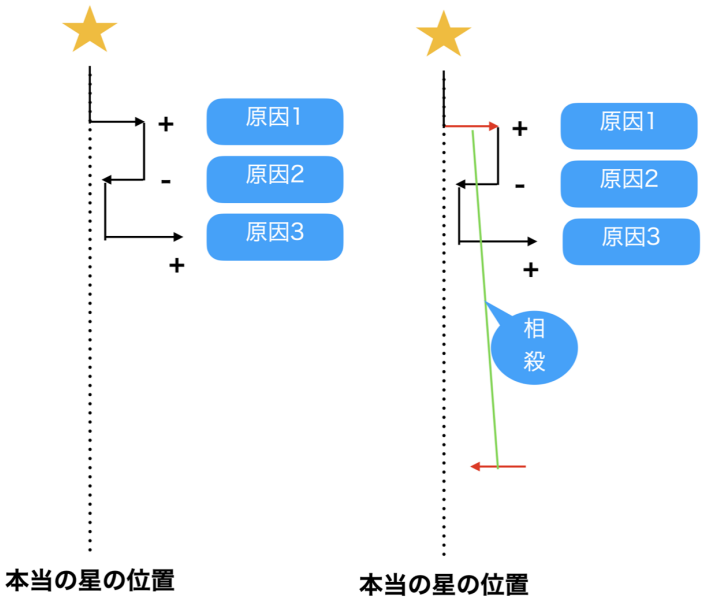

図 10.6　積み重ねて考えるので順番を入れ替えても良い

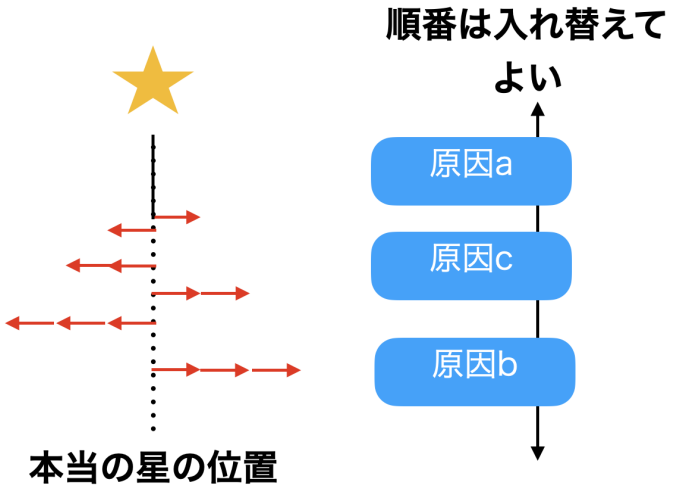

が，今回の**正規分布**なのです。

違った例から説明してみましょう。みなさんは**ゴルトンボード (Galton board)** というおもちゃをご存知でしょうか (図 10.7)。釘が等間隔に打ち付けられている板で，その上からパチンコ玉を落とすのです。パチンコ玉は釘にあたります。その時，右側に落ちるか左側に落ちるかの確率は $1/2$ ですね。たとえば左側に落ちたとしましょう。落ちた先にもまた釘があり，そこに当たって右にいくか左に行くかは，また $1/2$ の確率になります。右側に落ちていたとしても同様で，次の釘で左右のどちらに弾かれるかは半々です。2 段目までで考えると，「左，左」に来たケースと「左，右」あるいは「右，左」に来たケース，「右，右」に来たケースがありますが，それぞれのケースになる確率は $0.25 : 0.5 : 0.25$ ですね。これは二項分布の $\theta = 0.5, n = 2$ のケースですが，この n がどこまでも連なっている，つまり釘の段がどこまでも続いているのが正規分布の世界であり，それを模したのがゴルトンボードです。

図 10.7　二項分布と正規分布の関係を表すゴルトンボード。図は Wikipedia の「ゴルトンボード」の項より。

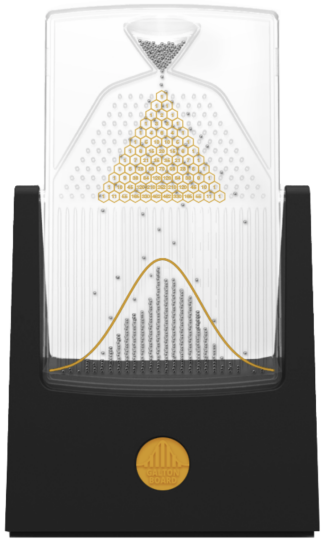

このボードの下には左右対称のなだらかな山の形が描かれていますが，これが正規分布の形です。美しいですね。

さて，「誤差は偶然生じる」「誤差は多段階で積み重なる」ということから，二項分布の極限を考えました。その結果得られる形のことを正規分布といいます。正規分布は連続値の確率分布の代表格で，さまざまなところにその形を見出すことができます。この確率分布のポイントは左右対称になっていることと，より極端な値はより出てきにくい，ということです，つまり誤差を生み出すさまざまな要素がすべてプラスに働くこと，すべてマイナスに働くことというのはめっっっっっったにない，ということです。

たとえば心理学で考えたい性質，性格とか社会的態度といった心理学的傾向は，何がその形成要因になっているかわかりません。親の学歴，親の年収，育った地域の教育水準，幼稚園に通ったのか保育園に通ったのか，食事は肉と魚どっちが多かったかとか，それはもう無数の原因があると思います。すべてがその心理学的傾向に影響したとして，それぞれが「高かった」「低かった」「よかった」「幼稚園だった」「魚だった」というように分岐していくと，無数のパターンが考えられます。その結果，人の心理学的傾向はどのように分布するかというと，とある平均的な程度を中心にして，「やや外向性が高い人」「やや不安定性が高い人」といった相対的な比較がされるようになり，かつ「極端に外向性が高い人」というのは滅多にいない，ということになるでしょう。つまりそうした性質は正規分布に従うと考えられるのです。学力なども同様です[*9]。

正規分布はこのように，さまざまな影響源による累積的影響の帰結として捉えることができます。意味的には，誤差のように確率的な散らばりの形を表すものでもあり，心理学的傾向の例のように集団レベルでの性質が従う分布としてとらえられることもあります。この形状をとくに Normal Curve ということもありますが，これの中心から外れることが Abnormal だというわけではありませんので，最近は Normal というより Gaussian という形容詞で呼ぶことが多いのかもしれません[*10]。

[*9] 収入などは偶然性による影響ではなく，人為的な傾向が入ってくるので正規分布になりません。

[*10] 平均的な人間が正常 normal で，平均から逸脱した人間は異常 abnormal である，という考え方は人類がその評価基準を社会的なものに求めるようになったからであり，このことをニーチェは「神は死んだ」と表現したわけです。正義や善悪を神の視点で考えるのではなく，人間同士の相対的な態度で考える態度です。しかし集団的傾向の中心にいることが正しいことを意味するものではないことは，みなさんもお分かりいただけると思います。

10.4.2 正規分布を特徴づける

正規分布の形で大事なのは,「位置」と「幅」です。系統誤差がどれぐらい出てくるのか, に該当するのが位置です。偶然誤差は相殺し合うので平均 0 になります。偶然誤差がどれぐらい出てくるのか (散らばるのか) については, 幅で特徴付けることができます (図 10.8)。

図 10.8 正規分布で重要なのは位置と幅

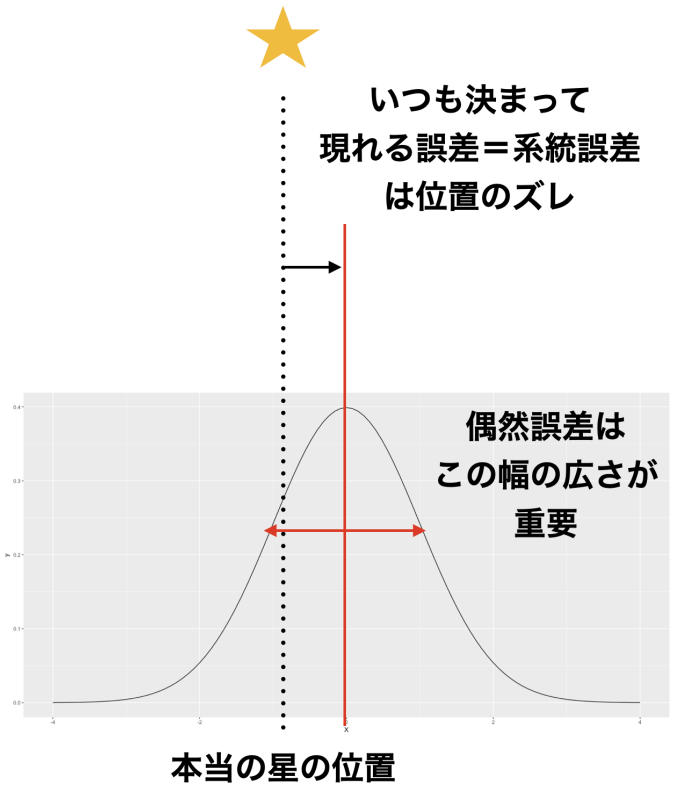

ところで, 正規分布の幅というのはどこで測れば良いのでしょう？ 分布の形はなだらかな山形ですから, 標準偏差がどこを表しているのかイメージしにくいのではないでしょうか。もしこの誤差の分布が三角形であれば, その幅を定義するには底辺の長さを使えば良いでしょう。しかし正規分布は緩やかなカーブをしていますし, 理論的にその裾野は $-\infty$ から $+\infty$ まで広がっているのです。

これについては, 長沼 (2016) がとてもわかりやすい解説をしてくれています。すなわち, この正規分布のカーブを飛行機が飛んでいると考えれば特徴が見つけやすいというのです (図 10.9)。飛行機は操縦桿を引くと機首が上がり, 上に上がります。操縦桿を押すと機首が下がり, 下に下がります。正規分布カーブのように飛ぶ時は, 二箇所で操縦桿が水平になるシーンが出てくるはず。そこを結ぶとカーブの幅が定義できます。この幅の長さが標準偏差 2 つ分に該当します。平均を挟んで, 左右に標準偏差 1 つ分ずつでてくるわけですね[*11]。

ということで, 正規分布は位置と幅が重要だということがわかりました。記述統計でいえば, 位置は平均で

[*11] 数学的には, この点は変曲点と呼ばれます。関数を微分すると変化量がわかります。距離 (と時間) から速度がわかるようなものですね。変化量をさらに微分すると加速度がわかります。この加速度に対応するのが操縦桿の位置です。この加速度がゼロになるところは, 関数を 2 階微分したものがゼロになる点として算出できます。

図 10.9　正規分布の幅を測る位置。長沼 (2016)を参考に作図しました。

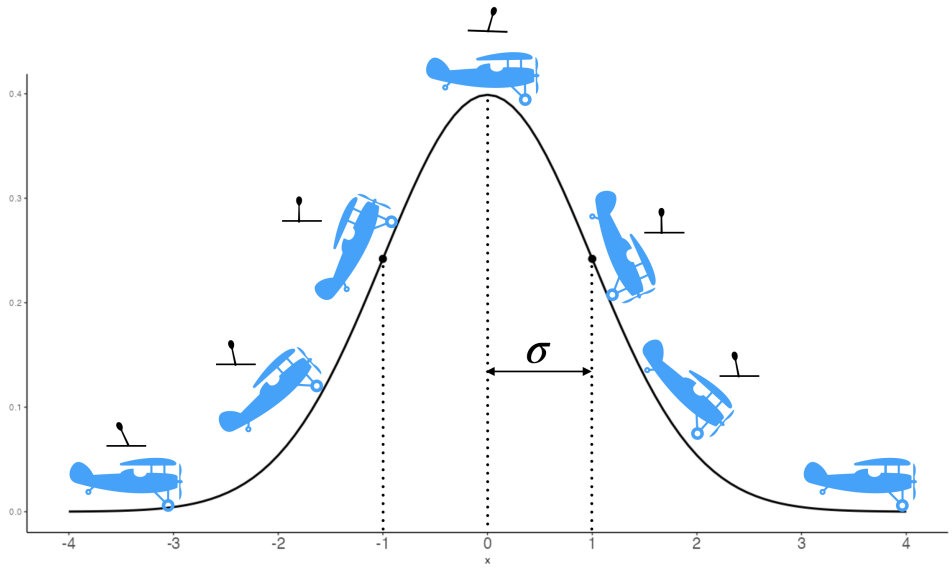

す。左右対称な分布の中心にあたりますから，これが適切な代表値でしょう。同様に幅は標準偏差で考えることができます。数学的に正規分布を記述する場合，ある変数 X が正規分布に従うことを，$X \sim N(\mu, \sigma)$ と記述します。ここで N は Normal の N です。μ は平均を表しており，ギリシア文字 μ は「ミュー」と読みます。σ は標準偏差を表しており，ギリシア文字 σ は「シグマ」と読みます。総和記号 $\sum$ はギリシア文字 S の大文字 Σ からきていますが，これは小文字の s です。

正規分布の表記法は，テキストによっては $N(\mu, \sigma^2)$ と書かれることも少なくありません。σ^2 は標準偏差 σ の二乗ですから分散を表しています。二乗するかしないかの違いはありますが，幅を表している数字ですし，二乗する/平方根をとる，という操作で相互に変換可能ですから，どちらで表現しても間違いではありません。本講義では σ で表記を統一したいと思います[*12]。

図 10.10 には，さまざまな平均値と標準偏差を持った正規分布の形を描いてみました。ここに描かれている曲線は**すべて正規分布です**。全然違うようにも見えますが，平均と SD の値の取り方によっては，このように見え方としての形 (Shape,Figure) は変わります。が，これを描いている数式としての形 (Form) は同じであることに注意してください。

図の中心にある緑の線が**標準正規分布**と呼ばれる，その名の通り標準的な形の正規分布です。これは平均が $\mu = 0$，SD が $\sigma = 1$ の分布です。平均値が変わることは，その位置がずれることです。標準正規分布と同じ形をしていて位置が右にずれている赤い線がありますが，これは $\mu = 1, \sigma = 1$ のときの形状です。

標準偏差が変わることは，その幅が変わることになります。標準偏差を小さくすると分布の山は尖っていき，標準偏差を大きくするとなだらかな分布に変わっていきます。図の最も左にピークを持っている分布は，$\mu = -2, \sigma = 0.5$ にしたときの正規分布の形です。位置が左にずれ，山が尖っていることがわかりますね。最もなだらかなラインは $\mu = 1, \sigma = 3$ にして描きました。ほとんど横ばいのような形ではありますが，これでも左右対称で山形の正規分布の一種です。

一口に正規分布と言っても，パラメータの設定によって見え方が大きく変わることがお分かりいただけたの

[*12] 心理統計のテキストでは，一般的に σ^2 で表すことの方が多いようです。数学や統計ソフトウェアでは二乗せずに計算することが多く，たとえば**確率的プログラミング言語 (probabilistic programming language)** の Stan がもっている正規分布関数は σ として扱っています。

図 10.10 さまざまな幅･位置の正規分布

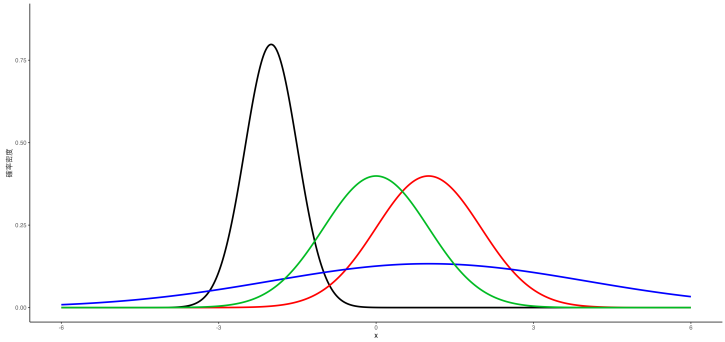

ではないでしょうか。言い換えると，パラメータさえ調節すればさまざまなデータにも応用できそうです。これが正規分布帝国が幅広く用いられる 1 つの理由であると言えるでしょう。

10.5 正規分布の関数

正規分布の形状は，ガウスが発見した確率密度関数で描かれます。その関数は次のような形をしています。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \tag{10.1}$$

ここで $\mu = 0, \sigma = 1$ という標準化されたスコアであれば，この関数の形は一気に簡単になります。標準化された正規分布のことを**標準正規分布 (standard normal distribution)** といいますが，次の式になります。

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{x^2}{2})$$

さて，数式が出てきてびっくりされた方もいるかも知れません。しかし実際は，この複雑にみえる数式も計算機を使って値を出したり確率を計算したりしますから，式を丸暗記してどこかで使わないと，というようなシーンはほぼありません[*13]。それよりも正規分布の形や，ソフトウェアはなんでもいいですから計算機で必要な値を算出できるようになることの方が重要です[*14]。

ここでは統計環境 R をつかった確率分布の数字を算出する方法を説明します。R は基本的な確率分布関数を最初から持っており，これを呼び出すだけで使えます。正規分布は `norm`，二項分布は `binom` など，英語名を省略した形が関数になっています。そのほかにも色々な分布があって，たとえば t 分布であれば `t`，χ^2 分布であれば `chisq`，F 分布であれば `F` などとします。しかし，その関数だけでは使えません[*15]。関数の略称の前に，文字を付け加えることで確率密度関数をさまざまな角度から捉えた数字を提示します。そのルールを表 10.2 にまとめました。

`XXX` のあたりが少しわかりにくいですが，ここには確率分布を表す関数名が入ると思ってください。正規分布でしたら `norm` であり，これに d, p, q, r をつけることで正規分布の確率密度，累積確率，確率点などの値を返してくることになります。

[*13] もちろん腕に自信がある人は，積分計算で答えを計算して出してもらっても構いません。

[*14] 計算機が今ほど普及していなかった頃，心理統計のテキストにはたいてい付録として数表がついているものでした。代表的な関数については，ある程度計算したものの一覧表があると，計算機を使う必要がないから便利だったのですね。数表の例はセクション 10.8.2,Pp.160 を参照してください。

[*15] とくに `F` は R の中では `FALSE` の予約語になっており，それだけで偽/0/スイッチオフ，のような特別な意味を持っています。

表 10.2　R の確率に関するルール

用途	コード名 XXX の関数名	説明
確率密度	dxxx(q)	q は確率点を表す。コード名が norm なら dnorm(q) となる。
累積確率	pxxx(q)	q は確率点を表す。コード名が norm なら pnorm(q) となる。
確率点	qxxx(p)	p は確率を表す。コード名が norm なら qnorm(p) となる。
乱数	rxxx(n)	n は乱数の数を表す。コード名が norm なら rnorm(n) となる。

図 10.11 に dXXX，pXXX，qXXX が何を表すかを図示しました。確率密度 d は関数の高さを意味します。累積確率 p は下限から指定した確率点 (x 座標，q で表す) までの面積を意味します。また，下限からの面積が p になる時の x 軸上の座標 q を求めることもできます。

図 10.11　dXXX，pXXX，qXXX の示すところを確認しよう

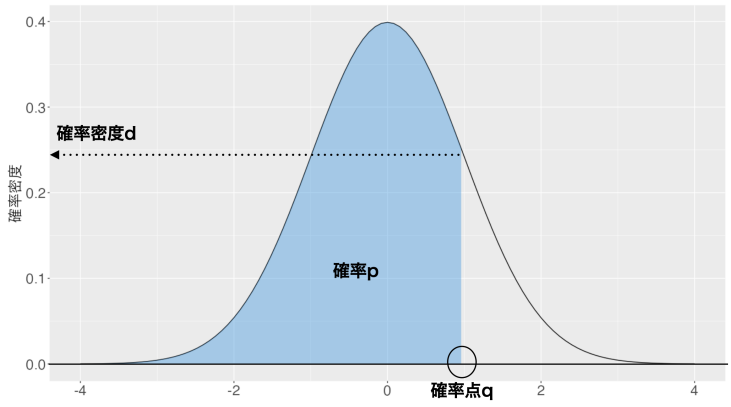

具体例を見てみましょう。R で次のように入力し，実行した例を示します。

code : 10.1　確率に関する関数使用例

```
1       dnorm(x = 0, mean = 0, sd = 1)
2       pnorm(q = 1.0, mean = 0, sd = 1)
3       qnorm(p = 0.841, mean = 0, sd = 1)
4       rnorm(n = 10, mean = 0, sd = 1)
```

R の出力 10.1: 確率に関する関数の出力例

```
> dnorm(x = 0, mean = 0, sd = 1)
[1] 0.3989423
> pnorm(q = 1.0, mean = 0, sd = 1)
[1] 0.8413447
> qnorm(p = 0.841, mean = 0, sd = 1)
[1] 0.9985763
> rnorm(n = 10, mean = 0, sd = 1)
[1] -1.00458071 -1.16956265  0.59980728 -0.07192335  0.66660905 -0.10629118 -
0.94452719 -0.04108743  2.39762300 -0.10580504
```

1 つずつ確認しましょう。dnorm(x = 0, mean = 0, sd = 1) は $\mu = 0, \sigma = 1$ の正規分布における，確率点 0 の確率密度，すなわち正規分布曲線の高さを示しています。

pnorm(q = 1.0, mean = 0, sd = 1) は $\mu = 0, \sigma = 1$ の正規分布において，確率点 1.0 までの面積を求めています。0.841 ですから 84.1% ですね。これは数式で言うところの $\int_{-\infty}^{1.0} f(x)dx$ を計算した結果，数表でいうところの $P(0 \leq Z \leq 1.0) = 0.341$ に対応しています[*16]。

qnorm(p = 0.841, mean = 0, sd = 1) は $\mu = 0, \sigma = 1$ の正規分布において，$-\infty$ からの面積が $p = 0.841$ になるときの確率点を答える関数です。先ほどの関数とは逆の操作ですね。ちょうど 1.0 になるべきなのですが，0.9985763 なのでほぼ 1.0 ということでよしとしてください。

こうした関数を使うことで，たとえば 0.3 から 1.0 までの面積は，pnorm(q = 1.0, mean = 0, sd = 1) - pnorm(q = 0.3, mean = 0, sd = 1) とすることで算出できます。実際にはこうした計算をすることは稀ですが，確率分布の関数をどのように使うかは想像できるようにしておいてください。

また最後の rnorm については説明がまだでした。関数 rnorm(n = 10, mean = 0, sd = 1) を実行すると，10 個の数字が出てきています。10 個というのは関数の中で $n = 10$ と設定したからです。幾つに設定しても構いませんが，さて出力される数字はなんでしょうか。

これは乱数といって，なんの規則性もない数字の連なりのことです。1 つ 1 つの数字の現れ方には規則性がないのですが，長い目で見ると正規分布にしたがっているといった，確率変数の実現値を擬似的に作り出すのがこの関数なのです。このようにコンピュータには擬似乱数発生装置が用意されていて，関数の形がわかっている代表的な確率分布であれば，そこからどういう数字が出てくるのかシミュレーションしてみることができるようになります。たとえば先ほど図 10.1 で，サイコロを 100 回投げた例を説明しましたが，アレは実際に 100 回投げたわけではありません。すみません。この乱数発生機能を使って，擬似的に一様分布する乱数を作ったのでした。皆さんも RPG などをしていて敵に出くわす，敵が攻撃してくる，というシーンを経験したことがあると思いますが，あれも機械の中で乱数を振っていて出くわしたかどうか，攻撃するか逃げるか，攻撃するとしたらどの程度 HP が減るかということを擬似的に計算しています。ソーシャルゲームなどでは「ガチャを回す」ということがありますが，あれもプログラムによってどのような数字が出るか計算済みです。偶然を，確率分布の力と計算機の能力で制御しているのです。乱数の使い方は，統計や心理学の研究上でも役に立ちます。具体的には後の講義で触れることになりますが，乱数によって確率的な振る舞いを近似し，データがどのような特徴を持つかを考えることができるようになります。この話は長くなりますのでひとまず横に置いておいて，先を急ぎましょう。

10.6 標準正規分布の利用

最後に (標準) 正規分布をどのように利用するかについて，少しだけ触れておきます。

正規分布は誤差だけでなく，集合的な性質を見るときにもよく現れるという話をしました。たとえば，大学入試共通試験の点数の分布はきれいな正規分布になっていたりします。心理学で扱う心理変数にも正規分布が仮定されます。というのも，人の行動を決めるのには，生まれてから今まで無数の選択を繰り返し，その積み重ねで出てきていると考えられるからで，そうしたデータをたくさん集めると (ゴルトンボードのように) 正規分布になると考えられるからです。

ここで次のように考えてみましょう。手元に何人かぶんのデータがあったとします。理論的にいって，このデータは正規分布に従うと無理なく仮定できるとします。手元のデータは数十，数百ぐらいしかなかったとしても，さっきの乱数の話のように，正規乱数に従う数十，数百の実現値があると考えると，この標本分布も正規分布を近似していると言えるかもしれません。であれば，このデータをつかってある種の推測ができるよう

[*16] 数表は確率点 0 からの差分で表現しますので，$-\infty$ から 0 までのちょうど半分の確率を足して，$0.5 + 0.341 = 0.841$ になります。詳しくはセクション 10.8.2，Pp.160 参照。

になります。

皆さん，模擬試験で「あなたの偏差値は XXXX です」とか「もしこの試験を 10000 人が受けていたとしたら，あなたは XXX 番目です」というフィードバックを受け取ったこと，ありませんか？繰り返しになりますが，学力テストのようないろいろな要因が絡むもの (ex. 本人の努力，使ってるテキスト，学校の雰囲気，テスト会場の気温と湿度，家庭環境，子供の頃の経験‥‥) は，正規分布に従うと考えられ，全体が正規分布するのなら，その相対的な位置は正規分布の式から推定できるので，このような推測が成り立つのです！

この授業のテーマは「見えないものを見るための心理統計」でした。その一端がここから伺えます。本当に 1 万人もテストを受けているとは言えない模擬試験でも，分布の仮定から「実際には見えない位置」まで推測できちゃうのです。

正規分布は平均と標準偏差で特徴付けられ，それがどういう値になっているかはわかりませんが，このデータを**標準化**すればそのことを気にする必要もなくなります[*17]。標準正規分布はその特徴がよくわかっています。数表や計算機を使うと特定の範囲の面積も明らかになります。たとえば正規分布は平均 ±1 標準偏差の中に全体の 68.2% が，平均 ±2 標準偏差の中に全体の 95.4% が，平均 ±3 標準偏差の中に全体の 99.7% が含まれるのです。であれば，標準化したスコアが 1 であれば全体の上位 15.8% に，標準化したスコアが 2 であれば全体の上位 2.2% にいると言えます[*18]。この確率を 1 万人換算すれば，「偏差値 60 のあなたは上位 15.8%」とか「偏差値 70 のあなたより上には 227 人しかいません！」といったことが言えるようになります。

この話を数式で表現しておきましょう。

1. データ x が正規分布にしたがっている，というのを $x \sim N(\mu, \sigma)$ と書く。
2. データを標準化する。$z_i = \dfrac{x_i - \mu}{\sigma}$
3. $z_i \sim N(0,1)$ より，標準正規分布の特徴を使って推測する。

ここで第二のステップ，標準化そのものは，データが正規分布にしたがっていると言えなくても行える計算作業であることに注意してください。集合的なデータが正規分布しているという仮定と組み合わさることではじめて，推測につかえるようになります。推測に用いる統計学，**推測統計学 (inferential statistics)** は後期に入るとじっくり取り掛かることになります。ここでは正規分布の特徴の活用例として示すにとどめます。

10.7 課題

■問題 1 標準正規分布 $N(0,1)$ において，$P(Z \leq 1.0) = 0.8413$ である。$P(-1.0 \leq Z \leq 1.0)$ はいくつか。

1. 0.1587
2. 0.3413
3. 0.6826
4. 0.8413

■問題 2 $X \sim N(50, 8)$ において，$P(X \leq 58)$ を求めるための標準化後の z 値はどれか。

1. $z = 1.0$

[*17] 標準化したスコアについてはセクション 6.3.1，Pp.87 を参照。

[*18] R を使って計算をしました。関数を利用して `1-pnorm(q=1,mean=0,sd=1)=0.15865`，あるいは `1-pnorm(q=2,mean=0,sd=1)=0.02275013` とします。

2. $z = 1.5$
3. $z = 6.25$
4. $z = 0.145$

■問題 3　身長が平均 170cm, 標準偏差 6cm の正規分布に従うとき, 以下を計算せよ。

1. 身長が 180cm 以下の人の割合
2. 身長が 160cm 以上 175cm 以下の人の割合
3. 上位 10% に入るために必要な身長

■問題 4　大学入試の偏差値が平均 50, 標準偏差 10 の正規分布に従うとき, 以下を計算せよ。

1. 偏差値 70 以上の受験生の割合
2. 1 万人が受験したとき, 偏差値 70 以上は何人か（整数で答えよ）
3. 偏差値 40 以上 60 以下の「普通」とされる受験生の割合

■問題 5　心理テストの得点が平均 100, 標準偏差 15 の正規分布に従うとする。このテストを 1000 人が受験したとき, 以下の問いに答えよ。

1. 得点 130 以上の「優秀」群は何人か
2. 得点 70 以下の「要支援」群は何人か
3. 得点 85 以上 115 以下の「標準」群は何人か

10.8 補遺

10.8.1 標準正規分布の関数形

すでに述べたように，正規分布の関数形，式 10.1 を必ずしも覚えておく必要はありません。しかし，どうしてこのような形になっているかを理解すると，この式も少しはわかりやすくなりますので，少し解説してみましょう。

まず今から求めたいのは，誤差の確率分布ですから，そこからいくつか満たすべき条件というのが出てきます。確率という数字は非負です。また，ここでは連続変数ですから，確率密度関数の面積を積分すると 1.0 になる必要があります。つぎに誤差の分布ですから，中心から外れるほどその出現確率が少なくなるようにならなければなりません。しかも傾向がないので左右対称です。これらの条件を満たすような関数を作ることを考えます。

左右対称の分布からいきましょう。左右対称の関数として，真っ先に思い浮かぶのは $y = x^2$ のような二次式ではないでしょうか (図 10.12 の 1 段目左)。ただ $y = x^2$ だと原点から離れるほど大きくなってしまいます。誤差は逆で，一箇所をピークにどんどん下がっていって欲しいので，$y = -x^2$ にした方が良さそうです (図 10.12 の 1 段目右)。さてそうすると，今度は値 y がすべてマイナスになってしまいます。確率関数を作ろうとしているのにこれはまずい。確率はすべて正の数字でなければならないからです。ここで**指数関数 (exponential function)** を導入します。指数関数とは $y = e^x$ という形をしています。これは $y = exp(x)$ とも書き，自然対数 e を何乗するかという関数です[*19]。関数の形をグラフにすると，図 10.12 の 2 段目左のようになります。指数の定理から，指数 x がマイナスであるとは逆数にするという意味ですから，マイナスになることはありません[*20]。この関数を先ほどの $y = -x^2$ と組み合わせて，$y = exp(-x^2)$ とします (図 10.12 の 2 段目右)。この段階で，すでに正規分布っぽい形にはなっているのです。すなわち，左右対称で両端に行くほど小さくなる関数ですね。足りないのは，パラメータ μ, σ によって位置と幅を調節する機能をつけたいこと，面積が 1 になるように整えたいこと，この 2 点です。これを追加します。

そしてパラメータを追加します。位置をコントロールできるようにするには，x に数字を足したり引いたりしてやればいいことになります。平均を μ として，$y = exp(-(x-\mu)^2)$ とすることでこの問題は解決します (図 10.12 の 3 段目左)。次に幅をコントロールしたいですね。これは x の倍率を調節してやれば良く，x を分散 σ^2 で割ってやることで対応できます。すなわち，$y = exp(-\frac{x^2}{\sigma^2})$ です (図 10.12 の 3 段目右)。位置と幅の両方をコントロールするには，$y = exp(-\frac{(x-\mu)^2}{\sigma^2})$ とすれば良いでしょう。

あとはこの関数が，積分して面積 1 になるように整えてやる必要があります。このようにしてやると，関数が確率を表す数字として扱うことができるようになるからです。この関数の面積を計算して，その面積で割ってやればいいことになりますね。ただこの複雑な関数，面積を求めるのが大変難しい。ただの積分ではうまくいきそうにないのです。その数学的な問題を突破したのがガウスで，凄すぎるのでガウス積分と名前がついているほどですが，これについては説明すると長くなるので解説は他所に譲り[*21]，答えだけ言っておくとその面積は $\sqrt{2\pi\sigma^2}$ になります[*22]。ということで，その面積で割ってやるように関数を規格化しましょう。そうすると

例の式になります。

図 10.12　正規分布の確率密度関数導出の経緯

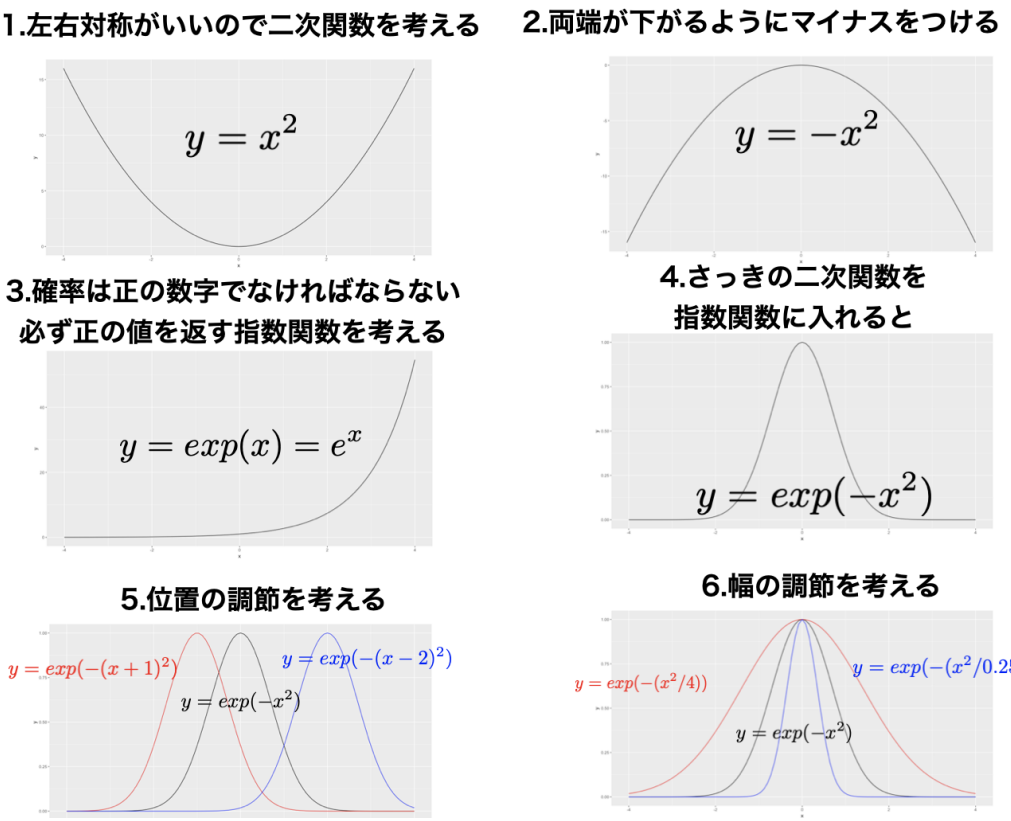

10.8.2　数表とその見方

表 10.3 が正規分布に関する値の一覧表です。ここには，z と lower , upper とした列があります。lower は $P(0 \leq Z \leq z)$ の範囲を，upper は $P(Z \geq z)$ の範囲を表しています (図 10.13)。

ここで z 列は今知りたい確率点，今回でいえば $z = 0.3$ とか $z = 1.0$ のことになります。次の lower= $P(0 \leq Z \leq z)$ 列には，$z = 0$ からその求めたい確率点までの面積が入っています。たとえば $z = 0.3$ のところを見ると，$P(0 \leq Z \leq 0.3) = 0.118$ となっていますから，この確率が 11.8% であることがわかります。今回は 0.3 から 1.0 までの面積が知りたかった訳ですが，それは直接この表には載っていません。ただ，$z = 1.0$ の数字を見ることができますから，それを参照して $P(0 \leq Z \leq 1.0) = 0.341$ がわかります。0 から 0.3 までが 0.118 で，0 から 1.0 までが 0.341 ですから，0.3 から 1.0 までは $0.341 - 0.118 = 0.223$，22.3% だと読み取ることができます。

この数表には $P(Z \geq z)$ の確率も載っています。たとえば upper= $P(Z \geq 0.3) = 0.382$ ですから，0.3

*19 e は何かというと 2.718... という実数です。微分しても変わらない数字ということで，数学の世界では重宝されます。e についてはマオール (1999)が読み物として楽しく理解できます。

*20 指数は $a \neq 0$ のとき，$a^0 = 1$，また，$a^{-n} = \dfrac{1}{a^n}$ と定義されています。

*21 こういうの見ると，「あ，ずるい。著者め逃げたな」と思いませんか。私なら思います。そう思われると悔しいので，参考図書として西内 (2017)をあげておきます。また長沼 (2016)の P.62–69 も参考になります。

*22 π は 3.141592... という実数です。円周率ですね。面積になぜ円周率が出てくるのか，それがガウスの凄いところです。

以上になる確率は 38.2% ということがわかります。こうした数表を駆使することで，ある範囲からある範囲までの面積がいくらか，という計算をできます。

またたとえば，確率点がマイナスの場合はどうするか，というのを疑問に思われる方もいるかもしれません。その時は，正規分布が左右対称であることを思い出してください。$z = -0.3$ 以上の面積が知りたい，という時は，まず $z = 0.3$ のときの数字から $P(Z \geq 0.3) = 0.382$ を見つけます。左右がひっくり返っても同じですから，$P(Z \leq -0.3) = 0.382$ になります。-0.3 までの面積がわかっても，知りたいのは -0.3 以上です。しかし確率はすべての面積が 1.0 ですので，$P(Z \geq -0.3) = 1 - 0.382 = 0.618$ と計算できます。あるいは，$P(0 \leq Z \leq 0.3) = 0.118$ で，平均 $z = 0$ までの面積が半分，すなわち 0.5 ですから，$0.5 + 0.118 = 0.618$ と求めても構いません。ともかく，半分しかない数表であっても，これを使えばさまざまな面積計算ができるということです。

図 10.13　数表の見方。上の段が $P(0 \leq Z \leq z)$，下の段は $P(Z \geq z)$ のイメージ図

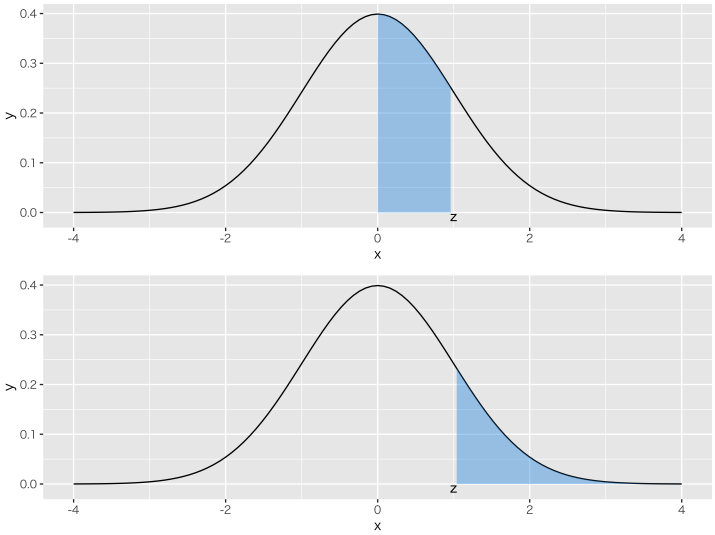

表 10.3　標準正規分布の表

z	lower	upper	z	lower	upper	z	lower	upper	z	lower	upper	z	lower	upper
0.00	0.000	0.500	0.60	0.226	0.274	1.20	0.385	0.115	1.80	0.464	0.036	2.40	0.492	0.008
0.01	0.004	0.496	0.61	0.229	0.271	1.21	0.387	0.113	1.81	0.465	0.035	2.41	0.492	0.008
0.02	0.008	0.492	0.62	0.232	0.268	1.22	0.389	0.111	1.82	0.466	0.034	2.42	0.492	0.008
0.03	0.012	0.488	0.63	0.236	0.264	1.23	0.391	0.109	1.83	0.466	0.034	2.43	0.492	0.008
0.04	0.016	0.484	0.64	0.239	0.261	1.24	0.393	0.107	1.84	0.467	0.033	2.44	0.493	0.007
0.05	0.020	0.480	0.65	0.242	0.258	1.25	0.394	0.106	1.85	0.468	0.032	2.45	0.493	0.007
0.06	0.024	0.476	0.66	0.245	0.255	1.26	0.396	0.104	1.86	0.469	0.031	2.46	0.493	0.007
0.07	0.028	0.472	0.67	0.249	0.251	1.27	0.398	0.102	1.87	0.469	0.031	2.47	0.493	0.007
0.08	0.032	0.468	0.68	0.252	0.248	1.28	0.400	0.100	1.88	0.470	0.030	2.48	0.493	0.007
0.09	0.036	0.464	0.69	0.255	0.245	1.29	0.401	0.099	1.89	0.471	0.029	2.49	0.494	0.006
0.10	0.040	0.460	0.70	0.258	0.242	1.30	0.403	0.097	1.90	0.471	0.029	2.50	0.494	0.006
0.11	0.044	0.456	0.71	0.261	0.239	1.31	0.405	0.095	1.91	0.472	0.028	2.51	0.494	0.006
0.12	0.048	0.452	0.72	0.264	0.236	1.32	0.407	0.093	1.92	0.473	0.027	2.52	0.494	0.006
0.13	0.052	0.448	0.73	0.267	0.233	1.33	0.408	0.092	1.93	0.473	0.027	2.53	0.494	0.006
0.14	0.056	0.444	0.74	0.270	0.230	1.34	0.410	0.090	1.94	0.474	0.026	2.54	0.494	0.006
0.15	0.060	0.440	0.75	0.273	0.227	1.35	0.411	0.089	1.95	0.474	0.026	2.55	0.495	0.005
0.16	0.064	0.436	0.76	0.276	0.224	1.36	0.413	0.087	1.96	0.475	0.025	2.56	0.495	0.005
0.17	0.067	0.433	0.77	0.279	0.221	1.37	0.415	0.085	1.97	0.476	0.024	2.57	0.495	0.005
0.18	0.071	0.429	0.78	0.282	0.218	1.38	0.416	0.084	1.98	0.476	0.024	2.58	0.495	0.005
0.19	0.075	0.425	0.79	0.285	0.215	1.39	0.418	0.082	1.99	0.477	0.023	2.59	0.495	0.005
0.20	0.079	0.421	0.80	0.288	0.212	1.40	0.419	0.081	2.00	0.477	0.023	2.60	0.495	0.005
0.21	0.083	0.417	0.81	0.291	0.209	1.41	0.421	0.079	2.01	0.478	0.022	2.61	0.495	0.005
0.22	0.087	0.413	0.82	0.294	0.206	1.42	0.422	0.078	2.02	0.478	0.022	2.62	0.496	0.004
0.23	0.091	0.409	0.83	0.297	0.203	1.43	0.424	0.076	2.03	0.479	0.021	2.63	0.496	0.004
0.24	0.095	0.405	0.84	0.300	0.200	1.44	0.425	0.075	2.04	0.479	0.021	2.64	0.496	0.004
0.25	0.099	0.401	0.85	0.302	0.198	1.45	0.426	0.074	2.05	0.480	0.020	2.65	0.496	0.004
0.26	0.103	0.397	0.86	0.305	0.195	1.46	0.428	0.072	2.06	0.480	0.020	2.66	0.496	0.004
0.27	0.106	0.394	0.87	0.308	0.192	1.47	0.429	0.071	2.07	0.481	0.019	2.67	0.496	0.004
0.28	0.110	0.390	0.88	0.311	0.189	1.48	0.431	0.069	2.08	0.481	0.019	2.68	0.496	0.004
0.29	0.114	0.386	0.89	0.313	0.187	1.49	0.432	0.068	2.09	0.482	0.018	2.69	0.496	0.004
0.30	0.118	0.382	0.90	0.316	0.184	1.50	0.433	0.067	2.10	0.482	0.018	2.70	0.497	0.003
0.31	0.122	0.378	0.91	0.319	0.181	1.51	0.434	0.066	2.11	0.483	0.017	2.71	0.497	0.003
0.32	0.126	0.374	0.92	0.321	0.179	1.52	0.436	0.064	2.12	0.483	0.017	2.72	0.497	0.003
0.33	0.129	0.371	0.93	0.324	0.176	1.53	0.437	0.063	2.13	0.483	0.017	2.73	0.497	0.003
0.34	0.133	0.367	0.94	0.326	0.174	1.54	0.438	0.062	2.14	0.484	0.016	2.74	0.497	0.003
0.35	0.137	0.363	0.95	0.329	0.171	1.55	0.439	0.061	2.15	0.484	0.016	2.75	0.497	0.003
0.36	0.141	0.359	0.96	0.331	0.169	1.56	0.441	0.059	2.16	0.485	0.015	2.76	0.497	0.003
0.37	0.144	0.356	0.97	0.334	0.166	1.57	0.442	0.058	2.17	0.485	0.015	2.77	0.497	0.003
0.38	0.148	0.352	0.98	0.336	0.164	1.58	0.443	0.057	2.18	0.485	0.015	2.78	0.497	0.003
0.39	0.152	0.348	0.99	0.339	0.161	1.59	0.444	0.056	2.19	0.486	0.014	2.79	0.497	0.003
0.40	0.155	0.345	1.00	0.341	0.159	1.60	0.445	0.055	2.20	0.486	0.014	2.80	0.497	0.003
0.41	0.159	0.341	1.01	0.344	0.156	1.61	0.446	0.054	2.21	0.486	0.014	2.81	0.498	0.002
0.42	0.163	0.337	1.02	0.346	0.154	1.62	0.447	0.053	2.22	0.487	0.013	2.82	0.498	0.002
0.43	0.166	0.334	1.03	0.348	0.152	1.63	0.448	0.052	2.23	0.487	0.013	2.83	0.498	0.002
0.44	0.170	0.330	1.04	0.351	0.149	1.64	0.449	0.051	2.24	0.487	0.013	2.84	0.498	0.002
0.45	0.174	0.326	1.05	0.353	0.147	1.65	0.451	0.049	2.25	0.488	0.012	2.85	0.498	0.002
0.46	0.177	0.323	1.06	0.355	0.145	1.66	0.452	0.048	2.26	0.488	0.012	2.86	0.498	0.002
0.47	0.181	0.319	1.07	0.358	0.142	1.67	0.453	0.047	2.27	0.488	0.012	2.87	0.498	0.002
0.48	0.184	0.316	1.08	0.360	0.140	1.68	0.454	0.046	2.28	0.489	0.011	2.88	0.498	0.002
0.49	0.188	0.312	1.09	0.362	0.138	1.69	0.454	0.046	2.29	0.489	0.011	2.89	0.498	0.002
0.50	0.191	0.309	1.10	0.364	0.136	1.70	0.455	0.045	2.30	0.489	0.011	2.90	0.498	0.002
0.51	0.195	0.305	1.11	0.367	0.133	1.71	0.456	0.044	2.31	0.490	0.010	2.91	0.498	0.002
0.52	0.198	0.302	1.12	0.369	0.131	1.72	0.457	0.043	2.32	0.490	0.010	2.92	0.498	0.002
0.53	0.202	0.298	1.13	0.371	0.129	1.73	0.458	0.042	2.33	0.490	0.010	2.93	0.498	0.002
0.54	0.205	0.295	1.14	0.373	0.127	1.74	0.459	0.041	2.34	0.490	0.010	2.94	0.498	0.002
0.55	0.209	0.291	1.15	0.375	0.125	1.75	0.460	0.040	2.35	0.491	0.009	2.95	0.498	0.002
0.56	0.212	0.288	1.16	0.377	0.123	1.76	0.461	0.039	2.36	0.491	0.009	2.96	0.498	0.002
0.57	0.216	0.284	1.17	0.379	0.121	1.77	0.462	0.038	2.37	0.491	0.009	2.97	0.499	0.001
0.58	0.219	0.281	1.18	0.381	0.119	1.78	0.462	0.038	2.38	0.491	0.009	2.98	0.499	0.001
0.59	0.222	0.278	1.19	0.383	0.117	1.79	0.463	0.037	2.39	0.492	0.008	2.99	0.499	0.001

第 11 章

確率と統計的推論

さて，前回は不確実なものを表現する方法として，確率を学びました。これを使ってどのように考えるのでしょうか。

この授業は全体を通じてのテーマとして，「見えないものを見る」があります。たとえば潜在変数ですとか誤差のようなものも見えないものの代表格ですが，ここから始まる話は一部のデータから全体を推測するという統計的な推測の考え方についてのお話です。

このようにそもそも統計学というものが，不完全な情報からできるだけ多くの知識を得ようとする営みであることを知っておいてください。そして，一見不可能に見えるようなこの営みを成立させるためには，確率の力を借り，いくつかの仮定をおいて議論を進める必要があります。この「仮定」の上に成り立った “みなし” の学問であることは，ずっと忘れないでいてください。

11.1 母集団と標本

さてでは始めていきましょう。例として，ある小さな学校で身体測定をしたと考えてください。とても小さな学校で，生徒の数はたったの 3 人です。3 人の身長はそれぞれ，165cm,173cm,182cm でした。さて，この 3 人の平均身長は？

そう，

$$(165 + 173 + 182)/3 = 173.33\cdots$$

ですね。大体 173cm と結論づけましょう。

こうした代表値の計算 (→ 第 5 講) は，統計学の中でも**記述統計 (descriptive statistics)** と呼ばれる領域に属します。そこでは，手元のデータの状態を記述することが目的なのでした。

ところで私たちがこうして何らかのデータを得たときに，手元のデータの状態だけではなくこれを使って何らかの推論をしたいということがあります。このままでは，ある地方の，ある学校の特徴がわかっただけだからです。しかもここは生徒数がたった 3 人ですから，特殊な例だと言われても仕方がありません。手元のデータを特殊な事例だといわれて困るのは，逆に言えば一般的な特徴を知りたかったからですよね。一般性を確保するという事は，他の学校ではどうか，他の地方ではどうか，日本全体ではどうか，世界ではどうか，と言及できる対象を広げたいと考えているということです。

もちろん日本全体や世界全体の児童生徒の身長を測って回るというのはとても大変なことですから一朝一夕にできることではありません。だからといって完全に諦めてしまうのではなく，手元のデータをヒントにして，この全体像を推測しよう。これが**推測統計学 (inferential statistics)** の基本的な狙いです。

推測統計学の話を始めるにあたって，いくつかの言葉を整理しておきましょう。図 11.1 を見てください。

推測統計学では，私たちが知りたい世界全体のことを**母集団 (population)** といいます。たとえばあなたが

図 11.1 母集団と標本

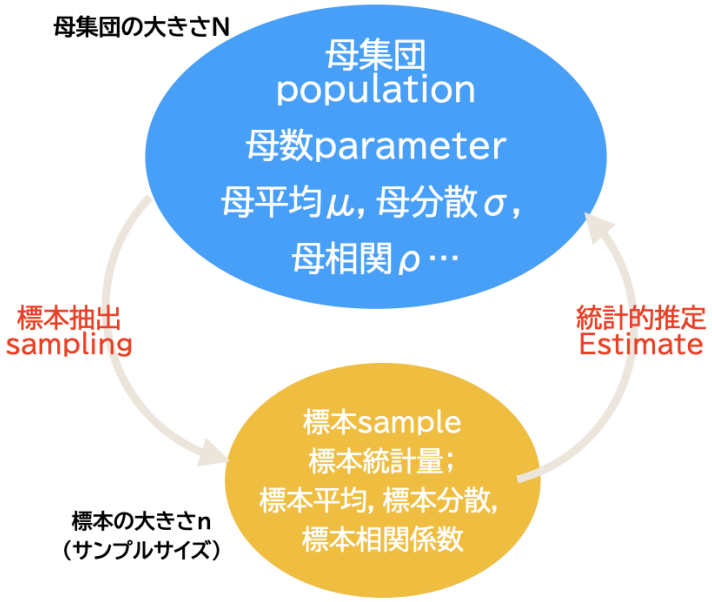

日本の小学生の平均身長が知りたい，というのであれば母集団は日本の小学生全体です。また母集団の統計的な特徴のことを，**母数 (parameter)** といいます。[*1]

母数として，たとえば母集団の平均のことであれば母平均，分散のことであれば母分散，相関係数のことであれば母相関，などと，「母」をつけて区別します。

母集団は非常に大きな集団を仮定することが一般的ですので，すべてを調査し尽くす事は非常に困難です。日本では 5 年に 1 度国勢調査が行われますが，これは日本という母集団全体のことを調べようとする調査です (悉皆調査といいます)。5 年に 1 度しか調査ができませんし，その結果をまとめるのにも数年かかります。私たち心理学者が，何らかの心理学的な特徴を知りたいと考える場合，母集団は日本を飛び越えて，世界全体あるいは人類全体を指すことになります。この全体の特徴を測ろうとすると，おそらく一生かかっても研究は終わりません。そこで全体の特徴を反映しているような，一部分を取り出してそれを詳しく調べることで，全体を考えるヒントにしようとします。この母集団から取り出されたもののことを，**標本 (sample)** と呼びます。また，取り出し方は**標本抽出 (sampling)** と呼び，一般に**無作為標本抽出 (random sampling)** をすることが必要です。無作為という言葉は聞きなれないかもしれませんが，要するに，作為がない，つまり意図がないという意味です。何らかの意図を持ったサンプリングというのはたとえば，背の高い人だけを連れてきてその平均身長を測り，全体を調べるヒントにしようというようなものです。そして計算された平均は，おそらく一般よりも高いものになるでしょう。だって背の高い人を “意図的に選んで” 連れてきたのですから。そうではなく，無作為に選び出すことが，全体の特徴を知るために重要なポイントになります。[*2]サンプリングは，お料理でいうところの味見のようなものです。中身をよくかき混ぜれば，ごく一部だけ取り出すことでも，十分全

[*1] 最近巷では，母数という言葉が，調査した全体を指す意味で用いられている誤用が散見されます。たとえば「データが少ないから，もう少し母数を増やさなければ」といった用法です。本来の母数という言葉を知っていれば，これはまったく意味の通じない表現です。おそらく，「分母」という言葉と混同しているのだと思われます。

[*2] 社会調査などでは，この標本抽出の方法について，どの程度の母集団に対し，ある精度で平均値を推定するためには，何人のサンプルをとってくる必要があるか，といった設計や技法が駆使されます。社会調査の方法については心理統計学の領域を超えますので，他書に譲ります。

体の味を推測できるわけです。

さて母集団における母数と区別するために，標本における統計量の事は，標本平均，標本分散，標本相関係数，などと標本という言葉を前につけておきます。これらの数値のことを**標本統計量 (sample statistics)** といいます。平均や分散，標準偏差，相関係数など，これまで標本に対して計算してきた記述統計量は，すべて標本における統計量なので，このように呼んで区別しておきます。この標本の数値や統計をヒントにして，母数がどうなっているかに言及することを，**統計的推定 (statistical inference)** と呼びます。

統計学では一般に，母数は未知であり，ギリシア文字で表します。母平均は μ(ミューと読む)，母分散は σ^2(シグマの二乗，と読む。総和を表すシグマ $\sum$ の小文字です)，母相関は ρ(ローと読む) などがよく使われます。これに対して，標本統計量は計算できる数字であり，一般にアルファベットを用いて表現します。標本平均は $\bar{X}$，標本相関係数は r_{xy} などです。

ここで誤解しやすい 2 つの言葉について解説を追加します。1 つは標本の大きさと数についてのお話です。図 11.2 を見てください。さきほどのとある学校での標本についての話ですが，そこでは 3 年の児童生徒を取り出したのでした。この時標本の大きさ，つまり標本に含まれる人数 (観測度数) は**サンプルサイズ (sample size)** と呼ばれます。このサイズの調査を他でも行ったとしましょう。つまり A 校，B 校，C 校... といろいろな学校で 3 人ずつ調査を繰り返していくのです。この時，得られた標本の数は**サンプル数 (number of samples)** といいます。誤用がおおいのは，このサンプルサイズとサンプル数の取り違えです。「人数 n のサンプルを取りました」というべきところを，「サンプル数 n です」というと，「で，何人取ったの？」とか「そんなに繰り返し調査したの？」という返事がかえってきて，混乱することにもなりますので注意してください。

図 11.2　サンプルサイズとサンプル数

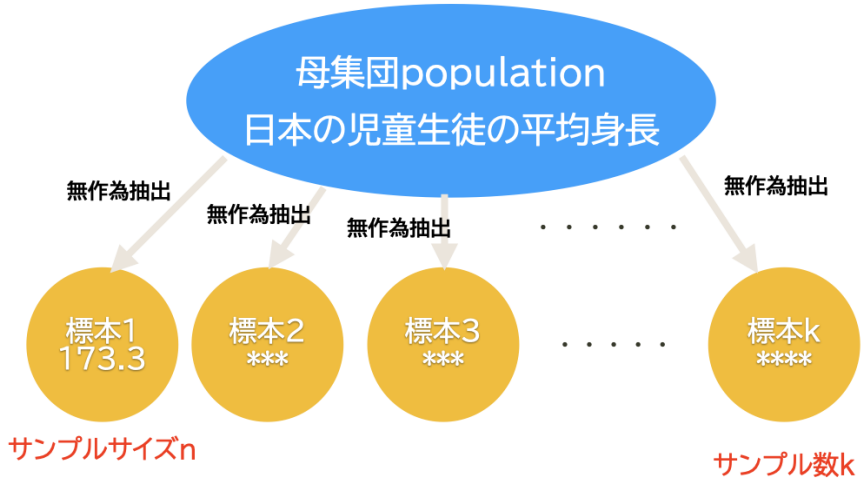

もう 1 つ。冒頭の例では，平均身長が 173cm だったわけです。これはもちろん，違う標本を取れば (i.e. 違う学校の 3 人を無作為に取ってくる)，違う数字になるでしょう。標本統計量はこのように，標本によって変わる変数なのです。メカニズムはわからないけどゆらぎがある，そう，確率的に変化するものと考えられます。確率的に変わる変数は，**確率変数 (random variable)** と呼ばれますが，標本統計量は確率変数なのです。このとき，173 という数字は，確率変数がたまたま今回定まった値をとったことになりますね。そこでこの数字

は，確率変数の**実現値 (observed value)**，あるいは**標本統計量の実現値**と呼ぶことにします。標本統計量そのものは確率的に変動するものであり，それが具現化したものとは区別しておきましょう。[*3]

11.2 母集団分布とモデル

さて用語の準備が整ったところで，実際にどのように推定していこうか，考えていきたいと思います。さきほどの標本では，平均身長 (標本平均の実現値) が 173 だということがわかりました。であれば母平均も 173 だろう，と考えて良いでしょうか。少し性急すぎるような気がしませんか。違う標本を取れば違う数字になるでしょうから，1 つの標本から答えを出すのは少し無理があるようです。

そこで，母集団の数字 (**母集団分布 (population distribution)**) がどのような分布をしているかを考えましょう。これはもう，仮定の話です。だって実際に母集団の数字を全部見ることは叶わないわけですから。たとえば身長に影響してきそうな変数は無数に考えられます。たとえばご両親の身長，生育環境，日々の睡眠時間，食事の量，運動の量など，何もかもが影響しているように思えます。さて，これら無数の条件がいろいろ積み重なって，1 つの数字となったのであれば，そうした数字を集めると正規分布に従うのではないか，と考えることができそうです。このように，仮定ではありますが，合理的な論拠があれば母集団の分布の形は正規分布である，と考えて話を進めても良さそうです。実際，心理学の多くの研究は，データの母集団分布に正規分布を仮定しています。心という目に見えないものも，無数の影響に晒されて出来上がるものと考えているからです。

重要なのは，母集団分布がどのような分布か，あるいは心的反応の結果として得られる数字の分布が，どのようなものであるかはすべて「モデル」であり[*4]，「仮定」に過ぎない，ということです。反応の結果として得られる数字 (アウトカム変数ともいいます) が，「はい」「いいえ」「どちらでもない」のような三択であれば，これの母集団分布は正規分布のような連続分布ではなく，離散的な分布を仮定しなければならないでしょう。

心理学は見えないものを見ようとする学問であり，統計は一部の不完全なデータから全体を見ようとする学問です。この一見不可能とも思えるような推論を進めるにあたって，仮定の力を借りて (モデルを置いて) いるのだということは，忘れてはいけません。

11.2.1 正規分布の意味

ここで母集団に正規分布を仮定する，という話をしました。この後も，正規分布はあちこちで顔を出します。心理学において (それ以外の統計モデルにおいても)，正規分布はとても重要な意味を持つ分布です。

この授業で前期の間は，正規分布は，1 つには誤差の分布として導入されました。偶然誤差はどの程度散らばるかということがわかれば，それを見込んで評価できます。データは真の値 + 誤差 ($X = t + e$) という**古典的テスト理論**はこの特徴を利用しているのでしたね。

そしてここで，集団全体の傾向を表す分布として正規分布を使うことになりました。推測統計ではとくに平均がどのあたりにあるのかに注目し，その傾向を掴むといった統計的な使い方をします。平均身長や平均寿命を考えるのはこういったところにあるわけですね。この時は個人の特徴を平均からの逸脱の程度だと考えているといえます。この考え方は心理学全域に関わるモデルです。平均的な傾向を探ったり比較したりすることで，人間全体の傾向を考えようというわけです。もちろん臨床心理学のように，全体の傾向ではなく個人内の変動を考えるという研究アプローチもありますが。

このように正規分布には大きく分けると 2 つの意味があるのです。第一の意味は偶然誤差の分布。平均が

[*3] サイコロの目は確率変数ですが，⚀や⚄は確率変数の実現値です。

[*4] モデルとは，雛形や模型という意味もありますが，ここでは些末な事例を省略して作られた，抽象的な理想型という意味です。

0 で分散が σ^2 の正規分布に誤差が従うと考えます。第二の意味は集団全体の傾向です。個々人に影響するさまざまな要因を特定することはできませんが，集団全体としては 1 つの傾向を持つ，つまりある平均値があり，そこから離れるほどその出現度数が少なくなるというパターン全体を表しています。前者の立場からは測定値=真値 + 誤差と考えていることになりますし，後者の立場では測定値=期待値 + 個人差と考えていることになります (期待値とは確率分布の平均のことです。)。

元々はガウス流の，誤差分布の流れから見つけ出された正規分布ではありますが，社会調査が始まった頃に社会全体の特徴分布として正規分布が改めて見直されたといえるでしょう。椎名 (2013)は他にも正規分布が見つけられた経緯として，7 種類のルートがあると論じています。

11.3 標本分布と標準誤差

母集団に分布を仮定すると標本統計量がどのような分布をするかが，数理的に導出できます。この計算はとても専門的ですので，興味がある方は「数理統計学」に関する他書をあたっていただくとして，そのエッセンスだけいただくことにしましょう。

そのエッセンスとはつまり，母集団に分布を仮定すると，標本統計量の分布がわかるということです。正確に言えば，標本統計量がどのような確率分布に従うのかがわかる，という点です。標本統計量がどのような確率分布に従うのかがわかれば，標本ごとにどの程度数字がブレるのか (分散・標準偏差)，標本分布の平均はどのあたりにあるのか (期待値) がわかります。であれば，1 回の調査＝標本が 1 つであっても，この標本の数字がどの程度ブレていくのかがわかる，つまり実現値の精度を評価できるということになります。ありがたいことに，母集団からいくつもの標本を取り出してそれぞれの標本平均を計算すると，その分布が正規分布になる，ということがわかっています[*5]。具体例で見ていきましょう。

表 11.1 100 人村のテスト分布

69	63	58	54	55	44	63	55	50	53
58	38	43	59	52	58	34	52	55	61
37	47	41	41	61	53	43	39	53	74
62	45	39	44	65	39	47	63	44	64
50	55	52	66	47	74	49	70	57	63
50	56	40	44	43	52	38	31	58	51
22	72	60	52	61	45	48	57	59	54
62	52	45	56	49	50	46	63	40	43
57	65	41	37	35	30	50	63	42	51
51	70	62	36	45	59	45	37	43	48

ここに表 11.1 を用意しました。10 行 10 列なので 100 の数字が入っています。100 人のテストの成績だ，とでも思っておいてください。さてこの 100 人が母集団だとします (世界が 100 人の村だったら，みたいに)。母平均はこの 100 個の平均ですから，計算してみますと $\mu = 51.24$ でした。

さて，これは仮想データなので，母集団分布は正規分布であることがわかっているとします[*6]。100 点しかデータポイントがありませんから，ヒストグラムもあまり正規分布っぽくはなりませんが，一応図にすると次のようになります (図 11.3)。

[*5] この性質は**中心極限定理 (central limit theorem)** として知られています。

[*6] これは R を使って `rnorm(100,50,10)` として発生させた乱数です。

図 11.3　100 人村のデータ

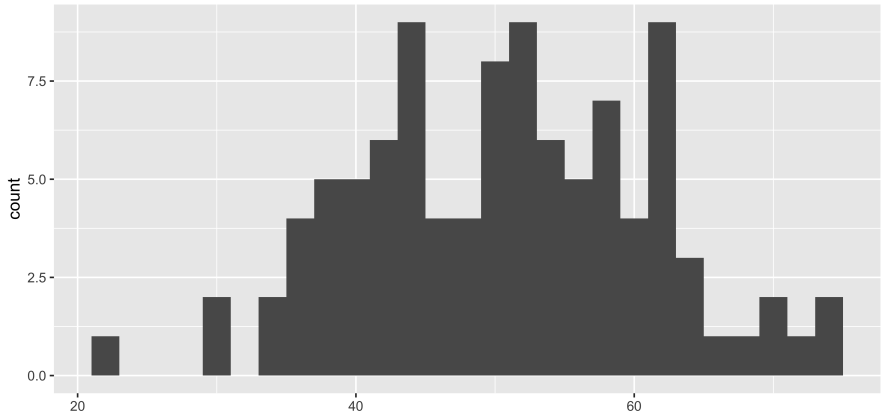

ここから，無作為にサンプルサイズ 5 のデータをとってみたところ，次のような数字が取れたとしましょう[*7]。

$$X_1 = \{57, 43, 47, 52, 63\}$$

これの平均は (標本平均は)$\bar{X}_1 = 52.4$ です。母平均が $\mu = 51.24$ ですから，結構近いですね。
次に，もう一度同じ母集団から，同じサンプルサイズのデータを取りましょう。

$$X_2 = \{63, 61, 52, 31, 62\}$$

これの平均は $\bar{X}_2 = 53.8$ でした。母平均からみると，少し大きいほうにずれてしまいました。
次にもう一度‥‥というのを繰り返していくと，表 11.2 のようになりました。

表 11.2　サンプルサイズ 5 のサンプリングを繰り返す

サンプル番号	標本平均
1	52.40
2	53.80
3	49.40
4	55.00
5	50.20
6	44.40
7	55.00
8	50.80
9	54.00
10	52.80

これを見るとわかるように，標本平均は標本を取るごとに変わります。分布するのです。標本を取るごとに

[*7] 無作為にサンプリングするのは非常に難しいです。「ぱっとみて」「適当に」やっても，人間がやると何らかのバイアスがかかって完全に無作為にすることはできません。ここでは 10 面サイコロを 2 つ振って行と列の番号を選び，数字をピックアップした‥‥とでも思っておいてください。実際は，R にある無作為抽出関数 `sample` を使っています。

数値が変わりますので，母平均に近い数字を取ることもあれば，母平均から離れた数字になることもあります。ところが，この標本平均**の平均**を取ると，$\bar{\bar{X}}_i = 51.78$ になります。母平均は $\mu = 51.24$ ですから，個々のどの標本平均よりもぐっと母平均，つまり推定したい正解に近づいています。

今度は，同じ母集団からサンプルサイズ 10 でサンプリングするとしましょう。

$$X_1 = \{50, 39, 65, 66, 44, 50, 36, 54, 70, 74\}$$

こちらの平均は $\bar{X}_1 = 54.8$ です。これは母平均には程遠い数字ですが，頑張って次々サンプリングを繰り返したとします。10 回分の結果が表 11.3 です。

表 11.3　サンプルサイズ 10 のサンプリングを繰り返す

サンプル番号	標本平均
1	54.80
2	49.40
3	51.90
4	49.80
5	47.40
6	54.10
7	50.50
8	52.80
9	54.60
10	47.70

この時の標本平均の平均は，$\bar{\bar{X}} = 51.3$ で，先ほどのサンプルサイズ 5 の繰り返しよりも母平均 $\mu = 51.24$ に近くなりました。ふむぅ。

さて，これらの実験から何がわかるでしょうか。まずは標本平均は分布するということです。取るたびに数字が変わるわけです。また，数理統計学の知見から，標本の平均は正規分布に従うことがわかっているのでした。つまり表 11.3 にある標本平均 (実現値 51.60,49.00,50.60,.... など) は平均を中心として左右対称の単峰分布だということです。また，平均から離れるほど，その出現確率はどんどん小さくなるはずです。

標本分布が正規分布になるわけですが，標本分布の期待値＝平均値は，究極的には (サンプル数を無限に増やしていけば)，母平均に一致することがわかっています。標本平均の平均は母平均に一致することをとくに**大数の法則**といいますが，これが推測統計学の基本です。つまり，標本をたくさん取ることで母平均を推定できるようになるということです！

このことをふまえて，表 11.2 と表 11.3 にある 2 つのサンプルサイズ ($n = 5$ と $n = 10$) を比較すると，次のことがわかります。まず，サンプルサイズが大きい方が，母平均に近い数字が出やすそうだ，ということです。これはデータをたくさんとっているからで，推測したい母集団のヒントがたくさん手に入るからです。直感的にもわかりやすいでしょう。今回も，サンプルサイズ 5 の時よりも 10 の時の方が，標本平均の平均が母平均に近くなりました。

また，サンプルサイズを大きくすると，標本平均のばらつきは小さくなります。多くのデータをとっているのですから，極端な値に振り回される可能性が減るからです。

この標本平均のばらつきのことを表す言葉があります。標本平均は正規分布に従うのですから，この幅，つまり標準偏差がそのばらつきを表すことになります。標本平均**の標準偏差**はとくに**標準誤差 (standard**

error) と呼ばれ，推定値としての標本平均の精度を表す数字になります。今回，表 11.2 にあるサンプルサイズ 5 の場合の標準誤差は 2.92，同じく表 11.3 にあるサンプルサイズ 10 では 2.48 です。サンプルサイズを大きくすると，標準誤差が小さくなる，つまり測定の精度が上がるわけですね。

具体的には，標本分布の分散は母分散 σ^2 をサンプルサイズ n で割ったものに一致することがわかっています。標本分布の標準偏差，つまり標準誤差は，$\frac{\sigma}{\sqrt{n}}$ に一致することになります。分母にサンプルサイズが入っているので，これが大きくなると標準誤差が小さくなることがわかります (図 11.4)。

図 11.4　標本，標本統計量，標本分布と統計的推測。母集団からサイズ n の標本を得る。個々のデータ (標本 1 の中にいる人物フィギュア) は，母集団と標本の枠組みの中で捉える。標本統計量は標本をたくさん取ると $(1, 2, \cdots k$, このときサンプル数 $k)$, 毎回異なる値を出すが，標本分布にしたがっている。標本分布の期待値は母平均に一致するし，ある標本平均の精度は標準誤差で評価できる。

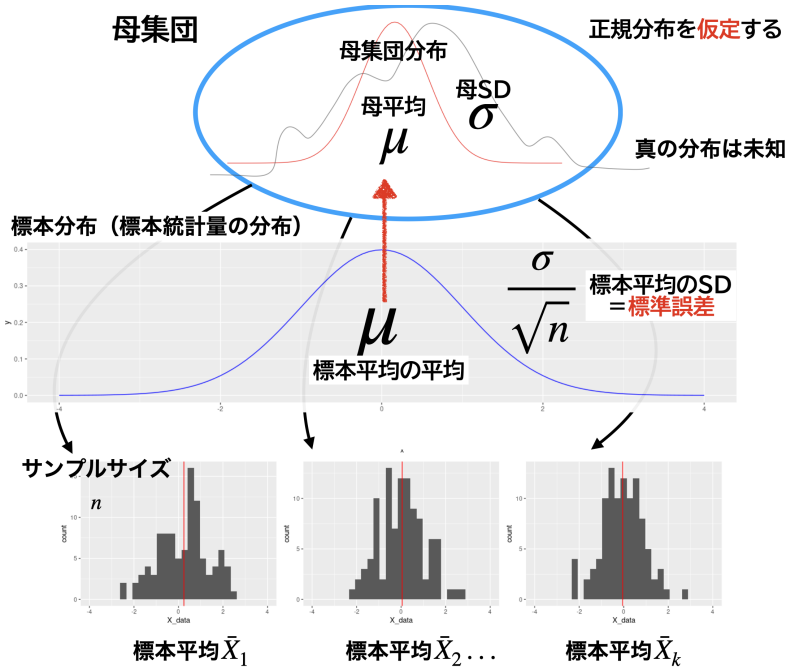

このことを数値シミュレーションでみてみましょう。先ほどと同じように，仮想的な数字を使って検討します。今度は一気に 100 万点のデータを作り，そこからランダムサンプリングをするようにしました。こうすることで，複数回無作為抽出しても，たまたま同じものがかぶる (再サンプリングされてしまう) ような危険性を回避できます。さて，図 11.5 をみてください。まず，100 万点のデータセットから無作為にサンプルサイズ 3,5,10,50 の標本を 100 回 (サンプル数 100) とりました。それらの標本平均も 100 あるわけですが，標本 1 の標本平均，標本 1 と 2 の平均，標本 1,2,3 の平均･･･と標本平均を 1 つずつ増やしていったときに，母集団の平均 μ(青の点線) に本当に近づいていくかどうかを検証したものです。図 11.5 からわかるように，サンプルサイズが小さくても 100 回もとれば母平均に一致していくようです。ただ，この折れ線の最初の頃をみてみると，サンプルサイズが小さい (3 や 5) ときは，大きく変動しています。サンプルサイズが大きくなると (n=50)，最初から母平均近くの値が得られているわけです。データをたくさん取ることの利点は，標準誤差が小さくなることにあります。

ここまでのことをまとめておきます。ポイントは，次の 2 つです。

- 標本平均の標本分布の平均 $\bar{\bar{X}} = \mu$
- 標本分布の標準偏差は $S.E. = \frac{\sigma}{\sqrt{n}}$

図 11.5　サンプリングを繰り返し，標本平均の平均を求めると，母平均に近づく

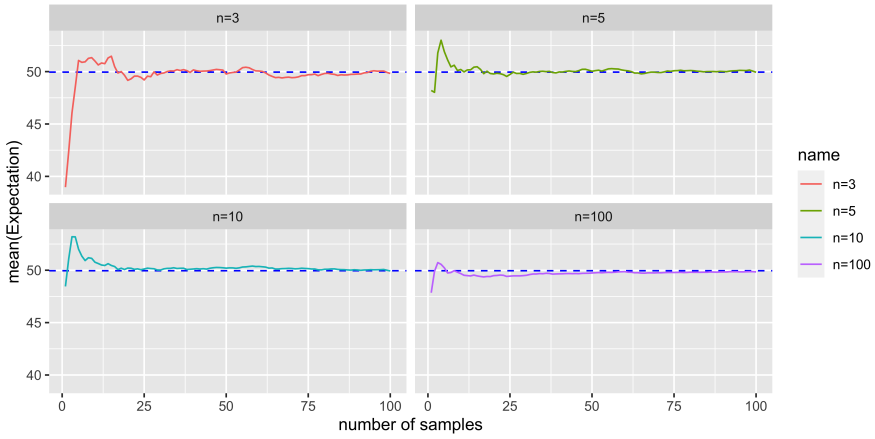

11.4　まとめ

今回は推測統計学の入り口でした。まずは用語として，母集団，標本，サンプルサイズ，サンプル数，母数，サンプリング，推定，標本分布といった言葉の整理を行いました。ちょっとした言葉の違い，ちょっとした数字の違いでも意味や結果が変わってくるので，慎重に読みこなしてください。

次に，母集団に確率分布を仮定することで，一部の標本から母集団のことを推測できる，という基本的なロジックをご紹介しました。推測統計学は，目に見えないものを想定して，仮定に仮定を重ねて推論していくことになります。仮定が多くてなにかいやだな，と思う人もいるかもしれませんが，そもそも全体像がわからないものを少数のヒントで推定するわけですから，無理な問題設定なのです。それをなんとか解決するためには，いくつかの仮定をおかざるを得ないのです。これらのお話は，あくまでも正規分布のような仮定・モデルの上での話であることは，いつまでも肝に銘じておいてください (それをいうと心理学そのものも，モデル上の話なんですけど！)。

ところで，最後に紹介した標本統計量をつかった母数の推定は，**モーメント法 (moment method)** とよばれるもので，実は他にも推定する方法があります。ただ，いずれにせよ確率分布は活用することになりますので，確率的な表現にも慣れておく必要があるでしょう。

11.5　課題

■前期と後期の学ぶ内容の違い　後期に入ってから推測統計学の領域に入ります。なぜ推測統計学を学ぶのか，前期で学んだ内容とどう変わってくるのかを，自分の言葉で説明してみてください (400-800 字)

第 12 章

推定

前回は標本の記述統計量をつかって母数を推定する方法をお話ししました。さて今回は，この話の続きをしていきましょう。どうやって母数を推定していくかについて，心理学でよく使われる正規分布を例に話を進めていきます。また，心理学の目的としては「母数がどういう数字だったか」ということよりも，相対的な比較によって考えることがあります。この考え方は，ひいてはモデル比較という話になっていきます。

12.1 不偏推定量

ここまでの話で，標本平均の平均が母平均に一致し，そのばらつきもわかるのですから，標本から母集団を推測できそうだ，ということが見えてきたかと思います。標本平均は多少のズレを含んでいるかもしれませんが，母平均の推定値として使うことができそうです。3 人学校の身長の例で言えば，母平均も 173cm ぐらいかもしれない，という予測ができそうだということですね。もちろん，サンプルサイズが小さいので，173± 何センチかのズレはありそうですが。

ところで，「母平均の推定値は XXX だ！」と一点張りで推定することを**点推定 (point estimation)** といいます。ただ，これはなかなかのギャンブルで，正解 (母平均) 近くにはあるかもしれませんが，正解そのものにピタリと当たることはなさそうです。とくに連続変数の場合は，小数点下何桁までぴったりと当たる，というのはほぼなさそうですから。そこで，「何センチかのズレ」を予測に盛り込むことが考えられます。これが**区間推定 (interval estimation)** です。母平均は 173cm だ，と言い切ってしまうのではなくて，160cm から 180cm の間に入ってるんじゃないの，というような予測の仕方をするのです。こうすると，外れる可能性は低くなります。ただ，0cm 以上 500cm 未満だったら 100% 当てられるぜ，という推定は何も推定していないことと実質同じですから，どれぐらいの幅で，どれぐらいの確率で･･･ということを考える必要があります。たとえば，173cm±5cm の区間に入ってる確率が 95%，といった具合に。

このように婉曲的な，少し保険をかけた推定の仕方はうまくいきそうですが，まだ問題が残っています。この幅を表現するためには，標本平均がどれぐらいブレるのか，その幅を推定しなければなりません。そう，標準誤差が必要なのです。ただこの標本平均のばらつき (標準誤差) は母分散によるので，母分散がどれぐらいになるのかを考えなければなりません。

母分散の推定値として，平均の時と同じように，標本分散をあてがうというのは 1 つのアイデアです。ですが，残念ながらこの方法だとうまく推定できません。図 12.1 をみてください。これは標本平均の時と同様に，サンプルサイズ 10 のサンプリングを 200 回繰り返し，標本分散の平均を順次とって行ったものです。これをみると･･･あれあれ，真値 (母分散 σ^2) の青いラインの，下側に収束して行ってるようですね。このズレのことをバイアスと言います。標本平均値は偏りのない推定量 (不偏推定量) なのですが，分散は偏り (バイアス) があるのです。

図 12.1　サンプリングを繰り返し，標本分散の平均を求めると，母分散から少しずれる

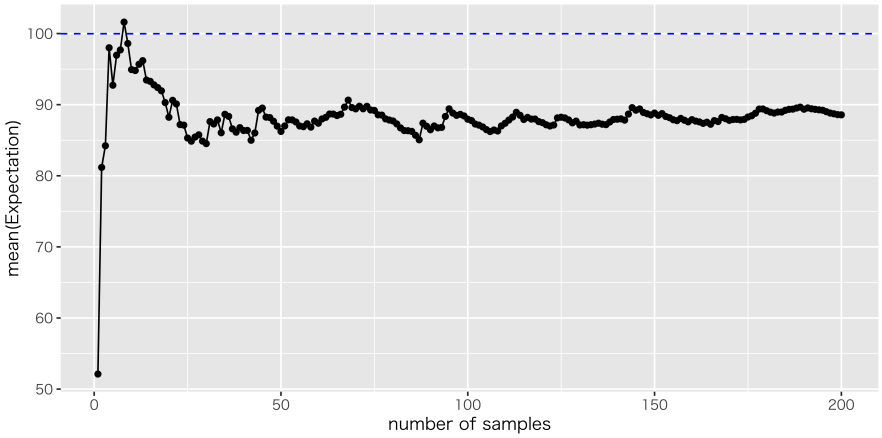

実は，標本分散の期待値 (平均を取ったもの) は，母分散に一致しないことがわかっています。ただ，このズレの加減は一定しているようですね。実際，これは計算できて (数理統計学の中身に入り込むのは避けて，答だけもらってきますが)，ズレの程度は $\frac{\sigma^2}{n}$ であることがわかっています。

ズレの程度がわかっているのなら，計算が合うように最初から計算を工夫しておけばいいでしょう。標本分散の計算式を覚えているでしょうか？ こんな式でしたね。

$$s_X^2 = \frac{1}{n}\sum (X_i - \bar{X})^2 \tag{12.1}$$

これが標本分散の期待値[*1]になると，母分散から $\frac{\sigma^2}{n}$ だけずれるのですから，母分散 σ^2 の推定値にするためには，事前にこのズレのことを考慮したいと思います。式を展開しましょう。

$$\begin{aligned}
\sigma^2 - E(s_X^2) &= \frac{\sigma^2}{n} \\
\sigma^2 - \frac{\sigma^2}{n} &= E(s_X^2) \\
n\sigma^2 - \sigma^2 &= nE(s_X^2) \\
\sigma^2(n-1) &= nE(s_X^2) \\
\sigma^2 &= \frac{n}{n-1}E(s_X^2)
\end{aligned}$$

こうなりますので，推定値としてこの計算を先にすることにします。

$$\hat{\sigma}^2 = \frac{n}{n-1}\frac{1}{n}\sum (X_i - \bar{X})^2 = \frac{1}{n-1}\sum (X_i - \bar{X})^2 \tag{12.2}$$

ということで，事前にこのずれが起きないように補正できました。

記述統計としての分散 (標本分散) はサンプルサイズ n で割り，推測統計量としての分散推定値 $\hat{\sigma}^2$ はサンプルサイズより少し小さな，$n-1$ で割るのだ，と考えれば良いでしょう。後者のことはバイアスのない標本統計量ということで，**不偏分散 (unbiased variance)** と呼びます。

先ほどのシミュレーションを，不偏分散の式を使って行ったのが図 12.2 です。補正してある不偏分散だと，母分散に近づいているのがわかりますね。

[*1] 確率変数の平均値のことを期待値というのでした。忘れてた人はセクション 10.2.4,Pp.145 を参照してください。

図 12.2　サンプリングを繰り返し，標本分散と不偏分散の期待値を求めたもの

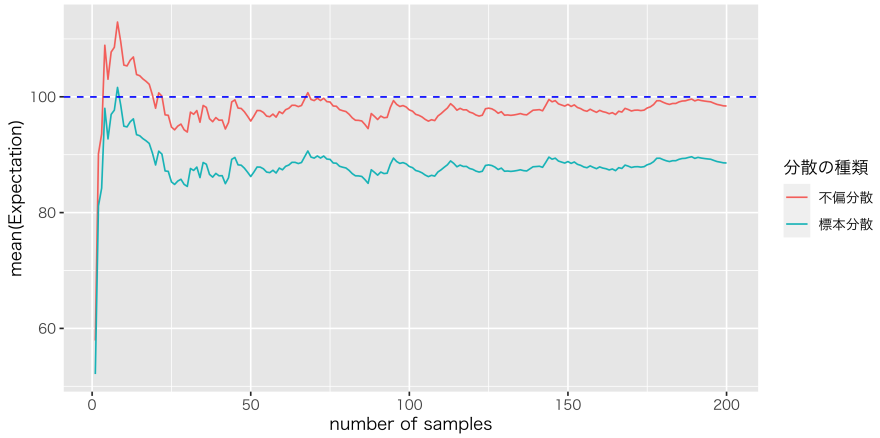

12.2　点推定と標準誤差

平均や分散のように，母集団の特性値 (母数) を推定するための標本統計量を**推定量 (estimator)** といいます。これに対して，実際に計算した値を**推定値 (estimate)** といいます。たとえば，標本平均 $\bar{X}$ は母平均 μ の推定量であり，実際に計算した値は $\bar{x}$ ということになります。分散の推定量としては不偏分散を使います。統計ソフトウェアはそれを見越して，分散を計算する関数 – たとえば R の `var()` 関数 – は自動的に不偏分散を計算します。標本分散が欲しい時は，別途計算式を用意する必要があることに注意してください。

さて，標本平均は母平均の推定値として使えることがわかりました。ですが，この推定値はサンプリング誤差を含んでいます。つまり，標本平均は母平均の推定値としては良いのですが，その精度を評価する必要があります。この精度を表す指標が**標準誤差 (standard error)** でした。この標準誤差を使って，推定の仕方を点推定から**区間推定 (interval estimation)** に変えることができます。

あるスコア x が正規分布にしたがっているとします。これは次のように表記されます[*2]。

$$x \sim N(\mu, \sigma)$$

この変数 x を標準化しておくと，標準正規分布に従うことになります。つまり，

$$z = \frac{x - \mu}{\sigma} \tag{12.3}$$

$$z \sim N(0, 1)$$

ですから，標準正規分布の表などを参考にすると相対的な位置が推測できる，という話でした。

これを母集団と標本という枠組みの中で考え直してみたいと思います (図 12.3)。先ほどの話は，あるスコアが平均 μ，標準偏差 σ の正規分布にしたがっている，というところから始まりました。これ，ギリシア文字で書いてありますから，母数ですよね。母数がわかっていれば苦労しないのですが。

そこで，μ の代わりに標本平均 $\bar{X}$ を使って – 標本平均は母平均の推定値として悪くないはずですから – 考えてみたいと思います。この標本平均 $\bar{X}$ は標本を取る度に変わります。どの程度変わるか，つまりどの程

[*2] 正規分布は Normal Curve なので，Normal，あるいは単に略してここにあるように N，とだけかかれます。正規分布は平均と標準偏差という 2 つのパラメータを持ちますが，統計の本によっては，平均と分散で書いてある場合があります。分散は標準偏差の正の平方根なので (→ 第 5 講)，持っている情報としては同じですから，単に表記の問題です。本書では統計環境 R と表記を合わせるために，標準偏差で記載しています。

図 12.3　今度は推測統計学の枠組みで考えることに注意。母集団が正規分布だと仮定して，そこから得られた標本のことについて考えています。個々のデータは標本の中にあります。

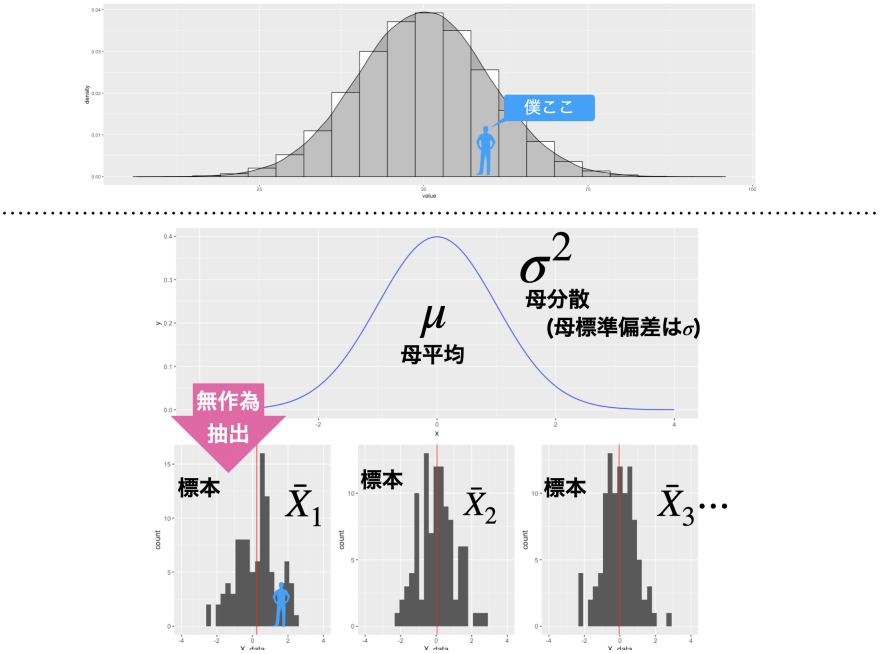

度標本平均が散らばるかを表すのが，標本平均の分散であり，標本平均の標準偏差でした。標本平均の分散は，$\frac{\sigma^2}{n}$ であり，標準偏差 (標準誤差) はその平方根ですから $\frac{\sigma}{\sqrt{n}}$ で表されます。つまり，

$$\bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$$

より，これを標準化して，

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

$$Z \sim N(0, 1)$$

となります。この Z は標準正規分布に従いますから，母平均がどのあたりにあるかを正規分布を使って推測できます (図 12.4)。

図 12.4　標本統計量の従う分布も正規分布。幅は母分散とサンプルサイズに依存します。

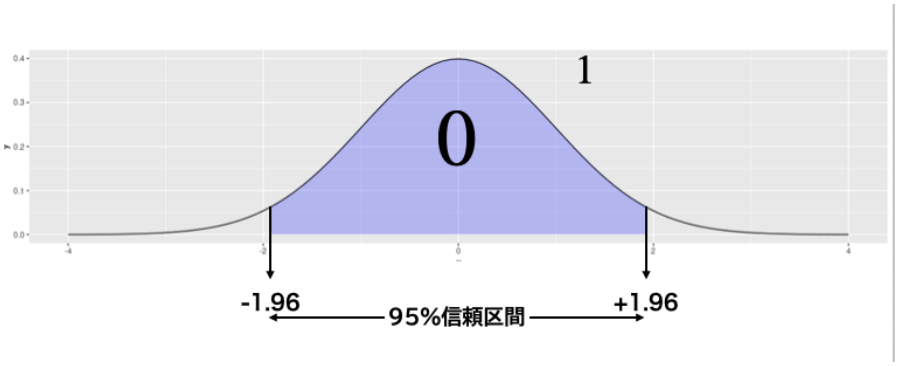

たとえば 95% の幅を持って推測するとしましょう[*3]。標準正規分布で 95% の幅を持つ区間はおおよそ ± 1.96 ですから[*4]，

$$-1.96 < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < 1.96$$

となります。この式を変形していきます。

$$-1.96\frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < 1.96\frac{\sigma}{\sqrt{n}}$$

真ん中を μ だけにしますと，

$$\bar{X} - 1.96\frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + 1.96\frac{\sigma}{\sqrt{n}}$$

となります。

具体的な数字をあてがって考えてみましょうか。母平均が 50，母標準偏差が 10 の母集団から，サンプルサイズ $n = 9$ のデータをとってきたところ，次のようになったとしましょう。

$$X = \{55.22, 50.10, 45.59, 61.99, 48.83, 50.38, 61.95, 53.44, 46.71\}$$

これの平均を考えると，$\bar{X} = 52.69$ となります。ただ，違う標本を取れば違う平均値になるはずなので，母平均 μ の推定値を 52.69 と一点張り (点推定) するのは外れてしまうかもしれないですね。実際，母平均 50 の設定だったので，点推定による推測は外れているわけです。ただ，標本統計量の散らばりが

$$\frac{10}{\sqrt{9}} = 3.33$$

ですから，

$$52.69 - 1.96 \times 3.33 < \mu < 52.69 + 1.96 \times 3.33$$

すなわち

$$46.1632 < \mu < 59.2168$$

となります。これを平易な言葉でいうと，「母平均は 46.1632 から 59.2168 の間に入っている確率が 95%」ということになります。この区間の中には設定した母平均 $\mu = 50$ が含まれていますから，区間推定をすることによって推測は当たった，と言えるわけです。

これが**区間推定 (interval estimation)** の実際です。ある値がはいる範囲を確率で表現するというのは，随分もってまわった言い回しのように思えますが，そもそも少ない標本から全体を推定しようとしている，という難しい問題をやっているのでこういう言い回しになります。少しずつ慣れて行ってください。ちなみにこの区間のことを**信頼区間 (confidence interval)** といい，CI[46.1632,59.2168] と書くことがあります。

また，これには母数が定数であるという隠れた考え方があります。母集団が推測したいデータの全体であれば，母数を知ることは絶望的に難しいですが，それでもなんらかの 1 つの値のはずです。であれば，この 95% の区間の中に「入っているか，入っていないか」の**どちらか**であり，入っている確率が 95%，という言い方であることに注意してください[*5]。

[*3] 心理学を始め，推測統計の業界ではよくこの 95%，あるいはその逆の 5% という数字が使われます。これにはなんの根拠もありません。50% や 30% の幅で考えたって，全然問題ありません。

[*4] 以前，R で計算した課題があったことを思い出してください。確率なので全部の面積は 1.0，95% 区間は両端 2.5%=0.025 を除いたことになりますから，`qnorm(0.975,0,1)` より，1.959964 です。左右対称なので，下側は符号を反転させれば OK です。

[*5] 最近の統計学の動向の中には，標本が定数で母数が確率変数であり，パラメータは定数ではないという考え方や (ベイズ理論的立場)，標本は確率変数で母数も確率変数であるという考えかた (情報統計学的ベイズ理論の立場) などがあります。テキストによっては立場によって，母数の区間推定についての説明が微妙に違ったりしますが，あまり気にしなくてよろしい。

12.3 標本だけから推測したい

さて，式 12.3 を使って区間推定できることがわかりましたが，よく見るとまだギリシア文字＝未知数が入っていることに気づきます。母平均 μ は推測したいものだからいいとして，母分散 σ^2 がわかっていないのです。母数がわかっていれば苦労しないのですが，わからないので推測するわけで，ここは母分散の代わりに推定量 $\hat{\sigma}^2$ を使うことにしましょう。標準化もこのスコアを使って行うことになります。

数値例でみてみます。先ほどのこのデータから，

$$X = \{55.22, 50.10, 45.59, 61.99, 48.83, 50.38, 61.95, 53.44, 46.71\}$$

標本平均は 52.69 でした。不偏分散は，

$$\frac{1}{9-1}\left\{(55.22-52.69)^2+(50.10-52.69)^2+(45.59-52.69)^2+\cdots+(46.71-52.69)^2\right\} = 36.5394$$

となります。標準偏差の不偏推定量は，不偏分散の正の平方根で代用して[*6]，

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{36.5394} = 6.044783$$

となります。

これを使って標準化する，つまり $(\dfrac{\bar{X}-\mu}{\hat{\sigma}/\sqrt{n}})$ として区間推定にしたいのですが，残念ながらこれは標準正規分布に従いません。その代わりと言ってはなんですが，母分散がわからないときに不偏分散で代用した場合，t **分布**というのに従うことがわかっています。ここでは，(また) 数理統計学による t 分布の導出を回避して結果だけ使わせてもらうことにして，この t 分布を使って推定することを考えます。

この t 分布，標準正規分布と違ってパラメータとして自由度 ν(ギリシア文字で「ニュー」と読みます[*7]) というものを使います[*8]。t 分布の形状は標準正規分布に近く，自由度が大きくなればほぼ標準正規分布と同じ形になるのがわかると思います (図 12.5)。この自由度とはなんでしょう？ t 分布の使い所は，母分散がわからないときに標本から計算した不偏分散で代用するというシーンだったことを思い出してください。この分散の推定量は，当然サンプルサイズによってその精度が変わります。このサンプルサイズによって推定の精度を調節しているのが，自由度というパラメータで表されているのです。しかも，この自由度は「サンプルサイズ -1」で計算できるという優れものです[*9]。

さて，これを使って母平均の信頼区間を標本だけから推定していきましょう。不偏分散で代用した標準化スコアは t 分布に従う，つまり次の数字を計算することになります。

$$t = \frac{\bar{X}-\mu}{\hat{\sigma}/\sqrt{n}}$$

[*6] 標準偏差は分散の正の平方根なので，分散を不偏分散にかえたものの正の平方根にすればそれが不偏標準偏差じゃないのかと言いたいところですが，実はそうではありません。不偏標準偏差を求めるためにはガンマ関数を利用した別のものにしなければならず，大変複雑ですのでここでは「代用する」にとどめています。

[*7] ニューガンダムのニューです。ニューガンダムについては「逆襲のシャア」を観てください。ジークジオン。

[*8] 正規分布のパラメータは平均 μ と標準偏差 σ でした。t 分布の平均は 0 で，自由度 ν は標準偏差に当たるような散らばりの指標だと思っていただければ結構です。

[*9] またマイナス 1 がでてきたー，なんだこれ。と思う人もいるかもしれません。イメージとして，標本における分散の代わりになる指標ですから，サンプルサイズ 1 の時は分散の計算ができず，サンプルサイズ 2 から計算し始めることができる，つまりサンプルサイズ 2 が最初の (1 番目の)t 分布の形なので，サンプルサイズ -1 が t 分布のかたちなのだ，と考えてみてはいかがでしょうか。

図 12.5　母分散がわからないときの標本統計量は t 分布に従う。自由度が大きくなるほど標準正規分布に近づきます。

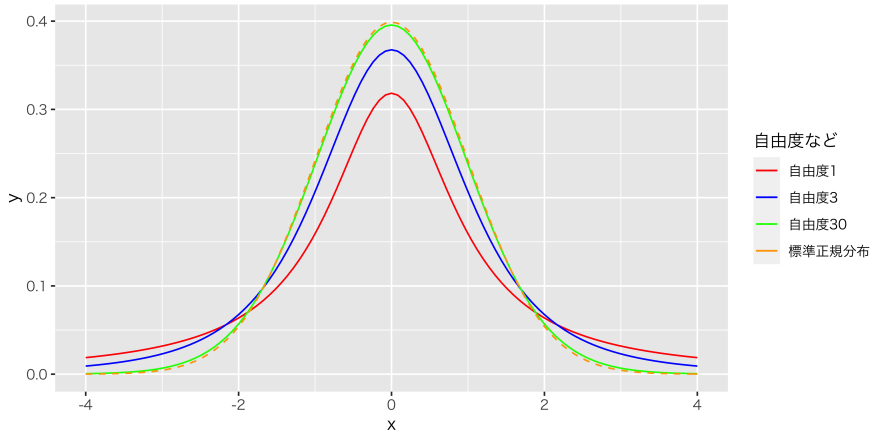

ここで，自由度 8 の t 分布について，95% 区間を R で求めると，両端は ± 2.306004 ですから[*10]

$$-2.306 < \frac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{n}} < 2.306$$

分母を両端にかけて，

$$-2.306 \times \hat{\sigma}/\sqrt{n} < \bar{X} - \mu < 2.306 \times \hat{\sigma}/\sqrt{n}$$

$\bar{X}$ を移項して，

$$\bar{X} - 2.306 \times \hat{\sigma}/\sqrt{n} < \mu < \bar{X} + 2.306 \times \hat{\sigma}/\sqrt{n}$$

これで標本統計量だけで計算できるようになりました。代入しましょう。

$$52.69 - 2.306 \times \frac{6.045}{\sqrt{9}} < \mu < 52.69 + 2.306 \times \frac{6.045}{\sqrt{9}}$$

ですから，

$$48.044 < \mu < 57.336$$

となります。この範囲に 95% の確率で母平均がある，と推定できました。レポートなどで報告するときには，CI[48.044,57.336] と書くことができます。

12.4　推定と検定の関係

さて，ここまでで「標本から母平均を推定する方法」を説明してきましたが，これが実際の研究シーンではどのように使われるのでしょうか。

心理学では，人間の心の状態に影響する要因をいろいろ探しています。人間に対して「これをすると心の状態が変化するんじゃないか？」と考えられる刺激を与えて，反応を見ることで効果があった，なかった，ということを調べるのです。もちろん人間の心の状態に影響する要因は無数に考えられ，すべてを統制することはできません。

そこで，心理学では**ランダム化比較試験 (randomized controlled trial; RCT)** という方法を使います。これは，実験に参加する人をランダムに 2 つの群に分けて，片方の群には刺激を与え，もう片方の群には刺

[*10] 標準正規分布と同じで，t 分布も R が関数を最初から持っています。d,p,q,r などを分布の前につけて (`qt(0.975,df=8)`) で計算します。また，t 分布も左右対称ですので (正確には，t 分布には非心度と呼ばれる位置母数があり，これが 0 のときは左右対称になります。これが 0 でないときは，対称でないのです)，片方が求まればもう片方はその符号反転です。

激を与えない (あるいは別の刺激を与える) という方法です。こうすることで，刺激を与えた群と与えなかった群の平均値を比較することができます。この方法のポイントは，ランダムに群わけすることで，この目に見えぬ無数の影響はどちらの群にも同じ程度に入っているだろう，と考える点です。そうすることで，それらの影響は相互に相殺 (キャンセルアウト！) しあって，結局平均値としては同じになるでしょう。その後，操作によって集団の平均値が変わることがあれば，それは操作の影響と言っていいでしょう，というロジックなのです (図 12.6)。

図 12.6　RCT による心理学研究のアプローチ

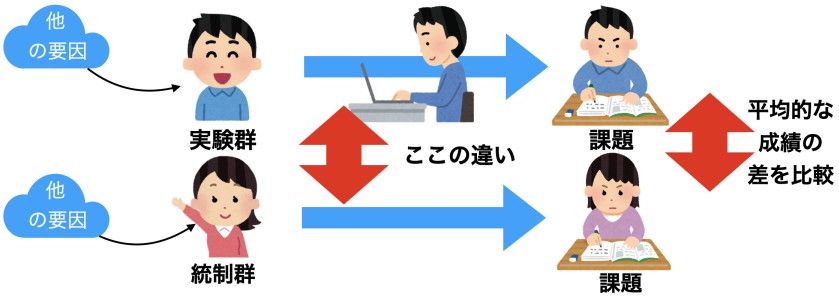

このアイデアに推測統計学の話を合わせて考えてみましょう。そうです，心理学的な実験のシーンで集められた集団も，母集団からの標本だと考えるわけです。母集団の標本である以上，興味があるのはデータの平均ではなくて (標本平均ではなくて)，母集団の平均であり，標本平均 (と不偏分散) から推定した母平均の比較がしたいのだ，ということになります。

このように推測統計学を使うことで，手元の標本だけではなく，結果を一般化して論じることができるようになります。推測統計学を使わずに記述統計だけで考えると，「あるデータをとったらこうなった，だからこう考えた」というだけで終わりです。これでは「あなたのデータがたまたまそういうデータだったのでしょう」と言われるかもしれません。小中学校の夏休みの自由研究であればこれでもいいのですが，専門的に科学的推論をするためにはこの謗りを排除し，手元のデータを超えて，目に見えぬ母集団の平均値で語りたいわけです (図 12.7)。

データが正規分布に従うとして，t 分布を使って標本統計量から母平均を計算することができるのでした。実験群のデータ X_1 と，統制群のデータ X_2 があったとしましょう。これらの標本平均をそれぞれ $\bar{X}_1$ と $\bar{X}_2$ とします。これらの平均値に差があるかどうかを調べたいとします。X_1 も X_2 も正規分布に従うと仮定できるので，それぞれの標本平均 $\bar{X}_1$ と $\bar{X}_2$ は正規分布に従います。ありがたいことに，これらの平均値の差 $\bar{X}_1 - \bar{X}_2$ も正規分布に従うことがわかっています。つまり，$d = \bar{X}_1 - \bar{X}_2$ は次のように表現できます。

$$d \sim N(\mu_1 - \mu_2, \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}) \tag{12.4}$$

ここで，μ_1 と μ_2 はそれぞれの母平均，σ_1^2 と σ_2^2 はそれぞれの母分散，n_1 と n_2 はそれぞれのサンプルサイズになっています。もし両群の分散が同じ ($\sigma_1^2 = \sigma_2^2$) で，サンプルサイズも同じ ($n_1 = n_2$) であれば，この式は次のように簡単になります。

$$d \sim N(\mu_1 - \mu_2, \sqrt{\frac{2\sigma^2}{n}}) \tag{12.5}$$

これで差の大きさを見積もれるわけですが，推定値はサンプリング誤差を含んでいるので，区間推定をすることになります。つまり，$\mu_1 - \mu_2$ の 95% 信頼区間を求めることになります。もし実験で使った刺激の効果がなければ，$\mu_1 - \mu_2 = 0$ となるはずです。つまり，この区間に 0 が入っていれば，刺激の効果はなかったと

図 12.7　RCT と推測統計を合わせて考える。標本平均に差があるのは当たり前で，問題は母平均に差があると言って良いかどうか，である。

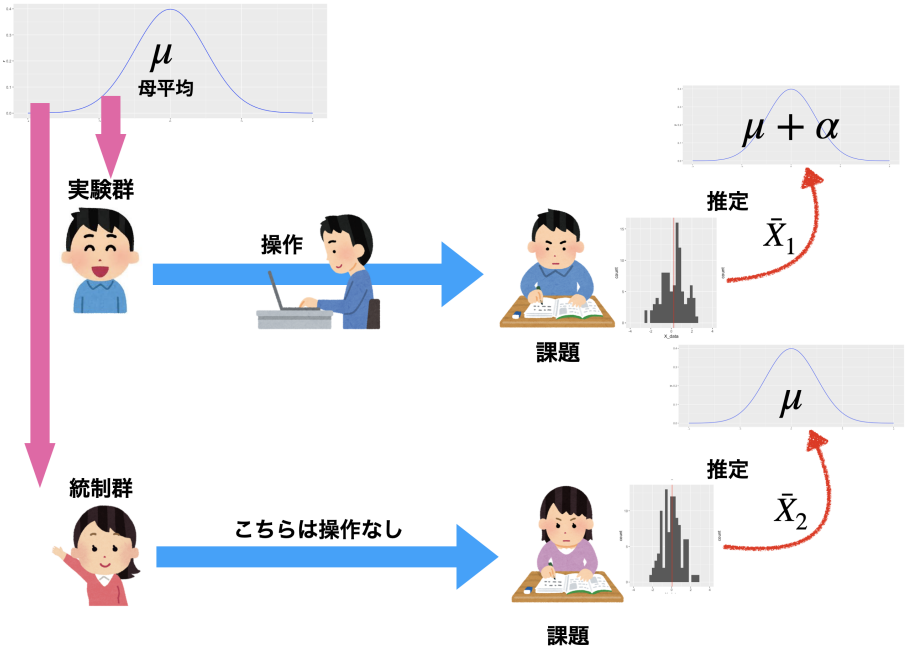

考えられます。逆に，この区間に 0 が入っていなければ，刺激の効果があったと考えられるわけです。このように，2 つの群の平均値の差があるかどうかを調べることを**検定 (test)** といいます。

この信頼区間は確率を含んだ表現ですから，解釈に注意が必要です。95% 信頼区間は，この区間の中に母平均が入っているはずだ，という幅です。これは区間で表しているものの，分布の情報を持った表現ではありません。確率変数のように，この区間の中の面積が 95% というのではなく，「95% の確率で当たるくじ」のようなもので，当たるか外れるかは，常にどちらか 1 つです[*11]。この確率の言葉を使った表現は，平易な表現からはかけ離れていますし，「確率で母平均に差があるということは 95% の確率で間違っている」と言われてもピンとこないかもしれません。

しかし，人間のように気まぐれで個性豊かな存在を相手に研究し，その成果を一般化するためには確率の力を借りる必要があり，判断の基準を確率で表現する必要があるのは仕方のないことです。確率の表現は直感的にわかりにくく，誤用してしまうことも少なくありませんので，注意深く使うようにしましょう。

[*11] 95% の確率で成功する手術があるとしましょう。それでも手術が失敗して死んでしまうということはあり得ます。たくさん手術をこなす医師にとっては 95% は成功率かもしれませんが，手術を受ける方にとっては生か死か，二択の事実があるだけです。

第 13 章

検定

前回は標本から母平均を区間推定する方法について説明しました。今回は，これを使って「差があるかないか」という**判断**をする方法について考えます。

母平均を区間推定することで，「このあたりにある，と予測したら XX% の確率で当たる」という範囲を定めることができました。この推定を実験群・統制群それぞれについて行うとすると，実験群の平均値はこの範囲，統制群の平均値はこの範囲にあると予測する，という言い方をすることになります。その範囲が重複していなければ，実験群と統制群の平均値は異なると言い切れるでしょうが，信頼区間が重複することは当然起こり得ます。そのときどうやって「差がある」「差がない」という判断をするのか，ということが問題になるのです。この判断は**検定 (test)** と呼ばれます。とくにその形式から，**帰無仮説検定 (null hypothesis significance test)**，略して **NHST** と呼ばれます。

どこに注意が必要なのでしょうか？ いろいろな問題があるのですが，ここでは説明しながら代表的なものを 1 つ挙げてみましょう。検定はモデル比較の考え方の一種です。統計的なモデル，というのは本講義の中では一貫して述べてきたように，データに対する理想形 + 誤差の考え方で，回帰分析に代表される線形的なモデルが代表的なものです。モデル比較とは，複数のモデルを用意したときにどちらのモデルがより良いか，という優劣を決めることです。統計的検定は，とくに**帰無仮説検定 (null hypothesis significance test)** と呼ばれ，帰無仮説 (H_0 と表記) と対立仮説 (H_1 と表記) という 2 つのモデルを戦わせ，どちらが良いかを決定することにあります。

つまり，検定は「推定」に「判断」が加わったものです。判断は，何らかの価値に基づいて，あるいは実践的な必要性に応えるためになされることです。たとえば感染症対策として新しい薬を開発し，この効果があるかどうかというときに，「効果あり」とか「効果なし」という判断をするのですね。この判断が必要なのは，効果がないのに投薬をすると時間とお金の無駄，ひいては何らかの副作用で人命に影響が出るかもしれない，というシーンだからです。幸い，心理学において人命が関わるような実験というのはほとんどあり得ませんが，実験や介入を行った効果があるのかどうかを判断するのにわかりやすいので，これまでよく使われてきました。実際とてもよく使われているのですが，同時に多くの誤用・悪用を生んでしまいました。あまりにも間違った使われ方，悪い使われ方が広まっていることから，アメリカ統計学会や権威ある科学雑誌である Nature が「間違った使い方はダメだぞ」という声明を出しており (Amrhein et al., 2019; Wasserstein & Lazar, 2016)，「統計学は瀕死だ」という人もいるほどです (豊田，2020)。念のためにいっておきますが，帰無仮説検定は間違った理論だ，というわけではありません。理論的に筋は通っているのですが，理論的仮定を犯さずに実践し，正しく解釈するのに細心の注意が必要だ，ということです[*1]。

[*1] これらの声明のタイトルもよく見ると，“p-value”(p 値) や “statistical significance”(統計的有意) について注意が必要だ，ということであって，帰無仮説検定 “significance test” そのものが間違っているというわけではないのです。

これら誤用・悪用を生み出す根本的な原因は，帰無仮説検定が「効果があった，なかった」という 1 bit 判断[*2]を提供することにあります。判断に迷うような推定結果を，とある基準で Yes/No に振り分けますが，そうするとそのインパクトが大きくなりすぎるのです。たとえばやり方によっては，二群にわけた群の平均の差が 0.1 点でも「差がある！」と判断することになったりします。これが二群の身長の差であれば，0.1cm は気にならないどころか実質的に意味のない差なのですが，「結果としてこの介入 (投薬) をする群と，しない群を比較すると**成長に差が見られた！**」なんて伝わってしまうかもしれません。またこの 0.1 点の差が男女の平均獲得賃金 (単位・100 万円) などであれば大きく意味が違います。この場合は男女差は 1 円だってあるべきではないのです。つまり，本来，差があるかどうかという程度の問題はドメイン知識[*3]に照らし合わせて考えなければならないものなのです。心理学のような目に見えない対象を研究する場合は，この判断が非常に難しく，どの程度の量であれば検出することに意味があるのか，どの程度なら無視して良いのか，ということについて，統一的な見解が作りにくいのです。心理学の場合は，判断の前の推定こそ重要であって，1 bit に落とし込まれた派手な結果だけに目移りすることがないよう，注意する必要があります。

さて，いきなり警句から始まってしまってすみません。上に書いたことには充分注意しつつ，具体的に説明を始めていきたいと思います。

13.1 帰無仮説検定の手続き

統計的帰無仮説検定の手続きは一般に，次のようなステップですすみます。

1. 仮説を設定する。
2. 統計的仮説検定に用いられる検定統計量を選択する。
3. 仮説選定判断の基準になる確率を設定する。
4. 実際のデータから検定統計量の実現値を計算する。
5. 最初に定めた仮説を支持するかどうかを判断する。

このステップについて，順に見ていきましょう。

13.1.1 仮説を設定する

まず最初のステップは仮説を設定するところです。帰無仮説検定では，**帰無仮説 (null hypothesis)** と**対立仮説 (alternative hypothesis)** という 2 つの仮説を用意します。検定は差があるかないかの判断をすることですから，差があるとするモデル，差がないとするモデルを勝負させて，どちらに軍配が上がるかを見ようとすることです。

帰無仮説は Null という言葉があるように，空っぽ，空虚な仮説です[*4]。普通，比較するときには何らかの違いがあるとか，効果がある，というようなことをいいたいわけですが，これに対して Null，つまり違いがない，効果がないというような仮説を一方の側に用意します。帰無仮説というのは，無に帰してほしい，なくなって欲しい仮説ということで名付けられています。

これに対して，対立仮説は Alternative(別の可能性，代わりになるもの，という意味) であり，「差がある」

[*2] 1 bit は付録 2 にあるように，2 進数のデジタルデータの最小単位で，0/1 の 2 つの状態しかありません。

[*3] ドメインとはその領域のことです。生物学的な身長の話をしているのか，産業社会学的な賃金体系の話をしているのか，といった話題にまつわる領域のことだと思ってください

[*4] ゼロと Null は違います。ゼロはゼロという数字があるといえますが，Null はその数字すらない，虚無です。余談ですが，ネットスラングの「ぬるぽ」とは Null pointer Exception の意味で，ポインタが行き着かない例外 (参照されたメモリ番地が存在しないエラー) という意味です。

「効果がある」という仮説になります。研究者としてはこちら側を応援したいところです。応援したい側があるのに，帰無仮説のようなものを置くのは，NHST の判断の仕方が背理法的なものになっているからです。つまり，差がないという帰無仮説を立てて考えると，おかしな事実が生じるのであれば，帰無仮説を棄却できる。**だから**対立仮説を採択できる。これが基本的な筋道です。

注意が必要なのは，もしかすると「効果がない」という研究がしたいことがあるかもしれない，ということですね。呪いやインチキはなかったんだ，ということを証明するのも科学の役割のような気がしますが，それではこの場合，なくなって欲しい帰無仮説は「差がある」で，対立仮説は「差がない」になるのでしょうか？ いいえ，そうはなりません。

たとえば，二群の母平均に差があるかどうかを検定したいとしましょう。母平均をそれぞれ μ_1, μ_2 とします。このとき，帰無仮説は $H_0 : \mu_1 = \mu_2$ であり，対立仮説は $H_1 : \mu_1 \neq \mu_2$ になります。これをよく見てください。帰無仮説と対立仮説は実は同等の仮説で戦っているわけではないことに気づきましたでしょうか。帰無仮説は「2 つの母平均は一致する」と言ってます。対立仮説は「2 つの母平均は一致しない」と言ってます。帰無仮説の「一致する」という言い方は，イコールの状態ですから，1 つしかありません。これに対して対立仮説は「一致しない」としか言ってません。$\mu_1 > \mu_2$ なのか，$\mu_1 < \mu_2$ なのか，はたまた $\mu_1 > \mu_2 + 0.5$(μ_1 と μ_2 は 0.5 以上離れている) なのか，あるいはもっと大きな，小さな差があるのかどうか･･･こうした詳細については何も言及していません。つまり，2 つのモデル比較といいながら，実はフェアではなく，一方は $H_0 : \mu_1 = \mu_2$ というモデル，他方はそれ以外全部，という非対称な関係があります。

どうしてそうなるのか，というのはこの後の検定の実際のロジックを進めていく時の，計算方法の中で明らかになっていきますが，ともかく帰無仮説はこうした「2 つの平均の差がない」という特殊な一点張りの状況に立脚するものですから，「差がない」という仮説は立てようがないのです。「差がない」，というのは差が 0.1 なのか 0.2 なのか 0.3 なのか 0.31 なのか 0.32 なのか，0.321 なのか 0.322 なのか･･･というどの状況なのかが特定できないからです[*5]

ともかくまずは，帰無仮説と対立仮説という 2 つを立てて戦わせる，というところを理解していただければと思います。

13.1.2 統計的仮説検定に用いられる検定統計量を選択する

たとえば平均値が違うといいたいのか，比率が違うといいたいのか，相関係数に意味があるのか，度数のばらつきが違うといいたいのか，などなど，研究のシーンに応じて考えたい標本統計量は変わります。

また，標本統計量をそのまま比較できない場合は，そこから計算して検定用の検定統計量を計算することになります。これまでの例では，たとえば平均の推定をするときに t 分布を使うという話がありました。平均の比較をする時は，この t 分布に従う統計量，すなわち t 値が検定統計量になります。しかし，相関係数などは推定に使う分布が簡単なものではないものがあります。その場合でも，母数の推定や信頼区間を考えなくても，検定の判断ができて，簡単に計算できる統計量に変換するという迂回路を取ることができます。

相関係数の検定はこの迂回ルートをとって，t 分布を使った検定を行います。他にも F とか χ^2 といった統計量を計算することがあります。

どのシーンでどの統計量が必要なのか，については数理統計学の力を借りてますので，天下り式に覚えるしかないところですが，逆に言えばいくつかの典型例を知っていれば数学的な展開を必要とせずに，結果を手に入れられるのだと思って奮い立ってください。

[*5] 面倒ですが，「差が 0.3 ジャストである」という帰無仮説 vs「差が 0.3 ジャストではない」という対立仮説の勝負なら，帰無仮説検定の文脈で検証することはできます。計算が面倒で一般化できなくなりますし，差が 0.31 でも 0.301 でも 0.3001 でも違う計算をすることになりますので，実際的ではありませんが。

13.1.3 仮説選定判断の基準になる確率を設定する

検定はモデル比較の結果，優劣を定める勝負です。推定の結果を考察するにあたって，帰無仮説と対立仮説のどちらに軍配をあげるかという，「実践上での意思決定ツール」でもあるわけです。ですので，事前に「こうなったら決着したとしましょう」というルールを決めておかなければなりません。分析の前に判断ルールを決めておかないと，あとでルールの方が変わってしまうと困りますので，必ず事前に決めておく必要があります。

この確率のことを，**有意水準 (significance level)** といいます。有意 significant とは，統計的に意味が有る，ということであり[*6]，これ以上の開きが出たら勝負あったと判断します，という基準です。これは確率の言葉で表現しますが，心理学では一般に 5% が用いられます。なぜ 5 なのか。とくに意味はありません。6 でも 4 でも良かったのですが，最初に統計的検定をやった人が「根拠はないけどとりあえず 5 で」と始めたのが，いまだに使われています。ということで，こだわる必要はないのですが，一般的に 5%，ときどき 1% や 0.1%，10% という数字が使われることがあります。どの数字でも，別に深い理由はありません。

ちなみにこの数字は，あくまでも優劣の判定基準であって，データそのものに言及する数字ではありませんし，仮説の正しさ，仮説モデルとデータの適合度を表す数字ではないことに注意が必要です。

13.1.4 実際のデータから検定統計量の実現値を計算する

実際のデータを当てはめて，検定統計量を計算します。

13.1.5 最初に定めた仮説を支持するかどうか判断する

ここまではルールの設定でした。このあとは，ルールにしたがって 2 つのモデル (仮説) を戦わせていきます。

実際のデータから，検定統計量がどれぐらいの数字になるのかを計算し，それが出現する確率を計算します。この確率をとくに p **値 (p-value)** と言います。この p 値が有意水準を上 (下) 回ったかどうかが，勝敗の結果になります。ちなみに勝った方の仮説を**採択 (accept)** し，他方を**棄却 (reject)** する，という言い方をします。

これが一連の流れです。このように手続きは形式的に定まっていますので，途中の計算は統計ソフトウェアが自動的にやってくれます。ですから計算の手間はほとんどないのですが，それだけに安易に使って安直に結果だけに飛びつくということがないように，注意が必要です。

13.2 相関係数の検定

具体的な例として，まずは相関係数の検定の話を考えてみましょう。相関係数の検定は，検定のロジックがわかりやすいため導入にもってこいです。

心理学では，平均値を推測するだけでなく，相関係数をテーマに研究することも少なくありません。実験など，介入の前後や群間の比較であれば平均値の話になりますが，こうした因果関係が明確でなく，何らかの関係があるかもしれない，という見込みで探索的に現象を解明していくこともよくあります。たとえばうつ病と起床時間に関係があるのかもしれない。自尊心の高さは学業成績と関係があるのかもしれない。恋愛に対する態度には性格が関係しているのかもしれない，云々。何だか心理学っぽい話になってきましたね！

[*6] 優位と誤変換しないように注意してください。普通の変換では優位のほうが先に候補になりますが，心理学畑出身の人は有意のほうが先に変換候補に出るようになるでしょう。

さて最後の例，恋愛に対する態度と性格の関係，を研究したいとしましょう。先行研究から，「恋愛についての積極性」を測定する尺度と，外向的な性格かどうかを測定する尺度があったとします[*7]。この尺度を使って，協力者を 20 人募って回答を求め，標本相関係数を算出したところ，$r = 0.5$ という数字が得られたとします (相関係数の算出については第 6 講を思い出してください)[*8]。

さて，標本相関係数は $r = 0.5$ ですが，母相関係数はどうでしょうか。母集団でもこの 2 変数は関係がある，と言って良いでしょうか。標本の話を母集団に広めるには推定，そして結論づけるには検定をするのでした。検定のステップを踏んで話を進めましょう。

■仮説の設定：相関係数の場合　まずは仮説の設定です。帰無仮説と対立仮説が必要なのでした。帰無仮説は Null な仮説ですから，今回は「相関関係がない」というのがそれになります。母相関はギリシア文字 ρ(ローとよむ) で表されますから，数学的な表現をすると帰無仮説は $H_0 : \rho = 0$ です。母相関が 0.0 と一致する，という強い主張ですね。これに対する対立仮説は，これの否定ですから $H_1 : \rho \neq 0$ です。既にこの 2 つのモデル対決，帰無仮説はピンポイント予測ですから，かなり狭い可能性のような気もしますが，帰無仮説検定の話の上ではこうならざるを得ないのです。

というのも，帰無仮説検定は背理法のロジックを使う，というところにその話の味噌があります。まずは極端かもしれませんが，帰無仮説の世界を想定しておき，それにしたがっていくとおかしなことが起こるなら，帰無仮説を棄却する，という話の進め方です。母相関が 0 な世界を想定してみましょう – 幸い，最近はコンピュータを使って簡単にシミュレーションをできます。相関係数が 0 の世界があり，そこから 20 人のサンプルをとっていくとしましょう。

図 13.1 に示したのは，母相関 $\rho = 0$ の世界から乱数を 10 万点発生させ，そこからランダムに 20 個の点を取り出した例です。黒い点の塊はほぼ円で，二変数に相関がないというデータを具現化したものが示されています。小さな赤い点がそこから 20 個取り出した場合で，今回この 20 個の点による標本相関係数は $r = 0.143$ でした。理論的には $\rho = 0$ の世界からのサンプルなのですから，r も 0 であって欲しいかもしれませんが，一部の標本だけ取り出すとぴったり 0 になることはありません。同様のサンプルを何度も繰り返すと，標本相関係数は $r_2 = 0.32, r_3 = -0.46, r_4 = -0.26....$ といろいろな数字を取ります。この分布が標本分布になるのです。

このように，いったん「母相関は $\rho = 0$」，としてから標本を取り出したとして，その標本分布がどうなるかを考え，たまたま今回得られた標本相関係数 (今回の例では 0.5 でしたが) が出てくる確率はどれぐらいか，を考えます。その確率が非常に小さければ，滅多にないことが目の前のデータで生じたわけですから，これは前提である「母相関は $\rho = 0$」という仮定の方がおかしい，ということで帰無仮説を捨てるわけです。ここが背理

[*7] ここでは軽〜く書いていますが，心理的な状態を測定する物差しのことを**尺度 (scale)** といい，この尺度を作る・使い方を考えるのも心理学の重要な研究領域なのです。この領域をとくに**心理測定法**といいますが，テスト理論の発展系である因子分析モデルや構造方程式モデリングによって，調査項目に対する反応を細やかに検証する世界があります。それでなくても目に見えないものを測定するのですから，きちんと測定できているかどうかは大問題です。また世の中には論文化され，公開されている心理尺度はたくさんありますが，自分の研究に借用するときは「本当に自分が測りたいものと，この尺度が測ろうとするものが同じなのか」「今の，私の研究対象に同じ測定方法で測って同じ結果が得られるのか」，など常に批判的な態度を持っておく必要があります。

[*8] ちなみに，標本相関係数の期待値 (標本を何度もとったときの標本相関係数の平均値) は，母相関に**一致しません**。つまり不偏分散を計算したように，不偏相関係数を計算しなければならないのですが，簡単な式で表現できないので標本相関係数のままで推定することが慣例になっています (南風原，2002; 平川，2021)。また区間推定をする場合は，標本相関係数の標準誤差を考えなければなりません。標本相関係数の標準誤差の推定値 $\hat{\sigma}_r$ は，次の式で与えられます。

$$\hat{\sigma}_r = \frac{1 - r^2}{\sqrt{n}}$$

今回の場合ですと，$\hat{\sigma}_r = \frac{1 - 0.5^2}{\sqrt{20}} = 0.1677$ となります。ただし標本相関係数の標本分布は正規分布ではありませんので，区間推定をするには Fisher の Z 変換という手続きが必要です。

図 13.1　母相関 $\rho = 0$ の世界とそこから $n = 20$ のサンプルを取った例

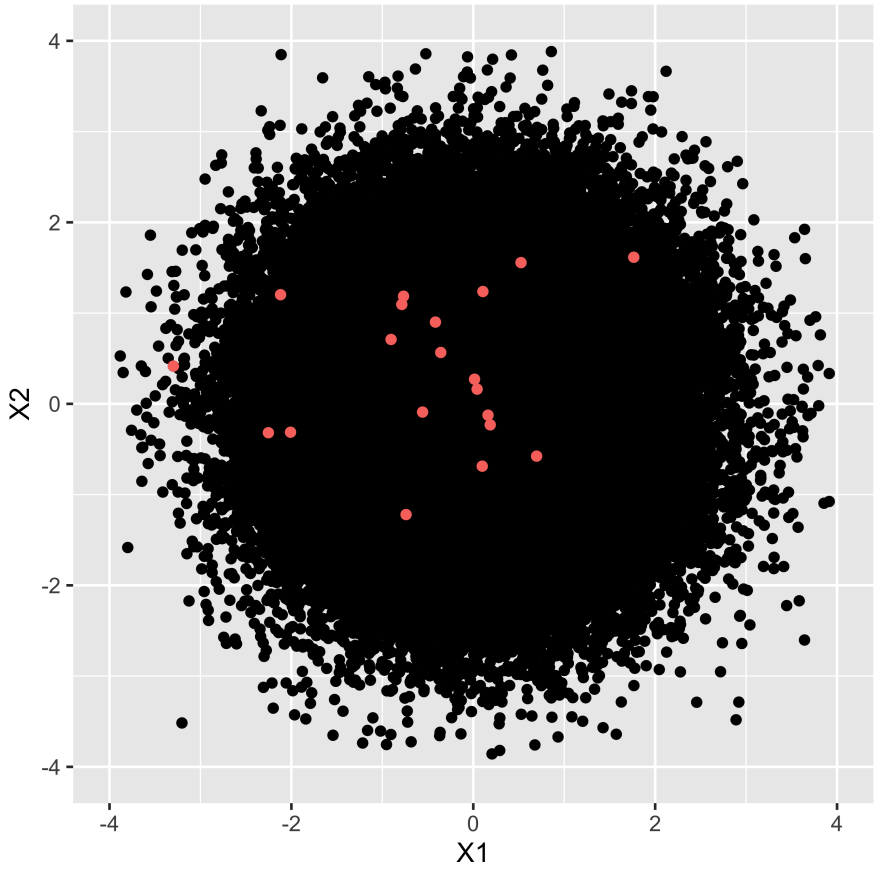

法になっているわけですね。また，帰無仮説として「母相関はありまぁす！」という仮定を置くのも難しいところなのがわかっていただけるかと思います。相関が「ある」といって，どの程度あるのかは無数に考えられるのに対し，相関が「ない」の場合は一意に定まるからです。

■検定統計量を定める　ここで，標本相関係数の標本分布は，自由度 $n-2$ の t 分布に従うことがわかっています[*9]。ただ，そのまま相関係数を使うのではなくて，標本相関係数を次の式で変換する必要があります。

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

■判断基準の設定　今回も慣例に倣って 0.05(5%) にしましょう。

■検定統計量の算出　今回の例では，

$$t = \frac{0.5 \times \sqrt{18}}{\sqrt{1-0.25}} = 2.44949$$

となりました。

[*9] なんだそれ！と思った人もいるかもしれません。どうして平均値の推定に使った t がここでも出てくるのか，という問題は興味深く，この話をするには数理統計学の話題を持ってくる必要がありますが，流石にそれは寄り道しすぎなので，数理統計学に感謝して先に進みましょう。

■では判定を 今回得られた数字，$t = 2.45$ よりも大きい数字が自由度 18 の t 分布から出てくる確率はどれぐらいでしょう？ これを計算すると[*10]その確率は $p = 0.01237173$ です。またここでは，$\rho = 0.0$ の元で標本相関係数が 0.5 より大きくなる確率を考えているのですが，この偏った相関係数の出方は $|r| > 0.5$ についての話ですから，左右対称の分布であることから $p = 0.0124 \times 2 = 0.0248$ と考えるべきです。いずれにせよ，絶対値 0.5 以上の標本相関係数が得られる確率は 5% よりも小さい数字で，勝負の判定としては「滅多にないことが起こった」と言って良いわけですから，これは帰無仮説がおかしい。そもそも母相関が $\rho = 0$ であれば，たまたま標本から相関係数 $r = 0.5$ が出てくるなんて，ありえへん，というわけです。そこで結論は，帰無仮説の棄却，対立仮説の採択となります。図 13.2 に t 分布，臨界値，実現値の関係を図示しましたので，確認しておいてください。

図 13.2 相関係数の検定結果を t 分布で判断する

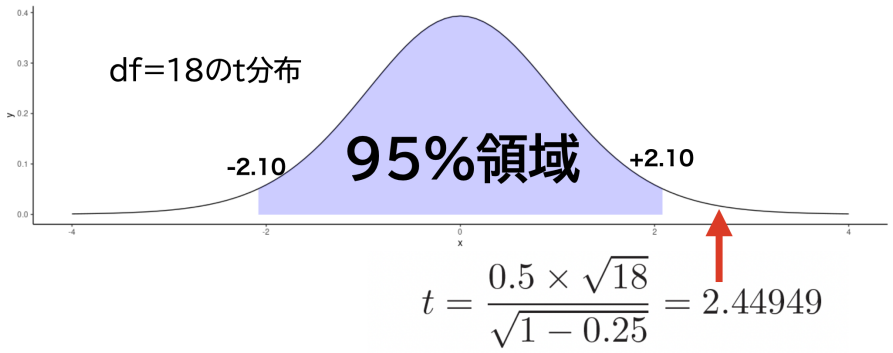

いかがだったでしょうか。帰無仮説検定は帰無仮説と対立仮説のモデル比較，仮想的な勝負であり，その判定の仕方を検定と呼ぶというのがお分かりいただけましたでしょうか。ちなみにここで有意かどうかの判断をしたことと，相関係数の大きさとは別の話です。サンプルサイズが非常に大きくなると，僅かな違いでも検出しやすくなり，たとえば $r = 0.01$ でも有意になることがあります。つまり，帰無仮説検定は「差があるかないか」を判断するものであって，「どれぐらいの差があるか」を判断するものではないことに注意してください。

13.3 χ^2 検定

今度は χ^2 検定を考えてみましょう。セクション 6.4.1,Pp.90 で学んだように，χ^2 検定は度数のばらつきが期待値とどれぐらい違うかを検定する方法でした。ここでは，χ^2 検定を使って，度数分布の偏りがあるかどうかを判断する方法を考えてみましょう。

セクション 6.4.1 でも紹介した，睡眠障害と年齢の関係のクロス集計表を例に取ります (表 13.1)。あらためて同じ表を掲載しますが，ここでは年齢層と睡眠障害の有無の関係を調べたのでした。年齢層は 10 代，20 代，30 代，40 代以上の 4 つに分け，睡眠障害の有無は「あり」「なし」の 2 つに分けています。

以前は，行や列の相対度数を見て考察したり，χ^2 値から**クラメールの V(Cramér's V)** を計算したりして，関係の強さを記述したのでした。χ^2 値が大きいとか，クラメールの V が大きいから関係があるんだ，というのはあくまでも記述的な話であり，大小の評価について客観的な基準が弱いともいえます。

そこで推測統計学的に，このようなクロス集計表の関係が偶然に生じたものではない，ということを検定してみましょう。

[*10] R で `1-pt(2.45,df=18)` とします。

表 13.1　年齢層と睡眠障害のクロス集計表

	あり	なし	合計
10 代	8	30	38
20 代	30	77	107
30 代	27	60	87
40 代以上	40	28	68
合計	105	195	300

■仮説の設定：クロス集計表の場合　まずは仮説の設定です。クロス集計表の検定では，**帰無仮説 (null hypothesis)** は「行と列の度数分布は独立である」とします。つまり，両者は実は何の関係もなく，たまたまこのようなばらつきになったのだと考えるのです。これに対して**対立仮説 (alternative hypothesis)** は「行と列の度数分布は独立ではない」，つまり何らかの関係がある，ということになります。

■検定統計量を定める　検定統計量はすでにサブタイトルにもあるように，χ^2 値を使います。

■判断基準の設定　今回も慣例に倣って 0.05(5%) にしましょう。

■検定統計量の算出　今回は 23.095 になりました。計算の仕方はセクション 6.4.1 で学んだ通りですが，実際は R が検定結果とともに算出してくれますので，それほど気にしなくて構いません。

■では判定を　ここで，χ^2 値がどれぐらいの確率で出てくるのかを計算します。自由度は (行数-1)(列数-1) として計算するので，今回は 3 になります。R には次のように入力するといいでしょう。

code : 13.1　クロス集計表の検定結果を R で計算する

```
1  cross <- matrix(c(8,30,30,77,27,60,40,28), ncol = 2, byrow = T)
2  print(cross)
3  chisq.test(cross)
```

■コード解説

1 行目　`matrix` 関数で度数データを行列として作成します。`c()` で数値を並べ，`ncol=2` で 2 列，`byrow=T` で行優先で入力します。今回はローデータからクロス集計表を作成するので，このような形で作りましたが，実際は `table` 関数などでデータから作ることが多いでしょう。

2 行目　`print` 関数で作成した行列の内容を確認・表示します。

3 行目　`chisq.test` 関数でカイ二乗検定を実行し，統計量と有意確率を算出します。

出力結果を見てみます (出力 13.1)。χ^2 値は 23.095，自由度は 3，そして p 値は 3.858×10^{-5} となりました。これは非常に小さい数字で，5% の有意水準を大きく下回っています。つまり，帰無仮説を棄却し，対立仮説を採択することになります。つまり，年齢層と睡眠障害の有無には何らかの関係がある，と判断することになります。

R の出力 13.1: 出力例

```
> cross <- matrix(c(8,30,30,77,27,60,40,28), ncol = 2, byrow = T)
> cross
     [,1] [,2]
[1,]    8   30
[2,]   30   77
[3,]   27   60
[4,]   40   28
> chisq.test(cross)

        Pearson's Chi-squared test

data:  cross
X-squared = 23.095, df = 3, p-value = 3.858e-05
```

13.4 1 つの平均値の検定

次に, 心理学で最もよく使われる検定の一つである, 平均値の検定についてみていきます。実践的には複数の群の平均値を比較することが多いのですが, まずは 1 つの平均値の検定から始めていきましょう。

まずは平均値の推定の時と同じく, 母集団の SD がわかっている場合に標準正規分布を使っての検定を, 次に母集団の SD がわからない時の, t 分布を使っての検定を見ていくことにします。

13.4.1 母 SD がわかっている場合

さて, 話を進めるために, 具体的な例をあげてみましょう。ある学校で, 学力テストしたとします。その学校で無作為に 49 人分の記録を取り出したところ, 平均が 52 点でした。このテスト, 全国平均は 50 点で, SD が 9 の正規分布であることがわかっていたとします。これとそのまま比べると, その学校の成績が良い, ということになりますが, たった 2 点差でそのように結論づけて良いかどうか, というのがここでの問題です。

帰無仮説検定のステップを思い出しましょう。まずは仮説を設定します。ここでやりたいことは,「この学校の成績が良いかどうかの判断」です。言い換えると, 全国平均の分布が母集団でそれの平均や SD がわかっているのですから, この標本の平均は母平均と同じなのか, 異なっているのかが知りたいのです。標本ですからたまたま高い点数が出ること (そしてその逆) もありますが, この標本平均から推測される母平均と, このテストの理論的な平均値 (全国平均) の違いが**統計的に有意な差なのかどうか**が知りたいわけです。数式で表現すると, 標本平均は $\bar{X}$ で, $\bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$ ですから, この時の $\mu = 50$ が帰無仮説, $\mu \neq 50$ が対立仮説ということになります。

次に検定統計量ですが, 平均値の推定, しかも理論的に平均 50, SD9 の正規分布との照合ですから, 推定したい対象の特徴がもうわかっている特殊なケースです。これは変換すれば標準正規分布に従うのですから, 標準化された Z 得点が検定統計量になります。

第 3 のステップは基準になる確率を設定する, でした。勝敗を決めるルールの決定ですね。これはとくに意味もなく, 慣例にしたがって 0.05(5%) としておきましょう。

これで準備が終わりました。実際の検定統計量の計算です。平均 μ, 分散 σ^2 の正規分布する母集団からの標本の場合, 標本平均の標本分布も正規分布に従い,

$$\bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$$

になります。今回の場合は，

$$52 \sim N(50, 9/\sqrt{49})$$

だと考えられます。標準化することで標準正規分布を使うことができますから，

$$(52-50)/(9/7) \sim N(0,1)$$

として，$(52-50)/(9/7) = 2/1.285714 = 1.555...$ を得ます。この 1.556(下三桁までで四捨五入しました) という数字はどのあたりに位置するのでしょう？

そこで確率の計算をしてみましょう。これが次のステップの，実際のデータから検定統計量の実現値を計算する，というやつです。標準正規分布において，1.556 より大きな数字が得られる確率は[*11]，$p = 0.05985405$ でした[*12]。5.9% なのですね。

最後に判定です。5% が判定ラインだったわけですが，今回得られた「確率変数の実現値」は 5% より大きな確率です。つまり大きい＝出現する可能性が大きい，よくある話だったわけです。そんなにレアな数字じゃない。つまり，たまたま今回の標本が，平均から 2 点大きくなるようなことは十分あり得る話だということです。この学校の生徒は優秀だー！と言いたいところなんですが，偶然それぐらいの差がでることがあるのであれば，そこまで胸を張っていうことができません。ということで，軍配としては帰無仮説の勝ち，つまり，「その学校の成績が特段良いわけではない」「統計的には差がない」ということになります。

図で確認しておきましょう。図 13.3 には標準正規分布と今回の判定に係る数字を記載しました。今回計算した統計量は，標準正規分布にしたがいます。標準正規分布で 5% という基準を考えると，± 1.96 を超えた領域になります。今回のデータがこの領域に入るほどのものであれば，帰無仮説は棄却することになりますが，今回はその領域に入らない，つまり「このサンプルからこの平均値が出てくることも，あるよ」ということで棄却できないのでした。帰無仮説を棄却する領域のことを一般に**棄却域**といい，この数字を越えれば棄却域に入るというギリギリの数字のことを**臨界値**といいます。今回の臨界値は ± 1.96 で，両端が棄却域，今回の 1.55 という実現値は棄却域に入らなかったので帰無仮説の勝ち，ということです。

図 13.3　棄却域と臨界値

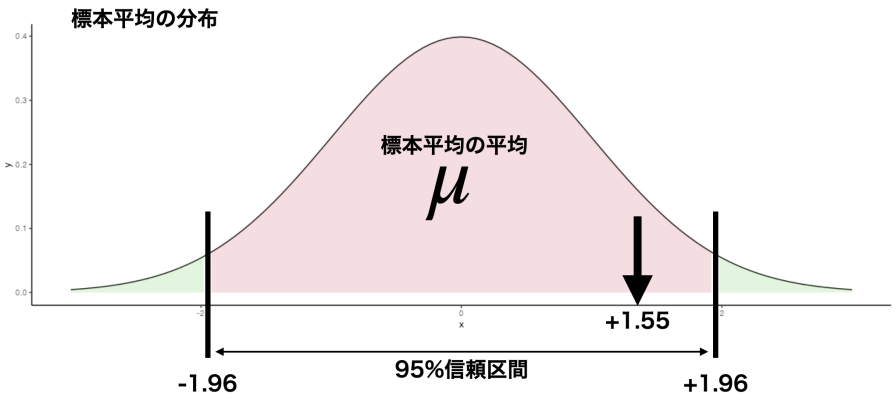

[*11] これまた確率の，とくに連続変数のややこしいところで，1.556 という数字が出てくる確率はゼロです。ユークリッド幾何学でいうところの，点は位置があって大きさがないというのと同じで，点の確率は大きさがないのです。確率は面積ですから，1.556より大きな数字が得られる確率，というのが本当は正しい表現です。

[*12] これは R で次のように計算しています：`1-pnorm(1.556,mean=0,sd=1)`

13.4.2 母 SD がわかっていない場合

先ほどの例は，母 SD がわかっているという話でした。まあ母数がわかっていれば苦労はないわけで，それが分からないから推測するのですよね。

ということで，母 SD の代わりに標本 SD(**不偏分散**の正の平方根) を使って推定することとします。そのさいは (標準) 正規分布が使えないので，サンプルサイズに応じた t 分布を使うのでした。同じデータ例でやってみましょう。今度は標本の標準偏差が必要ですので，これが $\hat{\sigma} = 10$ だったとします。

帰無仮説・対立仮説はさきほどと同じく，$\mu = 50$ か $\mu \neq 50$ です。ただし推測に使う統計量が t になるわけです。判断基準も同じく慣例にならって，なんとなく 5% にしておきましょう。検定統計量 t は $t = \dfrac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{n}}$ で求めることができますから，

$$t = (52 - 50)/(10/7) = 1.4$$

となります。これが自由度 $n - 1 = 48$ の t 分布に従うので，自由度 48 の t 分布において 1.4 以上の数字が出る確率を求めますと，$p = 0.08397194$ となりました[*13]。8.3% なのですね。

これで判定です。5% の判定ラインより大きな確率が出ましたので，これは滅多にないことではない。なくはないのだから，よくある話。珍しいことじゃない。つまり，母平均から外れて大きい数字，とまでは言えないねということになります。今回の判定に関するイメージを図 13.4 に示しました。今回は自由度 48 の t 分布を描き，検定統計量の実現値を示しています。実現値が棄却域に入るか入らないか，という判断をしてもいいですし，今回のように直接確率を算出して 5% になるかどうかの判定をしてもらっても結構です[*14]。

図 13.4 t 分布をつかったときの棄却域と臨界値

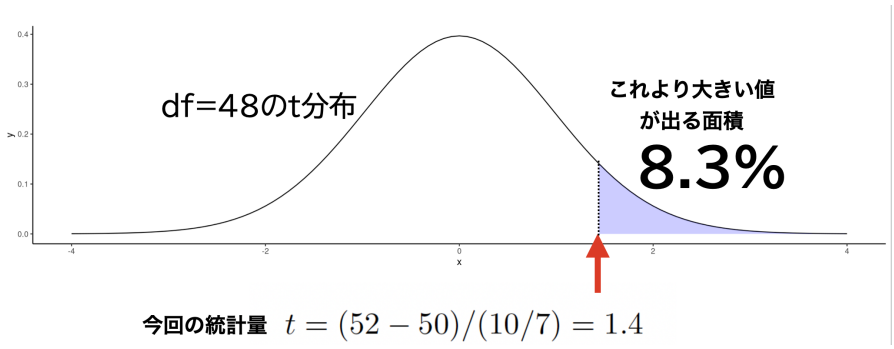

いかがでしたでしょうか。今回のデータでは (母 SD がわかっていても，わかっていなくても) 帰無仮説を棄却することはできませんでした。何だか持って回った言い方をしているように感じられるかもしれませんし，いまいちイメージが掴みにくいかもしれません。そこで，今度はまた別のケース，相関係数の例で考えてみたいと思います。徐々に手続きと結論の出し方に慣れていくと思います。

[*13] これは R で次のように計算しています: `1-pt(1.4,df=48)`

[*14] 直接確率を計算する方が楽なのに，と思う方もいるかもしれません。これは歴史的な経緯があって，今でこそ R などを使って簡単に確率点が計算できますが，そういう機械がなかった頃は数字の表を見て判断していたのです。第 10 講義のセクション 10.8.2,Pp.160 で数表のことをご紹介しましたが，あれを見て臨界値の大小で棄却域に入ったかどうかを判断する，というのが一般だった時の名残だと思ってください。

13.5 結果の報告の仕方

帰無仮説検定は帰無仮説と対立仮説のモデル対決なので，結果は軍配をはっきり示す必要があります。帰無仮説が勝ったのか，対立仮説が勝ったのかを明記するのです。ちなみに仮説が勝った，というのを**採択 (accept)**，負けたというのを**棄却 (reject)** と言うのでした。ですから「帰無仮説を棄却して対立仮説を採択」，あるいは「帰無仮説が棄却できずに採択，対立仮説を棄却」のどちらかになります。

また，結果の判定ですから，判定に使った数字＝検定統計量も報告する必要があります。たとえば相関係数の検定の例では，t 統計量が使われましたので，これを報告します。また，t 統計量は t 分布に従い，これはサンプルサイズに依存する自由度によって調整されるものですから，自由度も報告する必要があります。前回の例では，相関係数 $r = 0.50$ がサンプルサイズ 20 のデータから得られ，統計的に有意であると結論づけられたのでした。この結果は，次のように報告しましょう。

> 標本から得られた標本相関係数 $r = 0.50$ について仮説検定を行ったところ，$t(18) = 2.450, p = 0.0248$ で統計的に有意であった。

書き方のポイントとしては，統計量を書くこと，そしてその時の統計量はイタリック (斜体) であること[*15]，その統計量の実現値が得られる確率 (p 値) を記載すること，です。

p 値は上の例のように確率そのものを書くのが基本ですが，昔は判定基準を使って $p < 0.05$ とか $p < 0.01$ と書いていました。これは手計算で検定をしていた頃の名残で，統計環境 R などがなかったものですから確率計算が直接できませんでした。ではどうしていたか，というと代表的な確率分布の数字が載っている数表[*16]を使ってチェックするしかなかったので，細かい数字まで計算できなかったのです[*17]。今ではそういう問題がないので，そのまま p 値を書きましょう。

[*15] 字体を整えるのは，心理学だけでなく論文の書き方として一般的です。統計量や本のタイトルなどはイタリックであることが決まっています。誰が決めているかって? American Psychological Association の Publication Manual にそう定められていますし，日本の心理学会も基本的にこれに準じた出版作法を定めているのです。

[*16] 昔は確率分布の数字の一覧が載っている本がありました。確率のテキストには付録として，数表の一部が載っているものもあります。

[*17] たとえば t 分布は自由度によって変わりますが，自由度 $1, 2, 3\cdots$ と 1 つずつ書いてあったのでは，付録のページ数がいくつあっても足りません。そこで $1, 2, 3...10, 15, 30, 50$ のように，後半の方は「だいたいこれぐらい」という大雑把な幅でしか載っていませんでした。こんな時，じゃあ自由度 18 ならどうしたらいいんだ，と思うかもしれませんが，その時は手元のデータに最も近く，より厳しい自由度 15 のところを見て代替する，というやりかたでした。ですから具体的な p 値は書けなかったのです。

第 14 章

帰無仮説検定の注意点

さて前回は帰無仮説検定について説明しましたが，いかがだったでしょうか。まず「関係がない」「差がない」といった**帰無仮説**をおき，本来主張したいことを**対立仮説**とし，帰無仮説の否定をもって対立仮説の採択とする，という**背理法**のロジックで結論を導き出しますから，少しひねくれた考え方になっていることに注意が必要です。手元に得られたデータが，帰無仮説の下では滅多に生じ得ないことだということでもって，帰無仮説を棄却するということも理解していただいておりますでしょうか。

今回は，この帰無仮説検定を行った結果を，どのように報告し，どのように解釈するのかについての解説を行います。とくに解釈の仕方については注意が必要で，少し触れたように帰無仮説検定は**誤用・誤解が多い**ことも指摘されています。筆者の考えでは，背理法というひねくれた考え方と，基準となる確率の考え方が不自然であることに根本的な原因があり，初学者には帰無仮説検定は向いてないのではないかとさえ思います。それでもその手軽さから広く浸透した手法ですから，皆さんが先行研究などで触れる過去の論文の中にも間違った使い方，間違った解釈をしているものが含まれているかもしれません[*1]。皆さんが同じ過ちを犯さないように，しっかりと基礎知識を身につけ，安易で誤った答えに飛びつかないようにしてください。

14.1　有意水準と p 値の解釈

先の章では，相関係数と χ^2 値の検定，平均値がある値であるかどうかの検定 (一標本検定) をみてきました。どちらも帰無仮説と対立仮説を立て，検定統計量を計算し，その値が有意水準を上回るかどうかで棄却・採択を判断するという流れでした。データの種類や統計量にかかわらず，帰無仮説検定は同じ手順を踏みますので，このようにマニュアル化することができます。そのおかげもあって，心理学をはじめとして多くの領域で検定が行われるようになりました。実際，統計パッケージには検定をするための関数やメニューがあり，ジャンルが心理学であれ経済学であれマーケティングであれ生物学であれ，とにかく尺度水準や検定統計量の選定を間違えなければ検定はできるというわけです。また，検定の結果「有意である」となれば「差がある」「効果がある」といった結論にお墨付きがもらえるように思えるのも，検定が広く使われる理由の一つです。

しかし，検定の結果が有意であるということは，必ずしも意義のある結果であるというわけではありません。あくまでも「統計的に有意である」ということであり，「実社会において意味 (意義)がある」ということではないのです。この辺りは誤解や誤用が多いところなので，しっかりと注意しておきます。

[*1] プロの研究者 (大学教員など) が書いて，プロの研究者が査読して刊行されている学会論文においてさえ，間違った手法や解釈が含まれている可能性があります。一つは時代的なもので，かつて計算機が十分に発達していなかった頃には正しい分析法が適用できず，やむなく代替案・次善の策として別の方法を使わざるを得なかった，という事情です。当時は正しいとされていた分析手法が，のちの研究で問題が指摘され，より改良された正しい方法ができることもあります。いずれにせよ研究をする上では，常により正しい手法を使うように心がけなければなりません。また，正しくない手法と知りながら実践するような態度は厳に慎まなければなりません。

まず，検定は「誤った判断をしない」ことを目的にしています。確率的な判断なので確実に間違えないことは無理ですが，せめて「効果 (差) がないのにあると判断する」ことを避けよう，というのが検定の目的です。100% の確率で間違えない，というのは無理ですが，5% の確率で間違えることを許容する，というのが有意水準です。つまり，帰無仮説検定は「帰無仮説が正しいときに，それを棄却してしまう確率を 5% 以下に抑える」ということを目的にしています。

また，帰無仮説検定は判断のためのツールであることを忘れてはいけません。データからはいろいろ考えられることがありますが，その中で仮に「帰無仮説が正しかったら」という 'if' の世界を考えて，これに対抗する「帰無仮説が正しくなかったら」という 'if not' の世界との**モデル比較**をしているのです。その時の勝負の判定基準が有意水準です。ですから p 値が有意水準を下回った (=効果があった，差があった) というのも，あくまでも 'if' 世界の話であって，現実世界の話ではないのです。また，勝負がつくかどうかの判定であって，モデルの強さや正しさを表現する数字ではありません。

野球に例えていうならば，検定は遠くに飛んだ打球がフェンスを超えたかどうか，という判断をしているだけであり，ホームランの打球がどれぐらい速かったか，どれぐらい遠くに飛んだか，ということを表現しているわけではありません。ホームランの打球が速いかどうかは，別の指標である打球速度や飛距離で表現されるはずですし，打者が優れているかどうか，チームが強いかどうかという話ではないのです。

なぜこのように口やかましくいうかというと，上で挙げたような誤解が少なくないからです。Wasserstein & Lazar (2016) では，p 値について次の 6 つの原則をあげています。

1. p 値は，データが特定の統計モデルとどの程度両立しないかを示す
2. p 値は仮説が真である確率や，データが偶然によって生成された確率を測定しない
3. 科学的結論は，p 値が特定の閾値を超えるかどうかのみに基づくべきではない
4. 適切な推論には完全な報告と透明性が必要
5. p 値や統計的有意性は，効果の大きさや結果の重要性を測定しない
6. p 値単独では，モデルや仮説に関する証拠の良い尺度を提供しない

このような警句を発しなければならないほど，p 値や有意水準の使い方が誤解されているということです。心理学では，このような誤解を避けるために，検定の結果を報告する際には有意水準を明示することが求められています。たとえば「$p < .05$」といった形で，どの有意水準で検定したかを明示するのです。

また，結果の報告だけでなくその解釈において，p 値が小さければ小さいほど良いとか，p 値が小さい方がより強い・正しい仮説であることを意味する，といった解釈は明らかに誤りです (でもときどきそのような表現を見かけます)。p 値は帰無仮説が正しいという仮定の世界での値であり，現実の世界での正しさや正確さを表現しません。ある意味，帰無仮説は常に正しい (仮定しているのだから) わけであり，p 値の大きさに一喜一憂する必要はないのです。

同様に，有意水準の設定にも注意が必要です。心理学では 5% 水準がよく使われますが，これはあくまでも習慣的なものであり，1% の方が厳しい検定をした (それを潜り抜けたから，より強い証拠が得られたと言える！) というわけではありません。基準は 6% でも 4% でも 10% でも構わないのです。たまに，5% 水準で検定をしたが有意にならず，p 値を見ると 0.06「おしい」ので，「有意傾向にあった」という表現を見かけることがあります。これは「もうちょっとでホームランだったのに」と言ってることと同じで，「もうちょっとでホームランだったから，点数が入ったものとして考察する」というのはおかしなことなのです。

14.2 結果の報告と解釈

あらためて考えると，「統計的に有意 statistically significant」とはどういうものでしょうか。

相関係数の検定の時のことを思い出しましょう。帰無仮説は $\rho = 0$ というものでした。これが棄却されたので,「統計的に有意な相関係数だ」と結論づけたわけですが, より正しくは「母相関が 0 であるとはいえない」ということですよね。関係がないとは言えない $\rightarrow$ 関係がある, というこの $\rightarrow$ の部分は, 厳密に言えば少し飛躍があることになります[*2]。

この帰無仮説検定を考えた人は, R.A. フィッシャーという人なのですが, この人は帰無仮説が棄却されたら「なにかおかしなことが現実に起こっているのだから, 実験手続きを見直したほうがいい」というチェックのために使うことを想定していました。これを E. ピアソンと J. ネイマンという人が「帰無仮説の棄却＝対立仮説の採択, とすれば良い」という判断基準と合わせて使う方法へ応用したのです。心理学ではその流れを受けて帰無仮説検定を利用してきました。そういう意味で, 本来の創始者の意図とは違った, より実践的な意味のある (言い換えれば実用上の責任を負わなければならない) 使い方をしているのです。

また既に述べたように, 実際の相関係数の大きさや, 平均値の差についての情報がかき消された表現になっていることにも注意が必要です。最終的な判断は p 値だけを見るのですが, この数字だけみても相関係数の大きさや, 平均値の差がどれぐらいあったのかはわかりません。有意になったという結果だけをみて, 関係があったのか, そうかー, と考察を巡らせても, 実は標本相関係数が $r = 0.1$ だったということもありえるのです[*3]。これで「統計的に有意だ！無相関とは言えない！」と言っても, 標本相関係数が 0.1 なのですから,「(相関) 関係がある」という結果をもとに議論するとおかしなことになってしまいます。

ところが実際, このような表面上の使われ方に引っ張られてしまうことはよくあります。とくに研究をしていると, 努力したのに関係がなかったとは言いたくないという気持ちが働いてしまいます。そこで, 有意になったんだから意味はあるよね, と考えて無理やり二変数間の関係を考察してしまう, ということになってしまいます。これではせっかくデータを取ったのに, 正しく考えられたことになりません。

一般にサンプルサイズが大きいと, p 値は小さくできますから, 帰無仮説は棄却しやすくなります。図 14.1 には, 横軸にサンプルサイズ, 縦軸に p 値をとり, 標本相関係数が $r = 0.5, 0.3, 0.1$ のときにどうなるかをプロットしました。5% を有意水準 (点線) としていますが, サンプルサイズが大きくなるにつれて p 値は小さくなって行きます。

図 14.1 サンプルサイズと p 値の関係

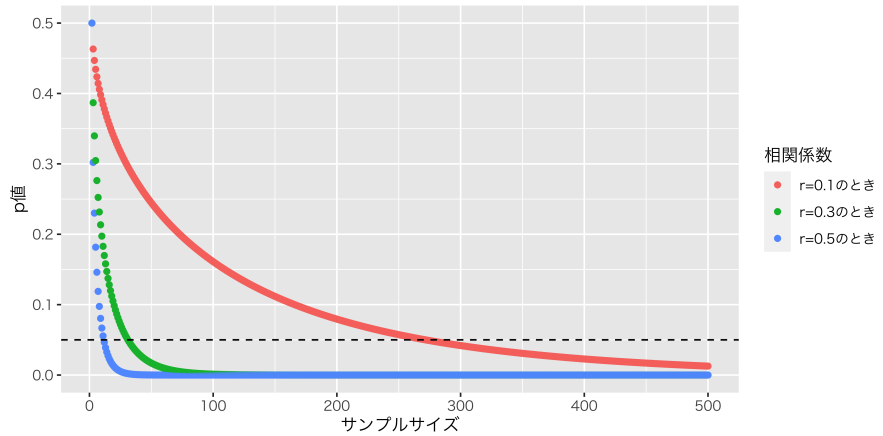

この下がり方はどこからスタートするかにかかわらず同じ形ですから, 判定はサンプルサイズが増えさえすればいずれ有意になるのです。これがまた, 研究の実践ではおかしな風潮を呼んでしまいます。つまり,

[*2] 「あなたのことが嫌いではない」といわれても好きだとは言われてないわけで。

[*3] 実際に, サンプルサイズが 271 人を超えると, 標本相関係数が 0.1 でも 5% 水準で有意になります。

有意にしたければサンプルサイズをたくさん取る＝頑張れば良いのです。

しかしながら，科学的に正しいかどうかを考えるべきシーンで，「頑張れば有意になる」といった “努力” に依存するのはおかしいことだと思いませんか。頑張った → 有意になった → 著者の主張が正しい，というのは，論理的ではありません。結果を自分の都合の良いように変えることは，正しい努力ではないはずです。

帰無仮説検定は，標本から母集団のことを「判定」できる優れた技術ですが，表現とその解釈に気をつけないと，科学を間違った方向に導きかねないことに注意が必要です。残念ながら，これまでの心理学の歴史の中でもこのような間違った努力がなされてきた事実があります。これらは**問題のある研究実践 (questionable research practices)**，すなわち **QRPs** と言われています。たとえば「有意な結果にするために」サンプルサイズを増やすとか，「有意な結果になるまで」検定を繰り返す，といったことが QRPs に当たります。そうした研究実践が実際に行われている現場も少なくないようです。しかしそんなことをしていると，必然的に科学の議論が「正しくない結果 (の解釈)」に基づきますから，後続の研究が土台から崩れ，長年の努力が無駄になってしまいます。データの捏造や，他人の書いた論文を盗む剽窃は明らかに悪意のある行為ですが，「頑張ってデータを増やす」というのは一見真面目で誠実な研究態度に思えてしまうので，ちょっとタチが悪い問題です。努力が人を誤らせるのですから。皆さんも騙されたり間違った道に進んでしまわないよう，十分に注意して研究を進めてください。

14.3 検定における 2 種類の誤り

14.3.1 p 値とは何か

ところで，帰無仮説検定は「推定」の応用である「判断」だということでした。判断が確率的に行われるのですが，人間は確率的な考え方が得意ではありませんから，うっかり間違って理解してしまうことも少なくありません。正しい判断，間違った判断というのはどういうときに起こるのかを考えてみましょう。実はこれも，確率的表現の難しさがあるのです。

帰無仮説検定最後のステップでは「最初に定めた仮説を支持するかどうか判断する」というのがありました。この判断の間違い方にも，2 種類あることになります。つまり，「帰無仮説が正しいのに棄却してしまう」という間違い方と，「帰無仮説が正しくないのに採択してしまう」という間違い方です。

図 14.2 二種類の間違い方

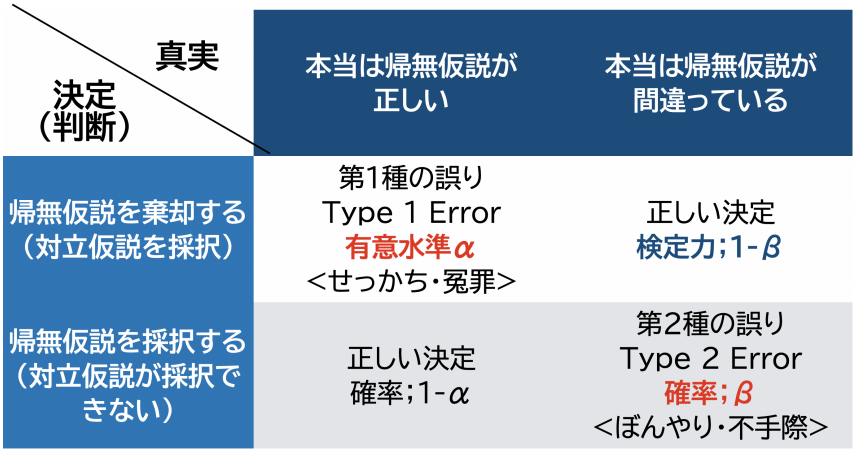

図 14.2 に，間違い方の組み合わせを書いてみました。帰無仮説が正しいときに帰無仮説を採択する，帰無

仮説が正しくないので帰無仮説を棄却する。これができれば正しい決定ですが，「帰無仮説が正しいのに帰無仮説を棄却する」のも「帰無仮説が正しくないのに帰無仮説を採択する」のも間違いです。

帰無仮説は差がないとか効果がないといったからっぽ (Null) な結論です。ここでは仮に，開発された新薬に治療効果があるかどうかを考えている，というシーンを想像してみてください。帰無仮説はこの新薬に効果がないときです。ロクな効果がないときに，帰無仮説を棄却する＝対立仮説を採択する＝効果があると言ってしまうのは，怖いことですね (患者さんに副作用など悪影響があるかも！)。このような功を焦って誤った判断をしてしまう危険な間違いを，**タイプ 1 エラー (type I error)** とよび，その確率を α で表します。実は，5% 水準で判断するというのは，この α の確率を 0.05 にしたことになります。慣例では $\alpha = 0.05$ となっていますが，別に 1% でも 10% でも，自由に決定して構いません。どの程度の水準にするかは，この間違いを犯した時の重要さを参照しながら決めるべきことです。

一方，効果があるのに (帰無仮説が間違ってるのに)，帰無仮説を採択するのは，せっかくの効果を見抜けなかった残念なケースです。これも困った結果ではありますが，少なくとも患者に迷惑がかかるようなことはありませんよね。なので，こちらについてはひとまず間違っても実際的な問題は生じないでしょう。こちらのケースは**タイプ 2 エラー (type II error)** と呼び，確率は β で表すのが一般的です。ただ，この β は帰無仮説が間違っている，つまり Null「でない」状態が，どう「である」のかわからないので，大きさを見積もることはできません。せめて，効果があるときはちゃんとあるって知りたいよね，と思いを馳せるだけです。この図 14.2 にある表は，列ごとに世界線が分かれていますから，右列の「帰無仮説が間違っている世界」で「帰無仮説を採択してしまう確率」が β であれば，ちゃんと効果を見つけ出せる確率は $1 - \beta$ です。この $1 - \beta$ を**検定力 (power)** といい，検定力のある分析ができているかどうかをちゃんとチェックしておくのは，研究の手続き上重要なことです。

すでに述べたことですが，帰無仮説検定は α 水準を一定に保つことを目標にしています。β の方は「本当はどれぐらい差があるのか」がわからないので，コントロールのしようがないのです。事後的に，今回の β はどれぐらいだったのかな，と考えることはできますが，事前に調整することはできません。ですからせめて，α の方はコントロールしておきましょう，というのが帰無仮説検定の基本的な考え方なのですが，実はここにも注意が必要なのです。

14.3.2 α のインフレ

先ほど，5% 水準という**有意水準**は α を設定したことと同義だという話をしました。つまり効果がないのに効果があると言ってしまう，うっかりミスを防いでおこうという方針で判断基準を設計しておきましょうということです。それを踏まえた上で，次のような話を考えてみてください[*4]。

> あるレストランの地下にはたくさんのワインが貯蔵されているが，20 本に 1 本は酸っぱくなった不良品が混じっている。客がやってきて 1 本のワインを注文する時，ソムリエは長い目で見て 20 回に 1 回冷や汗をかくことになる。このレストランで開かれるパーティには 10 本単位でワインを出すことになっているが，1 本でも酸っぱいワインが入っていたらパーティはダメになってしまう。パーティーのときは，ソムリエはどれほど謝らなければならないか？

何だか怪しいレストラン，いかがわしいソムリエですね。こんな店が実在していたら行きたくないですが，もちろんこれは架空の話で，20 本に 1 本のダメなワインがあるというのは，帰無仮説検定における 5% の有意水準のメタファーになっています。つまり，5% の判断ミスが生じる危険性がある，ということですね。うっかり

[*4] この例え話は永田･吉田 (1997) からの引用です。

ミスの水準を 5% にしているのは，言い換えると 95% の高確率で判断があっているのですから，ほとんどの場合は問題ないとも言えます。このレストランでは 20 回に 1 回しかミスはない，というわけです。

ところがパーティーが開かれると，ワインがまとめてどっさり提供されるのでした。1 回のパーティで 10 本のワインが出るんでしたね。ひとまず 2 本のワインを持ってきたとします。危険率は 5%，安全率は 95% ですが，これは一本あたりの話です。2 本連続で安全である確率は，$0.95 \times 0.95 = 0.9025$ になります。言い換えると，どちらか一本がアウトである確率は $1 - 0.9025 = 0.0975$ で，なんとほとんど 10% ではありませんか。

同じように考えて，10 本まとめて持ってくると，その中のどれか一本でも間違っている確率は，$1 - (0.95)^{10} = 0.4013$ ということになります。40% ですね。つまり 10 本まとめて持ってくると，一本ずつだと 5% だった危険率が 40% に跳ね上がっていることがわかります。

話を心理学の世界に戻しましょう。心理学では実験の結果を検証するときに，5% の危険率で判断するのでした。さて，とある熱心な研究者がある現象についてさまざまな角度から研究し，何度も統計的な検定を重ねて結論を導き出そうとしているとします。その研究者はとても熱心で慎重なので，1 つの研究のなかに 10 種類の実験を考え，10 回それぞれ 5% 水準で帰無仮説検定を行い，丁寧に判断を繰り返してすべて有意な効果が得られたとします。これは頑健な結果だ，一連の研究はうまくいったぞ･･･といえるでしょうか。

実はそうならないのです。さきほどのワインの話のように。つまり 1 つの研究で 10 回検定を行うと，たまたまどこかで有意になる (差がないのに差があるように判断してしまう) 可能性が 40% に膨れ上がっています。つまり，一連の研究で 5% の危険率を維持しようとするなら，たとえば 10 回の検定が含まれるのであれば，それぞれの有意水準はせめて 0.5% にしておかなければなりません。さもないと，うっかりミスの確率がインフレしてしまうのです。

これも悲しいかな，努力が裏目に出てしまう可能性ですね。一見，1 つの論文で複数回の実験や検定を行なっているのは，慎重で真面目であり，有意な結果が出ればそれは十分強い証拠だ，と考えてしまいます。しかしこれはあくまでも 0/1 の判断であり，しかも確率的な判断ですから，間違いの評価の仕方も確率の理論に沿って丁寧に考えねばなりません！

実際ひとつの論文の中に複数回の検定が行われていることは，少なくありません。しかしその中で，α 水準の全体的な調整がなされていることはあまり見かけません。そう，多くの研究者は気づいていながら間違った研究実践をしているのです。「みんな間違っていてみんないい」とはならないのでして，こうした状況は一刻も早く修正する必要がありますが，なぜかなかなか浸透しないところでもあります。本来は，1 つの論文全体で調整をかけるべきなのですが･･･。こうした誤りに振り回されないようにするには，「差がある/ない」といった 1 bit 判断にするのではなく，「どの程度の」差が見られたのか，その効果の大きさをしっかり見極める目が必要になってきます。

14.4 効果量と例数設計

検定力のチェックは，分析が終わった後に事後的にすることもできますし，事前にすることもできます。事前に，というのは，みたい効果がどの程度あるのかを考え，その効果をきちんと検出するにはサンプルサイズをどれぐらいにすれば良いのかを考えること，でもあります。このサンプルサイズを考えることを，**例数設計 (sample size design)** といいます。

帰無仮説検定において，例数設計はとても大事なことです。既に述べたように，サンプルサイズが大きくなると有意だという判断はしやすくなります。これは p 値で判断する以上仕方のないことですが，だからと言ってそれを逆手にとって，事実よりも主張をするためにサンプルをたくさんとるのは，帰無仮説検定のハッキン

グのようなものです[*5]。ですので，検定をするときはまず「どの程度の効果が見込まれ，これを検証するためには何人ぐらいのサンプルをとらなければならない」と宣言してから，検定して判断するという手続きが必要です。この宣言をせずに検定をすると，「有意にするためにサンプルサイズを変えたのではないか」と批判されてしまうかもしれません。学部の授業や卒論で行う実験で，例数設計をしたりサンプルサイズの宣言をするようなことはないかもしれませんが，学術業界では事前に学会にこの宣言を伝えてから研究に取り掛かる，事前登録制 pre-registration が導入されはじめています。

ここで，検定の判定結果に関係してくる要素を改めて思い出してみましょう。1 つはもちろん**有意水準**ですね。これは判定を決める基準ですから，これが緩いと対立仮説の勝ち！という結果が出やすいことになります。2 つ目は**サンプルサイズ**ですね。サイズが大きければ区間推定の幅は狭くなりますから，たくさんデータをとれば取るほど対立仮説の勝ち！という結果が出やすいことになります。ここまではお分かりいただけていると思います。続いて 3 つ目は，**効果量 (effect size)** です。平均値差の検定の場合を例に簡単に言えば，群間の差の大きさのことです。母集団において本当に平均値の差が大きければ大きいほど，対立仮説の勝ち！という結果が出やすいことになります。これは当然ですよね。ただ，効果量を一般的にいうと**標準化された差**という言い方をします。100 点満点のテストで 1 点の差がある場合と，1000 点満点のテストで 1 点の差がある場合は同列に考えることができないですから，標準偏差で割ることで「標準偏差何個分離れているか」という表現にするのです。標本から推定する効果量としては，**Cohen の d(Cohen's d)** と **Hedges の g(Hedges's g)** が有名です。Cohen の d は次のようにして計算します。

$$d = \frac{\bar{X}_1 - \bar{X}_2}{\hat{\sigma}}$$

ここで分母の標準偏差は，2 群で同じであれば問題ないですが，異なる場合は $\hat{\sigma} = \sqrt{\frac{\sigma_1^2 + \sigma_2^2}{2}}$ として合わせて計算します。いずれにせよ，「本当に差が大きければ対立仮説が採択される」というのは当然そうあって欲しい性質ですから，これもお認めいただきやすいと思います。

そして最後にもう 1 つ。先ほどの二種類の間違いのうち，本当に差がある場合に正しく検出できる程度，つまり**検定力 (power)** というのがありました。うっかりミスである**タイプ 2 エラー**を犯す確率が β ですから，検定力は $1 - \beta$ です。これも大きければ大きいほど，正しく対立仮説を採択できます。このように，帰無仮説検定において判定に関係してくるのは有意水準，サンプルサイズ，効果量，検定力の 4 つであり，これらのうち 3 つが決まると残りの 1 つの要素は計算で決まります (水本・竹内，2011)。また有意水準 α は一般に 5% を使いますし，検定力 $1 - \beta$ も 0.8 ぐらいにするのがよい，というのが通例になっています。であれば，効果量に応じてサンプルサイズを決めることができるわけです。小さな効果しかなさそうなものであればサンプルサイズはたくさん必要ですし，逆もまた真です。ただ，「サンプルサイズは大きいに越したことはないだろう」というのは間違いで，そうすると実質的にはごくわずかな違いであっても，検定で検出してしまうことになるからです。もっとも，研究を始める前に効果量がどれぐらいなのかを事前に知るのは難しいところです。効果がどの程度あるかがわからないので，研究しようというシーンが多いでしょう。それでも先行研究があれば，そこにはすでにサンプルサイズも，実際のデータによる効果量も計算できるわけですから，効果量がどれくらいある研究なのかを計算することは可能です。

研究を行う前に，事前にこれらの計算をすることを**検定力分析 (power analysis)** と言います。検定力分析は，**例数設計**をするためにも行われる場合と，研究後にどれぐらい効果量があったのかを調べる場合の二種類があります。またこうした計算をするための統計パッケージや R の関数などがありますので，実際はこれらを使って計算することになります。

[*5] 実際これは **p-hacking** と呼ばれるよくない研究実践の典型例です。

図 14.3　統計的検定における四つの要素の関係

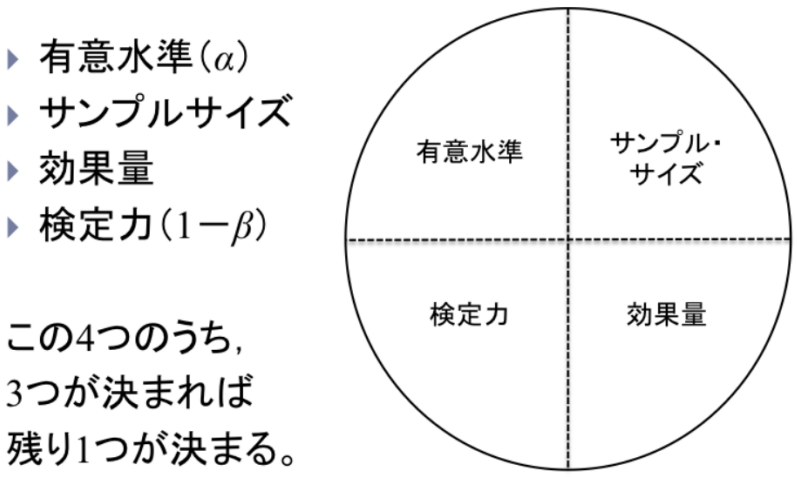

第 15 章

前期のまとめ

これで前期のお話はいったん終わりです。これまでの話を振り返ってみましょう。

そもそも心理学ではなぜ数学が必要なのか，ということを冒頭でお話ししました。数学が受験科目にないので文系を選んだ，なかでも心という非常にウェットな，文学的な対象なので数学は出てこないだろうと思っていた，と学生さんにはよく言われます。しかし今や，文学でも法学でも歴史学でも，数学的なアプローチは避けては通れません。それはあらゆる科学がデータに基づく客観的な思考の積み重ねであるからです。数学的な考え方は無味乾燥で面白くないと思われるかもしれませんが，無味乾燥，すなわち主観的な色合いのないプレーンで非感情的な言語だからこそ，科学的に物事を考えるのに必要なことなのです。最近はデータサイエンティストの需要が高まっていますが，私たちが扱うデータは人間の反応であり，その奥にいる「ひと」「こころ」を知りたいという目的は微塵もぶれていませんし，データをただの数字としてしかみない (見れない) アプローチよりも，よっぽど社会に必要とされています。心理学をやりながらデータを扱う，数学的発想を持っていることは，今後の社会にとても魅力的な人材として映ると思いますので，自信をもってください。

みなさんは最近のあたらしい学習指導要領の方針で，記述統計の基本的なことについては既に学んできたことと思います。ヒストグラムや折れ線グラフ，箱ひげ図や散布図の描き方を学ぶというのは面白みを感じない科目だったかもしれませんが，そこに現れてくるのが人間の反応であり，心の現れであるとかんがえるなら，数字がただの意味のない羅列には見えてこないはずです。しかも，個々のデータではわからなかったことが，たくさん集めると何らかの傾向を持っている (正規分布や相関関係など) ということがわかって来れば，日々目の前の事例だけで振り回されるようなことがない，俯瞰的な視点を持つこともできるようになるのです。ワクワクしてきませんか。

そうした記述統計や可視化の方法も，いまは計算機を使って簡単に表現することができます。R 言語は簡単じゃないよ！と思うかもしれませんが，これまた無味乾燥な機械の言葉で指示通りの反応を機械的にしか返してこないことが，客観性や手続的正当性を担保するために必要なものなのです。大学では科学をやっていますので，こうしたお作法にも慣れていただく必要があります。最初は苦労することも多いと思いますが，計算機という文房具をしっかり使いこなせるようになってください。

さて，変数の特徴の記述に続いて，複数の変数間関係を見てきました。相関係数やそれに基づく回帰分析がそれです。相関係数は 2 つの変数がどのように関係しているかを表す指標ですが，その値が高いからといって一方が他方の原因であるとは限らない，ということも学びました。心理学では実験的に操作できない変数も多く，また人間の行動や心は複雑に絡み合っているので，単純に「A が B の原因である」とは言えないことも多いのです。そうしたときに，回帰分析を使うと，複数の変数を同時に扱うことができるので，より現実的な分析が可能になります。ここでのポイントは，「線形関係 (一次関数) である」という仮定を置いて，それをデータに当てはめるというアイデアです。実際の人間の行動は，理論・仮定・モデルの通りに動くわけではありませんが，そうしたモデルを置いてみて，それがどの程度データに当てはまるかを検証する，というのが科学

的なアプローチです。心理学では，こうしたモデルを置いてみて，その妥当性を検証することがとても重要になります。

そして「理論通りに動かない」，「確実にはわからない」ことを確率で表現することを学びました。確率は数学的に難しい概念です。実際に専門家でもよく間違えたり，意見の相違で揉めることもあります。しかしこうすればこうなる，という物理学のような単純な関係でないからこそ心理学は興味深く，確率のような「不確実なことを表す技術」をつかってそれを扱うことができるのです。

確率の実際の使い方は，推測統計学の領域において学びました。母集団から取り出した標本，標本を記述した数字が確率的に振る舞うということを理解し，標本から全体像を推測しようというわけです。ここでのポイントは，標本から得られた数字が，母集団の真の値 (母数) と異なることがある，ということです。標本を取り出すたびに，その数字は変わります。だからこそ，その数字がどの程度母数に近いかを確率的に表現し，その不確実性を考慮しながら推測する必要があります。こうした考え方は，心理学に限らずあらゆる科学で必要な考え方です。

推測に加えて，検定の考え方も学びました。標本の特徴を母集団に一般化するときに，一般化できるかどうかの判断を加えるのが検定です。考え方が背理法的で，わざと「帰無仮説」をおき，「対立仮説」とのモデル比較という形にするのが特徴です。また判定も確率的であり，判断の結果が間違っている確率を考える (コントロールする) ということも学びました。この辺りは理解しにくいところなのですが，理解しないまま使うことは非常に危険です。実際，心理学では間違った使い方や，悪い使い方が横行しており，再現性問題と呼ばれる心理学の根本を揺るがす問題を引き起こしました。もっとも，そうした問題に対して研究者個人も，学会も，教育方法も改善しつつあります。このような自浄作用があることも，心理学が科学である重要なポイントです。

心理学というのが思った以上に厄介な学問である，というのが実感としてわかってきたのではないでしょうか。逆に言えば，ちょろっと考えたぐらいでわかる程度に，人間や心というものが簡単なはずがないんです。知識や技術をしっかり積み重ねて，「自分はこんなもんだ」「社会はこの程度なんだ」と自分を騙そうとする自分から自由になってください。学問的態度を身につけるということは，不確実であることを受け入れ，その中で最善を尽くすということであり，安易に結論を出さないことにこそあるのです。

後期は確率の考え方に加えて，要因計画という話が入ってきます。操作することの効果をどのように検証するかという話です。要因計画は実験計画法とも呼ばれ，数学的には回帰分析と同じ形式なのですが，注目する点や表現方法が異なります。要因計画と検定が合体した分散分析は，心理学的実験研究の基本中の基本になります。

そのあとは，確率の考え方をさらに発展させて，尤度，最尤法，ベイズ推定といった話に進みます。これらは心理学の研究だけでなく，機械学習や AI の基礎にもなっている重要な考え方です。特にベイズ推定は，最近の心理学研究では必須の考え方になりつつあります。これらの話は数学的には難しい部分もありますが，心理学をしっかりやるためには避けて通れない部分ですので，しっかり理解していただきたいと思います。

どうぞお楽しみに。

第 II 部

心理学データ解析基礎 1B

第 16 章

二群の平均値差

心理学の実践で最もよく用いられるのが，平均値差の検定です。

本講ではまず，二群の平均値差の検定を考えます。「実験群 (操作した群)」と「統制群 (操作しなかった群)」に分けることで，平均値に差が見られたということは操作の効果があったと判断する，という考え方です。

この平均値差の検定は，**対応がある**場合と**対応がない**場合で分けて考える必要があります。対応がある，というのは 2 つの群のデータを得る時，背後に相関が考えられるケースを指します。対応がないというのは相関が考えられない場合です。無作為に実験群と統制群に振り分けた場合，この 2 群のデータに相関を考えることはできません (どの点とどの点をペアにしていいかわからないし，ペアにする意味もないので)。逆に 2 群の各点をペアにする意味がある場合，たとえば事前・事後というように同じ人から 2 回データを取った場合とか，双子や “親密な関係”[*1]のように元々相関があると考えられる場合は，対応があると考えます。

対応がある二群の場合は実はひとつの「差の分布」についての判断になるため，これまでと同様の議論ができます。対応がない二群の場合は，線形モデルの最も単純な場合でもあります。順に見ていきましょう。

16.1　対応のある二群の平均値差の検定

まずはプレ・ポスト (事前・事後) のデータを取った研究を例に考えましょう。たとえば心理的な健康状態について，事前にアンケート調査をしておき，その後なんらかの臨床的介入 (リラックス法のトレーニングをする，など) を行って，一定期間後に同じ人に事後のアンケートを取る，というような研究デザインです (図 16.1)。

事前に集められた被験者は母集団から無作為に集められているとし，事前調査による健康状態のスコアが正規分布にしたがっていたとします。これと同じテストを事後に行ったとすると，個人差はあるにせよ全体的に効果があれば，この臨床的介入法は優れている，と言えそうです。個々のクライアントの変化も重要ですが，より効果を一般的に解釈するためには，推測統計学の力を借りて，母集団での変化，母平均の差を検証したいと考えるのは当然でしょう。そこで，標本平均から母平均を推定し，また母集団分布が正規分布であるという仮定をおくことで標本平均のブレ幅も想定できますから，これを使って母平均のありそうな場所を推定，それが事前・事後でどう違うかということを考えていきたいと思います。またここで，母平均はもちろん母 SD もわからないので，標本から計算した不偏分散を推定値として考えます。標本統計量から推定する場合は，正規分布ではなく t 分布に従いますので，ここでも t 分布を使った推定をすることになります。この推定値を使った検定を考えるのですが，とくにこの検定のことを **t 検定 (t-test)** といいます[*2]。

[*1] 恋人同士や夫婦関係のことを，社会心理学では一般的に「親密な関係」と表現します。持って回った言い方ですが，性別に限定されない良い表現だと思います。

[*2] t 分布を使った検定なので，t 検定です。実は平均の差の検定以外にも t 分布を使った推定・検定は多くあるのですが，非常に応用例の多いパターンですので，2 群の平均値差の検定のことを t 検定ということがあるのです。ちなみにこの時の t は小文字であることにご注意を。大文字の T は別の検定のときに使ったりします。ややこしい。

図 16.1 対応のある二群の平均値差の検定のシーン

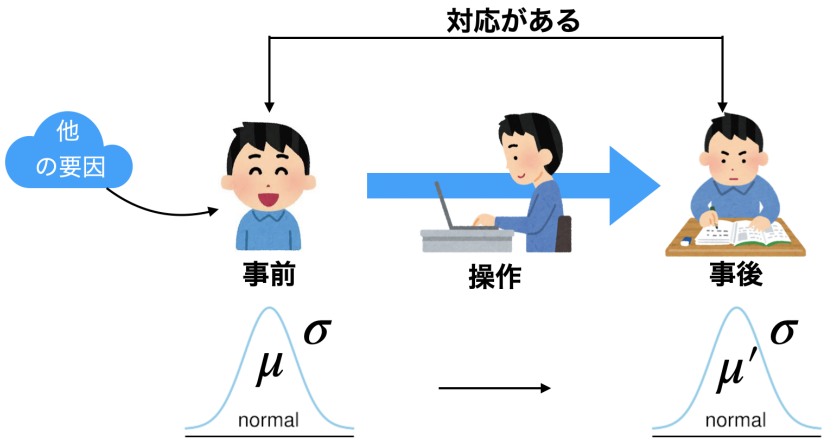

4410 さて，事前・事後で変化があったかどうかを知りたいのですが，ありがたいことに正規分布に従う確率変数
4411 X と，正規分布に従う確率変数 Y の差，$X - Y$ も，正規分布に従うことがわかっています。今回はデータに
4412 対応があり，事前と事後で変化があったかどうかが知りたいわけですから，この特徴を使うことができます。

数値例として，次のような 2 群を考えてみましょう (表 16.1)。ここには 10 人の実験参加者 (participants)

表 16.1 Pre-Post Design Data

Participants	1	2	3	4	5	6	7	8	9	10
pre	34	25	13	21	13	26	19	12	19	19
post	35	30	16	27	20	28	16	14	18	21
diff	1	5	3	6	7	2	-3	2	-1	2

4413
4414 がいます。表 16.1 には，それぞれの人の事前・事後のスコアと，その差分について示されています。数式で表
4415 しておきますと，まず事前のスコアを X_1，事後のスコアを X_2 とします。すると差分 D は

$$D = X_2 - X_1$$

4416 ですが，その平均についても

$$\bar{D} = \bar{X}_2 - \bar{X}_1$$

4417 という関係が成り立ちます。そしてこの D が，平均 μ_D，標準偏差 σ_D の正規分布に従いますから，

$$D \sim N(\mu_D, \sigma_D)$$

4418 より

$$\bar{D} \sim N(\mu_D, \frac{\sigma_D}{\sqrt{n}})$$

4419 ということになります。ここで σ_D がわかればいいのですが，わからないので D の不偏分散をその推定値と
4420 しますと，

$$t = \frac{\bar{D} - \mu_D}{\hat{\sigma_D}/\sqrt{n}}$$

4421 と自由度 $n - 1$ の t 分布に従うことになるわけです。この一連の流れ，数式で表されるとピンとこないという
4422 人がいれば，第 11 講に立ち返って，確認してください。

さて，検定の前に区間推定してみましょう。自由度 $n-1=10-1=9$ の t 分布の 95% 区間は ± 2.262157 ですから[*3]，今回の数字を使って考えると，

$$-2.262 < \frac{\bar{D}-\mu_D}{\hat{\sigma_D}/\sqrt{n}} < 2.262$$

から，両辺に分母をかけて

$$-2.262 \times \hat{\sigma_D}/\sqrt{n} < \bar{D}-\mu_D < 2.262 \times \hat{\sigma_D}/\sqrt{n}$$

$\bar{D}$ を移項して

$$\bar{D} - 2.262 \times \hat{\sigma_D}/\sqrt{n} < \mu_D < \bar{D} + 2.262 \times \hat{\sigma_D}/\sqrt{n}$$

ここで $\bar{D}=2.400, \hat{\sigma_D}=3.062$ ですから，

$$0.2097 < \mu_D < 4.590$$

ということがわかります。標本の差分は 2.4 点だったのですが，母平均の差は点推定で 2.4，95% の区間推定で [0.21,4.59] ぐらいだということでした。つまり，95% の幅で低く見積もっても，0.21 以上ではあるわけですから，差がないわけではない，ということがわかります。

これを検定のロジックに乗せて考えてみましょう。

■仮説の設定　帰無仮説と対立仮説が必要ですが，帰無仮説はないないづくし，前後の差がない，効果がないという仮説になります。記号を使っていうなら，$\mu_D=0$ です。対立仮説は臨床的な効果があった，ということになりますから，従属変数の差は 0 プラスであるはず。つまり $\mu_D>0$ です。

■検定統計量を選択　平均値の推定ですので，検定統計量は t ですね。

■判断の基準になる確率を設定　有意水準 α，今回も 5% で勝負を決めるとしましょう。

■検定統計量の実現値を計算　先ほどは区間推定をしたので $\frac{\bar{D}-\mu_D}{\hat{\sigma_D}/\sqrt{n}}$ の計算はしていませんでした。しておきましょう。帰無仮説に従うなら，$\mu_D=0$ なのですから，

$$t = \frac{\bar{D}-\mu_D}{\hat{\sigma_D}/\sqrt{n}} = \frac{2.4-0}{3.062/\sqrt{10}} = 2.479$$

この $t=2.479$ は自由度 9 の t 分布に従います。この実現値以上の t 値が出てくる確率は，$p=0.0175$ です。

■最初に定めた仮説を支持するかどうかを判断　判定基準 5% より小さい数字ですので，帰無仮説の下で計算したこの t の値は，珍しいと言えます。こんな珍しいことが生じたのだから，仮定が何か間違っている。つまり，差がないというのがおかしい。帰無仮説を棄却して，対立仮説を採択する，と判断します。

結果の報告の仕方は，

> 対応のある t 検定を行ったところ，$t(9)=2.479, p=0.0175$ で統計的に有意である。

ということになります。

ところで，先ほどの区間推定の結果を覚えているでしょうか？ 95% の幅で考えると，少なく見積もっても 0.21，大きく見積もると 4.59 も差があったかもしれません。この「少なく見積もっても」の方がゼロ (=帰無仮

[*3] 念のために書いておくと，R で `qt(0.975,df=9)` とします。

説) ではありませんので, この区間をみるだけでも帰無仮説を棄却することがわかります。この区間推定がゼロを挟む, つまり少なく見積もるとマイナス (逆効果！), 大きく見積もるとプラスだ, というときは検定をしても有意にはなりません。この区間推定の情報は, 推定された平均値がどれほど変化しうるのか, の情報でもありますから, この大きさを一緒に報告しておくと「この実験がどれほど信用できるか」という目安にもなって良いですね。そこで先ほどの報告例を少し修正して,

> 対応のある t 検定を行ったところ, $t(9) = 2.479, p = 0.0175$, 95%$C.I.[0.21, 4.59]$ で統計的に有意である。

とするとなお良いでしょう[*4]。

16.1.1 検定と方向性

ここで一つ注意をしておきます。今回の対立仮説は, $\mu_D > 0$ でした。これはスコアが「健康状態」を表しており, 大きな値の方がより健康であるということを意味していること, また臨床的介入によって「改善」されるのであるから, スコアが上がるはずであるということから必然的に出てくる仮説といえます。もしスコアが「不健康状態」「抑うつ度」などを表すものであれば, 臨床的介入によってスコアは下がるはずですから, 対立仮説は $\mu_D < 0$ となるでしょう。

あるいは値の大小に意味がなく, とにかく「変化があるかどうか」だけに興味がある場合もあります。この場合は, $\mu_D \neq 0$ という対立仮説を立てることになります。

このように, 仮説の立て方には「方向性」がある場合とない場合があります。この方向性によって, 検定統計量の判断が変わってきます。

今回は検定統計量の実現値の計算では, 分子が $D = 2.4$ であり, $t = 2.479$ でした。この t 値が自由度 9 の t 分布に従うことはわかっています。そこでこの値以上の t 値が出る確率を計算したのですが, R で `1-pt(2.479,df=9)` とすると, $p = 0.0175$ と出てきます。これは図 16.2 の上のように, 2.479 より右側の面積を求めたことになります。これが $\mu_D > 0$ という対立仮説を立てた場合です。

前者を**片側検定 (one sided test)**, 後者を**両側検定 (two sided test)** と言います。これは図 16.2 を見るとわかりやすいです。ここには自由度 9 の t 分布が描かれています。

今回は上のケース, すなわち変化の方向性に意味がある, 片側検定の場合です。この図の色付けられたエリアは**棄却域 (rejection region)** といい, この面積が全体の 5% になっています。今回の $t = 2.479$ はこのエリアに入っていますから, 帰無仮説が棄却され, 対立仮説が採択されます。臨床的介入の効果は, 5% 水準で統計的に有意である, と判断できるのです。ちなみに, 判断基準になる t 値は, R で `qt(0.95,df=9)` として, 1.833113 であることがわかります。この値を越えれば 5% 水準で有意, ということになる判定ラインですね。この判定ラインのことを特に**臨界値 (critical value)** と言います。

さて, では検定の方向性に意味がない場合はどうでしょうか。たとえば錯視のように, 大きく見えることもあれば小さく見えることもある, つまりどっちにしろ違いが出れば良い, というような場合です。対立仮説が $\mu_D \neq 0$ であるこの時, 同じ 5% でも棄却域は t 分布の両側 (図の下) で考えることになります。そうすると, 上下に 2.5% ずつ, 合計 5% のエリアが棄却域になります。臨界値は 97.5% 点と 2.5% 点の 2 つが必要になります。R で `qt(0.975,df=9)` を計算すると, 2.262157 であり, この t 分布は左右対称ですから, 2.5%

[*4] 5% 水準でカットするのも, 95% 水準の幅を報告するのも, 同じ情報で冗長だ, と思われるかもしれません。実にその通りで, かつ, 帰無仮説検定の「有意差あり」という報告は信頼区間をみればわかる一方, その逆は成立しない (p 値は分布に関する情報ではない) のですから, 有意差あり/なしという言い方は必要ないのです。今でもこの表現が使われるのは, 旧世紀の名残でしかありません。

図 16.2 片側検定 (上) と両側検定 (下)

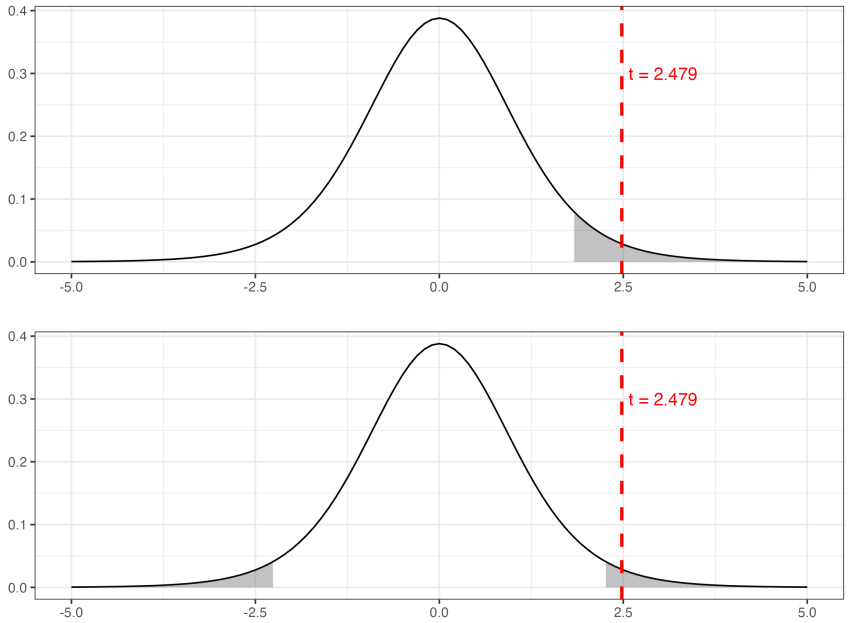

点は -2.262157 です。今回の t 値は 2.479 ですから，両側で計算しても臨界値をこえ，棄却域に入っていますから，判断は変わりませんが，両側検定の方がより厳しい基準であることはわかると思います。

心理学研究の実践では，両側検定が行われることが多いです。実際，統計パッケージもデフォルトでは両側検定をするようになっています。厳しい方がデフォルトだからいいだろ，という考えもあるかもしれませんが，不用意に厳しくすることは研究実践としてやはりおかしなことで，今回のように仮説に意味がある場合は片側検定で構いません。

16.2 対応のない二群の平均値差の検定

16.2.1 区間推定でまず考えてみよう

それでは次に，対応のないバージョン，つまり群間 (Between) 計画の例を考えてみましょう。これは両群に対応がない，それぞれの平均値の推定をして，その上でその推定値の間に差があるかどうか，という話になります。

具体的な数値例でみてみましょう。今回は $n = 5$ としました。5 人の実験参加者を実験群 (experimental) と統制群 (control) に無作為に割り付け，実験群にはある認知課題を課した後で，記憶力を測定するテストをした，と思ってください。テストのスコアが value 列に入っている数字です。さて，認知課題をした群とそうでない群の平均値に違いはあるでしょうか？

これまた母 SD がわからない中で，標本平均から母平均を推定するので t 分布を使うことになります。実験群，統制群ともに $n = 5$ ですから，自由度 $n - 1 = 5 - 1 = 4$ の t 分布を使って推定すると，統制群の母平均は $\bar{X}_{ctl} = 20.60$,$\hat{\sigma_{ctl}} = 4.393$ より，

$$15.145 < \mu_{ctl} < 26.055$$

図 16.3 対応のない二群の平均値差の検定のシーン

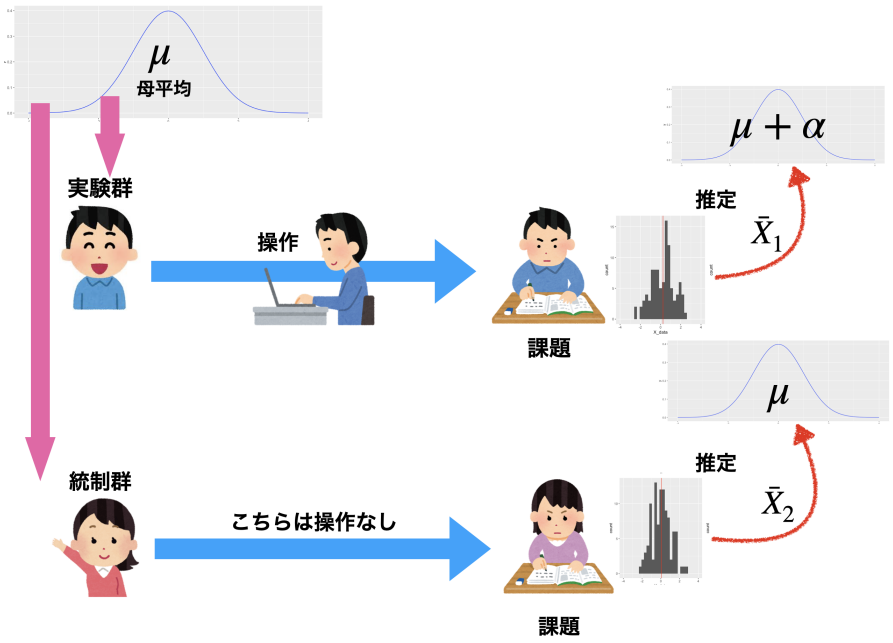

表 16.2 Between Design のデータ例

ID	condition	value
1	control	25
2	control	15
3	control	24
4	control	17
5	control	22
6	experimental	31
7	experimental	28
8	experimental	30
9	experimental	19
10	experimental	18

となります。実験群は $\bar{X}_{exp} = 25.20, \hat{\sigma_{exp}} = 6.221$ より

$$17.476 < \mu_{exp} < 32.924$$

となります。

差がありますか？ 微妙ですね！統制群は大きく見積もるなら 26.05 ぐらいの標本平均が出てきたかもしれなかったし，実験群は小さく見積もるなら 17.48 ぐらいの標本平均だったかもしれないわけです。区間推定だけだと判断に迷うところです。

16.2.2 検定で勝負を決める

そこで検定の出番。先ほどの例と同じく,「正規分布と正規分布の引き算はまた, 正規分布」という特徴を利用して検定を行います。正規分布である母集団 $N(\mu, \sigma)$ から無作為標本を取ってきたとすると, 標本平均 $\bar{X}$ は $N(\mu, \frac{\sigma}{\sqrt{n}})$ に従うのでした。ここで, 2 つの群の標本平均の差, $\bar{X}_1 - \bar{X}_2$ を考えると, その分布は平均 $\mu_1 - \mu_2$, 標準偏差 $\sigma/\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$ に従うことがわかっています。ただ, この σ がわかりませんので, 不偏推定量で置き換える必要があります。今回は 2 つの群があって, 実験群の不偏分散を使っても, 統制群の不偏分散を使ってもおかしいので, 両群をまとめて

$$\hat{\sigma^2}_{pooled} = \frac{(n_1 - 1)\hat{\sigma_1^2} + (n_2 - 1)\hat{\sigma_2^2}}{n_1 + n_2 - 2}$$

を使います。pooled とはプールした, まとめた, という意味です。これは分散の推定量ですから, 差の分布の標準偏差の推定値としてはこれの正の平方根,

$$\hat{\sigma}_{pooled} = \sqrt{\frac{(n_1 - 1)\hat{\sigma_1^2} + (n_2 - 1)\hat{\sigma_2^2}}{n_1 + n_2 - 2}}$$

を使えば良いことになります。

ややこしくなってきましたが, これを使って考えると統計量は次のように計算できます。

$$t = \frac{\bar{X_1} - \bar{X_2} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1-1)\hat{\sigma_1^2}+(n_2-1)\hat{\sigma_2^2}}{n_1+n_2-2}}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

あっ, 心を閉ざさないで！数式は話の筋を通すために書いているだけです。文字がいっぱい出てきて混乱したかもしれませんが, この数式, 覚えておく必要はありません。ここでは, 教材なので一応説明していきますが, 実際には統計ソフトウェアに組み込まれた関数が一気に答えを出してくれます。大事なのは, 筋道を理解することですので, 初めのうちは数式のところは「なんか書いてるわ」ぐらいの理解でも構いません。それよりも, この t の式には標本統計量しか入っていないことに感動しましょう。

「うそつけ, μ_1, μ_2 があるじゃないか」と思った人は, 目の付け所がいいですね。確かにこれはわからないところ (だからギリシア文字で書いてあります) なのですが, これを使って今から検定を行うのです。検定では帰無仮説をおきます。帰無仮説はないないづくし, ですから,「2 群の母平均の間に差はない」と仮定するのです。これを言葉でいうと, $\mu_1 = \mu_2$, あるいは $\mu_1 - \mu_2 = 0$ です。上手くできてますよね！帰無仮説の下では, 分母の $\mu_1 - \mu_2$ を $= 0$ とおくことができますので,

$$t = \frac{\bar{X_1} - \bar{X_2}}{\sqrt{\frac{(n_1-1)\hat{\sigma_1^2}+(n_2-1)\hat{\sigma_2^2}}{n_1+n_2-2}}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

となり, 完全に標本統計量から計算できることになりました。それでは検定を進めて参りましょう。

■仮説の設定 帰無仮説と対立仮説が必要です。先ほども述べたように, 帰無仮説は $\mu_1 = \mu_2$, 対立仮説はこれの否定ですので $\mu_1 \neq \mu_2$ になります。両側検定になっていることに注意してください。

■検定統計量を選択 平均値の推定ですので, 検定統計量は t ですね。

■判断の基準になる確率を設定 有意水準 α, 今回も 5% で勝負を決めるとしましょう。

■検定統計量の実現値を計算 これはちょっと厄介ですが，数式にしたがって，統制群を X_1，実験群を X_2 とおくと，$\bar{X_1} = 20.60, \hat{\sigma}_1 = 4.393, \bar{X_2} = 25.20, \hat{\sigma}_2 = 6.221$ です。

$$t = \frac{20.60 - 25.20}{\sqrt{(4.393^2 + 6.221^2)/5}} = -1.3506$$

となりましたので，これが自由度 $(n_1 - 1) + (n_2 - 1) = n_1 + n_2 - 2 = 10 - 2 = 8$ の t 分布に従うことになります。両側検定ですので，絶対値でこれより極端な t 値が得られる確率を求めると，$p = 0.2138$ になりました。

■最初に定めた仮説を支持するかどうかを判断 判定基準 5% より大きい数字ですので，帰無仮説の下で計算したこの t の値は，珍しいとは言えません。

報告する時は次のようになります。今回は両側検定ですので t 値の絶対値を使います。

> 実験群と統制群の平均値の差を検定したところ，$t(8) = 1.351, p = 0.214$ で統計的に有意であるとは言えなかった。

2 群の平均値の差の検定については，このような手続きで行います。繰り返しになりますが，実際の計算は機械がやってくれるので，どのような数字がどのような意味を持っているのか，得られた結果からどのように判定するのか，という手続き的な知識をしっかりと踏まえてください。

また，ここでこのように検定の具体例をみてきたわけですから，是非この技術を身の回りでも活用してみてください。

何か 2 つのグループがあって，その平均値が違うのであれば，これは偶然によるものなのかそうでないのか。一般化して良いのかどうか。この推測統計学的発想は，身の回りの至る所に応用できるものです。知識と技術を手に入れたら，是非具体例を自分で考えて，試してみてください[*5]

16.3 R による実践；対応のある t 検定

では今度は手を動かして，R で t 検定を実際に行ってみましょう。まずは対応のある **t 検定 (t-test)** です。面倒な計算式がありましたが，今回その辺の計算は機械がやってくれますので，例によって出力をしっかり確認するようにしましょう。

例として，表 16.1 の 10 人の参加者データを使います。元になるデータをオブジェクトに格納する code:16.1 を実行しましょう。

code : 16.1 t 検定を行う

```
1  X <- c(34, 25, 13, 21, 13, 26, 19, 12, 19, 19)
2  Y <- c(35, 30, 16, 27, 20, 28, 16, 14, 18, 21)
3  t.test(Y, X, paired = T, alternative = "greater")
```

■コード解説

[*5] たとえば「お兄ちゃんのフライドポテトの方が，いつも長いのばっかり入っていてずるい！」というような兄弟喧嘩の種も，両者のフライドポテトの長さを測り，その平均値を出して t 検定すれば「たまたま今回のポテトの問題だった」のか，いつもそうなる現象なのか検定で決着をつけることができます。実際に筆者が居酒屋のフライドポテトでこれの検証をした時，テーブルごとのポテトの長さに平均的な差はありませんでした。くわえて，フライドポテトの長さが非常に正規分布に近かったのを知って，感心したことがあります。

1 行目 一方のデータをオブジェクト X に代入しています。c は結合 combine という関数です。

2 行目 他方のデータをオブジェクト Y に代入しています。

3 行目 t 検定を行っています。引数として，データ X,Y を指定し，次に paired オプションを T に[*6]，対立仮説 alternative を「Y が X よりも大きい」という片側検定にしてあります。

さて，こうして得られる結果は R **の出力** 16.1 の通りです。

R の出力 16.1: t.test の出力

```
Paired t-test

data:  Y and X
t = 2.4783, df = 9, p-value = 0.01754
alternative hypothesis: true mean difference is greater than 0
95 percent confidence interval:
 0.6248331       Inf
sample estimates:
mean difference
            2.4
```

上から三行目に t 値が出ていますね。帰無仮説の下での t 統計量の実現値は $t(9) = 2.4783$ であり，これが出現する確率は $p = 0.01754$ です。対立仮説は，平均値の差が 0 より大きい (true mean difference is greater than 0) という方向性のある対立仮説になっています[*7]。これが片側検定になっているのは，t.test 関数の引数に alternative="greater"と書いたからで，これを alternative="less"とすれば逆の片側検定 (事後データのスコアの方が事前データのスコアより小さい) を検定することになり，とくに何も書かないか，alternative="two.sided"とすれば両側検定になります。

16.4 R による実践；対応のない t 検定

つづいて対応のない **t 検定 (t-test)** のほうも，R でできるようになりましょう。

さきほどの表 16.2 のデータを分析することを考えます。難しい計算は抜きにして，code:16.2 を入力し，分析を実行してください。

code : 16.2 formula で指定

```
1  X <- c(25, 15, 24, 17, 22)
2  Y <- c(31, 28, 30, 19, 18)
3  dat <- data.frame(condition = c(rep(1, 5), rep(2, 5)), value = c(X, Y))
4  dat$condition <- factor(dat$condition,
5                          labels =  c("control","experimental"))
6  t.test(value ~ condition, data = dat)
```

スクリプトの内容については，先ほどとほぼ同じです。大きな違いは，t.test 関数の引数がなくなったところで，paired オプションもなければ，alternative オプションもありません。ないのは，デフォルトの状態を

[*6] 大文字の T は $TRUE$, 真であり，この逆は F とかいて $FALSE$, 偽を意味する**特別な文字**です。真か偽か，本当か嘘かという 2 つの状態を表す論理値と呼ばれるもので，ここではスイッチオン/オフの意味です。対応スイッチ，オン！という意味ですね。大文字の T, F をオブジェクト名にして利用することも可能ですが，R が専門的な意味で使う予約語なので，一般的にはそのような使用は避けた方が望ましいです。

[*7] R では前の変数が後ろの変数に比べて大か，小かを表現しますので，Y,X の順で書いています。

使っているからで，R の t.test 関数はデフォルトで対応のない，両側検定の t 検定をやってくれるのです。

結果は次のように表示されるはずです (R の出力 16.2)。

R の出力 16.2: Welch の補正

```
Welch Two Sample t-test

data:  value by condition
t = -1.3506, df = 7.195, p-value = 0.2178
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -12.609577   3.409577
sample estimates:
     mean in group control mean in group experimental
                      20.6                      25.2
```

前回，手計算した結果と同じになっているかどうか確認してください。

んん？ 自由度が 7.195? 自由度って 8 になるんじゃなかったでしたっけ (実験群の自由度が $5-1=4$，統制群の自由度も $5-1=4$，足して 2 つで $4+4=8$)。

16.4.1 Welch の補正

そうです，t 検定の自由度は 8 のはずなのですが，変な数字で出ていますね。これは，検定に関わるまだ説明していない別の手続きがあったからです。

検定にはどのような仮定があったか，思い出してください。母平均の差をゼロとする，という帰無仮説をおくのも仮定ではありますが，さらにその前にあった仮定です。それは，2 つの群が正規分布から得られていること，とくに平均値に差はあるけれども，母標準偏差は同じところから取ってきていた，という仮定があったのです。

もしこの仮定が崩れていたら？ 母集団に正規分布が仮定できなければ，t 検定はできません。たとえば年収の差とか，データが比率や角度についての数字であったりすると，正規分布を仮定できないので t 検定はできないのです。正規分布は正規分布だったとしても，母標準偏差がちがっているなら，推定の仕方も考え直さないといけないかもしれません。

この問題は，t 値の自由度を調整することで解決されています。前回までのいわゆる t 検定は，等分散の仮定が満たされているケース (分散の均一性などということもあります) の計算方法であり，この仮定が満たされていない場合は **Welch の補正 (Welch's correction)**(ウェルチの補正) とよばれる調整が必要です。

R の t.test 関数は，より仮定の緩やかな，Welch の補正をかけた結果をデフォルトで返してくれます。まず分散が等しいかどうかチェックして云々，という手続きが面倒なので，最初から補正しておこう，ということですね。結果の一行目にも Welch Two Sample t-test と書いてあります。これを使って，結果は

$t(7.195)=1.351, p=0.2178$ で 2 群の間に統計的に有意な差は認められなかった。

と報告します[*8]。差があるかどうかの判断だけでなく，差の 95% 信頼区間にも目を向けておきましょう。結果から，差の 95% 信頼区間は CI[-12.609577,3.409577] でした。差は-12 から +3 までの幅があり，帰無仮説である差 $=0$ を含んでいるので，有意になりません。

[*8] t の値は，両側検定の場合符号に意味がないのでマイナスを取って記載します。

ところで，分散が同じだ，と仮定できる場合は t.test 関数のオプションを使います (code:16.3)。

code : 16.3 分散のオプション指定

```
1  t.test(value ~ condition, data = dat,var.equal = T)
```

これで，R の出力 16.3 のような結果を得ることができます。

R の出力 16.3: 分散が等しいという仮定を置く

```
 Two Sample t-test

data:  value by condition
t = -1.3506, df = 8, p-value = 0.2138
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -12.453967   3.253967
sample estimates:
     mean in group control mean in group experimental
                     20.6                       25.2
```

このやり方ですと，自由度も整数になっていますね (判定結果は変わりませんが)。

16.4.2 事後的に効果量を検証する

検定が終わった後ではありますが，このデータの実験は「勝ち目がある」ものだったのでしょうか。つまり，母集団における母平均の差が十分大きなものなのかどうかが気になります。母数は分かりませんが，これまでも分からないものは標本統計量で置き換えて推定してきたわけですから，データを取った後になって，これはどれぐらい効果量の大きなデータだったのか，を考えてみましょう。

効果量の計算についても，R を使って簡単に行うことができます。R ではパッケージを追加することでさまざまな統計関数が増えますが，効果量についての effsize パッケージ (Torchiano, 2020) を導入すれば，この計算も簡単にできます。効果量については第 14 講で触れましたので確認しておいてください。ここではより推奨される，Hedges の g の算出の仕方を紹介します (code:16.4)。

code : 16.4 効果量を求める

```
1  # パッケージの読み込み
2  library(effsize)
3  cohen.d(value ~ condition, data = dat, hedges.correction = T)
```

ここではまず 2 行目でパッケージを読み込み[*9]，次の行で cohen の d を Hedges の補正をかけて算出せよ，としています。

結果は R の出力 16.4 のように示されます。

[*9] このパッケージを持っていない場合は，当然インターネットからダウンロードしてローカル (手元の PC) に保存しておく必要があります。

R の出力 16.4: 効果量の出力

```
Hedges's g

g estimate: -0.7715342 (medium)
95 percent confidence interval:
       lower      upper
-2.1369693  0.5939009
```

g estimate: -0.7715342 (medium) とあるように，推定値は 0.77 で，これは中ぐらい (medium) の大きさだよ，ということです。中程度の違いがありそうなのに，今回有意にならなかったのは，サンプルサイズが小さかったからかもしれません。事前にきちんと設計してやっておけば，実験手続きとしてより良くなったでしょう。

効果量の計算はこのように，事後的に行って今回の標本から標準化された平均値の差がどれぐらいありそうか，と考えることもできます。もちろん事前に平均値の差を想定して，そこから例数設計 (どれぐらいのサンプルを取れば良いか考える) するのにも使います。今回ここで求めた標本効果量も，レポートに書くようにしましょう。

> $t(7.195) = 1.351, p = 0.2178$ で 2 群の間に統計的に有意な差は認められなかった。なお，Hedges の g で効果量を求めたところ，0.77 であった。

16.4.3 サンプルサイズの設計

ところで今回，対応のない t 検定で，効果量が 0.7 あるのに有意になりませんでした。これはサンプルサイズが小さかったからかも，ということでしたが，では何人分のデータがあればよかったのでしょうか。code:16.5 ように R に入力することで，そのヒントが得られます。

code : 16.5 power.t.test 関数

```
1  power.t.test(power = 0.8, delta = 0.7, sig.level = 0.05)
```

ここで，delta=0.7 としたのは，標準化された平均値差が 0.7 あるとして，という考え方です。これは先ほどの事後的検定力分析の結果，それぐらいあったんじゃないの？ と思われたのでその値を使いました。もっと小さく見積もったり，逆にもう少し大きく見積もったりしても構いません。また，power=0.8 としましたが，これは**検定力 (power)** で，セクション 14.3.1(Pp.198) で出てきたものです。Type II Error，つまり差があるのにあると言えない間違い (β) を 20% ぐらいに抑え，80% の確率で当てたいとしました ($1 - \beta = 0.8$)。また，有意水準は 5% です ($\alpha = 0.05$, スクリプトの中では sig.level=0.05 としています)。

さて，これの出力結果を見ると，次のように示されました (R **の出力** 16.5)。

R の出力 16.5: power.t.test の出力

```
Two-sample t test power calculation

n = 33.02467
delta = 0.7
   sd = 1
sig.level = 0.05
power = 0.8
alternative = two.sided

NOTE: n is number in *each* group
```

ここの n にあるように，効果量 0.7，検定力 0.8 で研究するのであれば，33 か 34 人は集めたいところ，だったわけです。逆に今回は 5 人しか集めていませんでしたが，これを使って，code:16.6 とすると，**R の出力 16.6** のように示されます。

code : 16.6 power.t.test で n を固定

```
1  power.t.test(n = 5, delta = 0.7, sig.level = 0.05)
```

R の出力 16.6: 検定力の出力

```
Two-sample t test power calculation

n = 5
delta = 0.7
sd = 1
sig.level = 0.05
power = 0.16318
alternative = two.sided

NOTE: n is number in *each* group
```

ここにあるように，検定力は 0.16，つまりサンプルサイズ $n = 5$ であれば，この研究は 100 回やっても「有意差あり」と正しく判断できるのは 16 回ほどしかなかった，ということになります。分の悪い勝負に出たというところでしょうか。

第 14 講，14.4 節 (Pp.200) で，このような検定力分析についても触れましたが，帰無仮説検定で「有意になること」を目的にするのであればサンプルサイズを増やせば良いのです。しかしもちろん，自分に都合のいい結果になるように努力？するのは科学的な実践としては不適切ですし，サンプルをたくさん取るのは研究上の労力もかかります。多過ぎず，少なすぎず，正しく判断するためのサンプルサイズを事前に設計してから，研究を始めることが重要です。

16.4.4 補遺

■対応のある t 検定の効果量を計算する 対応のある t 検定をして，その効果量を求める場合は，次のように paired オプションをオンにしておきます (code:16.7)。code:16.2 でオブジェクト X,Y,dat を対応のないデータで上書きしていますので，1-4 行目で表 16.1 の事前・事後のデータを作り直しています。

code : 16.7 cohen の d

```
1  X <- c(34, 25, 13, 21, 13, 26, 19, 12, 19, 19)
2  Y <- c(35, 30, 16, 27, 20, 28, 16, 14, 18, 21)
3  dat <- data.frame(condition = c(rep(1, 10), rep(2, 10)), value = c(X, Y))
4  dat$condition <- factor(dat$condition, labels = c("pre", "post"))
5  cohen.d(X,Y,paired = TRUE)
```

ただし, チルダを使った書き方をしている場合，code:16.8 のようにすると, 出力に次のような警告が付されます (R の出力 16.7)。

code : 16.8 cohen の d その 2

```
1  cohen.d(value ~ condition, data = dat, paired = TRUE)
```

R の出力 16.7: cohen.d の警告

```
Cohen's d

d estimate: -0.344241 (small)
95 percent confidence interval:
      lower       upper
-0.64457930 -0.04390272

    警告メッセージ:
cohen.d.formula(value ~ condition, data = dat, paired = TRUE) で:
Trying to compute paired samples Cohen's d using formula input. Results may be incorrect
 if cases do not appear in the same order for both levels of the grouping factor. Use the
format 'value ~ treatment | Subject(id)' to specify a subject id variable.
```

この警告は,「対応のある個々人を識別する変数がデータセットに入ってないので, 間違った結果になっているかもしれませんよ。次の書式を使ってください」と言ってます。これに対応するためには，code:16.9 のようにします。

code : 16.9 対応のある場合の cohen.d

```
1  X <- c(34, 25, 13, 21, 13, 26, 19, 12, 19, 19)
2  Y <- c(35, 30, 16, 27, 20, 28, 16, 14, 18, 21)
3  dat <- data.frame(condition = c(rep(1, 10), rep(2, 10)), value = c(X, Y))
4  dat$condition <- factor(dat$condition, labels = c("pre", "post"))
5  dat$ID <- rep(1:10,2)
6  cohen.d(value ~ condition | Subject(ID), data = dat, paired = TRUE)
```

ここでのポイントは 5 行目に ID を識別する変数を作り[*10], 効果量を計算する式を警告の提案通りのフォーマットに書き換えています。

16.5 課題

この講の課題は大問 2 つ, 小問 3 つです。次の要領で提出してください。

[*10] 関数 rep で 1:10 を 2 回繰り返しています。R ではコロンで繋げた数字は, 連番を意味します。

提出するもの　分析を実行する R コード (`.R`) を 1 つ提出してください。

ファイル名　`chNN_学籍番号_氏名.R` としてください。NN は講の番号です。

動くこと　提出されたコードは，こちらの環境でそのまま実行して確認します。提出する前に，新しいセッションを開いて最初から最後まで通して実行し，エラーが出ないことを確かめてください。動かないものは未提出扱いになります。

答えの書き方　小問で求めた数値は，指定された名前のオブジェクトに入れてください。小問 1 の答えは `ans1`，小問 2 は `ans2`，小問 3 は `ans3` です。複数の数値を答えるときは，`ans1 <- c(t = -0.07, df = 7, p = 0.47)` のように名前つきベクトルにまとめること。要素の名前はそれぞれの課題文に書いてあります。

数値は丸めない　オブジェクトに入れる数値は，**計算した値をそのまま**にしてください。`round` や `signif` で丸めると，正しく計算できていても不正解になることがあります。画面に表示するときに丸めるのは構いませんが，提出するオブジェクトの中身は丸めないこと。

わからないところがあれば，TA か小杉までメールで連絡し，指導を受けてください。

課題のデータは，伴走サイトの「各章のコード」にある `16_kadai_data.R` をプロジェクトフォルダに置き，`source("16_kadai_data.R")` と実行すると読み込まれます。課題 1 の事前・事後の成績はベクトル `pre` と `post` に，課題 2 の統制群と実験群の成績はベクトル `control` と `experimental` に，それぞれ表の左から順に入っています。

■課題 1 対応のある t 検定　表 16.3 にあるように，ある介入の事前・事後の心理検査の成績が得られたとして，次の各指示に従い，結果について回答してください。

表 16.3　課題 1

pre	19	38	24	25	12	28	11	17
post	31	23	28	35	14	4	4	38

1. 事前スコアの方が事後スコアよりも低いかどうか，5% 水準で検定してください。検定統計量，自由度，p 値を `ans1 <- c(t = , df = , p = )` に入れてください。

■課題 2 対応のない t 検定　表 16.4 にあるように，統制群と実験群の心理検査の成績が得られたとして，次の各指示に従い，結果について回答してください。

表 16.4　課題 2

Control	20	21	21	20	21	22	22	22	20	20
Experimental	20	18	22	20	21	18	19	21	21	21

1. 母分散が等しいと仮定した t 検定を実行してください。検定統計量，自由度，p 値を `ans2 <- c(t = , df = , p = )` に入れてください。
2. 母分散が等しいという仮定をおかない t 検定を実行してください。検定統計量，自由度，p 値を `ans3 <- c(t = , df = , p = )` に入れてください。

第 17 章

実験計画法の基礎と RCT

前回，統計的な検定で 2 群の平均値の差を判定することを見てきました。統計的な検定は，推定に基づいた「判断」であり，「意思決定」のための方法でもあったわけです。この方法を応用して，2 群だけでなく 3 群以上の場合でも，差があるのかどうかを判定することを考えます。そのためには，差があるかどうかを見極めるための計画が重要になってきます。

この実験計画法＋統計的な検定は，心理学研究のスタンダードな方法の一つです。ここからは心理学における実験と，その分析方法についての話に進んでいきます。

17.1　ランダム化の意義と方法

心理学は人間を対象にした学問であり，研究の方法はさまざまなものがあります。一般的には，調査，観察，実験，面接などの方法がとられます。ここでいう実験とは，皆さんが小中学校の理科の時間に習ったような実験と，同じようなものだと思っていただいて構いません。ただしその対象が人間になっているというところに，注意が必要なだけです。その注意というのは，もちろん倫理的な問題も多く含みますが，それに加えて，物理学の実験と違って研究の対象が意思を持っているというところです。そうした研究対象特有の問題に考慮しつつ，実験とはどのように進めていくべきかを考えてみましょう。

簡単なところから，小学校の理科でやるような実験として，次のような例を考えてみましょう。植物の種をまいて，植物の成長にはどういった要因が必要なのかを考える授業をするとします。ここでいろいろな条件を考えて実験を計画しますね。たとえば日向と日陰を比べればどちらが成長が速いのかとか，水をあげた場合とあげない場合とではどちらが成長が速いのかとか，どういった肥料をどれぐらいあげれば成長が速くなるのかといったことを検証したいとします。

たとえば日光の効果を検証したいのであれば，半分は日向に残りの半分は日陰に種をまいて，どちらの方が成長が良いかを記録するという方法で実験することになると思います。当然のことながらこの時重要になってくるのは，日向か日陰かという条件以外の要素を変更しないことです。たとえば日向にまいた種だけに水を与えるとか肥料を与えるといったことをすると，最終的に得られた成長の違いが日光によるものなのか，それ以外の要因によるものなのか区別できません。これでは研究の目的が果たせないわけです。実験をする場合は，検証したい条件の違い以外は均一にしておくということが必須です[*1]。

何を当たり前のことをと思われるかもしれませんが，人間の場合はさまざまな要因が絡み合っているので，何か 1 つの効果を見るために他のものを統制しようとしても，統制すべき要因が無数に考えられてしまうので，おのずと限界があるわけです。

[*1] このように介入が入り混じっていて効果が特定できなくなることを，要因が**交絡 (confounding)** するといいます。交絡という言葉は，字義通り「交わり，からまっている」という意味で，本当に見たい因果関係を切り出せないことを指します。

人間を研究の対象にする場合の問題は他にもあります。まずこの授業でも冒頭のほうにお話ししたと思いますが，何を結果変数にするかというところも明確ではありません。人の気持ちのようなものが従属変数になっていたとして，その気持ちをどのように測定するのかという測定方法にもさまざまな注意すべき点があるでしょう。測定するべき対象が明確になっていたとしても，被験者に負担をかけすぎないかどうかは倫理的に検証されるべきです。また，研究対象が人間ですから，人間の回答は嘘をつかれることもあれば，間違うこともあれば，実験者の意図を汲んで自然な状態でない反応をすることもあります。こうした問題に対しては，**二重盲検法 (double blind experiment)** を始めさまざまな方法で問題を回避しなければならないといった事は，心理学研究法の方で話を聞いていることと思います。

先に述べた測定の問題と，後半で述べた倫理的な問題を始めとする研究法の問題は横に置いたとしても，実験にはコントロールしてもコントロールしきれないものが含まれる事はお分かりいただけると思います。このコントロールしきれない部分のことを**偶然誤差**と言いますが，偶然誤差に振り回されるだけではなくこれを積極的に利用することによって，実験の質を高めるために利用できます。偶然をハンドリングするのです！

人間を対象にした実験の例を考えてみましょう。たとえば新しく商品開発された 3 つのミネラルウォーターがあったとして，いろんな人に試し飲みしてもらって採点してもらったとします。このドリンク A,B,C について評価してもらうとして，その場合に気にしないといけないことがあります。1 つはどの順番で飲んでもらうかということです。たとえばドリンク A に甘い味がついていたとして，その後で B,C を飲むと味が薄いと評価されるかもしれません。あるいは 1 種類目 →2 種類目 →3 種類目と順番に飲んでいたとして，最後のほうはもうお腹がタポタポで全然味の評価ができないということがあるかもしれません。このようにどういう順番で飲むかとか，どの並びで飲むかといったことも評価に影響してきます。こうなってくるとこれはもう統制できませんので，諦めるのではなくて，逆に偶然の力を借りるのです。つまり，サイコロを振って 1 か 2 が出れば A，3 か 4 が出れば B をまず飲む，といったようにし，人によって飲む順番も並びもバラバラになってしまえば，飲む順番や並びの効果があったとしても，相互に影響を殺しあって，平均をとればそれぞれのミネラルウォーターの評価として使うことができると考えるわけです。

ここでこのようにバラバラにするということを，言い方を変えると**ランダム化 (randomize)** するといいます。英語でランダム random は確率とも訳されます[*2]。確率化すると言い換えても構いません。偶然をハンドリングするために，確率の力を借りようというわけです。

第 10 講で**正規分布**の話をしました。正規分布はさまざまな要因の積み重ねとして，つまり二項分布の極限の形で出てくる分布だということでした。この話をここで思い出してみましょう。人にはさまざまな個性があり，それを統制した上で実験をするなんて事は不可能です。しかし 1 人ではなくて多くの人間を集めてくると，ある変数については正規分布の形に近づいてくるでしょう。たとえば身長や体重といった生理的な指標や，学力や心理的な変数なども正規分布にしたがうと考えられるわけです。このときの正規分布の平均は，集団の代表的な値，真ん中あたりの人ということになるでしょう。偶然誤差の部分は平均がゼロになっていますから[*3]，系統的な特徴が平均のところに現れていると考えられるわけです。

このように，被験者一人一人の特徴はあるとしても，平均を取れば何らかの傾向があるはずです。誰が飲んでも美味しい飲み物とか，その逆ということはあるわけです。平均を取ることで，個性をキャンセルアウトしようということですね。その上で，振り分けにも確率の力をかりてランダム化します。サイコロの目が偶数なら群 A，奇数なら群 B，というように無作為に群分けするのです。無作為にグループを分けていますから，どちらのグループにもさまざまな人が入ることになります。味覚に敏感な人やそうでない人など，今回の実験に関わる個性があったとしても，2 つのグループの平均は，個性がキャンセルアウトされていますから，平均的には

[*2] 確率的に決まる変数のことを確率変数と言いますが，確率変数は英語で random variables です。

[*3] プラスの要因とマイナスの要因，大きさもさまざまなので，それらが相殺し合う＝キャンセルアウトされる，といいます。

同程度の群が 2 つできたことになります。

心理学における実験で因果的な効果を考える場合は，無作為[*4]に群分けをし，一方を**統制群 (control group)**，他方を**実験群 (experimental group)** と呼びます。実験群には何らかの操作が加えられます。これに対して統制群には何もしない，あるいは何の効果もない同程度の介入をします[*5]。無作為に群分けしているので実験群のグループに含まれるさまざまな原因の効果は，統制群にも同程度に含まれているはずです。それが課題に影響を与えるものであったとしても，これは両群に同程度の効果を持っているはずです。介入の後で両群に何らかの心理学的な課題をさせるとか，反応を見るとかします。その結果のところで平均的な成績の差を比較します。何らかの要因があって，それが課題の成績にプラスに出るかマイナスに出るかといったことがあるかも知れませんが，群全体としてはそれは同程度のはずです。それを超えて群の間に差があるとしたら，その原因は操作をしたかしなかったかにあると言えるではありませんか。このように平均化することで，因果的な効果を考えることができるようになるのです (図 17.1)。この効果のことをとくに**平均因果効果**と言います。

図 17.1 RCT の基本的枠組み

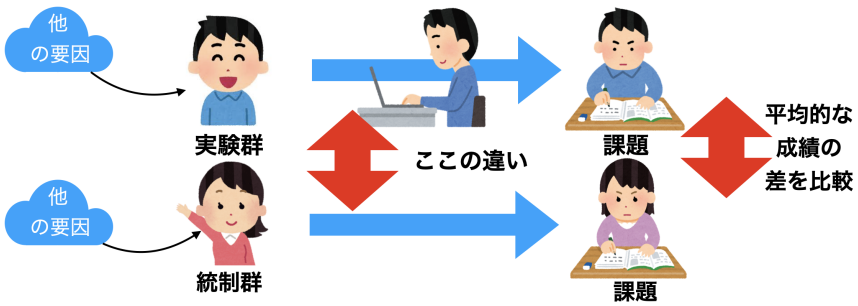

これが実験の基本的な枠組みです。集団の平均的な違いは，無作為に群分けすることで個体差を相互に打ち消し合うための仕掛けです。誤差をコントロールする方法の 1 つと言えるでしょう。この方法を**ランダム化比較試験 (randomized controlled trial; RCT)** といいます。偶然誤差，あるいは個体差が相互に打ち消し合うのは，それらが正規分布に従うという特徴を生かした方法だとも言えるでしょう。

17.2 用語の整理

17.2.1 要因と水準

このセクションでは今後のために実験計画に関わる用語を整理していきます。

実験の例として，心理学的な話ではありませんが，小学校の理科でやったような植物の成長に関する実験をとりあげます。植物の成長には何が必要かを学ぶための実験で，植木鉢を日向に置いたり日陰に置いたり，水分をあげたりあげなかったり，肥料をあげたりあげなかったりします。そのような条件のもとで，1 ヵ月間でその植物が何センチ成長したかを記録することにしました。

この実験の例でいうと，**独立変数 (説明変数**ともいう) と**従属変数 (被説明変数**ともいう) は明らかですね。従属変数は，1 ヵ月間で成長した植物の長さということになります。独立変数は，日光があるかどうか (日陰か日向か)，水分があるかどうか (水をあげない，時々あげる，毎日あげる)，肥料をあげるかあげないか，といった 3 つになります。従属変数は**比率尺度水準**で，独立変数は**名義尺度水準**になります。

[*4] 無作為の反対，作為とは意図を持ったという意味です。無作為はその否定で，何の意図も持たずに，という意味です。
[*5] 何もしないことが逆に何らかの意味や効果を持ってしまう可能性があるからです。人間を対象にした研究はややこしい！

このように，実験や研究で検証したいもののことを，**要因 (factor)** といいます。ここでは日光，水分，肥料の 3 つの要因がありますので，「この実験は 3 要因計画である」と言ったりします。

3 つの要因にはそれぞれ比較したい**水準 (level)** が複数あります。日光という要因は，日向/日陰という 2 つの水準がありますので，日光という要因は 2 水準ある，などと表現します。今回の例の場合，水分は 3 水準，肥料は 2 水準です。

要因と**水準**を使ってこの実験を表現するときは，「3 要因の 2× 3 × 2 デザイン」と言ったりします。実験がどのようにデザイン (計画) されているか，ということを説明する用語です。

17.2.2 群内計画と群間計画

さて要因と水準という言葉の違いがわかったところで，実験計画に関わるもう 1 つの区別について説明しましょう。さきほどと同じように植物を測定する実験の例を考えます。ただし今回は要因として 1 つは「日光」，つまり日向なのか日陰なのかの比較をすることを考えたとします。この条件のもとで 1 ヵ月間記録し，日向と日陰で成長がどれぐらい違うのかを，0 日目，15 日目，30 日目に記録して比較することを考えたとします。得られるデータは図 17.2 のようになることがお分かりいただけますでしょうか。

図 17.2 得られるデータの例

	日光の要因	0日目	15日目	30日目
植木鉢A	ひなた	5	16	27
植木鉢B	ひなた	12	23	34
植木鉢C	ひかげ	1	6.5	12
植木鉢D	ひかげ	10	21	31

このときに考えられる要因の 1 つはもちろん日光ですが，これは 1 行目 +2 行目と 3 行目 +4 行目の条件を比較すればわかることになります。ただしこの実験はそれ以外にもたくさんの情報を含んでいます。それは 1 つの行が 1 つの植木鉢についての繰り返し獲得できた情報だということに起因します。データを見ると，植木鉢 A とか植木鉢 C はそもそも初日でほとんど芽が出ていませんでした。それに対して植木鉢 B と植木鉢 D は，初日ですでに 10 センチ以上の芽が出ていたことになります。こうした実験開始時の個体差というのは，今回の研究でどのように考えるべきでしょうか。今回の研究では日光がどれぐらい成長を促進するかということに興味があるのであって，そもそもの個体差は興味がなく，何なら実験にとって邪魔な情報ですらあります。

成長の促進の度合いは 0 日目と 15 日目との差分，15 日目と 30 日目との差分でもって表されることであって，スタート地点の情報は必要ありません。同じ鉢から反復してデータを得ているわけですから，行方向に数字を見ていくことによって，個体差を取り除いた変化量を考えることができます (図 17.3)。

このように，日向と日陰といったグループ間の違いを見る要因と，個体差を考慮して 1 つ 1 つの個体がどのように変化していったかを見るグループ内の違いを見る要因があります。用語としてそれぞれ**群間要因 (between factor)** と**群内要因 (within factor)** といいます。今回の例では，日光を群間要因，測定日を群内要因と呼ぶことになります (図 17.4)。

この実験は群内要因と群間要因が組み合わさっていますので，とくに**混合要因計画 (mixed design)** と呼ばれることもあります。水準数にも配慮して表現すれば，この研究は 2 要因の 2× 3 デザインあるいは「間 2×

図 17.3 比較できる方向

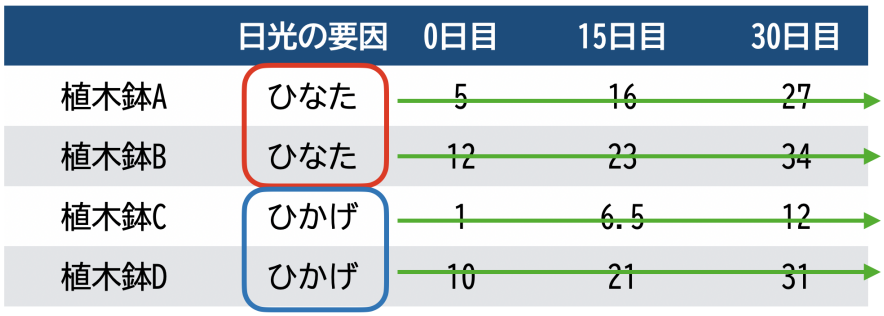

内 3 の混合計画」という言い方をします。

図 17.4 群内要因と群間要因

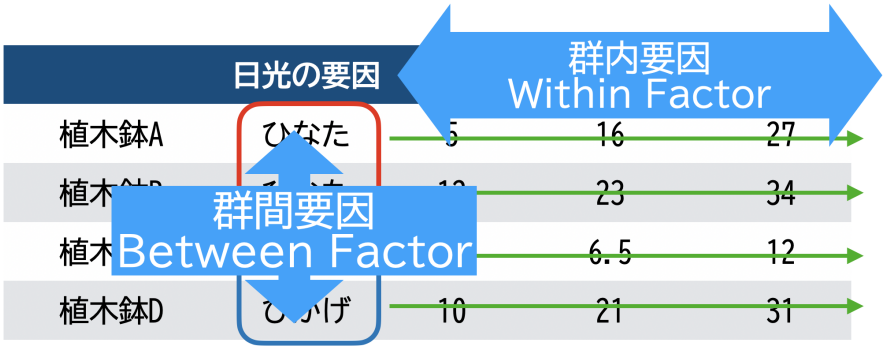

皆さんが実験を計画するときには，これらの言葉を使ってどういった要因を考え，どういった計画を立てているのかを表現する必要があります。ちなみに群間要因は別名**対応のない**要因とも言います。対して群内要因は，**対応のある**要因，あるいはそのデータの性質から**反復測定 (repeated measure)** 要因とも呼ばれます。

後ほどの講義で詳しく説明されますが，群間要因計画と群内要因計画を比べると，群内要因計画の方が個人差を算出できることから，より精度の高い分析になります。群間要因計画は**個人差**と**偶然誤差**を区別できないため，群内要因計画に比べると分析の精度は下がります。じゃあ全部群内要因で実験を計画すればいいじゃないかと思うかもしれませんが，群内要因の別名，「反復測定」という言葉にあるように，人を対象にする実験計画はそのまま実験参加者に対する負担になります。そういったことも考えると，内容によっては群間要因計画にせざるをえないということも少なくありません。

また，人間を研究対象にする場合は，考えるべき要因がたくさんあることも少なくありません。あの要因もこの要因も関係してくるに違いないと考えると，実験計画の要因数はどんどん増えていきます。ただしこの後見ていくように，要因をどんどん増やすと組み合わせを考慮しなければならない数も多くなり，解釈も難しくなりますから，せいぜい 3 要因で，できれば 2 要因までで研究計画をすることをお勧めします。

17.3 効果はどのように評価するのか

ここで図 17.5 を見てください。左に実験 A，右に実験 B とふたつの実験結果を示しています。これは箱ひげ図の箱をとったような図で，赤い点が群の平均値，そこから上下に伸びる線は群の最大値と最小値を結ん

図 17.5　平均値の差 (群の効果) が同じ 2 つの実験の例。どちらの実験が効果があると言いやすいか。

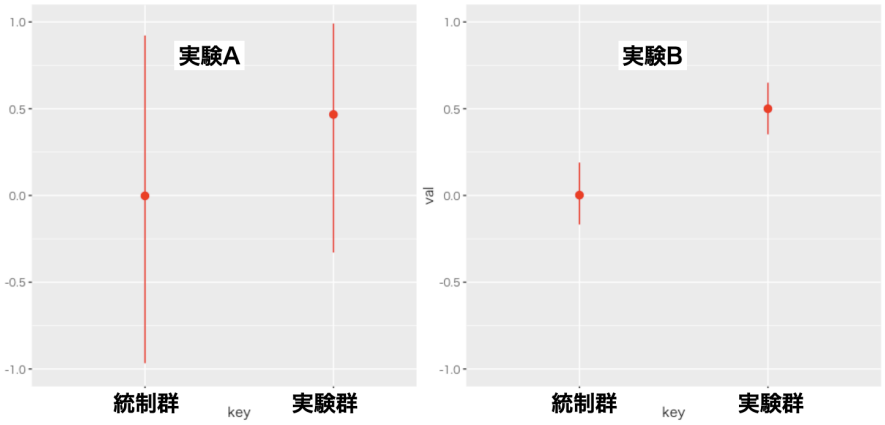

でいます。実験 A は実験 B に比べて，分散が大きいのがすぐにわかると思います。実は実験 A と実験 B は，平均値間の差は同じです。この時，実験の効果があった，とはっきり言い切れるのはどちらでしょうか？

実験 A の方は，確かに実験群のほうが平均値が高くなっていますが，統制群の中にいる最大値の人は実験群の中の数字と遜色ないですし，実験群の最小値の人は統制群に入ってもおかしくない数字です。これに対して実験 B の方は，統制群の最大値でも実験群の最小値におよびません。いくら頑張っても実験群ほどのスコアを出せないのですから，これは実験群による介入の効果が大きかったと判断しやすくなりますね。

つまり実験によって効果があった，なかったという評価をする時は，**群内の分散に比べて群間の分散が十分大きいかどうか**で考えることになります (図 17.6)。

図 17.6　平均値の差 (群の効果) が同じ 2 つの実験の例。左側は群間の分散 (緑の矢印) に比べて群内の分散 (青の矢印) が大きいため，効果があるとは言いにくい。右側の例では，統制群の最大値が実験群の最小値にも及ばないほどなので，効果があると言いやすい。

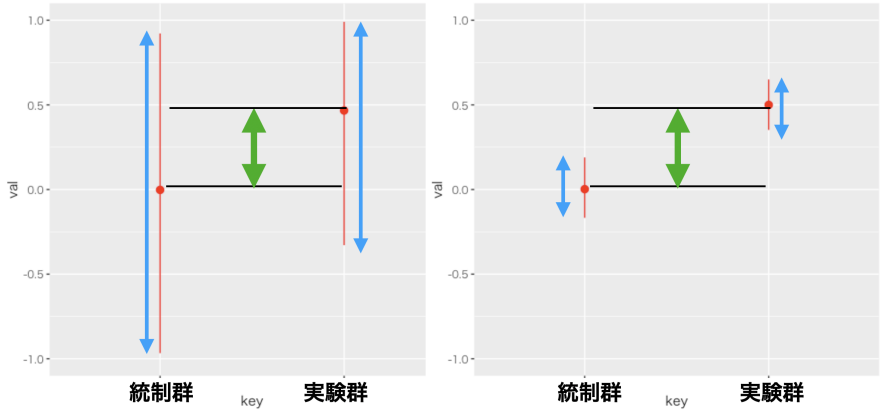

何らかの効果を評価するときに，誤差に比べた大きさで考えるというのは重要なポイントです。統計的な有意差は「帰無仮説が正しい」とした世界での (仮想空間での) 判断基準に過ぎず，実際にはどれぐらい意味のある効果だったのか，ということが大事だという話はすでにした通りです。有意差でなく，実際の差。あるいは，標準化された差で考えることが重要です。標準化された差のことを**効果量 (effect size)** というのでした。この効果量，特に平均値差の効果量は，群間の分散に比べて群内の分散がどれぐらい小さいか，ということを数値化したものです。群間 (要因の水準間) の分散が大きく，群内 (要因の操作では測れない変動) の分散

が小さいほど，効果量は大きくなります。この効果量が大事であるということと，多水準間での比較の話は，軌を一にするものなのです。

17.4 線形モデルとしてみた要因計画

要因計画に沿って得られたデータにおいて，効果の大きさは誤差に対する比で検証することが重要だ，という話でしたが，これを少し具体的な計算モデルで考えてみましょう。そう，平均値の差を比べるというのも，統計的なモデルに基づいた計算になるのです。ここまでの話でどこに「モデル」の話があったのか？と思う人がいるかもしれません。あるいは，また新しいモデル (数式) の話か，と思う人もいるかもしれませんが，大丈夫，実は皆さん既に学んだモデルの話なのです。ここからは，「要因計画は回帰分析と同じ線形モデルだったのだ」という話をしていきます。

さて，帰無仮説検定の話をしたときに，これはモデル比較だと言いました (→ セクション 13.1，Pp.184)。帰無仮説というモデル，対立仮説というモデルを比較して，どちらに軍配を上げるかという勝負判定をする，これが帰無仮説検定だと。

ここでの「モデル」という言葉は，データがどのように作られているかを数式で記述したもの，という意味です。実は巧妙に隠されているんです。前回の 2 群の平均値差の話を思い出してください。要因計画の文脈で言えば，2 群の平均値差の検定は，「一要因二水準計画」です。対応のある検定は群内計画，対応のないものは群間計画です。

ここでは例として，群間の一要因二水準計画で考えてみましょう。実験群と統制群のデータが得られたとしましょう，という話から始まりましたね。それぞれの群に含まれる個体の背景には様々な影響があって，個人差もいっぱいありますし，偶然誤差も含まれます。そこで得られたデータが正規分布に従う，と仮定してみましょう。実験群も統制群も，同じ正規分布 ($N(\mu, \sigma)$) から得られたデータです。

片方の実験群には何らかの心理学的な介入をして，もう片方の統制群には何もしません。とすると，統制群の方は実験前の平均値と分散に変化がなく (何もしていないのですから)，$N(\mu, \sigma)$ のままです。実験群の方は，心理学的な介入をしたので，平均値が変化して $N(\mu + \delta, \sigma)$ となったとします。ここで δ は介入の効果です。

はいこれ！これがモデルです！え，どこが，と思うかもしれません。モデルは「データがどのように作られているかを記述したもの」でしたね。ここでのモデルは，「データが正規分布によって生み出されている」ということ，そのものなのです。カッコつけて書くと，

$$X_A \sim N(\mu, \sigma), \quad X_B \sim N(\mu + \delta, \sigma) \tag{17.1}$$

と書くことができます。ここで X_A は統制群のデータ，X_B は実験群のデータです。データがどうやって作られたか，数式で書かれているでしょう！

そして検定の時は「帰無仮説モデル」vs「対立仮説モデル」とするのでした。帰無仮説モデルは母平均に差がないというモデルですから，$\delta = 0$ というのがそれです。対立仮説モデルは $\delta \neq 0$ です。

具体的に考える例として，次のようなデータを用意しました (図 17.8)。これは対応のない，2 つの群 (仮に実験群と統制群とします) の平均値をプロットしたものです。ここで示されている平均値は標本平均ですから，そこに差があるのは見た通りです。ちなみに黒い点は各群における個体 1 つ 1 つの観測値です。

今回の例において，従属変数である心理変数はどういう特徴なのか，目に見えないものなのでわかりません。でも，心の問題は無数の要因が積み重なった結果であると考えると，正規分布を仮定するのが自然です。つまり，実験群のひとも統制群のひとも，大きな視点から考えれば同じ人間という正規母集団からのサンプル

図 17.7 再掲;対応のない二群の平均値差の検定のシーン

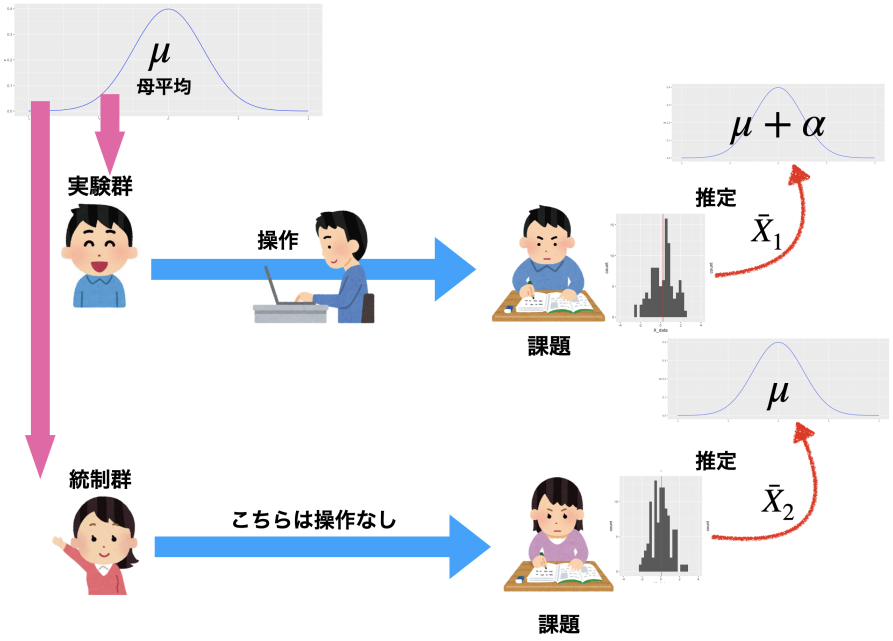

図 17.8 2 つの群の平均値のプロット。黒い点は各群のそれぞれの観測値

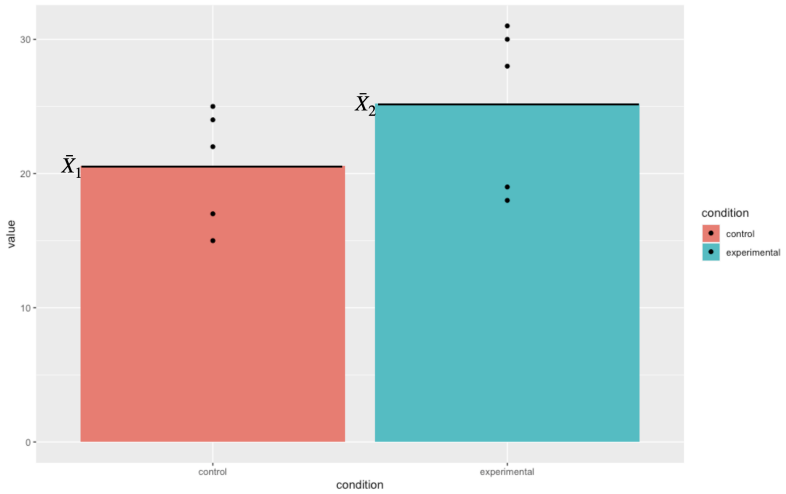

なのです。

さて，実験参加者たちは実験者によって無作為に実験群と統制群に割り当てられました (RCT)。個人差がなければ，各群 1 名ずつのスコアを比較して考えれば良いのですが，人間を対象にしている以上そうはいきません。個人差がどうしても生じてしまうので，複数人を集めて個人差を相殺することを考えます。各群の平均値の違いを見ることで，操作の効果を見ることにするのです。

もしこの実験に効果がなければ，2 群の平均値は同じになるでしょう。この時の平均値は，実験群と統制群に分けた効果がないのですから，両群のスコアを足しあわせた全体平均になるはずです。効果がない=全体平均，なのです。しかし，群ごとに見てみると全体平均から違いが生じています。図 17.9 では，統制群は相対的に低く，実験群は相対的に高い平均値を示しています。この差分こそ (図 17.9 では短い緑の矢印で示して

います), 実験の効果なのです。

図 17.9 効果がなければ全体平均に同じ。群の効果は相対的に平均値をずらす。

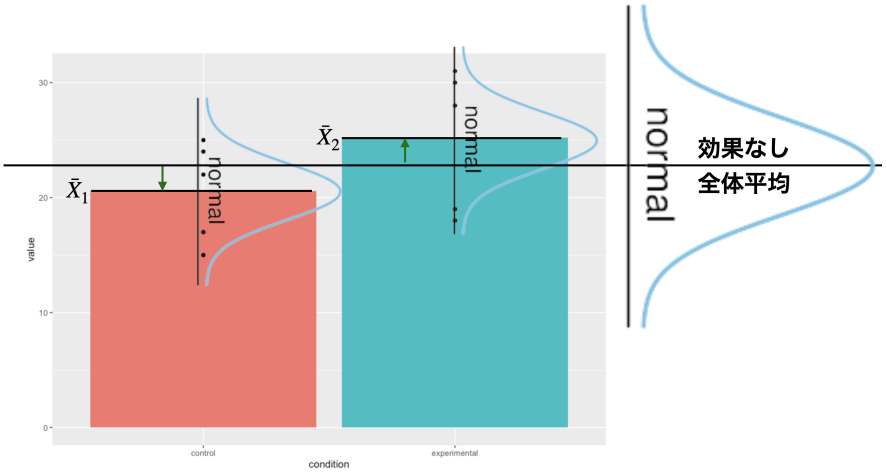

さて, 群ごとの平均は次のように書くことができます。

$$\bar{X}_1 = \frac{1}{5}\sum_{i=1}^{5} X_{i1} \tag{17.2}$$

$$\bar{X}_2 = \frac{1}{5}\sum_{i=1}^{5} X_{i2} \tag{17.3}$$

また, 全体平均は次のように書くことができます[*6]。

$$\bar{X}_{gm} = \frac{1}{10}\sum_{i}\sum_{j} X_{ij} \tag{17.4}$$

これは標本を使った平均値ですが, 本来は推定したい (群間の差がない) 母平均について議論したいところです。$\bar{X}_{gm}$ は母平均の推定値として使い道はありますが, 理想化·抽象化して語れるのがモデルの良いところですから, ここでは全体平均を未知数を表すギリシア文字 β をつかって β_0 としておきましょう。

さて次に, 群わけの効果を β_1 としましょう。すると各群の平均のモデルは

$$\mu_1 = \beta_0 + \beta_1 \tag{17.5}$$

$$\mu_2 = \beta_0 - \beta_1 \tag{17.6}$$

と表すことができます。左辺も各群の母平均なので, 未知数を表すギリシア文字になっています。

つづいて, ここでの個人差はこの実験で制御できない誤差であり, 群平均を中心にどういう向きで出るかわからないものですから, このことを表現するなら,

$$X_{ij} = \mu_j + \varepsilon_{ij} \tag{17.7}$$

[*6] gm は grand mean の略です。

ということになります。これらを組み合わせると，

$$X_{i1} = \beta_0 + \beta_1 + \varepsilon_{i1} \tag{17.8}$$

$$X_{i2} = \beta_0 - \beta_1 + \varepsilon_{i2} \tag{17.9}$$

と書くことができます。ここで一工夫。β_1 にプラス，マイナスの符号がついているのは，$+1, -1$ を掛け算していると考えてみましょう。この符号を決めているものを $X_1 = +1, X_2 = -1$ と表したとすると，まとめて次のように書くことができます。

$$X_{ij} = \beta_0 + \beta_1 X_j + \varepsilon_{ij} \tag{17.10}$$

Oh La La!どこかで見たことありませんか，この式の形？[*7]

そう，**線形モデル**ですね！ $y_i = b_0 + b_1 x_i + e_i$ と同じ，すなわち個々の値 (y_i) が，全体平均 (b_0) と効果 $(b_1 x_i)$ と誤差 (e_i) に分解されています。**実験計画は線形モデルだったのです。**違いは x_i が説明変数の大きさではなくて，どの群に含まれているかを表す離散的な変数になっているということだけです。回帰分析では独立変数も従属変数も連続変数だったのですが，説明変数が離散的な回帰分析のことを我々は実験 (計画) と呼んでいるのです。

要因計画の式 17.10 において，X_j はダミー変数と呼ばれるもので，2 つの群を区別するために使われています。$j = 1$ ならば $X_j = +1$，$j = 2$ ならば $X_j = -1$ となります。

1 つの共通の正規分布。2 つの群に分かれない，同じ正規分布。そろそろ帰無仮説検定と繋がってきたのではないでしょうか。効果がない，というのはまさに，帰無仮説のことですよね。つまり帰無仮説は，$\beta_1 = 0$ という傾きゼロの直線，図 17.9 では群平均を横切っている，横一線の線形モデルだったのです。平均値の差の検定というのは，群平均が横一直線＝傾きゼロではないよ，という結論を出すためのロジックであり，比較される対立仮説は「傾きゼロでない何か」というモデルです。

- 帰無仮説 H0: $\mu_1 = \mu_2 \rightarrow$ 線形モデルにおける傾きの係数 $\beta_1 = 0$
- 対立仮説 H1: $\mu_1 \neq \mu_2 \rightarrow$ 線形モデルにおける傾きの係数 $\beta_1 \neq 0$

帰無仮説が傾きゼロという一点ばりに対し，対立仮説はゼロ以外であれば何でも良いというラフなモデルです。ですから帰無仮説が棄却されたとしても「差がなくはない」という程度のもので，「じゃあゼロでない，何なのか」ということまでは強く主張できません。何度も繰り返すようですが，実質はどのように傾いているのか，差の信頼区間はどの程度あるのか，効果量 (標準化された平均値の差) は大きいのかといった，実質的な大きさを考えることが重要だ，ということを忘れないでください。

17.5 課題

■要因と水準 次の心理学実験は，どのような要因計画でできているでしょうか。要因，水準という言葉の違いに注意しながら，正しく表現してみましょう。

例)「3 つの学校で共通試験をした。成績の平均値に差があるかどうかを検証したい。」$\rightarrow$ 一要因 3 水準，群間 (Between) デザイン

- アサガオの生長を観察するため，水をあげる群とあげない群，肥料をあげる群とあげない群をつくり，成長の程度を比較した。

[*7] Oh La La!はフランス語で「おやまあ！」という意味ですが，筆者は映画 Back to the Future Part 2 に出てきたセリフとして知っています。

- ラットの種類 A/B それぞれに対して，トランキライザーの効果を見るため，0.4mg/0.7mg/1.5mg 投与する群を作り比較した。
- 4 つの学校で，1 年間で共通の試験を実施した。一学期，二学期，三学期の各校における成績変化を比較したい。
- 二つの社会的強化の方法 (a1,a2) があり，この条件に無作為に大学生を選び割り当てた。被験者は 4 つのセッション (b1,b2,b3,b4) を体験し，各セッションの作業量を調べ，比較する。

第 18 章

群間計画 (Between Design) と分散分析

実験計画について，用語の整理や効果の評価の方法について説明してきました。また，実験計画は線形モデルの一種であることも説明しました。ここでは，群間計画 (Between Design) に焦点を当て，分散分析 (ANOVA) の基本的な考え方を理解することを目的とします。特に，一要因および二要因の群間計画における効果の分解方法と評価方法について学びます。ポイントは，「平均値の差を検証するのに，なぜ “分散” 分析というのか」というところにあります。ではレッツゴー。

18.1 一要因群間計画の平方和の分解

前回は二群の平均値差の検定を例にしましたが，要因計画では，3 水準以上，つまり 3 つ以上の群の平均値を比較することがよくあります。ここでは，3 水準の群間計画を例にして，平方和の分解の考え方を説明します。まずは，効果と偶然誤差の切り分けについて考えてみましょう。

18.1.1 効果と偶然誤差の切り分け

表 18.1 をみてください。これは一要因 3 水準，Between デザインの実験データです。カバーストーリーとして，植物の成長を見る実験で水を毎日あげる，時々あげる，あげない，という違いを作って比較したものだと思ってください。要因は「水」で，水準数は 3，実験期間終了後に成長した長さを測って従属変数にしたとします。各水準に 4 つずつ植木鉢を用意し，無作為に種を蒔いて記録します。複数の植木鉢を用意するのは，その他の条件を相殺させるための手続きですね。

3 水準 $\times$ 各群 4 鉢ですので，合計 12 点のデータがあります。

これを見ると結果としての数字はバラバラです。ですが，群ごとに平均を求めると，個体差等今回見たくない他の要因は消しあって効果の大きさだけが見られるということでしたよね。そこでそれぞれの群の平均を計算してみましょう。水をあげる群は，

$$\bar{y}_{\text{あげる}} = \frac{1}{4}\sum_{i=1}^{4} y_i = 5.5 \tag{18.1}$$

時々あげる群は，

$$\bar{y}_{\text{ときどき}} = \frac{1}{4}\sum_{i=5}^{8} y_i = 6.0 \tag{18.2}$$

表 18.1 一要因 3 水準 Between 計画のデータ

ID	水準	記号表記	value
1	毎日あげる	y_1	6
2	毎日あげる	y_2	6
3	毎日あげる	y_3	5
4	毎日あげる	y_4	5
5	時々あげる	y_5	7
6	時々あげる	y_6	4
7	時々あげる	y_7	7
8	時々あげる	y_8	6
9	あげない	y_9	4
10	あげない	y_{10}	3
11	あげない	y_{11}	4
12	あげない	y_{12}	6

あげない群は,

$$\bar{y}_{\text{あげない}} = \frac{1}{4}\sum_{i=9}^{12} y_i = 4.25 \tag{18.3}$$

であり, 全体平均は

$$\bar{y}_{gm} = \frac{1}{12}\sum_{i=1}^{12} y_i = 5.25 \tag{18.4}$$

となります[*1]。

ここで結果から逆に, どうしてこういった数字になったのかを考えてみたいと思います。もし仮に, 水に成長を変えるような効果がまったくなかったとすれば結果はどうなったでしょうか。ランダム化したことによって, 見たい要因以外の効果はすべてキャンセルアウトされていたはずです。個体差も今回みたい要因ではなかったわけですから, そのために各群に 4 つの鉢を用意しておいたのです。複数用意することで平均が算出でき, この平均は個体差をキャンセルアウトしあった代表的な値のはずです。

であれば, 12 鉢全部の平均は, 個性を無くした全体の傾向のはずですね。つまり, 群わけのような人為的な操作がなければ, 原理的には全部同じ数字すなわち全体平均である 5.25cm になるはずなのです。

しかしもちろん実際には, 個体差があります。さらに水も何らかの効果があったと思われます。その大きさを考えてみましょう。水の効果はどのぐらいあったのでしょうか。水をあげた群, すなわち y_{i1} のグループは, 平均で 5.5cm の伸びになっています。何の効果も考えなければ 5.25cm だったはずなのに, 水をあげた群は 5.5cm になっていた。この事実から考えるに, 差分すなわち $5.5 - 5.25 = 0.25$cm が水をあげたことによる効果だったと考えることができます。水を時々あげたときの効果はどうでしょうか。y_{i2} のグループは, 平均で 6.0cm 成長しています。まったく何の効果もなければ, 5.25cm しか伸びなかったのに, この群は 6.0cm 伸びていたわけですから, $6.0 - 5.25 = 0.75$cm 普通より大きいことになります。これが

[*1] 総和記号の添字に注意して読みましょう。もう一つ別の表記法として, 水準も記号にしてしまう方法があります。すなわち 3 つの水準を記号 j で表し, データを y_{ij} のようにします。ここで i は第 j 群の何番目の鉢か, を表す数字であり, 1 から 4 までしか値をとりません。これを使って, $\bar{y}_j = \frac{1}{4}\sum_{i=1}^{4} y_{ij}$ と書くとスマートですね。数式は文字を含まない方が美しいと思いませんか。

水を時々あげたことによる効果です。水をまったくあげなかったときの効果はどうでしょうか。y_{i3} のグループの平均は，4.25cm です。まったく何の効果もなければ，5.25cm の成長ができたはずなのに，今回は 4.25cm しか成長できませんでした。これは，水をあげなかったことによる効果が，$4.25 - 5.25 = -1.0$cm だったということができます。もちろん平易な日本語で言えば，水をあげなかったことによって 1 センチメートル成長が抑えられた，成長の効果はなかったというところですが，ここは表現を整えるためにもマイナスの効果があった，という言い方をしていきましょう。

このように，**群平均－全体平均＝効果**と計算できます。これが実験計画の基本的なアイディアです。ポイントは，すでにさまざまな影響が入り込んでいる研究対象を，ランダムに配置することによって，平均点を揃えることができる。その上で，介入によって平均値を変えることができる。その変わった平均値の大きさが，効果の大きさだったと考えるということです。ここで注意して欲しいのは，それぞれの群に見られた効果をすべて足し合わせると，ゼロになってしまうということです。すなわち，$+0.25 + 0.75 - 1.0 = 0$ です。このようにあくまでも相対的な比較で検証していることに注意しておいてください。

実はこれで話が終わりではありません。もう 1 歩進んで，個体差のことも考えます。さきほどの考え方の例で言えば，全体の平均が 5.25，水をあげる群には +0.25 の効果が出てきますから，群 1 に含まれる植木鉢の数字はすべて 5.5 であるべきなのです。もちろんそのようにはなっていません。$y_1 = 6$ で $y_4 = 5$ です。この，理想通りにいかなかった理由は何でしょうか？ そうこれが，今回の実験では考えられなかった効果です。植物の持っている個体差なのかもしれません。植木鉢に埋められた種と土の接触面積が違ったのかもしれません。あるいはたまたま風が強く当たる場所だったとかそうでなかったとか。ともかく今回の実験では考えられなかった効果です。これらをひっくるめて，**偶然誤差**と呼ぶしかありません。この偶然誤差がどれぐらいそれぞれの答えに出たかを算出してみましょう。

y_1 は 5.5 であるべきところが 6 だったのですから，$6 - 5.5 = 0.5$ の誤差が出た，ということができます。同様にすべての個体に対して，**結果－群平均＝誤差**という計算式を当てはめることができます。

記号だと分かりにくいかもしれませんが，データで考えると表 18.2 のようになります。

表 18.2　一要因 3 水準 Between 計画のデータを分解する

ID	condition	notation	value(y_i)	全体平均 (b_0)	群の効果 (b_j)	誤差 (e_{ij})
1	毎日あげる	y_1	6	5.25	+0.25	+0.50
2	毎日あげる	y_2	6	5.25	+0.25	+0.50
3	毎日あげる	y_3	5	5.25	+0.25	−0.50
4	毎日あげる	y_4	5	5.25	+0.25	−0.50
5	時々あげる	y_5	7	5.25	+0.75	+1.00
6	時々あげる	y_6	4	5.25	+0.75	−2.00
7	時々あげる	y_7	7	5.25	+0.75	+1.00
8	時々あげる	y_8	6	5.25	+0.75	+0.00
9	あげない	y_9	4	5.25	−1.00	−0.25
10	あげない	y_{10}	3	5.25	−1.00	−1.25
11	あげない	y_{11}	4	5.25	−1.00	−0.25
12	あげない	y_{12}	6	5.25	−1.00	+1.75
合計					0.00	0.00

このようにデータを効果と誤差に分解できました。あとは，効果がどれぐらいあったかをどう評価するかを考えます。たとえば「水を毎日あげた群」はどれほど効果があったのでしょうか。4 つの植木鉢いずれについ

5057 ても $+0.25$ の効果があるのですが，誤差は $+0.5$ から -0.5 までさまざまです。誤差の大きさを評価するた
5058 めに，足し合わせちゃいましょう！となると当然ながら，どの群においても誤差の総和は 0 になります。効果が
5059 全体平均からの相対的な違いであったことと同じで，誤差というのも群平均からの相対的な違いでしかない
5060 からです。

5061 これは「大きさ」を足し合わせることで探そうとしたことに問題があります。誤差はすべて足し合わせるとゼ
5062 ロになりますが，それは偶然誤差の位置の話であって，大事なのはどの程度のばらつきをもって現れるか，に
5063 あります。誤差は分散で大きさを考えなければなりません。つまり，真値から離れている距離の平均を考える
5064 ことになるのです。

5065 効果にしてもそうです。効果も大きさで考えるときに総和で考えるのではなく，「水をあげたりあげなかった
5066 り，時々あげたりする」という変化に応じて，結果がどの程度ばらついたのかを考えなければなりません。

5067 そこで，誤差にしても効果にしても，その大きさを見積もるためには表 18.2 の各要素を二乗して足し合わ
5068 せたものを使います。これをとくに**平方和 (sum of squares: SS)** と言います。平方和を足し合わせた数で
5069 割って平均化したものが分散ですから，平方和と分散は同じ情報を持っているものと考えることができます。

5070 全体平均は 5.25 であり，表 18.3 にあるように，効果と誤差に分解した結果，$SS_T = 18.25, SS_A =$
5071 $6.50, SS_E = 11.75$ となりました。合計欄の (T) の二乗，(A) の二乗，(E) の二乗の合計がそれぞれ
5072 SS_T, SS_A, SS_E で，$SS_T = SS_A + SS_E$ となっていることを確認してください。

表 18.3　一要因 3 水準，Between デザインのデータの平方和

ID	水準	value	平均偏差 (T)	群の効果 (A)	誤差 (E)	(T) の二乗	(A) の二乗	(E) の二乗
1	毎日	6	0.75	0.25	0.50	0.562	0.062	0.250
2	毎日	6	0.75	0.25	0.50	0.562	0.062	0.250
3	毎日	5	-0.25	0.25	-0.50	0.062	0.062	0.250
4	毎日	5	-0.25	0.25	-0.50	0.062	0.062	0.250
5	ときどき	7	1.75	0.75	1.00	3.062	0.562	1.000
6	ときどき	4	-1.25	0.75	-2.00	1.562	0.562	4.000
7	ときどき	7	1.75	0.75	1.00	3.062	0.562	1.000
8	ときどき	6	0.75	0.75	0.00	0.562	0.562	0.000
9	あげない	4	-1.25	-1.00	-0.25	1.562	1.000	0.062
10	あげない	3	-2.25	-1.00	-1.25	5.062	1.000	1.562
11	あげない	4	-1.25	-1.00	-0.25	1.562	1.000	0.062
12	あげない	6	0.75	-1.00	1.75	0.562	1.000	3.062
		合計	0.00	0.00	0.00	18.25	6.50	11.75

5073 全体の平方和 SS_T は群間の平方和 (あるいは効果の平方和)SS_A と誤差の平方和 SS_E との関係から
5074 次のように表せます。

$$SS_T = SS_A + SS_E \tag{18.5}$$

5075 このように平方和を分解し，誤差 (群内分散) に対する効果 (群間分散) の比率を評価することになります。
5076 検定をするときは，分散の比が従う理論分布を使って，効果が偶然誤差に比べてどの程度大きいかを評価し
5077 ます。ここではまだ平方和で，データの数で割っていませんから，分散ではなく平方和の状態です。この後は，
5078 それぞれの平方和を自由度 (!) で割って平均平方を求め，その比率をとります。

この比率を評価する考え方は**分散分析 (analysis of variance)** とも呼ばれ，心理学における古典的かつ基礎的な研究手法になっています。詳しい計算については次講以降になりますが，多水準間の「平均値の差」を評価するために「平方和」「分散」を考えるのだ，ということを理解しておいてください。

18.2 二要因群間計画と主効果

分散分析の具体的な手順に進む前に，要因の数が増えたときの「平方和の分解」について見ていきましょう。

今度は，二要因の群間計画です。二要因計画とはたとえば，次のような実験計画です。

> 植物の生長を観察するため，水をあげる群とあげない群，肥料をあげる群とあげない群をつくり，成長の程度を比較したい

この例では要因は「水」と「肥料」，水準はそれぞれ「あげる・あげない」なので 2×2 の実験計画というのでした。

アサガオの例のまま進めても良いのですが，もう少し心理学っぽいほうがイメージしやすいかもしれませんので，以下では表 18.4 のようなコーヒーテイスティング事例を使うことにします。

2 つのメーカーがそれぞれ缶コーヒーを作っていて，ホットコーヒーにした場合，アイスコーヒーにした場合の美味しさを評価してもらいます。各条件に 3 名ずつ試飲をお願いして，20 点満点で評価してもらったら，表 18.4 のようになりました[*2]。これを図示したのが図 18.1 にあります。これを見るとわかるように，ホットコーヒーにすると銘柄 A は高い評価，アイスコーヒーだと両者の違いはなくなることがわかります。どうも銘柄 B はホットコーヒーにして売らない方がいいように思いますが，たまたまホットの銘柄 B を飲んだ 3 人がコーヒーが苦手だったのかもしれませんね。このような誤差に比べて，温度と銘柄の別の効果はどの程度あるのかを考えていきたいと思います。

表 18.4 二要因のデータ例

ID	温度	メーカー	notation	評価 (y_i)
1	Hot	銘柄 A	$X_{11} = +1, X_{12} = +1$	13
2	Hot	銘柄 A	$X_{21} = +1, X_{22} = +1$	11
3	Hot	銘柄 A	$X_{31} = +1, X_{32} = +1$	12
4	Hot	銘柄 B	$X_{41} = +1, X_{42} = -1$	7
5	Hot	銘柄 B	$X_{51} = +1, X_{52} = -1$	6
6	Hot	銘柄 B	$X_{61} = +1, X_{62} = -1$	8
7	Cold	銘柄 A	$X_{71} = -1, X_{72} = +1$	9
8	Cold	銘柄 A	$X_{81} = -1, X_{82} = +1$	9
9	Cold	銘柄 A	$X_{91} = -1, X_{92} = +1$	9
10	Cold	銘柄 B	$X_{10,1} = -1, X_{10,2} = -1$	13
11	Cold	銘柄 B	$X_{11,1} = -1, X_{11,2} = -1$	11
12	Cold	銘柄 B	$X_{12,1} = -1, X_{12,2} = -1$	9

さて，一要因の計画は，線形モデルと見ることができるという話をしていました。二要因の計画も当然，同じ

[*2] 添字にカンマが入っているのが美しくないですね。しかし他の良い方法が思いつきませんでした。

図 18.1　2 種類のコーヒーと 2 通りの飲み方による評価

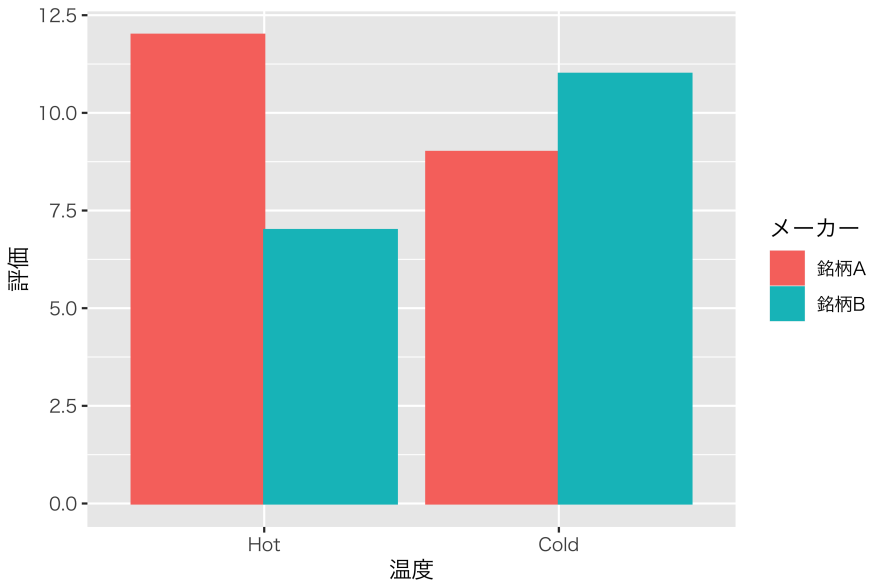

ように線形モデルとして考えることができます。今回は二要因計画です。要因は「温度」と「銘柄」の二種類ありますから，効果として b_1 と b_2 の 2 つが必要です。これを式に書き入れてみますと，次のようになります。

$$y_i = b_0 + b_1 X_{i1} + b_2 X_{i2} + e_i \tag{18.6}$$

ここで左辺の y_i は ID が i の人の評価で，たとえば $y_1 = 13, y_2 = 11, \cdots, y_{12} = 9$ ということになります。X_{ij} は i さんが要因 j のときにどちらに割り振られたかを表しているのだと思ってください。$j = 1$ は温度の要因，$j = 2$ は銘柄の要因を表しています。ですから，X_{i1} は i さんが温度要因で Hot/Cold のどちらを飲んだかを表します。具体的には，X_{11} は Hot 条件です。X_{71} は Cold 条件です。これは**名義尺度水準**であり，Hot/Cold になんらかの数字を割り振らなければなりません。数字は何でもいいといえば何でもいいのですが，ここでは数式的にわかりやすくするために Hot に +1 を，Cold に-1 を割り振ることにします。こうすることで，b_1 が温度効果の大きさを表すことになりますね。Hot/Cold で符号が違って大きさが同じですから，相対的な大きさを表しているだけになるからです[*3]。$X_{11} = +1, X_{71} = -1$ のような数字が入るものだと思って読み進めてください。同様に，X_{i2} は銘柄水準の割当を表していて，銘柄 A は +1, 銘柄 B は-1 を表しています。具体的に書き起こしてみましょう。

$$\left\{\begin{array}{rcccll}
y_1 & = & b_0 + b_1 X_{11} + b_2 X_{12} + e_1 & = & b_0 + b_1 + b_2 + e_1 & \text{Hot で銘柄 A} \\
\vdots & & \vdots & & \vdots & \\
y_4 & = & b_0 + b_1 X_{41} + b_2 X_{42} + e_4 & = & b_0 + b_1 - b_2 + e_4 & \text{Hot で銘柄 B} \\
\vdots & & \vdots & & \vdots & \\
y_7 & = & b_0 + b_1 X_{71} + b_2 X_{72} + e_7 & = & b_0 - b_1 + b_2 + e_7 & \text{Cold で銘柄 A} \\
\vdots & & \vdots & & \vdots & \\
y_{10} & = & b_0 + b_1 X_{10,1} + b_2 X_{10,2} + e_{10} & = & b_0 - b_1 - b_2 + e_{10} & \text{Cold で銘柄 B} \\
\vdots & & \vdots & & \vdots &
\end{array}\right. \tag{18.7}$$

[*3] 他にも Hot を 0,Cold を 1 とすることもできます。すると Hot 条件を基準にした Cold 条件の変化の大きさを表したことになります。詳しくは次講で扱います。

ここで X_{ij} は符号だけを表している名義尺度水準であることを確認しておいてください。

改めて式 18.6 や式 18.7 を見ると，これも線形モデル，とくに説明変数が複数ある**重回帰分析**のモデルと同じ形をしているのが分かりますね。重回帰分析は第 8 講でやりましたが，そのモデル式と同じ形をしているのが確認できると思います。要因計画は線形モデルなのです。

それでは，効果の大きさ，誤差の大きさを見積もってみましょう。二要因の場合でも考え方は同じです。無作為に割り当てたのですから，人間の手を加えなかったらデータの散らばりのすべては誤差 (個体差) です。誤差はキャンセルし合うはずなので，理論的にはすべて平均値に一致するはずです。

しかし，やれ温度の操作だとか，やれメーカーの違いだとかで人によって違う介入があり，しかも人間のやることですので個人差も加わってしまいました。だからデータがばらついてしまったのだ，と考えるのです。

理想的には全部同じはずと考えると，実験もしなければ個人差もない，理想的なデータの値は全体平均 $\bar{X}_{gm} = 9.75$ にぴったり合致するはずなのでした。しかしそこに温度の効果 b_1 が関係してきます。図 18.2 の左にあるように，温度で群わけして Hot 群だけの平均を計算してみましょう。

$$\bar{y}_H = \frac{1}{6}\sum_{i=1}^{6} y_i = \frac{1}{6}(13+11+12+7+6+8) = 9.5 \tag{18.8}$$

同じく，Cold 群だけの平均は次のようになります。

$$\bar{y}_C = \frac{1}{6}\sum_{i=7}^{12} y_i = \frac{1}{6}(9+9+9+13+11+9) = 10.0 \tag{18.9}$$

ここで，群平均-全体平均=効果だと考えられますから，Hot 群に割り当てられると -0.25 の効果が，Cold 群に割り当てられると $+0.25$ の効果があったということになります。

同様に，メーカーの効果も考えましょう。温度の効果を潰して (温度の効果で分けずに) 銘柄 A のデータだけ取り出して，平均値を計算してみます[*4]。

$$\bar{y}_A = \frac{1}{6}\left(\sum_{i=1}^{3} y_i + \sum_{i=7}^{9} y_i\right) = \frac{1}{6}(13+11+12+9+9+9) = 10.5 \tag{18.10}$$

同様に，銘柄 B の平均値を計算します。

$$\bar{y}_B = \frac{1}{6}\left(\sum_{i=4}^{6} y_i + \sum_{i=10}^{12} y_i\right) = \frac{1}{6}(7+6+8+13+11+9) = 9.0 \tag{18.11}$$

群平均-全体平均=効果ですから，銘柄 A は全体平均より $10.5 - 9.75 = 0.75$ 高くなる効果が，相対的に銘柄 B は全体平均より 0.75 下がる効果がある (-0.75 あげる効果がある)，ということがわかります。

図 18.2 に，群ごとに平均値をプロットし，全体平均 (9.75) のラインを横一線で引いてみました。これを見ると，各群の効果が全体平均 (b_0) を挟んで，相対的に同じ大きさで影響しているのがわかると思います。

さて，これらの効果がわかったところで，足し算を組み上げていきましょう。全体平均にそれぞれの効果を加えていきます。銘柄 A をホットコーヒーでいただくとすると，全体平均 9.75 に Hot の効果 (-0.25) があって，銘柄 A の効果 ($+0.75$) も入りますから，$9.75 - 0.25 + 0.75 = 10.25$ となり，これが銘柄 A をホットで飲んだ時の平均値になるはずですが・・・

$$\bar{y}_{H,A} = \frac{1}{3}\sum_{i=1}^{3} y_i = \frac{1}{3}(13+11+12) = 12 \tag{18.12}$$

[*4] この数式の美しくないこと！ $\sum$ の中身が 2 つに分裂してしまっています。しかしこれは i を通し番号でつけたから仕方のないこと。ここでは i が ID をあらわしていますから，その何番目から何番目までが加算されているかを確認してください。

図 18.2 群ごとにプロットしたもの。全体平均から見た相対評価になっていることが確認できる。

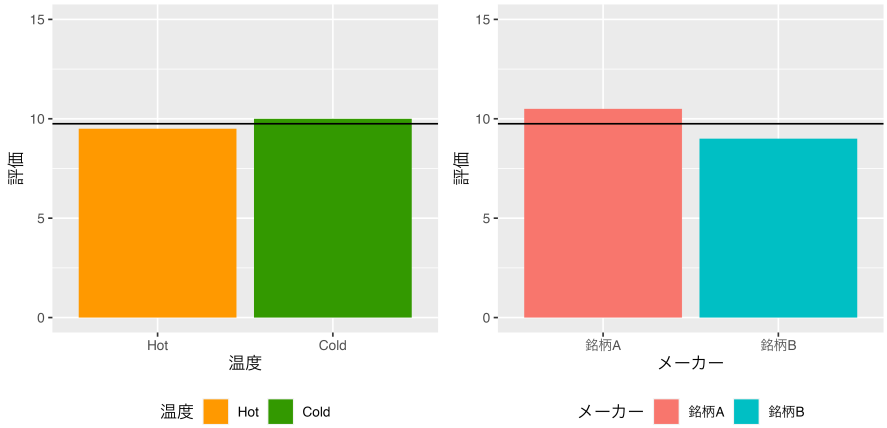

あれ？ なりませんでした。

18.3 交互作用の理解と解釈

18.3.1 交互作用の算出

実は，同様のことは他の組み合わせのところでも生じます。群平均からの差分が誤差なのだ，と考えれば良いはずですが，群平均が理論通りにならないのです。具体的に，表 18.5 に計算してみました。効果の総和と群平均は，理論的には合致するはずです。これはどうしたことでしょう。

表 18.5 二要因のデータ例

全体平均	温度の効果	メーカーの効果	効果を足し合わせると	群平均は	評価
9.75	-0.25	+0.75			13
9.75	-0.25	+0.75	10.25	12.0	11
9.75	-0.25	+0.75			12
9.75	-0.25	-0.75			7
9.75	-0.25	-0.75	8.75	7.0	6
9.75	-0.25	-0.75			8
9.75	+0.25	+0.75			9
9.75	+0.25	+0.75	10.75	9.0	9
9.75	+0.25	+0.75			9
9.75	+0.25	-0.75			13
9.75	+0.25	-0.75	9.25	11.0	11
9.75	+0.25	-0.75			9

銘柄 A(+0.75) のホットコーヒー (−0.25) が 10.25 で，群平均が 12.0 ということは，$12.0 - 10.25 = +1.75$ の差分があります。これも実は，考慮すべき効果のひとつなのです。これは「A をホットで」という組み合わせのときに**のみ**生じる組み合わせの効果で，とくに**交互作用 (interaction)** といいます[*5]。

[*5] 余談ですが，統計的な文脈では interaction を「交互作用」と訳します。社会心理学などの文脈では，「相互作用」と訳されます。

交互作用とはこのように，水準同士の組み合わせによって生じる特別な効果のことを指します。交互作用に対して，これまでみてきた群の平均は**主効果 (main effect)** と呼んで区別します。式 18.7 にあった線形モデルは，次の式 18.13 のように交互作用項も含めたものにアップデートしなければなりません。

$$y_i = b_0 + b_1 X_{i1} + b_2 X_{i2} + b_3 X_{i3} + e_i \tag{18.13}$$

この交互作用は，式 18.13 にもあるように，主効果とは別の独立した影響源です。ですから，主効果がなくても，交互作用だけある，ということがあり得ます。今回の例で言えば，温度の違いや銘柄の違いははっきりしないが，銘柄 B は温めるととんでもなくうまくなる，といった場合ですね。

つまり，交互作用はいわば「ただしイケメンに限る」という条件のようなものです。かっこいいセリフや仕草は，それぞれに評価を上げる効果がなくとも (あってもいいんですが)，イケメンがするからとくに良いのであって，イケメンでない人がするとむしろ逆効果，ということもあるのでそれを考慮しておこう，ということです[*6]。

さて，この組み合わせの効果も相対的なもので，全部足し合わせると 0 になるようにしなければなりません。相対的に評価する，というのは効果をただ足し合わせると 0 になるということだからです。他の交互作用の大きさを計算して確かめてみましょう。

銘柄 A($+0.75$) の Cold 条件 ($+0.25$) の効果が全体平均に加わると 10.75 で，群平均が 9.0 ですから，ここには -1.75 の交互作用効果が出ています。同様に銘柄 B の Hot 条件には -1.75，銘柄 B の Cold 条件には $+1.75$ ですから，4 つの要素を足すとキャンセルしあって合計 0 になっていますね。これを踏まえて，式 18.7 をアップデートしましょう。

$$\left\{\begin{array}{rcccl}
y_1 & = & b_0 + b_1 X_{11} + b_2 X_{12} + b_3 X_{13} + e_1 & = & b_0 + b_1 + b_2 + b_3 + e_1 \quad \text{Hot で銘柄 A} \\
\vdots & & \vdots & & \vdots \\
y_4 & = & b_0 + b_1 X_{41} + b_2 X_{42} + b_3 X_{43} + e_4 & = & b_0 + b_1 - b_2 - b_3 + e_4 \quad \text{Hot で銘柄 B} \\
\vdots & & \vdots & & \vdots \\
y_7 & = & b_0 + b_1 X_{71} + b_2 X_{72} + b_3 X_{73} + e_7 & = & b_0 - b_1 + b_2 - b_3 + e_7 \quad \text{Cold で銘柄 A} \\
\vdots & \vdots & \vdots & & \\
y_{10} & = & b_0 + b_1 X_{10,1} + b_2 X_{10,2} + b_3 X_{10,3} + e_{10} & = & b_0 - b_1 - b_2 + b_3 + e_{10} \quad \text{Cold で銘柄 B} \\
\vdots & & \vdots & & \vdots
\end{array}\right. \tag{18.14}$$

交互作用項 (b_3) のもつ符号は，プラスとマイナスが上から順に $+, -, -, +$ となっています。どうしてこういうことになっているのかについて，説明を追加しておきましょう。

今回は 2×2 の計画ですから，図 18.3 にあるように組み合わせの表を書いてみると，主効果はその周辺の平均値で考えていたことがわかります。たとえば 1 つ目の要因である温度 (図中では要因 A とします) の，「Hot(水準 a1)」か「Cold(水準 a2)」かの話は，もう 1 つの要因であるメーカーを潰して，列方向に 1 つのグループにした平均からその効果を計算していました (b_1)。この水準同士の比較は相対的なので，水準 1 と 2 は符号違いで $+b_1, -b_1$ になっています。同様に，2 つ目の要因である銘柄 (図中では要因 B とします) についても，要因 A の水準を潰して行方向に 1 つのグループと考え，平均を出して効果を算出し，相対比較にしていました ($+b_2, -b_2$)。

[*6] このたとえはポリコレ的に正しくないというか，恋愛至上主義的で容姿に基づく人物評価を助長するような笑いの形式になっているので，個人的には好ましく思っていないのです。が，みなさんが交互作用を身近に感じてもらえるのでは，と思って書いています。個人的には熱燗で飲む日本酒と冷やで飲む日本酒って違うよね，という例のが一番ピンとくるんですが，お酒を飲まない人，あるいは未成年の方にとってはこれも不適切な例かなと思ったり。本文はコーヒーにしていますが，わかりやすい例になっているでしょうか。何か良いアイデア，たとえがありましたら，ご一報ください。

これに対して，交互作用はセル内，各組み合わせについて生じている効果です。行方向，列方向についてはそれぞれの要因の主効果として計算されていますから，交互作用は行方向に足し合わせても ± 0，列方向に足しあわせても ± 0 になる必要があります。そうでないと，周辺の計算が合わなくなってしまうからです。図 18.4 の左上，a1b1 水準に交互作用効果 b_3 が生じたとすると，列方向，つまり同じ水準 a1 のなかで，総和がゼロにならないといけませんから，a1b2 水準には $-b_3$ が入ることになります。これはまた，行方向にも総和がゼロでなければなりませんから，a2b1 も $-b_3$ である必要があります。残る右下の a2b2 は，行方向にも列方向にも総和ゼロにするためには $+b_3$ でなければなりません。このようにして，交互作用の符号は周りとの関係で定まっていたのです。交互作用の大きさは，どの行方向，列方向をみても総和ゼロになっている，というのは水準数が増えても同じです。

図 18.3　主効果の計算は周辺の平均値から計算する

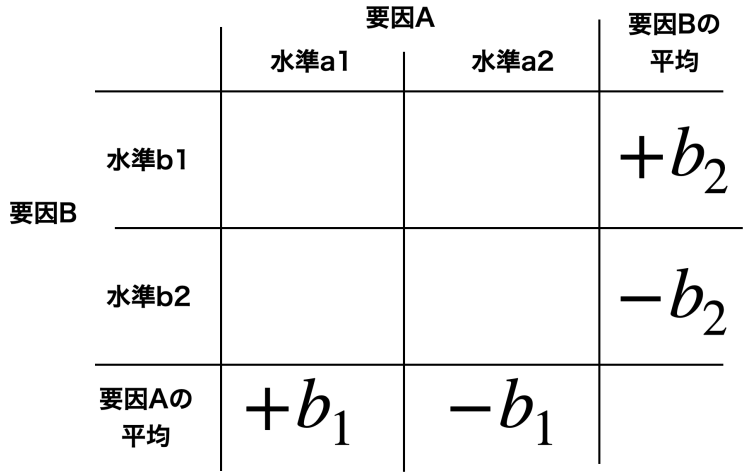

図 18.4　交互作用はセルの内部で相殺するように

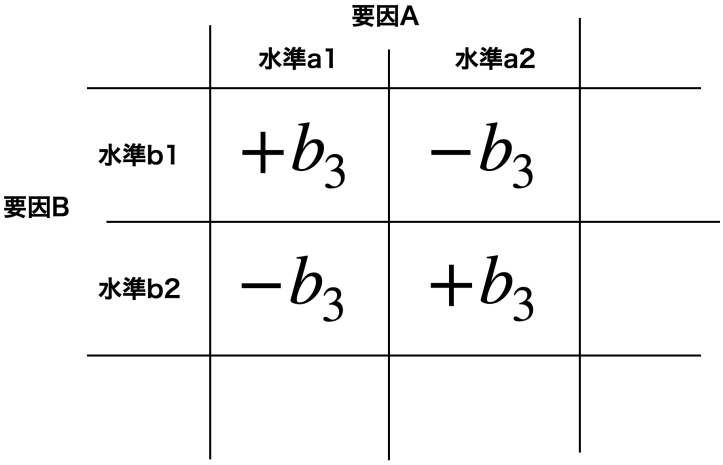

このように交互作用を含めて計算すると，組み合わせ水準のところまで含めて，群平均の計算が合うようになります。それでも一人ひとりのレベルまで考えてみると，やはりズレが出てしまいますが，これはどうしようもない個人差＝誤差ですので，これを計算することで誤差を算出できます。

表 18.6 には，それぞれの効果の大きさと，それを二乗して足したものを書きました。二乗して足し合わせた

表 18.6　平方和の計算

全体平均	温度の効果	銘柄の効果	交互作用	誤差	評価
9.75	-0.25	+0.75	+1.75	+1.00	13
9.75	-0.25	+0.75	+1.75	-1.00	11
9.75	-0.25	+0.75	+1.75	0.00	12
9.75	-0.25	-0.75	-1.75	0.00	7
9.75	-0.25	-0.75	-1.75	-1.00	6
9.75	-0.25	-0.75	-1.75	+1.00	8
9.75	+0.25	+0.75	-1.75	0.00	9
9.75	+0.25	+0.75	-1.75	0.00	9
9.75	+0.25	+0.75	-1.75	0.00	9
9.75	+0.25	-0.75	+1.75	+2.00	13
9.75	+0.25	-0.75	+1.75	0.00	11
9.75	+0.25	-0.75	+1.75	-2.00	9
平方和	0.75	6.75	36.75	12.00	56.25

ものはとくに**平方和 (sum of squares; SS)** といいます。これはもちろん，大きさを比較するため，幅の計算にするのです。評価の列にも平方和がありますが，これは各評価と全体平均の差の平方和になっています。評価の平方和はデータ全体のばらつきを表していますが，この全体平方和＝温度効果の平方和＋銘柄の平方和＋交互作用の平方和＋誤差の平方和となっているのがわかります ($56.25 = 0.75 + 6.75 + 36.75 + 12.00$ です)。2 要因計画の場合も，交互作用を考慮して，データの散らばりを足し算の形に分解できました。

18.3.2　交互作用のパターン

もう一度冒頭の図 18.1 にもどって，2 水準 ×2 水準のスコアをそれぞれ見てみましょう。横軸は温度の 2 水準で，名義尺度水準の数字すなわち離散的な変数ですから適切ではないのですが，同じ条件のところを線で結んでみますとクロスしているのがみて取れると思います (図 18.5)。交互作用が見られる典型的なパターンの 1 つが，このように平均点を結ぶとクロスする形になります。

図 18.5　平均点を結ぶとクロスする

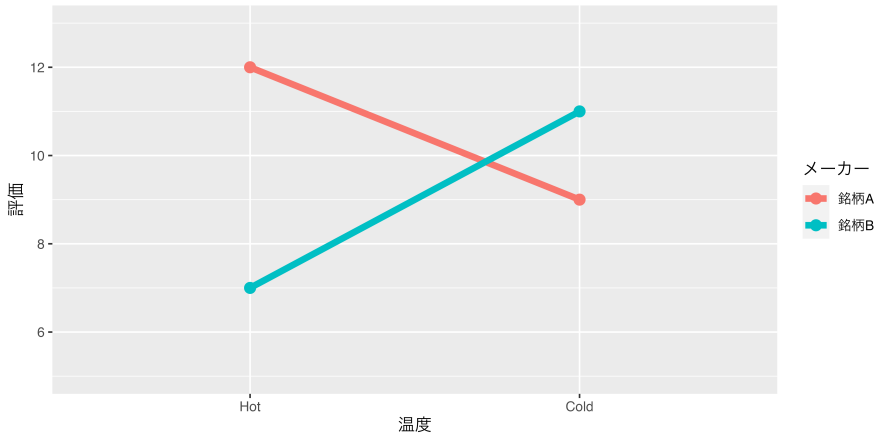

ここで再確認ですが，主効果というのは各群の平均における差を見るものです。温度の効果を見るときはメーカーの水準に関係なく，温度の Hot/Cold の別だけに注目して平均を見ます。逆にメーカーの効果を見るときは，温度の水準に関係なく銘柄 A/B の違いを見ます。図 18.6 には先ほどのクロスしたラインに主効果の位置を書き加えました。図 18.6 の左にあるのが，温度の主効果を比べる時の点で，右にあるのがメーカーの主効果を見るときの場所です。主効果はこのように，それ以外の群の水準を潰して平均を見ているわけですね。図 18.3 のように，表で理解した方がわかりやすい人もいるかもしれませんが，表でピンとこなかった人は図でイメージしてみてください。

図 18.6　主効果はどこを比べているのか確認しておこう

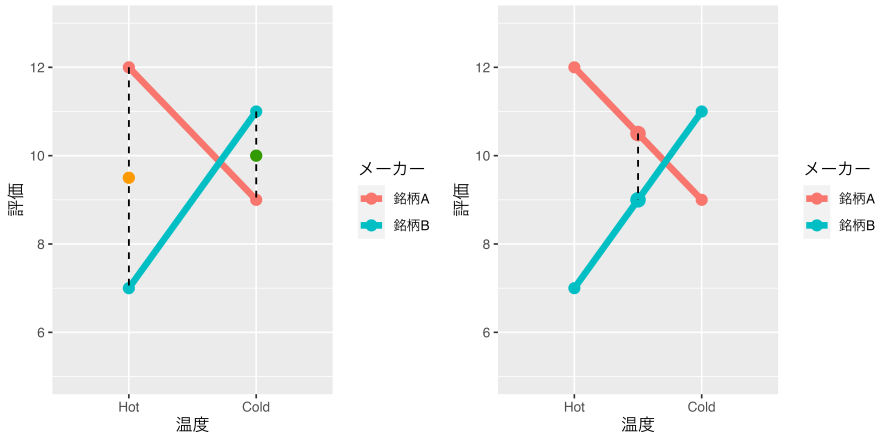

ところで，交互作用は必ずしもこのクロスしたような状況だけを指すものではありません。基本的に主効果ではなく，組み合わせたときに初めてみられる効果のことを言いますから，交互作用の現れ方は他にもあり得ます。順にいろいろなパターンを見てみましょう。

まず要因 A,B それぞれの主効果があり，交互作用がない例が図 18.7 です。要因 A の第一，第二水準の間に差があるので要因 A の主効果がありますし，要因 B のみ，つまり左右で見比べてもその平均に違いがあります。

一方の要因しか効果がない場合が図 18.8,18.9 です。図 18.8 は上下の違いだけで左右に違いがありませんから，要因 A の効果だけが出ていることになります。図 18.9 は左側と右側の違いがありますが，要因 A の水準に違いがありません。またこの図には交互作用が入っておらず，組み合わせの効果がないのでパターンが比較的みやすくなっています。

図 18.10 には，主効果も交互作用も含まれている例を示しました。上側・下側の比較でも差がありますし，左側・右側だけでも差があります。さらに左右を結んだ線が平行になっていないということは，特別な組み合わせの効果がどこかに出ていることを意味します。

図 18.11 は，コーヒーテイスティングの例を極端にしたようなパターンです。これは要因 A の第一水準の平均と第二水準の平均を取っても同じ，要因 B のそれも同じなのですが，明らかに効果の現れ方が一方向的ではありませんね。それぞれの主効果がないのに，交互作用だけあるというパターンです。

今回のコーヒーテイスティング事例では，主効果の大きさよりも交互作用の大きさの方が強かったので，図 18.11 のような形になったのでしょう。実際に「どれぐらい大きければ意味があるのか」といったことについては，次講で学ぶことになります。そこでは効果の大きさを評価し，意味があるのかどうかを判断するということについて学びますが，今のところはひとまず算出方法と，出現パターンのあり方について把握しておいてください。何にせよ，**データは図にする**ことの重要性が，改めて分かったのではないかと思います。

図 18.7　両要因の主効果だけがある

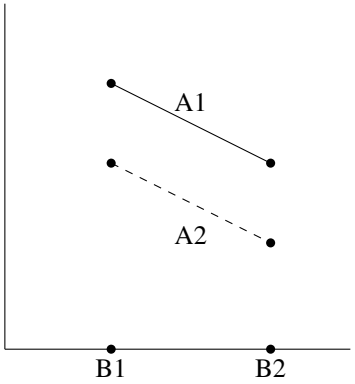

図 18.8　要因 A の主効果だけがある

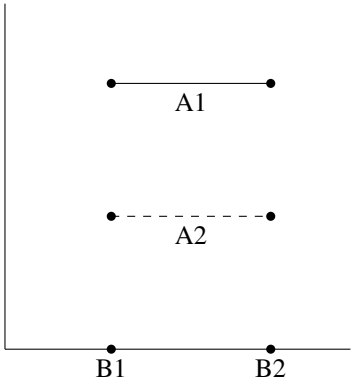

図 18.9　要因 B の主効果だけがある

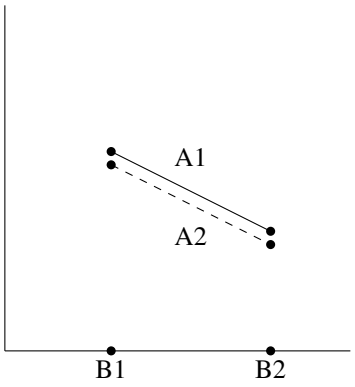

図 18.10　主効果も交互作用もある

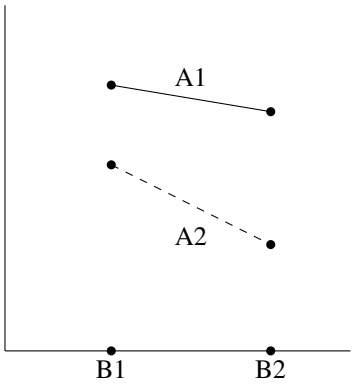

図 18.11　主効果はないが交互作用だけがある

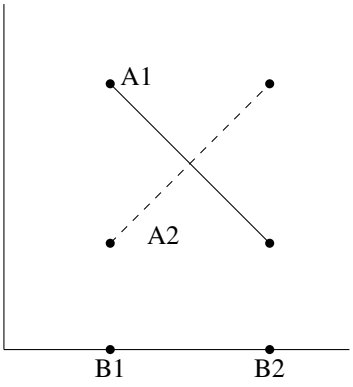

18.4　平方和の分解と変動の源泉

18.4.1　組み合わせが増えると

ところで今回，要因の組み合わせによる影響，つまり交互作用を考えようという話でした。今回は 2 要因の例でしたが，3 要因になるとさらにその組み合わせは増えます。下に要因計画ごとの要素の組み合わせを書

いてみました。

$$
\begin{aligned}
&\text{一要因群間計画} \quad \text{全体変動} = \text{要因 A} + \text{誤差} \\
&\text{二要因群間計画} \quad \text{全体変動} = \text{要因 A} + \text{要因 B} + \text{交互作用 AB} + \text{誤差} \\
&\text{三要因群間計画} \quad \text{全体変動} = \text{要因 A} + \text{要因 B} + \text{要因 C} + \text{交互作用 AB} + \text{交互作用 AC} + \text{交互作用 BC} \\
&\qquad\qquad + \text{交互作用 ABC} + \text{誤差} \\
&\text{四要因群間計画} \quad \text{全体変動} = \text{要因 A} + \text{要因 B} + \text{要因 C} + \text{要因 D} \\
&\qquad\qquad + \text{交互作用 AB} + \text{交互作用 AC} + \text{交互作用 AD} + \text{交互作用 BC} \\
&\qquad\qquad + \text{交互作用 BD} + \text{交互作用 CD} + \text{交互作用 ABC} + \text{交互作用 ABD} \\
&\qquad\qquad + \text{交互作用 BCD} + \text{交互作用 ABCD} + \text{誤差}
\end{aligned}
\tag{18.15}
$$

3 要因になると，3 つの主効果 (効果 A,B,C) に加え，組み合わせの効果が AB,AC,BC の一次の交互作用だけでなく，ABC3 つ揃った時の二次の交互作用も考える必要があります。4 要因についても書いてみましたが，もう訳が分からないレベルです。

このことからわかるように，要因計画はいくらでも複雑にしても良い，というものではありません。要因が増えるごとに考えるべき要素が増えるだけであり，結局統一的な解釈が難しくなります。お勧めとしては，交互作用のないような現象について，二要因までの研究計画にしておいた方が良いように思います。

18.5 課題

18.5.1 問題 1：一要因の効果の算出

とある 3 つの学校で行われた共通試験の結果は，表 18.7 のようになりました (児童は各校に 4 名しかいません!)。全体平均，群平均から学校ごとの差分 (効果の大きさ) を計算し，個々人の誤差の大きさも算出しましょう。

表 18.7 一要因 3 水準 Between 計画のデータを分解する

School	ID	Score	群平均	効果	誤差
A	1	58			
A	2	58			
A	3	64			
A	4	56			
B	1	53			
B	2	53			
B	3	54			
B	4	53			
C	1	39			
C	2	38			
C	3	35			
C	4	38			

18.5.2 問題 2：効果の大きさの算出

ある研究者が，勉強時間（長い・短い）と睡眠時間（十分・不足）がテストの点数に与える影響を調べるため，2×2 の群間計画で実験を行いました。各条件に 4 名ずつ配置し，100 点満点のテストを実施したとこ

ろ，各群の平均点は表 18.8 のようになりました。

表 18.8　勉強時間と睡眠時間によるテスト成績

	勉強時間：長い	勉強時間：短い
睡眠：十分	80 点	60 点
睡眠：不足	65 点	55 点

この時，次の値を算出しなさい。

1. 全体平均（Grand Mean）
2. 勉強時間の主効果の大きさ（$|b_1|$）
3. 睡眠時間の主効果の大きさ（$|b_2|$）
4. 交互作用の効果の大きさ（$|b_3|$）

ただし，効果の大きさは「群平均 - 全体平均」で表現できます。また，勉強時間が長い条件を $+1$，短い条件を -1，睡眠が十分な条件を $+1$，不足の条件を -1 としてコーディングします。

18.5.3　問題 3：平方和の計算

表 18.9 は，ある二要因実験（各セル 3 名）の結果です。

表 18.9　実験データ

要因 A	要因 B	データ	平均
a_1	b_1	12, 14, 13	13.0
a_1	b_2	8, 10, 9	9.0
a_2	b_1	10, 12, 11	11.0
a_2	b_2	14, 16, 15	15.0

次の値を算出しなさい。

1. 全体平均
2. 要因 A の主効果（b_1）
3. 要因 B の主効果（b_2）
4. 交互作用（b_3）
5. 各効果の平方和（SS）

ただし，要因 A は a_1 を $+1$，a_2 を -1 とし，要因 B は b_1 を $+1$，b_2 を -1 としてコーディングします。

第 19 章

F 検定/分散分析の基礎

ここまでは要因計画に基づき，全体の平方和を効果と誤差に分解する方法についてみてきました。今回はこれに帰無仮説検定の考え方を加えます。つまり，効果の大きさが誤差に比べてどれほど大きいかを評価し，その大きさが偶然にしては珍しいものであるかどうかを「判断する」ことについて考えていきたいと思います。

この検定方法は **F 検定 (F test)** と呼ばれます。検定統計量が F 分布と呼ばれる分布に従うからです。別名で**分散分析 (analysis of variance; ANOVA)** とも呼ばれます。注意して欲しいのは，分散を使った分析なので分散分析という名前がついていますが，目的はあくまでも群間の**平均値**に差があるかどうかを判断するために使うものであるということです。

ここでは，まず前期でやった線形モデルのことをよく思い出していただく必要があります。その上で，効果や誤差の「大きさ」として計算された平方和の比が従う分布を利用して，検定と接合することになります。検定は帰無仮説と対立仮説の勝負による判定にすぎないことに注意しつつ，また何が帰無仮説として置かれていたのかに注意して読み進めてください。

19.1 検定統計量の算出

ここまで行ってきた平方和の分解について，改めて確認しておきましょう。

まず要因による操作がなければ，すべてのデータは全体平均に一致すると考えたのでした。そこで全体平均から群平均の差分が効果，各データ点から群平均の差分が誤差と考えました。各データ点から全体平均の差分の二乗和が全体の平方和 (=SS_T) であり，これを効果の平方和 (=SS_A) と誤差の平方和 (=SS_E) に分解したのでした。

$$SS_T = SS_A + SS_E \tag{19.1}$$

要因の数が増えても基本的には同じですが，要因が 2 つ以上ある場合は「水準の組み合わせによる特別な効果」，すなわち交互作用も考慮する必要があるのでした。これを踏まえて，2 要因の場合は次のように表されるのでした。

$$SS_T = SS_A + SS_B + SS_{AB} + SS_E \tag{19.2}$$

ここでは交互作用を SS_{AB} と表しています。平方和の分解は要因の数に応じて複雑になりますが，基本的な考え方は同じです。

さて，この誤差に対して効果が十分大きいか，ということを考えます。効果が大きいとは，群平均が全体平均から大きく離れていることを意味します。つまり，SS_A が大きいことを意味します。しかし，SS_A が大きい

か小さいかは，そのままではわかりません。なぜなら，SS_A はデータの数に依存するからです。データ数が多ければ，それだけ SS_A も大きくなります。同様に，SS_E もデータ数に依存します。ここで知りたいのは，平方和の絶対的な大きさの大小ではなく，「群間のばらつきが，群内のばらつきに比べてどれほど大きいか」という相対的な大きさであり，SS_A や SS_E の大きさを生んだ群の水準 1 つあたりの影響力を考える必要があります。

分散は平方和を足した数で割ったものでした[*1]。ここでの SS_A, SS_E はまだ平方和 (Sum of Squares) の段階で，足した数で割ったものになっていません。また，推測統計学ですから標本分散ではなく不偏分散で考えますので，$n-1$，すなわち自由度で割ることになります。

平方和 (Sum of Squares) を自由度 (degrees of freedom) で割ったものを**平均平方 (mean squares)** と呼びます。この平均平方を使って，効果の大きさが誤差に比べてどれほど大きいかを評価します。これが F 検定です。

F 検定で用いられる検定統計量 F は，**F 分布 (F distribution)** に従います。F 分布は簡単にいうと，分散の比の分布です。誤差に比べて効果がどれだけ大きいかが知りたいのですから，丁寧にいうならば「誤差 1 水準の平均平方に対する効果 1 水準の平均平方の比」を考えることになります。F 分布は，分子 (効果) と分母 (誤差) の 2 つの自由度を持つ分布であることに注意してください。

では具体的な数字とともに，また帰無仮説検定の流儀に倣って，順に計算ステップを見ていきましょう。

19.2 分散分析の手順

数値例として，第 18 講，セクション 18.1.1(Pp.235) で用いたデータを使います。

さて，このデータから (水やりの) 効果が誤差に比べて十分大きいかどうかを「判断」しましょう。

帰無仮説検定の手順をもう一度確認しておきます。不安な人は第 13 講，セクション 13.1(Pp.184) を読み返してください。

1. 仮説を設定する。
2. 統計的仮説検定に用いられる検定統計量を選択する。
3. 仮説選定判断の基準になる確率を設定する。
4. 実際のデータから検定統計量の実現値を計算する。
5. 最初に定めた仮説を支持するかどうかを判断する。

■仮説の設定 帰無仮説と対立仮説が必要です。対立仮説は「効果があった」ということですから，帰無仮説は「効果がなかった」という仮説であり，この 2 つの仮説を戦わせることになります。

今回，効果がなかったというのはどのように考えれば良いでしょうか。効果がなかったというのは，群平均に差がなかった，すなわちすべてが全体平均に等しかったということです。仮説は母数に対して立てるものですから，帰無仮説は母平均に差がない，ということになります。数学的に書くなら，三つの群の平均が次のようになっていることを意味します。

$$H_0 : \mu_1 = \mu_2 = \mu_3 \tag{19.3}$$

そして対立仮説はこれの否定，ということになります。

ところで，勘の良い人はここで「おや，まてよ？」と思うかもしれません。そうです，この帰無仮説，いろんな否定の仕方が考えられるのです。つまり，

[*1] 思い出しましょう。$\hat{\sigma}^2 = \dfrac{1}{n-1}\sum(x_i - \bar{x})^2$ ですね。

- $\mu_1 \neq \mu_2$ だけど，μ_3 については $\mu_1 = \mu_3$ なのか $\mu_2 = \mu_3$ なのかわからない。
- $\mu_1 \neq \mu_3$ だけど，μ_2 については $\mu_1 = \mu_2$ なのか $\mu_3 = \mu_2$ なのかわからない。
- $\mu_2 \neq \mu_3$ だけど，μ_1 については $\mu_2 = \mu_1$ なのか $\mu_3 = \mu_1$ なのかわからない。
- $\mu_1 \neq \mu_2 \neq \mu_3$，つまりとにかく全部違う

の 4 パターン考えられます。実はこれ，すべて対立仮説の一員なのです。帰無仮説は一人でこれらに立ち向かうことになります。

ちなみにこれも，基本的には線形モデルの延長で考えることができます。線形モデルで考えれば，図 19.1 にあるように，傾きのない線形モデル，つまり $X_{ij} = \bar{X}_{gm} + \varepsilon_{ij}$ の横一線ということになります。

図 19.1　表 18.3 を可視化したもの。全体平均からの矢印は群効果の大きさ

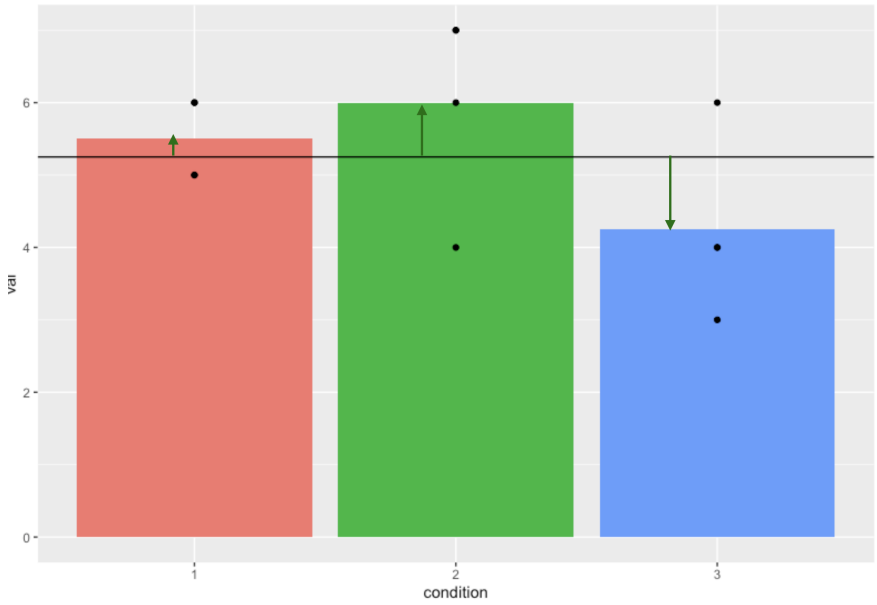

対立仮説は帰無仮説の否定ですから，横一線の直線ではない (傾きがある)，あるいは母平均のどこかに差がある，というものになります。横一線ではない，という話ではありますが，右上がりの直線なのか，右下がりの直線なのか，という話は一概にできないことに注意してください。というのも，横軸の水準 1,2,3 は名義尺度水準に過ぎないからです。水準 1,2,3 が「統制群」「操作 A をした群」「操作 B をした群」であったとして，統制群が 1 である理由はとくになく，2 でも 3 でも構いません。**名義尺度水準**は，対象と数字が一対一対応していることがその要件であって，数字の並びに意味がないからです。図 19.1 を見ると，水準 1 から 2 に向けては右上がり，水準 2 から 3 に向けては右下がりになって，一本の直線では表現できないですね。ただこれの並びを変えて，水準 3,1,2 の順番にすると右上がりの直線をあてがうことが可能です (図 19.2)。もちろん水準 2,1,3 の順にして右下がりの直線を当て嵌めても構いません。いずれもデータの持つ情報は同じです。ですから，対立仮説としては「横一線ではない」「母平均が同じではない」とするに留めましょう。

- 帰無仮説 H_0: $\mu_1 = \mu_2 = \mu_3 \rightarrow$ 線形モデルにおけるすべての係数が $0(\beta_1 = \beta_2 = 0)$
- 対立仮説 H_1: H_0 ではない。$\rightarrow$ 線形モデルにおける係数のうち少なくとも 1 つが 0 ではない

このように，水準が増えても同じ線形モデルとして表現できることがわかりました。要因の数が増えても同じです。説明変数が 2 つになりますので，散布図が 3 次元になり，直線が平面に変わるなどの違いはあります

図 19.2　横軸は並べ替えても構わない

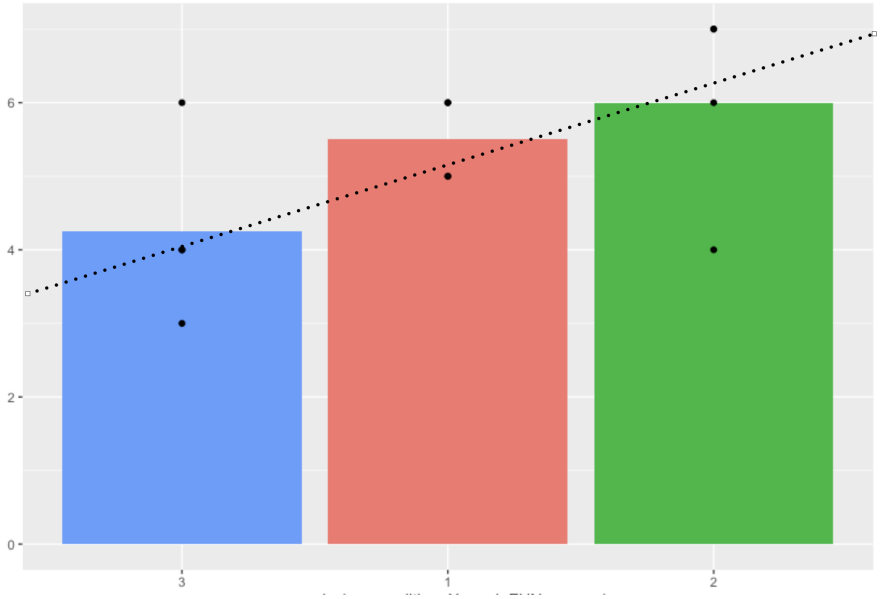

が，本質的に「母平均がすべて等しい＝平面が水平」という仮説に対する検定を行っていることになります。

■検定統計量を選択　平均値の比較ですが，分散の比を検定統計量にするので F 分布というものを使うのでした。検定統計量は F 値になります。

■判断の基準になる確率を設定　有意水準 α，今回も 5% で勝負を決めるとしましょう。

■検定統計量の実現値を計算　では実際に F 値を計算してみましょう。効果の平方和 SS_A は 6.50，誤差の平方和 SS_E は 11.75 でした。これを自由度で割って平均平方を求めます。

群の効果は，3 つの水準でこの平方和を作り出したわけですから，一単位は $3-1=2$ で考えて，MS は

$$6.50/(3-1) = 3.250 \tag{19.4}$$

となります。また，誤差の一単位あたりの大きさは，各群の平均と各値の差分で作られており，各群に 4 人配置されていますから，各群の誤差の自由度 $(4-1)$ が 3 群あると考えて

$$11.75/\{3(4-1)\} = 11.75/9 = 1.306 \tag{19.5}$$

です。

F 分布に従う検定統計量は，この MS の比率です。ここでは「誤差に比べてどれぐらい効果が大きかったか」がみたいのですから，効果の MS を誤差の MS で割って F 値を算出します。具体的には，

$$F = 3.250/1.306 = 2.489 \tag{19.6}$$

ということになります。

F 値は F 分布に従います。比の分布なので，分布の形状を決める自由度は分子と分母の 2 つが必要です。自由度は先ほどの一単位を計算した値であり，分子の自由度 $df_1 = 2$，分母の自由度 $df_2 = 9$ の F 分布からその出現確率を計算し，これが 0.1379077 と出ます[*2]。これは 5% よりも大きい値でしたので，統計的に有意とは判断できない (帰無仮説を棄却できない) ことになります。

[*2] R で F 分布を表す記号は `f` で，これに `d,p,q,r` をつけて使いますから，`1-pf(2.489,df1=2,df2=9)` として算出します。

■分散分析表 計算ステップは複雑に見えますが，実際は計算機が計算してくれます。また，結果がわかりやすくなるように，次のような**分散分析表 (ANOVA table)** にまとめて報告することが一般的です (表 19.1)。

表 19.1 ANOVA Table

	Df	SS	MS	F value	p
condition	2	6.500	3.250	2.489	0.138
Residuals	9	11.750	1.306		

この表にあるように，平方和 (SS)→ 自由度 (df) をつかって平均平方 (MS)→ 比率の F 比 →p 値の計算，という流れになっていることを確認してください。

結果をレポートなどで報告するときは，この表とともに，

> 一要因 3 水準の分散分析を行ったところ，$F(2, 9) = 2.489, p = 0.138$ で，水準間に統計的に有意な差はみられなかった。

などと表記します。

19.2.1 効果量は?

帰無仮説検定で，差があったかなかったか，という判断だけで終わらせるのではなく，どの程度の差があったのかについて報告しないといけないのでした。分散分析における効果量は，全体の分散のうち効果の分散がどれほどの量であったかという比率，つまり効果量=効果の分散/全体の分散=1 - (誤差の分散/全体の分散) で算出できます。これを ε^2(イプシロンの二乗) といいます[*3]。

とはいえ，母集団における効果の分散，母集団における誤差の分散は分かりませんので，標本の不偏分散をつかって標本効果量として推定するしかありません。今回，全体の標本 (不偏) 分散は，表 18.3 の「(T) の二乗」列の一番下にある 18.25，これを $12 - 1 = 11$ で割った $18.25/11 = 1.659091$ ですから，

$$\varepsilon^2 = 1 - \frac{1.306}{1.659} = 0.2127788 \tag{19.7}$$

となりました。合わせて報告した方が良いでしょう。

19.3 R で一要因群間計画の分析

さて，では理屈はここまでにして，実際に手を動かして計算してみましょう。といっても群ごとに平均を出したり，平方和を計算したり，そこから平均平方を作って比を計算して･･･というのはどう考えても大変。R にやらせましょう。

流石にそろそろ慣れてきたとは思いますが，一応念のため，作業を始める前の最初のステップについて書いておきます。

1. **RStudio の起動:**RStudio を起動してください。パッケージのインストールをするときなど，管理者権限が必要になるケースがあります。

[*3] 他にも同じような意味を持つ η^2 という指標もよく使われます。

2. **プロジェクトを開く:** プロジェクトは以前作成した物で良いと思います。同じフォルダの中で，スクリプトファイルだけ変えれば良いでしょう。メニューからプロジェクトを開き (File→Open Project)，RStudio の右上などで，プロジェクトが開いていることを確認しましょう。
3. **R スクリプトを開く:** 今日のコードを書くための R スクリプトファイルを準備します。`File > NewFile > R Script` と進み，何も書いてない R スクリプトの画面を表示させてください。真っ白いファイルが開いたら問題ありません。

準備ができたらスクリプトを書いていきましょう。と，その前に，R で要因計画を扱うときのポイントである「変数の型」について説明しておきます。

19.3.1 変数の型

繰り返しお話ししていますように，前期でやった回帰分析と今回扱う要因計画とは，線形モデルという同じ形をしています。違うところがあるとすれば，回帰分析の説明変数が連続的であるのに対し，要因計画の説明変数は離散的 (カテゴリカル) であるということです。ですから，R で分析する時も関数の形は同じであっても，変数の種類が違うということを明らかにしておかなければなりません。

R にはいろいろな数字のタイプがあります。オブジェクトにいろいろな変数を格納できますが，その格納された変数のタイプには，次のような種類があります。

numeric　数字。加減乗除などの対象になるもの。尺度水準で言えば**間隔尺度水準**か**比率尺度水準**にあたるもの。

factor　ファクター型。訳して要因型ということもある。要因計画の「要因」です。この変数は数字とそれにつけるラベルとの組み合わせからなります。尺度水準で言えば**名義尺度水準**です。

ordered factor　順序付きファクター型。ファクター型の特殊型で，中についている数字に順序情報がある物。尺度水準で言えば当然**順序尺度水準**に該当します。あまり使われることはないけど。

chr　文字型 (Character)。一見ファクター型と見分けがつかないこともあるが，こちらは内部に対応する数字があるわけでもなく，ただの文字。シングルクォーテーション，ダブルクォーテーションで括ったものが変数に渡されるとこの型になる。

logical　論理型。*TRUE* か *FALSE* の 2 つの値しか持たない。*TRUE* は 1 に，*FALSE* は 0 に対応している。名義尺度水準の特殊な型で，オプションのスイッチオン・オフなどをこれで表したりする。大文字で書く `TRUE` や `FALSE` は，欠測値を表す `NA` などと同じく予約語[*4]なので，オブジェクト名にはできない。なお，`TRUE` や `FALSE` は，`T` や `F` と省略することもできるが，こちらは予約語ではないので，ユーザが変数名として上書きできてしまう。上書きすると意図しない結果になることがあるので，`TRUE` や `FALSE` は省略せずに書く方が良い。

これらの型を確認するには，オブジェクトの仕組みがどうなっているかを調べる必要があります。調べるのは `str` 関数で，これを使うとオブジェクトの中身がわかるようになっています。

次のコード，`code:19.1` を入力してみてください。

code : 19.1　オブジェクトに代入

```
1  obj <- data.frame(
2      list(name=c("kosugi","yamada","ueda"),
```

[*4] R があらかじめ意味を決めている言葉で，オブジェクト名には使えない。他にも何もないことを表す `NULL` や，無限大を表す `Inf` などがある。

```
3          gender = c(1,2,1),
4          height = c(167,170,180),
5          weight = c(60,70,80))
6  )
7  str(obj)
```

■コード解説

1-6 行目　データフレームを作って obj オブジェクトに代入している。

7 行目　obj オブジェクトの構造を確認

さて，最後の 7 行目を実行すると，コンソールに次のように出力されていると思います (**R の出力** 19.1)。

R の出力 19.1: データフレームの中身

```
> str(obj)
'data.frame': 3 obs. of  4 variables:
 $ name  : chr  "kosugi" "yamada" "ueda"
 $ gender: num  1 2 1
 $ height: num  167 170 180
 $ weight: num  60 70 80
```

ここにあるように，obj オブジェクトの name 変数は chr 型で，他の 3 つの変数は数値型 (numeric) である，というのが示されています。ここで性別 gender を因子型にしてみましょう (code:19.2)。

code : 19.2　因子型にする

```
1  obj$gender <- factor(obj$gender,labels=c('male','female'))
2  str(obj)
```

これの出力は **R の出力** 19.2 のようになります。

R の出力 19.2: 変数を因子型にした

```
> str(obj)
'data.frame': 3 obs. of  4 variables:
$ name  : chr  "kosugi" "yamada" "ueda"
$ gender: Factor w/ 2 levels "male","female": 1 2 1
$ height: num  167 170 180
$ weight: num  60 70 80
```

ここに示されているように，性別がファクター型になり，それは 2 つの水準を持っている。それぞれに「male」「female」というラベルがついている，ということがわかります。

この factor 型にしておくというのは，R が名義尺度水準の変数なんだなと理解したことになりますので，これで回帰分析をすると OK ということになります。逆に factor 型にしておかないと，量的変数として普通の回帰分析をしてしまうので，正しくない結果になります[*5]。

[*5] 具体的には，3 水準に 1,2,3 という量的な数字を割り振って分析するということは，1 < 2 < 3 という順序性と 2-1=3-2 という等間隔性を持たせたことになります。要因計画の可視化のときに，横軸は入れ替え可能 (順序性がない) だったことを思い出してください。

19.3.2 一要因 Between 計画の計算

ではまず一要因 Between 計画の話から。何度も例として使っている，表 18.3 のデータを使います。code:19.3 のようにデータフレームを組み上げます。

code : 19.3 データの準備

```
1 # データフレームを組み上げる
2 Example1 <- data.frame(id = 1:12,
3                        condition = rep(1:3,each=4),
4                        value = c(6,6,5,5,7,4,7,6,4,3,4,6))
5 # 要因型にする
6 Example1$condition <- factor(Example1$condition,
7                              labels = c("control","exp1","exp2"))
```

■コード解説

1-4 行目 データフレームを作っています。ID は被験者番号です。12 人それぞれに異なる数字を振っています。条件 condition は 3 種類，各 4 人分 (rep(1:3,each=4))，最後の従属変数 (value) は手入力するしかありません。

5-7 行目 条件変数を要因型にしています。ラベルは統制群 (control) と実験群 1(exp1)，実験群 2(exp2) としています。

線形モデルとして分析

まずこれを線形モデルとして分析してみます。線形モデル (回帰分析) は，前期でやったように lm 関数を使います (code:19.4)。

code : 19.4 lm 関数で分析

```
1 result.lm1 <- lm(value~condition,data=Example1)
2 summary(result.lm1)
```

1 行目が lm 関数を使っていて，結果を result.lm1 オブジェクトに入れているところです。従属変数と独立変数をチルダ~で繋げているところ，思い出してください。2 行目はこの結果の出力になります。結果は **R の出力 19.3** のように示されているはずです。

R の出力 19.3: lm 関数の出力

```
Call:
lm(formula = value ~ condition, data = Example1)

Residuals:
   Min     1Q Median     3Q    Max
-2.000 -0.500 -0.125  0.625  1.750

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)     5.5000     0.5713   9.627 4.91e-06 ***
conditionexp1   0.5000     0.8079   0.619    0.551
conditionexp2  -1.2500     0.8079  -1.547    0.156
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.143 on 9 degrees of freedom
Multiple R-squared:  0.3562, Adjusted R-squared:  0.2131
F-statistic: 2.489 on 2 and 9 DF,  p-value: 0.1379
```

これを見ると，切片（Intercept）の推定値が 5.5，次に 2 つの説明変数の係数が書いてあります。文字が連なっているのでわかりにくいかもしれませんが，それぞれ condition と exp1 の関係，condition と exp2 の関係を表しています。図 19.3 を見ると結果の意味は分かり易いと思います。

図 19.3　線形モデルとして分析した結果の意味するもの

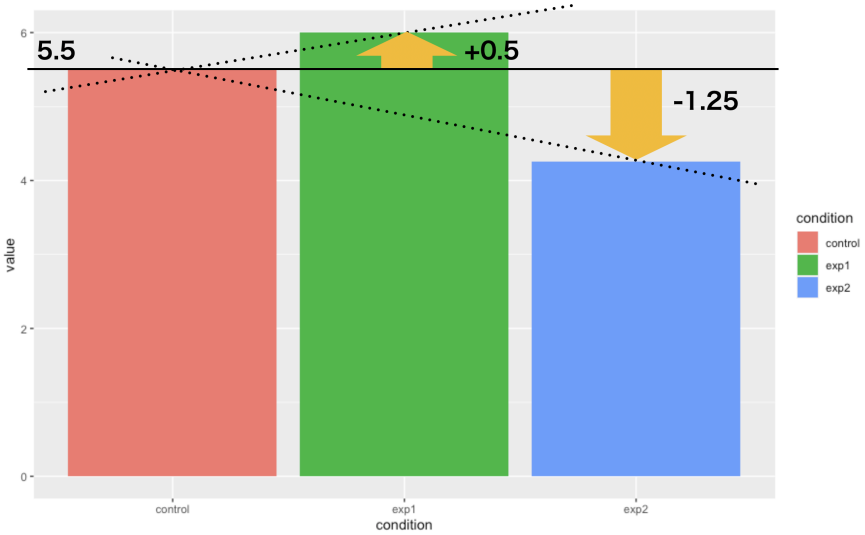

線形モデルの式は，次のようになります。

$$X_{ij} = \beta_0 + \beta_j + \varepsilon_{ij} \tag{19.8}$$

ここで β_0 は全体平均でした。全体平均を基本として，各水準に対する効果 β_j がどうなったか，というモデル化でしたが，ここでは

$$X_{ij} = \bar{X}_1 + \beta_j + \varepsilon_{ij} \tag{19.9}$$

という形になっています (図 19.3)。本質的に違うものではありません。統制群に比べて実験群 1 の平均値は $+0.5$, 実験群 2 は -1.25 の平均値の違いがあるのだな, と思っていただければ結構です。その後ろに Std.Error や t 値が出ていますが, これらは推定された回帰係数の標準誤差および, 係数が 0 であるという帰無仮説を棄却できるかどうかの検定結果が出ています[*6]。

線形モデルですから, モデルの適合度 (`Multiple R-squared, Adjusted R-squared`) なども出ていますが, それよりも最後の一行, この線形モデル全体の検定結果が出ています。これは要因計画のもう 1 つの切り口, 分散分析による結果と同じものです。では分散分析の視点からこの分析結果を見てみましょう。

帰無仮説検定として分析

要因計画の帰無仮説検定版, つまり分散分析の結果ですが, 線形モデルと同じなので今回得られた出力をすこし変えるだけで対応できます。最も単純には, 先ほどの線形モデルの結果を `anova` 関数に入れると, 分散分析表が次のように示されます (code:19.5,R の出力 19.4)。

code : 19.5 分散分析としてみる

```
1  anova(result.lm1)
```

R の出力 19.4: 分散分析表の出力

```
Analysis of Variance Table

Response: value
          Df Sum Sq Mean Sq F value Pr(>F)
condition  2   6.50  3.2500  2.4894 0.1379
Residuals  9  11.75  1.3056
```

ここから, $F(2,9) = 2.4894, p = 0.1379$ で統計的に有意な差はみられなかった, と判断できます。これらの数字, どこをどう読み取ったのか確認してください。

ちなみに, 同じことですが分散分析関数 `aov` というのもあります。こちらを使うと, 直接分散分析表が出力されます (code:19.6)。

code : 19.6 aov 関数で実行する

```
1  result.aov <- aov(value~condition, data = Example1)
2  summary(result.aov)
```

R の出力 19.5: 分散分析表の出力その 2

```
            Df Sum Sq Mean Sq F value Pr(>F)
condition    2   6.50   3.250   2.489  0.138
Residuals    9  11.75   1.306
```

どちらの方法を使ってもらっても構いません。

[*6] 各群の母平均の推定値でもありますが, 各群について一変数の t 検定をしているのではなく, これら線形モデル全体として (他の説明変数に条件づけられた分布の中で) 標準誤差を計算します。詳しくは南風原 (2002) の p.118 を参照してください。

19.4 R で下位検定

さて，今回は統計的に有意であるとは言えませんでしたが，もし統計的に有意であるという結果であれば，どの群とどの群が違うのか，ということを調べる必要があります。これを**下位検定 (post-hoc analysis)** や**事後比較 (post-hoc comparison)** といいます。手法はいろいろな種類がありますが，R では TukeyHSD 関数を使うのが簡単です (code:19.7)。

code : 19.7 事後比較

```
1  TukeyHSD(result.aov)
```

R の出力 19.6: 事後比較の出力

```
> TukeyHSD(result.aov)
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = value ~ condition, data = Example1)

$condition
               diff       lwr       upr     p adj
exp1-control  0.50 -1.755792 2.7557916 0.8137078
exp2-control -1.25 -3.505792 1.0057916 0.3158385
exp2-exp1    -1.75 -4.005792 0.5057916 0.1311336
```

もちろん最初に統計的に有意ではなかったのですから，ここでも群間の比較で統計的に有意な差は出ていません。しかし，もし有意であった場合，この表の p adj 列を見て，0.05 より小さいものがあれば，その 2 つの群の平均値は統計的に有意に異なる，と判断できます。

また，効果量も計算しておきましょう。効果量は effectsize パッケージを使うと簡単に計算できます (code:19.8)。

code : 19.8 効果量の算出

```
1  library(effectsize)
2  epsilon_squared(result.aov)
```

効果量については他にも様々な指標 (Cohen's f,η^2, ω^2 など[*7]) がありますが，ここでは ε^2 を使っています。出力は R **の出力** 19.7 のようになります。

[*7] 簡単に説明すると，Cohen's f は 2 群の効果量の多群版です。η^2, ω^2 は全体の分散のうち何 % が効果で説明されるかの指標。η^2 は標本における寄与率であり，母集団の効果を過大評価してしまう可能性があるといわれています。ω^2 は η^2 のその偏りを補正したものです。

R の出力 19.7: 効果量の出力

```
For one-way between subjects designs, partial epsilon squared is
  equivalent to epsilon squared. Returning epsilon squared.
# Effect Size for ANOVA

Parameter | Epsilon2 |       95% CI
-----------------------------------
condition |     0.21 | [0.00, 1.00]
```

このようにして，複雑な計算も R のコードを使うと比較的簡単に実行できるのでした。

19.5 課題

19.5.1 問題 1：平方和の計算と分散分析

ある研究者が，3 つの異なる学習方法 (方法 A，方法 B，方法 C) がテスト成績に与える影響を調べるため，各方法に 4 名ずつ，計 12 名の学生を無作為に割り当てました。1 週間後のテスト結果 (100 点満点) は表 19.2 のようになりました。

表 19.2 学習方法別のテスト成績

学生 ID	学習方法	成績
1	A	75
2	A	80
3	A	70
4	A	85
5	B	82
6	B	88
7	B	85
8	B	89
9	C	68
10	C	72
11	C	70
12	C	74

このデータを用いて，次の R コードを書いて分散分析を実行したものを提出してください。

1. データフレームを作成し，学習方法を因子型に変換するコードを書きましょう。テスト成績は，伴走サイトの「各章のコード」にある `19_kadai_data.R` をプロジェクトフォルダに置き，`source("19_kadai_data.R")` と実行すると，学生 ID の順に並んだベクトル `score` として読み込まれます。学習方法の列は自分で作ってください。
2. `aov` 関数を使って分散分析を実行し，結果を表示するコードを書きましょう。
3. 結果を読み，統計的に有意であると判断して良いかどうか回答してください。回答はスクリプトの中に，コメントアウトして書いてください。
4. 有意差があると判断した場合，Tukey の HSD 検定を実行し，どの群間に有意差があるかを調べま

5540 しよう。

5541 5. `epsilon_squared()` 関数を使って, 効果量 ε^2 を計算するコードを書きましょう。

第 20 章

R による分散分析

前回まで，要因計画＋統計的判断＝分散分析として，その理論的背景と計算方法について学んできました。また R を使った実習では，`lm()` 関数と `aov()` 関数を使って，分散分析を実行する方法についても学びました。下位検定を行う際も，`TukeyHSD()` 関数や `effectsize` パッケージを使って，効果量を計算する方法についても学びました。今回の講では，R で分散分析を行う際に便利な `anovakun` 関数を導入し，その使い方について学びます。`anovakun` は，分散分析の主な分析から事後検定までを一括して実行できる便利な関数です。これにより，分散分析の手順が簡略化され，より効率的に分析を行うことができます。

`anovakun` 関数を使うことで，一要因群間計画だけでなく，二要因群間計画の分散分析も簡単に実行できます。それどころか，三要因以上の複雑な要因計画にも対応しています (実に 26 要因計画まで分析可能です。もちろんそんな複雑な計画は立てない方がいいです。)。またこの関数の便利なところは，分散分析表や効果量の出力だけでなく，下位検定まで自動的に行ってくれるところです。

20.1 分散分析用の関数の導入

今回導入するのは，`anovakun` という関数です[*1]。これはネットで一般に公開されています[*2]。CRAN からダウンロードするパッケージのようにはなっていませんので，これを使うにはローカルに `anovakun` 関数を書いたファイル (執筆時点，2025 年 10 月現在で `anovakun_489.txt`) をダウンロードし読み込むか，R から直接インターネット経由でダウンロードして使うか，の 2 通りの方法のいずれかを使う必要があります。どちらにしても，R の `source` 関数をつかうもので，ダウンロードしたファイルを使う場合はプロジェクトフォルダに当該ファイルをダウンロードした上で，読み込むコードを実行します (code:20.1)。

code : 20.1 ソースを読み込む

```
1  source("anovakun_489.txt")
```

ネットから直接ダウンロードする場合は，インターネットにつながっている状態で code:20.2 を実行します[*3]。

[*1] かつて，下位検定まで自動的にやってくれる統計パッケージはありませんでした。広島大学ご出身の桐木建始先生が，4 要因まで分析可能なプログラムを書き，そのコードが広島大学大学院での秘伝ソースとして共有されていました。その後，非常に便利なそのプログラムが Web でも実行できる ANOVA4 on the web としてネットで公開され，当時 (2000 年頃) 大学院生だった筆者を始め，多くの研究者はそれを使って分散分析をしていました。その後，井関龍太先生が R で ANOVA4 のような，下位検定まで一気に計算してくれるプログラムを，ということで anovakun を開発され，現在まで公開されているという歴史があります。有料化されたサービスにすることもできたでしょうが，計算手続きがオープンソースで，フリーソフトウェアとして無償で公開されることはとても有意義な文化だと思いませんか。

[*2] https://riseki.cloudfree.jp/?ANOVA君

[*3] リンク先を転記するのは大変です。Google で「ANOVA 君」を検索し，井関先生のサイトに飛んでから，「下のアイコンをクリック

code : 20.2 ANOVA 君のソースをネットからとってくる

```
1  source("https://bit.ly/3WL8VYR")
```

これらのコードが実行されると，R の環境にたくさんの関数が入っているはずです (図 20.1)。これらが入っていれば OK です。それでは実際の使い方を見ていきましょう。

図 20.1 anovakun を読み込んだあとの環境タブ

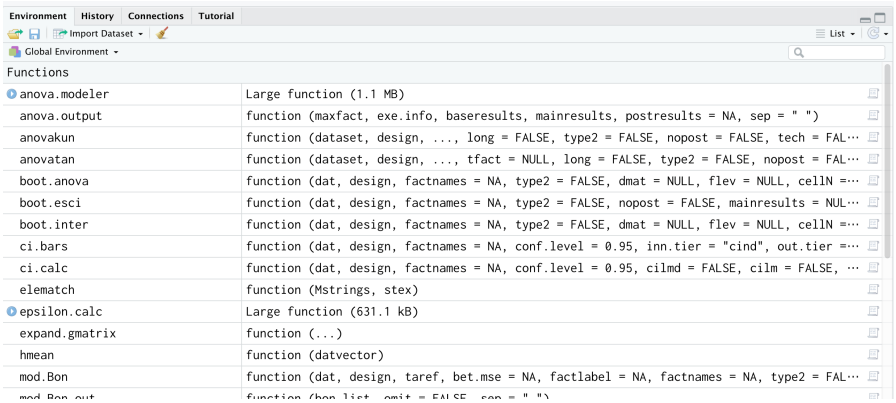

20.2 データの作りかた

20.2.1 整然データ

一般に心理学で作るデータセット，データファイルは，1 セルに 1 情報，重複や集計，オブジェクトや文字列のないデータセットであることが基本です。また図 C.2 にあるように，一行ごとに 1 人 (1 ケース，1 オブザベーション，1 レコードとも言います) のデータが入っており，各列が変数を表すようにすることが一般的です。変数が増えると横に伸びていきますので，こうしたデータの入力形式を**ワイド型**のデータということがあります。

ここで表 20.1 を見てください。このデータを見ると我々は，「大阪の午後は曇りなんだな」ということがすぐにわかります。

表 20.1 ワイド型データ

	午前	午後	夕方	深夜
東京	晴	晴	雨	雨
大阪	晴	曇	晴	晴
福岡	晴	曇	曇	雨

しかしその判断は，「大阪」行の「午後」列を見て，すなわち行と列に素早く目を走らせてそれのクロスするところで「曇」という情報を得ています。夕方や深夜の情報が知りたければ，列を変えますね。列ごとに違う変数になっているから当然です。行と列の名前を参照するというのは，目線を左右と上下に動かす 2 アクション必要なことです。

してファイルを保存してください。」とある ANOVA 君ソースファイルのリンク先を右クリック，リンク先をコピーすれば確実です。ちなみにこのアドレスはリンクの長さを縮める Link Shortener サービスを使っています。

しかしここで参照している「列名 (変数名)」も変数，データの一部ではないでしょうか。この観点に立ち，1行見るだけですべての情報がわかるようにしてみましょう。表 20.2 には表 20.1 と同じ情報しか含まれていませんが，一行見るだけですべての情報がわかるようになっています。

表 20.2 ロング型データ

地域	時間帯	天候
東京	午前	晴
東京	午後	晴
東京	夕方	雨
東京	深夜	雨
大阪	午前	晴
大阪	午後	曇
大阪	夕方	晴
大阪	深夜	晴
福岡	午前	晴
福岡	午後	曇
福岡	夕方	曇
福岡	深夜	雨

表 20.2 のような形のデータのことを，**ロング型**のデータと言います。このような形にしておくと，情報の欠落 (欠測値) があった時の対応が楽に行えたり，レコードの選択がやりやすくなるなどの利点があります。

このような分析しやすいデータの形について，Wickham (2014) が提唱したのが**整然データ (tidy data)** という考え方です。整然データとは，次の 4 つの特徴を持ったデータ形式のことです。

- 個々の変数 (variable) が 1 つの列 (column) をなす。
- 個々の観測 (observation) が 1 つの行 (row) をなす。
- 個々の観測の構成単位の類型 (type of observational unit) が 1 つの表 (table) をなす。
- 個々の値 (value) が 1 つのセル (cell) をなす。

さきほどの天気の例では，時間，場所，天候という 3 つの情報が表に含まれていますが，これが一行の中にまとまっているのが整然データです。人間にとってはワイド型のデータの方がわかりやすいこともありますが，分析を進めていく上ではロング型・整然データの方が便利なことも多くあります。たとえばこの後で行う作図においては，整然データの方が便利な形です。X 軸に割り当てる列，Y 軸に割り当てる列，色や形を指定する列，など列ごとに持つ特徴を図の設定に割り当てることができるからです。

実際にデータを入力するときは，人間にとってわかりやすいワイド型が便利ですが，統計的な処理をしたり，グラフを描画するときにはロング型の整然データの方が便利です。そこで，ワイド型のデータをロング型の整然データに変換する方法を学びましょう。ありがたいことに，`tidyverse` というパッケージを用いると，こうしたデータの加工が非常に楽に行える関数をいろいろ使うことができます。

20.2.2 分散分析のデータ形式

では実際に分散分析を行う際は，どのようなデータ形式にすればよいのでしょうか。`anovakun` はロング型にもワイド型にも対応していますが，まずはワイド型で入力する方がわかりやすいでしょう。すなわち，各列

が変数を表し，各行が 1 人 (1 ケース) のデータを表す形です。

群内要因のデータを列 (横) に並べ，群間要因のデータを行 (縦) に並べるのが基本です。次の例は，2 要因の混合計画 (間 (3)× 内 (2)) のデータ例です。

code : 20.3 データの準備

```
1  rm(list=ls())
2  library(tidyverse)
3  MixedDesign <- data.frame(id = 1:12,
4                            condition = rep(1:3,each=4),
5                            stimuli1 = c(6,6,5,5,7,4,7,6,4,3,4,6),
6                            stimuli2 = c(8,3,2,5,9,7,1,6,4,9,2,3))
7  # 要因型にする
8  MixedDesign$condition <- factor(MixedDesign$condition,
9                                  labels = c("control","exp1","exp2"))
10 print(MixedDesign)
```

■コード解説

1 行目 作業スペースをクリアしています。

2 行目 tidyverse パッケージを読み込んでいます。

3-6 行目 データフレームを作成しています。被験者 ID，条件変数，刺激 1，刺激 2 の 4 つの変数があります。

7-9 行目 条件変数を要因型にしています。ラベルは統制群 (control) と実験群 1(exp1)，実験群 2(exp2) としています。

10 行目 データフレームを表示させています。

R の出力 20.1: ワイド型データの出力

```
   id condition stimuli1 stimuli2
1   1   control        6        8
2   2   control        6        3
3   3   control        5        2
4   4   control        5        5
5   5      exp1        7        9
6   6      exp1        4        7
7   7      exp1        7        1
8   8      exp1        6        6
9   9      exp2        4        4
10 10      exp2        3        9
11 11      exp2        4        2
12 12      exp2        6        3
```

どこに何が入っているか，どのようにデータフレームを組み上げているかを確認してください。

さてここで，tidyverse パッケージを使うとワイド型とロング型を相互に変換できることを説明しておきます。ワイド型のデータをロング型に変換するには，pivot_longer() 関数を使います (code:20.4)。

code : 20.4 ワイド型からロング型への変換

```
1  MixedDesign_long <- MixedDesign %>%
```

```
2    pivot_longer(cols = c(stimuli1,stimuli2),
3                 names_to = "stimuli",
4                 values_to = "value")
5  print(MixedDesign_long)
```

■コード解説

1 行目 ワイド型のデータフレームをロング型に変換し，新しいデータフレーム MixedDesign_long に代入しています。

2-4 行目 pivot_longer() 関数を使って，stimuli1 と stimuli2 の列をロング型に変換しています。変換後の変数名は stimuli，値の入る変数名は value としています。

5 行目 変換後のデータフレームを表示させています。

R の出力 20.2: ロング型データの出力

```
> print(MixedDesign_long)
# A tibble: 24 × 4
      id condition stimuli  value
   <int> <fct>     <chr>    <dbl>
 1     1 control   stimuli1     6
 2     1 control   stimuli2     8
 3     2 control   stimuli1     6
 4     2 control   stimuli2     3
 5     3 control   stimuli1     5
 6     3 control   stimuli2     2
 7     4 control   stimuli1     5
 8     4 control   stimuli2     5
 9     1 exp1      stimuli1     7
10     1 exp1      stimuli2     9
# ☒ 14 more rows
# ☒ Use `print(n = ...)` to see more rows
```

どのようにデータフレームが変わったか，よく確認してください。ロング型データにしておくと，後でグラフを描くときに便利です。

20.3 二要因 Between 計画の実際

それでは実際に anovakun を使って，二要因計画の分散分析を実行してみましょう。データは第 18 講で使ったものと同じです (再掲。表 20.3)。コーヒーの温度 (Hot vs Cold) とメーカー (銘柄 A vs 銘柄 B) の 2 要因があり，それぞれの条件で 3 人ずつ被験者がいて，コーヒーの味の評価を行った，というデータです。

これをデータフレーム型にします。温度，メーカーは名義尺度水準なので要因型にします (code:20.5)。ID 変数は特に必要ありませんので，省略しています。

code : 20.5 データフレームにする

```
1  Between2 <- data.frame(
2    temp = rep(1:2, each = 6),
3    maker = rep(rep(1:2, each = 3), 2),
4    value = c(13, 11, 12, 7, 6, 8, 9, 9, 9, 13, 11, 9)
```

表 20.3 二要因のデータ例

通し番号	群での番号	温度	メーカー	評価
1	1	Hot	銘柄 A	13
2	2	Hot	銘柄 A	11
3	3	Hot	銘柄 A	12
4	1	Hot	銘柄 B	7
5	2	Hot	銘柄 B	6
6	3	Hot	銘柄 B	8
7	1	Cold	銘柄 A	9
8	2	Cold	銘柄 A	9
9	3	Cold	銘柄 A	9
10	1	Cold	銘柄 B	13
11	2	Cold	銘柄 B	11
12	3	Cold	銘柄 B	9

```
5  )
6  Between2$temp <- factor(Between2$temp,labels = c("Hot", "Cold"))
7  Between2$maker <- factor(Between2$maker,labels = c("A", "B"))
```

ではこれを anovakun でやってみましょう。彼 (?) なら一気にすべての答えを出してくれるのです (code:20.6)。

code : 20.6 anovakun で実行

```
1  anovakun(Between2,"ABs",2,2,eps = TRUE)
```

anovakun 関数の使い方のポイントは，要因計画の型を文字列で指定するところです。詳しくは開発者である井関先生のサイト[*4]を参照してもらいたいのですが，基本的な使い方は次の通りです。

anovakun(**データ，"要因計画の型"，各要因の水準数，...**)

ここで「要因の型」を指定する部分ですが，2 要因間 × 間計画の場合は ABs とします。小文字の s は実験参加者を表していて，s の左側にあるのは群間要因，s の右側にあるのは群内要因を表しています。要因には A,B,C,...,Z でラベルをつけます。今回のように間 × 間の場合は，ABs となります。内 × 内の場合は sAB，混合計画の場合は AsB や BsA などとします。最後の eps=T は，効果量である ε^2 を表示するスイッチをオン (TRUE)，ということです。

結果は R **の出力** 20.3 のように表示されます。

[*4] https://riseki.cloudfree.jp/?ANOVA君/ANOVA君の使い方

R の出力 20.3: ABs タイプの出力

```
[ ABs-Type Design ]

This output was generated by anovakun 4.8.9 under R version 4.5.1.
It was executed on Sun Oct 19 15:45:02 2025.


<< DESCRIPTIVE STATISTICS >>

------------------------------
  A   B   n     Mean    S.D.
------------------------------
 a1  b1   3  12.0000  1.0000
 a1  b2   3   7.0000  1.0000
 a2  b1   3   9.0000  0.0000
 a2  b2   3  11.0000  2.0000
------------------------------


<< ANOVA TABLE >>

-----------------------------------------------------------------
 Source      SS  df      MS  F-ratio  p-value      epsilon^2
-----------------------------------------------------------------
      A  0.7500   1  0.7500   0.5000   0.4996 ns     -0.0133
      B  6.7500   1  6.7500   4.5000   0.0667 +       0.0933
  A x B 36.7500   1 36.7500  24.5000   0.0011 **      0.6267
  Error 12.0000   8  1.5000
-----------------------------------------------------------------
  Total 56.2500  11  5.1136
                  +p < .10, *p < .05, **p < .01, ***p < .001


<< POST ANALYSES >>

< SIMPLE EFFECTS for "A x B" INTERACTION >

-----------------------------------------------------------------
 Source      SS  df      MS  F-ratio  p-value      epsilon^2
-----------------------------------------------------------------
A at b1 13.5000   1 13.5000   9.0000   0.0171 *       0.2133
A at b2 24.0000   1 24.0000  16.0000   0.0039 **      0.4000
B at a1 37.5000   1 37.5000  25.0000   0.0011 **      0.6400
B at a2  6.0000   1  6.0000   4.0000   0.0805 +       0.0800
  Error 12.0000   8  1.5000
-----------------------------------------------------------------
                  +p < .10, *p < .05, **p < .01, ***p < .001

output is over --------------------///
```

最初に，水準ごとの平均値と標準偏差が表示され，続いて分散分析表が示されています。ご丁寧に有意かどうかわかりやすいような記号 (. や*など) がついています。最後の一行には +p < .10, *p < .05, **p < .01, ***p < .001 とありますが，これは米印が 1 つなら 5%，2 つなら 1%，3 つなら 0.1% 水準で有意である，という意味です。さらに，+ の記号であれば 10% 水準で有意であるということもわかります[*5]。これを見ると，要因 A(温度) の主効果はなく ($F(1,8) = 0.500, p = 0.4996$)[*6]，ついで要因 B の効果も 5% 水準では認められない (10% 水準で有意，その記号として + が使われています)[*7]，また交互作用は 5% 水準で有意という結果になりました。さらに効果量 ε^2 の列を見ると，交互作用は全体の 62% の分散を説明したことになりますから，これはかなり大きな効果だったようだ，ということがわかります。

続いて POST ANALYSES として事後の検定が表示されています。SIMPLE EFFECTS for "A x B" INTERACTION とあるのは，「A と B の交互作用についての単純効果」という意味で (直訳！)，各水準に限定したときに他の水準の効果があったかどうかをみています。たとえば最初の行，A at b1 とありますが，これは要因 B(銘柄) の第一水準における要因 A(温度) の効果をみていることになります。以下同様ですが，これらは分散分析の表をより細かくしてチェックしているようなものです。これを見ると，冷たい時の銘柄には差がない (B at a2) ようですが，それ以外の差は統計的に有意，と言えそうです。

これらの結果を報告する時は，次のように書くと良いでしょう。

> 温度と銘柄の効果を独立変数とした二要因分散分析 (2×2 の Between デザイン) をおこなったところ，交互作用が有意 ($F(1,8) = 24.5, p = 0.0011, \varepsilon^2 = 0.6267$) になり，事後の検定の結果，銘柄 A における温度の効果 ($F(1,8) = 9.0, p = 0.0171, \varepsilon^2 = 0.2133$)，銘柄 B における温度の効果 ($F(1,8) = 16.0, p = 0.0039, \varepsilon^2 = 0.4000$)，および温かい時の銘柄の効果 ($F(1,8) = 25.0, p = 0.0011, \varepsilon^2 = 0.6400$) が統計的に有意であった。

20.3.1 線形モデルとして分析

ここまで anovakun 関数を使って分散分析を行ってきましたが，R の基本機能である線形モデルとしても同じ分析ができます。線形モデルで表現するには，次のようにします (code:20.7)。

code : 20.7 線形モデルとして実行

```
1  result.lm <- lm(value ~ temp * maker, data = Between2)
2  summary(result.lm)
```

ここで，説明変数が * でつなげられています。これで主効果と交互作用の両方をモデルの中に入れたことになります。結果は R の出力 20.4 のように表示されるはずです。

[*5] おそらくこれが諸悪の根源で，なんとなく星の数が多い方が「良い結果」のような印象を持ちますし，分析したらとりあえず星を探す，という仕草が生まれるようになっていますよね。帰無仮説検定はあくまでもモデル比較の判定であって，判定基準が厳しいほど「良い」とか，基準をクリアできなかったから「惜しい (残念)」という評価を伴うものではないはずなのに，です。有意差がなかったら，そういう結果が得られた，というだけですし，星の数が小さくてもえらいとかすごい，ということにはならない，ということを再確認してください。「心理学者は星を探して喜んでるんだ」というようなジョークの的にならないように，適切な分析的素養を身に付けましょう。

[*6] 米印があるべきところに ns とありますが，これは not significant，つまり有意ではないという意味です。

[*7] 世の中には「有意傾向」という変な言葉があります。今回要因 B の p 値は 6% でしたが，これは 5% 水準ではアウトですよね。こういった 5% をちょっとだけ上回っちゃった，惜しい！というときに，「有意になりそうな傾向があった」略して「有意傾向があった」という表現がされることがあるのです。あるいは「傾向差があった」という言葉もまことしやかに使われていたりします。が，これらは心理学独自の間違った表現であり，決して使うべきではありません。なぜなら，5% だろうが 6% だろうが，任意に決めた判定基準であって，p 値の大小関係は現実の効果の大きさとは関係がないからです。

R の出力 20.4: 交互作用を入れたモデルの出力

```
 > summary(result.lm)

Call:
lm(formula = value ~ temp * maker, data = Between2)

Residuals:
    Min      1Q  Median      3Q     Max
-2.00  -0.25   0.00   0.25   2.00

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      12.0000     0.7071   16.97 1.48e-07 ***
tempCold         -3.0000     1.0000   -3.00  0.01707 *
makerB           -5.0000     1.0000   -5.00  0.00105 **
tempCold:makerB   7.0000     1.4142    4.95  0.00112 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.225 on 8 degrees of freedom
Multiple R-squared:  0.7867, Adjusted R-squared:  0.7067
F-statistic: 9.833 on 3 and 8 DF,  p-value: 0.004641
```

ここに示されているのは，温度 temp 変数の第一水準 (Hot) かつメーカー maker 変数の第一水準 (銘柄 A) を基準にしたときに，tempCold つまりメーカーは同じ (銘柄 A) で温度だけ違う群は平均値が -3.0，次にメーカーを B で makerB 温度は Hot の群と比べるとその平均値は -5.0，両方変えると $+7.0$ になる，ということです。それぞれ標準誤差や t 値が出ていますが，これは傾きが 0 である，という帰無仮説を棄却しているだけであって，効果の大きさについてはわかりません。

また，最後に F 統計量が出ています。自由度が $(3, 8)$ のときに $p = 0.004641$ ですが，これは線形モデル全体としてみたときに横一線の帰無仮説モデルとは違うね，というだけであって，具体的にどこがどう違うのか，というのがわかりにくくなっています。

そこでそれぞれの水準について検証できる，分散分析モデルで分析してみます。

20.3.2 帰無仮説検定として分析

要因計画の帰無仮説検定版，でやってみましょう。先ほどと同じように，R がデフォルトで持っている関数 anova に線形モデルの結果を入れてみます (code:20.8)。

code : 20.8 分散分析としてみる

```
1  anova(result.lm)
```

結果は R の出力 20.5 のようになります。

R の出力 20.5: 分散分析表の出力

```
> anova(result.lm)
Analysis of Variance Table

Response: value
           Df Sum Sq Mean Sq F value   Pr(>F)
temp        1   0.75    0.75     0.5 0.499576
maker       1   6.75    6.75     4.5 0.066688 .
temp:maker  1  36.75   36.75    24.5 0.001121 **
Residuals   8  12.00    1.50
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

20.4 分析結果の可視化

これらの結果を見やすくするために，図 20.2 に可視化してみました。

図 20.2 分散分析結果の可視化 1;棒グラフで平均値と標準誤差を表示

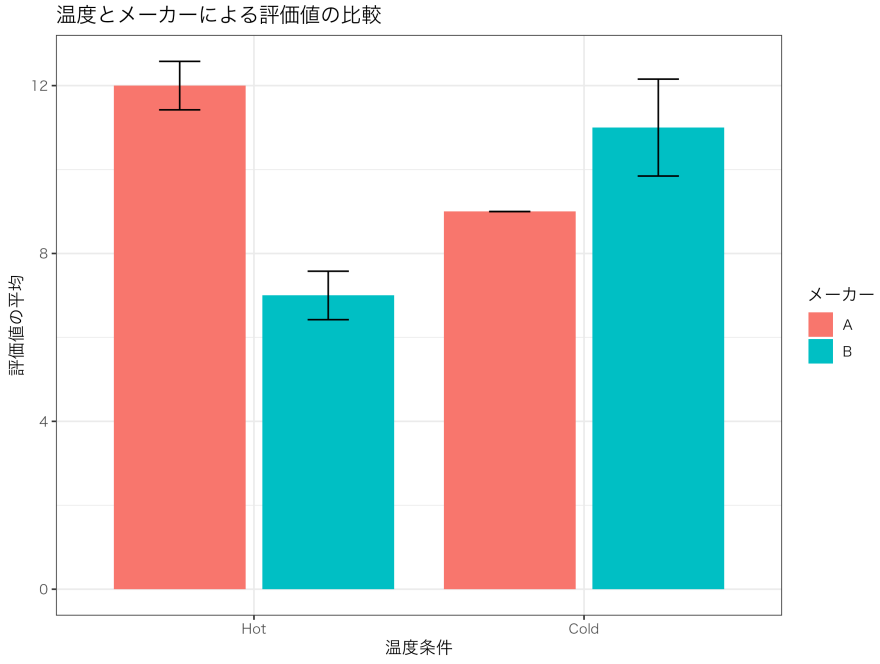

いかがでしょうか。こうすると群の平均がどのように違うのか，交互作用があるのかどうかが一目でわかります。加えて，平均値の標準誤差をエラーバーとして表示しているので，群間の差がどの程度のばらつきの中で生じているのかもわかります。

この図を書いたのは次のコードによるものです。コードの書き方は参考程度で結構ですが[*8]，どのようにして可視化できるかを確認してください (code:20.9)。

[*8] このコードは生成 AI のひとつ，Claude(Sonnet4.5 モデル) に「Between2 をつかった分散分析の結果を ggplot2 で可視化するコードをかけ」と指示して書かせたものです。このように生成 AI を使うと R のコードも書いてくれますのでコード自体を恐れる必要はありません。人間に必要なのは適切な指示を出すこと，ゴールのビジョンを明確に持つことです。

code : 20.9　可視化のコード

```
Between2 %>%
  group_by(temp, maker) %>%
  summarise(
    mean = mean(value),
    sd = sd(value),
    n = n(),
    se = sd / sqrt(n),
    .groups = "drop"
  ) %>%
  ggplot(aes(x = temp, y = mean, fill = maker)) +
  geom_bar(
    stat = "identity",
    position = position_dodge(0.9),
    width = 0.8
  ) +
  geom_errorbar(aes(ymin = mean - se, ymax = mean + se),
    position = position_dodge(0.9), width = 0.25
  ) +
  labs(
    title = "温度とメーカーによる評価値の比較",
    x = "温度条件",
    y = "評価値の平均",
    fill = "メーカー"
  ) +
  theme_bw()
```

■コード解説

1 行目　データフレーム Between2 をパイプでつないでいます。

2 行目　group_by() 関数で，温度 (temp) とメーカー (maker) の組み合わせごとにグループ化しています。

3-9 行目　summarise() 関数で各グループの記述統計量を計算しています。平均値 (mean)，標準偏差 (sd)，サンプル数 (n)，標準誤差 (se) を算出し，.groups = "drop"でグループ化を解除しています。

10 行目　パイプで ggplot() 関数に接続し，aes() で見た目の設定をしています。x 軸に温度，y 軸に平均値を割り当て，fill = maker で棒の塗りつぶしの色をメーカーごとに分けています。

11-15 行目　geom_bar() で，各条件の平均値を棒で描画しています。stat = "identity"で集計済みの平均値をそのまま棒の高さにし，position = position_dodge(0.9) でメーカーごとの棒を横に並べ，width = 0.8 で棒の幅を指定しています。

16-18 行目　geom_errorbar() でエラーバー (標準誤差) を追加しています。ymin と ymax で誤差範囲を指定し，position = position_dodge(0.9) で棒と同じ位置にずらし，width = 0.25 でエラーバーの横幅を指定しています。

19-24 行目　labs() 関数で図のタイトルと軸ラベル，凡例の見出し (fill = "メーカー") を設定しています。

25 行目　theme_bw() で白黒ベースのテーマを適用し，見やすいグラフにしています。

単純に，ボックスプロット (箱ひげ図) で表現するのもいいかもしれませんね。好みの問題ですけど。ボックスプロットで表示する例を図 20.3 に示します。

図 20.3　分散分析結果の可視化 2;ボックスプロットで分布を表示

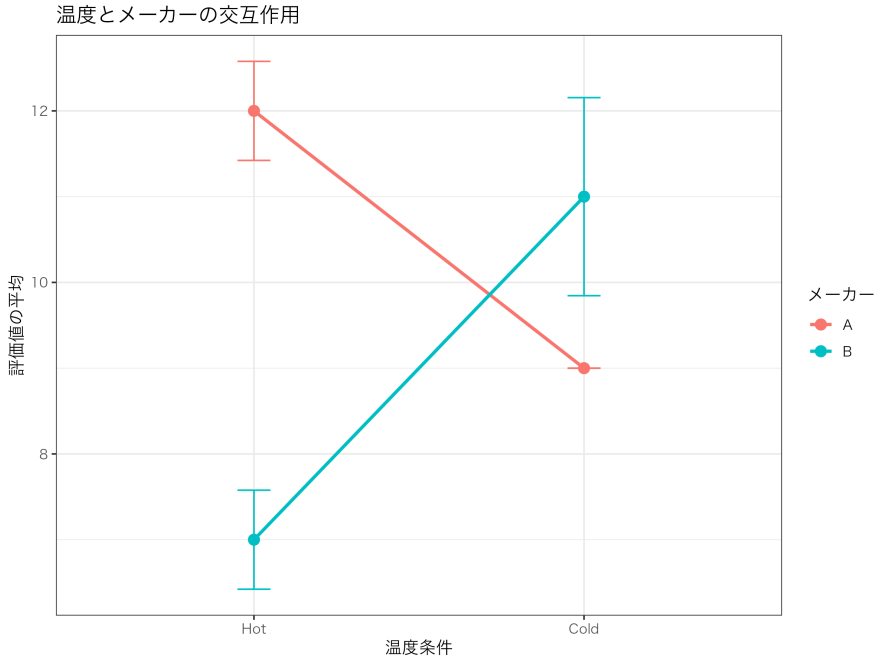

ボックスプロットは平均値に加え，データの分布や外れ値を視覚的に確認するのに便利です。また，今回は点ですべてのデータを重ねて表示しているので，どのような分布になっているのかもわかります[*9]。コードは次の通りです。

code : 20.10　箱ひげ図のコード

```
Between2 %>%
  ggplot(aes(x = temp, y = value, fill = maker)) +
  geom_boxplot(alpha = 0.5, outlier.shape = NA) +
  geom_jitter(aes(color = maker), position = position_jitterdodge(jitter.width = 0.2), s
  labs(
    title = "温度とメーカーによる評価値の分布",
    x = "温度条件",
    y = "評価値",
    fill = "メーカー",
    color = "メーカー"
  ) +
  theme_bw()
```

■コード解説

1 行目　データフレーム Between2 をパイプでつないでいます。箱ひげ図はデータそのものの分布を描くので，平均値などを事前に計算する必要はありません。

[*9] 点をそのまま書くと，同じ値が重複して表示され見た目に違いがわからなくなりますので，左右に少し散らばるように書きました。この散らばらせるやり方をジッター (jitter) といいます。

2 行目 パイプで ggplot() 関数に接続し，aes() で見た目の設定をしています。x 軸に温度，y 軸に評価値 (value)，塗りつぶしの色にメーカーを割り当てています。

3 行目 geom_boxplot() で箱ひげ図を描画しています。fill にメーカーを割り当てているので，温度条件ごとにメーカー別の箱が横に並びます。alpha = 0.5 で塗りつぶしを半透明にし，重ねる点が見えるようにしています。outlier.shape = NA で外れ値の点を描かないようにしています。次の行ですべてのデータを点で描くので，外れ値が二重に描かれるのを防ぐためです。

4 行目 geom_jitter() で，一つ一つのデータを点で描画しています。同じ値のデータが重なって見えなくならないよう，点を少しだけ横にずらして (jitter) 描きます。aes(color = maker) で点の色をメーカーごとに分け，position_jitterdodge(jitter.width = 0.2) で，点をメーカー別の箱の位置に合わせて並べたうえで横に散らしています。size = 2 で点の大きさを指定しています。

5-11 行目 labs() 関数で図のタイトルと軸ラベル，凡例の見出しを設定しています。塗りつぶし (fill) と点の色 (color) の両方に同じ見出し「メーカー」をつけているので，凡例が 1 つにまとまります。

12 行目 theme_bw() で白黒ベースのテーマを適用し，見やすいグラフにしています。

あるいはまた，交互作用のパターンを見るためには，次のような図もいいかもしれません。図 20.4 は，温度を横軸に，評価値の平均を縦軸にとり，メーカーごとに線で結んだものです。横軸が連続量ではないので，本来折れ線グラフにするのは適切ではないのですが，交互作用がある場合は，線が交差するようなパターンになって直感的にはわかりやすくなります。

図 20.4 分散分析結果の可視化 3;交互作用を示すプロット

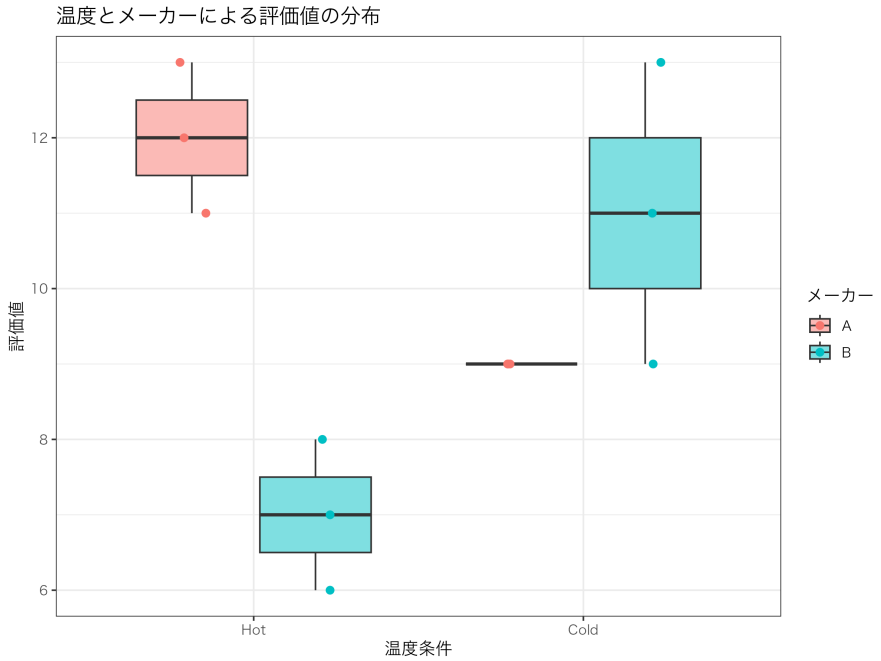

code : 20.11 交互作用の可視化のコード

```
1  Between2 %>%
2    group_by(temp, maker) %>%
3    summarise(
4      mean = mean(value),
5      sd = sd(value),
```

```
 6      n = n(),
 7      se = sd / sqrt(n),
 8      .groups = "drop"
 9    ) %>%
10    ggplot(aes(x = temp, y = mean, group = maker, color = maker)) +
11    geom_line(linewidth = 1) +
12    geom_point(size = 3) +
13    geom_errorbar(aes(ymin = mean - se, ymax = mean + se), width = 0.1) +
14    labs(
15      title = "温度とメーカーの交互作用",
16      x = "温度条件",
17      y = "評価値の平均",
18      color = "メーカー"
19    ) +
20    theme_bw()
```

■コード解説

1 行目 データフレーム Between2 をパイプでつないでいます。

2 行目 group_by() 関数で，温度 (temp) とメーカー (maker) の組み合わせごとにグループ化しています。

3-9 行目 summarise() 関数で各グループの記述統計量を計算しています。平均値 (mean)，標準偏差 (sd)，サンプル数 (n)，標準誤差 (se) を算出し，.groups = "drop"でグループ化を解除しています。

10 行目 パイプで ggplot() 関数に接続し，aes() で見た目の設定をしています。x 軸に温度，y 軸に平均値を割り当て，group = maker でメーカーごとに点を線で結ぶようにし，color = maker で線と点の色をメーカーごとに分けています。

11 行目 geom_line() で，各メーカーの平均値を結ぶ線を描画しています。linewidth = 1 で線の太さを指定しています。

12 行目 geom_point() で，各条件の平均値を点で描画しています。size = 3 で点の大きさを指定しています。

13 行目 geom_errorbar() でエラーバー (標準誤差) を追加しています。ymin と ymax で誤差範囲を指定し，width = 0.1 でエラーバーの横幅を指定しています。

14-19 行目 labs() 関数で図のタイトルと軸ラベル，凡例の見出し (color = "**メーカー**") を設定しています。

20 行目 theme_bw() で白黒ベースのテーマを適用し，見やすいグラフにしています。

20.5 課題

ある研究者が，学習方法 (対面授業 vs オンライン授業) と復習の有無 (復習あり vs 復習なし) が学習成果に与える影響を調べるために，2 要因の群間計画による実験を行いました。各条件に 4 名ずつ，合計 16 名の参加者を無作為に割り当て，学習後のテスト得点 (100 点満点) を測定しました。結果は次の通りです。

通し番号	群での番号	学習方法	復習	テスト得点
1	1	対面	あり	85
2	2	対面	あり	88
3	3	対面	あり	82
4	4	対面	あり	90
5	1	対面	なし	72
6	2	対面	なし	68
7	3	対面	なし	75
8	4	対面	なし	70
9	1	オンライン	あり	78
10	2	オンライン	あり	82
11	3	オンライン	あり	80
12	4	オンライン	あり	76
13	1	オンライン	なし	55
14	2	オンライン	なし	52
15	3	オンライン	なし	58
16	4	オンライン	なし	50

20.5.1 課題内容

このデータを使って，以下の課題に取り組んでください。

1. 上記のデータを R のデータフレームとして作成しなさい。テスト得点は，伴走サイトの「各章のコード」にある `20_kadai_data.R` をプロジェクトフォルダに置き，`source("20_kadai_data.R")` と実行すると，通し番号の順に並んだベクトル `score` として読み込まれます。学習方法と復習の有無の列は自分で作り，要因型 (factor) にすること。
2. `anovakun` 関数を使って二要因分散分析を実行しなさい。効果量 (ε^2) も表示すること。
3. 分散分析の結果から，次の点について答えなさい：
   - 学習方法の主効果は有意か
   - 復習の有無の主効果は有意か
   - 交互作用は有意か
   - 最も大きな効果はどれか (効果量 ε^2 を見て判断すること)
4. 交互作用が有意であった場合，単純効果の検定結果を解釈しなさい。
5. `ggplot2` パッケージを使って，この結果を可視化しなさい。グラフには平均値と標準誤差を表示すること。
6. 結果を文章でまとめなさい。APA 形式に準じて，統計量 (F 値，p 値，効果量) を含めて報告すること。

20.5.2 ヒント

- データフレームを作成する際は，`data.frame()` 関数と `rep()` 関数を活用しましょう。
- 要因型への変換には，`factor()` 関数を使います。ラベルは適切な日本語または英語を指定してください。

- anovakun の要因計画の型指定は，両方とも群間要因なので"ABs"となります。
- 可視化のコードは，本文中の code:20.9 を参考にしてください。
- グラフ作成時には，group_by() と summarise() を使って，各条件の平均値と標準誤差を計算します。

20.5.3 発展課題

1. 線形モデル (lm() 関数) を使っても同じ分析を行い，anovakun の結果と比較しなさい。
2. この実験結果から，学習効果を最大化するためにはどのような条件が望ましいと言えるか，考察しなさい。
3. もし交互作用が有意でなかった場合，主効果の解釈はどのように変わるか考えなさい。

第 21 章

群内計画 (Within Design) の理論

ここまで，線形モデルとしての実験計画法を見てきました。一要因，二要因がそれぞれ単回帰分析，**重回帰分析**に対応すること，二要因以上になると組み合わせの効果が出現することなどを見てきました。しかしここまでの話はいずれも，**群間要因**計画の話でした。そこで**群内要因**計画の場合はどのようになるか，というところに目を向けていきたいと思います。

21.1 群内計画の基本構造

群内要因での例を考えていくにあたって，今回も数値例を基に話を始めてから，線形モデルでの表現へ，と進めていきたいと思います。

今回は一要因 3 水準の，群内計画の要因計画の話をしましょう。データに対応がある，あるいは反復測定であることがポイントです。同じ人に複数回データを提供してもらう，次のような状況をイメージしてください。

臨床心理学者がある介入法をつかってメンタルケアに取り組んでいます。4 人のクライアントにこの手法を適用し，抑うつ度が改善されていくかどうかチェックします。表 21.1 のようなスコアが得られたとき，この介入法に効果があるかどうかを考えたい，とします。このデータを図にしてみましょう。ポイントは，3 つの調査時点 (Time1,2,3) それぞれが独立ではなく，クライアント番号 (ID) は共通しているというところです。横軸は時間だとすると，その軸に意味がありますから，同じ人のデータ点を線で結ぶことができるのです。

表 21.1　Within Data Example

ID	Time1	Time2	Time3
1	10	5	9
2	9	4	5
3	4	2	3
4	7	3	5

図 21.1 をみていると，個人差こそあれ，第一期 (Time1) から二期 (Time2) にかけてはいったん下降傾向があり，第二期から三期 (Time3) にかけては上昇傾向があるのかなあ，と思ったりします。この直感をデータで検証していくことが大事ですね。水準ごとの平均値と全体平均を比較して，効果を考えてみましょう。図 21.2 と表 21.2 をご覧ください。

図 21.2 は，水準ごとの平均値と全体平均を比較したものです。各水準の平均値が全体平均からどれだけ離れているか，というのが効果の大きさになります。第一期 (Time1) は全体平均より高く，第二期 (Time2) は低く，第三期 (Time3) はほぼ同じ，ということがわかりますね。

図 21.1 介入効果によるクライアントの状態変化

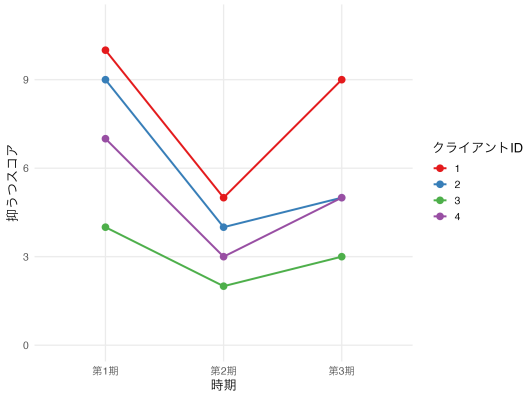

図 21.2 介入効果の可視化;全体平均と水準の比較

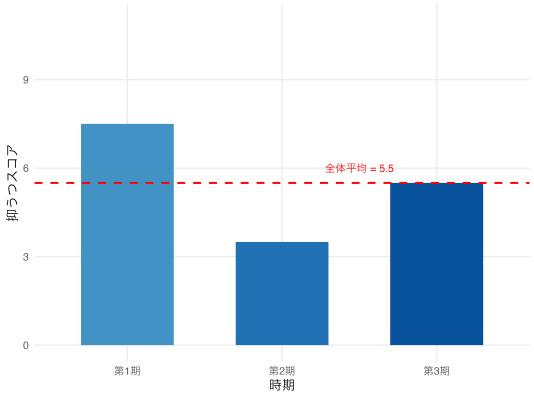

表 21.2 水準ごとの平均から効果を考える

ID	Time1	Time2	Time3	平均
1	10	5	9	8
2	9	4	5	6
3	4	2	3	3
4	7	3	5	5
平均	7.5	3.5	5.5	5.5

さて，次に考えたいのは，「個人差こそあれ」のところです。**個人差**とは，効果に関係なく，各人がもともと持っている特性や状態の違いを指します。たとえば，表 21.1 のデータを見ると，ID=1 の人は全体的にスコアが高く，ID=3 の人は全体的にスコアが低い，という傾向が見られます。個人の平均を図にしてみるとその違いは明らかです (図 21.3)。今回この差分は個人によるものであって，見たい介入効果の部分ではありません。見たい効果は「時期」要因による，3 つの水準それぞれへの影響，β_j です。数式的に表現すると，個人 i の第 j 期におけるデータ y_{ij} は，次のように表すことができます。

$$y_{ij} = \beta_0 + \delta_i + \beta_j X_{ij} + \epsilon_{ij}$$

ここで X_{ij} はまたしても，第 j 期に β_j の効果がある (1) かない (0) かを表している記号だと思ってください。また，ポイントとして，新たに δ_i というのが出てきていることに注意してください。これは i に伴って変わる数字で，時期 j の添字がついていませんから，「時期を通して一貫した個人の平均値」ということになります。β_0 は i も j もついていませんから，個人にも時期にも関係なく変化しない全体の平均値を表しています。

具体的な数字で見てみましょう。ID=1 の人について考えると，この人のデータは第 1 期では 10，第 2 期では 5，第 3 期では 9 でした。全体平均が 5.5 ですから，この人の個人差 δ_1 は $+2.5$ になります。時期の効果 β_j は，第 1 期では $+2.0$，第 2 期では -2.0，第 3 期では 0.0 ですから，第 1 期のデータは次のように表せます。

$$10 = 5.5 + 2.5 + 2.0 + \epsilon_{11}$$

ここで ϵ_{11} は誤差項で，逆算すると 0.0 であることがわかります。この人のこの時期のポイントは，誤差なく理論通りの値が出たことになります。

同様に，第 2 期，第 3 期も表してみましょう。

$$5 = 5.5 + 2.5 - 2.0 + \epsilon_{12}$$

$$9 = 5.5 + 2.5 + 0.0 + \epsilon_{13}$$

ここで，ϵ_{12} は -1.0，ϵ_{13} は $+1.0$ です。理論と実測のズレはこの介入ではわからない要素なので，これを誤差と考えるほかありません。この計算を図で表したのが図 21.4 です。

図 21.3　個人が持っている特性の違い (個人差) の考慮

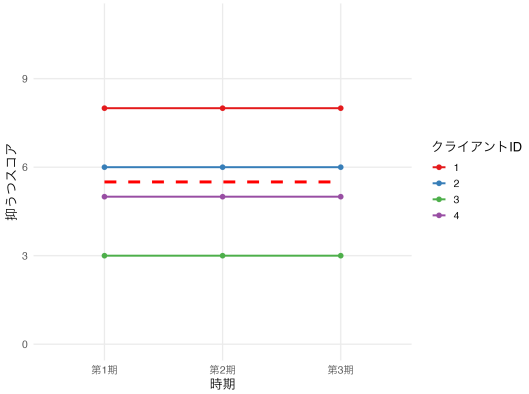

図 21.4　ID=1 のデータのモデル化

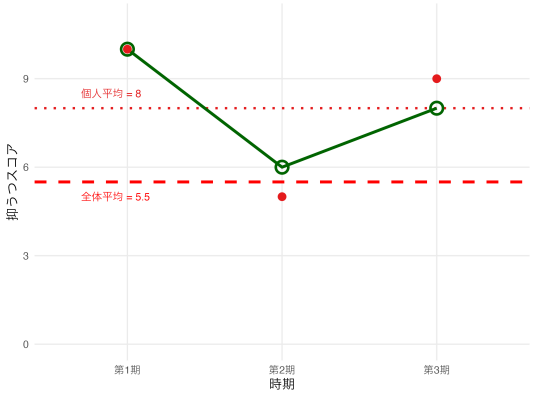

この計算を全員に対して行い，効果，個人差，誤差を計算して表にしたのが表 21.3 です。例によって総和すると 0 ですので，平方和を計算することで相対的な大きさを比較できるようになります。

表 21.3　効果，個人差，誤差を析出する

ID	時期	スコア	全体平均	個人差	効果	誤差
1	Time1	10	5.5	+2.5	+2.0	0.0
1	Time2	5	5.5	+2.5	-2.0	-1.0
1	Time3	9	5.5	+2.5	0.0	+1.0
2	Time1	9	5.5	+0.5	+2.0	+1.0
2	Time2	4	5.5	+0.5	-2.0	0.0
2	Time3	5	5.5	+0.5	0.0	-1.0
3	Time1	4	5.5	-2.5	+2.0	-1.0
3	Time2	2	5.5	-2.5	-2.0	+1.0
3	Time3	3	5.5	-2.5	0.0	0.0
4	Time1	7	5.5	-0.5	+2.0	0.0
4	Time2	3	5.5	-0.5	-2.0	0.0
4	Time3	5	5.5	-0.5	0.0	0.0
平方和				39.0	32.0	6.0

ここにあるように，個人 i の時期 j における誤差，と各セルに細かく誤差が計算できるようになりました。これが群内要因計画の強みなのです。

21.2 一要因群内モデルの平方和の分解

それではこの数値を元に，平方和の分解を確認してみましょう。群内要因計画の場合，総平方和 SS_T は，効果による平方和 SS_A，個人差による平方和 SS_S，および誤差による平方和 SS_E に分解されます。

$$SS_T = SS_A + SS_S + SS_E$$

上の数値例でいうと，次のような等式が成り立っていることがわかります。

$$77.0 = 32.0 + 39.0 + 6.0$$

これが群内要因の平方和の分解です。これを元に「意思決定」，つまり効果があるかどうかの判断をするわけですが，そのためには平方和 (SS) から平均平方 (MS) を計算しなければなりません。群間要因のときにやったように，平均平方にするには一水準あたりの平方和を考えることになりますから，それぞれの要因がどれだけの自由度を持っているかを考えなければなりません。効果 SS_A は 3 水準ですから，自由度は $3 - 1 = 2$ です。個人差 SS_S は 4 人ですから，自由度は $4 - 1 = 3$ です。誤差 SS_E は全体の自由度 $12 - 1 = 11$ から，効果と個人差の自由度を引いたものですから，$11 - 2 - 3 = 6$ となります。これを元に平均平方を計算すると，次のようになります。

- 効果の平均平方: $MS_A = SS_A/df_A = 32.0/2 = 16.0$
- 個人差の平均平方: $MS_S = SS_S/df_S = 39.0/3 = 13.0$
- 誤差の平均平方: $MS_E = SS_E/df_E = 6.0/6 = 1.000$

これを元に F 値を計算します。群内要因計画の場合，効果の F 値は，効果の平均平方を誤差の平均平方で割ったものになります。

$$F = \frac{MS_A}{MS_E} = \frac{16.0}{1} = 16.00$$

この F 値を元に，効果が有意かどうかを判断します。分散の比の分布である F 分布で，今回は分子の自由度が 2，分母の自由度が 6 ですから，理論値は 5.143253 になります[*1]。今回の 16 はこれに比べてかなり大きいので，有意である (3 つの水準間の平均値は同じではない)，と判断できます。

最後に分散分析表にこのことをまとめておきましょう。表 21.4 がその分散分析表です。

表 21.4 群内要因計画の分散分析表

要因	平方和 (SS)	自由度 (df)	平均平方 (MS)	F 値	p 値
個人差	39.0	3	13.0		
効果	32.0	2	16.0	16.00	0.0039
誤差	6.0	6	1.000		
総和	77.0	11			

21.3 二要因群内モデルの例

今度は二要因の群内計画の例を見てみましょう。二要因群内計画では，二つの要因があり，それぞれの要因が複数の水準を持っています。群間要因の時と同じように，交互作用も考えなければなりません。加えて面

[*1] R で `qf(0.95,2,6)` とすれば計算できます。

倒なことに,「要因に伴う誤差」をどう考えるかについて, 少し面倒なステップを踏みます。慎重に進めてまいりましょう。

二要因群内計画のデータ例を, 表 21.5 に示します。

表 21.5 二要因被験者内デザインのデータ

	m1			m2		
id	t1	t2	t3	t1	t2	t3
A	47.00	90.00	44.00	38.00	55.00	52.00
B	60.00	71.00	63.00	39.00	49.00	59.00
C	79.00	83.00	48.00	60.00	47.00	50.00
D	54.00	41.00	39.00	49.00	63.00	63.00
E	55.00	41.00	58.00	45.00	49.00	54.00
F	84.00	103.00	20.00	62.00	58.00	56.00
G	63.00	74.00	96.00	46.00	48.00	57.00
H	41.00	34.00	62.00	28.00	30.00	64.00
I	53.00	65.00	44.00	35.00	61.00	52.00
J	57.00	53.00	83.00	40.00	47.00	72.00

二要因群間要因の分散分析では, 平方和の分解を行いました。今回, 群内要因のときはそれを行わずにいきなり anovakun に計算させました。その理由はなんといっても複雑だからです。そしてその複雑な計算をひとつひとつ説明しても, レガシーとなった技術の細部を掘り返すようで, あまり意味がないかもしれません。

しかし, だからこそマニアックなあなたのために, 説明を追加しておこうと思います。知的なエッセイとして読んでいただいても結構ですし, 足し算と掛け算だけでできる算数パズルだとおもって一緒に計算してみていただいても結構です。

さあ, 楽しみましょう！

21.3.1 個人差の計算

まずは個人差です。データは一行が一人分を表していますから, 各行の平均値を計算することで「その人の平均」を見ることができ, それが全体平均からどれぐらい隔たっているかで, 個人差の効果を計算することができます。計算プロセスを表 21.6 に示します。

一行目, A さんのデータを見てみましょう。A さんの各条件における得点は, 47,90,44,38,55,52 で, 平均は 54.33 になります。全体平均が 55.55 でしたから, 効果は $54.33 - 55.55 = -1.22$ となります。これがこの人の効果です。この効果を二乗すると 1.48 になり, これが一行分・6 ケースすべてにあらわれていますから, 平方和に寄与するのは $1.48 \times 6 = 8.88$ と考えられます。これを全員分計算して, 最後に合計を出すと 2378.68 となり, 個人差の平方和 (SS) が得られます。分散分析表でも最初にこの数字が出ていましたね。

21.3.2 主効果の計算

今度は要因ごとの効果です。要因 A と要因 B の主効果を計算してみましょう。要因 A は 2 水準, B は 3 水準ですから, それぞれの水準ごとに平均を計算し, 全体平均からどれぐらい隔たっているかを見ます。表 21.7 に示します。

ここでも, 一行目, m1 水準を見てみましょう。m1 水準の平均は 60.17 で, 全体平均 55.55 からの効果は

表 21.6 個人差の計算

id	平均	効果	効果二乗	要素数	SS 寄与
A	54.33	-1.22	1.48	6	8.88
B	56.83	1.28	1.65	6	9.88
C	61.17	5.62	31.55	6	189.28
D	51.50	-4.05	16.40	6	98.41
E	50.33	-5.22	27.21	6	163.28
F	63.83	8.28	68.61	6	411.68
G	64.00	8.45	71.40	6	428.42
H	43.17	-12.38	153.35	6	920.08
I	51.67	-3.88	15.08	6	90.48
J	58.67	3.12	9.71	6	58.28
合計					2378.68

表 21.7 主効果の計算

水準	平均	効果	効果二乗	要素数	SS 寄与	合計
m1	60.17	4.62	21.31	30	639.41	1278.82
m2	50.93	-4.62	21.31	30	639.41	
t1	51.75	-3.80	14.44	20	288.80	450.10
t2	58.10	2.55	6.50	20	130.05	
t3	56.80	1.25	1.56	20	31.25	

$60.17 - 55.55 = 4.62$ となります。この効果を二乗すると 21.31 になり，m1 水準には 30 ケース (10 人 $\times$3 水準) ありますから，平方和に寄与するのは $21.31 \times 30 = 639.41$ と考えられます。これを m2 水準についても同様に計算し，合計すると要因 A の平方和 1278.82 が得られます。要因 B についても同様に計算し，平方和 450.10 が得られます。分散分析表にもこの数字がありましたね！

21.3.3 交互作用の計算

今度は交互作用です。交互作用は組み合わせの水準ごとに平均値を出します。たとえば m1t1 の水準の平均は 59.30 です。全体平均は 55.55，これに要因 A の m1 効果 4.62 と要因 B の t1 効果-3.80 を足し合わせると，予測平均は $55.55 + 4.62 - 3.80 = 56.37$ となります。交互作用がなければ 56.37 になるはずですが，実際の平均は 59.30 ですから，逆算すると交互作用の効果は，$59.30 - 56.37 = 2.93$ だったことがわかります。この効果を二乗すると 8.60 になり，m1t1 水準には 10 ケース (10 人 $\times$1 水準) ありますから，平方和に寄与するのは $8.60 \times 10 = 86.04$ と考えられます。これをすべての組み合わせ水準について計算し，最後に合計すると交互作用の平方和 980.63 が得られます。計算のステップを表 21.8 に示します。

21.3.4 要因 A に伴って生じる残差

群内計画がややこしいのはここからです！残差が要因に伴って生じる，という考え方をする必要があります。要因 A に伴って生じる残差は，要因 B のそれとは違うんだぞ，ということを考えます。まず B の 3 つの水

表 21.8 交互作用の計算

セル	観測平均	予測平均	交互作用効果	効果二乗	要素数	SS 寄与
m1t1	59.30	56.37	2.93	8.60	10	86.04
m1t2	65.50	62.72	2.78	7.75	10	77.47
m1t3	55.70	61.42	-5.72	32.68	10	326.80
m2t1	44.20	47.13	-2.93	8.60	10	86.04
m2t2	50.70	53.48	-2.78	7.75	10	77.47
m2t3	57.90	52.18	5.72	32.68	10	326.80
合計						980.63

準を平均した値を計算しましょう。表 21.9 に示します。

表 21.9 各被験者の要因 A 水準別平均

id	m1	m2
A	60.33	48.33
B	64.67	49.00
C	70.00	52.33
D	44.67	58.33
E	51.33	49.33
F	69.00	58.67
G	77.67	50.33
H	45.67	40.67
I	54.00	49.33
J	64.33	53.00

これは要因 B の影響を取り除いた (要因 B で平均化した) 要因 A 水準別の各被験者の平均値です。たとえば A さんの m1 水準の値を考えてみましょう。A さんの m1 水準の各条件における得点は，47,90,44 で，平均は 60.33 になります。これが要因 B の影響を取り除いたときの，A さんの m1 水準における得点です。全体平均 55.55，A さんの個人差は-1.22，m1 水準の効果は 4.62 ですから，予測平均は $55.55 - 1.22 + 4.62 = 58.95$ です。いっぽう，実際の平均は 60.33 ですから，残差は $60.33 - 58.95 = 1.38$ となります。これが要因 B に関係のない，要因 A に伴って生じる残差です。

この残差を二乗すると 1.91 になり，m1 水準には 3 ケース (3 つの要因 B 水準) ありますから，平方和に寄与するのは $1.91 \times 3 = 5.74$ と考えられます。これをすべての組み合わせ水準について計算し，最後に合計すると要因 A に伴う残差の平方和 1603.35 が得られます。計算のステップを表 21.10 に示します。

21.3.5 要因 B に伴って生じる残差

今度は要因 B に伴って生じる残差です。要因 B に伴って生じる残差は，要因 A のそれとは違うと考えますから，要因 A の水準を潰して平均化したデータを考えましょう。これを表 21.11 に示します。

さて，また A さんの t1 水準を考えてみましょう。A さんの t1 水準の各条件における得点は，47,38 で，平均は 42.50 になります。これが要因 A の影響を取り除いた (要因 A で平均化した) ときの，A さ

表 21.10 要因 A に伴う残差 (s×A) の計算

id	A 水準	観測平均	個人差効果	A 効果	予測平均	残差	残差二乗	要素数	SS 寄与
A	m1	60.33	-1.22	4.62	58.95	1.38	1.91	3	5.74
A	m2	48.33	-1.22	-4.62	49.72	-1.38	1.91	3	5.74
B	m1	64.67	1.28	4.62	61.45	3.22	10.35	3	31.04
B	m2	49.00	1.28	-4.62	52.22	-3.22	10.35	3	31.04
C	m1	70.00	5.62	4.62	65.78	4.22	17.78	3	53.34
C	m2	52.33	5.62	-4.62	56.55	-4.22	17.78	3	53.34
D	m1	44.67	-4.05	4.62	56.12	-11.45	131.10	3	393.31
D	m2	58.33	-4.05	-4.62	46.88	11.45	131.10	3	393.31
E	m1	51.33	-5.22	4.62	54.95	-3.62	13.08	3	39.24
E	m2	49.33	-5.22	-4.62	45.72	3.62	13.08	3	39.24
F	m1	69.00	8.28	4.62	68.45	0.55	0.30	3	0.91
F	m2	58.67	8.28	-4.62	59.22	-0.55	0.30	3	0.91
G	m1	77.67	8.45	4.62	68.62	9.05	81.90	3	245.71
G	m2	50.33	8.45	-4.62	59.38	-9.05	81.90	3	245.71
H	m1	45.67	-12.38	4.62	47.78	-2.12	4.48	3	13.44
H	m2	40.67	-12.38	-4.62	38.55	2.12	4.48	3	13.44
I	m1	54.00	-3.88	4.62	56.28	-2.28	5.21	3	15.64
I	m2	49.33	-3.88	-4.62	47.05	2.28	5.21	3	15.64
J	m1	64.33	3.12	4.62	63.28	1.05	1.10	3	3.31
J	m2	53.00	3.12	-4.62	54.05	-1.05	1.10	3	3.31
合計									1603.35

表 21.11 各被験者の要因 B 水準別平均

id	t1	t2	t3
A	42.50	72.50	48.00
B	49.50	60.00	61.00
C	69.50	65.00	49.00
D	51.50	52.00	51.00
E	50.00	45.00	56.00
F	73.00	80.50	38.00
G	54.50	61.00	76.50
H	34.50	32.00	63.00
I	44.00	63.00	48.00
J	48.50	50.00	77.50

んの t1 水準における得点です。全体平均 55.55，A さんの個人差は-1.22，t1 水準の効果は-3.80 ですから，予測平均は $55.55 - 1.22 - 3.80 = 50.53$ です。いっぽう，実際の平均は 42.50 ですから，残差は $42.50 - 50.53 = -8.03$ となります。これが要因 A に関係のない，要因 B に伴って生じる残差です。

これを二乗し，要素数 (今回は A の 2 水準だから 2) をかけると，平方和に寄与する値が得られます。これをすべての組み合わせ水準について計算し，最後に合計すると要因 B に伴う残差の平方和 6542.57 が得られます。計算のステップを表 21.12 に示します。

分散分析表でみた値が出ましたね！ここまでくれば後少しです。

表 21.12 要因 B に伴う残差 (s×B) の計算

id	B 水準	観測平均	個人差効果	B 効果	予測平均	残差	残差二乗	要素数	SS 寄与
A	t1	42.50	-1.22	-3.80	50.53	-8.03	64.53	2	129.07
A	t2	72.50	-1.22	2.55	56.88	15.62	243.88	2	487.76
A	t3	48.00	-1.22	1.25	55.58	-7.58	57.51	2	115.01
B	t1	49.50	1.28	-3.80	53.03	-3.53	12.48	2	24.97
B	t2	60.00	1.28	2.55	59.38	0.62	0.38	2	0.76
B	t3	61.00	1.28	1.25	58.08	2.92	8.51	2	17.01
C	t1	69.50	5.62	-3.80	57.37	12.13	147.22	2	294.44
C	t2	65.00	5.62	2.55	63.72	1.28	1.65	2	3.29
C	t3	49.00	5.62	1.25	62.42	-13.42	180.01	2	360.01
D	t1	51.50	-4.05	-3.80	47.70	3.80	14.44	2	28.88
D	t2	52.00	-4.05	2.55	54.05	-2.05	4.20	2	8.41
D	t3	51.00	-4.05	1.25	52.75	-1.75	3.06	2	6.12
E	t1	50.00	-5.22	-3.80	46.53	3.47	12.02	2	24.04
E	t2	45.00	-5.22	2.55	52.88	-7.88	62.15	2	124.29
E	t3	56.00	-5.22	1.25	51.58	4.42	19.51	2	39.01
F	t1	73.00	8.28	-3.80	60.03	12.97	168.13	2	336.27
F	t2	80.50	8.28	2.55	66.38	14.12	199.28	2	398.56
F	t3	38.00	8.28	1.25	65.08	-27.08	733.51	2	1467.01
G	t1	54.50	8.45	-3.80	60.20	-5.70	32.49	2	64.98
G	t2	61.00	8.45	2.55	66.55	-5.55	30.80	2	61.61
G	t3	76.50	8.45	1.25	65.25	11.25	126.56	2	253.12
H	t1	34.50	-12.38	-3.80	39.37	-4.87	23.68	2	47.37
H	t2	32.00	-12.38	2.55	45.72	-13.72	188.15	2	376.29
H	t3	63.00	-12.38	1.25	44.42	18.58	345.34	2	690.68
I	t1	44.00	-3.88	-3.80	47.87	-3.87	14.95	2	29.90
I	t2	63.00	-3.88	2.55	54.22	8.78	77.15	2	154.29
I	t3	48.00	-3.88	1.25	52.92	-4.92	24.17	2	48.35
J	t1	48.50	3.12	-3.80	54.87	-6.37	40.53	2	81.07
J	t2	50.00	3.12	2.55	61.22	-11.22	125.81	2	251.63
J	t3	77.50	3.12	1.25	59.92	17.58	309.17	2	618.35
合計									6542.57

21.3.6 交互作用に伴って生じる残差

後少し，と言いながらこれが厄介。というのも，各セルについて考えなければならない話だからです。各セルについて，交互作用に伴って生じる残差を計算します。たとえば A さんの m1t1 セルを考えてみましょう。観測値は 47 です。個人差効果は-1.22，A 効果は 4.62，B 効果は-3.80，交互作用効果は 2.93 です。さらに，m1 に伴って生じるズレ (残差) が 1.38，t1 に伴って生じるズレ (残差) が-8.03 加わります。これらを全部足し合わせると，予測値は 51.43 になります。実際の観測値は 47 ですから，残差は-4.43 となります。この残差を二乗すると 19.65 になり，これが SS に寄与します。これをすべてのセルについて計算し，最後に合計すると交互作用に伴う残差の平方和 2420.70 が得られます。計算のステップを表 21.13 に示します。

さあこれで，交互作用に伴って生じる残差も計算できました。あとはこれらを分散分析表にまとめるだけです。

単純だけど面倒な計算でしたね。R などが出てくる前は，専門のプログラムで，あるいは手計算でやってい

たわけです。さすがに私が学生の頃 (1990 年代後半) にはすでに R や SAS，SPSS など統計プログラムでやりましたが，それ以前の時代は大変だっただろうなあと思います。

逆にいうと，データを丁寧に丁寧にみていくことで，どうしても知りたい効果のところを洗い出す！ということをやってきていたわけです。そういう意味では，今でもデータを丁寧にみていくことは重要だなあと思います。

21.4 群間計画と群内計画の比較

以上で要員計画・分散分析の説明は一通り終わりました。面倒なステップかもしれませんが，加減乗除の計算だけで，どこにどれだけ効果があるか，どこが誤差なのかということが算出できることの巧妙なロジックを楽しい！と思ってくれると嬉しいのですが。

さて，最後に包括的なまとめとして，**群間要因 (between design)** 計画と**群内要因 (within design)** 計画の構造的な違いに触れておきたいと思います。

群内計画では，個人が誰であるかという情報があったので個人差を算出でき，それに基づいて分析しました。が，群内計画の時のデータを群間計画のように分析してみるとどうなるでしょうか。表 21.3 にある数字が同じであれば，群内計画であれ群間計画であれ，当然全体の平方和 (分散) は同じです。ただ個人情報が抜けているのであれば，効果と誤差にしか分割できません。言い換えると，群間計画というのは誤差の中に個人差が含まれており，「これは誤差なのかな，個人差なのかな？」という区別がつかない状態である，ということです (図 21.5)。

図 21.5 群内計画と群間計画の違い

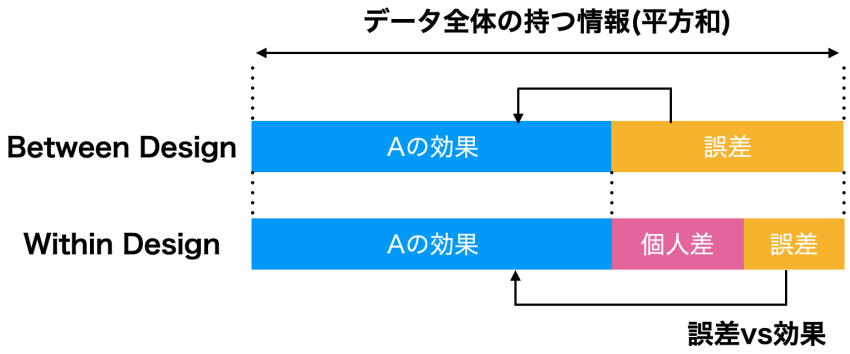

群間・群内どちらの計画であっても，最終的には，誤差の大きさに対して効果の大きさはどうか，という観点から評価します。効果の大きさ＝分子が同じデータであれば，分母が小さい方が相対的に大きいと判断されることになりますね。図 21.5 をよく見て，どことどこを比較しているか確認してくださいね。ここで群間計画の時の誤差は偶然誤差と個人差を含んでおり，群内計画の時は個人差を含みませんから，群内計画の方が群間計画よりも，分析の精度が高いということになります。群内計画の方が分析精度が高いということは，群内計画の方が効果を検出しやすいということでもあります。つまり，群内計画の方が少ない人数で実験を行うことができるということです。群間計画では，誤差の中に個人差が含まれているので，効果を検出するためにはより多くの人数が必要になります。

であれば，すべての研究が群内計画であればよいのに，と思うかもしれません。ただし現実的な問題として，同じ人に何度も何度もデータを提供してもらうのは，非常に負担をかけることになります (群内計画は反復測定計画とも呼ばれるのでした)。研究倫理的な観点，あるいは計画上の手間を考えると，群間計画にせざ

るを得ないということが少なくありません。研究者，研究に協力してくれる人，のコストを考えて実験計画はデザインする必要があるということです。

ところで，第 18.4 節でやったように，分散分析における平方和の分解を式にまとめてみましょう。今回は内 × 内の計画のときに，「要因に伴う誤差」を算出するのが面倒だ，という話でしたね。これも踏まえて，どのように分解されるかを書き出してみます。

$$
\begin{array}{lll}
\text{一要因群間計画} & \text{全体変動} = & \text{要因 A} + \text{誤差} \\
\text{一要因群内計画} & \text{全体変動} = & \text{個人差} + \text{要因 A} + \text{誤差} \\
\text{二要因群間 (間間) 計画} & \text{全体変動} = & \text{要因 A} + \text{要因 B} + \text{交互作用 AB} + \text{誤差} \\
\text{二要因群内 (内内) 計画} & \text{全体変動} = & \text{個人差} + \text{要因 A} + \text{要因 B} + \text{交互作用 AB} \\
 & & \quad + \text{要因 A に伴う誤差} + \text{要因 B に伴う誤差} \\
 & & \quad + \text{交互作用に伴う誤差} \\
\text{二要因混合 (間内) 計画} & \text{全体変動} = & \text{要因 A} + \text{要因 B} + \text{交互作用 AB} \\
 & & \quad + \text{要因 A に伴う誤差} + \text{要因 B に伴う誤差}
\end{array}
\tag{21.1}
$$

わかりにくいので図にしてみましょう。図 21.6 は，二要因計画のときの平方和の分解を，計画ごとに並べたものです。

図 21.6　二要因計画と誤差の分割

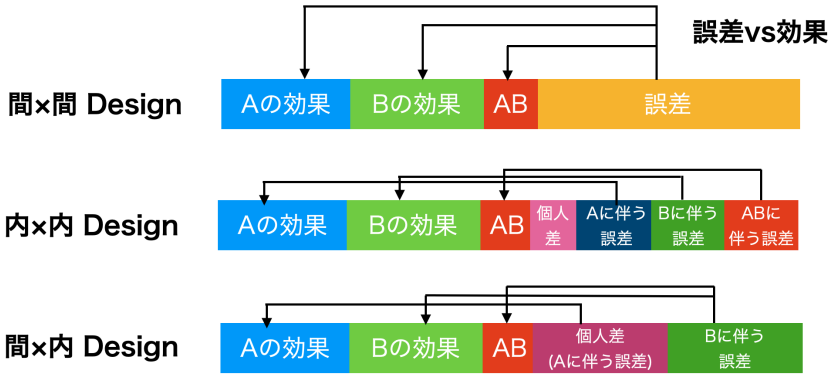

群間要因のときに個人差が析出できないのは，一要因の計画のときと同じです。そして今回やったように，群内要因のときはその要因における誤差を算出できるので，「要因に伴う誤差」という形で書き出せます。内 × 内計画のときは，各主要因および交互作用に伴う誤差を計算できます。ややこしいのは混合計画，つまり内要因と間要因が混ざった計画のときです。内要因に伴う誤差は算出できますが，間要因に伴う誤差は，個人差と区別して算出することができません。なので，間 × 内計画のときは，「要因 A に伴う誤差」「要因 B に伴う誤差」「交互作用に伴う誤差」を，内 × 内計画のようにすべて別々に算出することはできません。今回は要因 A が間要因ですので，同じ人が A の両方の水準に出てくることがありません。そのため，個人差と A に伴う誤差が区別できずひとかたまりになっています。また，要因 B(内要因) のほうで，B に伴う誤差と交互作用に伴う誤差も区分できなくなるので，これも一つのまとまりになります。分散分析表は表 21.14 のように書き表し，どことどこの比較なのかがわかるようにしておきましょう (anovakun はこのように区別して出してくれます)。

さあ，これで長らく続いた分散分析の話は一段落です。理屈は大変面倒な感じがしましたが，これを押さえておかないと実際に計算した時に混乱しますので，しっかり理解しておきましょう。次回は R を使って，これらを自動で計算する方法を紹介します。R を使うと，今回のような面倒な計算は一瞬で終わりますから，どうぞお楽しみに。

表 21.13　交互作用に伴う残差 (s×A×B) の計算

id	セル	観測値	個人差	A 効果	B 効果	AB	s × A	s × B	予測	残差	残差 ^{2}	SS
A	m1_t1	47	-1.22	4.62	-3.80	2.93	1.38	-8.03	51.43	-4.43	19.65	19.65
A	m1_t2	90	-1.22	4.62	2.55	2.78	1.38	15.62	81.28	8.72	75.98	75.98
A	m1_t3	44	-1.22	4.62	1.25	-5.72	1.38	-7.58	48.28	-4.28	18.35	18.35
A	m2_t1	38	-1.22	-4.62	-3.80	-2.93	-1.38	-8.03	33.57	4.43	19.65	19.65
A	m2_t2	55	-1.22	-4.62	2.55	-2.78	-1.38	15.62	63.72	-8.72	75.98	75.98
A	m2_t3	52	-1.22	-4.62	1.25	5.72	-1.38	-7.58	47.72	4.28	18.35	18.35
B	m1_t1	60	1.28	4.62	-3.80	2.93	3.22	-3.53	60.27	-0.27	0.07	0.07
B	m1_t2	71	1.28	4.62	2.55	2.78	3.22	0.62	70.62	0.38	0.15	0.15
B	m1_t3	63	1.28	4.62	1.25	-5.72	3.22	2.92	63.12	-0.12	0.01	0.01
B	m2_t1	39	1.28	-4.62	-3.80	-2.93	-3.22	-3.53	38.73	0.27	0.07	0.07
B	m2_t2	49	1.28	-4.62	2.55	-2.78	-3.22	0.62	49.38	-0.38	0.15	0.15
B	m2_t3	59	1.28	-4.62	1.25	5.72	-3.22	2.92	58.88	0.12	0.01	0.01
C	m1_t1	79	5.62	4.62	-3.80	2.93	4.22	12.13	81.27	-2.27	5.14	5.14
C	m1_t2	83	5.62	4.62	2.55	2.78	4.22	1.28	76.62	6.38	40.75	40.75
C	m1_t3	48	5.62	4.62	1.25	-5.72	4.22	-13.42	52.12	-4.12	16.95	16.95
C	m2_t1	60	5.62	-4.62	-3.80	-2.93	-4.22	12.13	57.73	2.27	5.14	5.14
C	m2_t2	47	5.62	-4.62	2.55	-2.78	-4.22	1.28	53.38	-6.38	40.75	40.75
C	m2_t3	50	5.62	-4.62	1.25	5.72	-4.22	-13.42	45.88	4.12	16.95	16.95
D	m1_t1	54	-4.05	4.62	-3.80	2.93	-11.45	3.80	47.60	6.40	40.96	40.96
D	m1_t2	41	-4.05	4.62	2.55	2.78	-11.45	-2.05	47.95	-6.95	48.30	48.30
D	m1_t3	39	-4.05	4.62	1.25	-5.72	-11.45	-1.75	38.45	0.55	0.30	0.30
D	m2_t1	49	-4.05	-4.62	-3.80	-2.93	11.45	3.80	55.40	-6.40	40.96	40.96
D	m2_t2	63	-4.05	-4.62	2.55	-2.78	11.45	-2.05	56.05	6.95	48.30	48.30
D	m2_t3	63	-4.05	-4.62	1.25	5.72	11.45	-1.75	63.55	-0.55	0.30	0.30
E	m1_t1	55	-5.22	4.62	-3.80	2.93	-3.62	3.47	53.93	1.07	1.14	1.14
E	m1_t2	41	-5.22	4.62	2.55	2.78	-3.62	-7.88	48.78	-7.78	60.58	60.58
E	m1_t3	58	-5.22	4.62	1.25	-5.72	-3.62	4.42	51.28	6.72	45.11	45.11
E	m2_t1	45	-5.22	-4.62	-3.80	-2.93	3.62	3.47	46.07	-1.07	1.14	1.14
E	m2_t2	49	-5.22	-4.62	2.55	-2.78	3.62	-7.88	41.22	7.78	60.58	60.58
E	m2_t3	54	-5.22	-4.62	1.25	5.72	3.62	4.42	60.72	-6.72	45.11	45.11
F	m1_t1	84	8.28	4.62	-3.80	2.93	0.55	12.97	81.10	2.90	8.41	8.41
F	m1_t2	103	8.28	4.62	2.55	2.78	0.55	14.12	88.45	14.55	211.70	211.70
F	m1_t3	20	8.28	4.62	1.25	-5.72	0.55	-27.08	37.45	-17.45	304.50	304.50
F	m2_t1	62	8.28	-4.62	-3.80	-2.93	-0.55	12.97	64.90	-2.90	8.41	8.41
F	m2_t2	58	8.28	-4.62	2.55	-2.78	-0.55	14.12	72.55	-14.55	211.70	211.70
F	m2_t3	56	8.28	-4.62	1.25	5.72	-0.55	-27.08	38.55	17.45	304.50	304.50
G	m1_t1	63	8.45	4.62	-3.80	2.93	9.05	-5.70	71.10	-8.10	65.61	65.61
G	m1_t2	74	8.45	4.62	2.55	2.78	9.05	-5.55	77.45	-3.45	11.90	11.90
G	m1_t3	96	8.45	4.62	1.25	-5.72	9.05	11.25	84.45	11.55	133.40	133.40
G	m2_t1	46	8.45	-4.62	-3.80	-2.93	-9.05	-5.70	37.90	8.10	65.61	65.61
G	m2_t2	48	8.45	-4.62	2.55	-2.78	-9.05	-5.55	44.55	3.45	11.90	11.90
G	m2_t3	57	8.45	-4.62	1.25	5.72	-9.05	11.25	68.55	-11.55	133.40	133.40
H	m1_t1	41	-12.38	4.62	-3.80	2.93	-2.12	-4.87	39.93	1.07	1.14	1.14
H	m1_t2	34	-12.38	4.62	2.55	2.78	-2.12	-13.72	37.28	-3.28	10.78	10.78
H	m1_t3	62	-12.38	4.62	1.25	-5.72	-2.12	18.58	59.78	2.22	4.91	4.91
H	m2_t1	28	-12.38	-4.62	-3.80	-2.93	2.12	-4.87	29.07	-1.07	1.14	1.14
H	m2_t2	30	-12.38	-4.62	2.55	-2.78	2.12	-13.72	26.72	3.28	10.78	10.78
H	m2_t3	64	-12.38	-4.62	1.25	5.72	2.12	18.58	66.22	-2.22	4.91	4.91
I	m1_t1	53	-3.88	4.62	-3.80	2.93	-2.28	-3.87	49.27	3.73	13.94	13.94
I	m1_t2	65	-3.88	4.62	2.55	2.78	-2.28	8.78	68.12	-3.12	9.71	9.71
I	m1_t3	44	-3.88	4.62	1.25	-5.72	-2.28	-4.92	44.62	-0.62	0.38	0.38
I	m2_t1	35	-3.88	-4.62	-3.80	-2.93	2.28	-3.87	38.73	-3.73	13.94	13.94
I	m2_t2	61	-3.88	-4.62	2.55	-2.78	2.28	8.78	57.88	3.12	9.71	9.71
I	m2_t3	52	-3.88	-4.62	1.25	5.72	2.28	-4.92	51.38	0.62	0.38	0.38
J	m1_t1	57	3.12	4.62	-3.80	2.93	1.05	-6.37	57.10	-0.10	0.01	0.01
J	m1_t2	53	3.12	4.62	2.55	2.78	1.05	-11.22	58.45	-5.45	29.70	29.70
J	m1_t3	83	3.12	4.62	1.25	-5.72	1.05	17.58	77.45	5.55	30.80	30.80
J	m2_t1	40	3.12	-4.62	-3.80	-2.93	-1.05	-6.37	39.90	0.10	0.01	0.01
J	m2_t2	47	3.12	-4.62	2.55	-2.78	-1.05	-11.22	41.55	5.45	29.70	29.70
J	m2_t3	72	3.12	-4.62	1.25	5.72	-1.05	17.58	77.55	-5.55	30.80	30.80
合計												2420.70

表 21.14　混合計画 (A: 群間，B: 群内) の分散分析表の構造

Source	中身	F 値の分母	内 × 内で対応する項
A	A の効果	s × A	A
s × A	各群の中での個人差 (A の誤差)	—	s と A x s が合わさったもの
B	B の効果	s × A × B	B
A × B	A と B の交互作用	s × A × B	A × B
s × A × B	B に伴う誤差 (B・A × B の誤差)	—	B × s と A × B × s が合わさったもの
Total	全体の変動		Total

21.5 課題

■Within 計画の分析例 本講で扱ったのと同じような，一要因 3 水準 Within 計画のデータを表 21.15 のように用意しました。要因の効果，個人差，誤差の大きさ (平方和) を計算する練習をしてみましょう。さらに，自由度・平均平方・F 値を求め，表 21.4 の形の分散分析表にまとめてみましょう。

表 21.15 効果，個人差，誤差の計算練習

ID	Time1	Time2	Time3
A	48	48	40
B	49	51	45
C	58	59	46
D	46	44	37
E	52	52	46

第 22 章

R による Within デザインの分散分析

前回は群内要因 (Within Design) の理論について学びました。今回は R を使って実際に群内計画の分散分析を行う方法について学びます。具体的には，anovakun 関数を用いて，一要因および多要因の群内計画の分散分析を実行し，その結果を解釈する方法について解説します。また，分析結果の可視化方法についても学びます。

22.1 一要因 Within 計画の実際

まずは RStudio を起動し，この授業のプロジェクトフォルダを開いてください。新しいスクリプトファイルを準備して，anovakun 関数を読み込みましょう。読み込み方は第 20 講で説明したとおりですから，忘れた人は確認してください。

1. RStudio を起動する。
2. この授業のプロジェクトを開く。
3. 新しいスクリプトファイルを開く。一行目に `rm(list=ls())` と書くとなお良い。
4. anovakun 関数を読み込むコードを書く。コードは `code:22.1` の通り。
5. environment タブに anovakun 関数が読み込まれたことを確認する。

code : 22.1 ソースを読み込む

```
1 # プロジェクトフォルダにソースコードをダウンロードしていればこちら
2 source("anovakun_489.txt")
3 # ダウンロードしていない場合はこちら(行頭の#を外してネットから読み込む)
4 # source("https://bit.ly/3WL8VYR")
```

さて，準備ができたところで実際に Within 計画の例をやってみましょう。仮想データは前回用いた，次のような表 22.1 を使います (表 21.1 と同じものを再掲しています)。

表 22.1 Within Data Example

ID	Time1	Time2	Time3
1	10	5	9
2	9	4	5
3	4	2	3
4	7	3	5

これをデータフレーム型にします (code:22.2)。

code : 22.2 データフレームにする

```
1  Example3 <- data.frame(ID=1:4,
2  Time1 = c(10,9,4,7),
3  Time2 = c(5,4,2,3),
4  Time3 = c(9,5,3,5))
```

線形モデルとして表現するには，少し複雑な操作が必要ですので，今回は分散分析的アプローチのみ紹介したいと思います。

群内モデルの anovakun での入力は次のようになります (code:22.3)。

code : 22.3 anovakun で実行

```
1  anovakun(Example3[, 2:4], "sA", 3, eps = TRUE)
```

データセットや変数の指定，効果量オプションの指定はとくに追記することはありません。デザインの指定が"sA"と s の右側に来ているところがポイントです。これを実行すると，ずらりと結果が示されます。以下，順に結果の読み方を解説します。

22.1.1 球状性の検定

結果の最初に，記述統計と球状性の検定の結果が示されます。出力 22.1 の箇所を見てください。

R の出力 22.1: sA タイプの anovakun 出力 1; 記述統計と球状性の検定

```
<< DESCRIPTIVE STATISTICS >>

--------------------------
  A   n    Mean    S.D.
--------------------------
 a1   4  7.5000  2.6458
 a2   4  3.5000  1.2910
 a3   4  5.5000  2.5166
--------------------------


<< SPHERICITY INDICES >>

== Mendoza's Multisample Sphericity Test and Epsilons ==

------------------------------------------------------------------------
 Effect  Lambda  approx.Chi  df      p         LB     GG     HF     CM
------------------------------------------------------------------------
      A  1.0000     -0.0000   2 1.0000 ns  0.5000 1.0000 3.0000 0.5000
------------------------------------------------------------------------
                              LB = lower.bound, GG = Greenhouse-Geisser
                             HF = Huynh-Feldt-Lecoutre, CM = Chi-Muller
```

まず<< DESCRIPTIVE STATISTICS >>の部分があります。これは群ごとの平均と標準偏差なので，問

題ないでしょう。

次に<< SPHERICITY INDICES >>とありますね。これは**球状性の検定 (sphericity test)** と訳されます。急によくわからない言葉が出てきて驚かれたかもしれませんが，これが群内要因の分散分析における重要なポイントです。ちょっと長くなりますが，丁寧に説明していきます。

等分散性の仮定とその拡張

まず，t 検定のときに Welch の補正をしたのを思い出してください。t 検定はその仮定として，2 つの群がどちらも正規分布に従い，かつ 2 つの群の母分散が等しいと考えます。2 つの群を X_1, X_2 と表すと，

$$X_1 \sim N(\mu_1, \sigma), \quad X_2 \sim N(\mu_2, \sigma) \tag{22.1}$$

ということです。ここで N は正規分布，μ は平均値，σ は標準偏差を表しています[*1]。2 群それぞれの平均値が違うことを，μ_1, μ_2 と添え字をつけて区別しています。

さてしかし，実際には 2 つの群の母分散が等しいとは限りません。等しくない場合を式で書くならば，次のようになります。

$$X_1 \sim N(\mu_1, \sigma_1), \quad X_2 \sim N(\mu_2, \sigma_2) \tag{22.2}$$

標準偏差の方にも添え字がついて，σ_1, σ_2 と区別していますね。$\sigma_1 = \sigma_2$ という仮定は，母集団についての情報がない場合にはかなり限定的であると言えますので，一般には $\sigma_1 \neq \sigma_2$ である，と考えた方が現実的です。これに対応しているのが Welch の補正であり，R ではデフォルトでこちらを使うようになっています。

さて，実は分散分析の時も基本的に正規分布からデータが出てきており，またその母分散が同じであるという仮定があります。群間要因の場合，たとえば 3 つの水準があれば，それぞれの群のデータは次のように表現されます。

$$X_1 \sim N(\mu_1, \sigma), \quad X_2 \sim N(\mu_2, \sigma), \quad X_3 \sim N(\mu_3, \sigma) \tag{22.3}$$

この仮定が満たされない場合は，t 検定同様 Welch の補正をしなければなりません。Welch の補正を使う分散分析は R の `oneway.test()` 関数で実行できます (今回は割愛します)。

さて，では群内要因の場合はどうでしょうか？これが少しややこしいのですが，群内要因であるということは水準間に対応がある，独立ではないということです。独立ではないということを統計的にいうと，相関があるということです。つまり，水準 1 と水準 2 のデータが相関している，水準 2 と水準 3 のデータが相関している，水準 1 と水準 3 のデータが相関している，ということです。

相関し合うデータはどこから出てくるかというと，ただの正規分布ではなく**多変量正規分布 (multivariate normal distribution)** から出てくると考えます。多変量正規分布，たとえば 2 水準であれば 2 変量正規分布といいますが，これはそれぞれの側面から見ると正規分布なのですが，それらが互いに相関し合っていることを踏まえたものになっています。

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{pmatrix} \right) \tag{22.4}$$

[*1] このテキストでは，正規分布の幅を表すパラメータを標準偏差で書いています。これを単に二乗すれば，分散になります。

ここで $\begin{pmatrix}\mu_1\\ \mu_2\end{pmatrix}$ と書いてあるのは，2 つの平均値をセットにした平均ベクトルです。また，$\begin{pmatrix}\sigma_1^2 & \sigma_{12}\\ \sigma_{21} & \sigma_2^2\end{pmatrix}$ と書いてあるのは，分散共分散行列といって，対角要素にそれぞれの変数の分散が入り，非対角要素にそれぞれの変数間の共分散が入っています。

共分散は次のように考えましょう。まず相関係数は，標準化された共分散であり (第 6 講の第 6.3 節，p.86 を参照してください)，次のように表されます[*2]。

$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y} \tag{22.5}$$

右辺の分子が共分散ですから，

$$\sigma_{xy} = \rho_{xy}\sigma_x\sigma_y \tag{22.6}$$

となります。これを考えると，分散共分散行列は，$\begin{pmatrix}\sigma_1^2 & \sigma_{12}\\ \sigma_{21} & \sigma_2^2\end{pmatrix} = \begin{pmatrix}\sigma_1^2 & \rho_{12}\sigma_1\sigma_2\\ \rho_{21}\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}$ と書くことができます。

図 22.1　2 変量正規分布と周辺分布

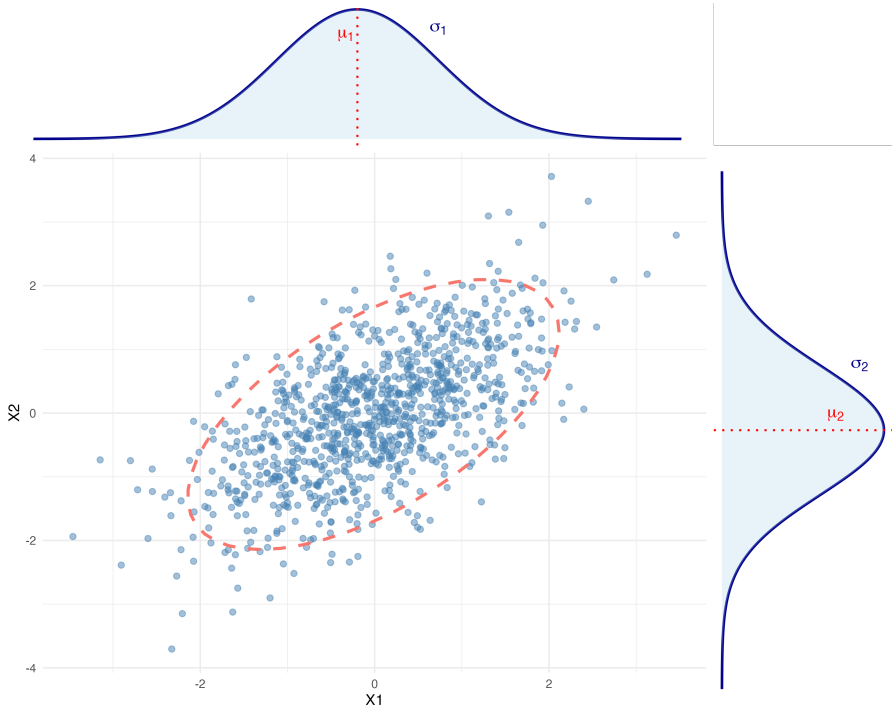

図 22.1 は 2 変量正規分布の例です。横軸が水準 1，縦軸が水準 2 のデータを表しています。ここで，横軸だけを見ると，水準 1 のデータは正規分布にしたがっていることがわかります。同様に縦軸だけを見ると，水準 2 のデータも正規分布にしたがっています。そしてそこから得られたデータが相関していることが，中央の

[*2] ここでは第 6 講の頃とは違い，推測統計学の世界に入っています。記述統計量はアルファベットでしたが，ここでは母数についてのモデルになっているので，ギリシア文字になっています。標本相関係数 r の代わりに母相関係数 ρ，標本標準偏差 s の代わりに σ を使っています。

散布図で確認できます。ここでは母相関 $\rho = 0.6$ の例を示しています。このように，多変量正規分布から出てきたデータは，各変数ごとに見ると正規分布に従う，という性質があります。

群内要因の場合は，各水準のデータがこのような多変量正規分布に従うと考えているわけです。また，図 22.1 は 2 変数 (2 水準) の例ですが，今回の例は 3 水準ですから，3 変量正規分布に従うと考えます。3 変量正規分布は立体図になり，4 変量以上になるともう図にはかけませんが，数学的には n 次元であっても同じように考えて利用します。

さて，この多変量正規分布における等分散の仮定ですが，すべての分散・共分散が等しいという仮定はなかなかに厳しそうです。そこで少し緩めて，**球状性の仮定 (sphericity assumption)** を置きます。これは，どの 2 つの水準を取り出しても，その差得点の分散が等しい，という仮定です[*3]。

群間要因で Welch の補正をしたように，群内要因ではこの仮定が満たされない場合，Greenhouse-Geisser の補正や Huynh-Feldt-Lecoutre などの補正と呼ばれる方法で，自由度を調整することで対応します。

球状性の検定結果の解釈

これが満たされない場合は，Greenhouse-Geisser の補正や Huynh-Feldt-Lecoutre などの補正をしなければならないが，どうでしょうね？ というのを確認するのがこの箇所です (R の出力 22.1)。今回は p が 1.000 で ns，つまり not significant=有意に歪んでいるとは言えない，ということなので補正は不要です。もしここが有意である，つまり丸いという状況から異なっている現状があると思われるのであれば，自由度などの補正が必要になります (anovakun はオプションで補正を指定できます)。

22.1.2 分散分析表の解釈と下位検定

その先にはやっと分散分析表が出てきました (出力 22.2)。これを見ると Source 列の s とあるところに個人差の平方和 (SS) と平均平方 (MS) が示されています。ここについては検定の対象外なので，F 値などの計算は行われていません。その下の A からが要因の効果で，s x A とあるところ，つまり A に伴って生じる個人差，のところが比較対象となる誤差のところです。この F 値が 16.00，$p = 0.0039$ で統計的に有意 (ちなみに効果量 $\varepsilon^2 = 0.3896$) なので，水準間のどこかには差があるということがわかります。

R の出力 22.2: 分散分析表の出力

```
<< ANOVA TABLE >>

------------------------------------------------------------------
 Source      SS  df      MS  F-ratio  p-value      epsilon^2
------------------------------------------------------------------
      s 39.0000   3 13.0000
------------------------------------------------------------------
      A 32.0000   2 16.0000  16.0000   0.0039 **      0.3896
  s x A  6.0000   6  1.0000
------------------------------------------------------------------
  Total 77.0000  11  7.0000
                  +p < .10, *p < .05, **p < .01, ***p < .001
```

[*3] 数学的には，水準間の差 (正規直交対比) の分散共分散行列が単位行列の定数倍になる (固有値がすべて等しい) ことを指します。

ちなみに，今回も eps = TRUE のオプションを指定しているので，効果量として ε^2 が計算されています。これは群内要因の効果量としてよく使われる指標で，今回はこれが 0.3896 となっています。これは中程度から大きな効果量であると考えられます。

さて，その下には下位検定の結果が示されています (出力 22.3)。今回は 3 水準のどこかに違いがある，ということがわかったのですから，具体的にどの水準とどの水準が違うのかを調べる必要があります。これを下位検定，事後検定，または多重比較などと呼ぶのでした。

R の出力 22.3: 下位検定の出力

```
<< POST ANALYSES >>

< MULTIPLE COMPARISON for "A" >

== Shaffer's Modified Sequentially Rejective Bonferroni Procedure ==
== The factor < A > is analysed as dependent means. ==
== Alpha level is 0.05. ==

--------------------------
  A   n    Mean    S.D.
--------------------------
 a1   4  7.5000  2.6458
 a2   4  3.5000  1.2910
 a3   4  5.5000  2.5166
--------------------------

-------------------------------------------------------------
  Pair     Diff  t-value  df       p   adj.p
-------------------------------------------------------------
 a1-a2   4.0000   5.6569   3  0.0109  0.0328  a1 > a2 *
 a1-a3   2.0000   2.8284   3  0.0663  0.0663  a1 = a3
 a2-a3  -2.0000   2.8284   3  0.0663  0.0663  a2 = a3
-------------------------------------------------------------


output is over --------------------///
```

anovakun ではデフォルトで，Shaffer の方法を使った事後の検定を行います。これによると，a1-a2 のペアは $a1 > a2$ の関係にあって有意で，そのほかのペアは有意ではない，ということがわかります。

これで結果を一通り眺めることができました。レポートに書くときは，たとえば次のように報告するといいでしょう。

> 一要因 3 水準の分散分析を行ったところ，$F(2, 6) = 16.00, p = 0.0039, \varepsilon^2 = 0.3896$ で統計的に有意であり，事後検定の結果 a1 水準が a2 水準よりも高いことが示された (Shaffer の方法による多重比較)。

22.2 二要因 Within 計画の実際

では引き続き，二要因の群内計画をやってみましょう。内 (2)× 内 (3) のデザインを考えます。カバーストーリーとしては，次のようなイメージです。

> ある学習方法 (M) が 2 種類 (m1,m2) あり，それぞれの方法で 3 回 (時間:t1,t2,t3) 学習したときの成績を比較したい。学生はそれぞれの学習方法で 3 回ずつ学習を行い，その成績を記録した。

仮想データは前回お示しした，表 21.5 を使います。学習方法の水準が m1,m2，時間の水準が t1,t2,t3 で，一人から 6 つのデータが得られています。可視化した図を図 22.2 に示します。

図 22.2 二要因被験者内デザインのデータの可視化

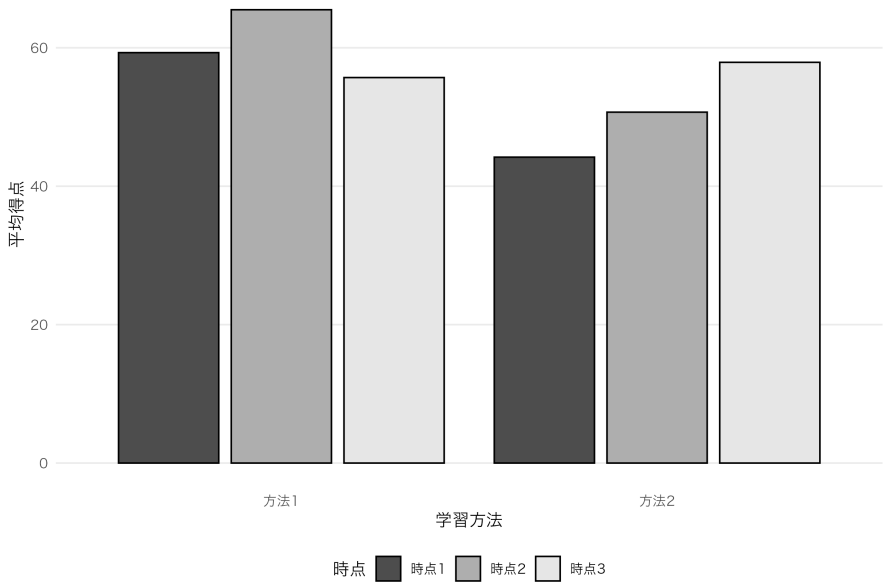

とりあえずこのデータを R に入力して，anovakun で分析してみましょう。ポイントは，要因デザインを"sAB"と入力するところと，A,B それぞれの水準数を 2,3 と指定するところです。また，球状性の仮定が破れている可能性を考えて，Greenhouse-Geisser の補正をかけるために gg = TRUE のオプションを追加してあります。コードは次のようになります (code:22.4)。

code : 22.4 二要因内 × 内デザインのデータと分析

```
dat <- data.frame(
  id = c("A", "B", "C", "D", "E", "F", "G", "H", "I", "J"),
  m1_t1 = c(47, 60, 79, 54, 55, 84, 63, 41, 53, 57),
  m1_t2 = c(90, 71, 83, 41, 41, 103, 74, 34, 65, 53),
  m1_t3 = c(44, 63, 48, 39, 58, 20, 96, 62, 44, 83),
  m2_t1 = c(38, 39, 60, 49, 45, 62, 46, 28, 35, 40),
  m2_t2 = c(55, 49, 47, 63, 49, 58, 48, 30, 61, 47),
  m2_t3 = c(52, 59, 50, 63, 54, 56, 57, 64, 52, 72)
)

```

```
11  anovakun(dat[, -1], "sAB", 2, 3, eps = TRUE, gg = TRUE)
```

今回も滔々と結果が出てきますが, 落ち着いて順番にみていきましょう。まずは球状性の仮定のチェックです (出力 22.4)。

R の出力 22.4: sAB タイプの anovakun 出力 1; 記述統計と球状性の検定

```
[ sAB-Type Design ]

This output was generated by anovakun 4.8.9 under R version 4.5.2.
It was executed on Tue Nov  4 16:40:26 2025.


<< DESCRIPTIVE STATISTICS >>

--------------------------------
  A   B   n     Mean     S.D.
--------------------------------
 a1  b1  10  59.3000  13.2920
 a1  b2  10  65.5000  23.0085
 a1  b3  10  55.7000  21.9952
 a2  b1  10  44.2000  10.6646
 a2  b2  10  50.7000   9.4169
 a2  b3  10  57.9000   6.7897
--------------------------------


<< SPHERICITY INDICES >>

== Mendoza's Multisample Sphericity Test and Epsilons ==

-------------------------------------------------------------------------
 Effect  Lambda  approx.Chi  df      p          LB     GG     HF     CM
-------------------------------------------------------------------------
 Global  0.0000     33.8813  14 0.0032 **  0.2000 0.3995 0.5134 0.4455
      A  1.0000     -0.0000   0            1.0000 1.0000 1.0000 1.0000
      B  0.0537      5.1974   2 0.0744 +   0.5000 0.6767 0.7542 0.6545
  A x B  0.1145      3.8528   2 0.1457 ns  0.5000 0.7235 0.8255 0.7163
-------------------------------------------------------------------------
                             LB = lower.bound, GG = Greenhouse-Geisser
                            HF = Huynh-Feldt-Lecoutre, CM = Chi-Muller
```

今回, グローバルな球状性の検定が $p = 0.0032$ で有意になっています。つまり, 球状性の仮定が破れている, と判断せざるを得ないですね。要因 A ではこの問題に該当しませんが, それ以外の要因についてはこの後，Greenhouse-Geisser の補正をかけた結果が使われます。分散分析表は次のようになっています。

R の出力 22.5: 分散分析表の出力

```
<< ANOVA TABLE >>

== Adjusted by Greenhouse-Geisser's Epsilon ==

-------------------------------------------------------------------------
   Source         SS    df        MS  F-ratio  p-value      epsilon^2
-------------------------------------------------------------------------
        s  2378.6833     9  264.2981
-------------------------------------------------------------------------
        A  1278.8167     1 1278.8167   7.1783   0.0252 *       0.0703
    s x A  1603.3500     9  178.1500
-------------------------------------------------------------------------
        B   450.1000  1.35  332.5749   0.6192   0.4939 ns     -0.0177
    s x B  6542.5667 12.18  537.1382
-------------------------------------------------------------------------
    A x B   980.6333  1.45  677.7204   3.6459   0.0667 +       0.0455
s x A x B  2420.7000 13.02  185.8841
-------------------------------------------------------------------------
    Total 15654.8500    59  265.3364
                            +p < .10, *p < .05, **p < .01, ***p < .001
```

さてご注目。一行目の小文字 s は個人差分散を表しています。これはこれまで通りですね。そのあとは要因 A,B の主効果と交互作用 (A×B) の要素が出ていますが，それぞれに対応する誤差項 (s x A, s x B, s x A x B) がついています。これが群内要因の分散分析のポイントです。群内要因における誤差は，個人差と要因の組み合わせによって生じるため，それぞれの要因ごとに誤差がどの程度あるかが変わるのです。群内要因の場合は「要因の効果」と「その要因に伴って生じる誤差」をセットで考えなければならない，ということですね。

詳しくみてみましょう。まず要因 A の効果の平方和 (SS) は 1278.8167 で，対応する誤差項 s x A の平方和は 1603.3500 です。要因 A は 2 水準 (m1,m2) ですから自由度 (df) は 1 で，要因 A に伴って生じる個人差の自由度は 9($= (10-1)\times(2-1)$) となっています。平均平方 (MS) は SS を df で割ったものですから，それぞれ 1278.8167 と 178.1500 になります。これらを使って F 値を計算すると，$F = 1278.8167/178.1500 = 7.1783$ となり，対応する p 値は 0.0252 で有意です。効果量 $\varepsilon^2 = 0.0703$ も計算されています。

次に要因 B ですが，平方和が 450.1000，対応する誤差項 s x B の平方和が 6542.5667 です。要因 B は 3 水準 (t1,t2,t3) ですから自由度は 2 で，要因 B に伴って生じる個人差の自由度は 18($= (10-1)\times(3-1)$) となっています。ただし今回は球状性の仮定が破れている可能性があるため，Greenhouse-Geisser の補正 (0.6767) をかけた自由度 1.35 と 12.18 が使われています。平均平方はそれぞれ 332.5749 と 537.1382 で，F 値は 0.6192，対応する p 値は 0.4939 で有意ではありません。効果量 $\varepsilon^2 = -0.0177$ も計算されています[*4]。

最後に交互作用 A×B ですが，平方和が 980.6333，対応する誤差項 s x A x B の平方和が 2420.7000 です。交互作用の自由度は 2 で，要因 A×B に伴って生じる個人差の自由度は 18($= (10-1)\times(2-1)\times(3-1)$) となっています。こちらも Greenhouse-Geisser の補正 (0.7235) をかけた自由度 1.45 と 13.02 が

[*4] ε^2 は，母集団の効果を偏りなく推定するために誤差の分を差し引いて計算するので，F 値が 1 より小さいときは負の値になります。この場合は，効果はほぼ 0 だと読めばよいでしょう。

図 22.3 二要因被験者内デザインの交互作用の可視化

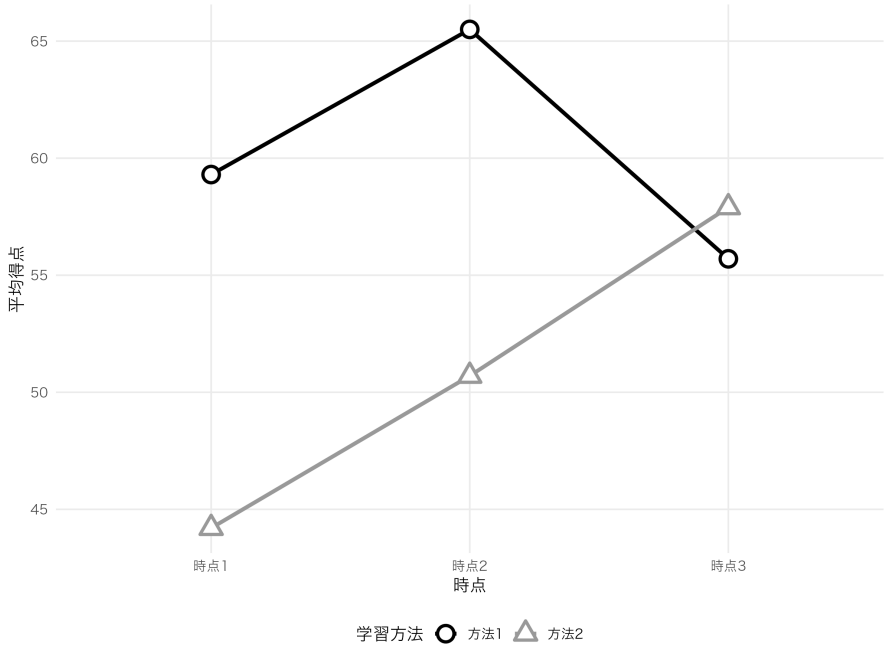

使われています。平均平方はそれぞれ 677.7204 と 185.8841 で，F 値は 3.6459，対応する p 値は 0.0667 で有意水準 0.05 では有意ではありませんが，0.10 では有意と考えられます。効果量 $\varepsilon^2 = 0.0455$ も計算されています。

これで，どこにどういう結果がでたかがわかりました。要因 A には有意な主効果があり，B には有意な主効果はなく，交互作用は有意水準 0.10 で有意である，ということですね。

さて，要因 A は 2 水準ですから母平均が違うということは，m1 の平均と m2 の平均が違うというだけですから，事後の検定は不要です。交互作用も有意ではないのですが，anovakun はデフォルトで 10% 水準未満であれば一応検討するということで，交互作用についての事後の検定が行われるようになります。

この後に続く事後の検定結果を見る前に，可視化してパターンをみておきましょう。図 22.3 に示します。

22.3 単純効果の分散分析表の分割

交互作用を細かく見る方法として，**単純効果 (simple effect)** の検定があります。たとえば，図 22.3 を見ると，t1 と t2 では m1 のほうが高く，t3 では m1 と m2 の差がほとんどないように見えます。このような場合，t1 のときに m1 と m2 の差が有意であるかどうかを調べることができます。これが単純効果の検定です。同様に，m1 のときに t1,t2,t3 の間に差があるかどうかも調べることができます。

単純効果を検定する際は，元のデータを見たいところに合わせて抽出し，小さいデータセットを作ってミニ分散分析を行う，というような形で行います。anovakun は自動的にこれらの結果も出してくれています。出力の次の箇所を確認してください (出力 22.6)。

R の出力 22.6: 単純効果の出力

```
<< POST ANALYSES >>

< SIMPLE EFFECTS for "A x B" INTERACTION >

-------------------------------------------------------------------------
  Effect  Lambda  approx.Chi  df      p         LB     GG     HF     CM
-------------------------------------------------------------------------
 A at b1  1.0000     -0.0000   0            1.0000 1.0000 1.0000 1.0000
 A at b2  1.0000     -0.0000   0            1.0000 1.0000 1.0000 1.0000
 A at b3  1.0000     -0.0000   0            1.0000 1.0000 1.0000 1.0000
 B at a1  0.0274      6.3967   2 0.0408 *   0.5000 0.6450 0.7068 0.6134
 B at a2  0.6628      0.7312   2 0.6938 ns  0.5000 0.9197 1.1447 0.9933
-------------------------------------------------------------------------
                              LB = lower.bound, GG = Greenhouse-Geisser
                             HF = Huynh-Feldt-Lecoutre, CM = Chi-Muller

-------------------------------------------------------------------------
     Source        SS    df        MS  F-ratio  p-value      epsilon^2
-------------------------------------------------------------------------
    A at b1 1140.0500     1 1140.0500  72.5376   0.0000 ***     0.2995
s x A at b1  141.4500     9   15.7167
-------------------------------------------------------------------------
    A at b2 1095.2000     1 1095.2000   4.7714   0.0568 +       0.1300
s x A at b2 2065.8000     9  229.5333
-------------------------------------------------------------------------
    A at b3   24.2000     1   24.2000   0.1199   0.7371 ns     -0.0371
s x A at b3 1816.8000     9  201.8667
-------------------------------------------------------------------------
    B at a1  491.4667  1.29  381.0058   0.5935   0.4978 ns     -0.0301
s x B at a1 7453.2000 11.61  642.0041
-------------------------------------------------------------------------
    B at a2  939.2667  1.84  510.6523   5.5980   0.0155 *       0.2429
s x B at a2 1510.0667 16.55   91.2200
-------------------------------------------------------------------------
                            +p < .10, *p < .05, **p < .01, ***p < .001
```

まずは, 単純効果の球状性の検定結果が示されています。要因 A の各水準における要因 B の単純効果, および要因 B の各水準における要因 A の単純効果について, 球状性の検定が行われています。b の各水準における A の効果は (2 水準しかないので) 球状性うんぬんの話ではないですが, a の各水準における B の効果については, a1 水準について $p = 0.0408$ で有意になっています。つまり, a1 水準のことを考えるときは, 球状性の仮定が破れている可能性がある, ということになります。ただし今回は `gg = TRUE` を指定していますので, 球状性の検定の結果にかかわらず, 群内の効果にはすべて Greenhouse-Geisser の補正がかかります。この後の分散分析表で, a1 水準だけでなく a2 水準における B の単純効果も自由度が小数 (1.84 と 16.55) になっているのはそのためです (2 水準しかない A の単純効果は補正の係数が 1 なので, 自由度は変わりません)。

以下は単純効果の分散分析表になります。

22.3.1 A at b_1 の単純効果

まずは A at b1 と書かれている箇所，つまり b_1(t1) の水準における A(方法) の単純効果を検定することを考えましょう。やっていることは，m1_t1 と m2_t1 のデータだけを使用した分散分析と同じです。つまり表 22.2 のようなデータに対して分散分析をしているようなものです。

表 22.2 A at b_1 の単純効果検定用データ (t1 のみ)

id	m1_t1	m2_t1
A	47	38
B	60	39
C	79	60
D	54	49
E	55	45
F	84	62
G	63	46
H	41	28
I	53	35
J	57	40

実際にこのデータに対して，一要因の群内計画の分散分析をやってみることができます。R では次のように実行します。

code : 22.5 A at b1 の単純効果検定

```
1 SimpleEffectA_at_b1 <- dat[, c(2, 5)]
2 anovakun(SimpleEffectA_at_b1, "sA", 2)
```

これで出力されるのは，ここの表に含まれているものと同じです (出力 22.7)。

R の出力 22.7: ミニデータの分散分析結果

```
  << ANOVA TABLE >>

------------------------------------------------------------
 Source         SS  df         MS  F-ratio  p-value
------------------------------------------------------------
      s  2472.2500   9   274.6944
------------------------------------------------------------
      A  1140.0500   1  1140.0500  72.5376   0.0000 ***
  s x A   141.4500   9    15.7167
------------------------------------------------------------
  Total  3753.7500  19   197.5658
              +p < .10, *p < .05, **p < .01, ***p < .001
```

ここでは有意であるという結果になっていますので，t1 のときには m1 と m2 の間に有意な差がある，ということがわかります。図 22.3 を見ても，t1 のときに m1 と m2 の差が大きいことがわかりますね。

22.3.2 B at a_2 の単純効果

以下同様の分割・分析が行われており，もう一つ有意なマークがついているのが，`B at a2` の箇所です。これは m2 のときに t1,t2,t3 の間に差があるかどうかを調べる単純効果の検定です。こちらも同様にミニデータを作って分散分析を行うことができます (表 22.3)。

表 22.3 B at a_2 の単純効果検定用データ (m2 のみ)

id	m2_t1	m2_t2	m2_t3
A	38	55	52
B	39	49	59
C	60	47	50
D	49	63	63
E	45	49	54
F	62	58	56
G	46	48	57
H	28	30	64
I	35	61	52
J	40	47	72

このデータに対して，一要因の群内計画の分散分析を行います。R では次のように実行します。

code : 22.6 B at a2 の単純効果検定

```
1 SimpleEffectB_at_a2 <- dat[, c(5, 6, 7)]
2 anovakun(SimpleEffectB_at_a2, "sA", 3, gg = TRUE)
```

もっとも，同じ結果はすでに全体の分析結果の中に含まれているので，あえて実行する必要はありません。ここでは全体出力の最後のところを抜き出してみました (出力 22.8)。

これは a2 水準における要因 B の効果を検証しているところで，これが有意 ($F(1.84, 16.55) = 5.5980, p = 0.0155, \varepsilon^2 = 0.2429$) だったのですから，t1,t2,t3 間のどこかに差があったわけです。どこに差があったのかがわからないので，さらに事後の検定が行われています。それが `< MULTIPLE COMPARISON for "B at a2" >`のところなのです。

R の出力 22.8: B at a2 の多重比較 (全体の出力から抜粋)

```
< MULTIPLE COMPARISON for "B at a2" >

== Shaffer's Modified Sequentially Rejective Bonferroni Procedure ==
== The factor < B at a2 > is analysed as dependent means. ==
== Alpha level is 0.05. ==

-----------------------------------------------------------
  Pair      Diff  t-value  df       p   adj.p
-----------------------------------------------------------
 b1-b3  -13.7000   3.0119   9  0.0147  0.0440  b1 < b3 *
 b1-b2   -6.5000   1.8622   9  0.0955  0.0955  b1 = b2
 b2-b3   -7.2000   1.7230   9  0.1190  0.1190  b2 = b3
-----------------------------------------------------------
```

これを見ると，t1 と t3 のペアが有意であることがわかります。つまり，m2 のときには t1 と t3 の間に有意な差があった，ということですね。図 22.3 を見ても，m2 のときに t1 と t3 の差が大きいことがわかります。

22.4 分散分析のまとめ

長い道のりでしたが，これで一通り分散分析の説明は終わりです。最後に，分散分析のポイントをまとめておきましょう。

- 分散分析は，データのばらつきを要因ごとに分解し，その要因がデータに与える影響を検証する手法である。
- 「分散」分析という名前がついているが，目的は平均値の比較である。「分散」という名前がついているのは，比較に際して要因が引き起こすばらつき (分散) と，説明できないばらつき (分散) を比較するからである。
- 分散と分散の比較の確率分布は F 分布である。
- 群間計画では，各要因の効果と全体の誤差項を使って F 値を計算する。
- 群内計画では，各要因の効果とそれに伴って生じる誤差を使って F 値を計算する。
- 要因が 2 つ以上になると，組み合わせの効果すなわち交互作用も検証する。
- 水準が 3 つ以上になると，どの水準間で差があるのかを調べるために事後の検定を行う。

最後の内 × 内デザインでみたように，交互作用の下位検定 (単純効果の検定) では，分散分析表をさらに分割して，ミニ分散分析を行うことで検証を行っていきます。これが分散分析の基本的な考え方です。

また水準が多い場合は，タイプ 1 エラーが起きる確率 (α, 有意水準に同じ) を制御するために，様々な補正をかけた分析を行います。Holm の方法や，Shaffer の方法 (修正 Bonferroni 法の一つ) などがそれです。anovakun ではオプションでこれらを選べます。

分散分析は，多様なデザインに対応できる強力な判断技術です。数字の計算は困難に見えるかもしれませんが，難しい (difficult) のではなく，簡単 (easy) な要素が複雑 (complex) に絡み合っているのでそう見えるだけなのです。実際，分散分析は手計算でも効果や誤差を計算できるわけです。それを統計パッケージ R が代わってくれるので，結果はますます簡単に得られます。

ユーザである我々に必要なのは，正しく結果を読み取り，解釈する能力です。あるいは，分散分析に落とし

込めば良い問題を見つける，分散分析で解決できるように実験をデザインする能力です。それは心理学を学んでいくなかで，自然と身につくでしょう。

ただ残念ながら，分散分析はレガシーといいますか，古典的な技術です。進んだ心理学の研究では，分散分析をより発展させたモデル，線形モデルをより展開したモデルが使われています。次回からは線形モデルを拡張するのに必要な，確率分布と線形モデルの合体について学んでいきましょう。

22.5 課題

本文の二要因群内デザインのデータ (dat，表 21.5) を使います。本文では，a2 水準における要因 B の単純効果 (B at a2) を，ミニデータを作って確かめました (code:22.6)。同じやり方で，a1 水準における要因 B の単純効果 (B at a1) を確かめてみましょう。

1. dat から学習方法 m1 の 3 回分 (m1_t1，m1_t2，m1_t3) だけを取り出したデータフレームを作るコードを書きましょう。
2. anovakun 関数を使って，一要因 Within 計画 ("sA"型) として分析するコードを書きましょう。Greenhouse-Geisser の補正をかけ，効果量 ε^2 も表示すること。
3. 結果を読み，球状性の仮定が満たされていたか，a1 水準で時間 (t1，t2，t3) の効果が統計的に有意であったかを答えてください。また，全体の分析 (code:22.4) の出力にある「B at a1」の行と同じ結果になることを確かめてください。回答はスクリプトの中に，コメントアウトして書いてください。

第 23 章

確率モデルと尤度

検定では平均因果効果を検証するため，平均値や (不偏) 分散などの標本統計量がどのような確率分布に従うかを参照し，結果を判定するという使い方を行なってきました。検定はこのように，母数を推定する方法に，結果を判定するロジックが組み合わさったものなのでした。この時の母数の推定方法は，標本平均や不偏分散を推定値とする方法で，モーメント法とよばれるものです。これに対し，モデルである確率分布をデータに最も近しい形に調節することで，そのパラメータを推定値とする方法があります。ここではこの方法，最尤推定法とその根幹にある尤度という考え方を解説します。

23.1 確率モデルによる推論

もう一度，統計的推論の基本を振り返ってみましょう。

私たちは，手元にあるデータの状態を記述するだけでなく，これを使って「推論」をしたいわけです。覚えていますか？ 手元のデータ (標本) において，群間に差があるかどうか！なんて考えなくても「そりゃあるでしょ」となります。微細な差でも差は差ですから，それは違いありません。問題は，手元の標本の特徴を使って，「だから人間は･･･」などと大きな主語のことを言おうとすると，ちょっと待て待て，となるわけです[*1]。たまたま標本の数字がそうだっただけじゃないか，というわけですね。ここでいう「大きな主語のことを言おうとする」，というのが統計的推論という話なので，そもそも雲を掴むようなというか，無理難題に挑戦しているというのが大前提，何も確定的に言えないんじゃないかとさえ思えてきます。

そこをぐっと堪えて，仮に，仮にですよ？ 仮に母集団の数字が正規分布に従うと仮定できるのであれば，そこから原理的に標本統計量の特徴が導かれますから，それを使って推論しようよ，という話をしてきたのでした。

さて，今回までの話は母集団が正規分布するなら，標本統計量がある程度の幅を持った正規分布に従うので，標本平均や標本分散を使って推定しましょう，というアプローチをとってきました。平均値や分散など，標本の特徴そのものから母数を推定してきましたが，今回からお話しするのは少し異なるアプローチです。それは，**確率モデル (stochastic model)** の考え方の入り口であり，これを知ることで線形モデルの表現がより豊かになっていきます。

[*1] でも人間は，自分の経験を使っていろいろ言いたい生き物です。政治家だって，タレントだって，それでいろいろ失敗してますよね。でもたとえば「どうして男性は浮気するのか！」と怒っている人に「サンプルサイズが少なすぎる。それでは妥当な推論ができないから，せめて 20 人以上と交際してから言え」なんていうと逆ギレされるかしらけられるかのどちらかです。統計家は辛いよ。

23.2 確率関数と尤度関数

確率とデータの関係について，改めて考えてみましょう。

確率分布の形がわかっていて，パラメータもわかっていたとします。たとえば $\theta = 0.5$ のベルヌーイ分布だとか，平均値 $\mu = 5$，標準偏差 $\sigma = 1$ の正規分布，といった具合に。そうすると，そこからデータがどう出てくるかを考えることができます。ベルヌーイ分布の例がわかりやすいので，それで考えてみましょう[*2]。とあるコインの表が出るか裏が出るかが，$\theta = 0.5$ のベルヌーイ分布に従う，というのがわかっていたら，きっと表 (1) と裏 (0) が半々で出てくるだろうな，と思えるわけです。$\theta = 0.7$ であれば，こりゃ表がよく出てくるだろうな，といったことがわかります。

ただ私たちが，確率的なことを考える時というのはもっぱら逆です。表，表，裏，表，表･･･とどうも表がたくさん出てくるという現実があり，「これのパラメータは $\theta = 0.5$ ではないのではないか (半々じゃない，イカサマコインだ)」といったように，実現値が既知でパラメータが未知な状況です。研究をしている時も，手元にデータがあって，パラメータがわからないわけです。これまで推論してきた母平均，母分散というのもパラメータですが，そこから得られたと思しきデータを使って推論してきたのでした。

もう少し考えを深めてみましょう。ベルヌーイ分布は次のような確率分布です。

$$p(k) = \theta^k (1-\theta)^{1-k}$$

ここで k は 1 か 0 のどちらかの数字をとります。表が出る確率 $p(1)$ は，$\theta^1(1-\theta)^0 = \theta$ になり[*3]，裏が出る確率は $p(0) = \theta^0(1-\theta)^1 = (1-\theta)$ になる，ということを数式で書くとこうなるのです。試しに $\theta = 0.7$ とすると，表が出る確率が 0.7 で裏が出る確率が 0.3 になっていますね。わかりやすい。

ここで $\theta = 0.7$，のようにパラメータがわかっている状況は普通とは逆なのですから，パラメータがわからない未知のまま (θ の記号のまま) 考えを進めたいと思います。もしコインが表，表と 2 回続けて表が出るとすると，その確率は $\theta \times \theta = \theta^2$ です。3 回続けて出たら θ^3，表，表，裏，裏，表なら $\theta^3 \times (1-\theta)^2$，と文字を使って表現できます。ここで θ は 0 から 1 の間を取る数字ですから，横軸に θ をとり，縦軸に $y = \theta^3 \times (1-\theta)^2$ として関数のグラフを書くことができますね。これを書いたのが図 23.1 です。これはパラメータがどのあた

図 23.1 「表，表，裏，裏，表」と出たコインのパラメータの関数

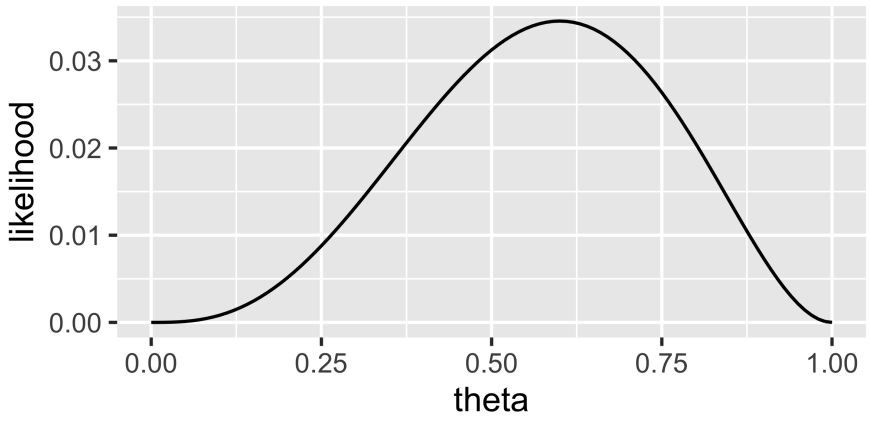

[*2] ベルヌーイ分布については第 10 講，セクション 10.3,Pp.147 を参照。

[*3] ある数字の 0 乗は 1 になる，というのが累乗の計算のルールです。

りにありそうか，という情報を持ったグラフになっています。このように，データが既知でパラメータが未知のとき，パラメータの関数のことを**尤度関数 (likelihood function)** といい，このグラフの縦軸 y のことを**尤度 (likelihood)** と言います[*4]

尤度関数は確率関数と形 (Form) は同じですが，考える向きを逆にしたものだと言えます。つまり，

- 確率関数；パラメータがわかっている → 実現値がどのように出てくるかを表現
- 尤度関数；実現値がわかっている → パラメータがどのあたりならこのデータが得られそうかを表現

という関係にある，というわけです。

23.3 最尤推定

さてこの尤度関数，横軸が θ ですから，いろいろな θ のときにこのデータが得られる可能性はどれぐらいありそうか，というグラフだといえます。そうするとこの山のピーク，ここでは $\theta = 0.6$ なのですが，これが「このデータから考えられる最もありえそうなパラメータの値」ということになります。尤度が最大になるところをそのパラメータの推定値とする，という意味で，この推定値を**最尤推定値 (maximum likelihood estimate)** といい，この方法でパラメータのことを推定する方法を**最尤法 (maximum likelihood method)** といいます (さいゆう推定，と読みます。略して ML 法とかかれることも)。

5 回中 3 回表が出たから，パラメータは 0.6 なのは当たり前じゃないか，と思ったかもしれません。それは標本平均を使って推定した，ということですが，同じ現象・データなので推定値が同じになるのはまあ当然のことです。答えは同じなのですが，その答えを出した筋道が違う，ということに注目してください。

最尤法は，関数の最大値を求めることによって最尤推定値を算出します。「関数の最大値を求める」という方法は，具体的には微分をつかって極値を求めることになります。微分について，高校数学で学んできたことを思い出して欲しいのですが，要するに「関数の傾きがフラットになる (傾き 0) ところがその関数の最大値，あるいは最小値になっている」という性質から，傾きの関数を求めてそれがどこなのか，を突き止める方法であり，まさに今回のようにピークを求めるにはもってこいのツールだったわけです[*5][*6]。

細かい数式はともかく，要するに関数のピークは最も尤もらしい，つまりこのデータが出てくる確率を最大にする値としてパラメータを推定できるということです。

ここで一点，注意を促しておきます。尤度関数は，確率分布関数の未知数と既知数を取り換えただけのものです。確率分布関数は，確率の出目 (実現値) に対応する確率の一覧を数式で表現したものだったことを思い出してください。また，確率とは非負で，その総和が 1.0 になるような数字なのでした。ここで図 23.1 を

[*4] ゆうど，と読みます。犬度 (いぬど) ではありません。尤度の尤は，「もっとも」と読み「尤もらしい」といったりします。

[*5] 高校までの数学は，こうした目的を先に教えておいてくれたらイメージしやすいのですが，先に概念や計算方法だけ教わるので苦手意識を持っている人もいるかもしれません。完成図を見ずにパズルのピースだけ渡されても，興味は持ちにくいかもしれませんが，幸い目的を持って学び始めると，いつ・どこから始めても必ず道がつながっているので，いつでも学び直すと良いでしょう。

[*6] 今回，この関数を微分すると，

$$\begin{aligned} y &= \theta^3(1-\theta)^2 \\ &= \theta^3(1-2\theta+\theta^2) \\ &= \theta^3 - 2\theta^4 + \theta^5 \text{より} \\ y' &= 5\theta^4 - 8\theta^3 + 3\theta^2 \\ &= \theta^2(5\theta^2 - 8\theta + 3) \end{aligned}$$

ここで $y' = 0$ とおいて極値を求めると

$$(5\theta^2 - 8\theta + 3) = (\theta - 1)(5\theta - 3)$$

より，$0 < \theta < 1$ の範囲では $\theta = 3/5 = 0.6$ が極大ということになります。

見ていると，これもなんだか確率分布のように見えたりもしますが，実はこれは確率分布ではありません。というのも，この関数の面積が 1.0 にならないからです。

簡単な例で解説しましょう。コイントスを 2 回連続でやることを考えてみたいと思います。この時何回表が出てくるかは，0 回 (裏･裏)，1 回 (裏･表，表･裏),2 回 (表･表) のいずれかです。

表 23.1　コインを二回トスします。

θ	0 回	1 回	2 回	合計
0.00	1.00	0.00	0.00	1.00
0.25	0.5625	0.375	0.0625	1.00
0.50	0.25	0.50	0.25	1.00
0.75	0.0625	0.375	0.5625	1.00
1.00	0.00	0.00	1.00	1.00
合計	1.875	1.25	1.875	

表 23.1 をみてください。これはコインを 2 回トスして，何回表が出たかについて，θ をいろいろに変えて計算してみた表です。たとえば $\theta = 0.0$ であれば，完全に裏しか出ないコインなのですから，0 回の確率が 100% で，1 回，2 回出る可能性は 0% です。この行方向の総和は 1.00 になっています。どの行についても，行の総和は $1.00 = 100\%$ で，θ が決まっているとしたらデータがどうなるかの確率は計算できるわけです。

一方，2 回コイントスして，1 回も表が出なかったという事実が先にあったとします。表 23.1 でいうところの 0 列，縦方向にみるのですね。θ は 0 から 1 のどこかにあるのですが，$0.00, 0.25, 0.50, 0.75, 1.00$ の 5 パターンだけピックアップしてみてみても，その総和は 1.00 を超えています。これを見ると，1 回も表が出ないパターンというのは，$\theta = 1.0$ であるはずがなく，$\theta = 0.75$ のような高い確率でもなさそう，$0.5, 0.25$ とパラメータが小さくなるにしたがって「そうなりそうな度合い」は高くなっていき，$\theta = 0.00$ であるというのが一番あり得そうではありますが，$\theta = 0.00$ の確率が高い，とは言えないのです。列の総和が 1.00 にならないから，これ (尤度) は確率じゃないからです。尤度は確率ではないのです[*7]。

尤度が最も高い，というのはそうなる可能性が最も高いわけですが，この数字は確率じゃない – ちょっと面倒な感じですが，言葉を正確にいうとこうなりますので，ご容赦ください。あくまでも，もっともらしさ，それっぽさが最大になるように推定値を定めるというのが最尤推定の正しい説明になります。

23.4　対数尤度関数

ところで，尤度の最大値を求める計算は，微分を使うのでちょっと面倒だな，と思うかもしれませんが，具体的な数値にしてしまえばそれほど大変ではありません。たとえば先ほどの例，ベルヌーイ試行 (コイントス) で表が 3 回，裏が 2 回でた，という場合ですが，$\theta = 0.3$ であれば，

$$0.3^3 \times (1 - 0.3)^2 = 0.3 \times 0.3 \times 0.3 \times 0.7 \times 0.7 = 0.01323$$

と計算できます。最尤推定値である $\theta = 0.6$ は，その尤度が

$$0.6^3 \times (1 - 0.6)^2 = 0.6 \times 0.6 \times 0.6 \times 0.4 \times 0.4 = 0.03456$$

である，と計算できるわけです。もちろん R などコンピュータに計算させれば良いわけですが，問題はこれ，数字が小さいってことなんですよね。

[*7] この表を使った説明の仕方は，私がみてきた「尤度は確率じゃない」の説明の中で最もわかりやすいもので，Lambert (2018) にあった説明の仕方です。ここではその数字を少し改変して紹介しました。

そもそも確率は 1 を超える数字になることがないので，小さい数字に小さい数字を次々掛け合わせていくと，どんどんと桁数が小さくなります。コンピュータは計算機ですから，「掛け算せよ」と言われたらどこまでも掛け算はしますが，その内部では数字とは言え 0/1 のビット情報の連なりで，物理的上限があるので無限に小さな数字を計算できるわけではありません。無限どころか，たとえば今の PC は 64 ビット OS が基本ですが，どんなコンピュータも数字に割り当てられる上限を持っています[*8]。64 ビット OS の場合は，1 つの数字に 64 ビットの情報を持たせますが，これは桁数でいうと 2^{64}，およそ 20 桁の計算が限界です。何が言いたいかというと，コイントスが全部で 5 回ぐらいならコンピュータで計算できますが，10 回，20 回となるとだんだん限界に近づいて，そのうち「これ以上は小さすぎて計算できません！」というエラーが出てくるということです。

そこで実際の計算には少し工夫が必要です。尤度関数をそのまま使うのではなく，尤度関数の対数をとって計算するというのがそれにあたります。

対数 (logarithm) というのは，その数字を何乗したかというのを表すための表記法で，log という記号を使います。$a^p = M$ のときに，$p = \log_a M$ と表記し，この時「p を a を底とした M の対数」という言い方をするのです。これが便利なところとして，対数にしても数字の大小関係は変わらないこと，掛け算が足し算に，割り算が引き算に変わるので計算がしやすいことなどが挙げられます[*9]。記号を使ってより正確に書いておきますと，次の通りです。

- $M > N$ のとき，$\log_a M > \log_a N$；たとえば $100 > 10$ だが，$\log_{10} 100 = 2, \log_{10} 10 = 1$ より $\log_{10} 100 > \log_{10} 10$ です。
- $\log_a MN = \log_a M + \log_a N$；たとえば $\log_2 8 = 3, \log_2 16 = 4$ ですが，対数の定義より $2^3 = 8, 2^4 = 16$ という関係を表していることになります。ここで $\log_2 8 \times 16$ は，$2^3 \times 2^4$ の $\log_2$ をとったもの，ということになりますが，$2^3 \times 2^4 = 2^{(3+4)} = 2^7$ ですから，$\log_2 8 \times 16 = \log_2 8 + \log_2 16$ と，掛け算が足し算になります。
- $\log_a \dfrac{M}{N} = \log_a M - \log_a N$；これも同様に，$\log_2 \dfrac{16}{8} = \log_2 2 = 1$ ですが，$\log_2 16 - \log_2 8 = 4 - 3 = 1$ で計算できます。

たとえば先ほどのコイントスの計算も，$\theta = 0.3$ の例について対数を取って計算すると[*10]，

$$\log(y) = 3 \log 0.3 + 2 \log 0.7 = 3 \times -1.203973 + 2 \times -0.3566749 = -4.325268$$

となり，「桁数が小さすぎて計算できない」という問題が生じなくなります。また，対数をとったグラフは図 23.2 のようになりますが，ピークの箇所は変わらないことが確認できます[*11]。

23.5 正規分布の尤度関数

対数の話は計算上の問題なので知識として頭の片隅に置いておいてもらったら OK です。それよりも，関数の形をそのまま使ってパラメータを推定できる，ということをしっかり踏まえていただければと思います。この方法だと，不偏推定量を考えるとか，標準誤差を考えるといったことがなくなるので，もしかするとこちらの

[*8] 1995 年に Windows95 という OS が出ましたが，それは 32bit が単位の OS でした。Nintendo のファミリーコンピュータは 8bit で，Nintendo64 というハードは 64bit 単位で計算できるようになった，ということを示すために「64」が入っているのです。

[*9] 対数はそもそも天文学など，桁数がとても大きな数字の計算に使われるものでした。対数を取るとどういう数字になるか，という対応表を考えたネイピアさんのおかげで，天文学者の寿命は 2 倍に伸びたと言われるほど画期的に便利な発明でした。

[*10] この時の底は何? と思うかもしれません。とくに明示されていない場合，底は自然対数 e を取ります。e はネイピア数とも呼ばれ，2.7 ぐらいの数字です。π のように，数学でよく出てくる定数の一種です。あるいは 10 を底にすることもあり，こちらは常用対数と呼ばれます。

[*11] 正直わかりにくいよね，でもあってますからご容赦。

図 23.2 「表, 表, 裏, 裏, 表」と出たコインのパラメータの関数について対数をとったもの。縦軸は対数尤度

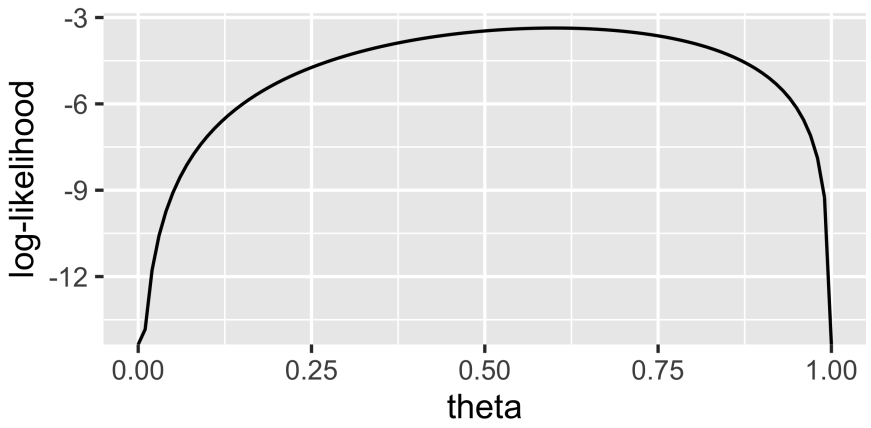

方が楽だな, と思われるかもしれません。注意しておきたいのは, これは「ある推定値が得られる確率」を考えているわけではないことです (尤度は確率ではないので)。また, データに最もぴったり合うようにパラメータを定めた, という方法なだけで, そもそもデータに当て嵌める確率分布関数 (=確率モデル) が間違っていたら, 何の意味もないことに注意してください。コイントスの結果にはベルヌーイ分布 (あるいは二項分布) を当て嵌めるのが正しく, 他の分布 – たとえば正規分布 – を考えると「答えは出るけど, そもそも全部間違ってる」というような話になります[*12]。とは言えここまで見てきたように, 心理学の場合は, 多くのデータに正規分布を仮定できます。私たちは正規分布という「仮定」, 「モデル」をおいて現象を理解しようとしているんだ, ということを忘れないでください。

そう言えば, 正規分布を使った最尤推定はどうなるんでしょうね。正規分布は平均 μ と標準偏差 σ という 2 つのパラメータで調整されますから, この 2 つのパラメータが両方未知であるという連立方程式を解くことになります。

数値例を使って考えてみましょう。たとえば「ある小さな学校で身体測定をしたところ, 3 人の身長はそれぞれ, 165cm,173cm,182cm だった」という話で考えてみたいと思います。話を単純にするために, 母標準偏差は $\sigma = 10$ だとわかっていたとします。こうすることで, 先ほどのベルヌーイ試行と同じで推定すべきパラメータはひとつ, μ だけになります。ここで知りたいのは, どんな μ をもった $N(\mu, 10)$ から $\{165, 173, 182\}$ というデータが得られたか, ということです。

仮に $\mu = 160$ として考えてみます。データの 165 という数字が $N(160, 10)$ から出てくる尤度 (尤もらしさ) を計算したいのですが, まず正規分布の式を再確認しましょう。次のような式でしたね。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

ここで, データ $x = 165$ というのが, $\mu = 160, \sigma = 10$ というパラメータのもとで出てきたとすると, 数字を代入しますから,

$$\frac{1}{\sqrt{2\pi \times 10^2}} \exp\left(-\frac{(165-160)^2}{2 \times 10^2}\right) = 0.03520653$$

[*12] 適切な確率分布関数を選択できていないことなどを総称して, モデル誤設定問題と言います。

となります[*13]。同じように，この正規分布 $N(160, 10)$ から 173 というデータが出てくる尤度は，

$$\frac{1}{\sqrt{2\pi \times 10^2}} \exp\left(-\frac{(173-160)^2}{2 \times 10^2}\right) = 0.01713686$$

となります。また，182 というデータが出てくる尤度は，

$$\frac{1}{\sqrt{2\pi \times 10^2}} \exp\left(-\frac{(182-160)^2}{2 \times 10^2}\right) = 0.003547459$$

となります。ちなみにこれらの数字は，R で `dnorm(165,mean=160,sd=10)` とすれば得られます。

イメージで考えてみるとわかりやすいかもですね。図 23.3 に $N(160, 10)$ から 3 つのデータ点 165，173，182 が出てきたシーンを図示しました。

図 23.3 $N(160, 10)$ から 165, 173, 182 というデータが出てくる

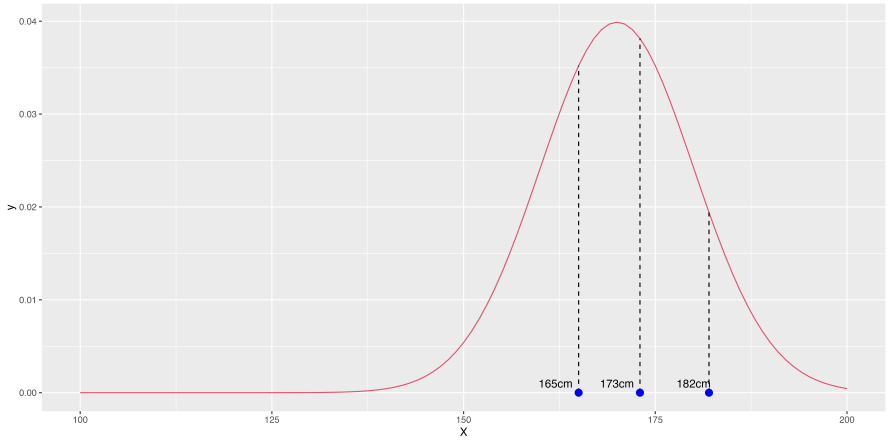

これと同様の計算は，さまざまな μ について実行することができます。試しに $\mu = 150$ の時の図と，$\mu = 180$ の時の図を書いたものを図 23.4 に示します。

図 23.4 上の図は $N(150, 10)$，下の図は $N(180, 10)$ の例

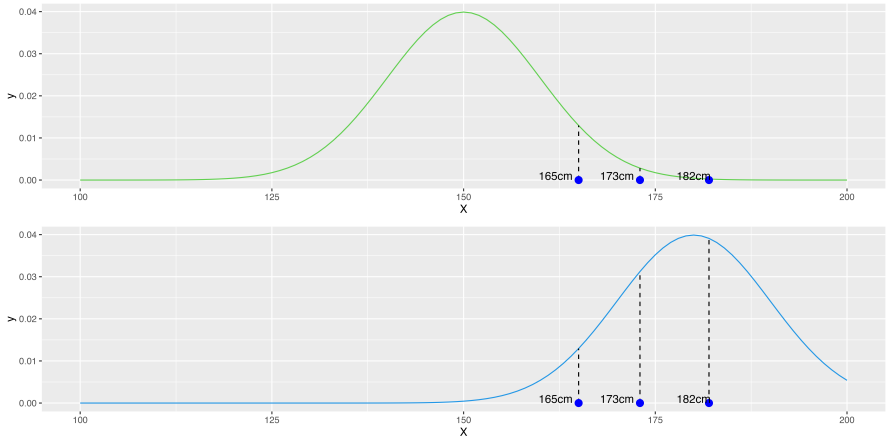

[*13] 確認ですが，$\pi = 3.1415...$ という数字，$\exp(x)$ は $\exp(x) = e^x$ という指数関数で，ここで $e = 2.71828...$ という数字ですので，この式に未知数はないのです。

この図を見ると明らかなように，今回はいい μ を探したいのですが，正規分布の幅が決まっているので結局は山の平行移動をしていることになりますね。

さて，これら 3 つのデータは同じ母集団から独立に得られているわけです。独立に，というのはデータ間にとくに関連がないことですので，この 3 つが同時に成立する確率は掛け算で表すことができます。

考えてみてください。コイントスの場合もこの同じ分布から独立して得られている，という仮定がありました。同じコインですから同じ確率分布を仮定できます。**独立**というのは前の試行が次の試行に影響を与えない，という意味です。コイントスしたときにコインが歪んでしまった (違う θ になった)，というようなことは考えていませんし，コインが「前は表になったから今度は裏を出してやろう」と考えるわけではありませんから，毎回確率 θ で表か裏になるはずです。ですから，繰り返したときに，掛け合わせて考えたのでした。ちなみにこの仮定のことを**独立同分布 (independently and identically distributed)** といい，i.i.d と略記して表現することがあります。

さて今回の 3 人，165cm,173cm,182cm という身長の持ち主も，同じ母集団からのサンプルですし，ある人の身長が他の人の身長に影響するとは思えませんから[*14]独立，つまりこのデータは i.i.d で，出現確率は同じ正規分布の関数を掛け合わせることで計算できますね。

これを計算すると，

$$L_{160} = 0.035 \times 0.017 \times 0.003 = 0.000002140286$$

になります。このようにとても小さい数字になりますので，対数をとって

$$LL_{160} = \log 0.035 + \log 0.017 + \log 0.003 = -13.05457$$

とした方がいいかもしれません。

もちろんほかのケース，たとえば $\mu = 150$ ならどうか，$\mu = 180$ ならどうか，といろいろ試すことができますね。実際 `dnorm(173,mean=150,sd=10)` とか `dnorm(182,mean=180,sd=10)` といった形で計算できます。尤度は次のようになります。

$$L_{150} = 0.0130 \times 0.0028 \times 0.0002 = 0.000000008746$$

$$L_{180} = 0.0130 \times 0.031 \times 0.039 = 0.0000158147$$

数字が小さいので対数尤度でみましょう。

$$LL_{150} = \log 0.0130 + \log 0.0028 + \log 0.0002 = -4.346524 - 5.866524 - 8.341524 = -18.55457$$

$$LL_{180} = \log 0.0130 + \log 0.031 + \log 0.039 = -4.346524 - 3.466524 - 3.241524 = -11.05457$$

となります。これを見ると，$LL_{150} < LL_{160} < LL_{180}$ ですから，$\mu = 150$ と仮定するより $\mu = 160$ のほうが，そしてそれより $\mu = 180$ の方が**尤もらしい**わけです。もちろん μ は他にもあり得ますから，横軸を μ にした関数とみて，そのグラフを描いてみましょう (図 23.5)。

このようにしてみると，μ が 170 から 175 の間あたりにピークがありそうですね。このピークを計算するには微分[*15]の計算が入りますが，実際に計算すると 173.3 になります。ピーク，すなわち最も尤度が高いわけですから，これが今回の**最尤推定値**になります。

[*14] 双子だとか血縁関係ではないとします！

[*15] 微分はある点における関数の接線の傾きを表す，というのは聞いたことがあると思います。この傾きがゼロになっているということは，つまり関数がピークを迎えたということです。つまり，微分は極値を求める操作だったのです。忘れていても習っていなくても大丈夫，テキストはあちこちにありますから，よくわからんという人は少し調べてみましょう。

図 23.5　さまざまな μ における尤度 (上図) と対数尤度 (下図)

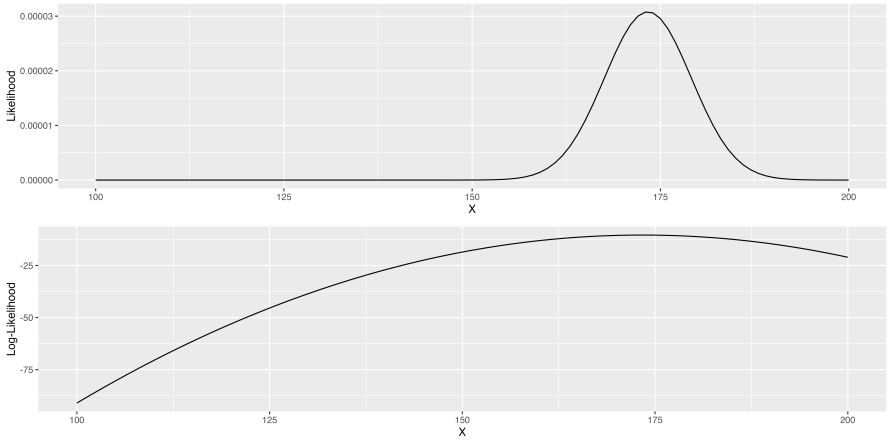

あれ，でもこれ標本平均と同じじゃないか，と思うかもしれません。その通り，同じなのです。実は推定方法が違うだけで同じ母集団の推定方法なので，むしろ答えが一致してよかったわけですね。推定方法が違うと答えが違う，というのでは困りますから。

ともかく，このように正規分布でも最尤推定ができます。もっとも，今回は母標準偏差がわかっている ($\sigma = 10$) という仮定の下で計算したのでした。本来はこちらも推定しなければなりません。つまり，平均 μ と標準偏差 σ という 2 つの変数の関数になるのです。この 2 つの関数のグラフを書いたのが図 23.6 です。2 つの変数で 1 つの対数尤度が決まるので，3 次元プロットになりますし，2 変数の微分方程式を解くことになるので数学的には少し面倒になりますが，同様に推定できることがわかります。

図 23.6　平均と標準偏差による 2 変数関数としての正規分布の対数尤度

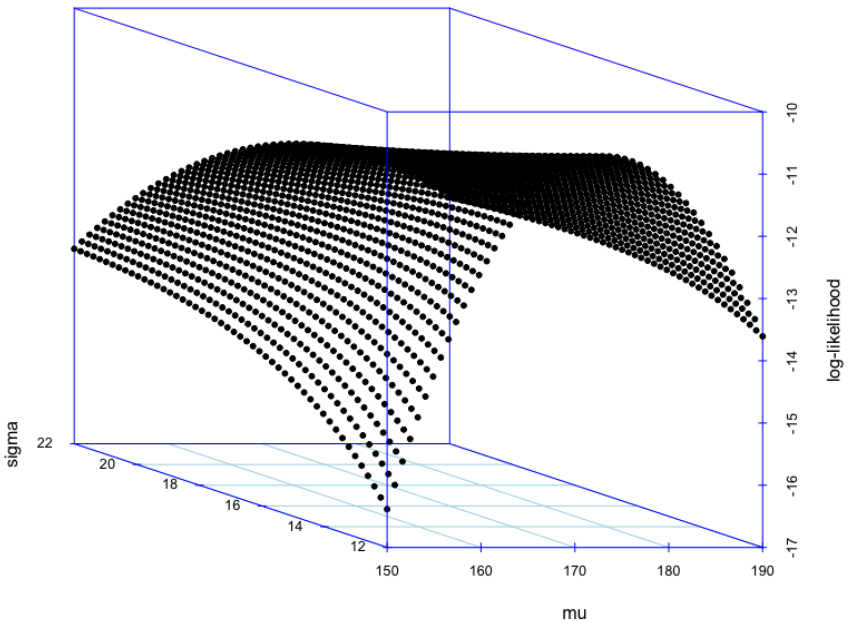

もちろんこの 2 変数の計算は機械がやってくれるので，皆さんがそこで苦労する必要はありません。それよりも，確率分布に基づいて推定するという方法があることを理解していただきたいと思います。最後に今日のポイントをまとめておきます。

- **確率密度関数 (probability density function)** と同じ形で，パラメータの方が未知数の場合これを尤度関数という。
- 尤度が最大になる点をパラメータの推定値とする，という推定方法を最尤推定という。
- 尤度の計算は数字が小さくなりがちなので，対数をとった対数尤度で計算することが一般的。対数をとってもピークの場所は変わらない。

今回は統計モデルを確率モデルに拡張するというお話でした。確率モデルに一般化することで，さまざまなデータ形式に対応したモデルを考えることができるようになりますが，それはまたどこかの機会で。

23.6 課題

ある小学校で身体測定をしたところ，3 人の身長はそれぞれ，155cm，143cm，132cm だったとします。このデータに基づいて，次の問いに答えなさい。

■正規分布の尤度を求める 1 このデータが，平均 170，標準偏差 10の正規分布から独立に得られていたとすると，その時の**尤度**はどれぐらいになるでしょう。

■正規分布の尤度を求める 2 このデータが，平均 140，標準偏差 10の正規分布から独立に得られていたとすると，その時の**対数尤度**はどれぐらいになるでしょう。

■正規分布の尤度を求める 3 このデータが，平均 140，標準偏差 10の正規分布から得られていたと考えるモデルと，平均 140，標準偏差 8の正規分布から得られていたと考えるモデルがあったとします。データはどちらをより支持しますか。

■正規分布の尤度を求める 4 このデータが正規分布から得られると考えて，そのときの平均値の最尤推定値を求めましょう。

第 24 章

尤度と線形モデル

前回は確率分布関数に含まれる変数の中で，パラメータの方が未知であると考えた尤度関数として捉え，尤度が最大になるようにパラメータの値を推定する**最尤推定法**について学びました。

今回はこれを，線形モデルに適用するお話です。線形モデルについては前期から今まで，折に触れては説明してきました。まず第 7 講で回帰分析に触れ，続いて重回帰分析 (第 8 講) に進みました。後期に入ってからは，要因計画と仮説検定の合体技，**分散分析**の話になりましたが，そこでの推定方法は**モーメント法**，すなわち**標本平均**や**不偏分散**を使ってのものでした。**平方和**を**自由度**で割って，**平均平方**を出し，その比が **F 分布**に従う，という考え方は，平均や分散から母数を考えようという発想と同じものだと言えます。

それに対して，前回は尤度から母数を考えようという発想でした。推定値は同じになるのですが，考え方が違っていることに注意して，線形モデルの最尤推定について考えていきます。

24.1 回帰モデルの確率表現

改めて線形モデル，とくに**単回帰分析**のモデルを復習しておきましょう。

データの組，x_i, y_i があったときに，変数 x をつかって y を予測する，線形モデルを当てはめるということを考えるのでした。線形モデルは最も単純な一次式で，

$$\hat{y}_i = \beta_0 + \beta_1 x_i \tag{24.1}$$

とし，予測値 $\hat{y}$ に誤差 ε がついて実現値 y が得られると考えて，

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \tag{24.2}$$

とするのでした。第 7 講でやった**最小二乗法**は，この式をデータに当てはめ，データの中で誤差が一番小さくなるように切片を求める，という方法だったことを思い出してください。あくまでも手元のデータの話しかしていませんでしたが，これに推測統計学のエッセンス，つまり手元のデータは標本に過ぎず，母集団の中でどうか，ということを考えたいと思います。

ところで，この時も仮定として誤差の分布に**正規分布**を仮定していましたね。誤差はさまざまな未知なる要因の積み重ねですから，数字を増やす方向に加わるのか，減らす方向に加わるのかは分かりません。それでも極端に大きな誤差というのは出にくく，平均周りの誤差が出やすいと考えるなら，単峰で左右対称のベルカーブのような形になるはずです。また，今回ここで考えているのは**偶然誤差**ですから[*1]，その平均はゼロだ

[*1] これに対して**系統誤差**というのがありました。システマチックな誤差，という意味で，常に定数が加わるようなイメージです。体重計などの秤で何も測っていないときに目盛がずれているようなものですから，今回のケースではその補正には触れません。測定する際に気をつけるべきことで，気をつけてもなくならないのが偶然誤差です。

と考えられます。ですから，$\varepsilon_i = y_i - \hat{y}_i$ をデータ全体で最小にするようにモデルをフィッティングするのでした。ここまでは前期の復習になります。

24.1.1 確率モデルとしての表現

この線形モデルを確率モデルと考えて，最尤推定したい，というのがここでの狙いです。

最尤推定をするためには，この回帰分析の式を確率モデルで表現しなければなりません。先ほどのモデル式の中に出てくる記号のなかで，確率的に変わるのは何かと言われれば，誤差 ε です。そしてこれは，正規分布に従うだろうと考えるのが自然なのでした。式で書くと，

$$\varepsilon_i \sim N(0, \sigma) \tag{24.3}$$

ということになります。ここで誤差の平均が 0 である，ということを再確認してください。また，平均は 0 ですが，誤差は一定の幅で散らばって出てきますので，これを標準偏差 σ で表しています。

さて，誤差が確率的に求まることがわかりましたが，x と $\hat{y}$ の関係は確率的ではありません。切片や傾きは未知数ですが (母集団での切片と傾きのことになるので β_0, β_1 と表記しますが)，これがわかりさえすれば $\hat{y}_i$ と x_i の関係は確定的です。つまり，「確率分布に従う」を表す $\sim$ という記号ではなく，「左辺はこのようになっ**ている**」ということを記述するために，$=$ を使って書くことができます。

$$\hat{y}_i = \beta_0 + \beta_1 x_i \tag{24.4}$$

これが線形モデルです。誤差に邪魔されることがない，理想的な予測値 $\hat{y}$ は，x_i の一次関数の形で記述できる，ということです。実際のデータ y_i は $\hat{y}$ に誤差がついて出てくるものですから，

$$y_i = \hat{y}_i + \varepsilon_i \tag{24.5}$$

と書くことができます。

さて，これらを組み合わせていきましょう。最後の式から $\hat{y}$ を消去する (線形モデルで代入する) と，

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \tag{24.6}$$

ということになります。ここで $\beta_0 + \beta_1 x_i$ のところは確率的に変わるものではない，ということを思い出してください。

$$y_i = \underbrace{\beta_0 + \beta_1 x_i}_{\text{確率的でないところ}} + \underbrace{\varepsilon_i}_{\text{確率的}} \tag{24.7}$$

誤差 ε_i は平均 0 を中心に確率的に散らばりますが，その前のところは確率的ではありませんので，これを組み合わせた式全体としては，最後に確率的な散らばりがひっついているような形になります。数式ではありませんが，イメージでいうとこんな感じ。

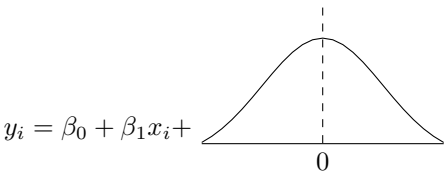

さて，この「確率的でないところ」が確率分布の中に入り込むとしたら，誤差 ε_i の平均値を一定の量，$\beta_0 + \beta_1 x_i$ 分だけ動かすことになります。回帰直線が表しているのは，誤差のない予測の線でもあります。実際のデータはそれに誤差が伴って生じます。確率モデルになった線形モデルは，図 24.1 のようなイメージで考えるといいかもしれません。

図 24.1 予測直線にまとわりつく誤差

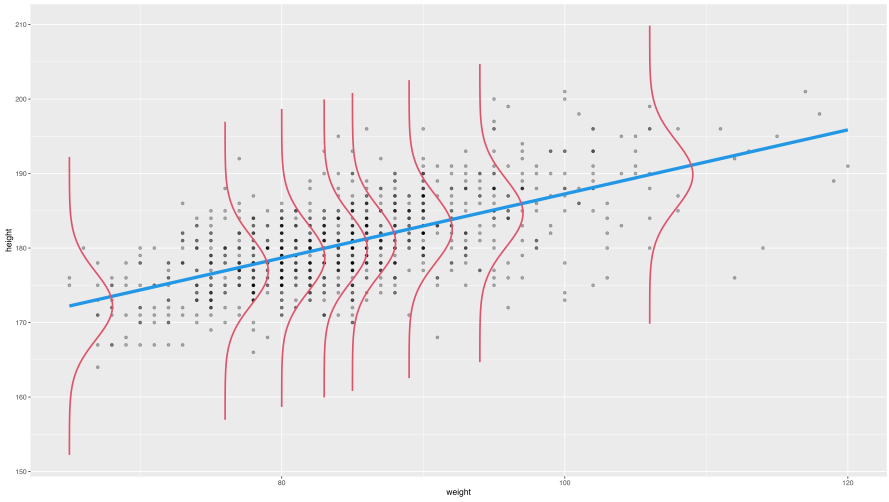

ここで正規分布がもつ 2 つのパラメータ，μ と σ は，それぞれ**位置**と**幅**を表しているわけですが，確率的でないところはこの位置をズラすような作用をすることになります。

大事なところなので，もう一度式で確認しながら説明します。まず今回のモデルに含まれる情報は次のとおりです。

$$\hat{y}_i = \beta_0 + \beta_1 x_i \tag{24.8}$$
$$y_i = \hat{y}_i + \varepsilon_i \tag{24.9}$$
$$\varepsilon_i \sim N(0, \sigma) \tag{24.10}$$

ここで式 24.8 と 24.9 を合わせて，

$$\begin{aligned} y_i &= \beta_0 + \beta_1 x_i + \varepsilon_i \\ \varepsilon_i &\sim N(0, \sigma) \end{aligned} \tag{24.11}$$

とします。ここで ε_i の中心は 0 で，それに $\beta_0 + \beta_1 x_i$ が加わるのですから，

$$y_i \sim N(\beta_0 + \beta_1 x_i, \sigma) \tag{24.12}$$

ということになります。

あるいは，式 24.9 と 24.10 から先に，

$$\hat{y}_i = \beta_0 + \beta_1 x_i \tag{24.13}$$
$$y_i \sim N(\hat{y}_i, \sigma) \tag{24.14}$$

と考えて，この式 24.14 の $\hat{y}_i$ に式 24.13 を代入しても，

$$y_i \sim N(\beta_0 + \beta_1 x_i, \sigma) \tag{24.15}$$

が得られます。どちらのルートでも結構ですから，自分のわかりやすい方で理解してください。一連の流れを図 24.2 にまとめてみました。

図 24.2 確率モデルと予測モデルの合体

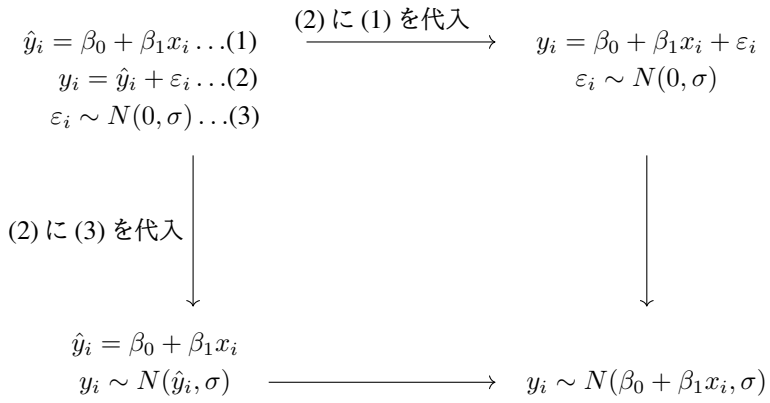

これが回帰分析の**確率モデル**になります。ポイントは，確率分布の位置を表すパラメータに，数式で表現された**構造**を書き込んだところにあります。狭義の**モデリング**とは，確率分布のパラメータに構造を与えるもの，ということができるでしょう。この枠組みをさらに一般化すると，正規分布以外の確率分布にも線形モデルを適用できるようになります。これについては本章の後半で改めて説明します。

24.2 回帰分析の最尤推定

このようにして確率モデルを書くことができれば，あとはこれにしたがって「データがこの確率モデルから出てくる尤もらしさが最も高くなるように，未知パラメータを推定すれば良い」ということになります。改めて確認ですが，今回のモデル $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma)$ において未知な数字は β_0, β_1, σ の 3 つになります。

正規分布の式をちゃんと書くと，x という値が出てくる確率密度は

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \tag{24.16}$$

となります。この平均 μ のところに $\beta_0 + \beta_1 x_i$ という数式を入れることになります。

すでに入り組んだ形をしているので，イメージしづらいところがあるかもしれませんが，あるデータ y_i が得られる確率密度は

$$p(y_i) = \frac{1}{\sqrt{2\pi\sigma^2}} exp\left(-\frac{(y_i-\mu)^2}{2\sigma^2}\right) \tag{24.17}$$

ですから，$\mu = \hat{y}_i = \beta_0 + \beta_1 x_i$ を代入して

$$p(y_i) = \frac{1}{\sqrt{2\pi\sigma^2}} exp\left(-\frac{(y_i-\beta_0-\beta_1 x_i)^2}{2\sigma^2}\right) \tag{24.18}$$

となります。

データは $i = 1, 2, \cdots, N$ とあり，それらが同じ母集団から独立に得られている，と考えます (i.i.d.)。つまり手元に同時にこれらのデータが出揃うときの尤度 L は，上記の確率密度 $(p(y_i))$ を全部掛け合わせたもの[*2]，と考えることができますね。i を 1 から n まで足し合わせることを総和する，といって

[*2] コインが表，表，裏，と出たら $\theta \times \theta \times (1-\theta)$ と書けたことを思い出して！

$x_1 + x_2 + \cdots + x_N = \sum_{i=1}^{N} x_i$ と表しますが, 同様にすべて掛け合わせる総積は,

$$x_1 \times x_2 \times \cdots x_N = \prod_{i=1}^{N} x_i \tag{24.19}$$

と書きます。ここでの記号 $\prod$ は総積（プロダクト）と言いますが, これを使って尤度 $L(y_i)$ を表現すると, 次のようになります。

$$L(y_i|\beta_0, \beta_1, \sigma) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} exp\left(-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right) \tag{24.20}$$

ここで $L(y_i|\beta_0, \beta_1, \sigma)$ という書き方の, $|$ は何かというと, この縦線の右側にある β_0, β_1, σ が与えられた場合の, という条件つき確率の書き方を借りた**尤度 (likelihood)** を表しています。

さてこれは確率 (密度) の掛け算になりますから, すごく小さな数字になって実際の計算は大変です。そこで前回習ったように, 尤度そのものではなく**対数尤度 (log-likelihood)** をとって, その最大値を求めるということにしたいと思います。対数をとると掛け算は足し算に変わりますから, $\prod \to \sum$ に記号が変わりまして, 対数尤度の関数は次のようになります。

$$\log L(y_i|\beta_0, \beta_1, \sigma) = \sum_{i=1}^{N} \log\left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right)\right] \tag{24.21}$$

非常に面倒な形をしていますね！しかもこれは β_0, β_1, σ という 3 つの変数が同時に関わりますから, 連立微分方程式を解くことになります。

ここからは少しテクい話になりますが, この式を展開していきましょう。$\frac{1}{\sqrt{2\pi\sigma^2}} = (2\pi\sigma^2)^{-1/2}$ であることに注意して対数尤度を書き直すと,

$$\begin{aligned}
\log L &= \log \prod_{i=1}^{n} (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2}\right) \\
&= \sum_{i=1}^{n} \log\left[(2\pi\sigma^2)^{-1/2} \exp\left(-\frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2}\right)\right] \\
&= \sum_{i=1}^{n} \left[\log(2\pi\sigma^2)^{-1/2} + \log\exp\left(-\frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2}\right)\right] \\
&= \sum_{i=1}^{n} \left[-\frac{1}{2}\log(2\pi\sigma^2) - \frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2}\right] \\
&= \sum_{i=1}^{n} \left[-\frac{1}{2}\log(2\pi) - \frac{1}{2}\log(\sigma^2) - \frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2}\right] \\
&= -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - (\beta_0 + \beta_1 x_i))^2
\end{aligned}$$

こうしてみると, $\frac{n}{2}\log(2\pi)$ は定数ですし, $\frac{n}{2}\log(\sigma^2)$ は推定すべきパラメータ σ^2 で, データによって変わるところではありません。第 3 項の $\sum_{i=1}^{n}(y_i - (\beta_0 + \beta_1 x_i))^2$ がデータによって変わるところで, これを最小

化することを考える必要がありますが，これは最小二乗法で考えるべきポイントと同じですね。ですから，この最尤推定の結果得られる β_0, β_1 の値は，最小二乗法の結果と一致します。

もちろんこの面倒な計算は，R がやってくれますから私たちはなんの心配もする必要はありません。ですから，実質的にはただの回帰分析をすれば良いのです。

24.2.1 実践例

数字としてはなんら変わるところはないのですが，復習も兼ねて第 9 講でやった回帰分析をもう一度見てみましょう。回帰分析の関数は `lm` という関数名で，R がデフォルトで持っている関数なのでした。実はこの関数，最尤推定値を返す関数だったのです。そのときは**最小二乗法**の説明しかしていなかったのですが，関数の使い勝手のこともあって，最尤推定する関数でご紹介しておりました。本当の意味で，最小二乗法のアルゴリズムで回帰分析をするときは `lsfit` 関数というものを使います。

使用例をコード 24.1 に示しました。ここでは野球選手のデータを使って，身長から体重を予測するというモデルを実行しています[*3]。データの `batter` は，第 9 講の `code:9.1` と `code:9.2` で作ったものです。新しいスクリプトで始める場合は，先にこの 2 つを実行して `batter` を作っておいてください。

code : 24.1 二つの推定法の比較

```
1 # 最小二乗法の推定
2 result.LS <- lsfit(x = batter$height, y = batter$weight)
3 result.LS$coefficients
4 # 最尤推定
5 result.LM <- lm(weight ~ height, data = batter)
6 summary(result.LM)
```

結果は出力 24.1 のようになります。

[*3] 第 9 講と同じ分析結果です。

R の出力 24.1: 比較した結果

```
> # 最小二乗法の推定
> result.LS <- lsfit(x = batter$height, y = batter$weight)
> result.LS$coefficients
  Intercept           X
-124.917552    1.166698
> # 最尤推定
> result.LM <- lm(weight ~ height, data = batter)
> summary(result.LM)

Call:
lm(formula = weight ~ height, data = batter)

Residuals:
     Min       1Q   Median       3Q      Max
-20.9217  -4.9213  -0.4214   4.0783  28.9118

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -124.91755   13.89317  -8.991   <2e-16 ***
height         1.16670    0.07746  15.063   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.435 on 327 degrees of freedom
Multiple R-squared:  0.4096, Adjusted R-squared:  0.4078
F-statistic: 226.9 on 1 and 327 DF,  p-value: < 2.2e-16
```

これを見ると明らかなように, どちらの方法でやっても同じ推定値 (切片 $\beta_0 = -124.918$, 傾き $\beta_1 = 1.167$) になっていますね。また少し余談ではありますが, 最尤推定した結果の最終行を見ると, F 統計量が自由度 $F(1, 327) = 226.9$ とあり, この p 値も計算されています。ここで線形モデルと要因計画・帰無仮説検定も関連があることがわかります[*4]。

方法が違っても推定値が同じ, というのは前回もお話ししたように, 同じ母数を推定しているわけですからむしろ当然の結果です。1 つの山の頂上に達するのに, 複数のルートがあってもゴールは同じ, ということです。違う点があるとすれば, 最尤推定の場合は誤差の標準偏差 σ も推定されているというところでしょうか。結果に $\sigma = ...$ という記載はありませんが, よく見ると `Residuals` のところに残差 e の最小値, 最大値, 四分位偏差, 中央値などが示されており, 誤差が分布するものと考えられていることがわかります。

今回は説明変数が 1 つの単回帰分析でしたが, 説明変数の数が増えた**重回帰分析 (multiple regression analysis)** でも同じで, `lm` 関数はデータが正規分布から得られたものとした上で, 尤度を最大にする推定値を返してくれます。

R で回帰分析をしたついでに, この結果を plot 関数にいれてみましょう。

code : 24.2 回帰分析の結果オブジェクトをプロットに入れる

```
1    par(mfrow = c(2, 2)) # 2x2の配置にする
```

[*4] ここでは切片以外のすべての説明変数 (今回の例では単回帰なので説明変数は一つですが) の傾きが 0 である, という帰無仮説にたいして検定が行われています。

```
2    plot(result.LM)
```

4 つの図が表示されますが，ここでは 2 × 2 の配置にしています。出力されるのは図 24.3 のようになります。

図 24.3　回帰分析の結果をプロットすると 4 枚の図が出てくる

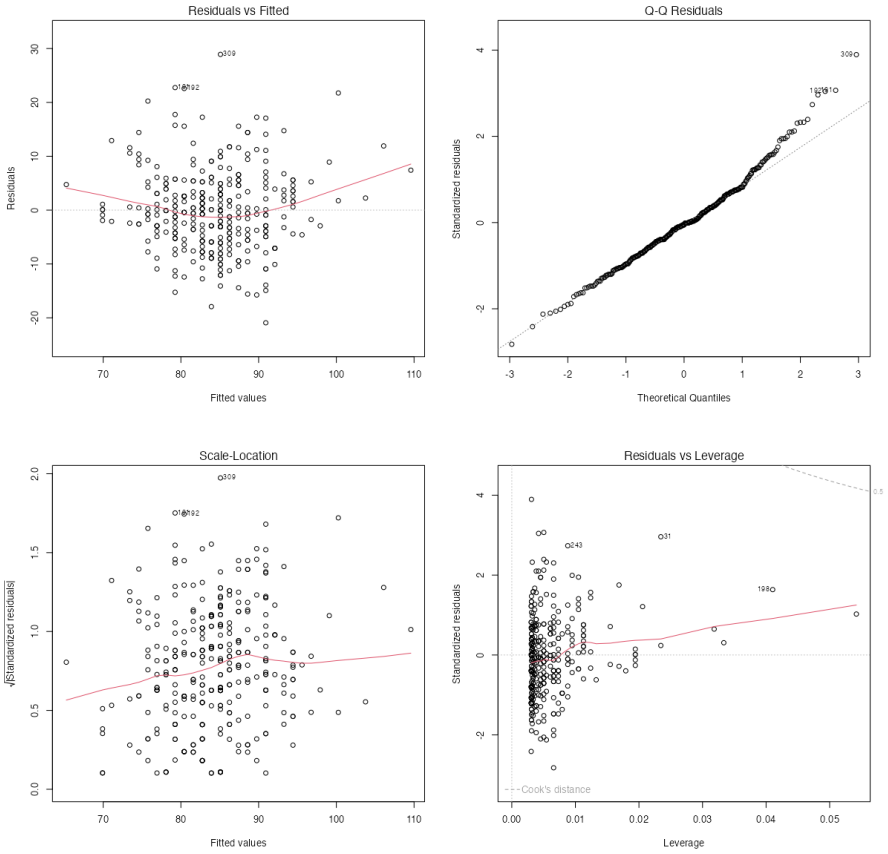

最初の図 (図 24.3 左上) は，残差と予測値の散布図です。回帰分析において，残差 e_i と予測値 $\hat{y}_i$ の相関は理論的にゼロになります。実際にそのようになっているかを確認するための図が表示されています。今回の散布図をみると，一定の関係はなさそう (緩やかな U 字で，特定の関係があるように思えない) ですね。残差は規則性を持たず，均一に散らばっているはずです。この図を見てそれを確認しましょう。

第二の図 (図 24.3 右上) は **Q-Q プロット (Q-Q plot)** と呼ばれるものです。Q-Q プロットとは一般的に，データが仮定された確率分布にしたがっているかどうかを表示するためのもので，今回は横軸に正規分布の理論点を，縦軸に残差をプロットしています。理論通りの分布をしていると，左下から右上への 45 度線上にプロットされていくはずで，このラインから外れるのは理論分布から外れていることになります。今回は右の方，大きな値のところで少し歪みが生じていますが，ほとんどの点がライン上に載っていますので，まあ正規分布していたと考えられるでしょう。

第三の図 (図 24.3 左下) は残差標準偏差と予測値のプロット，第四の図 (図 24.3 右下) は残差とレバレッジの散布図です。レバレッジとは，各データ点がモデルに与える影響の大きさの指標です。これらも残差の分布が均一であるか，外れ値がないか，というところを検証するためのものです。

これらの図をみて残差が正規分布という仮定にしたがっているか，ということを確認することが重要です。

こうした**残差診断 (residual diagnostics)** は，モデルの適合性や仮定の妥当性を評価しておくことが重要です。最尤法は確率モデルなのですから。

24.3 線形モデルの拡張

さて，こうしてみてくると，最小二乗法と最尤法，結局答えが同じになるのに，なぜこんな回りくどい話をするのかと思うかもしれません。大事なのは線形モデルが確率モデルになったというところで，確率モデルになることで適用できる範囲が広がるから，というのが 1 つの答えです。

線形で現象を記述する，つまり $\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots$ のように，説明変数 x の線形結合で予測値 $\hat{y}$ を表現する，という考え方は単純で分かりやすいです。重回帰分析における偏回帰係数は，条件つきの係数として解釈するという注意が必要ですが，ある変数が 1 単位増加したときに予測値がどれだけ変化するか，という直感的な理解が可能です。

人間や社会を扱う現象がすべて線形で説明できる，ということはあり得ません。勉強すればその時間に応じて成績がぐんぐん伸びる，というようなことは，残念ながら実際にはあまりないことかもしれません。現実的ではないかもしれませんが，俯瞰的に見れば，あるいは平均的に見れば，概ね線形関係があるとか，線形で例えてもいいだろう，というぐらいです。人文社会科学で線形モデルが使われるのは，ある程度の適合度を犠牲にしても，解釈のしやすさを優先するからです。

この線形結合で表したものを**線形予測子 (linear predictor)** と呼びます。そして，この予測値を中心に確率分布が広がっている，と考えましょう。そして，ここからが大事なポイントですが，この確率分布は必ずしも正規分布である必要はない，ということです。

たとえばベルヌーイ分布は，0/1 の二値データを表現する確率分布でした。ベルヌーイ分布はパラメータ θ ひとつだけ持っており，$\theta = 0.5$ であれば 0 と 1 が出てくる確率は五分五分です。言い換えると，平均的に 50% の確率で 1 が出る，ということです。他にも確率分布はいろいろありますが，それらの確率分布の平均的なパラメータに，線形結合子を対応させることができれば，線形モデルを使って様々なタイプのデータを説明できるようになります。

このように線形モデルを一般化したものを**一般化線形モデル (generalized linear model, GLM)** と呼びます。

回帰分析を確率モデルという観点から考えれば，線形予測子＋正規分布の組み合わせであり，正規分布の平均パラメータに線形予測子を当てはめたもの，と理解できます。一般化線形モデルは，線形予測子＋誤差分布，あるいは線形予測子＋確率分布の平均的なパラメータ，と考えることができます。これを使えば，必ずしも正規分布的でないデータに対しても，線形的な理解ができるようになります。そして，その時のパラメータの推定方法の一つが最尤法なのです。

24.3.1 確率分布としての線形モデル

さてここで，要因計画は線形モデルだという話を思い出してください。そして線形モデルのパラメータを最尤法で推定する，というここでの話を組み合わせましょう。つまり，要因計画のデータ生成メカニズム，確率モデルを考えてみようということです。

要因計画がどのようなものであれ，データの散らばりを生んでいるのは効果，個人差，偶然誤差によるものだと考えるのでした。逆に言えば，これらがなければすべての値は同じになるはずだ，という観点から逆算し，効果，個人差，偶然誤差の大きさを見積もっていったのでした。

ここで，誤差を考える時には確率の考え方を利用してそれをコントロールする，という話を思い出してくださ

い。ガウスが考えた誤差論は，平均が 0，分散 σ^2 で散らばる正規分布に従うのでした。すなわち誤差を ε_i とすると，次のように表現できます。

$$\varepsilon_i \sim N(0, \sigma) \tag{24.22}$$

群間計画の場合は，各観測値 y_i を切片 β_0 と効果 β_1 と誤差に分けます。X_i は，統制群なら 0，実験群なら 1 をとる変数です。

$$y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \tag{24.23}$$

$$\varepsilon_i \sim N(0, \sigma) \tag{24.24}$$

イメージでいうなら次のような形です。

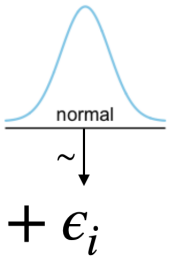

ε_i が正規分布に従うのですが，$\beta_0 + \beta_1 X_i$ のところは確率的に変わるものではないことに注意してください。ここが確率的に変わらないということをよく考えれば，数式に沿ってある値が足されることと同じです。確率分布にある数字を加えると，その分布の位置がずれますね。正規分布は位置と幅でその特徴が作られているのですが，右辺全体で見ると，$\beta_0 + \beta_1 X_i$ のところは，正規分布の位置をずらすことでもあります。

ずれた分布は，正規分布の平均値が $\beta_0 + \beta_1 X_i$ ですから，式全体を整えると次のようになります。

$$y_i \sim N(\beta_0 + \beta_1 X_i, \sigma) \tag{24.25}$$

この式のポイントは，$y =$ ではなく $y \sim$ になっているところです。データが正規分布に従う，という形に変わったのです。線形モデル (要因計画) はこのように，**確率分布の位置パラメータに数式 (モデル) を当てはめる**こととも言えます。

さらにさらに。群内計画の場合は，個人差 δ_i も計算できるのでした。この個人差というのも，たくさん集めると確率的な傾向を表してくるはずで，とくに個々人の生得的な性質に関係するのであれば，それはまた正規分布に従うと言えるでしょう。個人差は全体平均からのずれとして捉えるので，その平均は 0 と置きます (平均を ψ[*5]のような記号で置くこともできますが，切片 β_0 と区別がつかないので 0 とします)。これを踏まえて表現すると次のようになります。

$$\delta_i \sim N(0, \tau) \tag{24.26}$$

さてそうすると，群内計画の場合は 2 つの異なる正規分布が混ぜ合わさった形になっていることになります。式で書くと次のようになりますね。

$$y_{ij} = \beta_0 + \delta_i + \beta_j X_{ij} + \varepsilon_{ij} \tag{24.27}$$

$$\delta_i \sim N(0, \tau), \quad \varepsilon_{ij} \sim N(0, \sigma) \tag{24.28}$$

この式をイメージで表すと，次のような形になります。

[*5] ψ はギリシア文字でプサイと読みます。大文字は Ψ であり，心理学 Psychology をギリシア語で表現した最初の文字になります。

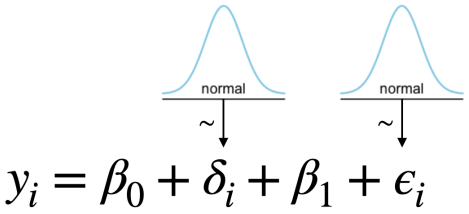

$$y_i = \beta_0 + \delta_i + \beta_1 + \epsilon_i$$

このように確率をふまえたモデルで考えると，群内計画のデータには，全員に共通の効果 (固定効果) と，個人ごとに確率的に変わる効果 (変量効果) の両方が含まれていることになりますから，**混合効果モデル (mixed effect model)** と呼ぶことがあります。先ほどの群間計画では，$\beta_0 + \beta_1 X_i$ で平均値をずらした正規分布にデータが従うことになりましたが，群内計画では $\beta_0 + \beta_1 + \delta_i$ がすでに確率的に分布し，それが平均値となった確率分布がデータの従う分布になる，つまり (誤差の) 正規分布の中に (個人差の) 正規分布が入れ子になった形でモデルが表現されたことになります。全員に共通の効果 (固定効果) と，個人ごとに確率的に変わる効果 (変量効果) が混ざっているので，**混合**というのですね。先ほどのデータを使って図で表現するなら，図 24.4 のようになります。

図 24.4 混合効果モデルのイメージ

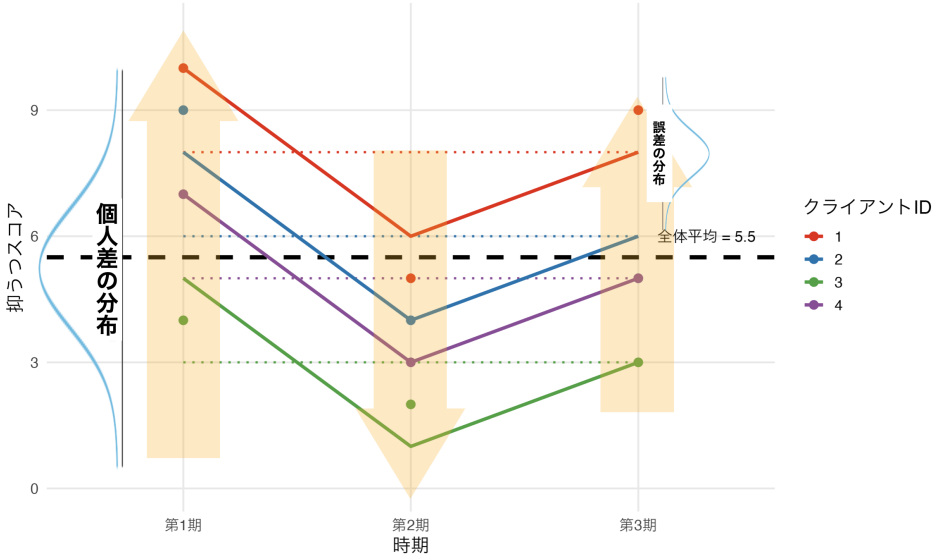

図で表すとかえってわかりにくくなったかもしれませんが，ポイントは，群内計画では個人差も確率的に変化する要素として捉えられる，ということです。さらに言えば，確率的な要素として考えるということは各個体・各実現値ひとつひとつの個性を考えるのではなく，それらは相互に交換可能な偶然の要素であり，全体的な傾向にしたがっていると考えることでもあります。

今回は個人差の要素として考えましたが，実験計画では「等価な刺激」を複数用意して，それらをランダムに割り当てる，ということもよく行います。たとえば記憶の実験として，無意味綴りの単語を覚えてもらって，幾つ覚えられたかを調べる，ということを考えます。実験参加者は「めぬそ」「きたへ」など，全く意味のない単語を覚えるわけですが，全員が同じものを同じ順番で覚える必要はありません。三文字のひらがなで意味を成さない組み合わせ，という条件を満たす単語を複数用意し，それらをランダムに割り当てることで，刺激の個性を抑え，実験参加者の個性も抑えることができます。このような場合も，刺激の個性は確率的に変化する要素として捉えられるわけです。この刺激グループの各要素が持つ個性も，個人差と同じように正規分布に従

うと考えられますから，混合効果モデルとして扱います。

このように個人差も刺激の個性も，さらには実験を行う日や場所なども，確率的に変化する要素として捉えられるわけです。これらすべてを混合効果モデルとして扱うことも可能であり，実際にそういう分析手法も存在します (線形混合モデル，Linear Mixed Model など)。たとえば同じ実験を複数の国や地域，実験室で行ったものを統合した**メタ分析 (meta analysis)** などでは，実験室ごとの違いも確率的に変化する要素として捉え，混合効果モデルで分析することがあります。

もっともっと面白いことを言えば，係数 β も確率的に変化する要素として捉えることもできます。いろいろな効果の現れ方が，個人や集団，実験室ごと，あるいは地域や国ごとに少しずつ異なるということも考えられるでしょう。もちろん全体的な効果はありますが，それに加えてローカルな影響があり，それが切片だけでなく傾きにも現れているかもしれません。このように考えるモデルは**階層線形モデル (hierarchical linear model)** などと呼ばれ，ベイズ統計学の枠組みで扱われることが多いです。ここでは詳細には立ち入りませんが，実験計画法の理論がこのように発展していることを知っておいてください。

24.4 一般化線形モデル

一般化線形モデルは，線形予測子と確率分布のセットで考えるということでした。しかし，ここで注意が必要です。線形予測子は $\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots$ のように表されますが，この値は原理的にはどのような値にもなり得ます。正の値でも負の値でもいいですし，ものすごく大きな数字や小さな数字になることもあるでしょう。

ところで，たとえば確率分布として先ほどのベルヌーイ分布を考えたとしましょう。ここで線形予測子を当てはめるのはパラメータ θ ですが，これは表が出る確率を表すパラメータですから，$0 \leq \theta \leq 1$ という制約があります。線形予測子はどんな値にもなり得るので，そのまま当てはめるとこの範囲を超えてしまいます。

そこで，線形予測子 η と，確率分布の平均的なパラメータ μ(ベルヌーイ分布なら θ) を結びつける関数を用意します。パラメータから線形予測子への変換 $g(\mu) = \eta$ を**リンク関数 (link function)** とよび，その逆の線形予測子からパラメータへの変換 $g^{-1}(\eta) = \mu$ を**逆リンク関数 (inverse link function)** と呼びます。用語がややこしいですが，リンク関数はデータの中心傾向を表すパラメータを，線形予測子の尺度へ写す関数であると考えてください。これに対し，私たちは線形予測子でデータがどう変わるか，という解釈をしたいわけです。つまり中心傾向を表す値に線形予測子を当てはめたいわけですから，リンクの逆の作用をする計算が必要です。そこでこれを逆リンク関数と呼びます。いうまでもないことですが，逆リンク関数の逆はリンク関数です。

たとえば，ベルヌーイ分布のパラメータ θ に線形予測子を当てはめるときには，逆リンク関数としてロジスティック関数を用います。ロジスティック関数は，次のように表されます。

$$\theta = \frac{1}{1 + \exp(-\eta)} \tag{24.29}$$

この関数は，線形予測子 η がどんな値であっても，出力が 0 から 1 の範囲に収まるようになっています (図 24.5)。なお，この逆がリンク関数で，ロジット関数 $\eta = \log \dfrac{\theta}{1-\theta}$ になります。

このように，一般化線形モデルでは，確率分布のパラメータの定義域に応じた適切な (逆) リンク関数を選ぶことで，線形予測子を様々な確率分布と結びつけることができます。正規分布の場合はリンク関数が恒等関数，$y = x$ という何の変化もさせない関数になります。参考までに，表 24.1 に，変数の種類と確率分布・逆リンク関数の対応をまとめました。これらを駆使すると，どんなデータがあっても，一般化線形モデルを当てはめることができますね。

図 24.5　ロジスティック関数：線形予測子 η がどのような値をとっても，出力 θ は 0 から 1 の範囲に収まる

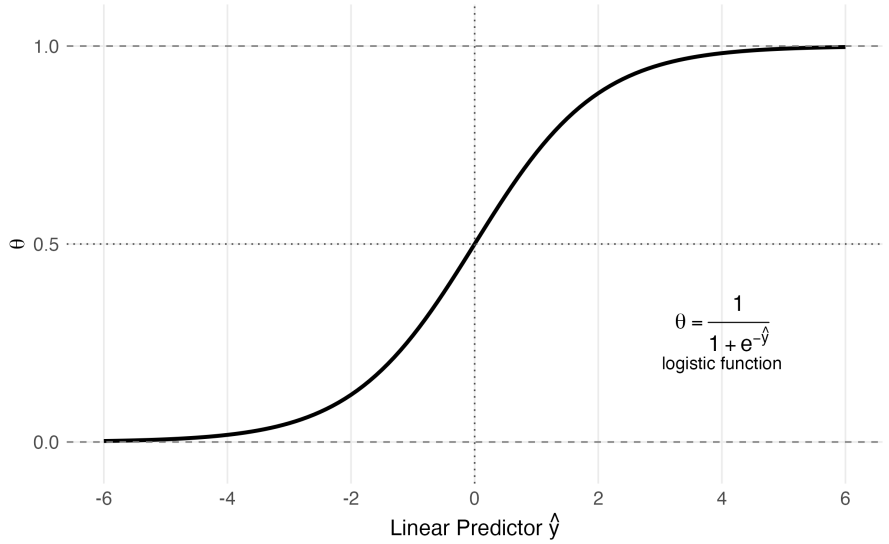

表 24.1　変数の種類と確率分布・逆リンク関数の対応

変数の種類	確率分布	逆リンク関数	数値の制約
量的	$Normal(\mu, \sigma^2)$	$\mu = \eta$	$\mu \in \mathbb{R}$
二値	$Bernoulli(\mu)$	$\mu = \frac{1}{1+\exp(-\eta)}$	$0 \leq \mu \leq 1$
カウント	$Poisson(\mu)$	$\mu = \exp(\eta)$	$\mu > 0$
名義	$Categorical(..., \mu_k, ...)$	$\mu_k = \frac{\exp(\eta_k)}{\sum_j \exp(\eta_j)}$	$0 \leq \mu_k \leq 1$
順序	$Categorical(..., \mu_k, ...)$	$\mu_k = \Phi\left(\frac{\theta_k - \eta}{\sigma}\right) - \Phi\left(\frac{\theta_{k-1} - \eta}{\sigma}\right)$	$0 \leq \mu_k \leq 1$

24.5　課題

■回帰モデルの確率表現　回帰モデル $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ を確率モデルとして表現したとき，正しい記述はどれですか。

- y_i は確定的な値であり，確率分布には従わない
- 誤差項 ε_i が正規分布に従うとき，y_i も正規分布に従う
- 線形予測子 $\beta_0 + \beta_1 x_i$ は確率的に変動する

- 誤差項の平均は β_0 である

■誤差項の仮定　回帰分析において，誤差項 ε_i に関する標準的な仮定として，正しいものはどれですか。

- 誤差項の平均は 1 である
- 誤差項は一様分布に従う
- 誤差項は平均 0 の正規分布に従う
- 誤差項の分散は観測ごとに異なる

■最尤推定の目的　回帰分析で使う「最尤推定」の目的として，最も適切なものを一つ選んでください。

- データの中から最大値を見つけること
- データがモデルから得られる尤もらしさ (尤度) が最も高くなるようにパラメータを推定すること
- データの平均値をそのままパラメータの推定値とすること
- データの平均値を求めること

■対数尤度　最尤推定において，尤度ではなく対数尤度を用いる理由として，最も適切なものはどれですか。

- 対数をとると推定値が変わるから
- 確率の積が和に変わり，計算が容易になるから
- 対数尤度の方が常に大きな値になるから
- 対数をとると正規分布になるから

■最小二乗法との関係　正規分布を仮定した回帰分析において，最尤推定と最小二乗法の関係について正しい記述はどれですか。

- 最尤推定と最小二乗法は常に異なる推定値を与える
- 正規分布を仮定した場合，最尤推定値と最小二乗推定値は一致する
- 最小二乗法を使うには，誤差が正規分布に従うと仮定しなければならない
- 最尤推定は誤差の分散を推定できないが，最小二乗法は推定できる

■線形予測子　線形予測子 $\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots$ について，正しい記述はどれですか。

- 線形予測子の値は必ず 0 から 1 の範囲に収まる
- 線形予測子は説明変数の線形結合で表される
- 線形予測子は確率分布のパラメータそのものである
- 線形予測子には切片項を含めてはならない

■一般化線形モデル　一般化線形モデル (GLM) について，正しい記述はどれですか。

- 一般化線形モデルは正規分布のみを扱うことができる
- 一般化線形モデルでは，線形予測子と確率分布をリンク関数で結びつける
- 一般化線形モデルは，リンク関数を使わずに非線形な関係を直接モデル化する
- 一般化線形モデルでは最尤推定を使うことができない

■リンク関数と逆リンク関数　リンク関数 $g(\mu) = \eta$ と逆リンク関数 $g^{-1}(\eta) = \mu$ について，正しい記述はどれですか。

- リンク関数は線形予測子をパラメータに変換する
- 逆リンク関数は線形予測子をパラメータに変換する
- リンク関数と逆リンク関数は同じものである
- 正規分布の場合，リンク関数は対数関数である

■ロジスティック関数　ベルヌーイ分布に対する逆リンク関数であるロジスティック関数 $\theta = \dfrac{1}{1 + \exp(-\eta)}$ について，正しい記述はどれですか。

- 線形予測子 η がどんな値でも，出力 θ は 0 から 1 の範囲に収まる
- 線形予測子 η が 0 のとき，θ は 0 になる
- ロジスティック関数の逆関数は指数関数である
- ロジスティック関数はカウントデータに用いる

■確率分布の選択　以下のデータの種類と，それに適した確率分布の組み合わせとして，正しいものはどれですか。

- 量的データ (連続値) — ベルヌーイ分布
- 二値データ (0/1) — ポアソン分布
- カウントデータ (度数) — ポアソン分布
- 順序データ — 正規分布

第 25 章

3 つめの推定法

ここまで尤度を使った推定方法について説明してきました。モーメント法と最尤法，平均値についてはいずれも同じ答えが出るのですがその考え方が違うというところを確認してきましたね。さてここからは，もう 1 つの推定法である**ベイズ法**について解説します。そのためには，ベイズ法の根本的な法則について知っておいた方が良いので，少し回りくどいかもしれませんが，まずはそこから説明していきましょう。目的を先に教えてくれないとやだよ，という人のために一言で目的だけ言っておきます。ベイズ法は最尤法と同じく確率モデルを使うのですが，尤度が「確率じゃない」という妙な性質があったのに対し，ベイズ法は答えを確率で出します。尤度を確率にするための仕掛けがこれから始まるのです。

25.1 ベイズの定理

ベイズというのは人の名前で，トーマス・ベイズ (Thomas Bayes，1702 年 - 1761 年 4 月 17 日) はイギリスの長老派の牧師であり数学者でもある人です。この人の考えた「逆確率の法則」から端を発した推定法が，21 世紀の現代においてとても重要なものになってきています。ベイズ牧師の考えついた法則は非常に単純なもので，簡単に書くと次のような式で表現できます。

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

この式の意味するところを，確率の用語をいろいろ紹介しながら説明していきたいと思います。

話をわかりやすくするために，具体的な数値例とともに話を進めましょう。たとえば，ある学校の生徒数は男子が 40 人，女子が 60 人だったとします。そこからランダムに一人を選び出した時，それが男子である確率はどれぐらいでしょうか？ この確率を $P(\text{男子})$ とすると，

$$P(\text{男子}) = \frac{40}{100} = 0.4$$

であることはすぐにわかりますね。

では次に**同時確率 (joint probability)** という考え方を導入しましょう。これは先ほどの学校について，表 25.1 のように学年情報を追加した例を使って説明します。

記号で表現するために，性別の変数を A とし，A_1 = 男子，A_2 = 女子，学年の変数を B として B_1 =1 年生，B_2 =2 年生，B_3 =3 年生とします。

ここでランダムに一人を選び出した時，それが「3 年男子」である確率はどれぐらいでしょうか？ これは「性別は男」かつ「学年は 3」なので，性別と学年の両方の条件が入った同時確率といい，$P(A_i, B_j)$ と書きます。これは表から，次のように計算できますね。

$$P(A_1, B_3) = \frac{13}{100} = 0.13$$

表 25.1 ある学校の学年と性別のデータ

	1 年	2 年	3 年	合計
男子	15	12	13	40
女子	22	20	18	60
合計	37	32	31	100

次に用語として**周辺確率 (marginal probability)** というのを考えます。これはある分割に関してすべて足し上げたもの, というものですが, 要するに表 25.1 の合計欄のことです。たとえば「男子生徒についての周辺確率」は, 男子生徒が学年によって 3 つに分割されていますが, これをすべて足し上げるので, 1 年男子 +2 年男子 +3 年男子で求まるものです。式で言うと, 次のような意味になります。

$$\sum_{j=1}^{3} p(A_i, B_j) = p(A_i)$$

$$\sum_{i=1}^{2} p(A_i, B_j) = p(B_j)$$

全部の数字を足し合わせるので, その変数の確率の話ではなくなる, と思ってください。このように一方の変数のすべての確率を足し合わせることを**周辺化**する, といいます。

では次のステップ。今度は**条件つき確率 (conditional probability)** というのを導入します。無作為に学生を選び出す時, 「選ばれたのが女子である」ということが先にわかったとします[*1]。その時, その生徒が 2 年生である確率はどれくらいでしょうか？ この問いを「女子という条件がついた上での確率」という意味で, 条件つき確率といい, 表現としては $P(2\text{年生}|\text{女子})$ と書きます。2 つの分割を縦棒で区切り, 条件の方が後ろに書きます。「女子という条件が与えられた上での二年生の確率は」というように読んだりします。

ちょっと状況はややこしくなりましたが, 確率の計算そのものはそれほど難しくありませんね。女子である, というのが決まっているので, 分母が変わるだけなのです。つまり,

$$P(B_2|A_2) = \frac{20}{60} = 0.333...$$

となります。

条件つき確率の計算は分母が変わったと思えばいいのですね。この条件つき確率は, 同時確率を周辺確率で割っても計算できます。すなわち,

$$P(B_2|A_2) = \frac{P(A_2, B_2)}{P(A_2)} = \frac{0.2}{0.6} = 0.333...$$

となるわけです。

今度は学年が一年生の時, 二年生の時, 三年生の時, で考えてみましょう。この場合, それぞれで分母が変わりますし, 条件つき確率も変化します。性別が変わると学年の確率が変わりますし, 学年が変わると性別の確率も変わります。このような関係にあるので, この性別と学年という 2 つの変数は関係しあっていることがわかります。逆に, 一方の変数が変わっても他方の変数に影響しない場合, 両者は**独立 (independent)** だ, といいます。確率において独立であるとは, すべての i, j, k において次の関係が成り立つことを言います。

[*1] たとえば名前とか容易に類推できた, といったようなシーンです。最近では名前だけから性別を判断するのは難しくなりましたが, かつての名残で明らかにわかるような名前だったと思ってください。

$$p(A_i|B_j) = p(A_i|B_k)$$

これまでも (確率的に) 独立である例の話はいろいろしてきました。たとえばコイントスを続けて行うときは，それぞれの試行は独立だよね，という話をしました (→ セクション 23.5，Pp.318)。1 回のコイントスの結果が次のコイントスの結果に影響しない，という意味です[*2]。

ここで独立しているのならば，ここまでの式展開から，

$$\begin{aligned} p(A_i|B_j) &= p(A_i|B_k) \\ \frac{p(A_i, B_j)}{p(B_j)} &= \frac{p(A_i, B_k)}{p(B_k)} \\ p(A_i, B_j)p(B_k) &= p(A_i, B_k)p(B_j) \end{aligned} \tag{25.1}$$

ここですべての k の状態について B_k を数え上げる，つまり B を周辺化します。

$$\begin{aligned} p(A_i, B_j)\sum_{k=1}^{K} p(B_k) &= p(B_j)\sum_{k=1}^{K} p(A_i, B_k) \\ p(A_i, B_j) &= p(B_j)p(A_i) \end{aligned} \tag{25.2}$$

ここからわかるように，A と B が独立である場合は，同時確率と確率の積がおなじになります。独立している事象が起こる確率は，それぞれの確率を掛け合わせましょうということです。これまでも，コイントスやサイコロの例で，2 回続けて計算する場合はその積で表現してきましたよね。確率 θ で表が出るコインで，2 回続けて表が出る場合は $\theta \times \theta = \theta^2$，表・裏と出る場合は $\theta \times (1 - \theta)$ といった表現をしてきました。独立した事象は掛け算で表せる，というのはこういう理屈からなんですね。

さて，これで用語の準備は終了です。ここから式の展開が面白くなってきます。

あらためて，条件つき確率は同時確率を周辺確率で割ったもの，でしたね。つまり，

$$P(B_j|A_i) = \frac{P(B_j, A_i)}{P(A_i)}$$

ここで右辺の分母を両辺にかけて，

$$P(A_i)P(B_j|A_i) = P(B_j, A_i)$$

とします。これは A,B が何であるかにかかわらず，一般的に成立します。たとえば $P(A_i|B_j)$ と記号をひっくり返しても，

$$P(A_i|B_j) = \frac{P(A_i, B_j)}{P(B_j)}$$

より

$$P(B_j)P(A_i|B_j) = P(A_i, B_j)$$

としても構いませんね。

ところで，「2 年の男子」と「男子の 2 年」というのは同じ意味です。つまり，

$$P(B_j, A_i) = P(A_i, B_j)$$

[*2] 逆に一回のコイントスが次のコイントスに影響するとはどういうシーンでしょうか? 無理矢理考えるなら，コインが意思を持って「さっき表になったから，次は裏にしようとする」とか，トスしたコインを受け取り損ねて地面に落下し，片方の面が欠けて他方の面が出やすくなった，というようなシーンです。コインは意思を持ってないし，硬いものですから，これらはやはり考えにくい話ですよね。

ですから，上の式をつなぎ合わせて

$$P(A_i)P(B_j|A_i) = P(B_j)P(A_i|B_j)$$

とできます。ここで両辺を $P(B_j)$ で割って清書すると，

$$P(A_i|B_j) = \frac{P(B_j|A_i)P(A_i)}{P(B_j)}$$

が得られます。やったね！ベイズの定理が導出できました。

さて，これの何がすごいのでしょう？ 数式を「記号の羅列だ！」と思って拒否するのではなく，その意味をしっかり味わってみましょう。

25.2 ベイズの定理の意味

25.2.1 因果の向きについて

さてベイズの定理のすごいところは，左辺と右辺の中にある条件つき確率の中身が**ひっくり返っているところ**にあります。これがひっくり返ると何がうれしいのでしょうか。ベイズの定理の左辺には $P(A|B)$ があり，右辺は分子に $P(B|A)$ を含んでいます。$P(A)$(分子の 2 つ目の項目) や $P(B)$(分母) のことはいったん忘れてくれてもいいですし，

$$P(A|B) = P(B|A) \times \frac{P(A)}{P(B)}$$

と考えて，$P(A|B)$ が $P(B|A)$ の関数である，と読み取ってくれても構いません。

ここで A を「心のモデル」，B を「データ」と考えてみてください。私たちは心の仕組みを考えるときに，モデルをたてます。「あの人が A という行動をとったのは，心の状態が X だったからではないか」というのは心というモデルを立てて考えるということなのでした。心の状態が X であれば，人は A という行動をとるであろう，というのが研究者の仮説，モデルなのです。つまり，P(データ|モデル) が心理学でやっていることなのです。

ところが実際には，手に入れることができるのはデータだけです。心がどうなっているかはわかりませんが，人が ◇◇◇◇ な行動をとった，という事実だけがそこにあるのです。この事実を使って，我々のモデルがどれぐらい正しいのか。あるいはモデルのパラメータはどうなっているのか，を検証したいわけです。つまり，研究の営みとは P(モデル|データ) であり，データを所与 (条件) としたときの，モデルの確率を考えることなのです。データをとってモデルを検証するという営みが成り立つ根拠を，ベイズの定理が示してくれていると言えるかもしれません。大事なのは，不確かな状況においては我々は確率的にしか判断をできず，ベイズの定理では条件の向きをひっくり返して計算できる，という点です。原因が結果を引き起こす確率が知りたいときに，結果を手にすることで，原因がどれほどあり得たかを考えることができる。それがベイズの定理のポイントなのです。ベイズの定理は因果の向きを逆にできる，ということを示しているので，**逆確率の法則**と呼ばれることもあります[*3]。

25.2.2 確率という数字，再考

ここまでベイズの定理の説明は，性別や学年など離散的な数字をもとに説明してきましたが，連続的な確率変数でも成り立ちます。連続的な確率変数の場合，すべての確率を足し合わせるという操作が積分するこ

[*3] ベイズ自身がこの法則を発見したときに，「なんかおかしなことになってるかも」と思って結果を公表しなかったと言われています。神様が決めた世界を裏返しにすることに，背徳感のようなものを感じたのかもしれません。

とに変わりますが，それ以外は本質的に変わりません。一般的に書くと，

$$f(\boldsymbol{\theta}|\boldsymbol{x}) = \frac{f(\boldsymbol{x}|\boldsymbol{\theta})f(\boldsymbol{\theta})}{f(\boldsymbol{x})}$$

となります。ここで $\boldsymbol{\theta}$ はパラメータで，複数ある場合があるのでベクトルの表記 (太字) にしてあります。$\boldsymbol{x}$ はデータのことで，これも 1 つのデータではないので太字にしています。f は連続的な確率関数だと思ってください。先ほど説明したように，この関数は

$$f(\boldsymbol{\theta}|\boldsymbol{x}) = f(\boldsymbol{x}|\boldsymbol{\theta}) \times \frac{f(\boldsymbol{\theta})}{f(\boldsymbol{x})}$$

と考えても構いません。ここで $f(\boldsymbol{x}|\boldsymbol{\theta})$ は，パラメータが所与の下でのデータの出てくる確率ですから，**尤度**だ，ということがわかります。式の左辺は $f(\boldsymbol{\theta}|\boldsymbol{x})$ ですから，データが所与の時のパラメータの確率ですね。これをとくに**事後確率 (posterior probability)** と言い，それに対して右辺の $f(\boldsymbol{\theta})$ は**事前確率 (prior probability)** といいます。ベイズの式は，確率を確率に変換する公式なのです。

ところでこの**確率**って何なのでしょうね。パラメータについての事前の確率とは，一体どういう意味があるのでしょうか。

さて，確率の公理を思い出してほしいのですが，確率とは次の条件を満たす数字だということでした。

1. 確率の値は非負 (正または 0 の数字)
2. 全標本空間におけるすべての事象の確率の合計は 1.0
3. 任意の 2 つの相互に排他的な事象について，どちらか一方が発生する確率は個々の確率の和である

そして，確率には**頻度主義**的な考え方と，**主観確率**という考え方があって，どちらでもこの公理を満たしている限り確率として計算できます，という話をしてきました。

高校数学までは頻度主義的な意味で確率が説明されてきたと思います。すなわち，コインやサイコロを**無限に**投げ続けると，パラメータの値は 1/2 や 1/6 に近づいていくだろう，ということです。この無限に繰り返すと 1 つの値に収束するというのは，確率的収束という数学的な証明がされる考え方ですが，現実には無限に行うというのはあり得ません。心理学の実験も，同じ実験を無限に繰り返すと，という設定のもとで考えて帰無仮説検定を行ったりしますが，それがそもそもあり得ない前提じゃないか，と言われたらどうしようもないのです[*4]。無限の回数を考えて，その相対頻度，割合で確率を考えるので**頻度主義**と呼ばれています。

これに対して天気予報などは，信念の確からしさを確率で表現しています。明日晴れる確率が 30% というのは，明日という日が無限に繰り返されればそのうちの 3 割は晴れている，と言うのはやはりおかしいわけです。どんなループに巻き込まれてしまったのでしょうか，明日が無限に繰り返されるなんて！そういう意味では，普段私たちが慣れ親しんでいるのは，自分達の確信の強さ，どの程度その事象を信じているかと言う信念の強さを表している数字と言えます。明日 100% 雨が降る，というのは完全にその状態を信じているということですし，50% の降水確率は雨が降る可能性が半分，降らない可能性が半分だと考えていると言うことですね。また，相対頻度・割合で考えるときは，全体で割った平均的な数字を出すことになります。この頻度主義的な考え方ですと，たとえば野球のシーズン最初の試合，勝ったチームは勝率 100% になります。一試合しかしていないので，1/1 だからです。でも誰も「このチームは今シーズン一度も負けないだろう」と本気で信じているわけではないですよね。あるいは最初の打席でヒットが出なかったからといって，打率 0 割，永遠に打てない打者だとは誰も考えません。本当はもう少し低い勝率，高い打率だと思っているのに，そう表現できていないのです。その意味では，「確からしさを表す数字」として確率を使うほうが自然かもしれません。

[*4] さらに帰無仮説というあり得ない仮定を置いてますから，一体どこの世界の話をしているのやら，という気持ちになります。

つまり，確率という数字の見方には大別して二種類あるということです。どちらが正しいとか，どちらが優れているというわけではありません。どちらも上に述べた 3 つの公理を満たすものですから，確率は確率なのです[*5][*6]。

頻度「主義」とか「主観」確率，という言葉の使い方をすると，個人の考え方で数学のルールや数字の意味が変わるのはおかしい，と思う人がいるかもしれません。数学のルールは人類が存在しなくても永遠普遍の真実だ！という考え方があるのもわかります。主義や信念の対立で優劣を決めたいわけではないのですが，頻度主義的な発想とベイズ主義的な発想とでは，母数についての考え方が違っているのも事実です。頻度主義的な発想では，無限に試行を繰り返せばいつかは答えにたどり着くはずで，言い換えれば「真実はいつも 1 つ」なわけです。ただそれが直接わかり得ないから，徐々に近づいていくしかない。図 25.1 の上の段にあるように毎回の試行で信頼区間をとって表現できますが，これは本当の値 (図では 0.5 が真の値としています) を跨いでいるかどうか 0/1 の判定が続くわけです。

これに対して主観確率で考えるベイズ法による推定は，そもそも母数の値がわかりませんので，わからないことを確率で表現する。最初は幅の広い，全域に渡るような確率でぼんやり考えるのです。これに毎回の試行＝データを積み重ねることによって，この幅を狭めていき，「この辺にあるんじゃないかなあ」という確信度を高めていくという考え方です。

図 25.1　確率についての 2 つの考え方

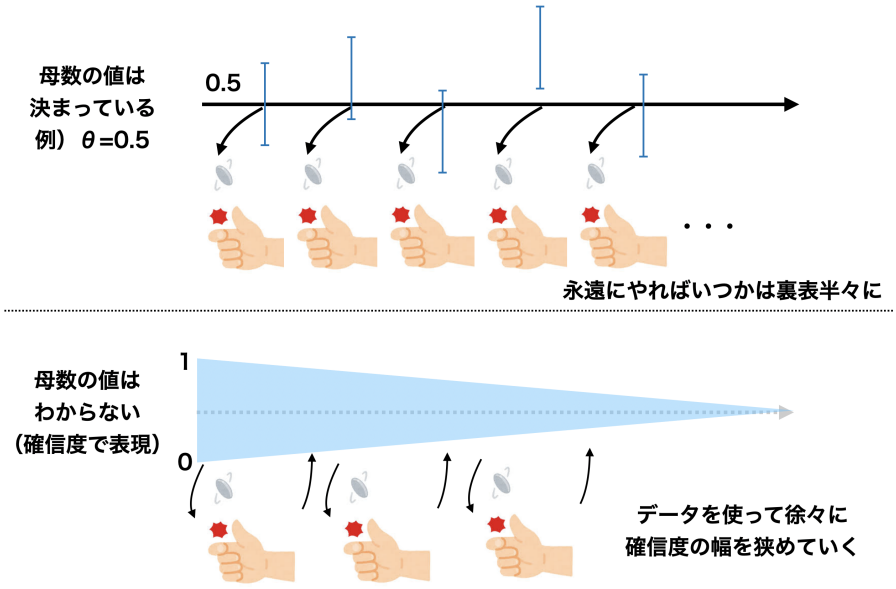

この後，ベイズ法による推定を説明していきますが，このとき真の値が定数としてただ 1 つ定まっている，と考えられるかどうかについては，とくに定まりがありません。母数は定数で定まっている，ただそれが確率的に

[*5] というか，この公理はさまざまな確率の考え方の共通基盤・最低限のルールをまとめただけなので，必然的にどちらにも合うようになっているというだけです。

[*6] ちなみに，主観確率が成り立つためにはどのような条件が必要かということについては，ギルボア (2014)などに詳しく論じられています。また繁桝 (2019)は主観確率という確率が成立する条件として，1. すべての不確かな事象の蓋然性は相互に比較できる，2. 蓋然性に関する判断は相互に矛盾しない，3. まったく可能性がない状態を 0，確実に起こることを 1 として，0 から 1 までのすべての数値を取りうる不確定な状態を作る実験が存在する，の 3 つを挙げています。人間が必ずこのルールに則って判断している，という話ではなく合理的な判断があるとするならば，この規則に則っていると考えるべきであるという規範理論であり，「そんな状況はあり得ないからだめだ」というのは反論として的外れなものです。経済学では合理的に価値判断をする人間を仮定して理論を組み立てており，この不確実状況下での意思決定論もそれと同じ系譜，かつ，ベイズ統計学の応用を許す理論的基礎になっているといえるでしょう。

しかわからないだけだという考え方をするのか，母数がそもそも確率的に分布していると考えるのか，いずれの考えであってもいいでしょう[*7][*8]。

現代的に，あるいは統計のユーザとしてはプラグマティックに「使い物になるほうが正しい考え方だ」という割り切り方をしても良いでしょう。いずれにせよ，これらの手法によって表現されるものの意味の違いについて，少し注意しておいていただければと思います。

25.3 3 つの推定方法の比較

さて，これで**モーメント法**，**最尤法**，**ベイズ法**という 3 つの推定方法が出そろったことになります。それぞれの特徴について，今一度確認しておきましょう。

■モーメント法 最初に説明したのは，標本平均をつかって母平均の推定値とする，不偏分散をつかって母分散の推定値とする，という，記述統計量に密着した推定法，モーメント法でした。

図 25.2 がそのイメージです。母集団から標本を得ている図ですが，まず母集団で実際にどのような分布になっているかは分かりません。図では薄い黒で描かれているのが神の目でみた母集団の分布です。我々はこれについては知り得ないので，正規分布じゃないかな，という仮定を置くわけです。正規分布は位置と幅，平均と標準偏差をパラメタに持ちますから，これが推定したい母数。この分布から無作為に標本が得られたとすると，小サンプルからなるヒストグラムが描けます。標本は正規分布かと言われると，サンプルサイズが小さい場合はとてもそうは思えませんが，原理的には正規分布にしたがっているはず。そして標本平均は母平均の，不偏分散は母分散の推定値として使えるということが数理統計学によって証明されているので，この標本統計量を母数を推定するための値として使う，というのがモーメント法です。ここには標本をたくさん集めれば，いずれは 1 つの値に収束していくという，無限試行の極限として確率を定義する考え方，いわゆる頻度主義的な考え方が根底にあります。

モーメント法は古くから使われてきた手法であり，また手続きのパターンが決まっているので統計パッケージに採用されやすく，最も広く普及した方法といえます。今でも心理統計のテキストのほとんどが，モーメント法に依拠しています。帰無仮説検定は基本的にこの系譜にあり，心理学においても他の分野においても，長らく使われてきています。ただし手続きがパターン化，悪く言えばマニュアル化し，「これさえやっておけば良いだろう」という使われ方が，マニュアルの誤読や誤解，ルール違反を生み出すことにもなりました[*9]。

ただし，マニュアル自体もアップデートされていってます。帰無仮説検定を行うには，結果を後から改竄したと言われないで済むように，事前のサンプルサイズ設計，検定基準の設定を行う。どこからどこまでが計画の範囲で，どこからは探索的な分析であるかといったことを明確にしておく。これらを事前に登録・公開しておくといったことが推奨されるようになっています。「とりあえず取れるだけデータを取って，あとでいろいろ分析

[*7] このような考え方の違いは，量子力学のコペンハーゲン解釈，ボーアとアインシュタインの哲学の違いに似たところがあります。アインシュタインは「神はサイコロをふらない」といい，物理現象は確たるものがあると信じていました。これに対してボーア率いるコペンハーゲン学派の解釈は，物理現象は究極的に確率的に存在していると言い，シュレディンガーの猫も生と死の重ね合わせた状態である (観測するまでわからない) と言い切るわけです。現代物理学としては量子力学が優勢ですが，アインシュタインの気持ちもわかりますね。

[*8] ベイズ統計の中にもさまざまな流派があり，Twitter では時折喧嘩になっています。争点はこの「主観確率」を認めるかどうかというところで，「人間はすべての情報を手に入れることはできないので，自分の知り得た情報の範囲の中で最適な判断をするしかない。」と考える主観ベイズ派と，「手に入れた情報はなんらかの確率分布から生成されたサンプルに過ぎず，確率的に変動するサンプルから真の分布の状態を推論するのだ」という情報統計学的立場があります。後者は日本の数理統計学者 (赤池弘次，渡辺澄夫) が展開している議論で，AIC や WAIC など有用な指標を提案していることもあって，日本ではよく知られています。しかし主観ベイズ派は，古くからいかにして主観的確率判断が成り立つかについて緻密な理論を打ち立てており，世界的にはこちらの方が多数派かもしれません。

[*9] これはこの統計手法が悪いというのではなく，何でもルール化してしまうと同時にハックする方法もできてしまうということですので，研究に対する態度の問題です。

図 25.2　モーメント法による母数の推定

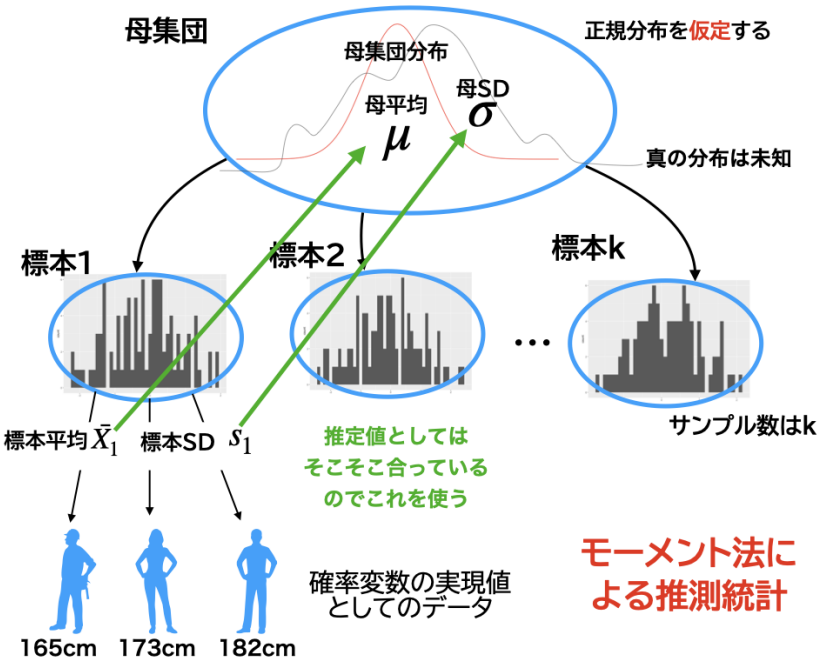

してみよう」というやり方は，探索的な研究領域では有効かもしれませんが，帰無仮説検定の手続きには向いていないということです。かつてはそのような実践がスタンダードでしたが，近年はそうもいかないということです[*10]。

■最尤法　さて，第二に，確率分布関数をつかってそれに合うパラメータを探すという，最尤法という考え方もあります。(図 25.3)。これは分散分析の生みの親，R.A. フィッシャー先生が考えた方法で，データが正規分布する母集団から生成されている，という情報をヒントに，データが与えられた時のパラメータがありそうな場所を探す方法，手元のデータが最も出てきやすいパラメータは何かを考える，という方法でした。これは母集団 – 標本の考え方からいっても非常に素直な発想です。いわば，確率分布をデータ生成機と考え，このデータを生み出す機械の設定 (=パラメータ) はどうなっているんだろう，と考えるというわけです。手元のデータが最も再現されやすいところがその設定値だろうと考える，というわけですね。

この最尤法による推定も長く広く使われています。計算にもそれほど時間がかかるわけでもないですから，多くのデータを扱った推定法としてはスタンダードな手法です。この方法が確率モデルの基本中の基本，王道といってもいいかもしれません。実際，回帰分析をはじめとする線形モデルをはじめ，多くの統計モデルが最尤法を使って解を出しています。

サンプルサイズが小さく，平均値の差を検出することだけが目的なのであれば，モーメント法による検定が有効なのですが，平均値の差に「個体差」「条件差」といった要素が絡んでくるとか，正規分布しないデータ (カウントデータや比率のデータなど) を扱う場合，つまり一般化線形モデル，一般化線形混合モデルのような場合は，最尤法を用いることになります。かつては正規分布の平均値差モデルに合わせるために，データを変

[*10] これは昔は適当に運用されていたが，最近はコンプライアンス意識が高くなって息苦しくなってきた，というような話とは違います。まず昔のマニュアルが作られた頃に比べて，計算機の能力が段違いです。かつては p 値をパソコンで厳格に出すことすらむずかしかったわけですから。加えてもちろん，再現性問題 (池田・平石，2016) があります。心理学の研究が再現されない原因の一つに，統計の誤用悪用，問題ある研究実践 (QRPs) があったということ。これらの反省にたって，自浄作用として生まれてきたムーブが事前登録などの対策なのです。真面目に学問をやる上では大事なことです。

図 25.3 最尤法による母数の推定

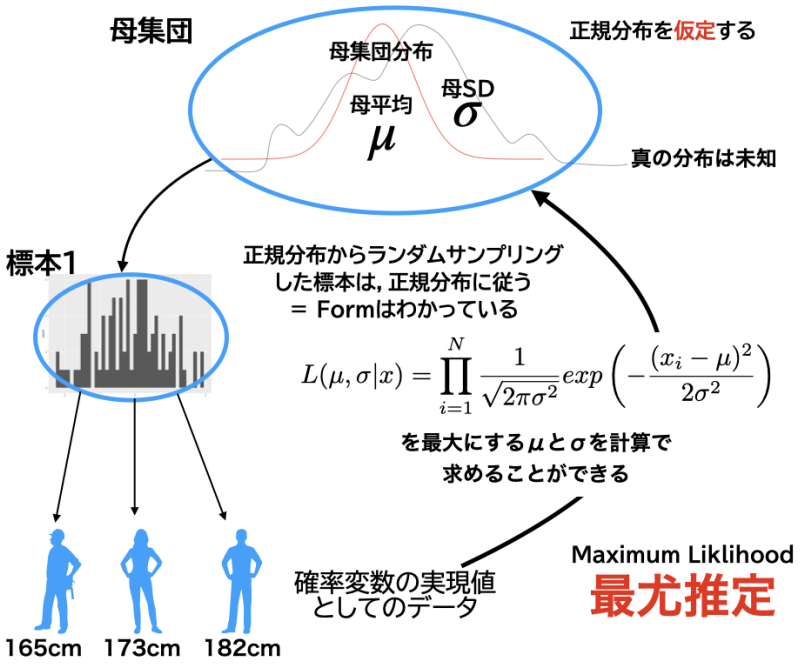

換して正規分布に近づけるというようなことがありましたが，今では正規分布に従わないデータをそのまま扱えるようになっています。

ただし，最尤法は確率の仮定とモデルが全面的に出てきますので，サンプルサイズが小さいと，推定値が不安定になったり，そもそも答えが出せなかったりすることがあります。もちろん確率分布の仮定が間違っている (比率のデータに正規分布を当てはめるなど) 場合は適切な答えが得られません。そもそも，確率・尤度の考え方がちょっと難しいので，誤解なくしっかり理解しておくことが重要です。

■ベイズ法 そして第 3 の手法，ベイズ法です (図 25.4)。このベイズ法の原理となる定理そのものは 18 世紀に考えられていたものですが，近年の計算機科学の発展によって実用可能なものになり，一気にその利用が広がっています。

この方法を使うと，最尤法でうまく答えが出せなかったような複雑なモデルであっても，問題なく答えが出せます。最尤法の場合はたくさんのデータがないと安定した答えが出ない，というようなことがあるのですが，ベイズ法の場合は少ないデータであっても答えを出してくれます。ベイジアン[*11]にとっての限界は，その人の想像力だけだ，という人もいるぐらいです (リー・ワゲンメーカーズ，2017)。

図にはベイズの結果の出し方，つまり事後の「確率分布」としての推定結果も示されています。モーメント法や最尤法は，推定値は一つの値でした。これに対してベイズ法は，結果が分布で出てきます。確率分布です。ですから，「この辺りにありそう」という感じ全体が答えになるのです。一つの値として得られないところが不思議に思えるかもしれません。この点，ベイズ法の結果の解釈が従来の方法 (モーメント法・最尤法) と大きく違うところであり，ベイズ法の結果を解釈する上で重要なポイントです。根本的には先ほど述べたように，「母数は確率的に分布している」と考える (あるいは「母数は定数であるが，その値は確率的にしかわからない」と考える) という根本的な発想の転換を必要とするのです。

[*11] ベイズ統計学をする人，ベイズ流の，というのをベイジアンといいます。ちなみにコンピュータ言語 Python を使う人はパイソニアン，組版ソフト LaTeX を使う人はテフニシャンなどといった呼称があります。なぜか R を使う人は「R おじさん」と言われています。

図 25.4　ベイズ法による母数の推定

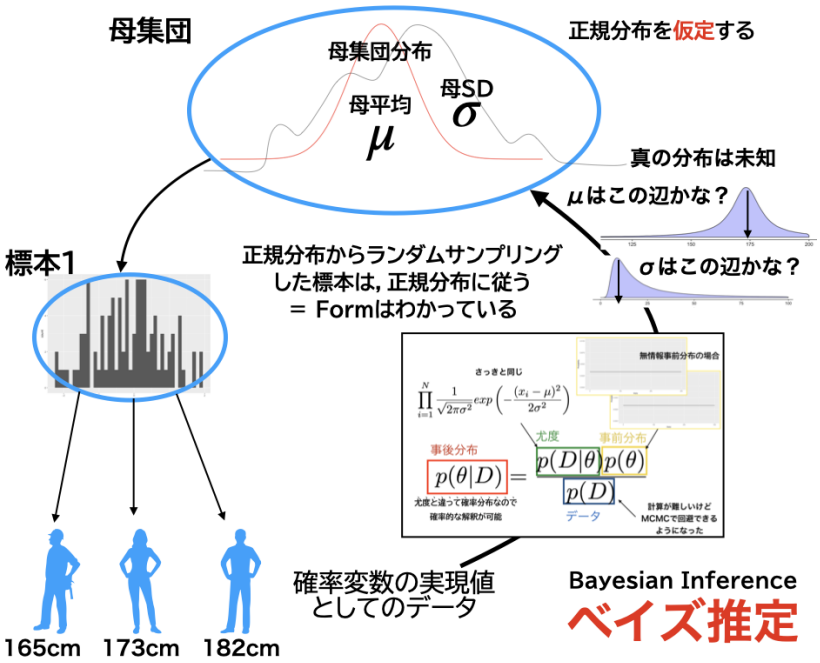

さて，三つの異なる手法を比較してきましたが，共通する点は「母集団に確率分布の仮定を置く」ということです。この仮定が間違っていれば，どの手法でやっても適切な推定にはなりません。そもそも推測統計学の根本問題として，少数のヒントから未知の答えを追い求めるという，不可能な条件設定での問題を解いていたわけですから，どれが正しいとか間違っているか，と言ったことを一概に言うことすらできません。しかし，仮定が適切であれば，どの手法を使っても同じ母集団についての推定なのですから，結果に大きな違いが出るわけではありません。モーメント法を使って有意にならなかったので，ベイズ法でなんとかならないか，というような考え方はお門違いで，厳に慎むべきです。

どの手法が良い悪いというのがあるわけではなく，考え方や特徴が異なるので，われわれユーザとしてはその手法の背景を理解し，異なる手法を用いる人との相互理解をするために，こうした違いに自覚的で言語化できるようにしておく必要があるでしょう。

■ベイズ法の強み　最尤法はサンプルサイズが大きくないと，安定した推定値が得られないことがあります。ベイズ法は，サンプルサイズが小さくても，モデルが複雑になっても答えが出せます。どうしてでしょうか？実践的には計算機科学の技術革新があったから，というのが答えなのですが (この点は第 29 講で改めて扱います)，原理的なところからも説明しておきましょう。

まずもう一度ベイズの定理を見てみます。

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

ここで $P(A|B)$ は事後確率，$P(B|A)$ は尤度，$P(A)$ は事前確率，$P(B)$ は正規化定数と考えることができます。事前・事後確率は，そのまま事前分布・事後分布と，確率分布と言ってもいいでしょう[*12]。つまり，

[*12] ここまでの説明では，離散的な変数による事前・事後確率でしたが，連続的な確率変数でも同様に扱うことができます。足し算が積分に変わると言ったことはありますが，ベイズの定理は同様に成り立ちます。

$$事後分布 = \frac{尤度 \times 事前分布}{正規化定数}$$

という形です。さて，最尤法はこの尤度だけを使って答えを出すのですが，ベイズ法の答え＝事後分布は，尤度に事前分布をかけています。この事前分布，つまり事前の情報や信念が，答えを出すために追加されているヒントなのです。このヒントのおかげで，尤度だけの最尤法では答えがでなくとも，ベイズ法では答えが出せる，ということになります。

次回は，ベイズ推定を実践的にどのように使うかを見ていきます。

25.4 課題

ある大学のクラスに，文系学部の学生が 30 人，理系学部の学生が 20 人います。統計の授業を履修済みの者は，文系に 12 人，理系に 14 人いました。このデータに基づいて，次の問いに答えなさい。

■同時確率と周辺確率 このクラスから無作為に 1 人を選んだとき，「理系学部かつ履修済み」である**同時確率**はいくつでしょう。また，「履修済み」である**周辺確率**はいくつでしょう。

■条件つき確率 選ばれた学生が履修済みであることが先に分かっているとき，その学生が理系学部である**条件つき確率**はいくつでしょう。またこれは「理系学部の学生が履修済みである確率」と一致しません。それはなぜでしょうか。

■事前確率を使った推論 ある感染症の有病率は 0.5%，感染している人が検査で陽性となる確率は 95%，感染していない人が誤って陽性となる確率は 5% だとします。検査で陽性になった人が実際に感染している確率を求めましょう。

■事前確率が変わると 前の問いと同じ検査を，有病率が 10% の集団で行ったとします。陽性になった人が実際に感染している確率はいくつになるでしょう。前の問いの答えと比べて，どのようなことが言えるでしょうか。

25.5 補遺: ベイズの定理を使った推論の例

ベイズの定理を使うとどういうことがわかるのでしょうか。事前の確率が事後の確率に変換される，つまり推論情報のアップデートができることの数学的な意味はわかったとして，実際どのようなシーンで活用できるのでしょうか。ここでは 2 つの例を見てみましょう。

25.5.1 事前情報を活用しよう

事前確率があることで何がわかるかについて，疫病の診断を例に考えてみたいと思います。

コロナウイルスに感染しているかどうかは，PCR 検査で明らかになりますが，これらの検査の結果というのも確率的な要素があるのはご存知でしょうか。本当は感染していないのに，検査では陽性になってしまう，ということがゼロではありません。こういうのを**偽陽性 (false positive)** といいます。逆に感染しているのに，検査で検出できずに陰性になる，**偽陰性 (false negative)** ということもあります。いずれも確率的な話です[*13]。

[*13] 勘のいい人はお気づきかもしれませんが，これは検定における 2 種類の間違い (→ セクション 14.3.1，Pp.198) と同じ話であり，偽陽性は**タイプ 1 エラー**，偽陰性は**タイプ 2 エラー**のことです。有意水準は偽陽性率 (本当は差がないのに差があると言ってしまう，本当は感染していないのに感染していると言ってしまう，せっかちなミス) として導入されていたのでした。

コロナに感染している → 検査で陽性になる，というのが因果関係ですが，我々は実際には検査で陽性である → コロナに感染しているかもしれない，というように推論します。これを今日学んだ確率の言葉で書いてみましょう。

感染している状態で，陽性反応が出るというのは条件つき確率として表現できますね。$P(\text{陽性}|\text{感染})$，というわけです。さてここに，そもそもの感染率というのが別途見積もれたとします。$P(\text{感染})$ ですね。さらにもうひとつ。感染しているかどうかに関係なく，陽性であるという結果だけ取り上げて $P(\text{陽性})$ を考えることもできます。これが揃うと，先ほどの定理を使って

$$\frac{P(\text{陽性}|\text{感染})P(\text{感染})}{P(\text{陽性})} = P(\text{感染}|\text{陽性})$$

を計算できます。つまり陽性になったという結果から，本当にかかっているかどうかの確率を計算できるのです。

多くの場合，検査で陽性だったら「もうだめだー」と思ってしまいがちです。これは陽性であると確実に検出できる，偽陽性がゼロの検査であれば正しい判断です。が，実際には確率的に判断すべき問題です。具体的に数字を例にして考えてみましょう。

ここでは乳がん検査 (マンモグラフィー) の数値例でお話しします[*14]。

- 40 歳の女性が乳がんにかかる確率は 1% です。
- 乳がんである人が乳房 X 線検査で陽性と出る確率は 90% です。
- 本当は乳がんでなくても，検査で陽性と出る確率は 8% にすぎません。
- あなたが 40 歳の女性で検査結果が陽性だったとしたら，あなたが乳がんである確率はどれぐらいでしょうか。

これは先ほどの公式に当てはめて考えると，

$$\frac{0.9 \times 0.01}{0.9 \times 0.01 + 0.08 \times 0.99} = 0.102$$

となり，10% ちょっとだということになります[*15]。ずいぶんと印象が変わりますよね。PCR 検査を複数回行うのは，これと同じような背景があるからです。

このように，事前確率があると，そこから遡って「診断された人が病気である確率」の計算をできるのです。逆確率，という言葉の意味が少しおわかりいただけたでしょうか。

25.5.2 モンティ・ホール問題

次は**モンティ・ホール問題**という，有名な事例を取り上げます。モンティ・ホールというのは人名で，この人がテレビショー「Let's make a deal」の司会をしていたのですが，その中で行われたゲームに由来するお話しです。問題はこんな内容です。

> プレーヤーの前に閉じた 3 つのドアがあって，1 つのドアの後ろには景品の新車が，2 つのドアの後ろには，はずれを意味するヤギがいる。プレーヤーは新車のドアを当てると新車がもらえる。プレー

[*14] 乳がんについては古くからの疫学的知見で，大体の罹患率が事前情報としてあるからです。コロナについては流行の状況によって罹患率が大きく変動するので，事前確率を 1 つに定めることが難しいのです。

[*15] おっと，計算についていけないぞ！と思った人。大丈夫です，いい方法があります。確率の計算は小数点を含みますし相対的な度数なのでわかりにくいですから，絶対的な度数に戻して考えればいいのです。たとえば 10000 人の世界だとして考えると，乳がんの人は 1%=100 人です。乳がんでない人は 9900 人です。陽性になる人は乳がんで陽性反応が出るひと ($100 \times 0.9 = 90$) と乳がんじゃないのに陽性反応が出る人 ($9900 \times 0.08 = 792$) の和で，882 人です。陽性反応が出た人の中で本当に乳がんであるひとは，$90/882 = 0.102$ となります。

ヤーが 1 つのドアを選択した後，司会のモンティが残りのドアのうちヤギがいるドアを開けてヤギを見せる。

ここでプレーヤーは，最初に選んだドアを，残っている開けられていないドアに変更してもよいと言われる。ここでプレーヤーはドアを変更すべきだろうか？

直感的には，選択したドアを変えても変えなくても，新車が得られる確率は 1/3 で変わらない，と思いますよね。でも実際は，変えた方が当たる確率は 2 倍になるのです。

なんでそんなことになるのか，と思うかもしれません。変えても変えなくても，確率は変わらないじゃないか，と思うのではないでしょうか。

実は明文化されていませんが，この話のポイントは，司会者のモンティは答えを知っていて，テレビ番組を盛り上げるために，必ずヤギ (ハズレ) のドアを開けるということです。司会者が「じゃあこっちを開けてみましょう，わー新車だ。ザンネーン」といったらシラけてしまうからですね。司会者がハズレのドアを開けるということは，新しい情報が追加されているということでもあります。であれば私たちは，情報をアップデートできるはずであり，確信度は変わるはずです。

3 つのドアを A,B,C として，どこかに当たりが入っているのですが，確信度はどれも同じぐらいなので，それぞれ 1/3 の確率だと考えます。あなたが A のドアを選んだとします。当たっている確率は 1/3 です。B か C が当たっている確率は，A ではないので，2/3 になります。モンティはどのドアを開けるでしょうか？ A のドアは番組がしらけてしまうので開けません。B か C を開けるしかないのです。ここでもし，ドア B の後ろに新車があるとモンティはこれを開けられないので，ドア C が開けられることになります。そうすると当然，ヤギが出てくることになりますね。さて，これまで B か C があたりの確率は 2/3 でした。でも C があたりということはあり得ないので，この 2/3 の確率は B=2/3,C=0 にアップデートされるはずです。あなたが最初に選んだ A のドアは，1/3 の確率だったわけですから，「A から B に変えますか？」と言われると，変えた方が 2 倍得だ (A=1/3,B=2/3,C=0) ということになります。

これはたとえば，3 つのドアでなくて 100 枚のドアがある場合で考えてみると，わかりやすいかもしれません。100 枚のドアがあって，あなたが 1 番目のドアを選び，モンティが 100，99，98, ...，5，4，3 番目のドア，と順番にドアを開け続けて，すべてにヤギが入っていたとします。それでも 2 番目のドアに変えないか？といわれると･･･モンティはどうして残り 99 枚のどれを開けてもよかったのに，隣のドアを開けなかったのか？と思いますよね。

モンティ・ホール問題は他にもいろいろな説明の仕方があります。納得いかなかった人は，Wikipedia などで調べてみると良いでしょう。

くどいようですが，ポイントは「情報がもたらされたときに，確率はアップデートできる」というところにあります。事前確率ともたらされる情報をつかって，確信度をどんどんアップデートしていく，これがベイズ法の考え方なのです。

第 26 章

分布で推定する

前回はベイズの定理の導入から，ベイズ推定の方法について話を進めてきました。ベイズ推定では結果が確率分布として得られる，ということから，考え方の転換が必要だという話もありましたね。この章では，ベイズ推定の結果として得られる確率分布をどのように扱うかについて話を進めていきましょう。

26.1 事前分布と事後分布

さっそく**ベイズ法**で，実際にパラメータを推定する例を考えてみましょう。

今回は例として，学力テストを取り上げます。難易度が同じぐらいの 10 問のテストを受けたとします。推定したいのは回答者の学力です。この能力は，問題に正しく答える比率 θ である，と定義します。学力 θ は直接観測できず，観測できるのは「正答数」だけです。今回ある回答者が 4 問正解したとして，学力はどうやって見積もれば良いでしょうか？ というのがここでの課題になります。

ベイズ法による考え方は，基本的にたった 2 つのステップからなります[*1]。

1. 不確実性，信念の強さを確率によって数量化する (**事前分布 (prior distribution)** の設定)
2. 観測データを使って事前の情報/信念を更新し，事後の情報/信念 (**事後分布 (posterior distribution)**) にアップデートする

これだけです。

ではまずステップ 1, **事前分布 (prior distribution)** について考えてみましょう。

26.1.1 事前の信念の表し方

事前分布は，確率のパラメータについて事前に与える分布です。パラメータがどれぐらいになるのか知りたいのに，事前に何かわかっていることがあるっておかしくない？ と思う人もいるかもしれません。ここで，確率のベイズ的考え方，すなわち確率とは確信の程度を表現しているのだと思ってください。不確実で，わからないものを，どの程度わからないのか確率で表現するのです。推論とは確率の再分配であり，「他に可能性がない」のであれば 100% 確からしい，と言えるのでした。逆に「事前にパラメータがどのあたりにあるのかなんて，まったくわからない」という場合も，確率で表現できます。この表現方法として，「どこ」にあるのかわからないのであれば「全部あり得る」と広く広く守備範囲を広げておけば良いことになりますね。確率なので面積は 1.0 でなければなりませんが，その分うすく伸ばすように考えれば良いのです。

図 26.1 に，4 つの確率分布を示しました。これらはベルヌーイ分布のパラメータ θ についての，個人の

[*1] 帰無仮説検定より少ない！やったね！

図 26.1　コイントスの出目についての四つの信念

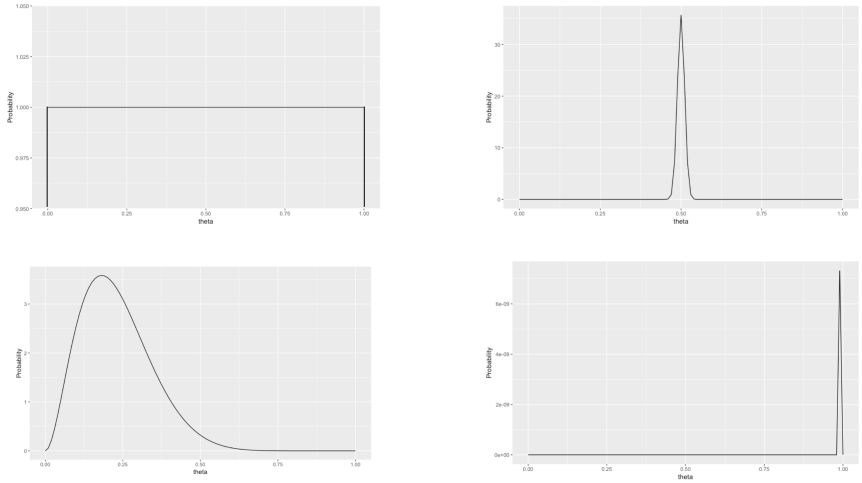

考え方を示していると思ってください。ベルヌーイ分布はコイントスのような，二値の結果を生じさせる試行についての確率分布ですから，確率 θ は $0 \leq \theta \leq 1$ の範囲にあるはずです。図 26.1 の左上は範囲すべてにわたってフラットです。つまり，「どこ」にあるとも断言できない，どこにも同じ程度にあるはずだという信念で，言い方を変えると何もはっきりとは言えない，つまりわからない状態を表しています。データを分析するにあたって，事前に何もわからないのであれば，このようにフラットな事前分布 (とくに**一様分布 (uniform distribution)** といいます) を置けばよく，こういう事前分布の置き方をとくに**無情報事前分布 (uninformative prior distribution)** と呼びます。図 26.1 の右上は逆に，$\theta = 0.5$ のあたりにあるはずだ，と思っている人の考え方です。少なくとも 0.45，大きくとも 0.55 ぐらいでしょう，ということなので，かなり確信度の高い (確率分布の幅が狭い) 状態にあると言えます。そこまではっきりわからないけど，でもちょっと裏が出やすそうだなあ，というふんわりと低めの予想をしている人は，図 26.1 の左下のような信念をもっている，と表現できますし，「絶対に表が出る。表しか出ない」と強く信じている人は図 26.1 の右下のようになります。

このように，まったくわからないことや，どこかに特定の強い思い入れがあること，あるいはなんとなくこの辺じゃないかと思っていること，など事前の情報を確率分布として表現することは可能なのです。研究の実践場面において，事前に何かわかっていることが「まったくない」のであれば，一様分布のような無情報事前分布，あるいはすごく幅の広い弱情報事前分布を置けば良いでしょう。身長や体重などのデータを分析するときに，正規分布を仮定しますが，このような場合は少なくとも負の値をとることはありませんし，いくら背が高い，体重が重いとしても 10m や 5t になったりするはずはないので，$0 \leq \mu \leq 100000$ のような幅で事前分布をおいても構いません。あるいは先行研究などから，ある程度のアタリがつけられるのであれば，その値を中心にふんわりした事前分布を置いたっていいのです。逆にいうと，このように事前分布をおくことで，先行研究との一貫性を持たせたり，先行研究の情報を活用して知見を積み重ねていくことができる，とも言えます[*2]。

さて今回の例に戻りましょう。この受験生の学力がどれぐらいなのか，事前にはまったくわかっていません。しかし正答率を考えるのですから，推定値は $0 \leq \theta \leq 1$ の範囲にあるはず。まったくわかっていないのですから，この範囲の一様分布を設定しましょう。つまり，とくになんの偏見も持たずにデータに立ち向かうという精神を，無情報事前分布で表現するわけです。

[*2] 分散分析や最尤法を考え出した R.A.Fisher 先生は，このベイズの考え方がお気に召さなかったようです。研究を始める前になんらかの思い込みを持って取り組むというのはおかしい，データに対してはなんら心構えを持たずに立ち向かうべきだ，という考え方です。Fisher 先生のベイズ統計学についての当たりの強さは，シャロン・バーチュ・マグレイン (2018) などにも記されています。

26.1.2 事後分布の計算

次にステップ 2 ですね。アップデートです。アップデートにはベイズの定理を使います。ベイズの定理を改めて見直しておきましょう。次のような式なのでしたね。

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

ここで $P()$ で表されているのは確率，とだけ言っていましたが，これは離散でも連続でも同じことですので，確率分布と呼びましょう。とくに左辺は「結果的にこうなる」という意味ですから，**事後分布 (posterior distribution)** と呼ばれます。

この確率的関係 (右辺も左辺も全部 P で囲われています！) を，実際に統計的推論の場面で用いることを考えます。左辺にある事後分布は，データをとったうえで，パラメータがどのあたりにあるのかを推論するということを条件つき確率で表しています。つまり，B がデータで A がパラメータ，事後分布 $P(A|B)$ が「データをとった上でのパラメータの確率」ということです。であれば，右辺にある $P(B|A)$ は「パラメータがあったときにデータが出てくる確率」を意味することになります。これってなんでしたっけ？ そう，**尤度 (likelihood)** ですね！

さて記号の意味を考えていきますと，$P(A)$ はデータを取る前のパラメータの確率，ということになります。これが先ほど説明した**事前分布**ですね。

また $P(B)$ はデータの確率，ということになります。データの確率？ データが得られるかどうかの確率？ というのはわかるはずがないような気もしますが，前回の乳がんの罹患率の例を思い出すと「あり得るパラメータから考えられるすべてのデータが出てくる確率をかき集めたもの」，というようなイメージができるかもしれません。用語としては**周辺尤度 (marginal likelihood)** といいますが，実践上はこれについて深く考えなくてもよいものであることを後で説明します。のでこれについても話はここまで[*3]。

今，言葉で表現したものでベイズの定理を書き変えてみます。

$$\text{事後分布} = \text{尤度} \times \frac{\text{事前分布}}{\text{周辺尤度}}$$

ここにあるように，尤度に何かをかけた結果，左辺が分布になっている，ということに注目してください。前回，尤度は確率ではないという話をしました。尤度関数の面積 (積分) が 1.0 にならないので，確率にならないのです。ですがこの式は，その尤度に事前分布をかけて，周辺尤度で割って，事後分布を得ています。事後分布は確率分布です。つまり，尤度を確率にしてくれるのがベイズの定理だ，とも言えるのです。

さて，ベイズの定理は事後分布=$\frac{\text{尤度} \times \text{事前分布}}{\text{周辺尤度}}$ で，今回の尤度は 4 問正解した，つまり (順番は分かりませんが) 正答，正答，正答，正答，誤答，誤答，誤答，誤答，誤答，誤答，というような状況です。ベルヌーイ分布ですから，尤度は $\theta^4(1-\theta)^6$ ということになります。

分子が確率と確率の掛け算になっているので，イメージしにくいかもしれません。私個人のイメージでは，波の衝突のような感じだと思っています。X 軸に沿って細かく数字を切り出して，逐一掛け合わせていくような方法のイメージでも良いかもしれません (図 26.3)。ちなみに事前分布が今回，無情報な一様分布ですので，尤度と組み合わせたところ，その高さは変わりますが全体的な形状は変化しません。このように，事前分布を一様分布にしておくと，データと確率分布の関係，尤度の形をそのまま結果に反映させることができることになります。さて，この掛け合わせた結果を $P(D)$，つまりデータの確率で割らないといけないのですが，こ

[*3] 本当の本当は，この周辺尤度というのがデータの適合度などを考えるときにとっても重要なものになってくるのですが，心理統計のライトユーザにとっては t 分布の導出のように「今ここでやらなくてもいい」ものです。興味がある人は浜田他 (2019) を読んでください。

図 26.2　ベイズ推定の実際

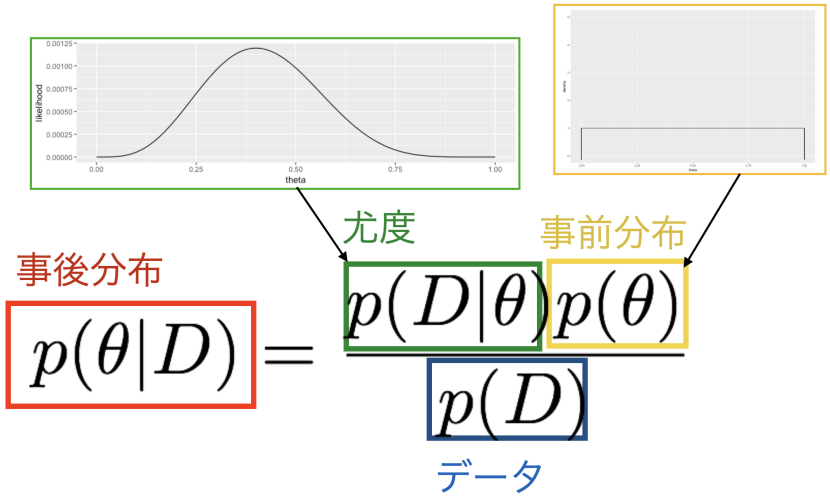

図 26.3　確率同士の掛け合わせ

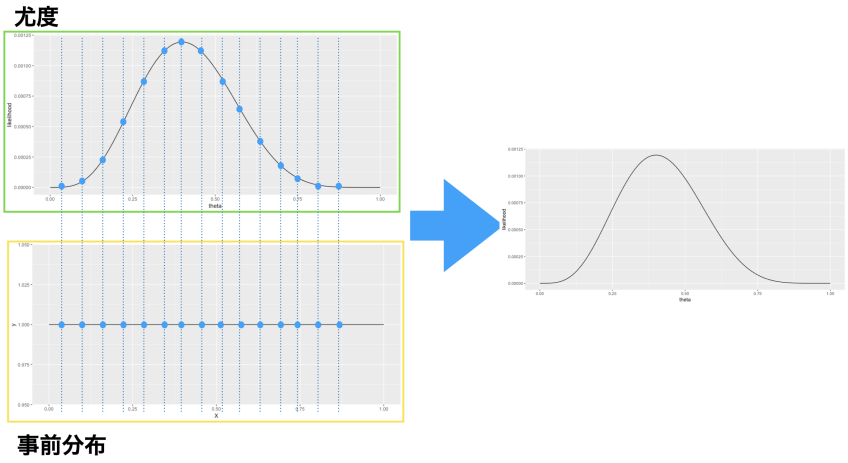

こは無視してしまいましょう。というのも，この分母が何をやっているかを考えれば，パラメータのような変わる数 (変数) が含まれていないのでここは「定数」になっていることがわかります。分子のところは尤度と事前分布を掛け合わせたものですから，数字はすごく小さいものになっているのでしょうが，最終的に左辺は事後分布という名の確率分布です。つまり，左辺は面積が 1.0 に規格化されており，分母は面積を 1.0 にするための，割り算用の定数に過ぎないということがわかります。我々はパラメータがどのあたりにあるのかが知りたいのですが，「ここにありそう」というのはそこの確率が高そうだ，ということであって，形さえわかれば縦軸の単位は別に詳しくわからなくても，横軸の位置を推測するのに苦労はない訳です。そういうわけで，分母は無視しちゃいましょう[*4]。この「形がわかればいい」というのを数学的に表すと，

$$P(\text{事後分布}) \propto \text{尤度} \times \text{事前分布}$$

[*4] 繰り返しになりますが，実は深くベイズ推論を進めていくとこの分母というのが結構おもしろいもので，このモデルの中でデータがどれぐらい出てきそうなのか，というモデルとデータの適合度を測る目安に使えちゃうのです。がそれはまたの講釈で。

となります。$\propto$ というのは，相似形である，という意味です。

さて，図 26.4 にあるように，事後分布が計算できました。これが θ の推定結果ということになります。

図 26.4 事後分布の計算

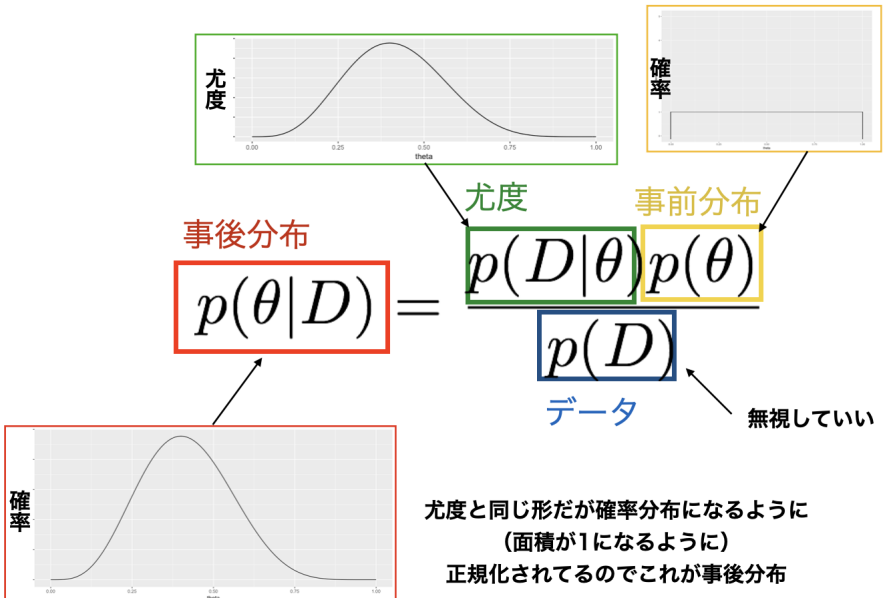

これで事後分布が計算できました。このように計算するのがベイズ法による推定方法です。推定結果である事後分布は図 26.4 の右下のような形になります。これが結果です，と言われても，ピンと来ないかもしれません。ベイズ法は推定結果も事後分布＝確率分布として得られます。モーメント法や最尤法は，θ の値が XXX です！と答えを出してはくれるのですが，ベイズ推定の場合は答えが「分布」で出ていますから，1 つの値にして回答を出すことができないのです。この分布全部が答えであり，事前分布の解釈のように「この辺りにありそうだ」という信念の強さを表しているとも言えます。

分布全体を見ながら「ふむふむ」でもいいのですが，分布の代表値を結果の報告に利用できます。たとえばこの分布関数のピーク，記述統計でいうところの最頻値を考えると，これは最も確率が高いところなので，最も尤もらしい，つまり最尤推定値と考えることができます。ちなみにこの関数の最尤推定値は**最大事後確率 (maximum a posteriori)** ということで **MAP 推定値** (maximum a posteriori estimate) と言われます。また，確率関数の期待値を代表値とすることもできて，それは Expected A Posteriori ということで **EAP 推定値 (expected a posteriori estimate)**，と呼ばれます。またこの関数は右に裾を引いていますから，平均値である EAP はあまり代表値として相応しくないため，中央値をつかって MEDian a Posteriori ということで **MED 推定値 (median a posteriori estimate)** を使ったほうがいいかもしれません。ちなみに今回のこの関数のピーク，MAP 推定値は $\theta = 0.4$ です。0.4 になる確率が最も高いのですね。

図 26.5 に分布を要約する数字を描いてみました。

また，分布の要約ですから，幅を表す指標を使って表現することもできます。幅を表す統計量としては，**四分位 (quartile)** や**パーセンタイル (percentile)** などがあります。四分位はデータを上から 25%, 50%, 75% のところで区切って四分割し，25% や 75% に当たる数値で報告するものでした。なお第 2 四分位，すなわち 50% 点は中央値と同じです。分割の場所はどこにおいても構わないので，任意のパーセント点で区切って報告するのがパーセンタイルです。33% だろうが 68% だろうが，なんでもいいのですが，下から 2.5%, 97.5% の点を報告することで全体の 95% が含まれるので，この 95% 区間を報告することも少なくありません。こうした事後分布の区間をとくに，**確信区間 (credible interval, C.I.)** といいます。

図 26.5 得られた事後分布を代表する数字

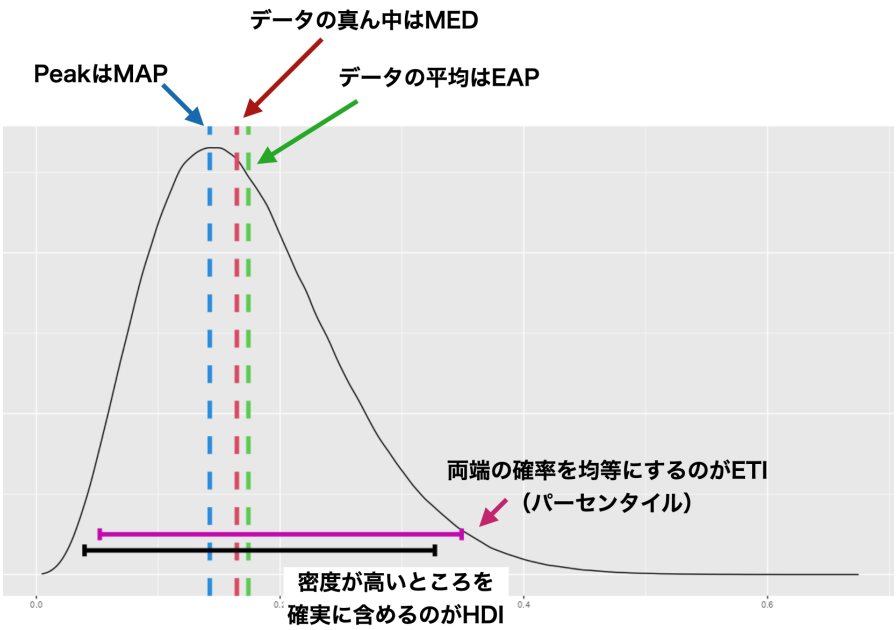

ちなみに，今回の事後分布のように，分布の形は正規分布のような左右対称であるとは限りません。左右それぞれに 2.5% ずつの裾を取る確信区間は，**等裾区間 (equal-tailed interval; ETI)** と呼びます。これに対して，分布の最も信頼できる部分，かつ分布の大部分をカバーし，区間内部のすべての点が，区間外の任意の点よりも高い密度を持っているように推定するものを**最高密度区間 (highest-density interval; HDI)** と呼びます。HDI の方が計算が面倒ですので，一般的には ETI の方が使われることが多いようです。

図 26.6 に ETI と HDI の違いを説明する図を作りました。やや左に偏っている分布を作ったのですが，この分布の 75%ETI は $[0.0886, 0.266]$ で，HDI は $[0.075, 0.242]$ です。ETI は左右の残りの面積を均等にした幅ですから，左側の面積が少し多めに取られています。一方 HDI は「その区間に入っている密度は他よりも高い」区間ですので，比較的均等な幅が得られているようです。数値的には微妙な違いですが，考え方の違いがあることに注意してください[*5]。

これらの数字を使って，事後分布を要約しながら考えていくことになります。今回の MAP 推定値は 0.4 でしたから，事後確率 0.4 である確率が最も高い，つまりこの人の推定値は 0.4 だ，とすれば良いでしょう。

・・・なんだそれ，と思ったかもしれません。10 問中 4 問正解だから 0.4 なのは当たり前じゃないか，ということだと思うのですが，繰り返しになりますがそれは標本平均値を使ったモーメント法の答え。尤度関数と事後分布の形が同じなので，最尤推定の結果も 0.4 になります。が最尤推定の場合は 0.4 になる「確率が最も高い」とは言えません。尤度関数は確率ではないからで，0.4 になるのが最も尤もらしい，というに止まります。ベイズ推定の場合は，(事後分布が)0.4 になる確率が最も高いといっても構いません。大事なのは，どの方法をとっても同じような答えが出るということです。同じデータで，同じ母数を推定しているのですから，筋道は違えど答えは同じということです。それよりも，各推定法の道のりの違い，表現の違い，どういうことが言えるかといった違いをしっかり踏まえておいてください。

ベイズ法の場合は確率での答えになっていますから，表現しやすい利点があります。たとえば MAP 推定値は 0.4 ですが，図 26.5 にあるように，「θ の値が 0.306 から 0.499 の間に入っている確率が 50%」だとか，

[*5] この区間を描くために，R で `bayestestR` パッケージ (Makowski et al., 2019) の `eti`,`hdi` 関数を使いました。

図 26.6 ETI と HDI の違い

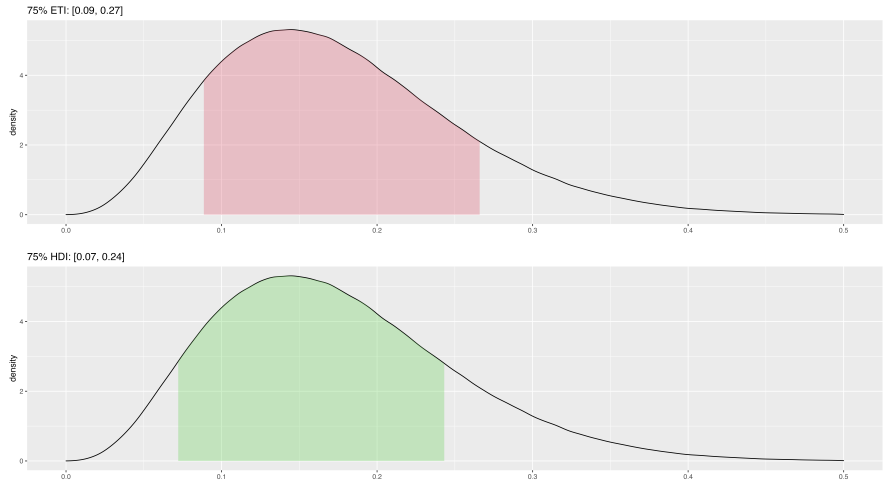

「95% の確率で θ が 0.159 から 0.682 の間に分布している」という表現ができます。この区間推定の方法は，モーメント法による信頼区間のそれとは違うことに注意してください。モーメント法による推定は，標準誤差を使って推定し，「この区間の中にある」と断言して，この宣言が的中する確率が 95% という意味です。実際には，あたっているかハズレているかの二択であり，基本的に点推定であるのに対し，こちらは基本的に区間推定で，逆に言えば「この区間の中にある」としか言えない，あるいは「この区間の中にある確信度が 95%」というような意味になります。頻度主義的な**信頼区間**に対し，ベイズ法によるこの区間は**確信区間 (credible interval)** と呼んで区別します[*6]。

26.2 事前分布と尤度の折衷

さて，改めてベイズ推定の (たった 2 つの) ステップを思い出してください。

1. 不確実性，信念の強さを確率によって数量化する (事前分布の設定)
2. 観測データを使って事前の情報/信念を更新し，事後の情報/信念 (事後分布) にアップデートする

まずは事前分布，それを事後分布に変える。これだけですね。データを得て事後分布にアップデートできれば，その事後分布を事前分布として次の分析に使うことができます。このようにデータ＝情報が得られるたびに，どんどんそれを活用して次に分析を進めていくことができるのが，ベイズ推定の大きな特徴です。

事後分布は，事前分布と尤度の積によって形作られます。図 26.7 に 3 つの分析例を示しました。図 26.7 は縦に見ていって欲しいのですが，最上段の尤度に二段目の事前分布を掛け合わせた結果として，事後分布の形が三段目に得られる，というステップを描いています。ここでいずれもデータと確率分布の関係＝尤度は同じで，前回の例である 10 問中 4 回正答がでたというベルヌーイ尤度関数の形になっています。二段目の事前分布ですが，一番左は「この人の能力は高そうだ (正答率が高い)」という分析前の見込みを示しています。この時，事後分布は一番左の一番下で，尤度のピーク (0.4) と事前分布のピーク (0.9 ぐらい？) の間ぐらいにピークを持っています。一番右は逆に「この人の能力は低いに違いない」という分析前の見込み，を示

[*6] といっても，英語でいうといずれも C.I. と略されるのです。ややこしいですが，これはおそらく後発のベイズ推定が表現を真似した，いたずら心による洒落ではないかと思います。微妙に違いはしますが，CI95 といっておけばどっちとも取れるので便利っちゃあ便利･･･なのかな。

図 26.7　事前分布と事後分布

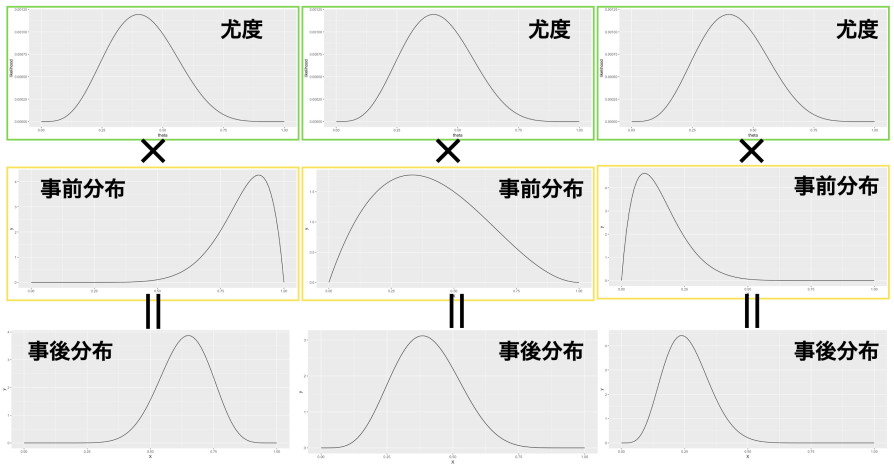

7383 しています。この時の事後分布は事前分布に引っ張られて，ずいぶんと低い方向によっています。真ん中の
7384 列はその中間で，「ちょっと出来が悪いかもな」，ぐらいの信念を表しています。これも事後分布は，尤度と事
7385 前分布の中間ぐらいの形になっています。

7386 私たちは事後分布を見て結果を解釈しますから，事前分布の持ち方 1 つでこんなにも結果が変わるので
7387 は，何かよくないのではないか，と思ってしまうかもしれません。事前分布が「分析者の恣意的な思い込み」に
7388 なってしまうかもしれないということです。勝手な事前分布を置いて答えが出たとしても，違う事前分布を置
7389 いてまったく違う答えが得られるというのでは，科学が恣意的な営みになってしまい，客観的で公平な性質を
7390 疑われるかもしれません。そこで事前分布は客観的に決めるとか，無情報事前分布をおくといった方法が良
7391 い，ということになります。

7392 しかし逆に言えば，事前分布を持っているというのはこれまでの蓄積を活用できるということでもあります。
7393 また，事前分布と尤度が掛け合わされて判断されるのですから，尤度がものすごく尖っている＝たくさんの
7394 データによってある事実が支持されているのであれば，ほんわかした事前分布ぐらいでは事後分布の形が変
7395 わることはありません。逆に，事前分布がものすごく尖っている＝とても強烈な事前の信念がある，あるいは
7396 これまでのたくさんの知識の積み重ねがある，という場合は，少しのエビデンスで結果が大きく変わることも
7397 ありません。その意味で，ベイズの性質はフェアな精神であるとも言えるかもしれません。

7398 26.3　課題

7399 **■事後分布を求める**　本文では，10 問中 4 問正答というデータから学力 θ の事後分布を求めました。同
7400 じテストを受けた別の受験者が，10 問中 8 問正答だったとします。事前分布を本文と同じ無情報事前分布
7401 (一様分布) にするとき，尤度はどのような式になり，MAP 推定値はいくつになるでしょうか。またこのとき，事
7402 前分布として図 26.1 の左下のような「正答率は低いだろう」という信念を置いていたら，事後分布のピークは
7403 この値より高い方，低い方のどちらに動くでしょうか。

7404 **■CI って？**　信頼区間と確信区間は，どちらも 95%CI と略されますが，意味は違います。それぞれ何につ
7405 いて 95% だと言っているのか，自分の言葉で説明してみましょう。

第 27 章

ベイズで判断する

心理学において，ベイズ法は比較的新しく導入されたものです。これまでは，後期から学んでいるように，要因計画と帰無仮説検定を組み合わせることで，群平均の差があるかどうかの判断を心理学理論の検証に使ってきていたのでした。では，新しくベイズ法が導入されることで，この帰無仮説検定はどのように変わるのでしょうか。ここでは，ベイズ法を使った判断の仕方について，心理学の研究における帰無仮説検定との違いを中心に説明していきます。

先に確認しておくと，帰無仮説検定はモーメント法，つまり母数がある値であるという前提のもとで標本から推論する立場でした。これに対してベイズ法は，母数が確率的なもの，確率分布として推論する立場という，考え方の転換があるわけです。このことは，推論に基づく判断に大きな影響を与えます。すなわち，モーメント法・頻度主義の立場では，母数に「差があるか・ないか」は必ずどちらかひとつです。真実はいつも一つ。だからこそ，「母数に差があるときに，間違って標本から差がないと判断してしまう場合」といった，タイプ 1 エラー，タイプ 2 エラーという考え方が出てきたわけです。これに対して，ベイズの立場では差が「ある」「ない」のような固定的な状態ではなくて，「差の大きさ」という確率分布として出てくることになります。真実はいつも分布。であれば，タイプ 1 エラー，タイプ 2 エラーという考え方そのものがなくなります。その他，帰無仮説検定を実践する上での注意点 (第 14 講) で触れたようなことも，ほとんどその前提から変わってしまうので，該当しなくなってしまうのです。なんということでしょう。

このことを念頭に置いて，それではベイズ法による判断のロジックをみていくことにしましょう。

27.1 ベイズ法と帰無仮説検定

27.1.1 帰無仮説検定の考え方を振り返る

ベイズ法での判断の違いをみるために，改めて，**帰無仮説検定 (null hypothesis significance testing)** の考え方をもう一度振り返っておきましょうか。

まずさまざまな個人差や誤差が含まれるであろうデータに対して 2 つのグループを作って (多群でもいいですが) 平均化し，そのことで個体差を相殺，一方の群にのみ影響があるような操作を行なって，結果の群平均を見ることで，平均的な**因果効果 (causal effect)** を見ることができるという**要因計画 (factor design)** を使って研究が行われます。この要因計画は，影響源をさまざまな要因と交互作用に分解していく**線形モデル (linear model)** であり[*1]，これを使って効果の大きさを見ることができるのでした。

ただ標本の効果の大きさだけでは限界があるので，これを**母集団 (population)** の世界での話に広げた

[*1] 分解していくというのは，全体の変動を要素の足し算に分解していくという意味です。単純な足し算にしているので線形 (一次関数) モデルです。

い。そこで**推測統計学**の出番です。平均値の位置や効果の大きさを，標本から推定していくわけです。

帰無仮説検定ではさらに，効果があったかなかったかという判断を行うための基準を用意してくれたのでした。効果がないというモデル vs 効果がなくはないという 2 つの仮説＝モデルを立てて，どちらのモデルが良いものかを検討します。

その際，いったん効果がないというモデル (=**帰無仮説 (null hypothesis)**) の立場に立って，効果がないと仮定した上でのモデル上の計算を進め，実現値がそのモデルからどれぐらい逸脱しているのかを考えるのでした。ここで効果が誤差に比べてどれぐらい大きいかという，分散の比の分布 (F 分布) を用いたり，二群の平均の差の分布 (t 分布) を用いたりして，実現値がどれぐらいあり得ないかを考えます。これが事前に決めた判定基準，すなわち**有意水準 (significance level)** よりも小さければ，滅多にないことが現実に生じているわけですから，帰無仮説が間違っていたのだ，と考えるのです。ここで，帰無仮説が間違っていたのだとなると，「差がないとは言えない」という結論になります。その結論を使って「もう少し検討しないとな」と考えるもよし，「差がないとは言えないというのは，差があるということだな」と判断するもよし，です。後者の場合は「本当は差がないのに差があると言ってしまう間違い (**タイプ 1 エラー (type I error)**)」とか，「本当は差があるのに差がないと言ってしまう間違い (**タイプ 2 エラー (type II error)**)」が生じる可能性があるので，注意しなければなりません。差があるかないか，という判断に飛びつくのではなく，どれほど効果があるのか量的に判断すべきで，この効果の大きさについては**効果量 (effect size)** という指標を使って報告する，というフォーマットがあるのでした。また，判断を繰り返しすぎると，タイプ 1 エラーがコントロールできなくなりますから，分析は慎重に，まず**主効果 (main effect)** をみてから事後の検定へ，といった丁寧な進め方をしなければなりません。

ふう！ここ何コマもかけて説明してきたことを，1 つのパラグラフにまとめるとこんな感じになります。十分面倒ですね！とくに「差がないとは言えない」とか，「差があるのにないと言ってしまう確率」のあたりで頭が混乱してくるのではないでしょうか。少なくとも私はいつも，教えていながら間違ってやしないか，ヒヤヒヤしております。どうしてこんなややこしい方法がありがたがられるのでしょう？それはひとえに，この考え方でいくと，出てきたデータが正規分布から得られていそうだということさえ仮定できれば，機械的にこの検定手続きを進めていくことができるからです。

27.1.2 帰無仮説検定のありがたさ

帰無仮説検定の話は，農学からでてきました。農業試験場で作物の成長についての実験をしていたところから，区画を分割して効果を比較するといったアイデアが形になっていったわけです。しかし一度，この分析のフォーマットが出来上がると，心理学でも利用できますよね。人間は農業試験場で取れる生産物ではありませんが，さまざまな特徴は正規分布してそうなので，利用すればいいのです。別に心理学に限りません。生物学でも，経済学でも，物理学でも，社会学でも，なんでも結構です。データが分布するとか，誤差が正規分布するといったアイデアがあれば，応用は可能です。しかもこの分析手続に含まれる，面倒な計算！とくに t 分布がどうだとか，F 分布がどうだとかいうことを数理的に導出しようとするととても大変ですが，計算のフォーマットは定まっているわけですから，R の関数にポンといれれば結果を出してくれる。難しいことを考えなくても，結果は出てくるのです。これが帰無仮説検定がありがたい理由で，フォーマットが定まっているからさまざまな領域に応用できること，その計算フォーマットを実装した統計パッケージが利用できること，これが大きいのです。

これのおかげで，必ずしも数学が得意ではないわたしたち心理学徒でも，統計の力を借りることができるようになりました[*2]。

[*2] しかしこのことが問題にもなってきています。すなわち，よくわかってないのに使って，結果だけ見て考えるというようなことが起こってしまうわけです。免許も持っていないのに，とりあえずアクセルを踏んだら車が走るから踏んでみた，というような話です

私たちは心理学が専門ですから，統計のことはよくわからない，ツールをつかうユーザの立場でしかない。というのはその通りだと思います。しかし同時に，心理学が専門だというのであれば，その結果の解釈や意味の理解にこそ，もっと責任を持たなければなりません。先ほど帰無仮説が棄却された場合について言及しましたが，差がないと言えるかどうか，判断基準を機械的に決めるのは確かに 1 つの方法です。しかしその前に，どの程度の差が実質的な意味を持つのか，何をもって差があると言えるのかについて，丁寧に考える必要があるでしょう。帰無仮説検定はあくまでも，区間推定の結果を判定するやり方の 1 つであり，そもそも推定された平均値の差，その区間，効果量や効果量の信頼区間について，考える必要があるのです。

ここで注意が必要なのは，従来の頻度主義的な考え方では，推定される平均値は定数として定まったものであるということです。**信頼区間 (confidence interval)** は，その区間の中に推定された平均値が**含まれる割合，正答率**を示す数字であり，区間と言いながら幅の情報を持っていないのです。これに対して，ベイズ法での推定値，たとえば群ごとの平均値の事後分布から考えられる**確信区間 (credible interval)** は，確率的に分布する平均値の**とりうる範囲**を示す数字であり，幅の情報そのものです。ベイズ法で推定される平均値の区間推定は，下限から上限の範囲に含まれる領域，あるいはあると思われる信念の領域を表しており，当たり外れの問題ではないのです。

27.1.3 ベイズ法のありがたさ

ところで，ベイズの考え方は事前分布を必要とします。これについては，「分析の前に差があるだろうとかないだろうとか，主観的な思い込みを持ってデータを弄るのはケシカラン」という批判がなされることもあります。しかし逆に，何の前提も置かないことが，果たして良いことなのかどうか，という話もあるのです (クルシュケ，2017)。

たとえばコイントスをして「21 回投げて 7 回は表が出た」話があったとしましょう。これは公平なコインか，というのを帰無仮説検定したいと思います。帰無仮説はコインが表になるか裏になるかに偏りはない，というもの。対立仮説は何らかの偏りがある，というものです。データは半分 (10.5 回) を下回っていますから，ちょっと怪しいところではありますが，実際に帰無仮説検定をするとこれは帰無仮説を棄却できません[*3]。つまり，7/21 という結果は 5% よりも生じやすい結果であり，驚くほどのことではないということになります。

しかし，この例がコインではなくて釘だったらどうでしょう？ 釘をトスして，頭の部分が底になって地面の上にピンと立ち上がったら表，そうでなかったら裏だと考えるのです。それで，21 試行中 7 回ピンと立ち上がったとします。なんで？ おかしくない？ 珍しくない？ すごくない？

こんな時でも，帰無仮説検定は棄却できません。21 回中 7 回表が出た，という事実は事実ですから，「おかしくない。こういうことだってある」という結論になります。私たちが「そんな馬鹿な，地面に磁石でもあるんだろ」などと思うのは，放り投げた釘が立ち上がることなんてあり得るはずがない，と強い信念を持っているからです。その信念は物理的な法則に裏付けられたものであり，十分に納得のいくものでしょう。しかしこうした信念すら「事前の思い込みはいけない」といって無視し，「事前に何も思い込みを持ってはいけない，出てきたデータがすべてだ」という態度を取るのであれば，偏りがあるとは言えない，という答えを支持するしかありません。これが科学者の定めでしょうか？

ね。そんな怖いことを現実社会でやったらとんでもないことなのですが，でも統計の話って難しいし，専門的すぎてどこかは機械や先人に任せるしかない。車だって，MT 車じゃなくて AT 車のほうが普及していますし，素人が AT 車のコンピュータ制御部分を修理したりできるほど専門知識を持ってるはずないですもんね。全部わからないと運転してはいけない，というのはちょっとやりすぎです。つまり私たちは，免許を持てる程度に基本的な知識を身につけ，悪用・誤用をしてしまわないように気をつけなければいけないのです。また，免許には更新があるように，統計の勉強を普段から怠っていてはいけません。新しい技術が使いこなせないと思った場合は，免許返納・車に乗らないという判断もするべきです。

[*3] 表 7，裏 14 という度数分布に偏りがあるかどうかは，χ^2 検定 (カイにじょうけんてい) を使います。R で `chisq.test(c(7,14))` と書くと，統計量 $\chi^2(1) = 2.33, p = 0.1266$ という答えが得られます。

これは，コインや釘といった違いを無視して，「表か裏か」という度数だけにしてしまったところに問題があります。データが得られるメカニズムは全く無視して，その表面的な度数だけ数えて考えています。事前情報を無視して (あるいは明記せずに)，結果だけで判断するのは，かえってフェアな態度ではないというべきです。これに対してベイズ推定をする時は，事前分布と尤度を明記しなければいけません。事前分布は研究者の事前知識を，尤度はデータが出てくるメカニズムを表しています。表か裏か，という結果もどういうメカニズムから 2 値になったのかを書き込むことができます。これを明確に記録するベイズ統計のほうがより開かれた態度だということもできるでしょう。

27.2 確信区間に基づく判断

27.2.1 確信区間の解釈

帰無仮説検定が面倒になる一番の理由は，判断が確率的になることです。判断して間違える確率，というところまで考えないといけないのでややこしいですね。これに対して**ベイズ法 (Bayesian method)** は，「正しい世界」「間違えた世界」を考えるわけではなく，「私が信じられる世界」を考えるので，こうした面倒が生じません。

例として，一要因 3 水準群間デザインをとりあげ，これをベイズ推定したとしましょう。このデザインは第 18 講でもやったもので，3 つの群から推定される母平均が同じかどうかということが問題になるのでした。何にせよ正規分布を仮定していますから，3 つの群 A,B,C についての確率モデルは，

$$X_{i1} \sim N(\mu_A, \sigma), X_{i2} \sim N(\mu_B, \sigma), X_{i3} \sim N(\mu_C, \sigma)$$

となっている，と書くことができます。ここで X_{ij} は，j 群に属する i さんのデータ，という意味であり，対応関係がないのでそれぞれ異なる 3 つの平均値 μ_A, μ_B, μ_C の正規分布から出てきているということをこの式が表しています。分散分析の時は，母分散が均等であるという仮定をおきますから，σ には群わけの添字がありません。

これをベイズ推定して，それぞれの群の平均値が得られたとしましょう。結果を図 27.1 に，各群の平均値の推定結果とその 95% 区間とともに示しました。この結果から「差があるかどうか」という意思決定をどのようにすれば良いでしょうか。

図 27.1 ベイズ推定による推定結果

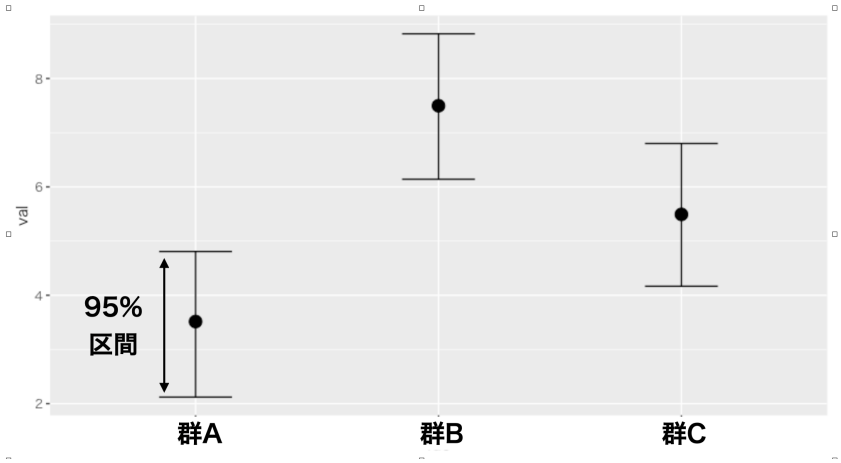

意思決定に際して，帰無仮説検定は「帰無仮説と対立仮説というモデル対決」に持ち込んでいき，5% の判定ミスを許容した上で決断するのでした。どうしてこのような形になっているかというと，母平均はどこか一点にあって，われわれはそれを探っているから，究極的には推定が「あっているか間違っているか」の 2 択にしかならないからです。

ところがベイズ主義的には，母平均はどこにあるのかわかりません。わからないので「この辺りにありそうだ」というのを確率で表現しています。それは知り得ない 1 点があるのか，それともそもそも確率分布としてあるのかは，哲学的観点が分かれるところです。何にせよあるかないか，という点の勝負ではなく，そもそも分布の勝負になっているので，この 95% 区間のどこかにあるとだけしておきましょう。図には 95% 区間を描いていますが，この幅のどこかに存在するとしたら，群 A の上側 95% 点よりも群 B の下側 95% 点の方が上にあって，この両群の確信区間は重複する領域がありませんから，この 2 群ははっきりと差がある，ということができます。一方，群 A と群 C，群 B と群 C は区間に重複がありますから，これらの組み合わせは差があるとは断言できない，ということになります。

That's all!これで終わりです。帰無仮説検定の場合は差があったとしても「差がないとは言えないし，そういってしまって間違える可能性が 5%」というのが正しい表現でした。まだるっこしいですね。これに対してベイズ推定した結果は，「95% の確信度で差がある」ということができます。ここでいう確信度とは言葉の通りこの主張の強さを表していますから，50% でも 99% でも構いませんし，95% よりも 99% の方が確信度が高い，つまりより強く主張していることになります。帰無仮説検定の時の p 値についてはこのような判断ができなかったのに比べて，非常に直感的でわかりやすい結果になっています。p 値については，5% と 1% を比べて 1% のほうが強い，などと言えないのでした。それは p 値がデータや母数についての数値ではなく，1. 帰無仮説という仮定を置いた上での，2. 現実値の珍しさの度合いを表す，3. 判定基準にすぎない，というものだったのでした。これに比べるとベイズ推定して得られた結果は，1. 母数の推定された区間，これだけですので，推定値で物事を考えるのにもってこいです。こうなってくると，5% にこだわった考え方が無意味であることが一層はっきりしてきますね。

この話は，ベイズ法でなくても別にいい話ではあります。というのも，頻度主義的なモーメント法による区間推定で，信頼区間をみて「差があるかなあ，ないかなあ」と考えることはできたわけです。どの群の信頼区間も大きくて，群間のそれが重複しているようであれば，平均値がどのあたりにありそうなのかわかりにくいわけですから，判断するには時期尚早。信頼区間が小さければ，判断があたるか外れるかのチェックをしてもいいけど，という感じで利用することもできます。何が言いたいかというと，帰無仮説検定は「判断」を定めることに無理があったのであり，科学的な研究アプローチとしては「外れたから研究は失敗」という短絡的なものではなく，徐々に何が正しいのかに近づいていけさえすれば良いのです。豊田 (2009) が指摘するように，重要なのは**有意差**ではありません。むしろ重要度はそれが一番小さくて，

$$\text{有意差} < \text{標準化された差 (効果量)} < \text{実質的な差}$$

の順に意味があるのです。データが実質的にどれぐらい違うのか，標準偏差いくつ分ぐらい違うのか，ということが大事なのであって，判断結果で有意差があるかどうかは大したことではありません。

27.2.2 実質的に等価な範囲による判断

とはいえ，確信区間や信頼区間を見て「差があるかなあ，ないかなあ」と思いを馳せるだけでは，レポートには書きにくいですね。そこで事前に，どれぐらいの差があれば良いと判断するかという基準を決めておく，というのがいいかもしれません。Kruschke (2018) は，**実質的に等価な範囲 (region of practical equivalence, ROPE)** という幅を事前に定め，そこに (差の) 事後分布の**最高密度区間 (highest density interval)** がどの

程度含まれるかで判断すべきである，という主張をしています (図 27.2)。

図 27.2 実質的に等価な範囲による判断 (Kruschke, 2018)

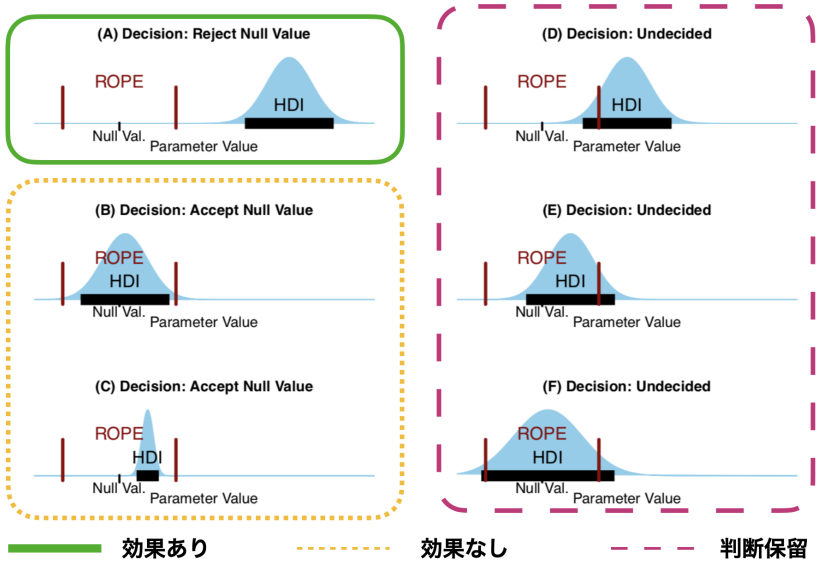

ROPE を使った判断をするためには，まず ROPE を決める必要があります。それをどうやって決めるんだ，ということについてまた議論があるかもしれませんが，それは分析を応用する各領域において，その領域専門の知識 (ドメイン知識) に依存する話なので一般論として語ることはできません。たとえば数字の上で 1 ポイント差があるというのが，男女の平均身長差の話であれば (そして単位が cm であれば)，なんだ 1cm の違いなんか実質的に意味ないね，という話になるでしょう。しかし 1 人の女性が一生のあいだに産む子どもの数 (合計特殊出生率) の国際比較であれば，子供が 1 人多いか少ないかというのは結構重要な差になります。錯視量が 1cm なのは大きいでしょうか？ 回転角が 1 度ちがうのは？ 反応時間が 1ms 違うのは？ こうした話はいずれも，単位とドメイン知識に依存することなので，一律に言えないのです。帰無仮説検定は一律に 5% と言ってくれました。しかしそのことが，大事な何かを見失わせたのかもしれません。ここを手抜きせず，しっかり考えることが第一歩です。

仮に，ROPE を $[-1.0, +1.0]$ と定めたとしましょう。ROPE は実質的に等価＝差がない範囲ですから，今回 0 を挟んでいます。さてベイズ法の場合，データから得られる平均値の差というのも事後分布として，幅を持ってえられます。たとえばこの差 δ の事後分布の 95%HDI 区間が，$[+1.5, +3.0]$ であったとしましょう。これは ROPE の範囲外です。図 27.2 の (A) のように，完全に外れていますから，これは差があると判断していいでしょう。逆に図の (B) の上のように，95%HDI 区間が $[-0.5, +0.5]$ の場合。完全に ROPE の中に含まれていますから，これは実質的に等価。差があるとは言えません。仮にこの 95%HDI 区間が短く，$[+0.4, +0.6]$ のように 0 を跨いでいなくても，ROPE の中に入っている場合はやはり，差があるとは判断しません。そして図の右にあるように，(上)HDI 区間が $[+0.5, +1.5]$ のように，ROPE に一部引っかかっている場合，(中)HDI 区間が $[-0.3, +1.3]$ のように一部はみ出したけれども ROPE の中に入っている場合，(下)HDI 区間が $[-1.2, +1.2]$ のように ROPE よりも広い場合。これらはいずれも「判断保留」とするのです。上・中はどちらの可能性も含まれていますし，下の図は HDI が広くて証拠不十分，というわけですね。「結局差があるかないか，どっちなんだ」という判断には時期尚早で，科学的な態度としては拙速な判断の方が弊害が大きいので，正直に「まだそこまで言える状態ではないですよ」というのが正しい態度です。

ベイズによる判断は，確率分布を使うからはっきりしない，と思うかもしれませんが，急いではっきりさせ

られるほど心理学の事象は明確でもないし，心理学の理論は強固でもないのです。だからこそ，確率分布を使って，まだそこまで言えない，ということを正直に表明するのが科学的な態度ではないでしょうか。

27.3 ベイズファクター

ベイズは確率分布で結果が出るから，「これ！」といった答えが出ないのか，と思われたかもしれませんが，実はそうではありません。むしろ，ベイズを使った方法ではっきりとした判断をすることもできます。それが**ベイズファクター (Bayes factor)** による判断です。ベイズファクターは，帰無仮説検定のように「差があるかないか」という判断をするための方法です。帰無仮説検定では，帰無仮説と対立仮説という 2 つのモデルを比較していました。ベイズ法でも同じように，2 つのモデルを比較することができます。

もう一度ベイズの公式を見てみましょう。ベイズの公式は次のようなものでした。

$$p(\theta \mid D) = \frac{p(D \mid \theta)p(\theta)}{p(D)}$$

言葉で言うと，事後確率は事前確率と尤度の積を**周辺尤度 (marginal likelihood)** で割ったもの，となります。ここまで事後分布の形に注目してきたため，分子に当たる事前確率と尤度の方に話が集中していましたが，ここでは分母に目を向けます。分母は $p(D)$，つまりデータが出てくる確率で，定数なので考えなくていいよという話をしてきましたが，モデル比較ということを考えると，重要な意味を持ってきます。

さて帰無仮説検定は，帰無仮説というモデルと対立仮説というモデルの対決だ，という話をしました。あるモデル $\mathcal{M}$ をつかって検証する，という条件をこのベイズの公式に追加してみましょう。

$$p(\theta \mid D, \mathcal{M}) = \frac{p(D \mid \theta, \mathcal{M})p(\theta \mid \mathcal{M})}{p(D \mid \mathcal{M})}$$

すべての要素に「あるモデルという条件のもとで」という条件が追加されています。今度はここで分母に注目します。分母の $p(D \mid \mathcal{M})$ を言葉にするならば，モデル $\mathcal{M}$ が与えられた時のデータの確率，ということになりますね。ここでモデル $\mathcal{M}$ はパラメータ θ を持つモデルなのですが，このパラメータがかりに 2 つしか状態を持たない，たとえば θ_1 と θ_2 しかないのであれば，この 2 つを使って次の計算ができます。

$$p(D \mid \mathcal{M}) = p(D \mid \theta_1, \mathcal{M})p(\theta_1 \mid \mathcal{M}) + p(D \mid \theta_2, \mathcal{M})p(\theta_2 \mid \mathcal{M})$$

これはつまり，θ で**周辺化 (marginalization)** したことになります。確率のすべてのパターンを足し合わせると，そのパラメータが消えてしまうわけですね。K 個の状態を持つ離散的なパラメータの場合に一般化して書くと，次のようになります。

$$p(D \mid \mathcal{M}) = \sum_{k=1}^{K} p(D \mid \theta_k, \mathcal{M})p(\theta_k \mid \mathcal{M})$$

連続的なパラメータであっても，総和 $\sum$ の記号が積分記号 $\int$ に変わるだけで，式としてはほぼ同じです。

$$p(D \mid \mathcal{M}) = \int p(D \mid \theta, \mathcal{M})p(\theta \mid \mathcal{M})d\theta$$

さてこのように考えると，$p(D \mid \mathcal{M})$ はモデルを考えた上でのデータが得られる確率，ということであり，求め方は「モデルが想定するすべての確率を網羅的に数え上げたもの」ということになります。検定のロジックは

帰無仮説と対立仮説という 2 つのモデルでしたから，$p(D \mid \mathcal{M}_{null})$ と $p(D \mid \mathcal{M}_{alt})$ というモデルを比較するという話だったことになります。そしてこの確率は，想定したモデルからデータが得られる確率，という意味ですから，言い換えると想定したモデルがどれほどデータに支持されているかということでもあります。モデルの想定通りのデータが出てきたのであれば，この数字は大きな値になりますし，モデルの想定していなかったデータが出てきたのであれば，この数字は小さくなります。もしモデルが「どんなデータでも出てくるよ」というような漠然とした広ーい予測しかしていなかった場合，これはパラメータの範囲がごく広いということですから，そのごく広い範囲すべての場合にわたってデータを計算すると，相対的に予測していないところからデータが出てきていることが多くなり，結局この値は小さくなります。つまり「なんでも説明できるモデル」は何も説明しないことになるのです。この値が，モデルがデータに支持されている程度を表している，ということの意味が伝わりましたでしょうか。

その上で，次のような数字を考えます。

$$BF_{10} = \frac{p(D \mid \mathcal{M}_1)}{p(D \mid \mathcal{M}_0)}$$

この数字は**ベイズファクター (Bayes factor)** と呼ばれるもので，モデル 0 に比べモデル 1 がどれほどデータに支持されているかを示す数字です。この数字が 1.0 より大きければ，モデル 1 はモデル 0 に比べて相対的に強くデータに支持されているということになります。逆に 1.0 を下回ると，モデル 0 のほうがモデル 1 よりもいいね，ということです。モデル同士の比による表現ですので，BF_{01} としても構いません。その場合は，モデル 0 がモデル 1 に比べて，どれほどデータに支持されているか，ということになります。

ここでモデル 1 が対立仮説モデル，モデル 0 が帰無仮説モデルだと考えてみてください。ベイズファクターはどちらがよりデータをうまく表しているか，どちらがよりデータに支持されているかがわかるのですから，対立仮説が帰無仮説モデルに比べてデータの支持が X 倍ある，と言い切れます。逆に，帰無仮説が対立仮説に比べて云々，も同じように言えるのです。このように，ベイズファクターを使うと，「差がない」という帰無仮説を積極的に支持することもできます。これは帰無仮説検定の枠組みでは決してできなかったことです。帰無仮説検定の枠組みでは，帰無仮説は仮定，つまり「帰無仮説が正しいとすると･･･おかしな現実があるよね」というロジックだったわけですから，帰無仮説は 100% 正しく，その正しさを検証することはできなかったのですから。

ということで，ベイズファクターを使うと，どちらのモデルがどれぐらい優れているかが定量化できます。しかしこのように指標化されると，つい「じゃあ BF がどれぐらいの大きさだったらいいんだ」と目安を聞きたくなるのではないでしょうか (そしてそれは一般に 3 以上と言われています)。しかしそれはあまりお勧めしません。帰無仮説検定が陥ったように，つまり p 値の 5% を目指した研究が陥ったのと同じように，無意味な目標数値になってしまうかもしれないからです。

ちなみに少し注意点をあげておくと，ベイズファクターは事前分布の置き方によって，その数値が大きく変わることがあります。3 倍，10 倍支持されている，というような程度なら可愛いもので，ものによっては 10 万倍，100 万倍，というような数字が出ることもあります。このこともあって，ベイズファクターの数値目標はあまり考えない方が良いかもしれません。もうひとつベイズファクターの弱点を挙げておくと，複雑なモデルの場合，ベイズの理論の分母，周辺尤度の計算がとても難しいということが挙げられます。パラメータのあらゆる可能性を考えるのが分母になるので，パラメータが多くなればなるほど，積分で計算する数がどんどん重なってしまうのです。ベイズファクターという一元化は便利ですが，実務上難しいところもある，というのも知っておいてください。

ともかく，これがベイズ流のモデル比較の方法のひとつです。他にも情報量統計学の観点からモデルの予

測力などで評価する方法[*4]などもありますが，いずれもこの周辺尤度を使うやり方です。

なんだ，絵に描いた餅か，と思われたかもしれません。でも大丈夫。計算が難しくなるのは，モデルが複雑な場合だけです。帰無仮説検定は非常に簡単なモデルなので，ベイズファクターも比較的簡単に計算できます。たとえば二群の平均値の差の検定に関して言えば，帰無仮説は $\mu_1 = \mu_2$ であり，対立仮説は $\mu_1 \neq \mu_2$ というものでした。対立仮説は 2 つの母平均がイコールでなければすべて OK，という仮説であり，言い換えれば $\mu_1 - \mu_2 \neq 0$ ということです。つまり差である $\mu_1 - \mu_2$ を X 軸に取ったとすると，帰無仮説は $X = 0$ というピンポイントな，ごく部分的な仮説になっています。対立仮説の広い範囲の中で，帰無仮説はその一部・特殊ケースということであり，このようにネストされた仮説の場合は**サヴェージ・ディッキー法 (Savage-Dickey method)**(リー・ワゲンメーカーズ，2017) という計算法でベイズファクターが計算できることがわかっています。この方法によるベイズファクターの計算は，次の講義で扱いますのでお楽しみに。

27.4 帰無仮説検定に対するベイズ法の利点

いろいろ説明してきましたが，**ベイズ法 (Bayesian method)** による推定でも，効果があるかどうか，平均に差があるかどうかを考える方法はあるということです。区間推定を使う方法，ROPE を決めておく方法，ベイズファクターの算出の 3 つの方法を見てきました。いかがだったでしょうか。

個人的には，ベイズ法は帰無仮説検定よりも優れている点が多いと思っています。特に，初学者にはベイズ法による検討の方が向いているのではないか，というのが私の意見です[*5]。ここでは，その理由を 3 つ挙げておきます。

■そのままの大きさの評価ができる まず 1 つは，上でも述べたように 1 bit 判断に陥りにくいことがあります。差，つまりどれほどの効果があったのかを直接議論しますから，最初から効果量を，効果の大きさを考えていることになります。帰無仮説検定の問題点として，差が大きかったのか小さかったのかを無視して「とにかく有意である」の一点張りで議論を組み立ててしまう危うさがあったわけですが[*6]，ベイズ推定をもちいた考え方であれば，このような誤解に陥る危険性を未然に防ぐことができているとも言えます[*7]。とくに未知な状態が多い現象について探索的な研究をする場合は，帰無仮説検定が性急に判定結果を出すことで，誤った方向へ仮説や理論が誘導される可能性があるので，この問題は心理学全体にとって重要なポイントだと思われます。

これまで，5% 至上主義だとか，有意にするための努力だとか，いろいろな問題を指摘してきました。これを指摘して「先人たちはなんてバカな！」という話をしたいのではありません。そもそも心理学という学問も西洋から輸入された概念ですし，日本に心理学がもたらされてきてから，要因計画，分散分析，線形モデルと徐々にその性質や手法がわかってきたわけで，まだ十分その欠点や限界が周知されてなかった時代があったことは事実です。その時代の研究者たちは，その時代の中で最善を尽くしてきたのだと信じます。そして問題があればそれを克服すれば良いわけですし，誤解や誤用がより少なくなるように，教育的配慮をしていくことが大

[*4] WAIC という指標を使います。詳しくは浜田他 (2019)などを参照してください。

[*5] 受講生がこれに同意しなければならない，ということではありません。もちろん賛同しないからと言って単位が出ないと言ったことはありません。異論・反論はウェルカムです。ただし，ロジカルに・批判的に反論してくださいね。

[*6] それにしたって「差がないとはいえない」「相関がないとは言えない」という程度の主張でしかないのが歯痒いところです。「君が僕と付き合う気がないとしても，今日こうやってデートできたのなら，君が僕のことを好きではないとは言えない」という帰無仮説検定のやり方って，あんまりかっこよくないですよね。「今日こうやってデートできたのだから，君が僕のことを好きだという確信がさらに強まった」というベイジアンの方がモテると思いませんか?

[*7] もちろんこれは私の「ベイズ贔屓」が入っている表現で，頻度主義的発想であっても帰無仮説検定のような判定をせず，推定値とその信頼区間で考察するに留めておけば良いのです。線形モデルでも最尤推定してその信頼区間を考えればよく，無理に判定までする必要はないからです。

事だと考えます。その意味で，ベイズ法は性急な判断に陥りにくく，現実的な「差とは何か」ということを考えるのに適しているという意味で，利点があると思うのです。

■帰無仮説を積極的に支持できる 第二の点は，帰無仮説を積極的に支持できることです。

研究の実践上は，関係がないとか効果がないということを示したいというシーンもあるでしょう。しかし帰無仮説検定の枠組みの中では，それはできませんでした。なぜなら帰無仮説を棄却することで決断するのであり，「差がない・効果がない」という仮定の下で計算を進める以上，その仮定が正しいかどうかはその技術で検証することはできないのです。

ベイズ推定の流れでは，帰無仮説もモデルとして表現します。2 群の平均値差がないモデルであれば $\mu_1 = \mu_2$ というモデル，といえます。これを線形モデルの文脈で言えば，回帰直線の傾き $\beta_1 = 0$ が帰無仮説モデルです。これはパラメータが特定の値である，という一点張りのモデルですから，対立仮説である $\beta_1 \neq 0$ というモデルに比べると，非常に自由度の少ないモデルと言えるでしょう。ですから，ベイズ推定するなら β_1 の事後分布がどのあたりにあるか，というのを見ればいいわけです。あるいは $\delta = \mu_1 - \mu_2$ の事後分布を見る，といっても同じです。そしてデータをたくさん追加すれば，その確信区間が狭くなっていくでしょう。その区間が 0 を含むことがはっきりわかれば，「差がない」ということがよりはっきりと言えるようになるわけです。含むべき値を 0 に限定せず，「実質的に差がない範囲」を ROPE として定めれば，帰無仮説モデルの自由度のなさも多少緩和され，いい勝負ができるのではないでしょうか。

また，一点張りの帰無仮説モデルではなく，符号を使った帰無モデルを考えることもできます。これを**情報仮説 (informative hypothesis)** と呼びます (謙介，2014)。$\mu_1 = \mu_2$ という帰無仮説モデルではなく，$\mu_1 \leq \mu_2$ というモデルを考えるのです。これは「差がないか，あるいは群 1 の方が小さい」というモデルであり，$\mu_1 \geq \mu_2$ というモデルと比較することができます。このようなモデルのパターンは，実践状況において色々考えることができるでしょう。ベイズ法のモデル比較はその意味でも自由度が高く，柔軟な議論が可能なのです。

そしてこれらのモデルは，ベイズファクターを使って定量的に評価できます。ベイズファクターはモデル比較です。$BF_{10} = 1/BF_{01}$ ですから，帰無仮説モデルと対立仮説モデルのどちらがよりデータに支持されているかは，どちらが分母に来るかだけの違いです。どのようなモデルでも，モデル同士の比較として考えることができます。しかも，モデル比較は一対一である必要はありません。モデルが A,B,C,D... と複数ある場合，それぞれ好きな組み合わせで (A と B，A と C，B と C，A と D，B と D，C と D...) 比較することができます。実際，分散分析の進んだ使い方では，要因の組み合わせ方をさまざまにした複数のモデルを，ベースラインモデルと比較してどれが最も優れているか，という形で表現することもできます。分散分析では，主効果や交互作用のあちこちで有意になったりならなかったりする結果が得られ，それを踏まえて総合的に評価する，ということがなされてきました。私は実はそれがすごく苦手で，結果が長くなると「全体像ってどうなってるんだっけ？？」となってしまうのですが，ベイズ法の場合はピンポイントで，見たい水準の効果の有無をモデルとして表現し，そのモデル同士を比較することができるのです。

■補正や多重性の問題から解き放たれる 最後に，私がベイズ法の利点として最も大きいと思う点を挙げておきます。

すでにお伝えしたと思いますが，t 検定や分散分析において，分散が均等であるかどうかを検定し，均等であるという仮説が保たれていないのであれば Welch の補正をするだとか，球状性の仮定が保たれていないのであれば Greenhouse-Geisser の補正をする，といった説明を重ねてきたのを覚えていらっしゃいますでしょうか。帰無仮説検定の流れという意味では，教えないといけないし覚えておいてほしいのですが，初学者

にとっては「色々ありすぎて覚えきれないよ！」となるのではないかと危惧しています[*8]。

ともかく，検定のことを真面目に考えると，いろんな付帯条件があって，それに基づいてあれもこれもチェックしていかなければならない，ということになっているわけです。マニュアルは分厚くなる一方です。これらは最初に考えられた ANOVA について，理論の展開や理解の深化とともに修正パッチをどんどん当てている，という状況です[*9]。

また分散分析の結果は，事後の検定が必要です。差がないとは言えない，じゃあどこにあったんだ，ということで改めて探しにいく必要がありましたし，このときに α 水準のインフレに怯えてさまざまな補正，修正を考えていかなければなりませんでした。これも非常に煩わしい問題です。主効果と交互作用だけでも面倒なのに，3 要因以上の分散分析になると，主効果と交互作用の組み合わせが増えます。解釈も難しい，インフレも対応しないといけない，ということで，初心者にとっては「もうやめてくれ！」となるのではないでしょうか。

ベイズ推定になれば，この問題が一気に解決します。後者の α のインフレについては，帰無仮説を設定するわけでも確率を含んだ判断をするわけでもないのですから，そもそも問題になり得ません。分散が等しいかどうか，球状性の仮定が保たれているかどうかといった検定を積み重ねる必要もありません。分散や共分散も未知なるパラメータとして推定するだけで，確率的判断はそこにはいってこないからです。

また，帰無仮説検定が有している問題の 1 つに，**停止規則 (stopping rule)** に関する問題があります。たとえばデータを 5 人分集めて，有意にならなかったので，頑張って 10 人にデータを増やして分析し，それでもダメだったので (?)20 人に増やしたら有意になったので，差があると結論してレポートした，という研究方法は，**帰無仮説検定的にはご法度**です。帰無仮説検定は，データを取る前に勝負のルールを決めて判定します。勝負の前になんら事前情報がない，フェアな形で進めなければなりません。サンプルサイズが大きくなると有意な判定になりがちである，という性質がありますから，「徐々に増やしていって有意になったところで止める」というのは勝つまで延長戦を続けるという不正なやり方なのです。これに対して，ベイズの流儀は基本的にデータが追加されると情報がアップデートされますので，徐々に確信度が変わっていくだけですから，最初の 5 人で得られた事後分布を事前分布として，追加の 5 人の情報を加えた事後分布を計算するというのはごく自然なやり方です[*10]。このように，帰無仮説検定が持っていた問題，とくに初心者が無意図的に陥りがちな問題を自然に回避できるのも，ベイズ法の利点といえます[*11]。

これらはいずれも，母集団が「差があるかないかのどちらかでしかない」という前提で議論していたからこそ生じていた問題です。最初に定めた状態があって，それは不変なものだという前提のもと，検定の条件を設計し，判断基準を定めます。データをとってから条件を変えたり，基準を変えたりしてはいけません。最初に定めた状態との違いが出てくると，設計をやり直さなければならないからです。まあ大変。

これに対しベイズ法では，最初から母集団の状態はわかりません。わからないので確率分布で表現しています。最初は何にもわからない，という状態ですが，データを取ると徐々にその範囲が狭まっていく。最初からデータは追加するものと考えていますし，最初から「あってるか間違っているかのどちらか」でもないので，

[*8] 昔のテキストには，フローチャートのようなものがありまして。こういう条件，こういうデータの時は XX 分析をして，次にここを見て，有意だったらこっち，有意でなかったらこっち･･･というような条件分岐だらけのマニュアルがあったのです。これも煩わしいですし，マニュアル至上主義になって中身を考えなくなる，悪しき習慣の温床だったと思います。

[*9] プログラミングをしたことがある人にはわかりやすいのですが，最初にメインの関数ができても，色々なバグがあってどんどん修正していくうちに，ソースコードがぐちゃぐちゃになってしまう，というのと同じです。可能なら，イチから全部書き直したいところですが，そんな元気も時間もなく･･･。

[*10] この「最初の 5 人の事後分布を事前分布として 5 人追加する」というやり方と，「10 人分まとめて事後分布を計算する」というやり方，いずれも事後分布の形は同じになります。

[*11] 停止規則に関する問題については，「頑張れば有意になる」という努力と科学的判断の交わるところですので，研究実践や教育的配慮の観点から知らず知らずのうちに罪を犯してしまうという，危うい性質のあるものなのです。研究も人間の営みの一つですから，わかっていてもなかなか区別しにくいところがあるのでしょうね。もちろんわかっていて，有意にするためにデータを加工するのは捏造に近い科学的犯罪です。

判断ミスの確率ということが存在しません。事前の計画から外れた分析をすることになっても，データ生成モデルと手元のデータから作られる世界 (事後分布) は常に一つの状態です。母数の事後分布をどのように切り分けようが，それは事後分布の形を変えることではないのです。ですから，停止規則の問題も，そもそも存在しないのです。こんなありがたいことがあるでしょうか。

もちろん，事前に計画していないことを分析し，いい結果が出たからそこだけ報告するとか (チェリーピッキング)，望んだ結果が出ないから報告しないとか (お蔵入り)，結果から遡って「最初からそう考えていたんだよ」と嘘をつく (HARKing) など，研究者の都合によって論文の内容を変えることは，ベイズ法でも許されません。これは推定方法の問題というより，研究者倫理の問題です。ただそれとは別に，方法論として，自由度が高く柔軟に分析できるのは，ベイズ法の利点といっていいのではないか，と思うのです。

心理学は，まだまだわからないことが多い学問です。心理学理論というほど，人間の行動パターンが明確にわかっていることがあるわけではありません。誤差があり，偶然があり，個性があり，時代や状況に影響される人間が相手ですから，それは仕方のないこと。というかそういう研究対象なのです。いわば，まだまだわからないことだらけ，心理学研究はほとんど探索的な手探り状態なのです。であればこそ，帰無仮説検定のように「差があるかないかのどちらかでしかない」という前提で議論するのは，あまりにも性急すぎるのではないでしょうか。ベイズ法は，まだわからないことだらけの心理学研究において，より柔軟に議論できる方法であり，初学者にも優しい方法なんじゃないかな。

27.5 課題

■ベイズファクターの解釈 ある研究で 2 群の平均値の差を検討したところ，ベイズファクター $BF_{10} = 8.5$ が得られました。この結果をどのように解釈すればよいでしょうか。また，もし $BF_{10} = 0.2$ だった場合はどうでしょうか。それぞれの場合について説明してみましょう。

■確信区間と ROPE による判断 2 群の平均値の差の事後分布から，95%HDI が $[0.3, 1.2]$ と得られました。ROPE を $[-0.5, 0.5]$ と設定した場合，この結果からどのような判断ができるでしょうか。「実質的に等価」「実質的に異なる」「判断保留」のいずれに該当するか，理由とともに説明してみましょう。

第 28 章

JASP でベイズ分析を体験する

さて前回は，ベイズ推定を使った判断の方法について，**HDI** と **ROPE** をつかって考える方法と，**ベイズファクター**をつかって考える方法などを紹介してきました。

では，理論はわかった。では実際にどうするか。これには色々なやり方があります。まずは R で，パッケージを使う方法。ベイズ関係のパッケージはいろいろあります。`brms`(Bürkner, 2017, 2018) や `blavaan`(Merkle et al., 2021; Merkle & Rosseel, 2018) などがそれで，回帰分析を書くように，従来の分析コードを書くようにして，推定方法だけ MCMC を使ったベイズ推定にしてくれるパッケージがあるのです。

この **brms** は Bayesian Regression Models using 'Stan' という言葉の頭文字で，基本的に Regression Models，つまり回帰モデルであればなんでもござれ，です。一般線形モデル，一般化線形モデル，一般化線形混合モデル，階層線形モデル，という線形モデルの展開がありますが，そのすべてに対応しています。つよい。

そしてこのパッケージの最後にある，**Stan** ですが，これが確率的プログラミング言語。brms は Stan という計算エンジンをつかって分析するのです。パッケージを経由して使えばいいのですが，brms はあくまでも線形モデルグループのもの。世の中には線形モデルでないモデルもいっぱいありますし，個々のデータに応じたモデリングもしたい。そういうときは自由度マックス，自分で統計モデルを書く。そのときの言語として Stan というのがあります。詳しくは次講で解説します。

とはいえ，プログラミングの勉強が苦手な人もいるでしょうし，R 言語や Stan 言語の文法を覚えるのは面倒だ，という人もいるでしょう。心理学者の多くはプログラミングよりも心理学の理論や実験がメインで，結果を出すための手段に過ぎない，統計のユーザであるという感覚は根強いと思います。しかしすでに述べてきたように，ベイズ法による推定はこれまでの方法とは画期的に違いますし，個人的には誤用・誤解を招きやすい頻度主義的方法よりも，初学者にはベイズ的アプローチの方が適しているように思います。ただ苦手だから，という理由でベイズ法を忌避するのはもったいないのです。

幸い，GUI を使ってベイズ的アプローチができるソフトウェアが存在します。JASP(JASP Team, 2025) と呼ばれるソフトウェアは，プログラミングを必要とせずにベイズ的な分析が行えるフリーソフトウェアです。JASP の特徴は，頻度主義的方法とベイズ的方法が同じメニューから扱えることです。従来通りの分析がしたいとき，メニューから「検定」とか「回帰」を選ぶときに，頻度主義的な方法でやるのかベイズ的な方法でやるのかを選ぶことができます。ユーザは今まで通りの分析もしつつ，ベイズでやると何がどう変わるのかを試して比較しながら進めることができますね。

具体的な JASP の使い方はこれから見ていきますが，興味がある人は JASP のウェブサイト[*1]からソフトウェアをダウンロードして試してみてください。また，近年は JASP の解説書 (清水・山本，2022) も出てきていますので，ぜひ参考にしてみてください。

[*1] https://jasp-stats.org/

28.1 JASP の導入とインターフェイス

JASP もまた R と同じくフリーソフトウェアです。こちらはアムステルダム大学から支援を受けたオープンソースプロジェクトだとされています。JASP と検索すると，メインのサイト https://jasp-stats.org/ にアクセスできるようになるでしょう (図 28.1)。本稿執筆時点 (2026 年 8 月) で最新版は ver 0.98.1 となっています。

図 28.1 JASP の Web サイト

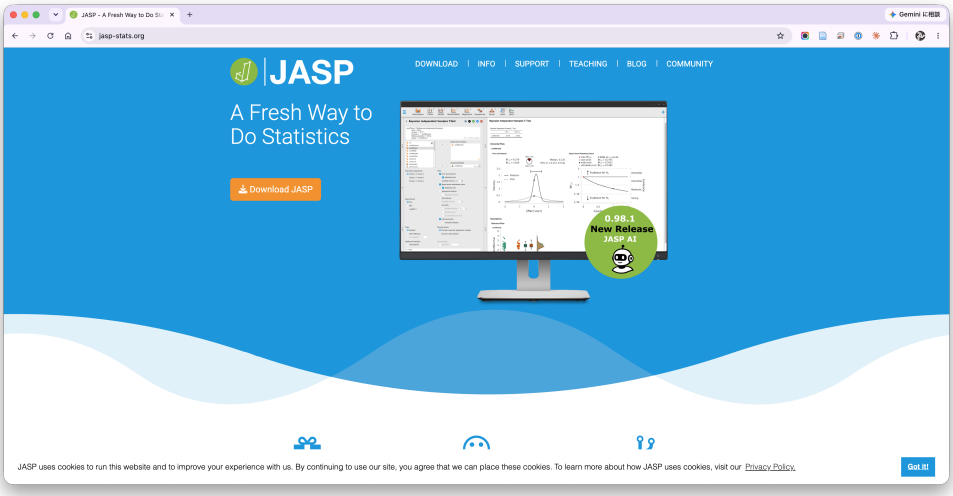

ここに，ダウンロードのボタン (Download JASP) がありますのでクリックすると，各種 OS に対応した JASP が用意されています。自分の環境に合ったものをダウンロードし，アプリをインストールしてみましょう (図 28.2)[*2]。

図 28.2 自分の環境に合ったものをダウンロードしよう

[*2] macOS ユーザで Homebrew によるソフトのパッケージ管理をしているひとは，`brew install --cask jasp` でインストールすることができます。

7819 インストールが無事終了したら，起動してみましょう (図 28.3)。JASP の起動画面がすでに日本語化されて
7820 いると思います。そこには JASP の特徴である，**フリー，フレンドリー，フレキシブル**の説明があります。とく
7821 に「フレキシブル」のところにあるように，このソフトは他のどのパッケージにもない特徴として，伝統的な分析
7822 方法とベイズ的な分析方法をシームレスにつなげているという特徴が明記されています。

図 28.3 起動画面のご挨拶も是非一読してください

7823 JASP のバージョンはまだ 1.0 にも満たないものですが，すでに十分使えるレベルになっているのに加え，
7824 開発も猛烈なスピードで進んでいます。長らく 0.16 といった数字でしたが，2025 年に一気に 0.9 台まで上
7825 がり，本書執筆時点の最新版は 0.98.1 です。そろそろバージョン 1.0 が近いのかもしれません。ちなみに日
7826 本語化チームには著者も加わっており[*3]，もし不自然な訳語や誤った表記，誤訳などがあるようでしたらご連
7827 絡ください[*4]。

7828 少し触ってみましょう。画面の左上にある 3 本線をクリックするとメインメニューが開きます。ここで「開く」
7829 →「コンピュータ」と進むと，自分の PC にあるデータファイルを読み込むことができます (図 28.4)。

[*3] 詳しくは https://jasp-stats.org/2021/10/28/日本語でjaspが使えるようになりました/
[*4] あるいは JASP ユーザの会 https://github.com/jasp-user-jp/jasp-user-jp に連絡いただいても結構です。

図 28.4 ファイルを読み込む

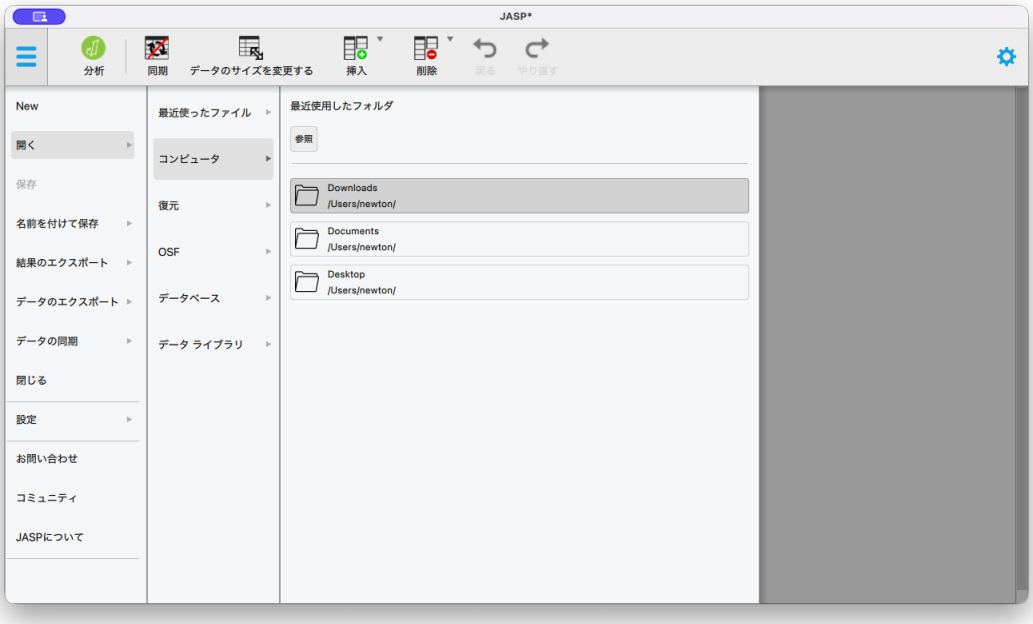

例として，野球選手のデータファイル (csv) を読み込んでみます (図 28.5)[*5]。

図 28.5 ファイルを読み込みました

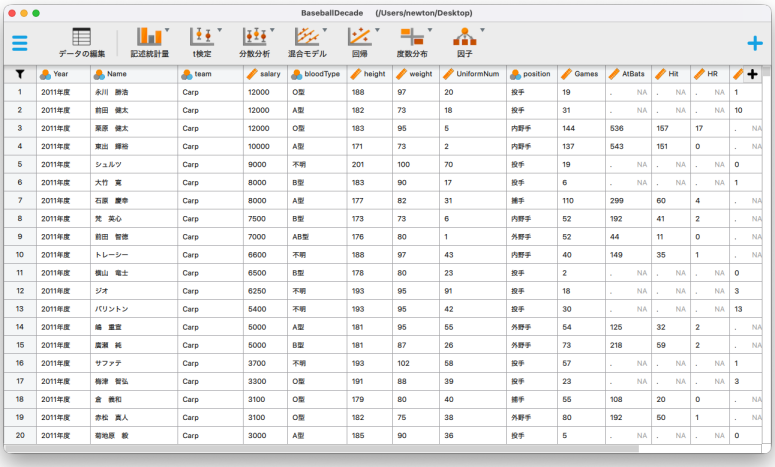

読み込んだらデータファイルが表示されます。ここで変数の横に，ベン図のような記号がついていたり，物差しのような記号がついていたりするのがわかると思います。JASP ではデータを**名義尺度水準**，**順序尺度水準**，**スケール**の 3 つに分類します。スケールは**間隔尺度水準**と**比率尺度水準**を合わせたものです。スケールになると加減乗除など算術的処理ができるので，それ以外の 2 つと区別するのですね。

変数名のところをクリックすると，これら 3 つの水準が表示されますので，もし間違った分類があるようでしたら修正しておきましょう。

[*5] このサンプルデータは本稿の伴走サイトにて提供されています。

28.2 記述統計と可視化

メニューにある「記述統計」をクリックすると，その名の通りさまざまな変数の情報を簡単に要約してくれます。たとえば身長変数 height と体重変数 weight をチームごとにみてみたい，というのであれば，「分割」のところに team 変数を投入し (右に向いた三角形ボタンを押すと，選ばれた変数がボックス内に移動します)，分析対象の変数を上のボックスに投入すればよく，右の画面に自動的に計算結果が出てきます (図 28.6)。簡単ですね！

図 28.6 記述統計の出力

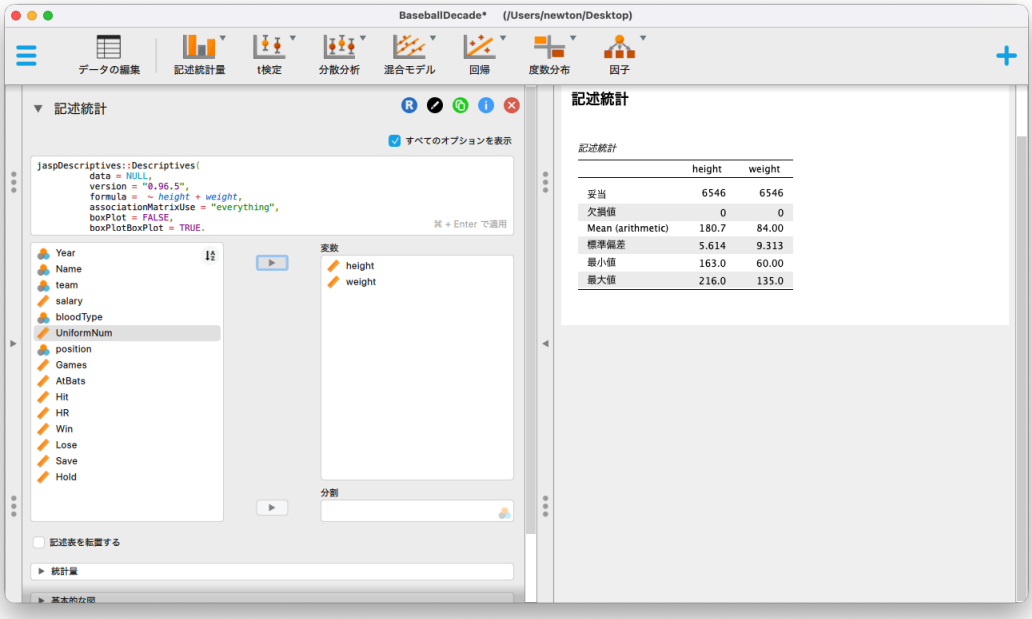

記述統計メニューは，下の方に「プロット」や「統計量」についてのオプション指定ができる場所があります。ここをクリックすると，さまざまなオプションが表示されます。たとえばプロットでは，色を指定するカラーパレットが選べますし，箱ひげ図，散布図，回帰直線の追加などが選べます (図 28.7)。選んだプロットは図 28.8 のように出力されます。

図 28.7　プロットオプション

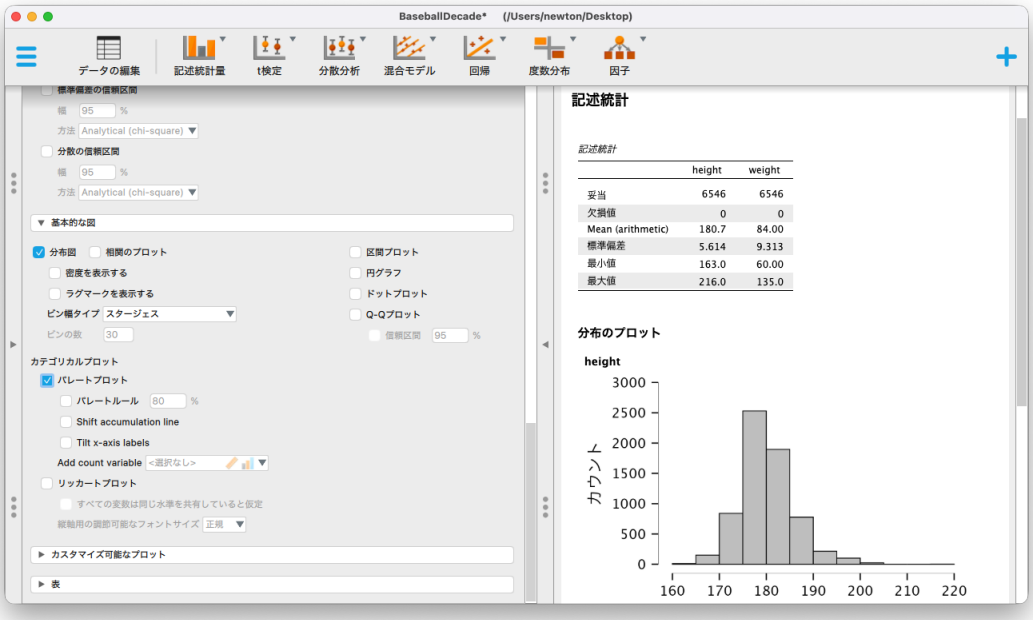

図 28.8　ボックスプロットや散布図

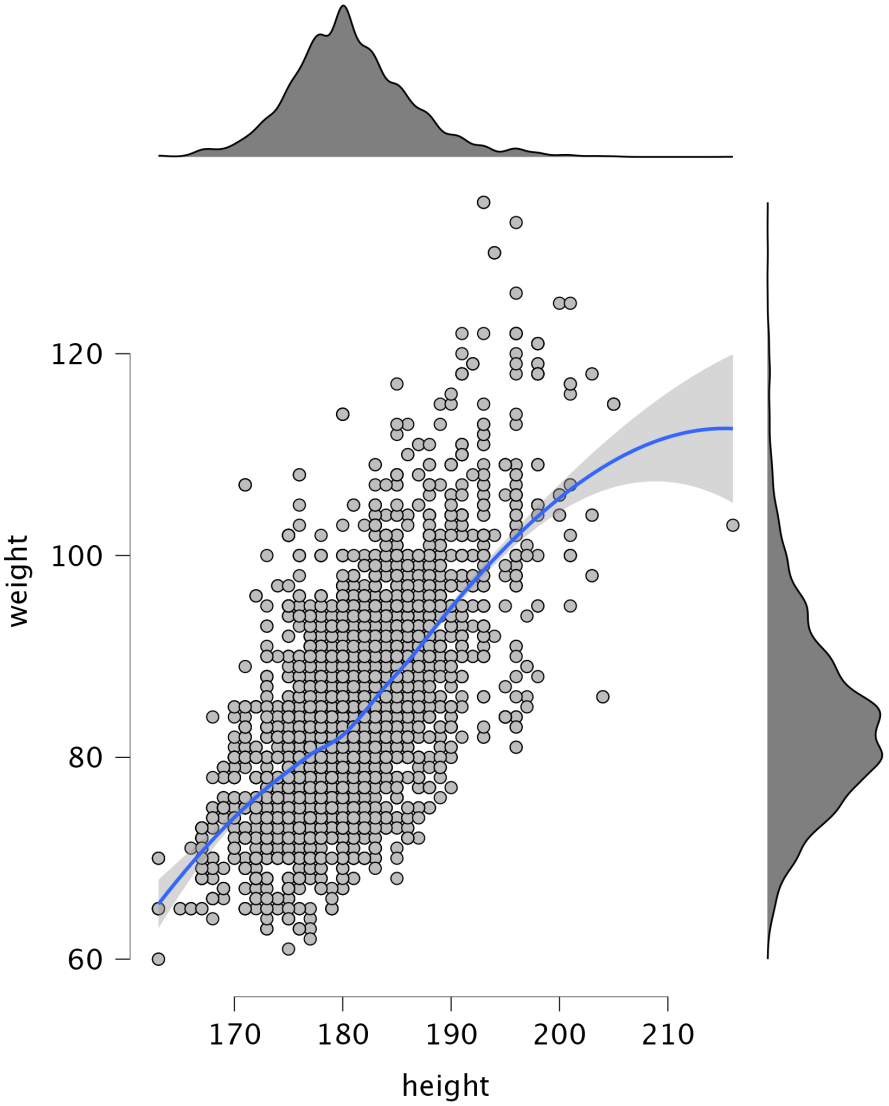

もちろん細かな図版の調整には **ggplot2** の方が向いているのですが，これでも概略を掴むには十分ですね[*6]。

これらのプロットは，図の横にある下三角をクリックすると，コピーしたり画像ファイルとして保存することもできます (図 28.9)。

[*6] JASP に準拠したテキストがオンラインで公開されていて，そちらも日本語訳が進められているのですが，そこでも「細かい調整は ggplot2 でないとね」といった内容の記述があります。詳しくは JASP で統計を学ぼう!のサイト https://jasp-user-jp.github.io/LSwithJASP/ をご覧ください。

図 28.9 JASP の図オブジェクトは保存できる

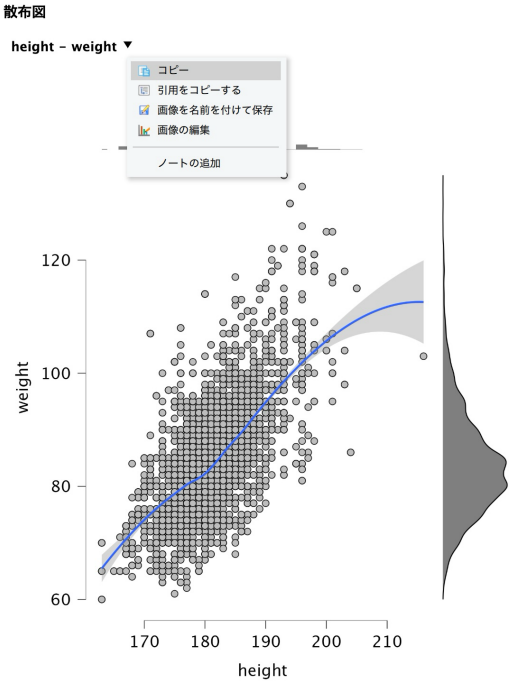

JASP だけで画像の調整がうまくいくのであれば，プレゼン資料の作成などに利用できるでしょう。

28.3 JASP による相関・回帰分析

JASP の特徴はすでに述べたように，1 つの分析法を従来型 (頻度主義的確率に基づくもの) とベイズ型 (主観確率に基づくもの) の両方で並列的に行えることです。メニューをクリックすると，伝統的な方法とベイジアン (ベイズ的な) が選べるようになっています (図 28.10)。

図 28.10 一つのメニューで二つの分析

また，もう 1 つの特徴として，サンプルデータが豊富なことが挙げられます。JASP が持っているサンプル

データだけでなく，OSF[*7]とよばれる Web 上で公開されている研究データにアクセスし，そこからデータを取ってくることもできるようになっているのです (図 28.11)。

図 28.11　サンプルデータも豊富にある

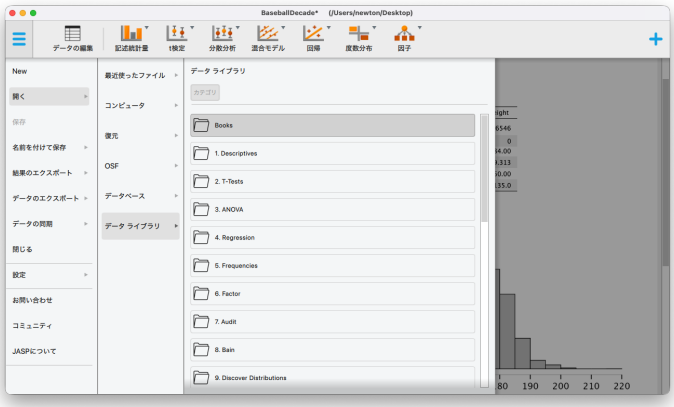

ここで適当なサンプルデータを選んで，相関係数や回帰分析を見てみることにしましょう。Big5 というデータを選びました。データライブラリ →4.Regression →Big Five Personality Traits と進めばデータが表示されます。これはパーソナリティ心理学の領域ではよく知られている，性格テストの結果から明らかになる性格の 5 次元で，開放性 Openness，誠実性 Conscientiousness，外向性 Extraversion，協調性 Agreeableness，神経症傾向 Neuroticism のスコアからなります。性格に関するスコアですから，当然相関がありそうな変数ですね。

普通の相関係数が欲しいだけでしたら，メニューの回帰 → 伝統的・相関を選びます。すべての変数を右側のボックスに移動するだけで，結果のところに変数の組み合わせごとの相関係数が表示されます (図 28.12)。

[*7] Open Science Framework の略で，心理学の再現性問題などと相まって，研究で使ったローデータそのものを公開したらいいじゃないか，という活動です。詳しくは https://osf.io/gceur/ を参照してください。

図 28.12　伝統的な相関分析

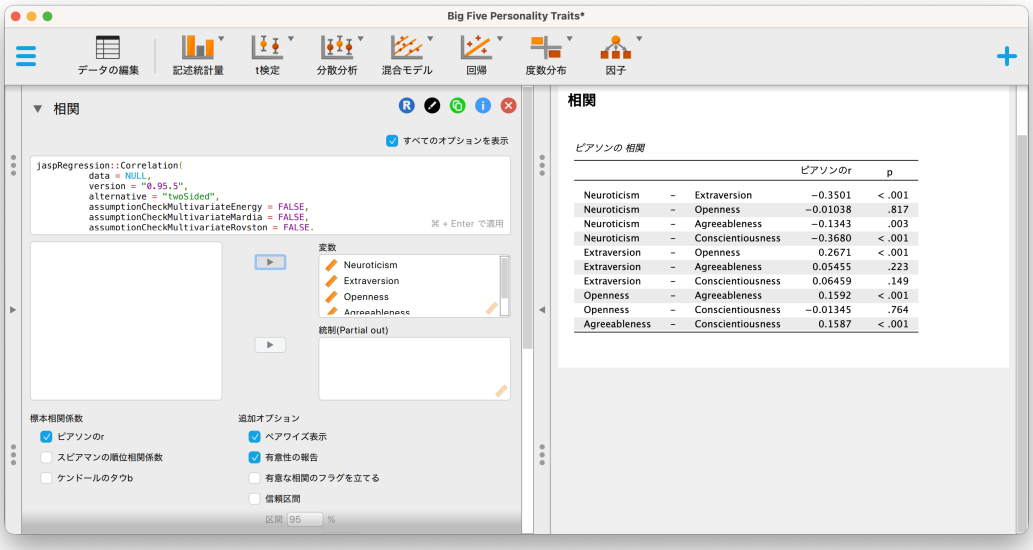

オプションのところにはデフォルトで，「ピアソンの r」と「有意性の報告」にチェックが入っています。いわゆる相関係数は**ピアソンの積率相関係数**というのが正式名称ですが，JASP では順序尺度水準の数字に適用できるスピアマンの順位相関係数や，ケンドールのタウ b と呼ばれる相関係数にすることもできます。また，有意性の報告にチェックが入っていて，表には p 値がでています。思い出して欲しいのですが，帰無仮説検定として「母相関 ρ はゼロである」という無相関を仮定したモデルと，「母相関はゼロではない」という対立仮説を比べています。たとえば神経症傾向と外向性の相関係数は $r = -0.3501$ であり，これが母相関 $\rho = 0$ のところから得られたデータだと考えるにはちょっと珍しすぎるよね ($p < .001$) ということが示されています。オプションで「有意な相関のフラグを立てる」にチェックを入れると，有意なところにはアスタリスクマークがつき，p 値が小さいほどアスタリスクの数は増えることでそれを示しています[*8]

同じ分析をベイズ的にやってみましょう。メニューの中で回帰 → ベイジアン・相関と進むだけです。変数の選び方も同じ操作です。分析結果の追加オプションには，p 値ではなく**ベイズファクター**が入っています。ここで比較するモデルは非ベイズ的分析と同じで，母相関がゼロというモデル 0 と，ゼロではないというモデル 1 を比べて BF_{10}，すなわちモデル 0 にくらべてモデル 1 がどれほどデータに支持されるかという比率を表してくれます。先ほど有意であった，神経症傾向と外向性の相関については 6.765e+12，すなわち 6765000000000 倍もモデル 1 を支持しています。ベイズファクターはこのように，時折とても大きな数字になることがありますし，事前分布を変えれば変わることも大きいので，とりあえず 0 ではないと思うぐらいでいいかもしれません。

それよりも，確信区間のところをチェックしてみましょう。95%確信区間が [-0.270,-0.424] ですから，相関係数が-0.270 よりも大きくなる (0 に近づく) ことはほぼない，2.5% ぐらいしかあり得ないだろう，ということがわかります。**ROPE** をどの程度に置いておくかによりますが，「ほぼ無相関と同じレベル」とは言えないと判断すべきでしょう。ちなみに従来法での信頼区間は，[-0.271,-0.425] です。ベイズ確信区間とほとんど同じですね。ただしこちらの場合は，この区間の中に真の相関係数が含まれる確率が 95%，言い換えるなら「この範

[*8] これが良くない風習ですね！ p 値が小さくても，相関係数が大きいことを意味しませんし，仮説の正しさを支持するものでもありません。

囲に相関係数があると言って間違える確率が 5%」という意味です。

28.4 ベイズファクターを使った検定

それでは最後に平均値の比較をしてみましょう。メインメニューから，開く → データライブラリ →2.T-Tests→ と進んで，一番上にある Directed Reading Activities を選びます。実験群と統制群に分かれて，差を検証する実験計画です。これはサンプルコードですから，すでに分析した結果が表示されていますが，改めて自分たちでやってみましょう。メニューから t 検定 → 伝統的·独立したサンプルの t 検定を選びます。そこで，従属変数に唯一のスケール変数 drp をいれ，グループ化変数に group を投入します。検定は等分散性を仮定したスチューデント法と，その仮定をしないウェルチの方法，両方を選んでみましょう。対立仮説は二群に差がある (グループ 1≠ グループ 2) とし，仮定のチェックや効果量など，適当に選んでみましょう (図 28.13)。

図 28.13 伝統的な t 検定

独立したサンプルのt検定

As we can see, the difference between the groups is statistically significant at the .05 level. The Treatment group has on average about ten points more on the DPR test than the Control group ($t(37.86) = 2.311$, $p = 0.013$), translating to medium effect size: Cohen's $d = 0.691$.

独立したサンプルのt検定

	検定	統計量	df	p	VS-MPR*	平均値差	SEの違い	コーエン(Cohen)のd	SE コーエン(Cohen)のd
drp	Student	−2.267	42.00	.029	3.616	−9.954	4.392	−0.6841	0.3182
	Welch	−2.311	37.86	.026	3.836	−9.954	4.308	−0.6908	0.3185

* Vovk-Sellke の最大 p 比: p-値に基づいたH_0よりもH_1を支持する最大の可能なオッズは、$p \leq .37$に対して$1/(-e\ p \log(p))$に等しくなります(Sellke, Bayarri, & Berger, 2001)。

Since the variance appears to be larger in the control group (see also the violin plot below), we consider the Welch version of the t-test; the Welch version does not assume that the variances in the two groups are equal.

仮定のチェック

The assumption checks are not statistically significant.

正規性の検定 (シャピロ・ウィルク)

残差	W	p
drp	0.9734	.396

注 有意な結果は、正規性からの逸脱を示唆しています。

分散の等質性の検定(ブラウン・フォーサイス(Brown-Forsythe))

	F	df_1	df_2	p
drp	2.342	1	42	.133

記述統計量

テキストを追加するにはここをクリック

群の記述統計

	群	N	平均値	標準偏差	標準誤差	変動係数

結果として，表 28.1 が示されます。ここで，分散が等しいという仮定の場合は Student の行をみて，

$t(42) = -2.267, p = 0.029, d = -0.684$ であることが読み取れます[*9]

補正が必要な場合は，Welch の方を見ましょう。このとき $t(37.855) = -2.311, p = 0.026, d = -0.691$ であるということがわかります。

表 28.1　独立したサンプルの t 検定

	検定	統計量	df	p	コーエン (Cohen) の d
drp	Student	−2.267	42.000	0.029	−0.684
	Welch	−2.311	37.855	0.026	−0.691

ではどういうときに Student 行をみて，どういう時は Welch 行を見ればいいのでしょうか。基本的に仮定が緩い Welch のほうをみればよいのですが，分散が同じと見做せるかどうかは「仮定のチェック」を見れば良いでしょう。仮定のチェックには，そもそもの前提である「データは正規分布にしたがっているのか」を検定する，シャピロ・ウィルク検定があります (表 28.2)。つづいて分散が同じと見做せるかどうかを検定するブラウン・フォーサイスの検定やレヴィーン検定 (表 28.4) があります。

ここで注意して欲しいのは，これらの検定は帰無仮説が「正規分布にしたがっている」「分散が等しいといえる」であり，対立仮説は「したがっていない」「等分散ではない」になります。つまり，ここでは分析結果が有意になると，「したがっていない」「分散が等しくない」ということになります。シャピロ・ウィルク検定で有意になると，そもそも t 検定をしてはいけません。分散の等質性の検定で有意になると，分散が等しいという仮定が破られているわけですから，Welch の方を見るように変える，ということになります。

表 28.2　正規性の検定 (シャピロ・ウィルク)

残差	W	p
drp	0.973	.396

表 28.3　分散の等質性の検定 (ブラウン・フォーサイス (Brown-Forsythe))

	F	df_1	df_2	p
drp	2.342	1	42	.133

表 28.4　分散の等質性の検定 (Levene の)

	F	df_1	df_2	p
drp	2.362	1	42	.132

今回は，正規性の検定でも有意ではなく ($p = 0.396$)，分散の等質性の検定でも有意でない (ブラウン・フォーサイスの検定で $p = 0.133$，レヴェーンの検定で $p = 0.132$) という結果になりました。つまり，正規性

[*9] t 分布はペンネーム Student さんが書いた論文が元になっているので，異分散のための補正のない t 検定は Student の t 検定，と言います。ちなみに著者は William Sealy Gosset であることが明らかになっています。彼を雇用するギネスビール社が本名使用を許さなかったため，ペンネームで論文を投稿したと言われています。

の仮定はやぶれてないし (有意に正規分布から異なっているとは言えない), 分散の等質性の仮定も破れていない (有意に分散が異なるとは言えない) ことになります。ということで, 一般的な t 検定の結果をみればよい, ということになりますから, 報告するなら「$t(42) = -2.267, p = 0.029, d = -0.684$」で二群の平均値に差があった, となります。

それにしても少し面倒ですね。仮定のチェックのところでは帰無仮説を応援し, 本番の検定では対立仮説の方を応援する, という形になってしまいます。帰無仮説を積極的に支持できないんじゃなかったのかよ, と言いたくなります。なにより検定を繰り返して行っていますから, α 水準が 5% ではなくなっているかもしれません。

そんな不安も, ベイズ統計の場合は必要ありません。早速ベイジアン分析をしてみましょう。今度はメニューから t 検定 $\rightarrow$ ベイジアン・独立したサンプルの t 検定を選びます。従属変数やグループ化変数の選び方は同じです。

結果は表 28.5 のように表されました。$BF_{10} = 2.217$ ですから, 差がないという帰無仮説 (モデル 0) に比べて, 差があるという対立仮説 (モデル 1) は 2.2 倍ぐらい支持されています。どちらかというと対立仮説の方が優勢, という感じですが, BF の 1 つの目安は 3 を超えるぐらいというのがありますので,「差があった」と断言するにはちょっと気が早いかもしれません。

表 28.5　ベイジアン独立サンプルの t 検定

	BF_{10}	エラー %
drp	2.217	0.002

このことは記述統計的なプロットを見るとはっきりします (図 28.14)。

図 28.14　二群の平均値と確信区間

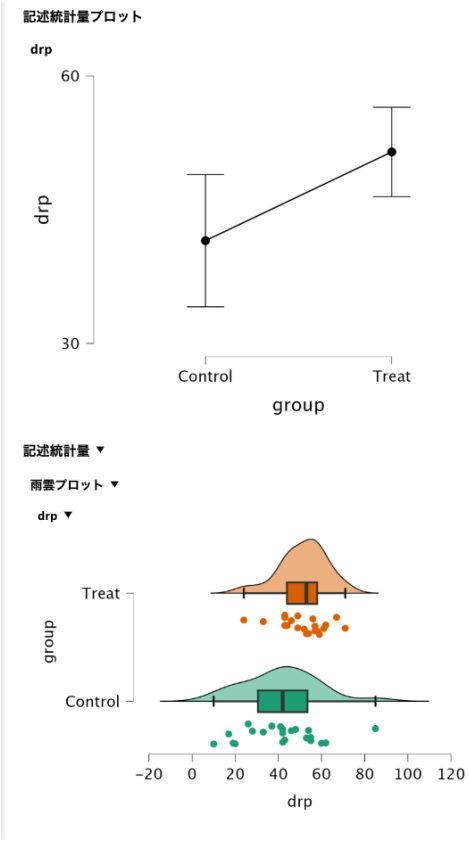

これをみると，実験群と統制群の 95% 確信区間は重複しているところが結構ありそうです。重複している場合は，ROPE がどれぐらいであるにせよ，性急な判断はやめて保留し，データ (エビデンス) をもっと追加してから考えた方がいいでしょう。

ここでもう 1 つ，「事前分布と事後分布」の出力を見てみましょう (図 28.15)。

図 28.15　事前分布と事後分布

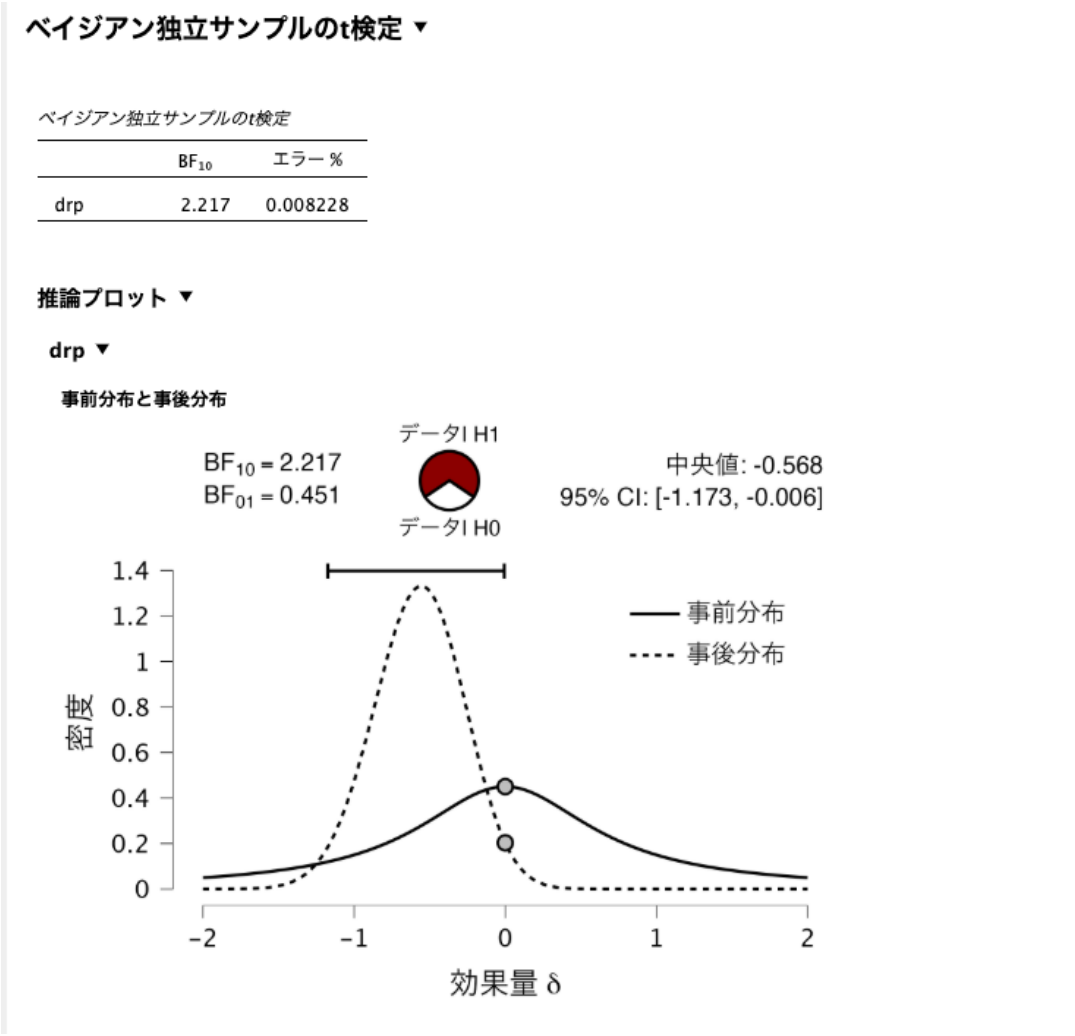

これは効果量 d の推定値 δ の事前分布と事後分布を示しています。効果量は標準化された平均値の差を表しており，事前分布では 0 を中心としたコーシー分布が置かれています。つまり，検定前の主観確率としては「差はないんじゃないかな」とうっすら思っている，という状態です。これにデータ (尤度と事前確率) から計算された事後分布を重ねると，$\delta = 0$ の密度が事前分布よりも低い位置にきていますね。この事前分布と事後分布の，特定の点についての密度比はベイズファクターに一致することが知られており，この方法でベイズファクターを計算するのは**サヴェージ・ディッキー法**と呼ばれています (リー・ワゲンメーカーズ，2017)。ベイズファクターの計算には，周辺尤度の積分が必要でなかなか難しい，というところだったのですが，帰無仮説のような点の仮説と，それを包含する対立仮説の関係にある場合，この事前分布と事後分布の密度比が利用できるのです。

ともかくこれを見ると，ちょこっと下がっただけ。また δ の確信区間は [-1.173,-0.006] です。上限がほとんどゼロですね。ゼロというのは差がないということですから，今回のデータを持って差があるよ，というのはちょっと厳しいかもしれません。

ここで注意を 1 つ。従来法と**ベイズ法**の両方の結果を見て，あれ？従来法なら有意差ありで，ベイズ法ならそこまで強く言えないんなら，従来法だけレポートに書いたらいいんじゃない，と思った人。そういう「ちょっと自分にまずいことは隠しておこう」という態度は科学的誠実さには欠けますよ。今回はいずれも対立仮説の

方が支持されていますが，もっと微妙な差であればもしかすると，従来法とベイズ法の結果が異なることがあるかもしれません。そのような場合でも今回の場合でも，両方の結果を記載して「このデータが本当に伝えていることは何か」をしっかり考えることの方が重要です。自分に都合の良い結果だけ利用するのではなく，差があるかないかという短絡的な判断で論じるのではなく，信頼区間や確信区間，p 値も効果量もベイズファクターもすべて記載して，現象の正しい理解をすることの方が重要なのですから。

ともかく，JASP というソフトを使うと，簡単に両方の手法が比較できることがわかっていただけたかと思います。今後は，t 検定と BF の併記のような形で，分析結果を報告する研究例が増えてくるでしょう。

第 29 章

ベイズを実践する

ここまで，ベイズの定理からはじまって，事後分布による推定，そしてベイズ的な判断の仕方までを見てきました。前講では JASP を使って，実際に手を動かしてベイズ分析を体験してもらいました。

しかし，ひとつ大きな疑問が残っているはずです。事後分布は，事前分布と尤度の積を積分して求めるのでした。その積分がとても難しいから，ベイズ法は長らく使えなかったのだ，という話もしました。それなのに，JASP のボタンを押すと数秒で答えが返ってくるのはなぜでしょうか。裏側で何が動いているのでしょうか。

この答えにつながる技術的なブレイクスルー，そしてそれを使った実践的なベイズ分析の方法について，見ていきましょう。そしてこのことを知ると，今まで「データを見て，それにあった分析法を探す」という受動的なデータ解析の姿勢から，「データの生成メカニズムを自分で考え，それをモデル化する」という能動的でクリエイティブなデータ解析へと，私たちの姿勢を変えることができるのです。

29.1　ベイズを実践する方法

29.1.1　ベイズ法が普及しなかった理由

ベイズ法は頻度主義的な方法と比べて，利点も少なくありませんが，21 世紀になるまでそこまで広く用いられることはありませんでした。実際，2010 年ごろからベイズ法が心理学領域でも広まってきたのですが，18 世紀にトーマス・ベイズが提唱して以来，200 年以上もかかっているのです。なぜでしょうか。その理由を 3 つほど挙げてみましょう。

第一の理由は，頻度主義者のフィッシャーがベイズ法を批判したことにあります。フィッシャーは厳格な科学的手続としての統計学の実践的利用を考えた人で，科学的な態度として事前分布の存在が許せなかったようです。データと向き合う前に何らかの思い込みを持つことは，科学的態度として適切でないと考えたようですし，「事前に何も想定しないこと」と「無情報事前分布をもつこと」は本質的に違うと考えていたようです。彼の言葉として「逆確率の理論はある誤謬の上に立脚するものであって、完全に葬り去らなければならない」，というのが知られています。いずれにせよ，統計学が花開かんとする時期に，その大御所に嫌われていると，どうしても後続が育たないという事情がありました。

第二の理由は，ベイズ統計学の実践的事例が，軍事関係にあったことにあります。暗号解読などに強力なベイズ的手法が用いられたことは知られていますが，軍事関係の研究は秘密主義的であり，その内容が広く知られることはありませんでした。これにより，学術的なコミュニティでのベイズ法の普及が妨げられたといわれています。これらの話は，シャロン・バーチュ・マグレイン（2018）に読み物として詳しく書かれていますので，興味がある人はぜひご一読ください。

さて。とはいえ，それらはまだ副次的な理由にすぎません。第三の理由はもっと本質的なものです。それは，

ベイズの理論は正しくても，計算が難しすぎるという問題です。ベイズの定理が示すように，ベイジアンは，事後分布を求めるために，事前分布と尤度関数を掛け合わせたものを周辺尤度で割る，という計算を行います。しかし，この分母にあたる「周辺尤度」を計算で求めるのがとても難しいのです。事前分布と尤度の積を，事前分布の全領域で積分しなければならないのですが，この積分が解析的に (計算機で) 解ける場合は限られています。特に多次元の場合は，この積分を解析的に解くことはほぼ不可能です。

これまで，ベイズの研究者はこの問題を解決するために様々な工夫をしてきました。ひとつは，事後分布の形が計算できるわかりやすいものにすること，特に事前分布と事後分布が同じ形の分布になるような，特殊なケースを探すことです。このようなケースを**共役事前分布 (conjugate prior)** といいます。たとえば，二項分布の成功確率の事後分布を求める場合に，ベータ分布を事前分布に選ぶと，事後分布もベータ分布になる，ということがわかっています。この方法は解析的に解ける場合に限られますが，計算が簡単になるため，古くから用いられてきました。

あるいは，グリッドサーチという方法です。これは計算したい範囲を細かく区切り，その各点で事前分布と尤度を計算し，それらを掛け合わせて正規化することで，事後分布を近似的に求める方法です。各領域での計算結果から，より事後分布の確率密度が高いところを探していくという方法で，計算できなくはないのですが，かなりの計算量を必要とするものでした。これらの方法では，あまり実践的な利用には向いていません。つまり，ベイズの定理は理論的には正しいけれど，絵に描いた餅だという状況だったのです。

29.1.2 MCMC 法の登場

ところが，近年になって技術的なブレイクスルーが生じます。**マルコフ連鎖モンテカルロ法 (Markov chain Monte Carlo)** と呼ばれる手法です。これを用いることで，事後分布を近似的に求めることが可能になったのです。この手法は略して MCMC 法と呼ばれますが，前の MC と後ろの MC は違うもの，二つの MC の合体技です。

前の MC，すなわちマルコフ連鎖とは，「機械の中になんだか安定的な確率空間を作ること」を意味します。ベイズ法が実践的でなかったのは，事後分布を計算するのが難しいことだったのですが，マルコフ連鎖を使うことで事後分布の形状に近い確率空間を作ることができるのです。

後ろの MC はモンテカルロ法。モンテカルロというのはモナコの地名です[*1]。モナコにはカジノがありますから，ギャンブルの代名詞のようにつかわれているのですが，モンテカルロ法は「乱数を発生させる方法」だと思ってください。**乱数 (random number)** とは，規則性のない数字のことです。人間が「規則性のない数字を適当に羅列して」と指示されると，1,3,6,5,8,2,0,3,5,9,2,.... のように適当な数字を上げることはできると思いますが，これを長い目で見てみると 5,3,8 などの数字が他よりも多く発生すると言われています。つまり，人間が作る乱数は完全にランダムではないのです。そこでコンピュータにランダムな数字を出させるのですが，コンピュータの中身はプログラミングで規則正しく動いていますから，規則正しく規則性のない数字を出せ，というのは語義矛盾のように思います。これを工夫して，とある数字を生み出す関数を生み出す関数を作り，その関数を反復的に活用していくことであたかも規則性がないような数字を出す方法，というのが考えられてきました。コンピュータの出すこのような乱数は**擬似乱数 (pseudorandom number)** と呼ばれ，スタート地点さえ同じであれば同じ数列が出てくる (規則にしたがっている) ため，完全な乱数ではありません。が，その数列自体は人間よりもはるかに不規則で均一な分布を作ることができます。これができれば，少し加工してたとえば正規分布に従う乱数を作る，ということも可能です。みなさんがゲームで「ガチャを引く」とか，「ランダムにアイテムをもらう」とかいうときに，計算機は内部でこの擬似乱数を使っているわけです。

[*1] F1 グランプリが好きな人は，モナコのコースがモンテカルロだというのをご存知かと思います。街中を走る，すごいシケインのある難しいコースですが，美しい街並みで富裕層やセレブリティの居住地としても知られています。

MCMC 法はこのマルコフ連鎖＋モンテカルロ法です。つまり「事後分布っぽい空間を作ること」＋「乱数を発生させる」ですから，「事後分布から乱数を発生させる」ことができるのです。事後分布の関数の形はわかりませんが，事後分布から乱数を発生させることができる。これが MCMC 法の本質です。「乱数なんか作ってどうするんだ」と思われるかもしれませんが，ある分布に従う乱数というのは，その分布の本質を反映するとても面白いものなのです。

図 29.1　正規分布の乱数を大量に発生させたもの。左上は 100 個，右上は 1000 個，左下は 10,000 個，右下は 100,000 個の乱数を生成してヒストグラムにしたもの

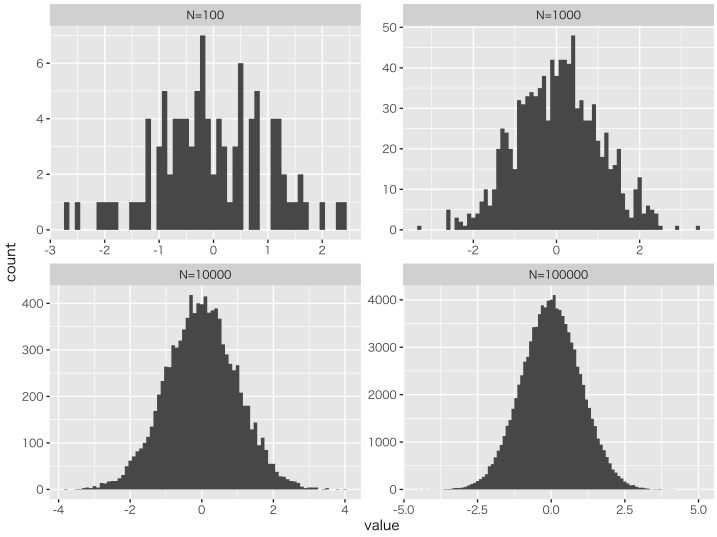

図 29.1 には，正規分布に従う乱数を生成させた図を示してあります。左上は 100 個の乱数をつくっていますが，そのヒストグラムはガタガタであんまり正規分布っぽくはありませんね。右上は 1000 個です。これぐらいになると，どうやら正規分布っぽい感じ，つまり中央が高くて両裾にむけた緩やかに減衰する感じが見て取れます。左下は 10,000 個です。ここまでくると理論的な正規分布のカーブの影が見えてきますね。右下は 100,000 個ですが，ここまでくるとほぼ理論的な正規分布のカーブを描いているかのようです。

このように，乱数を大量に発生させ，そのヒストグラムを描くと，稜線[*2]が，その分布の形を反映するのです。事後分布の関数の形は分からなくとも，乱数のヒストグラムで分布の形状を近似的に知ることができます。

乱数のメリットはそれだけではありません。セクション 10.2.4(Pp.145) で見たように，確率分布の期待値を求める計算は，次のようになります。

$$E(X) = \sum x_i \times p_i$$

これは離散分布の場合ですが，要するに実現値とその確率をかけて足し合わせることになります。連続分布の場合はここでも積分が出てきます。面倒ですね！しかし，乱数を使うとこの計算はとても簡単になります。というのも，乱数の実現値が大量にできているのですから，それを集計して，平均の計算をするだけで期待値になるのです。確率分布の分散の計算も面倒ですが，実現値が大量にあるわけですから，そのまま分散の計算をすれば良いのです。

もっといいことに，特定の領域の確率を計算したいとしましょう。たとえば標準正規分布で，-1 から +1 までの範囲の面積 (確率) を求めるには，次の計算をする必要があります。

[*2] りょうせん。すなわち山の尾根のことで空と山の境目の線のことです。

$$\int_{-1}^{+1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx$$

また積分です。当然です，確率は面積なんですから。でも面倒ですね！

しかし，乱数で実現値が大量にあるわけですから，得られた乱数のうち-1 から +1 までの範囲に入っているものの割合を計算すれば，その範囲の確率を計算したことになります。このように，あくまで近似的ではありますが，乱数を使うことで積分の計算が集計の方法に変わるのです。

そして私たちには R のような，データの集計に特化した言語があります。事後分布の乱数が大量にあれば，結果を R で集計させるだけで複雑な確率分布の計算に頭を悩ませる必要がないのです！素敵！

乱数によるアプローチの利点は他にも，ある変数に関する周辺分布を求める場合にも有効です。たとえば正規分布は μ と σ の二変数をもつ分布ですが，μ に関する周辺分布が欲しい場合 (μ だけの分布が欲しい場合) は，乱数の中から μ 変数についてのみ集計すれば良いのです。図 29.2 に示すように，乱数が大量にあれば，特定の変数について集計するだけで周辺分布を求めることができます。

図 29.2　周辺分布も当該変数の集計で求められる

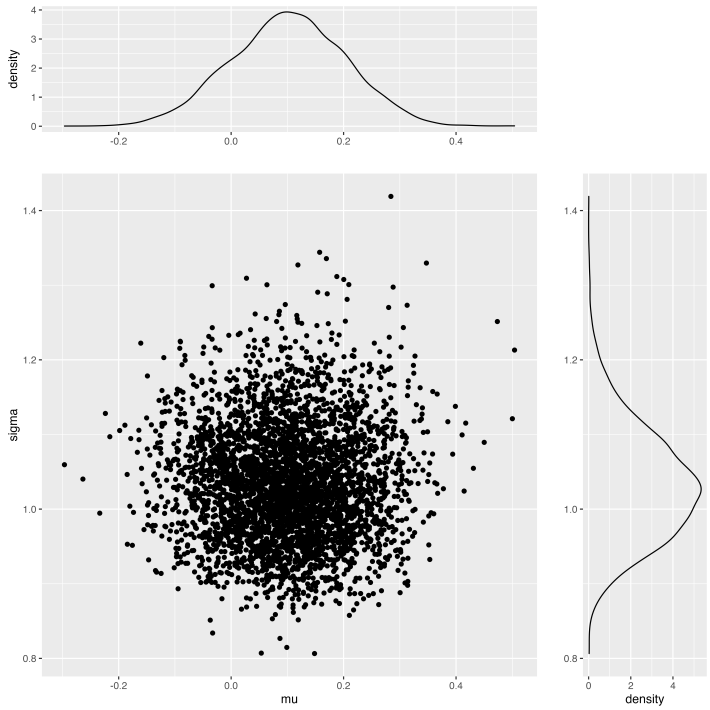

MCMC 法による乱数で結果を確認するのは，近似にすぎないといえばそうなのですが，乱数の数を増やせば増やすほど精度は上げることができますし，最近のコンピュータの能力を使えば 10 万，100 万の乱数を作るのも簡単ですから，実用上は十分な精度が得られます。ベイズ法が実践的な手法として普及したのは，この MCMC 法の登場によるところが大きいのです。

29.1.3 確率的プログラミング言語

この MCMC 法を用いたベイズ推定を実践するために，**確率的プログラミング言語 (probabilistic programming language)** というものが開発されてきました。有名なものに **JAGS(JAGS)**，**BUGS(BUGS)**，

Stan(Stan) などがあります。これらは R 言語のように，プログラミング言語の一種で，データと尤度，事前分布の関係を記述してやると，MCMC 法を用いて事後分布から乱数を生成してくれる，というものです。

図 29.3 Stan 言語と R 言語の連携

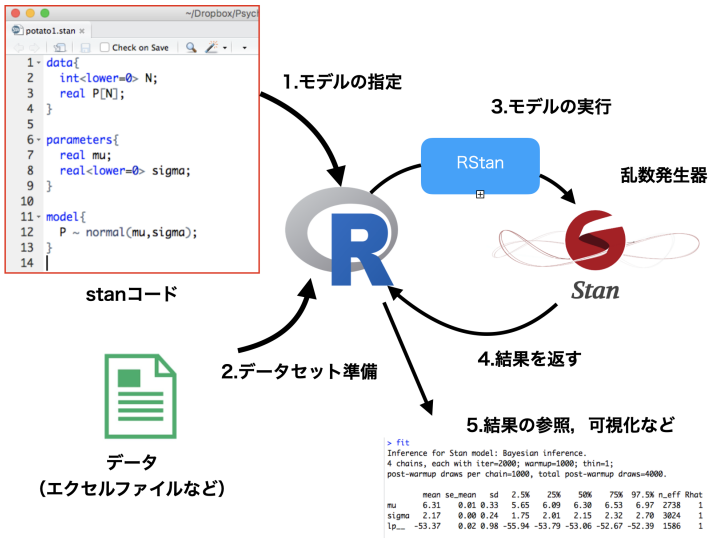

図 29.3 に Stan 言語と R 言語の連携の例を示します。Stan 言語でモデルを記述し，R 言語から Stan を呼び出してデータを渡し，MCMC 法で乱数を生成してもらい，R 言語で集計する，という流れです。Stan 言語自体は C++[*3]で書かれているため高速に動作しますし，R 言語から簡単に呼び出せるため，R ユーザーにはとても便利なツールです。

これを使うと，今まで絵に描いた餅だったベイズ法が簡単に使えるようになります。だって，データと確率分布の関係を書くだけでいいんですから。そして MCMC 法をつかったベイズ推定はとても強力ですから，非常に複雑なモデルであっても答えを捻り出してくれます。何十ものパラメータがあっても大丈夫です。そうなってくると，ベイズ法を使わない手はありません。「わからないものを確率で表現する」という思考方法さえ身につければ，どんなモデルであっても答えが出せますから，心理学のように確率的で不確実なものを扱う領域にはもってこいなのです。

29.2 brms による実用的モデリング

第 28 講では，JASP という GUI ソフトウェアを使ってベイズ的な分析を体験しました。マウスで操作できるのは手軽ですが，一つだけ制約があります。それは，**メニューに用意されている分析しかできない**ということです。前節で見たように，確率的プログラミング言語を使えばデータの生成メカニズムを自分で書き下すことができるのですから，メニューから選ぶという発想そのものが窮屈になってきます。

とはいえ，Stan 言語をゼロから書くのは，初学者には難しく感じるでしょう。そこで，まずはパッケージの力を借りましょう。ここで紹介するのは R の **brms** パッケージ (Bürkner, 2017) です。brms は Bayesian Regression Models using Stan の略で，その名のとおり Stan を使った回帰モデルを，**R の式記法のまま**書けるようにしてくれるものです。私たちが `lm()` や `glm()` で使ってきた `y ~ x` という書き方が，そのまま使え

[*3] 日本語ではシープラスプラス，と読まれることの多い，コンピュータ言語です。C 言語というのがあったのですが，それの一歩次に行くという意味の表記です。ちなみに ++ というのは C 言語の表記で 1 を足すという操作を指します。R で `a <- a + 1` と書くことでオブジェクト a を 1 つ増やすことができますが，C 言語ではこれを `a++` と書くだけでいいのです。

るのです。

注意！ 3: brms を使う前に，インストールを済ませておくこと

brms は R のパッケージですが，計算そのものは Stan が行います。そのため install.packages("brms") とするだけでは動きません。お使いのパソコンに C++ のコンパイラと，Stan の本体である cmdstan を入れておく必要があります。この準備は OS によって手順が異なり，つまずきやすいところでもありますので，実践したい人はこの章末にある補遺 (セクション 29.5,Pp.401) を参照して先に済ませておいてください。

29.2.1 lm() を brm() に書き換える

第 9 講と第 24 講で使った，野球選手のデータをもう一度使いましょう。打者の身長から体重を予測する回帰分析です。第 24 講では，これを最小二乗法と最尤法という二つの方法で推定したのでした。今度はこれを，三つめの推定法であるベイズ推定でやってみます。

code : 29.1 データの準備とパッケージの読み込み

```
1  rm(list=ls())
2  library(tidyverse)
3  library(brms)
4  dat <- read_csv("BaseballDecade.csv", na="NA",
5           locale=locale(encoding="utf8")) %>%
6           filter(Year=="2020年度")
7  batter <- dat %>%
8    dplyr::filter(position != "投手") %>%
9    dplyr::select(height, weight, HR, AtBats)
```

ここまでは第 9 講とまったく同じです。ここから先が本題で，推定のコードを見比べてみてください。

code : 29.2 最尤推定とベイズ推定を並べてみる

```
1  # 第24講でやった最尤推定
2  result.LM <- lm(weight ~ height, data = batter)
3  # 今回のベイズ推定
4  result.BRM <- brm(weight ~ height, data = batter, seed = 12345,
5                    backend = "cmdstanr")
6  # 最尤推定
7  summary(result.LM)
8  # ベイズ推定
9  summary(result.BRM)
```

いかがでしょうか。lm が brm になっただけです[*4]。第一引数のモデル式も，データの指定も，何も変わっていません。これだけで，裏では Stan のコードが自動生成され，コンパイルされ，MCMC 法が走り，事後分布からの乱数が返ってきます。

実行すると，コンパイルのために少し時間がかかったあと，MCMC の進行状況が表示されます。それぞれ summary() で結果を見てみましょう。

[*4] seed 引数は乱数の出発点を指定するものです。MCMC 法は乱数を使いますから，指定しないと実行するたびに結果の細かい数字が変わります。同じ結果を再現できるようにしておくのは，研究の作法として大事なことです。

R の出力 29.1: 最尤推定とベイズ推定の結果

```
> # 最尤推定
> summary(result.LM)

Call:
lm(formula = weight ~ height, data = batter)

Residuals:
     Min       1Q   Median       3Q      Max
-20.9217  -4.9213  -0.4214   4.0783  28.9118

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -124.91755   13.89317  -8.991   <2e-16 ***
height         1.16670    0.07746  15.063   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.435 on 327 degrees of freedom
Multiple R-squared:  0.4096, Adjusted R-squared:  0.4078
F-statistic: 226.9 on 1 and 327 DF,  p-value: < 2.2e-16

> # ベイズ推定
> summary(result.BRM)
 Family: gaussian
  Links: mu = identity
Formula: weight ~ height
   Data: batter (Number of observations: 329)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
          Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept  -124.90     13.93  -152.55   -97.45 1.00     3803     2420
height        1.17      0.08     1.01     1.32 1.00     3807     2603

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma     7.46      0.28     6.92     8.05 1.00     3229     2706
```

最尤推定の結果とベイズ推定の結果を並べました。最尤推定の結果は第 24 講でもみたとおりで，推定値 Estimate のところをみると，切片が -124.92，傾きが 1.16670 と出ています。

これに対してベイズ推定の方も見てみます。最初の数行は何やら色々書いてますが，これは一旦後回しにして，推定値を見てみましょう。Regression Coefficients の Estimate の列をみてください。傾き height は 1.17 とあります。最尤推定の 1.16670 とほとんど同じです。切片も -124.90 と，最尤推定の -124.92 とほぼ同じです。

ただ，その後ろの数字が，最尤推定の場合とちょいと違います。最尤推定の時は Std. Error, t value

,Pr(>|t|) と並んでいます。それぞれ標準誤差，t 値，p 値です。点推定がどれほどの幅を持ってブレる可能性があるのか。推定値が 0 であるという帰無仮説から考えると，どれだけ外れてるのか。それは統計的に有意か。ということが書かれていたのでしたね。

これに対してベイズ推定の場合は Est.Error,l-95% CI, u-95% CI, Rhat,Bulk_ESS,Tail_ESS とあります。後ろの三つは MCMC がうまくいったかどうかの診断に使われる数字で，今は一旦横に置いておきましょう。大事なのは推定値ですから。で，Est.Error。最尤推定の時は Standard Error と書かれていましたが，ベイズ推定では Est.Error と書かれています。似ているようで違います。最尤推定の Standard Error は，推定値がどれぐらいの幅でブレるかを表すものでした。ベイズ推定の Est.Error は，事後分布の標準偏差です。ベイズ推定は，推定値が確率的，事後分布として得られることを思い出してください。この事後分布の標準偏差を計算したものが，Est.Error です。

後ろの l-95% CI と u-95% CI は，それぞれ 95% 確信区間の下限 (lower) と上限 (upper) です。CI は信頼区間 Confidence Interval のそれと区別して**確信区間 (credible interval)** と呼ばれます。信頼区間が「この幅に入ると言って当たる確率が 95%」という意味だったのに対して，確信区間は「この幅にパラメータがある確率が 95%」ということです。このように，推定の結果の背後についているのが，分布の情報になっているところが，最尤推定とベイズ推定の大きな違いです。

ところで，推定値自体は大きく変わりませんでした。「なんだ，同じ答えなら苦労してベイズにする意味がないじゃないか」と思われたかもしれません。しかしこれは，むしろ安心してよい結果なのです。329 人分ものデータがあれば尤度は十分に強い情報を持っていますから，弱い事前分布の影響は相対的に小さくなり，最尤推定とほぼ同じところに落ち着きます[*5]。ベイズにすると答えが変わる，という話ではないのです。そもそも，方法は違っても推定しようとしている母集団が同じなんですから，手法によって結果が都合のいいように変わるはずもないのです。

変わるのは，**得られるものの性質**です。lm() が返してくれたのは，1 組の点推定値とその標準誤差でした。これに対して brm() が返してくれたのは，4000 組のパラメータの乱数です。ここに決定的な違いがあります。前節で見たように，乱数が大量にあるということは，分布の形そのものが手元にあるということでした。図 29.4 に，得られた事後分布を描いてみました。

分布が手元にあると，たとえば「傾きが 1.1 より大きい確率はどれぐらいか」という問いに，そのまま答えることができます。4000 個の乱数のうち 1.1 を超えているものの割合を数えればよいだけだからです。標準誤差から検定統計量を計算して，p 値の表を引いて，といった手続きは必要ありません。

29.3 stan 言語を使ったプログラミング

brms は便利ですが，中で何が起きているのかが見えないままでは，やがて行き詰まります。brms が書けるのは「回帰モデルの形に収まるもの」までで，それを超えるモデルを考えたくなったときには，結局 Stan コードを自分で書くことになるからです。

Stan のコードは C++ 言語の書き方をしますから，最初は慣れないかもしれません。R と違って，古典的で厳格な書き方を必要とする言語です。大きな違いは，次の 3 つです。

1. 一行の終わりをセミコロンで書くこと
2. 変数の型を宣言してから使うこと
3. ブロック構造を意識して書くこと

[*5] 逆に言えば，データが少ないときには両者は一致しません。そのようなときこそ事前分布の置き方が効いてきますし，何を仮定して推定しているのかが問われることになります。

図 29.4 brms で推定したパラメータの事後分布。濃い部分が 95% 確信区間を表す

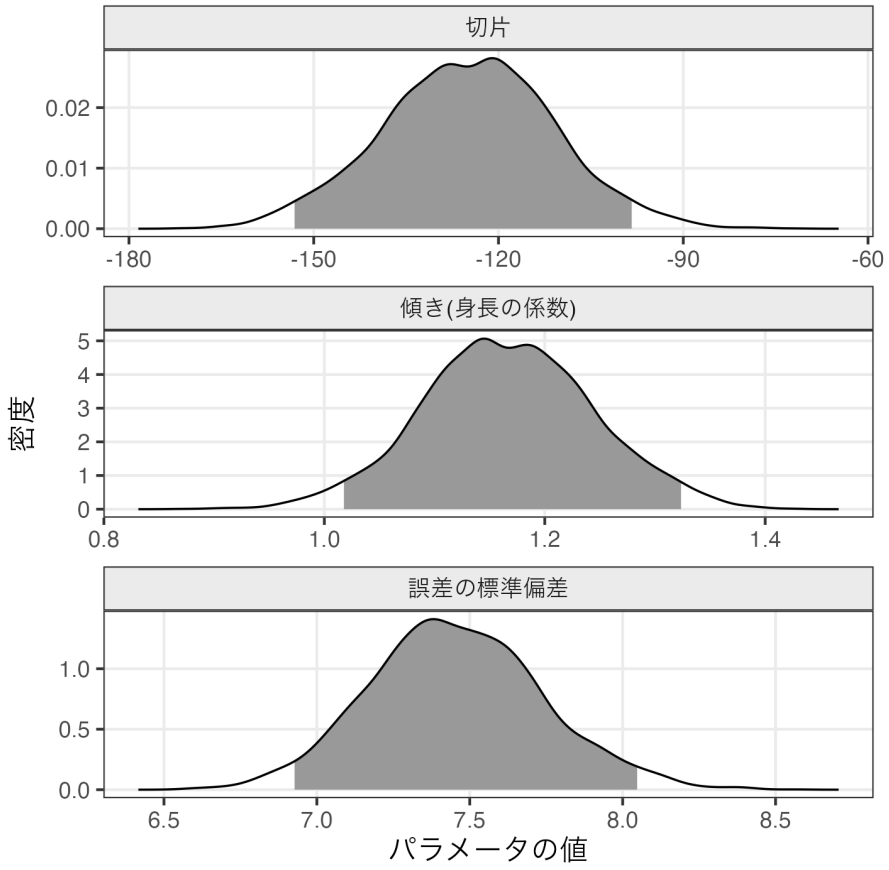

一つ目の点は，単なる表記上のマナーです。英語ではピリオド，日本語では句点で一文の終わりを示すように，C++ 言語ではセミコロン; で一行の終わりを示します。実は R でも複数行を一行にまとめるときにはセミコロンで区切ることができます。たとえば `a <- 1; b <- 2; c <- a + b` のように書くことができるのです。R ではセミコロンを入れなくても，改行すればそれで一行と見てくれますが，これはインタプリタ言語だからで，改行が入力 (R に対する指示実行) を意味するからですね。C++ 言語はコンパイル言語ですから，改行は意味を持ちません。セミコロンで一行の終わりを示す必要があるのです。これはもう，慣れてもらうしかありません。

二つ目の**型宣言**は，変数の性質を宣言してから使うということです。R では，オブジェクトに何か代入するとき，`a <- 5` とか `obj <- list(c(1,2,3))` のようにいきなり思いついたオブジェクト名，`a`,`obj` を使って代入していました。実は，R は少しやんちゃな言語なんです。C++ 言語はお上品に，まず「整数のオブジェクト，N を使わせていただきます。この中には 1 以上の整数しか入れません」「ベクトルのオブジェクト，mu を使わせていただきますので，サイズは N のベクトルを用意してください」，というお伺いを立ててから使うことになります。C++/Stan 言語はこのように，使う変数名をブロックの最初に書いて，しっかりと管理してくれるのです[*6]。

[*6] このような宣言が必要な歴史的経緯として，まだ計算機の性能が貧弱だった頃の時代背景があります。変数でもなんでも，計算機の中では本質的に短期的に記憶するためにメモリを使います。整数の 1 がはいった `a` をメモリに記憶しておくとき，メモリの xxxx 番地から xxxxx 番地までを `a` の領域として取っておこう，ということが内部で行われます。ここで `a` にはいま 1 が入っていますが，このあとどんな数字が入るかわかりません。2 になったり 100 になったりするかもしれないので，1 ビットだけ取っておけば良いというわけにはいきません。なので，扱える整数の範囲だけ領域を一旦確保しておくことになります。ここで，型が重要に

いちいち書くのは面倒だ，と思われるかもしれません。今まで野放図な R の世界だったので，急にマナーに厳しいこの業界に来ると不自由さを感じるのでしょう。でもこれはこれで，慣れると便利です。おかしな数字になったり，あり得ない値が出てこないようにする，という安全装置の役割も果たしているからです。

たとえば標準偏差パラメータは，負の数になることはありません。二乗して平方根を取った正の値なのですから，負の数が出てくるはずがないのです。Stan で標準偏差パラメータを推定したいとしましょう。推定したいパラメータ，変数も宣言する必要があります。その時，`real<lower=0> sigma;` のように書きます。標準偏差パラメータ `sigma` は real 型 (実数値) で，0 以上の値しか取らない，と宣言しているのです。もしも負の値が出てきたら，Stan はエラーを返してくれます。R では，`sigma <- -1` と書いてしまうと，そのまま-1 が入ってしまいます。Stan はそういうことを許さないのです。変数は使う前に宣言する，というのは他の言語でもよくあることですから，慣れてしまえば大したことはありません。

さて，最後の**ブロック構造**についてです。これは，関数などひとかたまりになるところをブロックとして，中括弧{}で囲む，という表記です。C 言語では関数，クラス，オブジェクトなど色々なものがブロックになりますが，Stan では決まったものだけがブロックになります。Stan のブロックは次のとおりです。

data **ブロック**　データを宣言するブロックです。R など，Stan 外から受け取るデータの型と名前を宣言します。

transformed data **ブロック**　データを変換するブロックです。Stan 外から受け取ったデータを，Stan 内で使いやすい形に変換するためのブロックです。省略しても構いません。

parameters **ブロック**　推定したいパラメータを宣言するブロックです。Stan が推定するパラメータの型と名前を宣言します。

transformed parameters **ブロック**　パラメータを変換するブロックです。Stan が推定したパラメータを，Stan 内で使いやすい形に変換するためのブロックです。省略しても構いません。

model **ブロック**　データとパラメータの関係を宣言するブロックです。Stan が推定するモデルの形を宣言します。具体的には，尤度と事前分布を書き下すことになります。

generated quantities **ブロック**　事後分布からの乱数を生成するブロックです。Stan が推定したパラメータを使って，事後分布からの乱数を生成します。省略しても構いません。

必ず必要なのは，`data` ブロック，`parameters` ブロック，`model` ブロックの 3 つです。その他のブロックは必要に応じて書けば良いでしょう。

以上が Stan のコードを書くときの基本的なルールです。でもこれだけで，白紙の状態から Stan のコードを書くのはちょっとイメージができませんよね。そこで，RStudio の手助けを借りてみましょう。RStudio の File > New File から，Stan File を選んでください。エディタ画面に Stan のファイルが開きます。そしてここには既に，サンプルコードが書いてあるのです。これを読んでみましょう。

なってきます。というのも，整数の場合と実数の場合とでは，確保しておく領域のサイズが変わるからです。実数は小数点以下の値をもちますから，整数部分と小数部分の両方を確保しておく必要があります。メモリが無尽蔵にある今では気にしなくていいですが，昔の貧弱なメモリ空間では実数の領域を確保することと，整数の領域を確保することでは，メモリにかける負担が大きく違っていたのです。なので，メモリを使う前にどれぐらい使うのか教えておいて！ (宣言して！) というのはメモリ管理上重要なステップなのです。

R の出力 29.2: RStudio の Stan サンプルファイル。紙幅の関係でコメント文はカットしています。

```
data {
  int<lower=0> N;
  vector[N] y;
}

parameters {
  real mu;
  real<lower=0> sigma;
}

model {
  y ~ normal(mu, sigma);
}
```

スラッシュが 2 つ並んでいる//はコメント文, この行は無視して良いという意味で，R でいう#と同じですから, 無視して構いません。ここに掲載したのはコメント文を除外したものです。

さて, このサンプルコードを見ると, 確かに data ブロック，parameters ブロック，model ブロックの 3 つからなることがわかりますね。そして，data ブロックと parameters ブロックでは, 変数の型宣言 (だけ) がなされています。この変数を使うよ, ということです。コードの中身は次のような意味になります。

■コード解説

data ブロック 整数 (integer) 型の変数 N と, 長さ N のベクトル型の変数 y を使う, という宣言です。このブロックは外部からデータを受け取るところですから, 外部から長さ N の実数ベクトルを受け取る, という意味になります。

parameters ブロック 実数 (real) 型の変数 mu と，0 以上の実数 (real<lower=0>) 型の変数 sigma を使う, という宣言です。このブロックは Stan が推定するパラメータを宣言するところですから，Stan は mu と sigma を推定する, という意味になります。

model ブロック y ~ normal(mu, sigma); は，y は平均 mu, 標準偏差 sigma の正規分布に従う, という意味です。Stan では, ~を使って「従う」という意味を表します。これは尤度関数そのものですね。正規分布からデータが生成されている, とも読めます。

特に model ブロックに注目してください。$y \sim N(\mu, \sigma)$ というモデルが，ほぼそのまま y ~ normal(mu, sigma); と書かれているのがわかると思います。確率分布や尤度関数，$\prod$ や $\sum$ の記号を使った数式を書かなくていいのです。変数 (データ) がどういう確率分布から出てきているかを書けば, モデルが書ける！答えが得られる！これが Stan の強みです。ここから先の計算は全部やって, 答えを出してくれるというのですから, 私たちは確率モデル, データがどういう数式から出てきているかを考えるだけでよくなったわけです。確率プログラミング言語が, 数理統計学者だけでなく心理学者のような統計ユーザにも, 大きく門戸を開いてくれたということが, 少しは実感していただけたでしょうか。

ちょっと補足

ここの補足セクションは，読み飛ばして次に進んでもらっても構いません。実践する上で大事なことを 2 つだけ，書いておきます。

■事前分布の記述 `model` ブロックには尤度と事前分布を書くのですが，ここには事前分布の記述がありません。データ y と確率分布の関係，つまり尤度関数しか書かれていないのです。事前分布はどこに行ったのでしょう。

実は，Stan は事前分布を省略することができます。省略した場合は，Stan が自動的に「無情報的事前分布」を設定してくれます。正確には，Stan はパラメータの取りうる範囲を無限大に広げて，その中で一様分布を仮定することになります。つまりどんな値をもとりうる，どういう値になるか全くわかっていない，という状態で推定してくれるわけです。こうしておくと，事後分布の形は尤度をそのまま反映してくれますから，最尤推定とほぼ同じ結果が得られることになります。

もちろん積極的に事前分布を設定することもできます。事前分布はパラメータにおかれるものですから，ここでは μ と σ に事前分布を設定することになります。たとえば，μ は平均 0，標準偏差 100 の正規分布に従うと仮定したい場合は，`mu ~ normal(0, 100);` と書きます。σ は正の値しか取らないので，平均 0，標準偏差 10 のコーシー分布に従うと仮定したい場合は，`sigma ~ cauchy(0, 10);` と書きます。

■尤度関数を正確に記述する もう一度尤度関数を見てみましょう。$y \sim N(\mu, \sigma)$ の y は，正確にはベクトルですね。要素が N 個あるベクトルです。数学的に正しく書くならば，

$$L(\mu, \sigma | y) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \mu)^2}{2\sigma^2}\right) \tag{29.1}$$

となります。$\prod_{i=1}^{N}$ の部分にあるように，データ y_i を全部掛け合わせたものが尤度となるはずなのです。ところが Stan のコードでは y しか書いていない。正しくは，次のように書くべきです。

```
y[1] ~ normal(mu, sigma);
y[2] ~ normal(mu, sigma);
...
y[N] ~ normal(mu, sigma);
```

つまり，y の要素ごとに，平均 μ，標準偏差 σ の正規分布に従う，と書くべきです。ただ，N が 5 や 10 ぐらいであればまだしも，大きくなったら大変。ということで，プログラミング言語の表現を借りて，次のようにするのが一般的です。

```
for (i in 1:N) {
  y[i] ~ normal(mu, sigma);
}
```

これで正しく $\prod_{i=1}^{N}$ の部分が表現できました。実際，自分でコードを書くときはこのように `for` 文で書くことも多いです。しかし，同じベクトルに同じ確率関数を適用する場合は，Stan は省略した書き方，すなわちここにある `y ~ normal(mu, sigma);` のような書き方を許してくれます。Stan は，`y` の要素ごとに同じ確率分布に従う，と解釈してくれるのです。便利ですね。

もし尤度関数が，回帰分析のように $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma)$ のように，x_i の値によって平均が変わる場合は，for 文で書く必要があります。すなわち，

```
for (i in 1:N) {
  y[i] ~ normal(beta_0 + beta_1 * x[i], sigma);
}
```

としなければなりません。この例のように，x_i の値によって毎回尤度関数が変わる場合は，Stan は省略した書き方を許してくれないことに注意してください。

29.4 生成量による新しい仮説の立て方

さて，Stan を使ってコードを書くことができるようになりました。ここから少し発展的な使い方を見てみましょう。

ベイズ推定の利点として追加で説明しておきたいのは，仮説検定的に「手に入ったデータについて考える」のではなく，「データを生み出すメカニズムを考える」という視点が得られるというところです。この視点を特に **生成モデル (generative model)** といいます。

たとえば独立サンプルの t 検定では，これまでは A 群と B 群の数値の列だけが与えられ，さてこの平均値に差があるか，という話から始まりました。その上で，急に複雑な数式が出てきて，そこに数字を当てはめさえすればあとは有意かどうかを判定する数字が出てくる，という感じではなかったでしょうか。こうなると「なんだか分からないけど，$p < 0.05$ ならいいんでしょ」という理解になってしまいがちなのも無理はありません。このオールドファッションなやり方の利点は，A 群・B 群の数字がなんであってもいいことです。心理学の実験データでも，農業試験場の農作物のデータでも，経済学でもマーケティングでも法学でも生物学でも，とにかく 2 群の数列があれば，平均値の差を検定できるという理屈です。やり方が決まっているので，統計ソフトウェアに実装することも簡単ですし，手順を教えるだけで誰にでも使えます。しかしそのことが，誤用・誤解を生んできたのだということを，忘れてはなりません。

しかし，ベイズ的に考えると，A 群と B 群のデータが独立した正規分布から出てきている，という生成メカニズムの観点から考えます。A 群のデータは平均 μ_A，分散 σ^2 の正規分布から出てきている，B 群のデータは平均 μ_B，分散 σ^2 の正規分布から出てきている，というモデルを考えているのです。ここで確率分布関数・尤度関数はデータを生成するメカニズムだといえます。このような背景を考えるのですから，間違って割合のデータに t 検定を適用するとか，反応時間のように正規分布しないデータに t 検定を適用するとか，そういう誤用は起こりにくくなります。なぜなら，そのようなデータはそもそも正規分布から生成されているとは考えにくいからです。生成メカニズムを考えることは，データの性質を考えることにつながります。データの性質を考えることは，適切な分析方法を選ぶことにつながります。ベイズ的な考え方は，このように分析方法の選択にも良い影響を与える可能性があります。

また，MCMC 法ではこの μ_A, μ_B, σ といったパラメータを推定するために，乱数を発生させるのでした。乱数とは事後分布を代表する数字であり，データから得られた情報をもとにパラメータが取りうる値の具体的な値をたくさん作っていることになります。乱数を 100,000 個作るというときは，$\mu_A^{(1)}, \mu_B^{(1)}, \sigma^{2(1)}$，$\mu_A^{(2)}, \mu_B^{(2)}, \sigma^{2(2)}$, ...，$\mu_A^{(100000)}, \mu_B^{(100000)}, \sigma^{2(100000)}$ というように，100,000 組のパラメータの組み合わせを作っていることになります。

さて，このそれぞれの代表値を使って応用的に考えてみましょう。ここで興味があるのは μ_A と μ_B の差です。これを $\delta = \mu_A - \mu_B$ という新しいパラメータ δ で表しましょう。これは MCMC 法で得られた乱数を使って具体的に計算できて，$\delta^{(1)} = \mu_A^{(1)} - \mu_B^{(1)}$，$\delta^{(2)} = \mu_A^{(2)} - \mu_B^{(2)}$, ...，$\delta^{(100000)} = \mu_A^{(100000)} - \mu_B^{(100000)}$ と

いうように，差の乱数を 100,000 個作ることができます。この差の乱数をヒストグラムにすれば，「差」の事後分布が得られます。この差の事後分布を使って，差が 0 より大きい確率はどれぐらいあるか，差が 0 より小さい確率はどれぐらいあるか，ということもわかりますし，差の 95% 確信区間もわかります。これと ROPE を組み合わせれば，差が実質的に意味があるのかどうかの判断ができます。

このようにパラメータから作られる量のことを，**生成量 (generated quantities)** と呼びます。生成量は，もとのパラメータから計算される新しい量です。ベイズ推定の MCMC 法では，この生成量を簡単に計算できるという利点があります。パラメータの事後分布が得られれば，そこから生成量を計算することは容易だからです。差の大きさそのものを考えているわけですから，これが効果量です。わざわざ効果量を別途計算しなくても，生成量として差の大きさを直接考えることができるわけです。さらに差の確率分布を考えているのですから，「差の 95%HDI がゼロを含むかどうか」といった一点についてだけ考えるのではなく，「差が 0 より大きくなる確率はどれぐらいか」とか，「差が 5 より大きくなる確率はどれぐらいか」といった具体的な議論ができるようになります。

もっと面白いことも言えますよ。データ生成のメカニズムを考えているわけですから，推定された値を使って，新しくデータを作り出すこともできるのです。A 群のデータは平均 μ_A，分散 σ^2 の正規分布から出てきている，と考えるのでしたね。であれば，`rnorm(100,mu_A, sigma)` とすれば，この μ_A, σ の組み合わせから 100 個の新しいデータを作り出すことができますよね。もちろん同様に B 群のデータを作ることもできます。MCMC 法では，$\mu_A^{(1)}, \sigma^{(1)}$，$\mu_A^{(2)}, \sigma^{(2)}$, ...，$\mu_A^{(100000)}, \sigma^{(100000)}$ というように，100,000 組のパラメータの組み合わせを作っているわけですから，これらを使って `rnorm(n,` $\mu_A^{(i)}$`,` $\sigma^{(i)}$`)` というように 100,000 回新しいデータを作り出すことができます。

このように，推定された値を使って作られる予測分布のことを，**事後予測分布 (posterior predictive distribution)** と呼びます。事後予測分布が表しているのは，「パラメータがある値だったときに取りうる実現値」のことです。つまり，母集団における母数 (パラメータ) ではなく，得られる標本 (データ) についての分布を考えることができます。そうすると，どういうことが考えられるでしょうか。これまでは A 群と B 群の母平均に差があるかどうか，という話をしていましたが，「もし新しくデータを取ったときに，A 群の人が B 群の人よりもスコアが高い確率は」といったことがわかるようになりますよね。これを仮説として検証することも，もちろん可能です。

世の中には「男性脳と女性脳」「日本人と外国人」のように，大きな主語で物事が語られることがあります。しかしそれらは，平均的には差があるという話であって，平均を中心とした分散をともなって一人一人のデータとして実現するわけですから，あまり意味のないことも少なくありません。一言で言うと効果量が小さい場合が多いのです。たとえば「男性は女性よりもたくさん食べる」ということが統計的に示されたとしても，少食の男性もいるし，たくさん食べる女性もいるでしょう。もしあなたが次に初めて出会う男性が女性よりたくさん食べるかどうかを知りたければ，平均値の差があるかどうかを調べるよりも，事後予測分布を使って「男性が女性よりたくさん食べる確率はどれぐらいか」を調べた方がよほど実践的です。このように，生成モデルの視点からデータを考えることは，仮説の立て方や検証の仕方にも新しい可能性をもたらします。

新しく得られるデータにおいて，一方の群が他方の群よりどれほど大きいか，という指標を**優越率 (probability of dominance)** と呼びます。また，両方の群がどれほど重複しているかを表す指標として，**被覆率 (overlap coefficient)** というものもあります。実はこれらの指標は，ベイズ統計学による生成量のアプローチを待つまでもなく，頻度主義統計学の中でも提案されてきた指標です。ですが，頻度主義的統計学の誤用・誤解の広がりのように，p 値万能主義の中でこれらの指標にはあまり注目されてきませんでした。ベイズ的アプローチ，特に MCMC を使った生成量のアプローチで，これらの指標が簡単に計算できるようになったことで，改めて注目されるようになってきています。皆さんもぜひ柔軟な姿勢で，分かりやすい角度から仮説を考えるようにしてください。

29.4.1 この先の学びへ

ここまでで，ベイズ推定を実践するための道具立てが一通り揃いました。確率的プログラミング言語があり，brms という入口があり，生成量という自由な発想があります。あとは，皆さんが立てたいモデルを書くだけです。

Stan を具体的にどのように使うか，brms の詳しい使い方などについては紙幅の都合で触れていませんが，これらについては 3 年次の「ベイズ統計学」で扱いますので，本講はそこへの橋渡しと考えてください[*7]。

29.5 補遺・Stan 環境の準備

29.5.1 インタプリタ言語とコンパイラ言語

パッケージ `brms` は R のパッケージですが，その中で Stan を使います。ですから，CRAN から `brms` をインストールするだけでなく，それとは別に Stan の環境を整えなければなりません。

Stan は R/RStudio のように，ダウンロードしてきたらコンソールが出てきて，そこに書き込んで実行するというような使い方はしません。インストールしても決して表に出てくることなく，PC の中に潜んで事後乱数の計算をしてくれるものです。表に出てこないし，アイコンも出てこないので，インストールしたことが分かりにくいところがあります。ちなみに R のように一問一答型で実行できるのはインタプリタ言語といい，Stan のように表には出てこず結果だけ返すような言語をコンパイラ言語と言います。Stan 言語でかかれた事後分布からの乱数発生装置・指示書を機械の言葉に翻訳 (コンパイル) して，みなさんの PC が直接わかる機械の言葉で計算させます。インタプリタ言語は逐一の翻訳が必要なので計算スピードが遅い[*8]のに対し，コンパイラ言語は一度設計図全体を完全に翻訳させてから計算させるので，翻訳に少し時間がかかるけれども，翻訳後のスピードはものすごく速いのです[*9]

さて，この翻訳には C++ という言語が使われています。C++ も言語，Stan も言語，R も言語なんですが，C++ は非常に古典的かつ汎用的な言語で，Stan の翻訳に使われるだけでなく，ゲームやアプリケーションの開発にも使われています。たとえば Windows や Mac の OS なんかも (以前は)C++ で書かれていました。Stan はこの C++ の翻訳機能をいわば利用させてもらう言語なので，みなさんの PC には C++ のコンパイラ (翻訳機) を入れ，さらに Stan を入れる，という手順が必要です。

初学者にとって，Stan 言語の壁があるとすると，この導入の箇所，環境構築なのです。計算機を使う上で，ファイルの場所，ディレクトリ構造などの基本的な知識が必要で，失敗すると「Stan が動かない」ということになってしまいます。R や RStudio のように，アイコンをクリックしたらインストールできて，アイコンをクリックしたら起動する，というような簡単な関係にないところが難しいところです。しかも，R や Stan はもちろん，OS も日々アップデートしますよね。となると，人によって環境・OS の微妙な違いがあちこちにできます。しかもこのテキストのように，「こうやってインストールしますよ」という説明が日々時代遅れになってしまう。これは文章書きとしては致命的な問題で，ほとほと困ってしまいます。

さて。泣き言を言っても仕方がないので解説していきますが，前提として次のことを約束してください。

[*7] なお，この Stan のコンパイルを使うステップ，すなわち環境の準備や Stan 言語の習得の障壁が高いと思われる人には，BayesRTMB(Shimizu, 2026) というパッケージもあります。これは R 言語だけで完結し，Stan ばりのベイズ推定ができるパッケージです。ただし，その後さらに発展的なモデルを試すためには，いずれ Stan や他の言語に移行する必要があると思われるため，本書では「急がば回れ」で，最初から Stan を使うことを推奨します。

[*8] といっても，みなさんが使っている分には十分早く，瞬時に答えが返ってくると思いますが。

[*9] といっても，Stan で計算させる内容はモデルが複雑になれば，さすがにみなさんの PC でも数分から数十分かかることもあるでしょう。私なんかは込み入ったプログラムを書きすぎて，数時間から数日計算し続けるなんてこともあります。

- 自分の今の環境 (PC, OS) を把握し，OS はアップデートを当てた最新のものにしておくこと。
- R や RStudio 環境についても同じ。アップデートをして，常に最新のものにしておくこと。新しいバージョンは，前のバージョンの不具合を修正してくれているのです。なんだか面倒だから，よくわからないから放置する，というのがトラブルの元になります。
- ここで説明するのは書いてる時点[*10]での情報です。時間が経つごとにこの情報は古くなりますので，Stan の公式サイトや R の公式サイトで最新情報を確認してください。

既に R や RStudio を使っている，あるいは以前 Stan を入れたはずだけど時間が経っているひとは，まずは R や RStudio を最新のものにアップデートしてから始めてくださいね。

29.5.2 Stan 環境の準備

ここからは，OS ごとにやり方が異なりますので，みなさんは必要なところを読んでください。ちなみにこのステップは，Stan の公式サイト https://mc-stan.org/install/ に書かれています。最新版も確認してください。

MacOS の場合

1. まず C++ 環境ですが，これは Xcode という Apple 純正の開発環境を入れるのが簡単です。App Store から Xcode をインストールしてください。これで C++ 環境が入ります。
2. R を起動して，コンソールで次のように入力します。これで Stan の R パッケージが入ります。まず R パッケージを入れるのです。

```
install.packages("cmdstanr",
  repos = c("https://stan-dev.r-universe.dev",
            getOption("repos")))
```

3. パッケージが入れば，それを使って Stan を入れます。コンソールで `cmdstanr::install_cmdstan()` と入力してください。

Windows の場合

1. まず C++ 環境です。公式サイトには Conda を使えばいいのでは，ともありますが，それよりも簡単なのは Rtools を入れることです。Rtools は R の公式サイトからダウンロードできます。`CRAN R` と検索して，https://cran.r-project.org/ に行きます。ここで base を選ぶと R 本体が入りますが，その下にある `Rtools` を選んでインストーラをダウンロードします。ちなみにこの Rtools は，R のバージョンに合わせたものを選ぶ必要があります。2026 年 8 月 18 日現在の最新 R は 4.6.1 で，Rtools は Rtools4.5 が最新です[*11]。
2. インストーラがダウンロードできたら，それをダブルクリックします。インストールときに「PATH に追加する」オプションをクリックして選択してください。また，インストール先にも注意してください。自分のドキュメントや Program Files の中に入れると，OneDrive という仮想空間の中に入ってしまい，PC にその実体が入らないという不具合が生じかねません。おすすめは C ドライブ直下。C ドライブに `Rtools` というフォルダを作って，そこに入れるのが無難です。いずれにせよ，**どこにインストールしたかをしっかり把握しておいてください。**

[*10] 2026 年 8 月 18 日現在

[*11] R のバージョンが 4.6.1 なのですから，Rtools も 4.6 であって欲しいのですが，まだ提供されていません。が，4.5 が 4.6.1 でも動きますので，それで。

3. この後は MacOS と同じです。R を起動して，コンソールで次のように入力します。これで Stan の R パッケージが入ります。まず R パッケージを入れるのです。

```
install.packages("cmdstanr",
  repos = c("https://stan-dev.r-universe.dev",
            getOption("repos")))
```

4. パッケージが入れば，それを使って Stan を入れます。コンソールで `cmdstanr::install_cmdstan()` と入力してください。

インストールが終わったら，最後に R に「どこに Stan が入っているか」を教えてあげる必要があります。インストールの最後に「このパスにインストールしたよ」という情報が表示されているはずです。そのパスをコピーして，R のコンソールで `cmdstanr::set_cmdstan_path()` の () の中に貼り付けてください。これで R が Stan の場所を認識します。

うまくインストールできたかどうか，確認するために CmdStanR のサイト，https://mc-stan.org/cmdstanr/articles/cmdstanr.html をみてみましょう (「Getting started with CmdStanR 」で検索するといいでしょう)。そこには上でも述べたインストールの方法が書いてありますが，その下にサンプルコードがあります。

code : 29.3 Stan サンプルコード

```
1 library(cmdstanr)
2 file <- file.path(cmdstan_path(), "examples", "bernoulli", "bernoulli.stan")
3 mod <- cmdstan_model(file)
```

このコードが走れば，あなたの PC には Stan が入っていることになります。もしエラーが出る場合は，どこかで手順を間違えている可能性があります。バージョンを確認する，パスを確認することが大事です。エラーが出たら，私や生成 AI に相談してください。でも「なんかうまくいかない！」ではなく，自分の言葉で自分の環境について説明し，このバージョン，このパスで，このエラーが出る，というような伝え方をしてくださいね。助ける側もノーヒントでは助けられません。自分の環境を把握することが，Stan を使いこなす第一歩です。

第 30 章

後期のまとめ

後期のテーマを振り返ってみます。

後期は**帰無仮説検定 (null hypothesis significance testing; NHST)** の基礎から始まりました。NHST は心理学におけるデータ解析の中心的な手法であり，実験結果が偶然によるものかどうかを判断するための方法です。帰無仮説と対立仮説を設定し，得られたデータに基づいて帰無仮説を棄却するかどうかを決定します。この過程で p 値が重要な役割を果たし，その解釈と限界についても学びました。

二群の平均を比較する **t 検定 (t-test)** や，三群以上の平均を比較する**分散分析 (analysis of variance; ANOVA)** も学びました。分散分析は特に，**要因計画 (factorial design)** に基づく実験デザインで用いられ，複数の独立変数が従属変数に与える影響を同時に評価することができます。これに検定の要素である **F 検定 (F-test)** が組み合わさることで，群間の差異を統計的に判断できるようになるわけです。これらの手法は，実験デザインに応じて適切に選択され，データのばらつきを考慮しながら群間の差異を評価します。また，R 言語を用いた実践的なデータ解析方法も習得しました。「群内・群間」「要因」「水準」といった用語，「交互作用」という概念は心理学実験の基礎であり，これらを理解することで，より複雑な実験デザインにも対応できるようになります。

そしてここまでは，データが得られたときに確率分布に当てはめて考えるものでした。特に標本統計量を母数の推定値としてそのまま用いるのは，**モーメント法**と呼ばれます。後期の授業はそのあと，より積極的に確率分布を使う，確率モデルの世界に入っていきます。

確率モデル (probabilistic model) とは，データがどのように生成されるかを確率分布を使って記述したものです。個々のデータは理論通りにいかず，個性や誤差によってばらつくのが心理学です。この「予想できない実現値」を不確実なものの傾向を捉える「確率分布」で表現しようとするものです。いわば，確率分布をデータ生成器のように捉えるわけです。確率モデルを仮定し，データとの関係を考えるときに，**尤度 (likelihood)** という考え方が重要になります。尤度は，ある確率モデルが与えられたときに，観測されたデータが得られる確率を表します。尤度を最大化することで，最もデータに適したモデルパラメータを推定する方法が**最尤法 (maximum likelihood estimation; MLE)** です。最尤推定は，心理学データ解析において広く用いられており，様々な確率モデルのパラメータ推定に利用されます。このように考えると，線形モデルは単純な確率モデルの一種であり，様々な確率分布を使えば一般化できることがわかります。

そして最後に出てきた推定法が，**ベイズ法 (Bayesian method)** です。ベイズ法は，確率モデルのパラメータを確率変数として扱い，**事前分布 (prior distribution)** と**事後分布 (posterior distribution)** の概念を用いて推定を行います。事前分布は，データを観測する前にパラメータについて持っている知識や信念を表し，事後分布は，観測されたデータに基づいて更新されたパラメータの分布を示します。ベイズ法の利点は事前分布を取り入れること，結果の解釈が自然で直感的なものになることだけでなく，非常に複雑な確率モデルであっても推定が可能になる点にあります。特に，**マルコフ連鎖モンテカルロ法 (Markov chain Monte**

Carlo; MCMC) と呼ばれる数値的手法を用いることで，解析が困難な事後分布を近似的に求めることができます。これにより，心理学研究における複雑なデータ構造やモデルにも対応できるようになるのでした。

こうして見てくると，帰無仮説検定が少し窮屈に思えてくるでしょう。帰無仮説検定は正しく結論づけるために，非常に細かくルール・マニュアルを設計していきますが，そのマニュアルが窮屈すぎるきらいがあることは否めません。ここまでくると，そもそも線形モデルであるというのも気に入らなくなってきませんか。これまでは帰無仮説検定しかツールがなかったので，無理やり正規分布かつ線形の枠組みに研究を押し込めてきたという歴史的経緯がありました。

たとえば比率のデータは正規分布しませんから，分散分析の対象にはなりません。どうしても分散分析したい場合はデータを角変換して補正するとか，所得や反応時間のように正規分布しないものを対数変換して補正する，といったように，データの変換というのが行われてきました。これは分散分析に落とし込むしか検証の方法がなかった，前時代的な風習です。

線形モデルも発展していき，正規分布の仮定を取り払った**一般化線形モデル (generalized linear model)**(GLM) では，二項分布やポアソン分布といったデータの生成過程にあった分布を選択できるようになりました[*1]。いまではデータの変換ではなく，適切な確率関数・尤度関数を選ぶのが基本的なやり方です。

それでも線形の性質は保持されたままです。もっと自由に変数間関係を表現することはできないのか，という考えが湧いてきた人もいるかもしれません。もちろんそれは可能で，線形ではないモデルを自分から考える，**モデリング (modeling)** の考え方は現代心理学にもどんどん広まっています。そのモデルのパラメータ推定には，ベイズ統計の力が非常に強力で役立つので，とくに**ベイジアンモデリング (Bayesian modeling)** と呼ばれています。

後期の話を通じて伝えたかったことは，「心理統計学は面白い」ということに他なりません。数学を使うこと，覚えるべきことが多いこと，正解と間違いがはっきりしていることなど，文系を自認する人にとっては敬遠されるところも少なくありません。しかし，心理学が科学であり，データを扱うものである以上，データを正しく扱う技術はなくてはならないものです。生兵法は大怪我のもと，というように，恐々データに触れるとか，わからないから適当にやってしまうというのは，かえって危険なことなのです。わからないことがあれば，わかるところまで戻って知識を積み上げればいいのです。心理学の実践的技術の中には，熟練したり経験を積まなければ到達できないものが少なくありません。一方で，心理統計は確実に積み上げることができますから，入り口の恐怖心さえ克服すれば，あとは着実に前進できるのです。繰り返しますが，戦々恐々としながら，生半可な理解でデータを分析し，間違った実践をする方が危険で怖いことなのです！

確率モデルのところまで理解できれば，あとは身の回りにある人間の行動，思考，感情などのデータを確率モデルで表現して理解することになります。これこそ心理学ではありませんか。心がどのような (確率) モデルになっているのか，振る舞いがどのような (確率) モデルから生まれてくるのかを考えるのですから！これが心理学の本質でなければ，何だというのでしょう。そして今の世界には，確率モデルが至る所にあります。自動運転技術やロボットの動きも，学習メカニズムという確率モデルです。マーケティングや経済の動きも確率モデルです。生成 AI が人間のようなやり取りをしてくれるのも，言葉を生み出す確率モデルです。犯罪者のプロファイリングや臨床的な診断も確率モデルです。心理学だけでなく，社会のあらゆるところで確率モデルが使われているのです。心理統計学を理解することは，現代社会を理解することでもあるのです。

心理統計の世界は非常に広大ですから，半年や一年ですべてを理解できるわけではありません。その時は，いつでもわからないところまで立ち返ってください。私はいつでも，あなたが心理統計学を理解する手助けをします。わからないままデータが目の前に現れ，分析モデルに振り回され，苦しむことがありませんよう

[*1] 平均値の差の検定は線形モデルと同じ (一般) だぞ，ということを一言でいうと一般線形モデル General Linear Model といいます。日本語でいうと「化」，英語でいうと-ized があるかないかで意味が随分変わってしまうので要注意です。

に。その苦しみのもとにあるのは, あなた自身の数学に対する恐怖心でしかないのです。

Enjoy Psychology and Statistics!

付録 A

よくある質問とミスの例

A.1 Frequently Miss and Comments

Rmd でレポートを提出したのに，なんだか中身の問題じゃないのに突き返された，中身を見てくれよ！と思う人もいるかもしれません。テキストでは R や Rmd での課題を提出するよう求めているところがありますが，その際よく見られる学生さんのミスとその対応についてのコメントをここにまとめておきます。

A.1.1 FMC1；そもそもファイルの書式が違う

Rmd で提出してください，R で提出してください，という指示に対して，違うものが提出されてくることがあります。書式があっていない，というのは些細なことのように思えるかもしれませんが，学術論文は書式に捉われず内容に集中するためにも，書式は整えられたものである必要があります。学会誌に掲載されている論文も，みなさんが書く卒業論文も，レポートに至るまで，書式や指示に沿ったものを準備する必要があります。書式があっていない場合は，門前払いになっても文句が言えないのがアカデミックの世界です。

ということですので，R や Rmd で提出してください，という指示があれば，R や Rmd で提出してください。ファイルの種類は拡張子で分類され[*1]，R ファイルは `.R`，Rmd ファイルは `.Rmd` という拡張子になっています。たまに `.Rproj` というファイルを提出してくる人がいますが，これは R プロジェクトのファイルで，これには R スクリプトも文書も含まれておらず，みなさんの計算環境情報が少し書いてあるだけです。また，`.Rmd` だけ入っていれば良いかというとそうではありません。まれに `Filename.Rmd.R` というようなファイルを送ってくる人がいます。これはファイル名にピリオドが含まれているだけで，ファイルの種類を識別する拡張子は `.R` ですから Rmd ファイルではありません[*2]。そもそもファイル名には 2 バイト文字はもちろん，!や?などの記号を含めるべきではありません。ピリオドも当然記号の一種ですから，ファイル名にするのは不適切です[*3]。

ではどうやって適切なファイル形式にするか，ということですが，最も素直な方法としては RStudio で新しくファイルを開くときに，R markdown 形式 (略して Rmd) を選ぶようにしましょう。もし間違って，R script 形式 (`.R` 形式) で開いてしまった，というときは，そのファイルを破棄して新しく作り直すのが一番ですが，エディタペインの右下にあるファイル種類表示 (図 A.1) をクリックして修正することもできます。

[*1] 拡張子についてはセクション 2.4,Pp.23 参照

[*2] 最近の OS は拡張子を表示しない設定になっているものも少なくないので，このようなミスが生じます。

[*3] 長いファイル名などの場合，空白を入れるのも適切ではありません。できなくはないのですが，やるべきではないのです。どうしても空白を入れたければ，アンダースコアなどで区切ると良いでしょう。

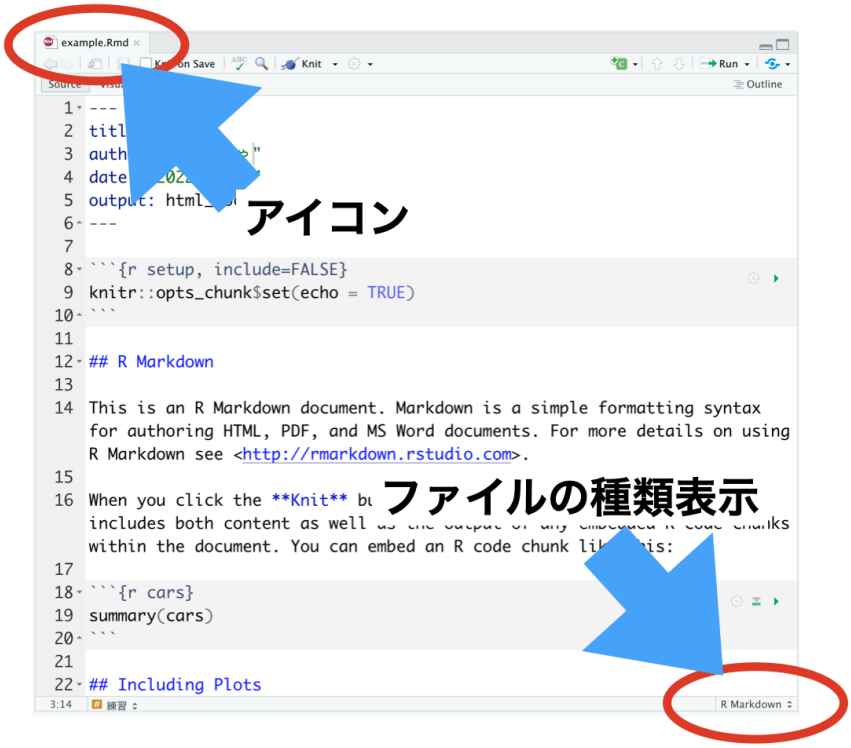

図 A.1 ファイルの種類を判別する方法

A.1.2 FMC2；やっぱりファイルの形式が違う

Rmd 形式のファイルは，拡張子だけで決まるものではありません。図 A.2 にあるように，Rmd ファイルは冒頭の 6 行 (正確には---で囲まれた領域) が YAML と呼ばれるところで，文書全体の設定をしています。その下に，R のコードを実行する部分 (**チャンク (chunk)**) や文章の領域があります。文章のところは#記号で見出しを作ったりできます。

この YAML 部分が壊れている，あるいはチャンクが正しく記述されていない場合，拡張子が.Rmd であっても適切な Rmd ファイルにはなっていません。YAML 部分の書き方はよくわからない，という人も多いと思いますので，RStudio で Rmd ファイルを作ったときの状態をなるべく変更しないように注意すると良いでしょう[*4]。

チャンクは R のコードを書くところで，バッククォーテーション 3 つでくくるのが決まりです。チャンク領域が始まるところに{r}とかいて「ここが R で計算するところですよ」というのを指定するわけです[*5]。このバッククォーテーション 3 つ (```) が全角だったり (｀｀｀)，ダブルクォーテーションだったり (") すると，機械は正しくチャンクであると認識しません。フォントなどの見せかけ上は，微妙な違いのように見えますが，機械にとって違う文字列は違う意味を持ちますので注意してください[*6]。RStudio で編集する場合，チャンクの領域はやや

[*4] Rmd ファイルを新しく開くときに，文書タイトルや著者名，日付，出力ファイル形式などを設定することができるウィンドウが開きますので，そこに必要な情報を書くと自動的にそれを使った YAML が生成されます。また，本文として幾つかのサンプルコードが最初から含まれていますが，これらに関してはサンプルをそのまま使うことはないので，全て削除してしまって結構です。

[*5] ほかにも Python や Julia など他の計算言語を混ぜることもできます。

[*6] 記号の名称や入力については，セクション 2.7,Pp.27 を参照してください。

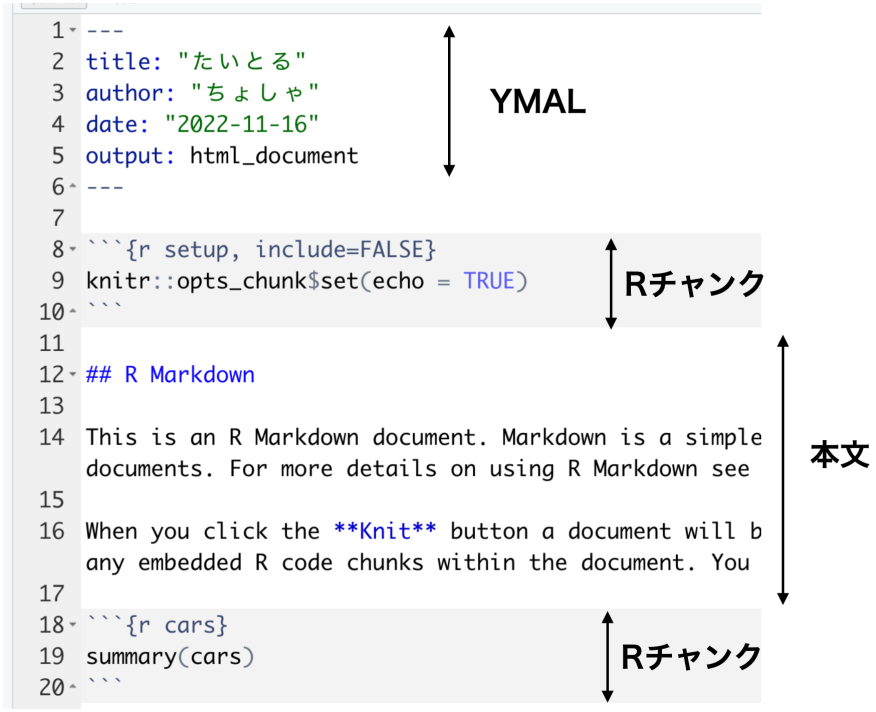

図 A.2　Rmd ファイルの中身における書式

灰色がかった強調表示がされますので，どこにチャンクがあるかわかると思います。もし強調表示されていないようであれば，チャンクとして認識されていない可能性を疑った方が良いでしょう。

チャンクはバッククォーテーション 3 つで開き，おわったら同じくバッククォーテーション 3 つで領域を閉じます。閉じなければずっと R の計算領域が続くと解釈されますし，最後までチャンクが閉じられないと Rmd ファイルとして正しくない書式ということになります。チャンクが正しく入力できているかについて，常に注意を払っておく必要があります。また，自分でバッククォーテーション 3 つを使ってチャンク領域を開いたり閉じたりするのが面倒だ，という人は RStudio のチャンク挿入ボタンから挿入すると間違いないでしょう。

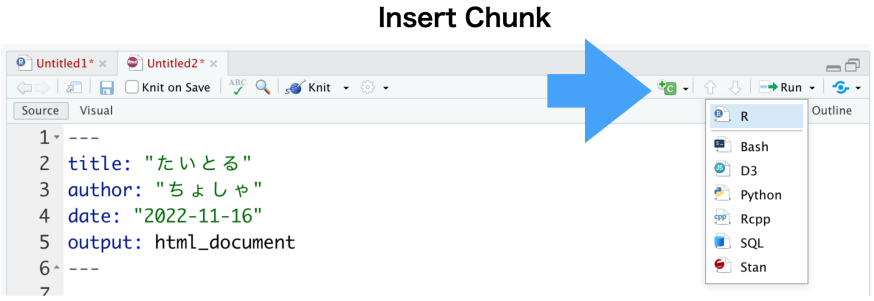

図 A.3　RStudio のチャンク挿入ボタン

A.1.3　FMC3；Rmd が knit できない

Rmd は文書作成に加えて，R での計算がセットになったファイル形式であり，文中の数字や分析結果は「書き写す」のではなく「その場で生成する」ものです。生成する，というのは Rmd ファイルを変換して，

HTML や DOCX，PDF 形式のファイルにすることを指します[*7]。このファイル変換を**ニット (knit)** といいます。編み物を編むようなイメージですね。このときに，タイトルをつけ，見出しのサイズを変え，R の計算をして結果を埋め込む作業をするわけです (図 A.4)。こうすることで，結果のコピペを避けること，再現性を担保することができるようになるわけです。すでに説明したように，チャンクを使って計算に必要な指示を Rmd ファ

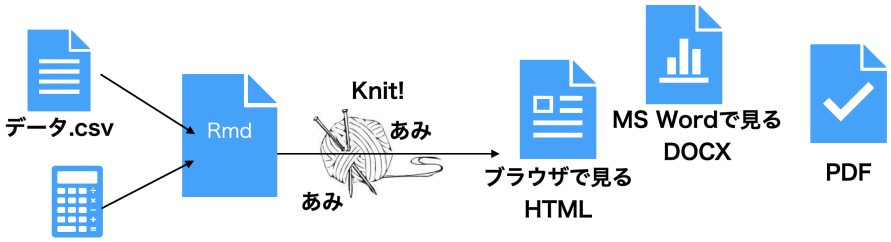

図 A.4 knit してレポートが完成する

イルに書きます。この指示はエラーのないコードである必要があります。当然ですが，スペルミスや間違った R コードは「実行できない」というエラーになるわけです。その場合，knit は中断され結果のファイルが出力されません。提出されたレポートは knit して出来上がったもののことを指しますから，knit できない Rmd ファイルを提出されてもレポートが提出されたことにはならないわけです。

knit できない Rmd ファイルになっていないか，というのはご自身の RStudio 環境で knit して確認できることです。提出前に一度，きちんと機能する Rmd ファイルになっているかどうか確認するようにしてください。以下で述べるように，自分の環境で knit できても，提出先の (私の) 環境で knit できないということもあり得ます。しかし，自分の環境で knit できないのに提出先でできる，ということはあり得ませんので，「knit できませんよ」というコメントをつけて返される前に自分で確認するようにしてください。

A.1.4 FMC4；外部環境を参照してしまう

さて，R で行う作業の中には，csv ファイルを読み込むといった「外部のファイルを使う」指示もありえます。例えば次のようなコードです。

code : A.1 Rmd 中の R コードが外部環境を参照してしまう

```
1  dat <- read.csv("social_effects.csv")
2  dat <- read.table("clipboard")
```

このコードでは，上の行は `social_effects.csv` というファイルを，下の行はクリップボードの内容を読み込むようになっています。ファイルを読み込む指示は，ファイルがなければ当然エラーになりますから注意が必要です。レポート等で Rmd ファイルを提出するとき，Rmd ファイルの他に必要な読み込むべきファイルがあれば一緒に提出するようにしてください。また，クリップボードの内容は再現できません。クリップボードとは，コピーアンドペーストのコピーを行ったとき，PC の内部で一時的にコピー内容を覚えておく場所のことです。つまり，みなさんがみなさんの環境で，クリップボード上にデータを一旦保持している場合は，このコードでエラーが生じることはありません。しかし，レポート提出先の (私の) 環境で，事前にデータのコピー作業を行なっているわけではないのですから，提出先でエラーが発生します。

[*7] HTML は Hyper Text Markup Language の略で，ブラウザで開くファイル形式です。DOCX は Microsoft Word のファイル形式です。PDF は Portable Document Format の略で，データを紙に印刷した状態のようにサイズを固定して出力したファイル形式であり，OS がもつビューワーや Adobe Acrobat Reader などで見ることができます。

そもそも Rmd ファイルは，作業の再現性を担保するためのファイルになっているわけですから，クリップボードの利用のような「自分の環境だけで可能な記録されない作業」をそのファイルに含めるのは適切ではありません。Rmd ファイルは Rmd ファイルだけで分析作業が完結するように，必要な記録は全て記載されている必要があります。同様に，分析作業に関係のない冗長な指示や無駄な指示は Rmd ファイルに含めるべきではありません。

A.1.5 FMC5；提出先の環境を変更してしまう

R はさまざまなパッケージを使って分析環境を拡張することができます。パッケージは **CRAN** を通じてインターネット経由で配布されますから，ネット環境があれば誰でも最新のパッケージをとってくることができます。みなさんが Rmd ファイルの中で使う R の関数の中には，パッケージの関数も含まれているでしょう。パッケージがなければ関数が動きませんから，パッケージをインストールする作業も Rmd に書いておきたいと思うかもしれません。しかし，これは推奨できません。

パッケージのインストールは，実行環境の準備にあたる作業です。Rmd ファイルを使ってコードのやり取りをするとき，提出先の環境で分析することになりますが，提出先の環境にどのようなパッケージをいつ入れるかは，提出先の環境の管理人が判断すべき問題です。提出する Rmd ファイルにパッケージをインストールする関数，すなわち `install.packages()` 関数が含まれているというのは，相手の環境を勝手に操作してしまうことと同じであり，セキュリティ的にも適切な発想ではありません。

環境の準備は提出先の管理人が管理すべき問題であり，またすでにパッケージが入っている場合は無駄な上書き作業をさせることにもなります。また `install.package` 関数は CRAN のサーバを参照したりしますから，適切な設定がなければ R チャンク実行時にエラーが発生します。いずれにせよ，R チャンクの中に `install.package` 関数を含めないようにしましょう。

以上が Rmd ファイルや R ファイルでレポートを提出するときの留意点です。その他にも R や RStudio を使うときによくある質問がありますので，それらも一問一答型で紹介しておきましょう。

A.2 Frequently Asked Questions；よくある質問と答え

Q. A.2.1: テキストを参考にパッケージをインストールしようとしたところ，エラーが発生しました。

A. 質問ではなくて報告ですね。お返事としては，「わかりました。エラーが発生して大変ですね。」としか言いようがありません。どの環境で，何をしようとして，どのようなエラーが出たのか，明示してください。メールのやり取りで指示が明確になるように，テキストを準備しています。何章，何ページの，どの文章を参考にしたのかも教えてください。

Q. A.2.2: 添付のようなエラーが発生しました (図 A.5)。対応策を教えてください。

A. エラーの発生画面を送ってこられていますが, この画面に写っていない上の方でエラーが発生していますから, これではどのエラーなのかわかりません。スクリーンショットを送ってこられることはよくありますが, ほとんどの場合, 適切な箇所が写っていません。複数枚添付してこられる人もいますが, 画面を拡大しながら読むのも難しいので, **R コードそのものを送ってきてください**。そうすると, 何行目のどこにエラーがあるかが明確になり, 対応に関係ない無駄なやり取り (ex.「もう少し上を写してください」「違う, もっと上」) が減ります。

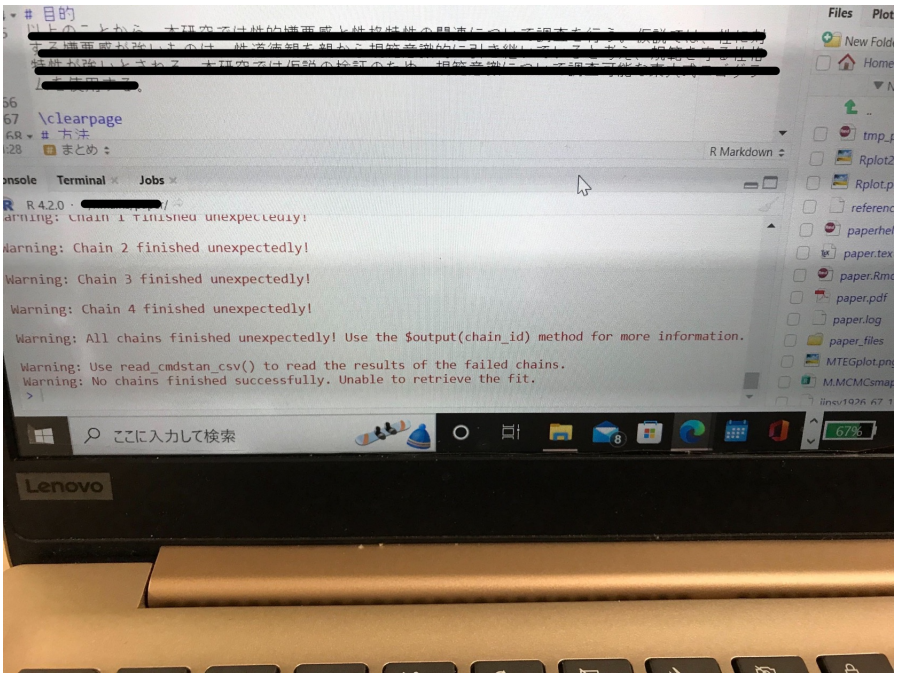

図 A.5 添付されてくるスクリーンショットの一例

Q. A.2.3: ファイルを読み込もうとすると次のようなエラーが出ます。どうすれば良いですか。

`'xxxxx'` に不正なマルチバイト文字があります

A. 文字化けの原因は, たとえば UTF-8 形式で提供されているファイルを, Windows 標準の CP932 形式で読み込もうとする, という文字コードの不一致です。ですからそれをオプションで指定してあげれば問題解決です。`read.csv` 関数を使っている場合, オプションの指定は `read.csv("foo.csv",fileEncoding="UTF-8")` のようにします。`tidyverse` の `read_csv` 関数を使っている場合, locale オプションで, locale 関数の encoding を明示的に UTF-8 とします。`read_csv("foo.csv", locale=locale(encoding = "UTF-8"))` のようにします。

Q. A.2.4: ファイルを読み込もうとすると次のようなエラーが出ます。どうすれば良いですか。

`'xxxxx'` に不正なマルチバイト文字があります

A. 文字化けの原因は，たとえば UTF-8 形式で提供されているファイルを，Windows 標準の CP932 形式で読み込もうとする，という文字コードの不一致です。ですからそれをオプションで指定してあげれば問題解決です。`read.csv` 関数を使っている場合，オプションの指定は `read.csv("foo.csv",fileEncoding="UTF-8")` のようにします。`tidyverse` の `read_csv` 関数を使っている場合，locale オプションで，locale 関数の encoding を明示的に UTF-8 とします。`read_csv("foo.csv", locale=locale(encoding = "UTF-8"))` のようにします。

Q. A.2.5: パッケージを読み込もうとすると次のようなエラーが出ます。どうすれば良いですか。

`library(tidyverse)` でエラー；`'tidyverse'` というパッケージはありません。

A. パッケージがないので，インストールしてください。

Q. A.2.6: パッケージをインストールしようとすると次のようなエラーが出ます。どうすれば良いですか。

```
Warning in install.packages:
    'lib = "C:/Program Files/R/R-4.0.5/library"' is not writable
```

A. ユーザがファイルに書き込みをする権限を持っていないので，(パッケージファイルをドライブに) 書き込みできないというエラーです。RStudio を実行する時に，「管理者として実行」を選びましょう。

Q. A.2.7: パッケージをインストールしようとすると次のようなエラーが出ます。どうすれば良いですか。

```
Warning in install.packages:
    ディレクトリ 'C:〜(任意の文字列)〜\????' を作成できません。理由は
```
```'Invalid argument' です。```

A. ユーザ名が全角文字を含んでいるため, 文字化けして R 側から操作ができません。解決する方法は二つあります。

ユーザを作り直す方法 ユーザ名に全角文字を含まない, 新しいユーザを作成します。設定＞アカウントから新しいアカウントを作りましょう。

インストールフォルダを指定する R のコンソールで `.libPaths()` と実行すると, パッケージをインストールするフォルダが出てきますが, ここを変更する方法です。次の 2 ステップで対応できます。

- まず C ドライブのすぐ下にインストール先のフォルダを作ります。`myLib` としましょう。
- 次に R のコンソールで `.libPaths("C:/myLib")` 書いて実行します。

これでインストール先が変わりますので, 書き込み・インストールができるようになります。老婆心ながら付け加えますと, フォルダ名はなんでも構いませんが, 全角文字ではいけません。また場所も C ドライブのすぐ下である必要はありませんが, 全角文字や空白を含むフォルダの下に入れてしまってはいけません。OndDrive のようなクラウドを指定するのも良くありません (探しに行った時にオフラインだとまたエラーになります)。
```

Q. A.2.8: ファイルが読み込めません

```
file(filename, "r", encoding = encoding) でエラー:
  コネクションを開くことができません
 追加情報:  警告メッセージ:
 file(filename, "r", encoding = encoding) で:
  ファイル 'foo.csv' を開くことができません: No such file or directory
```

A. 指定された場所にファイルがないので，読み込むことができないエラーです。確認すべきは，「プロジェクトを開いているか」，「プロジェクトフォルダの中に当該ファイルはあるか」，「ファイル名のミススペルはないか」です。プロジェクトってなんだという人は，RStudio の基本に立ち戻り，プロジェクトでファイルやフォルダを管理するようにしてください。プロジェクト管理については，Pp.40 にもその説明があります。

プロジェクトによる管理とは要するに，R が今見ているフォルダの場所を固定する方法です。プロジェクトを開くと，プロジェクトフォルダが「今見ているフォルダ (ワーキングディレクトリ)」になりますので，その中のファイルを参照することになります。プロジェクトフォルダの中に当該ファイルがないと読み込むことができませんので[a]，当該ファイルをプロジェクトフォルダ内に移してきてください。

Rmarkdown や Quarto ファイルの場合も，必ずプロジェクトフォルダの中に置くようにしてください。これらは Knit するときはファイルの置かれた場所を WorkingDirectory にしますので，プロジェクトフォルダの中にないとパスが通らない問題が頻発します。

[a] フォルダの位置を相対的・絶対的に指定してやれば，どこにおいていても読み込むことはできますが，この問題で悩んでいる人は相対・絶対パスの指定というところでさらに疑問が深まることになると思いますので，気にしないでくれて結構です。相対・絶対パスが知りたい人は，付録 2,26 でファイル場所とは何かを再確認してください)。

Q. A.2.9: ANOVA 君が読み込めません

```
file(filename, "r", encoding = encoding) でエラー:
  コネクションを開くことができません
 追加情報:  警告メッセージ:
 file(filename, "r", encoding = encoding) で:
  ファイル 'http:/riseki.php.xdomain.jp/index.php?plugin=attach&refer=
  ANOVA 君&openfile=anovakun_486.txt' を開くことができません: Invalid argument
```

A. ファイルを読み込みにいく先が URL，すなわちインターネット上になっています。ANOVA 君のファイルを一度手元の PC のフォルダにダウンロードし，そのローカルのファイルの位置を指定して読み込むようにしてください。

Q. A.2.10: 効果量を求めるテキストのコードを実行すると，g ではなく d が出てしまうようなのですが，どうすればよいでしょうか。コードは次の通りです。

```
cohen.d(value ~ condition, data = dat, hedges.crrection = T)
```

A. Hedges の補正 (correction) のオプションが通っていません。スペルミスです。オプションのスペルが間違っているので無視されたので，関数名通り Cohen の d が算出されます。

Q. A.2.11: 描画の際に次のような注意が出てきます。これはどういう意味ですか。

```
Removed 671 rows containing missing values (geom_point).
```

A.「671 件の行で欠測値が含まれています」ということです。つまりデータセットの中に欠測値 (観測されていない，数値が入っていない行) が 671 件あったので，それは表示できませんでしたよ，という意味です。警告が嫌だということであれば，データセットの中で欠けているものを除外する必要があります。R の関数では，`na.omit` で欠測値を除外することができます。

Q. A.2.12: lm 関数を実行するコードでオブジェクトがないと言われます。

```
result <- lm( weight - height, data = dat)
```

A. 従属変数と独立変数とをつなげるのはチルダ (~) という記号です。そこがハイフン (-) になっています。スペルミスの一種です。

Q. A.2.13: lm 関数を実行するコードでオブジェクトがないと言われます。

```
result <- lm( weight - height )
```

A. データを与えていないので，`weight` というオブジェクトを探しに行って，見つからないというエラーです。`data` オプションでデータを与えてあげてください。

Q. A.2.14: 因子分析の Robust 法での RMSEA の p 値って超えてたらまずいですか。Standard(DWLS) の方だけで報告はだいじょぶでしょうか。

A. 非常に専門的な質問をしておられますが，まず，「因子分析」「Robust 法」「RMSEA」など，個々の用語の意味はわかっているでしょうか。キーワードによる検索で，「ロバスト法とは」「Robust の意味」などは答えが出てくると思いますが，これらを分析法の体系的な文脈の中に位置付けないと，答えられない種類の問題です。この例をもとに説明すると，Robust を辞書で引くと「壮健」「たくましいこと」などと出てきますが，もちろんそういう意味ではありません。ロバスト法を検索すると，「統計学の分野でロバスト推定法というやり方がある」「観測値に外れ値が含まれている可能性を考え，その影響を抑えることを目的とした手法」などの説明が出てきます。ロバスト推定法は因子分析に限らず，回帰分析など他の手法でも使われる考え方なので，このような一般的な解説になります。ですがここで知りたいのは「因子分析におけるロバスト推定」ですから，因子分析でロバスト推定するとはどういうことか，因子分析の観測値における外れ値とは何か，因子分析における推定とは何を推定するのか，そもそも因子分析とは何を目的としているのか，なぜ自分は因子分析方を使うのか，さらに何故因子分析の中のロバスト推定を使いたいと思っているのか，といったことがわかっていないと，この質問に正しく回答することができないのです。このように，複合的な要素について一回で質問しても，適切な答えに辿り着けないことがあります。聞くことは恥ずかしいことではありません。知らないことを知っているふりをすることが恥ずかしいことであり，知らないまま「みんなそうやっているから」「テキスト/ネットに書いてあったから」と看過してしまうことこそ恥ずべきことなのです。ちなみに，質問に対する回答を間違えることも恥ずかしいことではありませんから，「正しく答えられなければ恥をかく (から質問しない)」というのも同様に恥ずべきことです。こうした恥ずかしさ (保身) から，「専門用語を使ってそれっぽく質問してわかった感じになろう」というのは，かえって遠回りになります。実は回答よりも，質問の仕方でその人の理解度が明らかになってしまっています。このように書くと，なんでも反射的に「わかりません，教えてください」という人もいますが，それも適切な質問方法ではありません。教員がアドバイスできるのは，「答え」ではなく「理解」が欲しい人に対してだけなのです。質問する場合は，自分は何がわかっていて何がわかっていないのか，何が知りたいのかを明確に言語化して質問するようにしてください。

8621

付録 B

ギリシア文字一覧

ギリシア文字ってかっこいいけど，読み方わからない･･･という人のための一覧。ついでに TEX 表記も。

表 B.1　ギリシア文字とその読み方

読み方	大文字	小文字	英語表記	TEX 表記
アルファ	A	α	alpha	`\alpha`
ベータ	B	β	beta	`\beta`
ガンマ	Γ	γ	gamma	`\gamma`
デルタ	Δ	δ	delta	`\delta`
エプシロン	E	ε	epsilon	`\varepsilon`
ゼータ	Z	ζ	zeta	`\zeta`
イータ	H	η	eta	`\eta`
シータ	Θ	θ	theta	`\theta`
イオタ	I	ι	iota	`\iota`
カッパ	K	κ	kappa	`\kappa`
ラムダ	Λ	λ	lambda	`\lambda`
ミュー	M	μ	mu	`\mu`
ニュー	N	ν	nu	`\nu`
クサイ	Ξ	ξ	xi	`\xi`
オミクロン	O	o	omicron	`\mathrm{o}`
パイ	Π	π	pi	`\pi`
ロー	R	ρ	rho	`\rho`
シグマ	Σ	σ	sigma	`\sigma`
タウ	T	τ	tau	`\tau`
ウプシロン	U	υ	upsilon	`\upsilon`
ファイ	Φ	ϕ	phi	`\phi`
カイ	X	χ	chi	`\chi`
プサイ	Ψ	ψ	psi	`\psi`
オメガ	Ω	ω	omega	`\omega`

付録 C

よいデータの形式とは

ここでは，データをどのように準備するかについて説明します。

みなさんはこれまで，学校の授業や自由研究などでデータを収集し，データを使って・作って集計したり分析したりしたことがあるかもしれません。その際はデータの入力の仕方について，テキストや資料通りに進めたかもしれませんが，実際に自分で研究をするときは「どのようにデータを入力するか」も自分で考えることになります。このとき，分析しにくい形でデータを作ってしまうと，後で分析に苦労することになります。そこで，分散分析を行う際に適したデータの形について説明しておきます。

データが数件しかないのであれば，これまでのように手入力することになるでしょう。しかしデータが多くなってくると，入力するところだけは表計算ソフトを使う方が便利です[*1]。このときに注意すべきことは，**1 つのセルには 1 つのデータしか入れない**ということです。これからデータを色々加工していきますが，加工する前のデータはなるべくプレーンな状態であったほうが良いのです (すでに加工された食材を違う料理に利用するのは大変ですから！)。

たとえば図 C.1 は，悪いデータファイル作成の例です。これをまずはじっくり眺めて，どこがまずいのか考えてみてください。少なくとも 7 つの点で問題があります。

図 C.1　分析に不向きなデータファイル

[*1] データを入力するために使い，その後の分析はすべて R でやるのが得策です。表計算ソフトで平均や分散などの数値を特定のセルに計算してしまうと，それを読み込んで R で分析するときに邪魔になります。とったデータだけの生のデータ (ローデータといいます) は R で読み込み可能な CSV 形式などで保存し，以降の処理はすべて記録の残る R でやるようにしましょう。

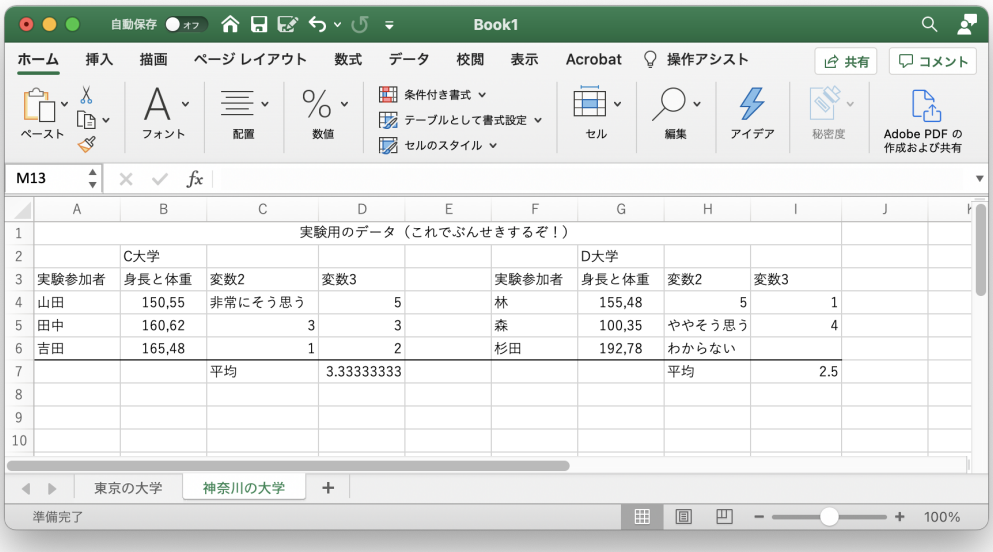

分析しにくいよくないデータになっているのは次の箇所です。

1. 1 行目にこの表のタイトルのようなものが入っていますが，これは分析には使わない情報なので不要です。
2. 1 行目はセルを結合しています。データセットは `data.frame` 型のように矩形であるべきなので，データのサイズを狂わせる行の存在は不適切です。
3. 2 行目には大学名が入っているようです。A から D 列は C 大学，F から I は D 大学のデータのようですが，1 つのデータセットに複数のデータが混在しているのはよくありません。
4. 身長と体重，という変数名のところには 1 つのセルに複数の数字が入っています。カンマで区切られており，見た目にはわかりますが，機械的には (カンマのせいで) 数字ではなく文字列として扱われます。データがデータになっていないのです。
5. 変数 2 の列は「非常にそう思う」という言葉の回答と，数字が入っています。1 つの列の中に複数の種類のデータが含まれるので分析できません (文字と数字の集計ができない。ちなみにこの場合は文字変数として扱われます)。
6. 7 行目に平均とありますが，データの平均はデータから計算できる量なので，R で算出するものです。データの中に計算結果を入れておくべきではありません。
7. I 列 6 行目，D 大学の杉田さんに関する変数 3 の箇所が空欄です。これはデータが入手できなかったところかもしれませんが，これは欠測値であることを明示すべきです。
8. 「東京の大学」と「神奈川の大学」という複数のシートがあります。データファイルとしては 1 つのシートにすべての情報が入っていなければなりません。同時に分析できるデータなのであれば，一枚のシートにまとめるべきです。

皆さんはいくつ気づいたでしょうか。これらの問題点を通じて言えることは「1 つのデータセット，1 つのセルには過不足ない情報を入れる」ということです。表を作って見せるのであればこのような入力でも良いのですが，ここでは数値データを分析することが目的なのですから，レイアウトや数字でない情報，計算してここから作れる情報は，分析に必要のない過剰な情報なのです。ちなみにアンダーラインや文字色，セルの色などは分

析のときに自動的に抜け落ちます (データではない情報なので)。表計算ソフトは数字を表にして計算するソフトウェアであり，方眼用紙やレイアウトする文書とは異なることを意識しましょう。

加えて分析のときに不便なのは，文字と数字の関係です。1 つのセルに複数の数字が入る場合，区切り記号などをつけることが多いかと思いますが (スペースも機械にとっては文字です！)，こうした文字種・変数の種類・水準が混在しているのも情報過多ということになります。

今回の問題点を修正したのが図 C.2 のようなデータセットです。単一のデータセットで完結しています。また 1 つの列に一種類の変数，不要な情報はなく，過剰な情報もないデータセットになっているのがわかるかと思います。なお，変数 3 のところに `NA` とあるのは `No Answer` の略で**欠測値 (missing value)** を意味しています。これは読み込むときに，欠測値をどのような文字にしているか，という指定ができますので問題になりません。

図 C.2　分析に適したデータファイル

	A	B	C	D	E	F	G
1	実験参加者	地域	所属大学	身長	体重	変数2	変数3
2	山田	神奈川	C	158.1	62.3	非常にそう思う	1
3	田中	神奈川	C	149.7	55.3	非常にそう思う	5
4	吉田	神奈川	C	158.2	53.9	非常にそう思う	3
5	林	神奈川	D	149.5	53.8	ややそう思う	2
6	森	神奈川	D	158.7	54	非常にそう思う	4
7	杉田	神奈川	D	161.8	57.6	非常にそう思う	5
8	久保田	東京	A	168.5	55.2	ややそう思う	6
9	悲鳴嶼	東京	A	155.7	57.9	非常にそう思う	2
10	荒木	東京	A	151.1	60.8	非常にそう思う	3
11	荒尾	東京	B	156.9	63.3	ややそう思う	2
12	田邊	東京	B	156	56.5	非常にそう思う	NA
13	末次	東京	B	163.3	59.6	わからない	5
14	青山	東京	B	158.6	59.7	非常にそう思う	3
15	諫山	東京	B	154.7	55.9	非常にそう思う	NA
16							

このように，データの入力の基本は，**1 行に 1 ケースの情報が入っている，過不足のない 1 つのデータセットを作ること**である，と言えます。

このようにして作られたデータファイルは，UTF-8 の文字コードによる csv 形式で保存するのが基本です (→ 第 2 講，2.4 節，Pp.23 参照)。ファイルを保存するときに，ファイル形式をしっかり指定し，拡張子も `.csv` にしましょう。csv ファイルは ASCII ファイルですし，文字コードも世界基準の UTF-8 にしておけばどの PC からでもみることができます。ある一企業が開発した特定の OS，特定のアプリケーションを持っていなければデータを見ることができない，というのは科学的研究の観点からは不適切なのです。

ちなみに 2020 年 12 月，総務省により機械判読可能なデータの表記方法の統一ルールが策定されました (総務省，2020)。それには次のようなチェック項目が含まれています。

チェック項目 1-1　ファイル形式は Excel か CSV となっているか
チェック項目 1-2　1 セル 1 データとなっているか
チェック項目 1-3　数値データは数値属性とし，文字列を含まないこと
チェック項目 1-4　セルの結合をしていないか
チェック項目 1-5　スペースや改行等で体裁を整えていないか
チェック項目 1-6　項目名を省略していないか
チェック項目 1-7　数式を使用している場合は，数値データに修正しているか
チェック項目 1-8　オブジェクトを使用していないか
チェック項目 1-9　データの単位を記載しているか
チェック項目 1-10　機種依存文字を使用していないか
チェック項目 2-1　データが分断されていないか
チェック項目 2-2　1 シートに複数の表が掲載されていないか

みなさんも自分でデータを作るときは，こうした基準に沿うように心がけてください。また表計算ソフトの中で，代表値を計算したりグラフを書いたりしたくなりますが，みなさんは既に統計環境を手に入れているのですから，そうした加工・可視化などは R のほうでやり，データは「誰が触っても良いプレーンな素材」として保管しておくように心がけましょう。

付録 D

分散分析ワークシート

このワークシートでは，実験データから効果の大きさや平方和を計算する練習をします。表の空欄を埋めながら，データの散らばりがどのように分解されるかを確認しましょう。

課題 1：一要因 3 水準の分散分析

ある実験で，3 つの条件（A，B，C）に被験者を割り当て，課題の成績を測定しました。以下の表を完成させなさい。

表 D.1　一要因 3 水準のデータ

被験者 ID	条件	スコア	全体平均	群平均	効果	誤差
1	A	12				
2		14				
3		16				
4		18				
5	B	10				
6		12				
7		14				
8		16				
9	C	16				
10		18				
11		20				
12		23				

計算欄：

条件 A の平均：＿＿＿＿＿＿＿＿

条件 B の平均：＿＿＿＿＿＿＿＿

条件 C の平均：＿＿＿＿＿＿＿＿

全体平均：＿＿＿＿＿＿＿＿

平方和の計算：

条件 A の効果：＿＿＿＿＿＿＿＿

条件 B の効果：＿＿＿＿＿＿＿＿＿＿

条件 C の効果：＿＿＿＿＿＿＿＿＿＿

条件間平方和（SS_between）：＿＿＿＿＿＿＿＿＿＿

誤差平方和（SS_error）：＿＿＿＿＿＿＿＿＿＿

全体平方和（SS_total）：＿＿＿＿＿＿＿＿＿＿

確認： SS_total = SS_between + SS_error が成り立つか確認しましょう。

課題 2：二要因（2×2）の分散分析

ある実験で，2 つの要因（要因 A：2 水準, 要因 B：2 水準）を組み合わせた実験を行いました。以下の表を完成させなさい。

表 D.2　二要因（2×2）のデータ

ID	A	B	スコア	全体平均	A の効果	B の効果	交互作用	群平均	誤差
1	a_1	b_1	18						
2			20						
3			22						
4		b_2	10						
5			9						
6			14						
7	a_2	b_1	10						
8			12						
9			14						
10		b_2	16						
11			18						
12			20						

計算欄：

a_1b_1 群の平均：＿＿＿＿＿＿＿＿

a_1b_2 群の平均：＿＿＿＿＿＿＿＿

a_2b_1 群の平均：＿＿＿＿＿＿＿＿

a_2b_2 群の平均：＿＿＿＿＿＿＿＿

全体平均：＿＿＿＿＿＿＿＿

主効果の計算：

a_1 水準の平均：＿＿＿＿＿＿＿＿ → 要因 A の効果（a_1）：＿＿＿＿＿＿＿＿

a_2 水準の平均：＿＿＿＿＿＿＿＿ → 要因 A の効果（a_2）：＿＿＿＿＿＿＿＿

b_1 水準の平均：＿＿＿＿＿＿＿＿ → 要因 B の効果（b_1）：＿＿＿＿＿＿＿＿

b_2 水準の平均：＿＿＿＿＿＿＿＿ → 要因 B の効果（b_2）：＿＿＿＿＿＿＿＿

交互作用の計算：

a_1b_1 の交互作用：＿＿＿＿＿＿＿＿

a_1b_2 の交互作用：＿＿＿＿＿＿＿＿

a_2b_1 の交互作用：＿＿＿＿＿＿＿＿

a_2b_2 の交互作用：＿＿＿＿＿＿＿＿

平方和の計算：

要因 A の平方和（SS_A）：＿＿＿＿＿＿＿＿

要因 B の平方和（SS_B）：＿＿＿＿＿＿＿＿

交互作用の平方和（SS_AB）：＿＿＿＿＿＿＿＿

誤差平方和（SS_error）：_____

全体平方和（SS_total）：_____

確認： SS_total = SS_A + SS_B + SS_AB + SS_error が成り立つか確認しましょう。

課題 3：一要因 3 水準の群内計画（Within デザイン）

ある実験で，同じ 5 人の被験者に 3 つの時期（Time1，Time2，Time3）で測定を行いました。以下の表を完成させなさい。

表 D.3　群内計画のデータ

ID	時期	スコア	全体平均	個人差	効果	誤差
A	Time1	48				
	Time2	48				
	Time3	40				
B	Time1	49				
	Time2	51				
	Time3	45				
C	Time1	58				
	Time2	59				
	Time3	46				
D	Time1	46				
	Time2	44				
	Time3	37				
E	Time1	52				
	Time2	52				
	Time3	46				

計算欄：

ID=A の平均：＿＿＿＿＿＿＿＿

ID=B の平均：＿＿＿＿＿＿＿＿

ID=C の平均：＿＿＿＿＿＿＿＿

ID=D の平均：＿＿＿＿＿＿＿＿

ID=E の平均：＿＿＿＿＿＿＿＿

Time1 の平均：＿＿＿＿＿＿＿＿

Time2 の平均：＿＿＿＿＿＿＿＿

Time3 の平均：＿＿＿＿＿＿＿＿

全体平均：＿＿＿＿＿＿＿＿

個人差の計算：

ID=A の個人差：＿＿＿＿＿＿＿＿

ID=B の個人差：＿＿＿＿＿＿＿＿

ID=C の個人差：＿＿＿＿＿＿＿＿

ID=D の個人差：＿＿＿＿＿＿＿＿

ID=E の個人差：＿＿＿＿＿＿＿＿

時期の効果の計算：

Time1 の効果：＿＿＿＿＿＿＿＿

Time2 の効果：＿＿＿＿＿＿＿＿

Time3 の効果：_____

平方和の計算：

個人差の平方和（SS_S）：_____
時期の効果の平方和（SS_A）：_____
誤差平方和（SS_E）：_____
全体平方和（SS_T）：_____

確認： SS_T = SS_A + SS_S + SS_E が成り立つか確認しましょう。

引用文献

Amrhein, V., Greenland, S., & McShane, B. (2019). Scientists rise up against statistical significance. Nature, 567, 305–307. https://doi.org/10.1038/d41586-019-00857-9

Bürkner, P.-C. (2017). brms: An R Package for Bayesian Multilevel Models Using Stan. Journal of Statistical Software, 80 (1), 1–28. https://doi.org/10.18637/jss.v080.i01

Bürkner, P.-C. (2018). Advanced Bayesian Multilevel Modeling with the R Package brms. The R Journal, 10 (1), 395–411. https://doi.org/10.32614/RJ-2018-017

ギルボア I. (2014). 不確実性下の意思決定理論　勁草書房(Original work published 2009)

南風原 朝和 (2002). 心理統計学の基礎――統合的理解のために――　有斐閣

浜田 宏・石田 淳・清水 裕士 (2019). 社会科学のためのベイズ統計モデリング　朝倉書店

蛇蔵 (2014). 決してマネしないでください。(1)　講談社コミックス

平川 真 (2021). 2 変数の関係を表す統計量の推定　清水 裕士(編) 心理学統計法 (pp. 150–162)　放送大学教育振興会

池田 功毅・平石 界 (2016). 心理学における再現可能性危機:問題の構造と解決策　心理学評論, 59 (1), 3–14. https://doi.org/10.24602/sjpr.59.1_3

池内 了 (2014). 宇宙論と神 (集英社新書)　集英社

アイザクソン W. (2011). スティーブ・ジョブズ　講談社(Original work published 1995, JSTOR)

JASP Team (2025). JASP (Version 0.95.1)[Computer software].

椎名 乾平 (2013). 七つの正規分布　心理学評論, 56 (1), 7–34. https://doi.org/10.24602/sjpr.56.1_7

小杉 考司 (2018). 言葉と数式で理解する多変量解析入門　北大路書房

クルシュケ J.K. (2017). ベイズ統計モデリング: R, JAGS, Stan によるチュートリアル 原著第 2 版　共立出版(Original work published 2014, Elsevier)

Kruschke, J. K. (2018). Rejecting or accepting parameter values in Bayesian estimation. Advances in Methods and Practices in Psychological Science, 1 (2), 270–280.

Lambert, B. (2018). A Student's Guide to Bayesian Statistics (1st ed.) SAGE Publications Ltd.

リー M.D ・ワゲンメーカーズ E-J. (2017). ベイズ統計で実践モデリング: 認知モデルのトレーニング　北大路書房(Original work published 2013, Cambridge University Press)

Makowski, D., Ben-Shachar, M. S., & Lüdecke, D. (2019). bayestestR: Describing Effects and their Uncertainty, Existence and Significance within the Bayesian Framework. Journal of Open Source Software, 4 (40), 1541. https://doi.org/10.21105/joss.01541

マオール E. (1999). 不思議な数eの物語　筑摩書房(Original work published 1994, Princeton University Press)

Matejka, J. & Fitzmaurice, G. (2017). Same stats, different graphs: generating datasets with varied appearance and identical statistics through simulated annealingProceedings of the 2017 CHI conference on human factors in computing systems, 1290–1294.

松村 優哉・湯谷 啓明・紀ノ定 保礼・前田 和寛 (2021). 改訂 2 版 R ユーザのための RStudio[実践] 入門 ——tidyverse によるモダンな分析フローの世界—— 技術評論社

シャロン・バーチュ・マグレイン (2018). 異端の統計学ベイズ 草思社(Original work published 2011, Yale University Press)

Merkle, E. C., Fitzsimmons, E., Uanhoro, J., & Goodrich, B. (2021). Efficient Bayesian Structural Equation Modeling in Stan. Journal of Statistical Software, 100 (6), 1–22. https://doi.org/10.18637/jss.v100.i06

Merkle, E. C. & Rosseel, Y. (2018). blavaan: Bayesian Structural Equation Models via Parameter Expansion. Journal of Statistical Software, 85 (4), 1–30. https://doi.org/10.18637/jss.v085.i04

道又 爾 (2009). 心理学入門一歩手前——「心の科学」のパラドックス—— 勁草書房

三中 信宏 (2018). 統計思考の世界——曼荼羅で読み解くデータ解析の基礎—— 技術評論社

水本 篤・竹内 理 (2011). 効果量と検定力分析入門 : 統計的検定を正しく使うために 2010 年度部会報告論集「より良い外国語教育のための方法」

長沼 伸一郎 (2016). 経済数学の直観的方法 確率・統計編 講談社

永田 靖・吉田 道弘 (1997). 統計的多重比較法の基礎 サイエンティスト社

西内 啓 (2017). 統計学が最強の学問である [数学編]——データ分析と機械学習のための新しい教科書 —— ダイヤモンド社

ノーレットランダーシュ T. (2002). ユーザーイリュージョン——意識という幻想—— 紀伊國屋書店 (Original work published 1999, Penguin)

繁桝 算男 (2019). ベイズ統計学 楠見 孝・日本心理学会 (編) 公認心理師の基礎と実践 5 心理学統計法 (pp. 275–296) 遠見書房

清水 裕士 (2016). フリーの統計分析ソフト HAD : 機能の紹介と統計学習・教育, 研究実践における利用方法の提案 メディア・情報・コミュニケーション研究, 1, 59–73.

Shimizu, H. (2026). BayesRTMB: Bayesian Inference Using 'RTMB'. R package version 0.2.4. https://doi.org/10.32614/CRAN.package.BayesRTMB. from https://CRAN.R-project.org/package=BayesRTMB

清水 優菜・山本 光 (2022). JASP で今すぐはじめる統計解析入門 講談社

下山 晴彦 (2001). 臨床心理学研究の多様性と可能性 下山 晴彦・丹野 義彦(編) 講座臨床心理学 (pp. 3–24) 東京大学出版会

Shojima, K. (2022). Test data engineering: latent rank analysis, biclustering, and bayesian network. Springer.

Stevens, S. S. (1946). On the theory of scales of measurement. Science, 103 (2684), 677–680.

末永 俊郎(編) (1987). 社会心理学研究入門 東京大学出版会

Torchiano, M. (2020). effsize: Efficient Effect Size Computation. R package version 0.8.1. https://doi.org/10.5281/zenodo.1480624. from https://CRAN.R-project.org/package=effsize

豊田 秀樹 (2009). 検定力分析入門——R で学ぶ最新データ解析ー—— 東京図書

豊田 秀樹 (2020). 瀕死の統計学を救え! 朝倉書店

Wasserstein, R. L. & Lazar, N. A. (2016). The ASA Statement on P-Values: Context, Process, and Purpose. The American Statistician, 70 (2), 129–133. https://doi.org/10.1080/00031305.2016.1154108

Wickham, H. (2014). Tidy Data. Journal of Statistical Software, 59, 1–23. https://doi.org/10.18637/jss.v059.i10

Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., … & Yutani, H. (2019). Welcome to the tidyverse. Journal of Open Source Software, 4 (43), 1686. https://doi.org/10.21105/joss.01686

吉野 諒三 (2007). 公理的測定論の基礎——心理表現の論理と実際—— 吉野 諒三・山岸 侯彦・千野 直仁(編) 数理心理学 (pp. 49–108) 培風館

ルネ・デカルト (1997). 方法序説 岩波書店(Original work published 1637)

総務省 (2020). 統計表における機械判別可能なデータ作成に関する表記方法

謙介 岡田 (2014). ベイズ統計による情報仮設の評価は分散分析にとって代わるのか?(閉じられた ANOVA とその先-心理統計の現状と将来を考える,2013 年度日本基礎心理学会第 1 回フォーラム) 基礎心理学研究, 32 (2), 223–231. https://doi.org/10.14947/psychono.KJ00009351488

索引

B

brms 371
BUGS 390

C

Cohen の d 201

E

EAP 推定値 355

F

F 検定 251, 405
F 分布 252, 321

G

ggplot2 377

H

HDI 371
Hedges の g 201

J

JAGS 390

M

MAP 推定値
　　最大事後確率 355
MED 推定値 355

P

p-hacking 201
p 値 186

Q

Q-Q プロット 328
QRPs 198

R

ROPE 371, 380
R^2 値 110, 117

S

Stan 371, 391

T

t 検定 207, 214, 215, 405
t 分布 178

W

Welch の補正 216

あ

一様分布 352
因果関係 103, 111
因果効果 359

か

回帰係数 109
回帰分析 109, 115
　　重回帰分析 115, 127, 135, 241, 281, 327
　　単回帰分析 115, 321
下位検定 261
カイ二乗 90
ガウス分布 58, 149
カウント 57
確信区間 355, 357, 361, 394
確率 141, 341
確率質量 143
　　確率質量関数 145
確率的プログラミング言語 153, 390
確率分布 57, 143
確率分布関数 143

確率変数 57, 142, 165
確率密度 144
　確率密度関数 145, 320
確率モデル 311, 324, 405
仮説 103
片側検定 210
カテゴリ 57
カテゴリカル分布 57
関数 105
間接効果 122
偽陰性 347
棄却 186, 194
棄却域 192, 210
記述統計 163
擬似乱数 388
期待値 145
帰無仮説 184, 190, 195, 360
帰無仮説検定 183, 359, 405
逆確率の法則 340
逆リンク関数 332
客観性 54
球状性の仮定 299
球状性の検定 297
偽陽性 347
共分散 84, 86
偶然誤差 149, 224, 227, 237, 321
区間推定 173, 175, 177
クラメールの V 91, 189
クロス集計表 83
群間要因 226, 281, 290
　対応のない 227
群内要因 226, 281, 290
　対応のある 227
系統誤差 149, 321
結果変数 147
欠測値 62, 425
決定係数 110
検定 181, 183
検定力 199, 201, 218
　検定力分析 201
効果量 201, 228, 360
交互作用 242
構成概念 56
交絡 223
誤差 107, 149
個人差 227, 282
古典的テスト理論 166
ゴルトンボード 150
混合効果モデル 331
混合要因計画 226

さ

再現性 54
最高密度区間 356, 363
最小値 72
最小二乗法 108, 115, 321, 326
最大値 72
採択 186, 194
最頻値 67
最尤推定値 313
最尤法 116, 313, 343, 405
　最尤推定 322
サヴェージ・ディッキー法 367, 385
残差 107, 110
残差診断 329
散布図 103
サンプルサイズ 165, 201
　例数設計 200, 201
サンプル数 165
事後確率 341
事後比較 261
事後分布 351, 353, 405
事後予測分布 400
指数関数 159
事前確率 341
事前分布 351, 353, 405
　共役事前分布 388
　無情報事前分布 352
実験群 225
実現値 166
実質的に等価な範囲 363
質的変数 54
私秘性の排除 14
四分位 72, 355

四分位範囲 72
尺度 187
尺度化 54
尺度水準 58
　間隔尺度水準 58, 60, 256, 374
　順序尺度水準 58, 59, 143, 256, 374
　比率尺度水準 58, 60, 225, 256, 374
　名義尺度水準 58, 143, 225, 240, 253, 256, 374
従属変数 106, 225
自由度 321
周辺化 365
周辺確率 338
周辺尤度 353, 365
主観確率 142, 341
主効果 243, 360
条件つき確率 338
情報仮説 368
信頼区間 177, 357, 361
信頼性 53
心理測定法 16, 53, 59, 187
水準 226
推測統計学 157, 163
推定値 175
推定量 175
数学的現象主義 13
スタナイン 72
正規分布 58, 131, 141, 149, 150, 224, 321
　多変量正規分布 297
　標準正規分布 153, 154
生成モデル 399
生成量 400
説明変数 106, 225
線形回帰 115
線形関数 105
線形モデル 115, 129, 232, 359
　一般化線形モデル 329, 406
　階層線形モデル 332
線形予測子 329
相関関係 103, 111
相関係数 84, 86
　スピアマンの順位相関係数 90, 91
　部分相関係数 119
　偏相関係数 120

た

対数 315
大数の法則 169
対数尤度 325
タイプ 1 エラー 199, 347, 360
タイプ 2 エラー 199, 201, 347, 360
対立仮説 184, 190, 195
多重共線性 122
妥当性 53
単純効果 304
中央値 67
中心極限定理 167
停止規則 369
適合度 110, 117, 130
点推定 173
統計的推定 165
同時確率 337
等裾区間 356
統制群 225
特徴量エンジニアリング 82
独立 338
独立同分布 318
独立変数 106, 225

な

二項分布 148, 149
二重盲検法 224

は

パーセンタイル 72, 355
バイナリ 57
箱ひげ図 76
外れ値 67
パラメータ 145
範囲 72
反復測定 227
被説明変数 106, 225
非線形関数 106
批判的思考 112
被覆率 400

標準化 87, 123, 157
標準化スコア 88
標準化偏回帰係数 124
標準誤差 170, 175
標準偏差 72
標本 164
標本抽出 164
標本統計量 165
標本平均 321
頻度主義 142, 341
不偏分散 174, 193, 321
分散 69
分散分析 239, 251, 321, 405
　分散分析表 255
平均因果効果 225
平均値 66
平均平方 252, 321
平均偏差 70
ベイジアンモデリング 406
ベイズファクター 365, 366, 371, 380
ベイズ法 116, 337, 343, 351, 362, 367, 385, 405
平方和 238, 245, 321
ベルヌーイ分布 57
偏回帰係数 118, 121
偏差値 88
変数 54
ポアソン分布 57
母集団 163, 359
母集団分布 166
母数 164

ま

マルコフ連鎖モンテカルロ法 388, 406
無作為標本抽出 164
メタ分析 332
モーメント法 171, 321, 343, 405
モデリング 406
モデル 15, 103, 105
問題のある研究実践 198
モンティ・ホール問題 348

や

有意水準 186, 199, 201, 360
優越率 400
尤度 313, 325, 341, 353, 405
尤度関数 313
要因 226
要因計画 359, 405
予測値 106

ら

乱数 388
ランダム化 224
ランダム化比較試験 179, 225
離散的 58
離散分布 143
リテラル 56
両側検定 210
量的変数 54
臨界値 192, 210
リンク関数 332
連続 57
連続分布 143

R・操作用語索引

B

brms 391

C

CRAN 33, 413

R

R 33
RStudio 34

か

コンソール 35

さ

作業フォルダ 27
式 129
整然データ 267
絶対パス 27
相対パス 27

た

チャンク 410
データフレーム 48

な

ニット 412

は

パッケージ 44
引数 43

ら

リスト 47
ロング型 267

わ

ワイド型 266